

从人类视频到机器人动作

EgoMimic 与 VidBot：方法、证据与复现进展

汇报人：_____

具身智能文献与复现实验汇报

2026 年 9 月



The Chinese University
of Hong Kong

汇报路线

- ① 问题与基础概念
- ② EgoMimic: 人机数据联合策略学习
- ③ VidBot: 从野外视频提取 3D 交互轨迹
- ④ 总结与方向讨论

结论 两篇论文共享同一目标：降低机器人示教成本；但学习目标不同——EgoMimic 学策略，VidBot 学可迁移的 3D 交互轨迹。

Outline

① 问题与基础概念

② EgoMimic: 人机数据联合策略学习

③ VidBot: 从野外视频提取 3D 交互轨迹

④ 总结与方向讨论

共同问题：机器人数据昂贵，人类视频丰富

EgoMimic

输入：第一人称人手数据 + 机器人示教

输出：可直接预测机器人动作的联合策略

关键词：跨域对齐、共享表征、多头监督

VidBot

输入：网络中的普通单目人类视频 + 语言

输出：接触点与 3D 末端轨迹


关键词：SfM、深度、可供性、扩散轨迹



Outline

- ① 问题与基础概念
- ② EgoMimic: 人机数据联合策略学习
- ③ VidBot: 从野外视频提取 3D 交互轨迹
- ④ 总结与方向讨论

EgoMimic 方法总览



来源: Kareer et al., *EgoMimic*, 2024, Fig. 1.

人类数据与机器人数据的原始差异



差异	人类域	机器人域
形态	手/身体	连杆/夹爪
状态	3D 手位姿	关节、EE、夹爪
视角	头戴相机	顶视 + 腕部相机
速度	快、自然	慢、受控制约束
外观	手遮挡	机械臂遮挡

结论 不能把两个 HDF5 简单拼接：至少要解决“同一个动作如何表达、同一个场景如何看起来相近、缺失字段由谁监督”。

来源：Kareer et al., 2024, Sec. III-B/C；项目数据字段与加载代码。

跨域对齐：把“可共享部分”映射到同一语义

1. 坐标系对齐

人手未来位置通过 Aria MPS/SLAM 变换到当前相机坐标系；机器人 EE 由 FK + 手眼标定得到相机坐标。

$${}^{C_t}p_{t+k} = T_{C_t \leftarrow W} T_{W \leftarrow C_{t+k}} {}^{C_{t+k}}p_{t+k}$$

2. 时间对齐

同为 100 个未来点：人类覆盖约 1 s，机器人覆盖约 4 s，相当于把手运动“放慢”到机器人节奏。

3. 数值分布对齐

每个域分别做 Gaussian / Z-score 归一化：

$$\tilde{a}^{(d)} = (a^{(d)} - \mu_d) / (\sigma_d + \epsilon)$$


避免一个域的量纲和方差支配梯度。

“对齐”不等于数据完全相同

共享的是末端运动语义；机器人关节、夹爪、腕部图像仍保留为机器人专属信号。

来源：Kareer et al., 2024, Sec. III-C; Supplementary Sec. VI.

视觉外观对齐：mask 掉 embodiment，再保留运动方向



你下载的数据：human / robot 原图、mask 与对齐后输入


来源：本地 bowlplace 数据可视化；Kareer et al., 2024, Fig. 4 与 Table IV.

- 🕒 SAM2 分割人手或机械臂；
- 🕒 将实体区域遮蔽，减小形态与纹理差异；
- 🕒 叠加红色方向线，避免把与动作有关的信息全部删掉。

mask 与动作线索的平衡

消融中去掉方向线、进一步去掉 mask，性能继续下降；视觉对齐既要“去域差异”，也要“留动作线索”。

统一策略架构：共享主干 + 域专属输入/输出头



共享

前视 RGB 编码器 (ResNet18) 与 ACT Transformer: 共同学习“场景—目标—运动”的规律。


域专属

输入投影与输出头不同; 机器人额外使用腕部图像、关节和夹爪监督。

$$\begin{aligned}\mathcal{L}_R &= \|\hat{a}_R^{pose} - a_R^{pose}\|_1 \\ &\quad + \|\hat{a}_R^{joint} - a_R^{joint}\|_1 + \text{KL}, \\ \mathcal{L}_H &= \|\hat{a}_H^{pose} - a_H^{pose}\|_1 + \text{KL}.\end{aligned}$$

来源: Kareer et al., 2024, Fig. 5; 项目 `algo/act.py` 与双数据加载逻辑。

人机数据联合训练过程



共同梯度


两域损失在同一优化步骤内汇总（代码中做平均），一起更新共享视觉与 Transformer 参数。

缺失维度

人类没有关节/夹爪标签：不填假值、不计算对应损失；这些头只由机器人 batch 学习。

来源：EgoMimic 开源实现：双 DataLoader / training step / ACT policy wrapper。

全机器人、人类与混合数据的实验对比



论文采用的比较方式

等采集时间比较：2 h robot + 1 h human 的 EgoMimic 得分 128；3 h robot 的 ACT 得分 74。

论文未覆盖的严格对照

没有“相同轨迹条数”的全机器人 / 全人 / 混合三方对比；且纯人类数据缺少机器人关节与夹爪监督，不能直接构成完整部署策略。

合理的控制组

EgoMimic w/o Human 保持架构不变，只去掉人类数据，用于隔离人类数据的增益。

来源：Kareer et al., 2024, Fig. 8、Table II/III。1 h human 约 1400 条，1 h robot 约 135 条，因此“等时间”并非“等条数”。

论文证据：各模块对性能的贡献

方法	Bowl 得分	Laundry SR	Grocery SR
ACT	39	55%	22%
MimicPlay	71	50%	8%
EgoMimic w/o H	68	73%	28%
EgoMimic	128	88%	30%

Bowl 消融	得分
Full / 去线 / 再去 mask	128 / 112 / 95
再去 action norm / 去 human	79 / 68

创新点不是单一模块

➊

可扩展的人类第一视角采集；

➋

面向人机共享的动作与视觉对齐；

➌

共享策略主干 + 域专属头；

➍

在长时程、双臂任务中验证规模效应。

来源：Kareer et al., 2024, Table III/IV。指标定义因任务而异，勿横向混成同一“准确率”。

EgoMimic 复现



左：人类域；右：机器人域

绿色：真实未来轨迹 紫色：模型预测
红色：机器人末端位姿预测头

结果

- ▶ 训练正常完成，human 与 robot 两个域均能生成连续未来轨迹；
- ▶ 从首次验证到最后一次验证，paired MSE 分别下降约 25.4% 和 23.1%；
- ▶ 两个域的最低验证误差均出现在约 epoch 400，随后略有回升。

结果分析


预测已经捕捉到主要运动方向，短期轨迹通常与真实轨迹接近。偏差主要出现在长预测段和终点，部分样本呈现平滑化或平均化。后续闭环测试应优先比较 epoch 399 与最终 checkpoint。

来源：本地验证代码与第 50–450 轮验证日志；MSE 数值仅用于同一域内纵向比较。

Outline

- ① 问题与基础概念
- ② EgoMimic: 人机数据联合策略学习
- ③ VidBot: 从野外视频提取 3D 交互轨迹
- ④ 总结与方向讨论

VidBot: 把视频变成机器人可消费的 3D 动作



训练时学习

从普通人类视频恢复 $a = \{c, \tau\}$: 3D 接触点 c 与交互轨迹 τ 。

来源: Chen et al., VidBot: Learning Generalizable 3D Actions from In-the-Wild 2D Human Videos, CVPR 2025, Fig. 1.

测试时执行

给机器人 RGB-D 场景与语言指令, 生成候选 3D 轨迹, 再交给 IK / 规划 / 控制执行。

数据准备：单目 RGB 获得 3D 监督



SfM 的作用


Structure from Motion: 利用多帧特征匹配同时估计相机内参/位姿与稀疏三维点。它提供跨帧几何关系，但整体尺度不确定。

度量深度来源

使用预训练的 metric depth 模型得到每帧稠密深度；它补足尺度与稠密几何，但逐帧预测会有时间不一致。

来源：Chen et al., 2025, Sec. III-B; 其数据来源基于 EPIC-KITCHENS-100 / EPIC Fields 的预计算 SfM。

一致位姿优化：SfM 与深度的再对齐



- ① 用静态背景点比较 SfM 深度与 metric depth，估计全局尺度；
- ② 再优化逐帧相机 pose 与深度尺度，使静态场景跨帧一致；
- ③ 从每帧手 mask 求手中心像素 (u_t, v_t) ，结合深度反投影成 3D；
- ④ 用优化后的位姿把所有点变换到第 0 帧：


$$p_t^{C_0} = T_{C_0 \leftarrow W} T_{W \leftarrow C_t} (D_t(u_t, v_t) K^{-1} [u_t, v_t, 1]^T).$$

核心

相机在动，但任务轨迹需要一个稳定参考系；因此“统一到第 0 帧”是在消除相机自身运动。

来源：Chen et al., 2025, Fig. 2 与 Sec. III-B.

三维可供性的粗细两阶段模型



粗可供性模型：接触点与目标点

视觉 + 语言预测 2D contact / goal 概率图；
接触点深度可从物体表面读取，而 goal 可能在自由空间，因此额外预测 goal depth。

细可供性模型：完整交互轨迹

1D U-Net 扩散模型以接触、目标、语言、物体特征和 TSDP 场景特征为条件，生成完整 3D 轨迹 τ 。

来源：Chen et al., 2025, Fig. 3 与 Sec. III-C.

Language 条件与测试时轨迹筛选

语言条件

指令如 “*open the microwave*” 经 CLIP 编码：

- ▶ 条件化 contact / goal 热图；
- ▶ 条件化扩散轨迹；
- ▶ 动词与物体名帮助选择检测目标及交互类型。

语言条件的必要性

同一物体可能对应打开、关闭、拉出、放入；图像只告诉“有什么”，语言补充“要做什么”。

来源：Chen et al., 2025, Sec. III-C/D；开源推理代码中的 CLIP 条件与 guidance cost。

可微 guidance + 排序

扩散采样时施加：

- ▶ multi-goal：保留多种可能终点；
- ▶ collision：轨迹避开 TSDF 障碍；
- ▶ contact-normal：接近方向符合表面法向。

最终用综合代价从候选轨迹中选择一条。

$$\tau^* = \arg \min_{\tau_i} (\lambda_c J_{coll} + \lambda_n J_{normal} + \lambda_g J_{goal}).$$

VidBot 证据：性能与关键消融

主结果

设置	VidBot	对比方法
模拟器 13 tasks 平均	88.2%	Octo 69.2%
真实机器人 55 trials	80.0%	—

6-task 消融平均成功率

版本	成功率
Full	85.6%
无 coarse goal / 无 multi-goal	57.8 / 73.3%
无 normal / 无 collision	76.7 / 77.8%
随机选候选轨迹	74.5%

来源：Chen et al., 2025, Table I–III。真实平台包括 Stretch 3 与 Spot。

结果解释

最大掉点来自去掉 coarse goal：说明“先找交互起终点，再生成细轨迹”不是装饰，而是分解复杂多模态动作的关键。

创新点

将 SfM、metric depth、分割、可供性与扩散组织成从野外 2D 视频提取 embodiment-agnostic 3D 监督并零样本迁移的系统。

Outline

- ① 问题与基础概念
- ② EgoMimic: 人机数据联合策略学习
- ③ VidBot: 从野外视频提取 3D 交互轨迹
- ④ 总结与方向讨论

结论与下一步

技术判断

- ▶ 从 RGB 人类视频恢复 RGB-D 并用于机器人动作学习的工作，明显少于传统单目深度估计研究。
- ▶ 逐帧 RGB 到深度的技术已较成熟。面向机器人，关键仍是识别目标物体、手和接触区域，并解决位姿、尺度与深度的跨帧一致性。
- ▶ VRB (CVPR 2023) 从人类视频学习 2D 接触与运动，是 VidBot 最直接的前序工作。VidBot 将其扩展到 metric 3D，并加入粗细两阶段预测和测试时几何约束。
- ▶ 在目前调研范围内，VidBot 是这条路线中较完整、效果较强的代表性方案。

希望与老师讨论

我此前没有接触过具身智能，对后续研究问题和切入点仍需进一步明确，希望与老师确认：

- ▶ 后续重点问题与阶段目标；
- ▶ 独立开展一个小方向，或参与学长已有方向；
- ▶ 需要协助的具体工作，我可以补充相关知识后承担。

谢谢！

欢迎讨论

来源：Bahl et al., *Affordances from Human Videos as a Versatile Representation for Robotics*, CVPR 2023; Chen et al., VidBot, CVPR 2025。