

Being-H0.5：扩展以人为中心的机器人学习，实现跨具身形态泛化

原文：Being-H0.5: Scaling Human-Centric Robot Learning for Cross-Embodiment Generalization

作者：BeingBeyond 团队。

项目：<https://research.beingbeyond.com/being-h05>

版本：arXiv:2601.12993v1, 2026 年 1 月 19 日。论文摘要后标注日期为 2026 年 1 月 20 日。

阅读说明：本文按照原文逐段、逐句翻译，合并 PDF 的跨页断句和排版换行，以中文阅读顺畅为准；公式、数值、表格、图注和引用编号均保留。文中的“我们”指论文作者。图像本身不嵌入译稿，在对应位置标明原文图号并翻译图中关键信息。

【图 1 位置】图中文字：UniHand 2.0；3.5 万小时、4 亿样本、1200 亿 token；预训练；后训练；统一动作空间；统一预测：文本回答、人类运动、机器人动作；跨具身形态物理控制；机器人操作；人类示范；视觉—文本理解；通用视觉—文本理解；理解专家；生成专家；前馈网络（FFN）；共享注意力；文本、视觉、状态；下游结果；真实机器人任务；双臂、长时程、空间、泛化；真实世界部署。部署示例：叠碗、擦白板、浇花、放入抽屉、清理桌面、交接并放置、插花、打包两件产品、翻转并扫描包裹、叠积木。

图 1：Being-H0.5 概览。我们通过 Being-H0.5 扩展以人为中心的机器人学习，迈向跨具身形态泛化。我们提出 UniHand-2.0，一个超过 35,000 小时的大规模语料库，同时涵盖跨具身形态物理控制与通用视觉—文本理解。在这些数据的基础上，我们使用统一动作空间，将人类手部运动与多种机器人具身形态统一起来，并在单一框架内通过统一序列建模训练所有异构监督信号。由此得到的单一基础模型能够在同一框架中感知、描述和行动，支持稳健的跨具身形态泛化，以及跨多种机器人和任务的真实世界部署。在实验中，我们部署 Being-H0.5 的单个检查点，控制 PND Adam-U、Franka+Inspire、Unitree G1、BeingBeyond D1 和 LeRobot SO-101 完成多样任务。

摘要

我们提出 Being-H0.5，这是一个基础视觉—语言—动作（VLA）模型，旨在不同机器人平台之间实现稳健的跨具身形态泛化。现有 VLA 往往难以应对形态异质性与数据稀缺问题；为此，我们提出以人为中心的学习范式，将人类交互轨迹视为物理交互的通用“母语”。为支持这一范式，我们推出 UniHand-2.0：截至目前规模最大的具身预训练方案，包含超过 35,000 小时的多模态数据，覆盖 30 种不同的机器人具身形态。

我们的方法引入统一动作空间，将异构机器人控制映射到语义对齐的槽位，使低资源机器人能够借助人类数据和高资源平台建立初始技能。在这一以人为中心的基础上，我们设计了统一序列建模与多任务预训练范式，连接人类示范与机器人执行。

架构方面，Being-H0.5 采用混合 Transformer（Mixture-of-Transformers）设计，其中包含一种新型混合流（Mixture-of-Flow, MoF）框架，将共享运动原语与具身形态专属的专业专家解耦。最后，为使跨具身形态策略能够在真实世界中稳定运行，我们引入流形保持门控（Manifold-Preserving Gating），提高感知分布变化下的鲁棒性；同时引入通用异步分块（Universal Async Chunking），使分块控制适用于具有不同延迟和控制特征的具身形态。

实验证明，Being-H0.5 在 LIBERO（98.9%）和 RoboCasa（53.9%）等仿真基准上取得当前最佳结果，同时在五个机器人平台上表现出强大的跨具身形态能力。

日期：2026 年 1 月 20 日。

目录

1. 引言（原文第 4 页）
2. 相关工作（第 6 页）
3. UniHand-2.0：大规模以人为中心的学习方案（第 7 页）
◦ 3.1 人类示范数据（第 10 页）
◦ 3.2 机器人操作数据（第 11 页）
◦ 3.3 视觉—文本理解数据（第 11 页）
4. UniCraftor：便携、可扩展、经济的数据采集系统（第 13 页）
5. Being-H0.5：统一跨具身形态控制的基础 VLA（第 14 页）
◦ 5.1 模型架构；5.1.1 统一状态—动作空间；5.1.2 混合流
◦ 5.2 预训练：以人为中心的机器人学习；5.2.1 统一序列建模；5.2.2 以人为中心的多任务目标；5.2.3 混合人类运动表示
◦ 5.3 后训练：迈向跨具身形态适配；5.3.1 具身形态专属适配；5.3.2 流形保持门控；5.3.3 通用异步分块
6. 基础设施：实时跨具身形态部署（第 22 页）
◦ 6.1 流形保持细化；6.2 通用异步分块协议；6.3 多线程部署架构

7. 实验（第 24 页）

- 7.1 真实机器人间的比较；7.1.1 实验设置；7.1.2 结果分析
- 7.2 仿真基准比较；7.2.1 LIBERO 结果；7.2.2 RoboCasa 结果
- 7.3 消融研究；7.3.1 以人为中心的学习如何促进下游适配？；7.3.2 掩码运动 token 预测如何促进对行为先验的捕捉？；7.3.3 实时效率：MPG 与 UAC

8. 结论（第 34 页） A. 贡献分工（第 43 页） B. 完整执行过程（第 44 页）

1 引言

真正的智能以知识在不同媒介之间的流畅表达为特征。在自然语言处理（NLP）[1,2] 中，多语言预训练 [3–5] 通过提炼“通用语义”超越了语言边界，使知识能够从高资源语言无缝迁移到低资源语言。如今，通用机器人学站在类似的十字路口：异构机器人的运动空间，本质上就是不同的物理语言。因此，扩展机器人智能的一项主要挑战是跨具身形态翻译：

机器人智能怎样才能像人类学习一门小语种一样，仅凭有限数据就掌握一个新平台？

尽管视觉—语言—动作（VLA）模型展现了实现通用机器人策略的潜力，却受到深刻的“物理鸿沟”阻碍。当前 VLA 就像只会一种语言的人：在特定硬件上高度熟练，但部署到不同形态时实际上无法兼容。众所周知，机器人专属数据的稀缺 [6,7] 加剧了这种碎片化。与 NLP 中可用的数万亿 token 不同，机器人领域的大多数独立平台都缺少大规模示范语料。

对基于扩散的 VLA [8,9] 而言，这一问题尤其突出：在较简单硬件（例如平行夹爪）上预训练的模型，特别是在遇到复杂实体（例如灵巧手）的高维向量场时，会遭遇严重分布偏移。这种不匹配使推理轨迹从有效运动流形中“漂移”出去，导致不稳定行为。

为克服这些障碍，我们通过两个核心概念，提出转向与具身形态无关的 VLA：

- **以人为中心的学习。** 正如不同人类语言共享底层语法（例如句法和逻辑），不同机器人也遵循共同的物理规律。我们将海量人类交互行为视为“母语”——物理世界的通用语。人类运动提供密集的语义先验，捕捉因果交互的逻辑和接触物理；这些规律在所有运动学“方言”中保持不变。以人为中心的数据为学习提供基础，带来物理常识，使 VLA 能够快速适应新硬件。
- **统一动作空间。** 通过将不同机器人动作表示为共享物理词汇中的 token，我们把不同机器人形态对齐到统一潜空间，使数据资源少、结构复杂的机器人能够从数据丰富的平台和人类示范中建立初始运动技能。

基于这些动机，我们提出 Being-H0.5，一个面向跨具身形态泛化的基础 VLA。模型以 UniHand-2.0 为依托：这个大规模语料库包含超过 35,000 小时的数据、1200 亿 token，总计超过 4 亿样本。作为 [10] 的扩展，UniHand-2.0 集成了 16,000 小时第一视角人类视频、14,000 小时机器人操作数据，以及 5,000 小时通用视觉—语言理解数据。值得注意的是，UniHand-2.0 覆盖 30 种不同的机器人平台，从桌面机械臂到腿式人形机器人。

与多语言 LLM 类似，Being-H0.5 在这一“多语种”数据集上预训练，内化稳健、共享的物理操作表示。此外，UniHand-2.0 纳入大规模视觉—文本语料，以确保模型保留其 VLM 骨干的高层推理、策略规划和指令跟随能力。与前一代相比，UniHand-2.0 的规模增加了 200 倍。据我们所知，这是截至目前最大的具身预训练方案，使用了最广泛的人类视频，并汇集了最多样的机器人具身形态。通过将海量人类数据与数十个机器人数据集共同用于预训练，即使目标平台专属数据极其有限，我们仍赋予 Being-H0.5 在异构平台之间强大的泛化能力。

此外，为解决现有数据集的局限并扩大数据获取规模，我们开发了一个名为 UniCraftor 的以人为中心的数据采集系统。通过精心设计，系统集成了深度信息、关键帧事件和精确相机外参——这些模态很重要，但当前基准中往往缺失。系统被有意设计为模块化、可扩展的形式，以支持多样且灵活的视角，以及未来的触觉信息。利用这一系统，我们整理了一个超过 200 小时、覆盖 43 项不同任务的综合数据集。

除了数据稀缺之外，通用机器人系统的扩展还受到具身异质性的限制——人类形态与不同机器人平台之间存在物理差异，涉及不同运动学结构、驱动限制和控制频率。简单聚合这些数据集会引入动作空间干扰：相互冲突的控制信号产生显著噪声。这通常造成负迁移，跨平台训练会使性能下降，而不是产生协同。

一些工作 [9] 通常通过使用平台专属动作头来缓解这一问题。但这种策略绕过了底层结构错位，因此存在内在局限。如果不协调这些配置，模型就无法形成能感知本体状态的推理，也无法在不同领域之间提炼可迁移的物理先验 [11]。因此，现有策略要么仍是具身形态专属专家，要么只是难以应对灵巧操作或双臂操作等高自由度任务的“浅层通才”。

为弥合这一差距，我们提出统一动作空间，将人类轨迹和异构机器人控制映射到语义对齐的槽位。它充当不同硬件的“通用语法”，有效地将功能意图（例如抓取的语义目标）与机械关节运动解耦。由此，模型内化的是交互背后的物理规律，而不只是具身形态专属命令。

在统一动作空间的基础上，我们进一步将所有异构监督转化为统一序列建模问题，迈向可扩展预训练。我们将人类示范、机器人轨迹和视觉—语言语料串行化成单一多模态 token 流，而不再维护彼此独立的流水线。其中，视觉和文本为上下文提供依据，统一状态/动作 token 则携带具有物理意义的交互信号。这样，我们可以在相关的受监督片段上施加不同损失，优化所有数据。

具体而言，以文本为中心的语料（例如 VQA 和运动描述）提供标准的文本下一 token 预测损失；人类和机器人语料则在统一空间内监督动作预测。人类行为提供密集、可迁移的行为先验，机器人轨迹则为高保真的运动学控制提供锚点。通过统一表示和优化，预训练成为围绕单一 token 流的连贯学习过程，使模型能够在同一框架中感知、描述和行动。

在架构上，Being-H0.5 采用混合 Transformer (MoT) 设计，将高层多模态推理与低层执行专家解耦。尽管统一动作空间有效表示了不同具身形态，并避免预训练中的表示冲突，但传统动作专家容量有限，仍然是一个关键瓶颈。受混合专家 (MoE) [12] 原理启发，我们引入可扩展架构框架 Mixture of Flow，将动作模块拆分为具有共享动力学知识的基础专家，以及采用具身感知任务路由的专业专家。

为确保实际可扩展性，我们引入两个互补组件，使基于 flow 的动作生成既稳定又可迁移。(1) 流形保持门控鼓励模型依赖可信上下文，在感知含糊时退回稳健先验，避免不稳定修正在迭代细化过程中被放大。(2) 通用异步分块将实时分块控制扩展到跨具身形态设置。我们训练统一策略，使其在具有不同驱动频率和延迟特征的异构平台上保持一致，而不将单一机器人的时序和控制假设固化其中，从而让单个检查点能够流畅控制所有具身形态。结合起来，这些创新使 Being-H0.5 能够在不同感知条件和异构机器人“方言”之间保持流畅表现。

我们通过在真实和仿真环境中开展广泛的基准测试，评估 Being-H0.5 及以人为中心学习的有效性。仅使用低分辨率 RGB 输入、不使用辅助模态，Being-H0.5 就在 LIBERO (98.9%) 和 RoboCasa (53.9%) 上达到当前最佳水平 (SoTA)。此外，在五种物理上不同的具身形态中，我们的模型显著超过 $\pi 0.5$ 等现有 VLA，说明无论结构复杂度如何，它都具有更强的跨具身形态泛化能力。

值得注意的是，真实机器人实验揭示了一个意料之外的具身形态级零样本迁移涌现信号：一个通过统一动作接口、跨具身形态联合训练的 Being-H0.5 通用模型检查点，在目标机器人没有任何对应数据的未见“任务—具身形态”组合上取得了非零成功率。我们认为，这一观察揭示了跨具身 VLA 的一条实用途径，并为通过增加多样化后训练数据、改善涌现迁移能力铺平道路。

为支持社区并确保完全可复现性，我们提供全面的开源发布，包括模型权重、训练流水线和仿真脚本。此外，我们还将纳入真实部署基础设施，以及一套 1,000 GPU 小时的预训练方案。主要贡献总结如下：

- **最大的训练方案。** 我们提出 UniHand 2.0，这是截至目前覆盖最广的具身 VLA 数据集，包含 35,000 小时的 4 亿样本，其中人类数据 16,000 小时、机器人数据 14,000 小时，覆盖 30 种具身形态。为促进未来规模扩展，我们还提供便携、即插即用的人类数据采集系统。

- **统一训练范式。** 我们首次将人类手部运动与多样机器人控制统一到单一动作空间，实现跨具身泛化。配合统一序列建模范式，Being-H0.5 可以在同一序列内感知、描述和行动，支持在异构语料上开展可扩展的、以人为中心的预训练。
- **架构创新。** 为最大化模型容量和跨领域迁移能力，我们引入混合流、流形保持门控和通用异步分块等新设计。这些组件解决了扩展基于 flow 的动作生成时的内在瓶颈。
- **实时基础设施。** 我们开发了高效推理基础设施，支持低延迟实时控制，提供高自由度复杂平台所需的计算吞吐量。
- **当前最佳结果。** 在五个不同真实平台和主要仿真基准上的评估表明，Being-H0.5 创下新的最佳成绩，包括 LIBERO 98.9% 和 RoboCasa 53.9%，同时展示了向未见机器人形态涌现的零样本迁移能力。

2 相关工作

视觉—语言—动作模型。 机器人操作的近期进展 [13–16] 已从狭窄的单任务专家，转向在覆盖多个场景和具身形态的多样、大规模数据集上训练的通用模型。这一转变中的重要范式是视觉—语言—动作模型（VLA）[6,17–20]：它通过在机器人控制数据上微调预训练视觉语言模型（VLM）[21–27]，连接互联网规模感知与物理执行。许多 VLA 虽然共享架构骨干，却在动作头设计上差异显著。

早期工作通常采用自回归方法，将连续动作离散化为 token，以匹配 VLM 的训练目标 [6,28]。这虽然有助于无缝知识迁移，却经常带来较高的推理延迟，并限制高自由度任务的精度。为缓解这些瓶颈， $\pi 0$ [8]、GR00T-N1 [9] 等近期框架 [19,29–31] 集成了基于扩散的架构 [32]，例如流匹配 [33]，以生成高频动作块；这种做法已被后续工作 [34–36] 广泛采用。尽管有所改进，弥合高层推理与精细执行之间的差距仍是一项挑战。

一些方法 [37–39] 使用思维链（CoT）推理 [40] 分解长时程任务，例如 OneTwoVLA 的自适应“思考”模式 [38]，以及 RAD 从人类视频中提取的语言指导 [39]，但文本规划往往缺乏物理交互所需的精度。因此，近期研究探索了非文本中间表示，例如边界框 [41]、稠密对应场 [42] 和三维点 [43]。一个值得注意的例子是 MolmoAct [44]：它将观测转换为具有深度感知能力的感知 token，以可编辑轨迹的形式生成中层空间计划。尽管有这些进展，大多数 VLA 仍受限于对实验室遥操作数据的依赖；这类数据缺少真实世界的环境多样性。我们利用数百万段第一视角视频，捕捉稳健泛化所需的行为丰富性，以解决这一问题。

异构预训练数据集。 VLA 的效果从根本上与预训练数据的规模和多样性相联系。Open X-Embodiment [7] 等大规模项目，以及 DROID [45]、BridgeData [46] 等数据集，已经汇集了来自不同平台的数千小时机器人示范。社区推动的基准，例如 [47]，通过采用易于获取的便携硬件，进一步扩展了这一领域。

为应对高维双臂协调和灵巧操作的复杂性，AgiBot World [48]、RoboMIND/2.0 [49,50]、RoboCOIN [51] 等近期数据集应运而生，填补细粒度运动控制的重要缺口；Open Galaxea [52] 则针对移动操作的特殊需求。尽管取得这些进展，大多数遥操作数据仍局限于特定实验室环境，形成可泛化策略学习的瓶颈。合成数据 [53,54] 虽具可扩展性，却受到持续存在的仿真到现实差距影响。

关键在于，这些数据集跨越结构差异显著的异构平台，现有 VLA 缺少有效整合它们的统一机制。数据格式、标注粒度和具身结构的差异，给大规模统一建模带来了重大挑战。本文提出统一状态—动作空间，以弥合这些结构差距。

以人为中心的学习。 人工遥操作成本高昂，导致真实机器人数据稀缺，推动了向以人为中心学习的转变。为降低数据采集门槛，UMI [55–57] 等便携物理接口允许将自然环境中的人类技能直接迁移到可部署的机器人策略。近期工作已经将通过 UMI 采集的数据扩展到超过 10,000 小时 [58]。一种可扩展性更强的替代方案，是直接从丰富的人类视频中学习。

与机器人采集的数据相比，人类视频语料覆盖的环境、物体配置和长时程任务结构分布要广泛得多。这一领域已经从识别和指代定位等传统视觉任务 [59,60]，发展到 Ego4D [61]、Ego-Exo4D [62]、EPIC-KITCHENS [63] 和 EgoDex [64] 等大规模第一视角基准。尽管它们提供大量交互先验，但根本性的具身差异与任务对齐标签的缺失，使其直接用于 VLA 建模并非易事。

早期以人为中心的学习工作，尝试通过表示学习 [65,66] 利用人类视频的视觉多样性。然而，所得特征大多是隐式的，而且缺少动作级监督，限制了它们在精确下游控制中的作用。因此，近期研究转向更加结构化的方法，可以归纳为几条路线。

首先，一些工作 [67–69] 探索将潜动作作为意图抽象，通过把时间变化编码为离散码或连续嵌入来表示意图。LAPA [70] 使用从帧对中得到 VQ-VAE token 预训练 VLM，随后增加动作头进行微调。UniVLA [71] 使用 DINOv2 [72] 特征预测替代像素重建，并引入两阶段码本方案，分离以任务为中心的潜变量，从而通过轻量潜变量到动作解码，实现自回归规划。

除了潜表示，GR-1/2 [73,74] 和 Gen2Act [75] 等方法通过显式预测未来环境状态或视频帧建模物理交互，将视频生成视为理解动力学的代理任务。第三条路线 [76–80] 利用显式二维几何线索，例如点轨迹、关键点和边界框 [81–83]，弥合视频像素与物理运动之间的差距。

一些近期研究不再使用间接代理，而是重点从示范中恢复实际的人类动作，为策略预训练提供直接监督 [84–89]。例如，EgoVLA [90] 使用 MANO 手模型参数构建共享动作空间，通过逆运动学，将第一视角视频中的三维手腕和手部姿态重定向为机器人命令。

Being-H0 [10] 通过引入运动分词器，将连续 MANO 轨迹离散为 token，用于大规模指令微调，从而扩大这一范式。

尽管取得这些进展，现有方法仍常受限于高质量动作标注难以规模化，以及缺少能够无缝整合异构人类示范和机器人采集数据的框架。本文扩展 Being-H0 建立的范式，借助多源集成的统一范式，构建截至目前最大的以人为中心预训练语料。

3 UniHand-2.0：大规模以人为中心的学习方案

视觉—语言—动作模型（VLA）需要大量机器人交互数据，才能获得可用于行动的知识 and 世界常识。然而，当前机器人数据生态受到几项根本局限的阻碍。我们的工作系统地处理以下关键挑战：

- 1. 数据规模和多样性有限。** 大多数现有 VLA [6,91] 受限于预训练语料的规模和多样性不足。许多模型依赖范围狭窄的数据，例如 Open X-Embodiment [7] 在严格过滤后，只提供六个主要子集，多样性有限；AgiBot World [48] 则仅包含约 200 小时桌面操作数据，而且缺少重要的第三人称相机视角。这种稀缺阻碍了模型泛化到新任务和动态环境。为克服这一问题，我们整理了一个综合机器人操作数据集，汇集了绝大多数可用机器人数据。
- 2. 具身形态种类受限。** 除规模外，现有数据集通常只包含有限的具身形态，往往仅有一种机器人，例如 AgiBot World [48] 和 LET [92]。虽然存在一些跨具身数据集 [51]，但由于显著的结构差异，统一这些数据源用于预训练仍然困难。因此，很少有 VLA 能成功纳入广泛的机器人形态。例如 π 系列 [8,34] 仅包含 10 种机器人，而且主要是同质的双臂平台。相比之下，UniHand-2.0 包含 30 种不同具身形态的数据，涵盖单臂、双臂、便携、半身人形和腿式人形机器人。这是截至目前 VLA 文献中报告的最广泛具身形态集合。我们通过将这些异构数据源投影到统一状态—动作空间来实现这一点，并确保训练稳定性。
- 3. 灵巧手数据稀缺。** 尽管通用数据采集取得进展，涉及灵巧手的数据仍极其稀少，在现有语料中占比不到 5%。这种不足源于硬件成本高和灵巧遥操作吞吐量低。为缓解这一问题，我们采用类似 [10] 的方式，利用大规模人类运动数据作为可扩展代理，借助自然场景中人手交互相对容易采集这一优势。
- 4. 视觉与语言信息不平衡。** 先前 VLA [8,93] 通常只依赖机器人数据预训练，导致严重模态不平衡，文本与视觉 token 的比例可达 1:3,000。这种差异导致模型丧失大量文本推理能力，而这种能力对长时程任务执行至关重要。虽然一些工作引入视觉—语言数据 [34,54] 或交错多模态样本 [94]，我们则在预训练期间系统性地纳入海量多模态数据，确保 Being-H0.5 在原子动作执行，以及长时程任务规划和空间推理方面都表现出色。

【图 2 位置】图中分为人类示范（1.6 万小时）、机器人操作（1.4 万小时）、视觉—文本理解（等效 5000 小时）。人类场景：实验室、日常生活、工业。运动生成示例：“把牙膏挤到牙刷上。为双手生成一段 1 秒运动序列。”运动描述示例：“〈运动〉描述左手的运动。”“起初，左手移动……”运动续写示例：“左手运动是 〈运动〉。接下来 1 秒切板的运动是什么？”片段意图：“松开顶部，打开罐子”“拧紧并整理零件”。细粒度语义：“双手抓握，反复调整并顺时针旋转，以拧开圆形盖子。”“左手固定蓝色箱子中的一叠零件，右手压紧它们。”视觉问答：“这张图片里有什么？”“这张图片展示了一个充满活力且温馨的客厅。以下是详细描述……”空间定位：“请仔细检查图片，检测这句话描述的物体：前方的黑椅子。”“前方黑椅子对应 [0.707,0.546,0.981,0.884]。”规划问答：“现在能否开始‘把拿着的桃子放进购物车中的塑料袋’？”“不能。”

图 2: UniHand 2.0 总览。UniHand 2.0 是我们用于以人为中心机器人学习的大规模预训练方案，包含来自三个互补来源的 3.5 万小时多模态数据。(1) 人类示范，具有多样场景、用于运动对齐的多任务和多粒度语义。(2) 机器人操作，跨越 30 多种具身形态，包含多个观测视角及异构控制信号。(3) 视觉—文本理解，涵盖通用视觉问答、二维空间定位与可供性，以及任务规划与推理。

这里，我们提出 UniHand-2.0，它是在前一代 UniHand-1.0 [10] 基础上显著扩展的数据集。数据集（图 2）包含从 35,000 小时多模态数据中提取的超过 4 亿样本，共计超过 1200 亿训练 token。这些样本覆盖三个关键领域：第一视角人类运动、机器人操作和视觉—语言理解。如图 3 所示，据我们所知，UniHand-2.0 是最大的以人为中心 VLA 预训练语料。需要注意，不同工作使用 Open X-Embodiment 数据集的方式并不明确。因此，我们在统计具身形态时，仅计入数据超过 10 小时的形态。

UniHand-2.0 使用低成本人类数据作为主要预训练材料，将人手视为所有末端执行器的通用模板，赋予模型基础交互知识和物理理解。我们从 16,000 小时第一视角视频中提取了 1.34 亿个人类数据样本，较 UniHand-1.0 扩大 100 倍，从而推进这一范式。此外，UniHand-2.0 纳入超过 14,000 小时、覆盖 30 种具身形态的多样机器人数据，例如 Franka、AgiBot-GR1、Unitree-G1、SO101，赋予模型稳健的跨具身泛化能力。

【图 3 位置】图例：机器人操作、视觉—文本理解、人类示范、具身形态数量。横轴比较 UniHand-2.0、 $\pi 0.5$ 、 $\pi 0$ 、wall-oss、GR00T、EO-1、InternVLA-M1、Galaxea-G1、OpenVLA；纵轴为训练数据小时数和具身形态数量。

图 3: 训练规模和具身形态多样性的比较。堆叠柱表示训练数据时长（左轴）；带斜线的柱表示具身形态数量（右轴）。UniHand-2.0 是截至目前规模最大、最多样的 VLA 预训练方案，总计 35,000 小时多模态数据，包括 16,000 小时人类数据、跨 30 种具身形态的 14,000 小时机器人数据，以及等效 5,000 小时 VLM 数据。

我们认为，这种具身多样性是现有扩散式 VLA 的前提条件。从流形学习角度看，简单具身形态，例如平行夹爪，在低维、平滑的动作流形上运行。相比之下，灵巧机器人处于

复杂、高维的空间中，其流形结构通常是非线性、碎片化的。这类复杂实体的动作分布与简单实体存在根本差异。例如，夹爪的二元“开／关”命令是一个简单标量，而灵巧手的“精确捏取”需要高维、协调的向量。这种差异在适配时造成严重的目标分布偏移。

此外，对于扩散框架，它必须推断一个连续向量场，来定义朝向下一动作状态的概率演化。当只在简单机器人上预训练的模型遇到复杂实体的未见状态空间时，其向量场预测会出现误差累积。这些误差使生成轨迹“漂移”，迅速偏离有效机器人运动流形，导致不稳定或物理上不可行的行为。

为维持关键的模态平衡，我们纳入规模相当的视觉—语言理解数据，保留模型的推理与指令跟随能力。因此，UniHand-2.0 构成了按照以人为中心学习理念组织的最大预训练数据集。下面各节详细介绍其各个部分，统计可视化见图 4。

【图 4 位置】左图：机器人数据组成，总计 13,817 小时。仿真 3592 小时（26%），真实 10,225 小时（74%）；真实数据细分为其他 9381 小时、OXE 424 小时（3.1%）、AgiBot 420 小时（3.0%）。右图外圈为小时数：人类 1.6 万、机器人 1.38 万、VLM 5000；内圈图例为 token：人类 457 亿、机器人 502 亿、VLM 256 亿。总计 3.48 万小时、1220 亿 token。

图 4：UniHand-2.0 统计。（左）仿真与真实世界数据的比例。我们保持均衡比例，仿真数据为 26%；广泛使用的 Open X-Embodiment（OXE）和 AgiBot World 分别占 3.1% 和 3.0%。（右）训练来源和规模。人类、机器人及视觉—语言（VLM）数据分别包含 1.6 万小时（256 亿 token）、1.4 万小时（457 亿 token）、等效 5000 小时（502 亿 token）。这些来源经过整理，使规模相当，以平衡预训练。

译注：图 4 英文图注中的 token 对应关系，与图内图例不一致。上方图内标签和图注分别按原文保留，未自行纠正。

3.1 人类示范数据

近期进展 [9,10,88,90,95] 已经表明，人类示范数据正成为预训练 VLA 的一种强大且可扩展的基础。以人为中心的视频不仅可以替代稀缺的机器人交互数据，还为观察人类在物理世界中如何感知、推理和操作提供了直接窗口。这些语料涵盖极其多样的日常活动，从细粒度的手—物交互，到复杂工具使用和内容丰富的上下文场景；若要用实体机器人按同等规模复现，成本将高得难以承受。这种多样性建立了稳健、可泛化的行为先验，并广泛覆盖脚本式机器人采集或仿真环境通常缺失的运动模式与可供性。

沿用 Being-H0 建立的范式，我们把人手运动视为一种通用操纵器模板。这一范式将视觉观察在物理上锚定到真实世界交互之中，有效地把被动视频帧转化为与动作相关的监

督。以手部运动作为锚点后，模型通过三种主要机制利用第一视角人类视频学习机器人策略：

1. **与动作相关的视觉上下文。** 手部运动起到空间注意机制的作用，定位某项动作在何处发生、哪些内容与其相关。这使以行为为基础的视觉上下文远远超出标准 VLM 语料所能提供的范围。
2. **丰富的操作结构。** 以手为中心的交互轨迹揭示细粒度接触模式、灵巧控制策略和多样的物体可供性，捕捉当前大多数机器人数据集缺失的操作动力学。
3. **用于意图锚定的多样文本上下文。** 将语言上下文与以手为中心的交互轨迹对齐，可以让模型把人类语言落实到物理结果和运动上，从而学习意图层面的知识，而不是只匹配表面视觉模式。

在 Being-H0 的基础上，我们显著扩大并丰富了人类视频语料。其范围不再局限于实验室录制、专门针对操作的场景，而是同时纳入开源资料和自行整理的数据库。为使这些视频能直接用于机器人学习，我们从不同视频来源中提取统一的手部运动表示，并以内部采集的高保真数据作为补充，提供开放网络视频通常欠缺的信号精度。

异构人类视频的整理。 除 UniHand-1.0 数据集外，我们还整合了来自大型公共资料库的大量野外第一视角视频，包括 Ego4D [61]、EPIC-KITCHENS [96]、Egocentric-10K [97] 等。这项扩展大幅增加了环境与具身行为的多样性，覆盖家务、烹饪和工业操作（见图 2）。为了将这些异构来源转换成统一接口，我们使用 HaWoR [98]，通过 MANO 参数 [99] 和相机外参估计手部姿态。我们还使用 Gemini-2.5 [100] 生成双层标注，以细粒度语义监督丰富数据集：一层是逐秒的详细指令，另一层是以 10 秒片段为单位的整体意图描述。

我们把训练数据组织成三个相互关联的任务族：运动生成，即把视觉／语言映射到运动学动作的主要目标；运动描述；以及运动续写。

为保证较高的数据保真度并尽量减少虚假相关性，我们实施严格的四阶段后处理流程：

1. **语言增强。** 使用 LLM 对所有模板格式的指令文本进行释义改写并增加表达多样性，防止模型过拟合僵化的语言模式。
2. **运动质量过滤。** 根据检测置信度和 DBA 误差过滤带噪声的 HaWoR 估计，同时移除腕部空间中的高频抖动或不连续运动，以保证数据可靠性。
3. **操作相关性过滤。** 借助 Gemini 的语义筛选，排除主要由纯移动等非操作动作构成的片段。
4. **惯用手去偏。** 对所有样本进行左右空间镜像，缓解常见的右利手偏差，促进所学策略向双手通用能力泛化。

3.2 机器人操作数据

机器人控制数据是策略学习的基石，为实现广泛的具身形态泛化和熟练的灵巧操作提供关键路径。为此，我们整理了一套大规模异构机器人示范集合。该数据集汇总约 14,000 小时的交互数据，约合 15 亿帧，是目前最广泛的机器人行为资料库之一。它系统整合 Open X-Embodiment [7]、AgiBot-World [48]、SO100-Community [47]、InternData-M1 [54]、RoboMIND [49]、RoboCOIN [51]、LET [92] 等众多数据集。我们对汇总数据去重，并把帧下采样到 30%，在减少冗余的同时尽可能提高数据多样性。

处理后的数据集覆盖 30 种不同的机器人具身形态，例如 Franka 机械臂、Split ALOHA 和 Agibot G1，在硬件形态和控制接口方面具有显著广度。为了进一步扩大任务覆盖范围，我们还加入程序化生成的仿真样本 [54] 和通过图像修复增强的轨迹 [101]。仿真数据可以有效提升标准基准上的表现，但过度依赖仿真会加剧仿真到现实的差距。为缓解这一问题，我们严格限制仿真数据在预训练混合数据中的比例，如图 4 所示，仅占总语料的 26%，从而保证真实世界信号仍是主要学习信号。最后，我们还为 PND Adam-U、BeingBeyond D1 等硬件平台贡献了新的示范，以提高数据多样性与平衡性。机器人数据分布的更多细节见表 1。

表 1：UniHand-2.0 机器人操作数据统计概览。 语料汇集 30 种不同具身形态的示范，总计 14,000 小时交互。数据在相机视角、运动学结构和操作环境方面具有很高的多样性。末端执行器类型中，“Grp”表示平行夹爪，“Dex”表示灵巧手；数据来源中，“Real”表示物理世界，“Sim”表示仿真。

机器人类型	相机视角	末端类型	来源	小时数
单臂机器人				
Franka	第一视角、2 个第三视角、腕部	Grp/Dex	Real/Sim	2196.4
Google Robot	第一视角、第三视角	Grp	Real/Sim	1195.2
Kuka-iiwa	第一视角、第三视角	Grp	Real/Sim	338.2
WidowX	2 个第三视角、腕部	Grp	Real/Sim	305.2
Xarm7 Robot	顶部、第三视角	Grp	Real/Sim	594.4
UR5E	第三视角、腕部	Grp	Real/Sim	208.3
Hello Stretch	第一视角、第三视角	Grp	Real	270.3
Kinova Jaco	3 个第三视角	Grp	Real/Sim	194.6
Kinova Gen3	3 个第三视角	Grp	Sim	197.4
Sawyer	第三视角	Grp	Sim	196.1

机器人类型	相机视角	末端类型	来源	小时数
Cobotta	第三视角	Grp	Real	10.6
DLR Sara	第三视角	Grp	Real	12.1
Willow Garage PR2	第一视角	Grp	Real	11.9
RMC RM65	第三视角	Dex	Real	41.3
双臂机器人				
RMC Aida L	高位、2 个腕部视角	Grp	Real	325.7
Galaxea R1 Lite	高位、2 个腕部视角	Grp	Real	630.5
Agilex Split ALOHA	高位、2 个腕部视角	Grp	Real/Sim	1099.1
Agilex Cobot Magic	高位、2 个腕部视角	Grp	Real	399.2
Piper	第一视角、2 个腕部视角	Grp	Real/Sim	904.5
便携式教育机械臂				
BeingBeyond D1	第一视角	Dex	Real	100.0
SO101	第一视角、2 个腕部视角	Grp	Real	194.4
半身人形机器人				
PND AdamU	第一视角	Dex	Real	200.0
Agibot-G1	左右各一组第一视角和腕部视角	Grp/Dex	Real/Sim	2391.7
Leju Kuavo 4 LB	第一视角、2 个腕部视角	Grp/Dex	Real	1198.2
AlphaBot 2	第一视角、2 个腕部视角	Grp	Real	13.8
Airbot MMK2	第三视角、2 个腕部视角	Grp	Real	23.1
Galbot G1	2 个腕部视角	Grp	Sim	195.8
Tianqing A2	高位、2 个腕部视角	Grp	Real	19.4
人形机器人				
Unitree G1edu-u3	第一视角、2 个腕部视角	Grp/Dex	Real	135.7
Tiankung	顶部	Grp	Real	214.3
总计：30 种具身形态				13817.4

3.3 视觉—文本理解数据

标准机器人训练语料中的视觉和文本成分往往严重失衡。机器人交互数据提供密集的视觉信号，但与之配套的语言监督通常既稀疏又简单。这种差异在多模态监督中造成根本性不对称，使模型的复杂文本推理、指令跟随和高层规划能力面临退化风险。例如，仅在我们的机器人交互语料中，视觉 token 就有 457 亿，而文本 token 只有 3000 万，两者比例高达约 1000:1。如果不处理这种差距，模型可能会牺牲语言智能而过拟合视觉模式，最终把机器人智能体降格为视觉—运动反射系统，而不是能够推理的智能体。

为恢复模态平衡，我们专门整理了一套综合视觉—语言理解语料，用于保留并增强模型的语义推理能力。我们有策略地将其分成三个支柱，确保覆盖从一般世界理解到精确、可执行的机器人推理：

1. **通用视觉—语言问答。** 为保持稳健的通用视觉—语言对齐，我们纳入已有的大规模指令微调数据集，包括 LLaVA-v1.5 [102]、LLaVA-OneVision [103]、FineVision [104] 等图像基准，以及 LLaVA-Video [105] 等视频数据集。这些数据防止机器人专用微调期间对一般世界知识产生灾难性遗忘。
2. **二维空间定位与可供性。** 机器人操作所需的不只是语义描述，还需要精确的空间定位。为弥合语义理解与物理执行之间的差距，我们整合了以落地推理、物体定位和可供性检测为重点的数据集。数据来源包括用于指代表达理解的 RefCOCO [106] 和 RefSpatial [107]，以及 RoboPoint [108]、ShareRobot [109]、RoboRefit [110]、RoboVQA [111]、MolmoAct [44] 和 A0-ManiSkill [112] 等机器人专用定位数据集。我们还加入 PixMo-Points [113] 和 AsV2 [114] 等点级监督基准，增强模型在二维图像平面中的细粒度空间感知。
3. **任务规划与推理。** 除即时感知外，一个有能力的智能体还必须对长时间跨度进行推理。为此，我们纳入 ShareRobot [109]、EO1.5M-QA [94] 等高层规划数据集。这些来源显式训练模型把复杂的长时程命令分解成合乎逻辑的子任务序列，弥合抽象用户意图与低层运动执行之间的关键差距。

4 UniCrafter：便携、可扩展且经济的数据采集系统

开源语料虽然规模可观，却常常缺少准确深度、稳定相机对齐和时间精确的交互事件等关键监督信号。例如，Ego4D [61] 及其多视角扩展 Ego-Exo4D [62] 提供丰富的语义描述，却没有几何深度。Egocentric-10K [115] 包含 10,000 小时的野外工业视频，但只提供未经标注的原始 RGB 流。此外，HD-EPIC [116] 和 HOI4D [117] 等基准依赖离线标定来近似估计相机姿态，其交互标签通常只与视频片段边界或少量标注帧对齐。这种粗粒度标注会让物体接触和释放的确切时刻产生时间歧义，对细粒度策略学习不利。为弥补

这些不足，我们开发了一套模块化、即插即用的数据采集系统，用同步监督采集高质量多模态记录。

1. **原生深度采集。** 我们使用头戴式 Intel RealSense D435 采集第一视角 RGB-D。主动红外立体视觉可以提供原始物理深度，绕开基于学习的深度估计所固有的伪影和不一致问题；后者在严重遮挡、快速自运动或不良照明条件下往往会退化。
2. **高精度外参。** 为将手部运动与相机运动解耦，并建立一致的世界坐标系，我们使用五个桌面 AprilTag [118]，通过透视 n 点（PnP）算法计算真实相机姿态。这种方法源于经典机器人手眼标定；与当前基于学习的外参预测器 [98,119] 相比，它对头部运动抖动和传感器噪声更加稳定。它还支持无缝整合外部视角，实现灵活且同步的多视角采集：只要至少有一个 AprilTag 处于视野中，额外的 D435 相机就可以自由改变位置，无需人工重新标定。
3. **硬件同步的交互事件。** 自动标注时，下采样帧往往会错过物体接触或释放的精确瞬间。为消除这种时间歧义，我们加入与硬件同步的脚踏板，记录明确的交互事件。该机制能以很高的时间精度捕捉与可供性相关的关键帧，又几乎不会给示范者增加认知负担。这些时间戳在所有传感器流之间同步，既作为细粒度语义描述的真实标注，也用于验证操作线索在时间上的准确性。

利用这套系统（见图 5），我们构建了包含 43 项桌面任务、超过 200 小时多模态记录的数据集。所有传感器通过中央时间戳设备同步；模块化架构允许快速更换传感器，未来计划扩展到触觉感知和移动场景。

后处理流程分为三个阶段。首先，使用 Grounded-SAM2 [120] 和 DiffuEraser [121] 追踪并修复 AprilTag 区域，保持画面洁净。其次，通过多视角深度融合细化 HaWoR [98] 估计的手部运动，强制保证不同视角之间的空间一致性。最后，以脚踏板触发的事件信号为条件，由 Qwen2.5-VL [122] 自动生成细粒度任务描述，再经人工最终核验，确保描述有所依据且内容正确。

【图 5 位置】UniCraftor 系统包括 RealSense D435、AprilTag 和脚踏板。任务示例为“堆叠并拆开三个蓝色积木”。时间轴上的关键步骤标注包括“拿起中间的积木，把它放在左侧积木上方”和“拿起右侧积木，把它放到已叠好的积木上方”。系统同步记录带原生深度的头部、右侧和左侧多视角观察。

图 5：我们的数据采集系统 UniCraftor 概览。

5 Being-H0.5：统一跨具身形态控制的基础 VLA

5.1 模型架构

遵循 BAGEL [123] 的架构原则，Being-H0.5 采用专门设计的混合 Transformer

(Mixture-of-Transformers, MoT) 架构 [124]，用于将高层语义推理与低层运动控制解耦。在这个结构中，Being-H0.5 集成了两个功能不同的专家模块：

1. **多模态理解专家**负责解释高维感知输入。在 VLA 语境中，该专家的作用超越传统图像描述，专门用于长时程规划、生成中间子目标，并提供让模型立足于复杂环境所需的推理。
2. **动作生成专家**是一套专用策略网络，负责把高层计划转化为精确的运动学执行。

这种双专家范式在语义理解和连续控制之间取得平衡，与 $\pi 0$ [8] 等近期先进模型形成的架构共识一致。关键在于，两个专家虽然承担专门的功能角色，却在统一的 MoT 骨干中运行。两个模块处理同一个 token 序列，并在每一层 Transformer 中利用共享的自注意力机制。这样的设计保证信息顺畅流动，使动作生成可以深度依赖视觉—语义上下文，又不会引入架构瓶颈的额外开销。

在生成范式上，我们针对不同输出模态采用混合方法。对于高层推理和运动描述等文本输出，我们使用标准的下一 token 预测范式，借助 VLM 已得到验证的能力，生成连贯且逻辑清晰的指令链；对于离散手部运动，则采用掩码 token 预测准则。动作预测使用整流流 (Rectified Flow) [33,125]，不把动作离散化，而是直接使用连续动作。这使策略头与前沿扩散式 VLA 方法一致，可以在动作空间上生成平滑、高保真的多模态分布。

Being-H0.5 的骨干初始化自公开 VLM InternVL-3.5 [126]，后者采用稳健的仅解码器 Transformer 架构。我们选择 InternVL-3.5，是因为它在复杂视觉推理基准上表现可靠且容易获取。需要指出的是，VLM 骨干的选择十分关键；经验证据表明，底层视觉特征会在很大程度上决定下游 VLA 的效果。架构偏置可能使机器人性能产生显著差异，因此我们计划在未来系统评测其他骨干。

【图 6 位置】左侧展示统一动作空间，把手运动 and 机器人控制映射到末端位置、末端旋转、夹爪状态、手指关节等槽位。中部展示 Being-H0.5 的理解专家和动作专家，它们共享注意力，并分别处理文本、视觉、答案、离散运动、状态和连续动作。下方把 UniHand-2.0 中的人类示范、视觉—文本理解和机器人操作统一序列化为问答格式。右侧展示混合流：底层为基础专家，上层由 Top-K 路由器激活专业专家。

图 6：Being-H0.5 概览。Being-H0.5 是一种专门设计的 MoT，通过共享注意力机制维持耦合，同时将多模态理解（理解专家）与动作生成（动作专家）解耦。统一状态—动作空间把手运动 and 不同机器人控制映射到语义对齐的槽位，从而支持跨具身形态预训练。预训练把 UniHand-2.0 的多模态数据串行化为统一的问答格式，并将各模态分配给相应分支。最后，混合流设计把共享基础层与面向具身形态／任务动力学的路由专业专家结合起来，扩展动作容量。

5.1.1 统一状态—动作空间

扩展通用机器人学习时，一个主要障碍是多来源具身数据固有的极端异质性。人手与机器人末端执行器之间的“物理鸿沟”，再加上不同机器人平台在运动学、驱动限制和控制频率上的差异，形成了高度碎片化的数据格局。此外，现有数据集经常用不同名称和不同物理单位表示语义相同的动作。以往方法 [9] 通常为每一种具身形态分配独立的 MLP 投影层，即不同的编码器／解码器头，以处理维度差异。

我们认为这种策略并非最优，因为它无谓地占用模型容量，还割裂了物理共性的学习。在实践中，不同夹爪配置和灵巧手的末端执行器轨迹具有很高的几何一致性，许多关节配置也存在潜在的对齐可能。用不同 MLP 头隔离它们，会使模型无法利用共享物理先验，从而削弱跨具身形态泛化。此外，许多现有方法容许混用旋转表示，例如欧拉角和四元数，迫使网络把计算资源浪费在无关紧要的格式差异上。这种结构缺失会引入不必要的噪声，使训练不稳定，并严重限制模型把人类视频知识迁移到机器人控制的能力。

为弥合这些运动学差异，我们提出具有明确物理解释的统一状态—动作空间。遵循 [10] 提出的物理语义对齐原则，我们把状态和动作都形式化为固定长度的高维向量。概念上，我们把向量空间划分成语义隔离的子空间，其中每一维都对应一个有物理依据的量，例如双臂末端位姿、关节位置、夹爪宽度、手指关节状态，或移动基座的速度和航向命令。

统一空间的一项关键创新，是把人手运动视为一种通用具身形态。我们将 MANO 手部模型的参数直接映射到该统一空间。具体来说，人手的全局腕部位姿与机器人末端执行器子空间对齐，手指关节则映射到预留的“精细操作”槽位。这种架构保证不同自由度不会互相冲突，使模型能够学习共享的、与具身形态无关的操作逻辑潜在表示。使用这种共同的“动作语言”，Being-H0.5 可以在海量人类视频和不同具身形态的轨迹上有效预训练，同时与下游机器人执行直接兼容。

为保证不同平台之间的可迁移性，我们在每个子空间内执行严格标准化。对于笛卡尔控制，所有末端动作都表示为统一世界坐标系中的相对增量位移。旋转统一使用轴角表示，避免万向节锁，并保证在 $SE(3)$ 流形上平滑插值。对于关节空间控制，位置统一为绝对弧度值。值得注意的是，我们放弃了传统统计归一化，例如缩放到 $[-1, 1]$ ，而保留原始物理量级。我们认为，移动 1 弧度或 10 厘米本身具有内在物理含义，而归一化会将其掩盖。我们只执行离群值过滤来缓解传感器噪声，迫使模型学习动作的真实物理尺度，从而得到可以跨不同具身形态和环境泛化、且具有物理依据的策略。

5.1.2 混合流

统一状态—动作空间虽然可以有效表示不同具身形态，并防止预训练时发生表示冲突，但传统动作专家的容量有限，仍是一个关键瓶颈。把形态各异的机器人整合进来时，这种容量约束往往会使 VLA 性能下降，尤其因为动作专家的参数通常远少于视觉生成所用的流式专家 [123,127]。有限的容量还会妨碍模型在大量具身形态和复杂下游任务之间泛化。

为克服这些限制，我们提出混合流（Mixture of Flow, MoF）：一种可扩展架构框架，在利用共享基础表示的同时，把不同具身形态和技能解耦。该方法来自两项关键观察。第一，许多具身形态虽然视觉和运动学差异显著，却共享一部分控制结构。例如，Franka 和 Kuka 都是以关节位置及末端状态定义的 N 自由度操纵器，而轮式半身人形等移动平台共享基座控制的速度和方向度量。把统一专家拆成专门子模块，可以让模型分别掌握状态空间的特定区间，减少具身形态之间的干扰。第二，人类运动控制本身就是模块化的，通用运动原语会根据具体任务动态调整。

按照这些原则，我们把基于流的动作专家组织成两级结构：

1. **基础专家，共享动力学。** 动作专家的前几层由所有输入共享的标准 Transformer 块组成。这些层编码基础且可迁移的运动原语，例如伸手、抓取动力学和避碰；这些原语在不同具身形态与任务之间保持不变。
2. **专业专家，具身形态与任务路由。** 上层使用一组并行专业专家，由受混合专家架构 [12] 启发的可学习门控网络管理。对于给定的输入状态和指令，路由器动态激活少量专家子集，例如 Top-K 专家，从而实现高效专业化，而计算开销不会随专家总数线性增加。

这种架构稀疏性是 Being-H0.5 高效且稳健的基础。它让模型可以把细化的基础原语组合成复杂、针对特定任务的行为，同时避免跨任务干扰。训练某项任务时，梯度只更新相关专家路径，从而保留其他局部技能的权重。此外，这种设计将总参数量与激活参数量解耦。统一模型虽然容纳了庞大的技能库，推理时却只激活一小部分参数。因此 Being-H0.5 很适合部署到 NVIDIA Orin-NX 等资源受限的边缘硬件上，机器人可以按需调用广泛能力，又不超出内存带宽或延迟限制。

5.2 预训练：以人为中心的机器人学习

我们的机器人学习框架从根本上以人为中心，并以 UniHand-2.0 数据集为结构基石。在这一范式中，人类行为被视为密集的物理先验来源，而不是被动参考。UniHand-2.0 承担双重角色：大规模第一视角人类数据提供可迁移的行为意图，对复杂交互在开放世界中如何展开进行编码；机器人轨迹则提供低层运动控制所需的高保真运动学监督。

为弥合人类示范与机器人执行的差距，我们加入通用视觉问答（VQA）信号。它注入广泛的视觉—语言上下文并增强场景理解，处理具身智能中的一组关键双重需求：既要精确运动控制，也要有丰富的上下文依据。多任务目标综合这些异构数据流，训练模型像 VLM 一样细致地感知，同时精确地执行动作。

5.2.1 统一序列建模

我们把所有监督都转化为统一的多模态序列建模问题。将状态—动作空间视为显式模态后，我们定义所有具身形态共享的状态向量 $\mathbf{s} \in \mathbb{R}^d$ 和动作向量 $\mathbf{a} \in \mathbb{R}^d$ 。每种具身形态 e ，例如平行夹爪、灵巧手或移动基座，都通过稀疏槽位分配投影到统一空间：

$$\mathbf{s} = \Phi_e(\mathbf{s}^{(e)}), \quad \mathbf{a} = \Phi_e(\mathbf{a}^{(e)}). \quad (1)$$

其中， $\mathbf{s}^{(e)}$ 和 $\mathbf{a}^{(e)}$ 是原始的具身形态专属信号。映射函数 Φ_e 将这些信号路由到全局向量中的相应槽位，未使用的槽位置零。这样，人手运动与机器人轨迹就能和视觉、语言一起存在于同一个具有物理解释的接口中。

形式上，每个训练样本被串行化为由 K 个模态片段组成的 token 流 S ：

$$S = [x_1, x_2, \dots, x_K], \quad (2)$$

每个片段 $x_k = \langle m_k, C_k \rangle$ 由模态标签 $m_k \in \mathcal{M}$ 及对应内容 C_k 组成。模态集合定义为：

$$\mathcal{M} = \{\text{vision, text, state, action}\}. \quad (3)$$

每个样本根据可用监督实例化一个子集 $\mathcal{M}_i \subseteq \mathcal{M}$ ，每种非文本模态都包在两个不同的特殊 token 之间。训练时，我们采用物理指令微调 [10]，把数据组织成问答格式 $[S_Q; S_A]$ 。模型以上下文 S_Q 为条件，只在回答 S_A 上用生成损失进行优化。

5.2.2 以人为中心的多任务目标

在统一序列中，我们根据模态组织方式定义一系列任务。首先，**运动生成**是操作学习的主要目标：模型以视觉、文本和状态为条件预测一个动作块。大规模人类交互轨迹和机器人轨迹主要通过这条路径提供与策略相关的监督。

作为补充，我们引入**运动描述**与**运动续写**作为对齐目标，加强视觉—语言—运动的锚定关系与时间连贯性。在运动描述任务中，模型以视觉和交互轨迹（状态／动作）为条件预测文本，以此强制建立语义锚定，把高层语言意图与有物理依据的结果对齐。在运动续写任务中，模型以过去的观察和动作历史为条件预测未来动作块，促使其学习超越单步模仿、在时间上连贯的交互动力学。

预训练虽然从根本上以人为中心，第一视角人类数据构成数据方案的核心，但问答对串行化可以无缝吸收不同的辅助监督。框架只实例化已有模态，因此既能纳入用于动作生成的机器人操作数据 ($S_A = \{\text{action}\}$)，也能纳入用于标准文本预测的 VQA 数据集 ($S_A = \{\text{text}\}$)。所有任务共享同一骨干，并通过联合损失优化：

$$\mathcal{L} = \lambda_{\text{text}} \mathcal{L}_{\text{text}} + \lambda_{\text{act}} \mathcal{L}_{\text{act}}. \quad (4)$$

为处理 S_A 的多模态性质，我们定义 token 级索引集 Ω_{text} 和 Ω_{act} ，标识统一序列中分别接受两种损失的片段。对于 VQA 和运动描述任务，我们在目标文本 token 上采用标准交叉熵损失：

$$\mathcal{L}_{\text{text}} = - \sum_{i \in \Omega_{\text{text}}} \log p_{\theta}(y_i | S_{<i}). \quad (5)$$

对于来自人类和机器人数据的运动生成及续写任务，我们用专门的动作损失 $\mathcal{L}_{\text{act}}$ 监督动作 token；其具体形式取决于运动表示，下一节将详细说明。

5.2.3 混合人类运动表示

人手运动天然具有丰富表现力，但规模扩大后，不可避免地包含细微的执行差异与观察噪声。完全依赖连续监督可能学到脆弱的先验，而纯离散表示又可能牺牲精细控制所需的精度。为同时满足机器人控制的高保真要求和类人运动的稳定行为先验，我们在同一个训练实例中使用两种互补表示监督运动：一是统一空间中的连续动作块，二是通过动作块量化得到的离散运动 token，后者由 Being-H0 [10] 提出。

具体来说，给定长度为 T 的运动块，我们把它表示为连续序列 $A = [a_1, \dots, a_T] \in \mathbb{R}^{T \times d}$ ，其中每个 $a_t \in \mathbb{R}^d$ 都位于统一高维动作空间中。同时，我们使用预训练分词器，把运动量化为离散序列 $z \in \{1, \dots, |\mathcal{C}|\}^{T_z}$ 。这里， $\mathcal{C}$ 是大小为 $|\mathcal{C}|$ 的码本， T_z 是分词后的序列长度。这个离散通道是一种稳健、类似语言的抽象，可以过滤高频执行噪声，从而在异构数据集上稳定运动先验。联合目标是连续流匹配和离散掩码运动预测的加权组合：

$$\mathcal{L}_{\text{act}} = \lambda_1 \mathcal{L}_{\text{FM}} + \lambda_2 \mathcal{L}_{\text{MASK}}. \quad (6)$$

连续流匹配。 我们使用以时间为条件的速度场 $v_{\theta}(x, t, c)$ 对连续运动分布建模，其中 c 表示作为条件的视觉和文本上下文。该场用于把标准高斯分布 $x_0 \sim \mathcal{N}(0, I)$ 的样本输送到目标数据分布。对于时间索引 i 处的目标动作 a_i ，我们通过线性插值定义概率路径： $x_t = (1 - t)x_0 + ta_i$ ，其中 $t \in [0, 1]$ 。目标 $\mathcal{L}_{\text{FM}}$ 最小化预测速度与理想向量场 $u_t(x_t) = a_i - x_0$ 之间的均方误差。令 Ω_{FM} 表示回答片段 S_A^{FM} 中连续动作步骤的索引集合，则目标为：

$$\mathcal{L}_{\text{FM}} = \sum_{i \in \Omega_{\text{FM}}} \|v_{\theta}(x_t, t, c) - (a_i - x_0)\|_2^2. \quad (7)$$

掩码运动 token 预测。 除连续回归外，我们还监督离散通道，以注入抽象层面的稳定运动原语。具体而言，我们为量化 token 在模型骨干上增加专用 token 嵌入和线性预测头。训练时，按照掩码比例 ρ ，从 token 序列 $z \in \{1, \dots, |\mathcal{C}|\}^{T_z}$ 中随机采样索引子集 $\Omega_{\text{MASK}} \subseteq \{1, \dots, T_z\}$ ，并把原 token 替换为专用 [MASK] token。模型通过交叉熵损失重建原始码本索引：

$$\mathcal{L}_{\text{MASK}} = - \sum_{i \in \Omega_{\text{MASK}}} \log p_{\theta}(z_i | c). \quad (8)$$

通过预测这些离散 token，模型学习手部运动底层的“语法”，为连续流匹配头提供结构支架。

联合串行化。 为实现无缝多模态集成，我们把上下文和混合目标串行化成统一序列。对于给定实例，将共享上下文前缀 S_Q 与两个目标片段拼接成 $[S_Q; S_A^{\text{FM}}; S_A^{\text{MASK}}]$ 。其中， S_A^{FM} 包含连续动作目标， S_A^{MASK} 包含离散运动 token 目标，两者都以相同上下文 S_Q 为条件。

为防止模型在连续和离散通道间直接复制信息而造成简单的信息泄漏，我们让两个目标片段都能关注共享上下文 S_Q ，但彼此不可见。这通过带门控矩阵的改造注意力掩码实现：

$$G = \begin{bmatrix} 1 & 0 & 0 \\ 1 & 1 & 0 \\ 1 & 0 & 1 \end{bmatrix}, \quad \text{对应 } [S_Q; S_A^{\text{FM}}; S_A^{\text{MASK}}]. \quad (9)$$

有效注意力掩码通过把该门控应用到原始掩码上得到。我们还对齐位置索引，保证两个目标从同一个位置原点获得依据。令 $r(j)$ 表示片段内相对索引， $p_0 = \max_{j \in S_Q} (j + 1)$ ，位置编码定义为：

$$\text{PE}(j) = \begin{cases} j, & j \in S_Q, \\ p_0 + r(j), & j \in S_A^{\text{FM}}, \\ p_0 + r(j), & j \in S_A^{\text{MASK}}. \end{cases} \quad (10)$$

这种对齐让模型把连续和离散表示视作同一时间事件的两个互补视角，并以完全相同的上下文原点为依据。

5.3 后训练：迈向跨具身形态适配

UniHand-2.0 为 Being-H0.5 提供了广泛的具身形态多样性，使它拥有强于现有 VLA 的结构先验，但后训练阶段仍然并不简单。主要目标是让预训练策略适应专门的部署机器人；这些机器人往往具有独特运动学、约束和运行时特征，而适配又不能侵蚀大规模预训练获得的通用表示。实践中，这个阶段主要受可塑性与稳定性的两难困扰：下游微调很容易坍塌成狭窄的专用模型，在有限轨迹分布内取得高成功率，却牺牲推理深度和跨具身形态迁移能力。

我们识别出跨具身部署中三个相互关联的脆弱性来源：一是具身形态相关动作场在共享参数下相互竞争，造成形态干扰；二是在分布偏移下，上下文不可靠，退化特征会使流

更新产生动作抖动；三是不同延迟和频率下，推理与执行之间存在实时性错位。为解决这些问题，我们提出两种互补的后训练技术，即具身形态专属适配和流形保持门控，以及一种面向部署的训练协议，即通用异步分块。

5.3.1 具身形态专属适配

尽管预训练学习了强大的视觉—语言—动作表示，模型仍必须考虑目标硬件独有的物理动力学。每一种具身形态 e 都会产生受运动学限制、自碰撞和接触约束支配的不同可行动作集合。因此，具身形态越复杂，条件分布 $p(a | H, e)$ 的多模态性越强，也越不平滑。从流匹配角度看，动作专家学习以具身形态为条件的速度场 $v_\theta(a_t; H, e)$ ，使其匹配目标场 $v^*(a_t, a_0)$ ：

$$\min_{\theta} \mathbb{E}_e \mathbb{E}_{(a_0, H) \sim \mathcal{D}_e} \mathbb{E}_t \|v_\theta(a_t; H, e) - v^*(a_t, a_0)\|_2^2. \quad (11)$$

当不同具身形态的最优场相差很大时，具身形态专属梯度 $\nabla_{\theta} \mathcal{L}_e$ 会互不对齐，造成形态干扰，减慢收敛，并在复杂硬件上产生不稳定或被“平均化”的行为。

关键设计目标。 我们的目标是把专业化限制在与特定具身形态相关的动作分量中，同时保持共享 VLM 骨干稳定。我们没有采用为每个机器人分配独立投影头的常规策略，而是让具身形态专属适配 (ESA) 利用统一动作空间：不同具身形态激活不同索引集合；具有共享形态部件的机器人会有部分重叠；我们只更新与这些活跃索引绑定的参数。

统一动作空间中的逐槽适配器。 令 $\mathcal{S} = \{1, \dots, K\}$ 表示 K 个语义动作槽位，例如机械臂关节、手/夹爪关节和基座控制；令 $I_e \subseteq \mathcal{S}$ 表示具身形态 e 的活跃槽位索引。共享硬件部件的具身形态，例如同一机械臂搭配不同手部，其索引集合会重叠，因此也共享一部分适配参数。我们维护一个逐槽轻量适配器库 $W_{\text{ESA}} \in \mathbb{R}^{K \times d_{\text{out}} \times d_{\text{in}}}$ ；后训练具身形态 e 时，只更新 I_e 索引的子集：

$$W_{\text{ESA}}^{(e)} \triangleq \{W_{\text{ESA}}[k] : k \in I_e\}, \quad \Delta W_{\text{ESA}}[k] = 0 \quad \forall k \notin I_e. \quad (12)$$

在实际操作中，ESA 更新由槽位选择器 I_e 掩蔽：只有绑定活跃槽位的适配器贡献梯度，因此绑定共享槽位的参数可以在不同具身形态之间迁移知识，而不重叠的槽位保持隔离。最终得到的单一检查点可以支持异构机器人，又不会发生参数冲突。

【图 7 位置】 左侧为 MPG：在切片 Wasserstein 距离空间中比较观察嵌入与参考动作嵌入；训练时参考是真值，推理时参考是前一次迭代。差异决定门值 g ，门控缩放依赖特征的残差，无门控的已学习先验偏置提供稳定回退，从而为动作专家生成增强上下文特征 $\tilde{H}$ 。右侧为 UAC：按照具身形态专属动态延迟 d ，把动作块分为已排队/正在执行的承诺前缀 $A_{<d}$ 和预测后缀 $A_{\geq d}$ ；高延迟机器人使用较大的 d ，低延迟机器人使用较小的 d ，双线程缓冲区负责异步执行与推理。

图 7: MPG 与 UAC 概览。左 (MPG): 我们在切片 Wasserstein 距离 (SWD) 空间中比较观察嵌入与参考动作嵌入, 得到由差异引导的门值 g 。门控缩放以特征为条件的残差, 而不受门控的已学习先验偏置提供稳定回退, 最终产生供动作专家使用的增强上下文特征 $\tilde{H}$ 。右 (UAC): 根据具身形态专属动态延迟 d , 每个预测动作块被分成承诺前缀 $A_{<d}$ 和预测后缀 $A_{\geq d}$ 。双线程缓冲区使不同延迟预算的机器人能够异步推理和执行。

5.3.2 流形保持门控

流匹配以动作专家使用的 token 级上下文特征 H 为条件, 把噪声输送到动作空间。在我们的实现中, H 指由本体状态嵌入和当前动作 token 嵌入拼接而成的后缀 token 特征; 二者都投影到 VLM 隐藏维度, 而语言/视觉前缀保持不变。

动机。 一个关键却常被默认的假设是, H 能忠实捕捉与任务相关的语义。在光照变化、视角扰动、部分遮挡等分布偏移下, 策略可能根据退化特征盲目回归动作, 产生不稳定行为。跨具身形态适配会放大这个问题: 自由度更高的具身形态引入更多未观察状态和更强约束, 使从 H 到可行动作的映射更不确定, 也更易受微小特征误差影响。在流匹配中, 步长为 Δt 的去噪更新为 $a_{t-\Delta t} = a_t + \Delta t v_\theta(a_t; H)$; 因此, 上下文特征中的扰动, 例如 $H = H^* + \epsilon$, 可能产生与 $\|\partial v_\theta / \partial H\|^2 \text{Var}(\epsilon)$ 成比例的动作方差, 表现为动作抖动。

受 DiG-Flow [128] 启发, MPG 把 H 视作带噪声的条件信号, 并显式估计其可靠性。当 H 对目标具身形态而言处于分布外时, 用它作为动作专家的条件会注入虚假信号, 迫使模型拟合不一致的速度场, 常常产生抖动动作。因此, MPG 用差异引导的门控降低依赖特征的修正权重, 同时保留不受门控的已学习先验偏置, 以便平稳回退 (见图 7 左侧)。

带无门控先验偏置的门控残差。 MPG 计算门值 $g \in (0, 1]$, 差异越大, g 越小, 并且只调制依赖特征的残差路径:

$$\tilde{H} = H + \lambda P_{\text{MPG}}(g E_{\text{obs}}(H)) = H + \lambda g W_{\text{MPG}} E_{\text{obs}}(H) + \lambda b_{\text{MPG}}. \quad (13)$$

其中, E_{obs} 把 H 投影到公共嵌入空间, $P_{\text{MPG}}(\cdot) = W_{\text{MPG}}(\cdot) + b_{\text{MPG}}$ 生成增强残差。这样便得到直观的回退机制: 当 $g \approx 1$ 时, MPG 信任当前上下文, 允许较强的特征条件适配; 当 $g \approx 0$ 时, 依赖特征的项被抑制, 模型回退到稳定的已学习先验偏置 $H + \lambda b_{\text{MPG}}$ 。由于 b_{MPG} 不受门控, 即使置信度很低, 它仍会影响 $\tilde{H}$, 相当于为不确定上下文学习一种稳健的默认修正。

相对于输出门控的方差降低。 与 DiG-Flow [128] 中的传统输出门控 $\tilde{H} = H + \lambda g R(H)$ 不同, MPG 在投影之前应用门控。当门值波动时, 例如视觉抖动造成波动, 输出门控会同时缩放投影项和偏置, 引入与 $\|W E_{\text{obs}}(H) + b\|_2^2$ 成比例的方差。MPG

只缩放投影项，产生与 $\|W E_{\text{obs}}(H)\|_2^2$ 成比例的方差。由于无门控偏置不随 g 变化，MPG 在上下文扰动下会生成更平滑的轨迹。

差异与门值计算。 为评估上下文可靠性，我们从无噪声动作构造动作先验锚点。令 Z^{nf} 表示在零噪声水平编码的无噪声动作 token 嵌入，通过均值池化将其概括为 $\bar{Z} = \text{MeanPool}(Z^{\text{nf}})$ 。直观上， $\bar{Z}$ 描述了模型训练分布下合理动作嵌入的流形。我们使用切片 Wasserstein 距离 (SWD) [129,130]，在共享且尺度不变的空间中量化特征与动作的分布差异：

$$D(\mu_{\hat{H}}, \mu_{\hat{Z}}) \approx \frac{1}{M} \sum_{m=1}^M \left\| \text{sort}(\theta_m^\top \hat{H}) - \text{sort}(\theta_m^\top \hat{Z}) \right\|_2^2. \quad (14)$$

其中， θ_m 是随机单位方向， $\hat{H} = \text{LN}(E_{\text{obs}}(H))$ ， $\hat{Z} = \text{LN}(E_{\text{act}}(\bar{Z}))$ 。计算 D 时， $\bar{Z}$ 沿观察序列长度广播。差异产生一个经过温度缩放的可靠性门值：

$$g = \exp(-D/\tau) \in (0, 1]. \quad (15)$$

实践中，我们对门值使用停止梯度操作 $g^{\text{sg}} = \text{stopgrad}(g)$ ，防止模型学习操纵 g 而不是提高底层特征质量这种退化解。这样， g 就只作为增强路径上的缩放因子。不考虑通过 g 的反向传播时，雅可比矩阵近似为：

$$\frac{\partial \tilde{H}}{\partial H} \approx I + \lambda g W_{\text{MPG}} \frac{\partial E_{\text{obs}}(H)}{\partial H}. \quad (16)$$

该形式保证上下文不可靠、 g 较小时，依赖特征的修正会越来越不敏感，为分布外观提供稳健保护。

5.3.3 通用异步分块

动机。 在实体硬件上部署动作分块策略会产生根本性的时间错位：模型计算下一个动作块时，机器人必须继续执行此前已经提交的轨迹。在仿真环境中，这种延迟差距常可忽略；但在真实机器人上，推理延迟会直接造成控制不连续和灾难性任务失败。

训练时实时分块 (RTC) [131] 通过在训练阶段模拟推理延迟缓解这一问题：前缀动作被分配干净时间步 $t = 1$ ，后缀动作接受随机带噪时间步 $t < 1$ ，损失只在后缀上计算。然而，RTC 通常只针对单个平台实例化。这对跨具身形态 VLA 仍是重大限制，因为不同机器人平台具有不同的控制周期和延迟预算。

UAC 扩展 RTC，使延迟具备具身形态感知能力。对于控制周期为 $\Delta t^{(e)}$ 、预期推理延迟预算为 $L^{(e)}$ 的具身形态 e ，以控制步数计的有效延迟缩放为 $\lceil L^{(e)} / \Delta t^{(e)} \rceil$ 。UAC 使用具身形态专属的延迟分布和最大延迟阈值，并与 ESA 联合训练，使一个检查点可以适应不同的运行时特征（见图 7 右侧）。

具身形态感知的延迟采样与目标。我们采样延迟：

$$d \sim \pi^{(e)}(d), \quad d \in \{0, 1, \dots, d_{\max}^{(e)} - 1\}. \quad (17)$$

分布 $\pi^{(e)}$ 和最大延迟 $d_{\max}^{(e)}$ 都根据相应具身形态的控制频率与预期推理延迟配置。沿用 RTC，我们把每个动作块划分成承诺前缀 $A_{<d}$ 和预测后缀 $A_{\geq d}$ ，并为各 token 分配时间步：

$$t_i = \mathbf{1}[i < d] + \mathbf{1}[i \geq d] t_{\text{base}}, \quad t_{\text{base}} \sim p(t). \quad (18)$$

训练目标排除前缀位置：

$$\mathcal{L}_{\text{UAC}} = \sum_{i \geq d} \|\hat{v}_i - v_i^*\|_2^2. \quad (19)$$

UAC 与具身形态专属适配结合，训练统一模型为不同机器人生成平滑续写；每种机器人可以有各自的延迟特征，同时仍与第 6.3 节所述、通过双线程缓冲区进行的实时异步部署兼容。

6 基础设施：实时跨具身形态部署

要弥合高容量 VLA 模型与真实机器人控制之间的差距，需要一套优先保证时间一致性、分布偏移鲁棒性和低延迟执行的部署流水线。本文设计了一套推理基础设施，把 Being-H0.5 的跨具身形态与异步能力转化为稳健的实时控制。具体而言，这套基础设施由三个紧密耦合的组件组成：一是使用缓存前缀特征提高效率的整流流动作推理；二是由 MPG 驱动的流形保持细化，用于稳定发生偏移时的推理；三是通用异步分块协议，以及用于在异构平台上连续控制的双线程环形缓冲区架构。MPG 和 UAC 机制可回看图 7。

6.1 流形保持细化

整流流去噪。 动作生成遵循基于整流流的迭代去噪过程。从高斯噪声 $a^{(0)} \sim \mathcal{N}(0, I)$ 开始，我们使用欧拉步积分已学习的速度场 v_θ ：

$$a^{(k+1)} = a^{(k)} + \Delta t v_\theta(a^{(k)}, t^{(k)} | H), \quad \Delta t = 1/K, \quad t^{(k)} = k/K. \quad (20)$$

其中， K 是去噪步数， H 表示动作专家使用的 token 级上下文特征。如第 5.3.2 节所述， H 由静态视觉—语言前缀和动态后缀组成，后者是状态 token 与当前动作 token 嵌入的拼接。去噪期间，只有动作 token 嵌入随 $a^{(k)}$ 演化，因此可以缓存视觉—语言前缀的 KV，以提高效率。实践中，我们保持 $K < 10$ ，在动作保真度和延迟之间取得平衡。

MPG 在这种少步数设置下尤其有价值：它在置信度低时提供稳定回退，降低模型对带噪声上下文的敏感性，使较少去噪步数也能取得良好表现（图 7 左侧）。

使用 MPG 的两阶段细化。 推理时启用 MPG 后，我们采用轻量的两阶段策略：第一步由一次基线运行生成参考预测；第二步使用少量细化轮次，把前一次预测作为代理锚点，计算差异并对特征增强执行门控。

1. **阶段 1：无 MPG 的基线预测。** 首先，以原始上下文特征 H 运行整流流去噪，得到初始预测 $a_{\text{pred}}^{(0)}$ 。该基线在分布偏移下可能不是最优，但它为构造 MPG 动作锚点提供了具体参考。
2. **阶段 2：使用 MPG 的迭代细化。** 随后执行 N_{ref} 轮细化；实践中 $N_{\text{ref}} \in \{1, 2, 3\}$ 。在第 n 轮细化中，我们根据前一次预测形成无噪声参考动作嵌入：

$$\bar{Z}^{(n-1)} = \text{MeanPool}\left(\text{Enc}(a_{\text{pred}}^{(n-1)}, \sigma = 0)\right), \quad a_{\text{pred}}^{(n)} = \text{FlowDenoise}\left(H; \bar{Z}^{(n-1)}\right).$$

其中， σ 表示动作噪声水平， $\sigma = 0$ 表示无噪声。MPG 在去噪循环内部的每个欧拉步应用，作用于当前后缀特征，并把 $\bar{Z}^{(n-1)}$ 作为计算差异的参考动作锚点（第 5.3.2 节）。直观而言，这形成了一个反馈循环：更好的动作产生更好的锚点，更好的锚点产生更准确的门值，进而产生更稳健的特征。

MPG 为何有助于少步数设置。 MPG 的输入门控形式与较小的 K 尤其相容。当门值 g 较低，即差异较大时，MPG 抑制依赖特征的修正，回退到无门控先验偏置，实际上变成 $\tilde{H} \approx H + \lambda b_{\text{MPG}}$ 。这会在不确定情况下稳定速度场预测 $v_{\theta}(\cdot | \tilde{H})$ ，缩短流从噪声到可行动作模态所需跨越的“距离”。实验中，即使 $K < 10$ ，性能通常也会在 2 至 3 轮细化内饱和。

6.2 通用异步分块协议

动机。 真实机器人持续执行动作，而推理是间歇进行的。使用动作块生成时，这会造成时间错位：模型计算新动作块期间，机器人仍在执行此前已经提交的动作。如果策略忽略这种错位，推理延迟会造成轨迹不连续和控制卡顿。

训练时 RTC [131] 通过模拟推理延迟，并只在后缀上计算损失来处理这种错位。这里，我们把该原则明确形式化为跨具身形态部署协议：根据延迟提交一个前缀，在整个去噪期间锁定该前缀，只把后缀拼回执行缓冲区（图 7 右侧）。

延迟承诺。 每个推理周期开始前，我们声明延迟 d ，作为新动作块就绪前将被执行的控制步数上界：

$$d \geq \left\lceil t_{\text{inference}} / t_{\text{control}}^{(e)} + \epsilon_{\text{safety}} \right\rceil. \quad (22)$$

其中， $t_{\text{control}}^{(e)}$ 是具身形态专属控制周期， ϵ_{safety} 是吸收时间抖动的小余量。一个关键性质是：高估是安全的，低估会破坏连续性。高估 d 只会增加锁定前缀的长度；低估意味着机器人会执行模型未曾纳入条件的动作，造成不连续。

跨具身形态部署时，我们根据三项因素为每个平台配置 d ：控制周期 $t_{\text{control}}^{(e)}$ ，频率越高，每秒步数越多；预期推理延迟 $t_{\text{inference}}$ ，取决于模型和硬件；以及安全余量 ϵ_{safety} ，取决于平台容忍度。

硬前缀锁定，去噪时约束。 去噪期间，我们在所有欧拉步强制保持前缀一致：

$$a_i^{(k)} \leftarrow \begin{cases} B_i, & i < d, \\ a_i^{(k)}, & i \geq d, \end{cases} \quad \forall k \in \{0, \dots, K\}. \tag{23}$$

其中， B 是包含最近已提交动作的执行缓冲区。这样可以防止流“编辑”正在执行、或会在推理完成前执行的动作。

硬拼接，缓冲区更新规则。 去噪完成后，我们丢弃前缀 $a_{<d}$ ，只把后缀 $a_{\geq d}$ 写入缓冲区：

$$a_{\text{exec}}^{(n)} = a_{<d}^{(n-1)} \oplus a_{\geq d}^{(n)}. \tag{24}$$

只要遵守式（22）的延迟承诺，这就能保证连续性。

表 2：异构真实机器人具身形态的硬件规格。

组别	名称	自由度	关节结构	手部	相机	配置
半身人形	PND Adam-U	31	双臂+头部+腰部	灵巧手（6自由度）	ZED Mini	可移动第一视角，双相机
半身人形	Unitree G1+ LinkerBot O6	26	双臂	灵巧手（6自由度）	D435	固定第一视角
单臂+灵巧手	FR3+Inspire Hand	13	单臂	灵巧手（6自由度）	2×D435	固定第三视角
单臂+灵巧手	BeingBeyond D1	14	单臂	灵巧手（6自由度）	D435	可移动第一视角
单臂+夹爪	LeRobot SO-101	6	单臂	夹爪	D435	固定第三视角

6.3 双线程部署架构

为实时实现 UAC，我们将推理和控制解耦为两个独立线程，通过共享环形缓冲区 B 通信（图 7 右侧）：

- **控制线程，消费者。** 以固定频率 $1/t_{\text{control}}^{(e)}$ 运行，从 B 中取出动作并发送给机器人。如果缓冲区余量不足，它会保持最后一个动作，或执行平台专属的安全回退，以避免不连续。
- **推理线程，生产者。** 异步运行：获取观察，执行整流流去噪，可选择使用第 6.1 节的 MPG 细化，然后从偏移 d 开始，只把后缀动作写入 B 。

我们把环形缓冲区容量设置为至少两倍动作块长度，以降低典型延迟抖动下缓冲区耗尽的风险。轻量互斥锁只在短暂读写操作期间保护并发访问，保证线程安全，又不引入明显阻塞。

收益。 该架构提供三项优势：第一，吸收延迟，推理抖动不会转化成控制抖动；第二，平稳退化，缓冲区耗尽时触发安全回退，而不是未定义行为；第三，跨具身形态兼容，通过调整 (d, B) 参数和延迟余量，同一协议可以支持不同控制频率与计算预算的机器人。

这些基础设施组件共同使一个通用 Being-H0.5 检查点可以在不同平台上实时运行，例如从 10 Hz 桌面操纵器到 50 Hz 人形机器人；无论是在网络延迟高的云端计算环境，还是在计算性能有限的边缘部署环境，例如 NVIDIA Orin NX，它都能维持平滑、连续的控制。

7 实验

7.1 真实机器人间的比较

我们在五种真实世界具身形态上评估 Being-H0.5；它们在形态、传感配置和操作特征上均有显著差异。我们设计了共 10 项任务，用于严格评估四个核心目标：第一，分析空间、长时程、双臂和泛化能力；第二，验证单一检查点能否作为通用模型部署到异构具身形态；第三，量化它与具身形态专属优化模型之间的性能差距；第四，通过消融隔离对实时鲁棒性至关重要的架构与数据组件。

7.1.1 实验设置

实验硬件配置见图 8，受测具身形态和传感设置汇总于表 2，完整真实机器人任务集见表 3。每项任务采集 30 至 60 分钟的真实机器人示范数据。我们在相同评估基础设施下比

较 Being-H0.5 与以下方法：

- **Being-H0.5-specialist**。从预训练骨干开始进行具身形态专属后训练，使用某一机器人平台上采集的完整任务集，分别为每个平台微调模型。
- **Being-H0.5-generalist**。用所有具身形态和所有任务联合后训练的单一检查点，可以部署到五个平台。
- **Being-H0.5-scratch，专用与通用版本**。不使用 UniHand-2.0 预训练的基线。它采用与 Being-H0.5 相同的 MoT 架构和后训练流水线，但初始化时没有通过 UniHand-2.0 进行以人为中心的机器人学习。我们同时报告专用和通用版本，以隔离大规模人类—机器人预训练对跨具身形态迁移的贡献。
- $\pi_0.5$ 。一个有竞争力的开源 VLA 基线，使用相同的逐具身形态数据微调。需要注意， $\pi_0.5$ 使用具身形态专属动作接口，需要补零到固定维度，因此原生不支持跨具身形态通用设置；本文只在专用设置下评估它。

【图 8 位置】五种真实机器人平台依次为：(a) FR3 与 Inspire Hand；(b) Unitree G1 与 LinkerBot O6；(c) PND Adam-U；(d) BeingBeyond D1；(e) LeRobot SO-101。

图 8：真实机器人具身形态。我们在五种机器人平台上评估，覆盖半身人形机器人、单臂灵巧操作和轻量平行夹爪。

表 3：真实机器人任务集及指令。任务按照所需操作能力分类。

类别	任务	具身形态	指令
空间	插花	Adam-U	“把花整齐地插进花瓶。”
空间	浇花	FR3+ Inspire	“用手拿住洒水壶，给植物浇水。”
空间	叠碗	FR3+ Inspire	“拿住碗的边缘，逐个把它们叠在盘子上。”
空间	叠积木	D1	“按照颜色顺序 <ORDER> 叠放积木。”
长时程	抽屉：打开→放入→关闭	FR3+ Inspire	“打开抽屉，把 <OBJECTS> 放进去，然后关上抽屉。”
长时程	包裹：翻转→扫描	G1+O6	“翻转包裹，然后用扫描器扫描条形码。”
双臂	交接→放入箱子	Adam-U	“用双手拿起并传递 <OBJECTS>，把它放进箱子。”
双臂	装入两件产品→合盖	G1+O6	“用双手把 <OBJECTS> 放进箱子，然后合上盖子。”

类别	任务	具身形态	指令
泛化	擦白板	FR3+ Inspire	“用板擦清理白板上任意有标记的区域。”
泛化	清理桌面	Adam-U	“清理桌面：把所有物体放进箱子。”
泛化	清理桌面	SO-101	“清理桌面：把所有物体放进盘子。”

评估协议。 真实机器人评估的一项主要风险是操作者偏差，它会严重损害比较的公平性。为避免这种偏差，我们通过统一黑盒推理服务器实施盲测协议。协议的核心是把所有候选策略端点封装进统一黑盒推理服务器。服务器只暴露一个标准化接口，保证每个模型使用完全相同的评估基础设施。

每次评估前，我们为每项任务预先定义 N 种不同布局，系统改变物体位置、朝向和场景布置，以覆盖预期运行分布并挑战边界情况。评估时，每次试验都通过以下自动化盲测流程执行：

- **配置采样。** 系统随机采样 N 种预定义配置中的一种，并据此重置场景。
- **策略采样。** 系统从候选池中随机选择一项策略。关键是，策略身份对人类操作者完全隐藏。
- **盲测执行与评分。** 操作者不知道当前评估的是哪个模型。任务完成或超时时，操作者只依据预先定义的客观成功标准，记录二元的成功／失败结果。

上述过程重复到满足停止条件：每项策略在每个预设配置下都必须恰好评估 K 次，默认 $K = 20$ 。为保证统计有效性，该协议满足三项关键性质：所有策略遇到完全相同的环境条件；人类操作者无法有意或无意偏袒特定模型；评估顺序随机化，以避免机器人磨损、光照漂移等时间混杂因素。

7.1.2 结果分析

图 9 展示实验执行示例，图 10 汇总真实机器人上的分类成功率。下面详细分析实验结果。

专用模型最强，但通用模型出人意料地接近。 与具身形态专属适配的预期一致，Being-H0.5-specialist 在多数类别中表现最好。值得注意的是，在空间、长时程和双臂类别中，Being-H0.5-generalist 只略微落后。在若干共享技能很多的设置中，通用模型甚至优于专用模型。实验上，联合训练增加了模型接触共享子技能的机会，例如接近—抓取—放置、盖子／把手交互、平面擦拭／清理，从而提高模型对布局变化、部分遮挡和相机漂移等干扰因素的鲁棒性，又不至于过拟合单一具身形态。

显著超过 $\pi_0.5$ ，在长时程与双臂任务上尤其明显。 两个 Being-H0.5 版本都显著优于 $\pi_0.5$ 。差距在长时程和双臂类别中最大，因为细微的感知／控制错位会不断累积。一个

关键差异是，Being-H0.5 在统一状态—动作空间中训练和部署，并显式采用跨具身形态设计；而本文设置中的 $\pi_0.5$ 仍受具身形态专属动作接口约束，无法利用联合训练。

【图 9 位置】五种代表性真实机器人任务的完整执行示例：1. 插花，“把花整齐地插进花瓶”；2. 扫描包裹，“翻转包裹，然后用扫描器扫描条形码”；3. 浇花，“用手拿住洒水壶，给植物浇水”；4. 叠积木，“按照红、蓝、黄的颜色顺序叠放积木”；5. 清理桌面，“把所有物体放进盘子”。每种具身形态只展示一项任务，全部任务执行过程见附录 B。

图 9：代表性真实机器人任务集的执行示例。

UniHand-2.0 预训练对强大的通用模型至关重要。 在专用设置下，移除 UniHand-2.0 的消融模型仍具有不可忽视的表现，依然能从真实机器人微调数据中学习；这说明我们的架构和后训练流水线提供了较强归纳偏置。然而，通用消融模型性能显著下降，无法追上相应的专用模型。这种反差说明，大规模、跨具身、以人为中心的预训练不只是“增加数据”：它提供广泛的操作先验，能够稳定异构具身形态混合数据上的优化，并实现跨平台正迁移。

具身形态级零样本迁移。 除分布内评估外，我们观察到显著的具身形态级零样本迁移现象。具体来说，完成跨具身形态后训练后，单个 Being-H0.5-generalist 检查点可以部署到 Adam-U，解决此前未见的任务—具身形态组合，即我们完全没有为 Adam-U 采集示范的任务。在与其他具身形态示范任务相似的环境中，Adam-U 获得非零成功率，并且稳定表现出符合任务的多步执行。

示例包括：第一，类似 G1 包裹流水线的翻转并扫描行为，机器人会重新调整包裹方向，使标签区域露出，再让扫描器靠近；第二，与 FR3 长时程任务一致的抽屉交互行为，机器人会伸向类似把手的可供部位、拉开抽屉、尝试放入物体，再关闭抽屉；第三，类似 D1 积木任务的堆叠行为，机器人会以明确的堆叠意图依次抓取和放置。

虽然零样本成功率仍低于分布内表现，运动精度也不够可靠，但策略明确展示出一种能力：可以在新的运动学链条上实例化从其他形态学结构学到的任务结构。

我们把这种能力归因于全文强调的两个设计选择：统一动作空间鼓励模型学习可迁移运动原语，而不是具身形态专属的动作惯例；跨具身形态联合后训练让模型看到相同底层任务抽象的不同实现，包括物体、目标和子目标组合。据我们所知，这是 VLA 策略在真实机器人部署中实现具身形态级零样本任务完成的首个实验证据，尽管成功率还较低。我们认为，这一结果揭示了 VLA 一个有前景的扩展方向：提高后训练数据的多样性与覆盖范围，再结合统一动作接口，可能为跨具身策略铺平道路，使它们以组合方式超越有限的任务—具身形态配对，逐步获得更多可迁移的涌现智能。

【图 10 位置】四类真实机器人任务的成功率柱状图，对比 Being-H0.5 专用／通用模型、 $\pi_0.5$ ，以及从零训练的 Being-H0.5 专用／通用消融模型。各类别对应数值依图中系

列为：空间 75、70、55、50、35；长时程 60、60、45、35、25；双臂 55、45、40、25、30；泛化 75、80、65、60、50。

图 10：四类真实机器人任务的成功率（%）。我们比较 Being-H0.5 专用／通用模型、从零训练的专用与通用消融，以及 $\pi_0.5$ 。

7.2 仿真基准比较

我们在两个广泛使用的仿真基准 LIBERO [135] 和 RoboCasa [136] 上评估 Being-H0.5，并与近期 VLA 系统及专用机器人策略比较。除非另有说明，Being-H0.5 只使用分辨率为 224×224 的 RGB 观察和 2B 骨干。

专用与通用。 本节同样报告两种训练设置：专用设置只使用一个基准的数据，为 LIBERO 或 RoboCasa 分别训练检查点；通用设置在 LIBERO 与 RoboCasa 上联合训练单一检查点。为使优化量公平，通用设置的训练步数是专用模型的两倍，使模型在学习跨两个测试平台的统一策略时，每个基准获得的更新步数大致相当。评估时，同一个通用检查点直接在两个基准上评估，不做额外适配。

7.2.1 LIBERO 结果

实验设置。 我们遵循标准 LIBERO 评估协议 [135,137]。策略输入多视角 RGB 观察，包括腕部相机和第三视角相机，均缩放到 224×224 。动作块大小为 8，训练使用打包序列，每块 GPU 处理 7680 个 token，有效批大小为 128。专用模型使用 4 张 A800 GPU 优化 45,000 步。通用模型在 LIBERO+RoboCasa 混合数据上训练约两倍步数。评估时，每个任务集运行 500 次试验。

表 4：LIBERO 基准成功率（%）。 每项任务报告 50 次评估轨迹的平均成功率。原文以粗体和下划线分别标记最佳和次佳结果。

方法	L-Spatial	L-Object	L-Goal	L-Long	平均
Diffusion Policy [20]	78.5	87.5	73.5	64.8	76.1
OpenVLA [6]	84.7	88.4	79.2	53.7	76.5
SpatialVLA [28]	88.2	89.9	78.6	55.5	78.1
CoT-VLA [132]	87.5	91.6	87.6	69.0	83.9
π_0 -Fast [133]	96.4	96.8	88.6	60.2	85.5
GR00T-N1 [9]	94.4	97.6	93.0	90.6	93.9
π_0 [8]	98.0	96.8	94.4	88.4	94.4

方法	L-Spatial	L-Object	L-Goal	L-Long	平均
F1 [134]	98.2	97.8	95.4	91.3	95.7
InternVLA-M1 [54]	98.0	99.0	93.8	92.6	95.9
Discrete Diffusion VLA [31]	97.2	98.6	97.4	92.0	96.3
$\pi_0.5$ [34]	98.8	98.2	98.0	92.4	96.9
OpenVLA-OFT [91]	97.6	98.4	97.9	94.5	97.1
X-VLA [11]	98.2	98.6	97.8	97.6	98.1
EO1 [94]	99.7	99.8	99.2	94.8	98.2
Being-H0.5（通用）	97.0	98.2	99.0	96.2	97.6
Being-H0.5（专用）	99.2	99.6	99.4	97.4	98.9

结果与分析。表 4 显示，Being-H0.5 专用模型在 LIBERO 上达到 98.9% 的平均成功率，在所有任务集上都很强，包括 LIBERO-Long 的 97.4%。在 LIBERO+RoboCasa 上联合训练两倍步数的通用模型也很有竞争力，平均成功率为 97.6%。两者差距很小，说明单一检查点可以吸收大量跨基准多样性，而不显著牺牲 LIBERO 性能，尽管通用模型除了覆盖 LIBERO 的任务分布，还必须分配容量处理 RoboCasa 的长时程厨房交互。关键在于，两项结果都只使用 224×224 RGB 输入和 2B 骨干，已经追平或超过许多分辨率更高、模型更大或使用多模态输入的系统。

7.2.2 RoboCasa 结果

实验设置。我们在 RoboCasa [136] 上评估；它包含不同厨房环境中的 24 项长时程家务任务。我们采用具有挑战性的 Human-50 少样本设置，每项任务使用 50 条人类示范。在五个保留场景中，每项任务进行 50 次试验，场景包含未见物体实例和未见厨房风格。输入只有 224×224 RGB 和自然语言任务命令，不使用深度或点云。专用模型使用与上文相同的训练预算，只使用 RoboCasa；通用模型在 LIBERO+RoboCasa 上联合训练两倍步数。

表 5：RoboCasa 24 项任务基准成功率（%）。结果按三类任务汇总，每项任务平均 50 次试验。原文以粗体和下划线分别标记最佳和次佳结果。

模态	方法	抓取放置	门／抽屉	其他	总平均
3D 多模态	3DA [138]	0.0	2.3	13.1	5.5
3D 多模态	DP3 [139]	1.5	41.7	32.0	22.8
3D 多模态	GWM [140]	14.8	54.3	49.8	39.3

模态	方法	抓取放置	门／抽屉	其他	总平均
RGB 256 × 256	BC [136]	4.3	47.0	42.2	28.9
RGB 256 × 256	GR00T-N1 [9]	18.6	50.2	39.1	36.0
RGB 256 × 256	$\pi_{0.5}$ [34]	21.5	57.8	44.9	41.4
RGB 256 × 256	π_0 [8]	14.0	53.1	58.5	42.4
RGB 224 × 224	Being-H0.5（通用）	40.0	73.0	52.0	53.3
RGB 224 × 224	Being-H0.5（专用）	36.0	71.7	57.6	53.9

结果与分析。如表 5 所示，Being-H0.5 在 RoboCasa 上创造了新的最佳结果：专用检查点成功率为 53.9%，通用单检查点模型为 53.3%。值得注意的是，通用模型在维持很强 LIBERO 表现的同时，几乎完整保留了 RoboCasa 性能；这表明在统一动作接口下，联合训练没有在两个基准之间引入严重负迁移。最大提升出现在抓取放置任务，Being-H0.5 达到 36% 至 40% 的成功率，大幅超过此前 VLA，例如 $\pi_{0.5}$ 的 21.5%，甚至超过使用显式 3D 输入的多模态基线。这一点尤其显著，因为 RoboCasa 的抓取放置要求在外观变化下进行可靠空间推理，并保持抓取—搬运—放置协调一致。结果说明，大规模以人为中心的预训练能够提炼可迁移空间先验，即使输入只有 RGB 且分辨率较低，这些先验依然有效。

结论。在两个基准上，如果允许针对基准适配，专用设置给出了性能上界；通用设置则表明，单个 Being-H0.5 检查点可以同时覆盖 LIBERO 和 RoboCasa，只在 LIBERO 上有小幅下降，在 RoboCasa 上则几乎完全相同。这为可扩展部署提供了一条实际路径，因为实际部署不希望维护大量基准专属检查点。

7.3 消融研究

7.3.1 以人为中心的学习如何促进下游适配？

以人为中心的学习提供基础先验，有助于高效适应下游机器人任务。本节分析这些预训练权重对适配过程的具体影响。机器人基准经常面临过拟合风险；为了降低这一风险并严格评估少样本泛化，我们采用 LIBERO 5-shot 基准，并把训练窗口限制为 10,000 步。只使用极少量训练样本，可以有效区分性能提升究竟直接来自预训练知识，还是来自任务专属的死记硬背。

验证采用两种协议：第一，**单任务集**，为每个 LIBERO 任务集分别训练模型，观察预训练在单一任务场景中的效果；第二，**多任务集**，在全部任务集上训练统一模型，评估预训练 VLA 适应大规模、多样任务分布的能力。结果见表 6 和表 7。表中比较了以本文人

类中心预训练权重初始化的模型，以及直接以原生 VLM 初始化的基线。所有实验配置中的动作专家都保持可训练。图 11 和图 12 进一步研究动作专家对参数冻结的敏感性。

表 6：以人为中心的学习对单任务 5-shot 适配的影响。 我们选择性冻结关键架构组件进行研究。“原生 VLM”表示从原始大型多模态模型初始化，“人类中心”表示从本文的人类中心预训练权重初始化。所有设置中的动作专家均可训练。 Δ 表示绝对性能增益。Und 为理解专家，Proj 为投影器，ViT 为视觉编码器。

冻结组件	初始化	L-Spatial	L-Object	L-Goal	L-Long	平均
Und+Proj+ViT	原生 VLM	67.8	76.8	57.2	29.8	57.9
Und+Proj+ViT	人类中心	78.6	78.9	72.6	46.2	69.0
Und+Proj+ViT	增益 Δ	+10.8	+2.1	+15.4	+16.4	+11.1
Und+ViT	原生 VLM	70.6	50.0	67.0	17.4	51.3
Und+ViT	人类中心	85.0	84.2	80.0	59.0	77.1
Und+ViT	增益 Δ	+14.4	+34.4	+13.0	+41.6	+25.8
仅 Und	原生 VLM	78.4	84.8	62.0	49.2	68.6
仅 Und	人类中心	83.2	79.6	74.0	63.6	75.1
仅 Und	增益 Δ	+4.8	-5.2	+12.0	+14.4	+6.5
Proj+ViT	原生 VLM	87.2	86.6	80.8	58.0	78.2
Proj+ViT	人类中心	86.2	86.2	84.6	66.8	81.0
Proj+ViT	增益 Δ	-1.0	-0.4	+3.8	+8.8	+2.8
无，全量微调	原生 VLM	84.2	83.6	75.0	65.8	77.2
无，全量微调	人类中心	87.2	91.4	81.6	66.8	81.8
无，全量微调	增益 Δ	+3.0	+7.8	+6.6	+1.0	+4.6

表 7：以人为中心的学习对多任务 5-shot 适配的影响。 与单任务设置不同，模型在四个任务集的全部数据上联合训练，再分别在各任务集上评估。这一多任务协议用于严格评估 VLA 在多样跨任务场景下的泛化能力与鲁棒性。

冻结组件	初始化	L-Spatial	L-Object	L-Goal	L-Long	平均
Und+Proj+ViT	原生 VLM	61.6	77.0	68.0	36.0	60.7
Und+Proj+ViT	人类中心	80.8	81.8	74.4	52.4	72.4
Und+Proj+ViT	增益 Δ	+19.2	+4.8	+6.4	+16.4	+11.7

冻结组件	初始化	L-Spatial	L-Object	L-Goal	L-Long	平均
Und+ViT	原生 VLM	78.4	84.8	71.4	38.6	68.3
Und+ViT	人类中心	83.6	82.6	80.8	59.2	76.6
Und+ViT	增益 Δ	+5.2	-2.2	+9.4	+20.6	+8.3
仅 Und	原生 VLM	75.8	84.2	71.2	59.8	72.8
仅 Und	人类中心	85.2	90.6	84.2	68.4	82.1
仅 Und	增益 Δ	+9.4	+6.4	+13.0	+8.6	+9.3
Proj+ViT	原生 VLM	87.6	91.0	82.2	62.6	80.9
Proj+ViT	人类中心	89.6	88.8	89.6	65.8	83.5
Proj+ViT	增益 Δ	+2.0	-2.2	+7.4	+3.2	+2.6
无，全量微调	原生 VLM	87.8	94.6	82.6	71.4	84.1
无，全量微调	人类中心	88.8	90.2	85.4	76.0	85.1
无，全量微调	增益 Δ	+1.0	-4.4	+2.8	+4.6	+1.0

骨干预训练的影响。 结果揭示了权重初始化如何影响不同范式下的 VLA 性能。首先，参数约束最强时，预训练的影响最明显。如表 6 所示，冻结核心推理组件 Und+ViT，只允许投影器和动作专家训练时，预训练模型比基线的平均成绩高出显著的 25.8 个百分点。

单任务和多任务设置中都有一个一致趋势：LIBERO-Long 从预训练中获得的收益格外大。在单任务设置中，冻结 Und+ViT 后，Long 任务集的提升高达 41.6 个百分点。这说明，简单空间或物体任务可以用 50 条示范从头学会，但长时程操作所需的时间一致性与意图锚定，几乎完全来自预训练 VLM 中嵌入的基础“世界知识”。

有意思的是，随着可训练参数增加、设置逐渐接近全量微调，预训练的边际效用 Δ 会下降。在 L-Object 等情况下，我们甚至观察到轻微负迁移，例如多任务全量微调中的 -4.4 个百分点。这表明，对于较简单、以物体为中心的任务，激进联合微调可能会“覆盖”专门的预训练特征，转而采用任务专属启发式。消融证实，语言骨干 Und 和视觉骨干 ViT 是通用机器人能力的主要载体；它们提供稳定的“意图流形”，在下游数据稀少时防止过拟合。

动作专家可塑性的敏感性。 骨干受益于稳定性，而动作专家需要可塑性。我们研究了冻结动作专家不同层的影响，冻结范围从输入端逐渐延伸到输出头，结果见图 11。冻结最初 0 至 7 层几乎不会造成性能下降，大多数任务集的成功率仍稳定高于 80%。然而，冻结层数超过 14 层后，性能会急剧下降；整个专家全部冻结时，成功率低于 20%。图 12 突出了可训练参数量与相对峰值性能之间的权衡。

这说明，以人为中心的预训练可以迁移高层语义规划，但低层运动控制，即从特征到精确关节速度的映射，必须主动从下游示范中学习。因此，在低数据适配中，最佳配置是冻结预训练语义骨干 Und+ViT，同时让动作专家完全可训练。

【图 11 位置】动作专家冻结层数消融。横轴为冻结层数 0、7、14、18、21、24、27、28；纵轴为成功率。分别展示 LIBERO-Spatial、Object、Goal、Long，对比无预训练、人类中心预训练（pt）和 pt+MoF。所有实验冻结 MLLM 的全部参数，包括视觉编码器和投影器。受时间限制，每项任务评估 20 条执行轨迹。原文图注先写“MoF”，图例可辨为 pt+MoE；此处按图注方法名保留为 MoF。

图 11：动作专家冻结层数的消融研究。

【图 12 位置】同样展示四个 LIBERO 任务集上的动作专家冻结层数，并标出可训练参数比例 16.4%、6.5%、0.8%，以及相对性能区间 100%、80–99%、50–79%、低于 50%。所有实验冻结 MLLM 的全部参数，包括视觉编码器和投影器；每项任务评估 20 条执行轨迹。

图 12：动作专家冻结层数的消融研究。

7.3.2 掩码运动 token 预测如何促进捕捉行为先验？

我们进一步验证预训练中加入离散掩码运动 token 预测目标的收益。具体来说，我们进行一项移除 $\mathcal{L}_{\text{mask}}$ 、其余设置不变的消融，并在人类示范数据的保留子集上评估运动生成。评估集按数据来源分成两个域：一是控制设置下采集、由实验室整理的示范；二是场景多样、运动模式异构的野外视频。

由于统一动作空间采用增量表示，平均逐关节位置误差（MPJPE）等典型位置误差指标的信息量较低：初始姿态通常支配此类误差，而本文设置中的初始状态由真值提供。因此，我们改用**平均腕部位移相似度（MWDS）**，衡量模型能否捕捉语言中的意图，并把它落实到图像几何中。具体而言，MWDS 对预测和真值中从初始到最终状态的腕部位移向量余弦相似度 $\cos(\Delta \hat{p}_{\text{wrist}}, \Delta p_{\text{wrist}})$ 求平均。

表 8：掩码运动 token 预测消融。 在保留的人类示范测试集上报告 MWDS，包含实验室整理（Lab）和野外（Wild）划分，指标越高越好。

方法	Lab ↑	Wild ↑
混合表示（本文）	0.33	0.20
移除 $\mathcal{L}_{\text{mask}}$	0.35	0.28

正文称，表 8 显示移除掩码预测会使 Lab 和 Wild 两个划分上的 MWDS 都明显下降。这说明离散掩码目标注入了抽象层面的稳定行为先验，可以改善与意图对齐的生成，并增

强模型面对异构运动模式时的鲁棒性。正文还称，Wild 划分上的提升更显著，因为其中示范的行为变化和观察噪声都高得多；这表明抽象层面的掩码目标对带噪声、大规模、以人为中心的预训练尤其重要。

原文一致性说明：表 8 印刷数值中，移除 $\mathcal{L}_{\text{mask}}$ 的两项 MWDS (0.35、0.28) 反而高于混合表示 (0.33、0.20)，与紧随其后的正文结论相反。这里逐项保留原表和原文，没有自行猜测哪一处有误。

7.3.3 实时效率：MPG 与 UAC

我们进一步消融部署时组件：同时禁用 MPG（流形保持门控）和 UAC（通用异步分块），同时保持骨干与训练数据不变。图 13 显示各类别性能一致下降。

没有 UAC 式异步一致性时，长时程性能急剧下降。 长时程任务包含多阶段行为、执行延迟以及异步感知／驱动。没有 UAC 时，策略对感知状态和动作块已提交部分之间的时间错位更加敏感，造成误差累积，例如抓取漂移、过早接触、把手接合失败，并使成功率明显下降。

没有稳定机制时，双臂协调很脆弱。 双臂任务要求两个末端在部分可观察和接触条件下紧密保持时间耦合。禁用 MPG+UAC 后，当观察上下文带噪声或迅速变化时，振荡和犹豫不决的修正会增加；对于相机可移动的平台尤其如此，因为视角变化可能使短期视觉线索失效。

空间／泛化任务也受影响，但后果没有那么严重。 空间任务仍依赖精确放置，但执行跨度较短，累积的子目标也较少。场景发生变化时，泛化任务可以受益于鲁棒机制，不过通常具有更大的容错和恢复空间，因此下降较小，但仍保持一致。

【图 13 位置】真实机器人上的 MPG+UAC 消融，对比 Being-H0.5-generalist、移除 MPG、移除 UAC、同时移除 MPG+UAC。图中四类任务的柱值依系列顺序为：空间 70、55、65、50；长时程 60、55、40、35；双臂 45、40、20、20；泛化 80、60、80、55。

图 13：真实机器人上的 MPG+UAC 消融。移除 MPG+UAC 对长时程和双臂类别的损害最大，因为执行延迟与不可靠上下文会放大累积误差。

8 结论

本文提出 Being-H0.5，这是一种基础视觉—语言—动作（VLA）模型，建立了一套可扩展、以人为中心的跨具身形态机器人学习范式。通过在有物理依据的状态—动作空间中

统一人类和机器人运动，并利用大规模 UniHand-2.0 数据集，我们证明人类交互轨迹可以作为密集物理先验，弥合不同机器人形态之间的差距。

我们的混合 Transformer（MoT）架构有效地把高层多模态推理与低层运动执行解耦；流形保持门控（MPG）和通用异步分块（UAC）则分别缓解上下文分布偏移与硬件专属推理延迟，保证稳健部署。在由五种异构机器人平台构成的机器人群上进行的广泛评估证明，单个 Being-H0.5 检查点可以内化复杂交互动力学，在双臂协调和长时程任务中取得较高成功率。归根结底，Being-H0.5 标志着机器人智能朝通用、多能方向迈进，使其能够在不同环境和具身形态之间顺畅运行。

参考文献

参考文献共 140 项，保留原文英文书目信息以便检索，见原论文第 34—42 页。正文中的引用编号与原文一致。

附录 A 贡献分工

符号 † 表示该部分负责人。

核心贡献者（按字母顺序）： Hao Luo、Ye Wang、Wanpeng Zhang、Sipeng Zheng。

模型训练： Hao Luo、Ye Wang、Wanpeng Zhang、Sipeng Zheng。

基础设施： Wanpeng Zhang†、Ye Wang、Chaoyi Xu、Chi Zhang、Haoqi Yuan。

人类数据： Hao Luo†、Ziheng Xi、Yiqing Wang、Yicheng Feng。

机器人数据： Ye Wang†、Sipeng Zheng†、Haiweng Xu。

实验： Wanpeng Zhang、Ye Wang、Hao Luo、Sipeng Zheng。

项目负责人： Sipeng Zheng、Zongqing Lu。

附录 B 完整执行过程

【图 14 位置】全部真实机器人任务集的逐帧执行示例，覆盖五种具身形态与表 3 所列所有任务。

图 14：全部真实机器人任务集的执行示例。

