

Being-H0.7：从第一视角视频学习潜在世界—动作模型

原文：Being-H0.7: A Latent World-Action Model from Egocentric Videos。

作者：Hao Luo、Wanpeng Zhang、Yicheng Feng、Sipeng Zheng、Haiweng Xu、Chaoyi Xu、Ziheng Xi、Yuhui Fu、Zongqing Lu（BeingBeyond 团队）。

项目主页：<https://research.beingbeyond.com/being-h07>

版本：arXiv:2605.00078v1，2026 年 4 月 30 日。论文摘要后标注日期为 2026 年 4 月 14 日。

阅读说明：本文按照原文逐段、逐句翻译到第 5 节结论结束，合并 PDF 的跨页断句和排版换行，以中文阅读顺畅为准；公式、数值、表格、图注和引用编号均保留。文中的“我们”指论文作者。图像本身不嵌入译稿，在对应位置标明原文图号并翻译图中关键信息。参考文献及结论后的附录按要求不翻译。

【图 1 位置】左侧对比三种具身模型：VLA 从观察和指令直接生成动作；WAM 从观察和指令生成未来像素及动作；Being-H0.7 的潜在 WAM 包含只在训练时使用的后验分支和用于训练与推理的先验分支。后验分支从观察、指令和未来嵌入生成动作；先验分支从观察、指令和潜在查询生成动作，两者联合对齐。右侧雷达图比较 Being-H0.7、 $\pi_{0.5}$ 、各 VLA 的最高成绩和各 WAM 的最高成绩，覆盖 RoboTwin 2.0、LIBERO、LIBERO-Plus、LIBERO-Plus*、RoboCasa、CALVIN ABC、CALVIN ABCD 和 GR1。

图 1：Being-H0.7 概览。我们构建了一种不同于 VLA 和 WAM 的潜在世界—动作模型。在先验分支中，一组潜在查询引入了潜在推理空间；通过与感知未来的后验分支联合对齐，这一空间进一步获得世界建模能力。Being-H0.7 在大规模第一视角视频上预训练，并在多样的机器人任务中取得强劲表现。

摘要

视觉—语言—动作模型（VLA）把多模态观察和语言指令直接映射为动作，推动了通用机器人控制的发展；然而，稀疏的动作监督经常鼓励模型学习捷径映射，而不是学习动力学、接触和任务进度的表示。近期世界—动作模型通过视频展开引入未来预测，但像素空间预测是一种成本高昂且间接的控制基础：它可能对与动作生成无关的视觉细节建模，并带来大量训练或推理开销。

我们提出 Being-H0.7，这是一种潜在世界—动作模型，无需生成未来帧，便能把未来感知推理引入 VLA 式策略。Being-H0.7 在感知与动作之间插入可学习潜在查询，作为紧凑的推理接口，并采用由未来信息指导的双分支设计来训练这些查询：可部署的先验分支根据当前上下文推断潜在状态，而只在训练时使用的后验分支则用来自未来观察的嵌入替换这些查询。

在潜在推理空间中联合对齐两个分支，使先验分支只依靠当前观察，就能推理具有未来感知能力、且对动作有用的结构。推理时，Being-H0.7 丢弃后验分支，不执行任何视觉展开。六个仿真基准和多种真实世界任务上的实验表明，Being-H0.7 达到当前最佳或相当的性能，把世界模型的预测收益与直接 VLA 策略的效率和可部署性结合起来。

日期：2026 年 4 月 14 日。

1 引言

通用机器人策略正在迅速从任务专属控制器，演进为能够遵循语言指令、感知多样场景，并跨具身形态执行长时程操作的大型具身模型。主流范式之一是视觉—语言—动作模型（VLA）[1–3]，它调整预训练视觉—语言表示，从而把观察和指令直接映射为动作 [4–7]。

VLA 虽然取得了强劲的实验进展，却面临一个关键瓶颈：观察是密集且语义丰富的，动作监督却稀疏，并且与示范高度相关。这种不平衡会鼓励模型从视觉线索到动作学习捷径映射，而不是学习物体动力学、接触和任务进度的中间表示。因此，这些模型通常在分布内表现良好，但当稳健控制要求预判世界如何随交互演化时，就会遇到困难。

世界建模 [8–11] 为解决这一局限提供了一条自然路径：它使机器人能够推理场景可能如何演化，而不只是对当前观察作出反应。近期世界—动作模型（WAM）[12–15] 把未来预测引入机器人学习，通常借助视频生成模型，将视觉展开与动作生成耦合起来 [16–18]。这种“先生成图像、再行动”的范式很有吸引力，因为未来帧可以从大规模无标注数据中提供密集监督。

然而，显式未来预测未必是动作生成的正确基础。操作任务很少需要高视觉保真地重建未来视频；真正需要推断的是决定下一动作的紧凑、动作相关线索，例如接触、物体运动、可供性和任务进度。像素空间预测还具有很强的不确定性：视觉上不同的未来可能对应同一个正确动作，而视觉上合理的未来对控制来说可能无关，甚至会造成误导。因此，密集视觉预测可能把容量消耗在纹理、光照、背景和外观细节上，而这些细节并不能改善动作预测。

这种不匹配还造成效率瓶颈。先生成图像再行动的世界模型继承了视频生成的高昂训练成本，面对互联网规模的视频预训练时很难扩展。推理期间，展开未来帧的方法会在每个控制步引入额外延迟和内存成本；对于接住运动物体或与传送带交互等动态任务，这是一项严重限制。即使某些方法取消了测试时展开，仍然依赖视频生成训练，继承了它的成本、不稳定性以及对不完美像素预测的敏感性。

这些观察提出了另一种观点：未来信息应该塑造策略的内部推理，却不必重建成像素。机器人策略在生成动作之前，应该学会问“哪些与未来相关的信息对控制很重要？”，而不是“下一张图像会是什么样子？”。这要求一种潜在世界—动作模型：既保留直接动作预测的可部署性，又引入显式潜在推理空间，用来组织感知未来、对动作有用的结构。该空间应该足够紧凑，以免产生像素级冗余；又应该有足够的表达力来捕捉动力学和可供性，并与动作生成紧密耦合，使未来建模改善控制，而不是改善视频保真度。

本文提出 **Being-H0.7**，一种在大规模第一视角视频上预训练的潜在世界—动作模型。**Being-H0.7** 不预测未来帧，而是在多模态上下文和动作 **token** 之间引入少量可学习潜在查询。在模型传播期间，这些专用推理槽位关注指令、观察历史和机器人状态，聚合与任务和交互相关的信息，并在生成动作前形成紧凑潜在状态。

这样，动作预测不再被迫直接把原始多模态上下文映射到低层控制。模型先形成关于即将发生的交互中哪些信息最重要的内部潜在表示，再以该表示为条件生成动作。

关键挑战是训练潜在查询，使其支持预测性推理，因为与动作相关的线索没有显式标注。我们采用由未来信息指导的双分支设计来解决这个问题。在可部署的先验分支中，可学习潜在查询被置于专门槽位，根据当前多模态上下文推断对动作有用的预测因素。在后验分支中，这些查询由后续观察中提取的嵌入替换，架构其余部分保持不变。该分支提供了隐式训练目标：如果后续观察已经揭示出来，哪些信息会对动作决策有用？

通过在潜在推理位置对齐两个分支的隐藏状态，先验查询学会只从当前上下文推断类似后验的推理。因此，后续观察在训练期间充当特权监督，而不是部署时的必要输入。推理时，后验分支被完全移除：**Being-H0.7** 在行动前既不生成未来帧，也不执行像素空间展开。它保留 VLA 的效率，同时注入与动作生成直接关联的世界建模信号。

为了使这种潜在未来对齐稳定且可扩展，我们使用范数和秩约束正则化潜在状态，防止幅值缩小和方向坍塌。我们把两个分支打包进一个带双分支注意力掩码的混合 **Transformer** 序列中，以实现双分支设计；这样既能共享上下文计算，又让两条推理路径保持结构对齐。

广泛实验表明，这条潜在路径既有效又可部署。在仿真中，Being-H0.7 在六个基准上取得当前最佳或相当的表现。在真实世界中，我们在三种机器人平台和 12 项高难任务上评估 Being-H0.7，覆盖动态场景、物理推理、运动推理、长时程执行和泛化。Being-H0.7 在全部五个能力导向任务集中领先，包括接住快速滚动的球、向移动容器倾倒、折叠衣物、在传送带上扫描并分拣包裹，以及用锤子钉钉子等任务。

与此同时，部署栈仍然高效：配合具备延迟感知能力的通用异步分块（UAC），Being-H 系列可以在每步 3–4 毫秒的范围内运行，而且不增加测试时生成未来内容的负担。

本文贡献概括如下。第一，我们重新审视面向机器人控制的世界—动作建模，并主张预测应该在面向动作的潜在空间中进行，而不是在像素空间中进行。这样，世界建模被重新定义为学习紧凑、与控制相关的预测因素，避开先生成图像再行动的流水线在训练和推理上的低效率。

第二，我们提出 Being-H0.7，它以可学习潜在查询作为感知与动作之间的显式推理接口。感知未来的后验分支在训练期间监督该接口，而可部署的先验分支只根据当前上下文推断潜在预测状态。

第三，我们开发了一种高效双分支形式，使用隐藏状态对齐和轻量正则化防止潜在表示坍缩，从而支持在大规模第一视角视频上进行可扩展预训练。

最后，我们证明 Being-H0.7 在多样的仿真基准和真实世界任务中取得强劲表现，把世界模型的预测收益与直接 VLA 式策略的效率和可部署性结合起来。

2 相关工作

视觉—语言—动作模型。 机器人操作的近期进展 [19–22] 已从狭窄的单任务专用模型，转向在多样、大规模数据集上训练的通用模型。其中，视觉—语言—动作模型（VLA）[1–3,23–26] 调整预训练视觉—语言模型（VLM）[27–33] 进行机器人控制，并能有效地从当前观察直接预测动作。

一条关键进展路线是动作头设计：早期方法依赖自回归、token 化的动作 [3,34]；近期方法则越来越多地采用基于扩散 [35,36] 的生成器 [4,5,23,37–39]，提高复杂控制的效率和精度 [40–42]。为了更好地支持高层推理，一些工作进一步引入文本规划或结构化中间表示，包括思维链规划（CoT [43]）[44–46]，以及边界框 [48]、稠密对应场 [49]、三维点 [50] 或轨迹痕迹 [51] 等空间抽象 [47]。然而，这些方法仍主要根据当前观察推断动作，没有显式建模世界可能如何随交互演化。

世界—动作模型。 近期工作越来越多地把视频生成和世界建模作为机器人控制的基础，其动机是：视频模型能够捕捉静态视觉—语言预训练中基本不存在的时间动力学和合理未来演化。一类工作主要把视频模型用作预测表示学习器或可迁移世界先验，之后再连接独立的动作解码模块 [52–55]。第二类工作走向更紧密的耦合，在统一架构中联合建模未来视频和动作 [56–58]；这些研究表明，联合预测视觉未来与动作序列可以改善泛化和数据效率。

更近期的工作建立在日益强大的预训练视频基础模型之上，进一步推动统一世界—动作模型，使其支持闭环控制、因果展开或在预测未来上进行规划 [59,60]。DreamZero [12]、Cosmos Policy [13] 和 LingBot-VA [14] 是这一趋势的代表，表明更强的视频先验可以迁移到具身策略中，改善泛化和具身形态迁移。Fast-WAM [15] 表明，在训练期间保留视频联合训练、同时移除测试时未来生成，可以在显著降低延迟的情况下维持强劲动作表现。

本文与这条新兴世界—动作建模路线关系最密切，但不同之处在于，我们不依赖显式未来视频展开，而是用未来信息共同塑造一个直接参与动作生成的潜在推理空间。

【图 2 位置】左侧展示潜在推理：指令 x 、观察与状态 $o_{-H;0}$ ； s 、潜在查询和带噪动作 $a_{0:T}$ 在网络层中依次传播；潜在查询形成与任务相关的未来预测，其隐藏状态引导动作。右侧展示潜在世界—动作模型：训练与

推理都使用先验分支，其中包含共享上下文、潜在查询和带噪动作；只在训练时使用的后验分支读取未来观察，并用未来嵌入替换潜在查询。两个分支的隐藏状态联合对齐。

图 2：潜在推理与潜在世界—动作模型。左：插入可学习潜在查询，形成潜在推理空间；该空间逐步组织中间隐藏状态，并通过传播引导动作生成。右：通过双分支设计之间的联合对齐，模型学会在推理时使用未来信息进行推理，从而成为潜在世界—动作模型。

此外，还有一条相关但不同的趋势，探索在潜在空间中进行未来预测或未来感知对齐，以生成动作 [61–64]。该方向近期出现了多种形式：对未来表示引入多重监督 [65–68]；把动作侧隐藏状态与查询未来所得的状态对齐 [69]；以及把未来观察压缩为对动作有用的条件 [70]。

然而，未来信号通常要么附加到动作预测路径上，要么通过分阶段过程引入，即先学习由未来导出的目标，再从当前上下文预测该目标。本文则把需要与未来对齐的对象放在动作生成之前的显式潜在推理查询中，并在这些查询上联合对齐先验和后验分支。这使潜在空间可以自适应地组织未来感知且能从上下文推断的信息，作为一种用于动作解码的潜在思考。

以人为中心的学习。 收集大规模机器人示范成本高昂，推动了以人为中心的学习：它试图把人类行为中的交互先验迁移到机器人策略。一条路线通过 UMI [71–73] 等便携式物理接口降低数据采集门槛；近期，这类数据已扩展到超过 10,000 小时的机器人兼容示范 [74]。

另一条路线直接从丰富的人类视频语料中学习。人类视频广泛覆盖环境、物体和长时程交互；相关研究已从传统识别与定位 [75,76]，发展到 Ego4D [77]、Ego-Exo4D [78]、EPIC-KITCHENS [79] 和 EgoDex [80] 等大规模第一视角基准。早期工作主要通过表示学习利用这些视频 [81,82]；近期研究则引入更结构化的监督，包括将潜在动作表示作为意图抽象 [83–88]，把未来状态或视频预测作为理解动力学的代理任务 [89–91]，以及点轨迹、关键点和边界框等显式几何线索 [92–99]。

更接近直接策略监督的另一条路线，会从视频中恢复人类动作，例如手部姿态、腕部运动或经过重定向的操作轨迹，用于 VLA 预训练 [100–106]。Being-H0 [6] 通过对重建的人手轨迹进行运动 token 化，扩大了这一范式；Being-H0.5 [7] 又进一步把该方向推广到统一的跨具身形态预训练。本文沿用这条以数据为中心的规模扩展路线，并引入潜在世界—动作建模这种推理形式，把未来感知结构注入人类—机器人 VLA 预训练。

3 方法

3.1 潜在推理：VLA 与世界—动作模型的交汇点

有效的具身模型不仅应该对即时上下文作出反应，还应该真正理解交互可能如何展开。VLA 和视频生成式世界—动作模型的发展，突出了这两个互补方面。标准 VLA 模型擅长把当前观察直接映射为动作，却没有显式建模世界在交互下可能如何演化。相比之下，视频生成式世界模型尝试通过密集像素预测捕捉这种未来演化，但这种做法计算成本高昂，也与物理动力学的抽象层级不匹配。

我们认为，关键并不是在两种范式中二选一，而是通过潜在推理空间把它们连接起来：在生成低层动作之前，先在一个显式中间空间中组织与未来相关、面向动作的信息。

如图 2 左侧所示，我们在骨干中引入少量可学习潜在查询，并将其放在多模态上下文与带噪动作之间，以此实现上述想法。具体来说，令 x 表示指令， $o_{-H:0}$ 表示长度为 H 的观察上下文， s 表示状态。我们在动作块之前插入潜在查询集合 $Q \in \mathbb{R}^{K \times d}$ ，得到增强序列：

$$S = [x; o_{-H:0}; s; Q; a_{0:T}], \quad (1)$$

其中， K 是潜在查询数量， d 是隐藏维度， $a_{0:T}$ 表示长度为 T 的动作块。这些潜在查询定义了潜在推理空间；它们与指令、观察、状态和动作一起，参与 Transformer 逐层传播。

通过各层中的反复交互，潜在查询逐步整合多模态上下文中与任务相关的信息，把它们组织成面向动作的潜在状态，继而塑造下游动作生成。这样，模型不再被迫把抽象多模态语义直接映射为密集低层动作，而是可以在前向传播过程中逐步形成紧凑的中间推理状态，并用它引导动作预测。

然而，仅靠这种形式并不能保证潜在推理过程中真正涌现未来预测。只用动作监督训练时，潜在表示可能坍缩为薄弱的中间表示，或者只编码足以进行局部动作解码的浅层线索。因此，下一节会引入由未来信息指导的对齐机制，把这种潜在推理显式塑造成世界建模。

3.2 潜在世界—动作模型：与未来信息联合对齐

第 3.1 节引入的潜在推理空间，为中间推理提供了显式基础，但它本身并不能保证潜在查询会组织有意义、与未来相关的结构。为了用未来信息塑造这一空间，同时保留可部署的推理路径，我们引入图 2 右侧所示的双分支训练设计。

双分支设计。 我们构建两个结构匹配的分支，它们共享相同的上下文、骨干和动作生成路径。先验分支是主要的可部署分支；其中，动作生成只以当前指令、观察上下文、状态和一组可学习潜在查询为条件。与之并行的是只在训练时使用的后验分支，它能够读取未来观察 $\tilde{o}_{0:T}$ 。

我们在后验分支中用一组形状相同的紧凑未来嵌入替换潜在查询，使两个分支在潜在推理位置保持结构对齐。具体来说，未来观察先由冻结的预训练 ViT 编码，再由 Perceiver 重采样器聚合为 K 个未来嵌入：

$$z^{\text{post}} = E(\tilde{o}_{0:T}) \in \mathbb{R}^{K \times d}, \quad (2)$$

其中， E 表示由冻结 ViT 和 Perceiver 重采样器组成的时间视觉编码器。这里的 K 与先验分支中的潜在查询数量相同， d 是隐藏维度。

在动作监督下，两个分支自然捕捉用于动作生成的不同推理视角。先验分支促使模型先根据当前上下文组织潜在推理状态，再从该状态生成动作。相比之下，后验分支负责揭示哪些未来信息对动作决策真正有用。它用未来嵌入替换潜在查询，提供感知未来的推理空间版本，并突出未来演化中应该影响下游动作生成的部分。

【图 3 位置】Being-H0.7 使用混合 Transformer，把共享上下文、先验分支中的潜在查询与带噪动作，以及后验分支中的未来嵌入与带噪动作打包进同一序列。先验和后验分支分别计算流匹配损失 $\mathcal{L}_{\text{FM}}$ ；两者的潜在隐藏状态计算对齐损失 $\mathcal{L}_{\text{align}}$ ，并接受正则项 $\mathcal{L}_{\text{reg}}$ 。双分支注意力掩码让两分支相互隔离，同时都能看到共享上下文。

图 3：Being-H0.7 架构。我们把先验和后验分支打包进一个具有共享上下文的 MoT 序列，同时优化两个分支。后验分支用未来嵌入替换潜在查询，两个分支通过隐藏状态对齐和轻量正则化耦合。双分支注意力掩码隔离先验和后验分支，同时保留它们对共享上下文的访问，从而提高训练效率。

联合对齐。 随后，我们在两个分支的潜在推理位置，对隐藏状态执行联合对齐，使两种视角显式地汇合到同一个潜在空间。形式上，令 h_ℓ^{prior} 和 h_ℓ^{post} 分别表示先验和后验分支在第 ℓ 个对齐层中相匹配的潜在隐藏状态。我们采用以下逐点对齐损失：

$$\mathcal{L}_{\text{align}} = \frac{1}{L} \sum_{\ell=1}^L \frac{1}{|h_\ell|} \left\| h_\ell^{\text{prior}} - h_\ell^{\text{post}} \right\|_F^2, \quad (3)$$

其中， L 是对齐层数量， $\|\cdot\|_F$ 表示 Frobenius 范数， $|h_\ell|$ 表示第 ℓ 层中相匹配潜在隐藏状态所含的标量元素数量。

经过这种由未来信息指导的联合对齐后，潜在推理空间不再只是动作解码的中间载体，而是被显式塑造成编码未来相关、面向动作的结构。从这个意义上说，最终模型可以被视为潜在世界—动作模型：未来信息只在

训练期间引入，但它的作用通过推理时仍可完整执行的潜在推理路径得到体现。

3.3 高效双分支实现

如图 3 所示，我们以结构简单且训练高效的方式实现潜在世界—动作模型。我们采用类似 Being-H0.5 [7] 的混合 Transformer (MoT) [107] 结构：动作和状态向量由专门的动作专家处理，其他信号则由规模更大的理解专家处理。

我们没有运行两次完全独立的前向传播，而是把先验和后验分支打包进同一个序列。两个分支共享当前上下文 token，但各自专属的 token 占据不同的潜在推理位置：先验分支在动作之前使用可学习潜在查询，后验分支则使用形状相同的未来嵌入。

为了在一个打包序列中保持预期的双分支结构，我们应用双分支注意力掩码。共享上下文 token 对两个分支都可见，而先验和后验分支的 token 不能互相关注。因此，两个分支只通过应用在相应潜在推理位置上的对齐损失进行耦合，而不是通过直接的跨分支注意力耦合。

此外，我们为先验和后验分支中相应的 token 位置分配相同的位置 ID，保证潜在查询和未来嵌入在所有 Transformer 层中始终保持结构匹配。借助这一设计，模型可以在骨干的一次前向传播中，通过双分支形式高效实现潜在世界—动作建模。

动作生成方面，我们对先验和后验两个分支都应用流匹配目标。令 $\mathbf{a}$ 表示真值动作块， $t \in [0, 1]$ 表示采样的流时间， $\epsilon \sim \mathcal{N}(0, I)$ 表示高斯噪声。沿线性概率路径构造插值动作 $\mathbf{a}_t = t\mathbf{a} + (1 - t)\epsilon$ ，目标速度为 $\mathbf{u}_t = \mathbf{a} - \epsilon$ 。

令 $\mathbf{c} = [\mathbf{x}; \mathbf{o}_{-H:0}; \mathbf{s}]$ 表示共享当前上下文， $\mathbf{q}$ 表示可学习潜在推理查询， $\mathbf{z}^{\text{post}}$ 表示后验分支使用的未来嵌入。两个分支分别预测速度场 $\mathbf{v}_\theta^{\text{prior}}(\mathbf{a}_t, \mathbf{c}, \mathbf{q})$ 和 $\mathbf{v}_\theta^{\text{post}}(\mathbf{a}_t, \mathbf{c}, \mathbf{z}^{\text{post}})$ 。组合流匹配损失为：

$$\mathcal{L}_{\text{FM}} = \mathcal{L}_{\text{FM}}^{\text{prior}} + \mathcal{L}_{\text{FM}}^{\text{post}}, \quad \mathcal{L}_{\text{FM}}^{\text{prior}} = \left\| \mathbf{v}_\theta^{\text{prior}}(\mathbf{a}_t, \mathbf{c}, \mathbf{q}) - \mathbf{u}_t \right\|_2^2, \quad \mathcal{L}_{\text{FM}}^{\text{post}} = \left\| \mathbf{v}_\theta^{\text{post}}(\mathbf{a}_t, \mathbf{c}, \mathbf{z}^{\text{post}}) - \mathbf{u}_t \right\|_2^2 \quad (4)$$

由于仅使用隐藏状态对齐可能产生简单的退化解，我们从两个方面对两分支的潜在推理状态施加轻量防坍缩正则化：保持范数和维持谱多样性。对于潜在隐藏状态 $\mathbf{h}$ ，范数正则项为：

$$R_{\text{norm}}(\mathbf{h}) = [\text{ReLU}(\tau - \|\mathbf{h}\|_2)]^2, \quad (5)$$

其中， τ 是预定义阈值。该项防止对齐状态向趋近于零的幅值坍缩。

对于谱多样性，令 $\mathbf{H} \in \mathbb{R}^{M \times n}$ 表示把某个分支、某个对齐层中的一组潜在隐藏状态投影到一个随机 n 维子空间的结果，其中 M 是所收集潜在状态的数量。我们把 $\mathbf{H}$ 的每一行归一化为单位范数，得到 $\hat{\mathbf{H}}$ ；随后计算 Gram 矩阵 $\mathbf{G} = \hat{\mathbf{H}}\hat{\mathbf{H}}^\top$ ，并令 $\{\lambda_i\}_{i=1}^M$ 表示其特征值。用归一化谱 $p_i = \lambda_i / \sum_j \lambda_j$ ，定义：

$$R_{\text{rank}}(\mathbf{H}) = \sum_{i=1}^M p_i \log p_i. \quad (6)$$

最小化这种负谱熵会鼓励更平坦的谱，防止潜在推理空间发生方向坍缩。把两种正则化应用于所有对齐层中的对齐潜在状态，得到：

$$\mathcal{L}_{\text{reg}} = w_{\text{norm}} R_{\text{norm}} + w_{\text{rank}} R_{\text{rank}}. \quad (7)$$

实践中，我们遵循 UniHand 2.0 [7] 的统一序列格式，在人类和机器人混合操作数据上预训练模型。这为跨具身形态动作学习提供共享接口，使异构操作轨迹可以在同一个潜在世界—动作框架中训练。所提架构虽然也兼容相同数据格式下的文本生成任务，但当前阶段重点关注动作生成。

结合上一节定义的先验—后验对齐损失 $\mathcal{L}_{\text{align}}$ ，最终训练目标为：

4 实验

4.1 训练细节

所有实验中的策略都只使用 RGB 视觉观察。上下文图像统一缩放到 224×224 ，后验分支使用的未来帧则缩放到 256×256 。Being-H0.7 构建在 Being-H0.5 [7] 之上，以 InternVL3.5 [108] 作为理解专家，以 Qwen3 [109] 作为动作专家。为了让上下文观察和未来观察具有一致的视觉嵌入空间，我们为两个视觉编码器都采用 V-JEPA2.1 [110]，同时保持上下文帧编码器可训练。

预训练期间，我们使用 $H = 4$ 的观察跨度、 $T = 20$ 的动作块长度，以及 $K = 16$ 个潜在推理查询。后验分支感知数量相同的未来嵌入，从而与先验潜在查询在对齐位置形成一一对应。我们在最后 $L = 9$ 个 Transformer 层中应用先验—后验潜在对齐。

我们使用流匹配动作目标、先验—后验潜在对齐损失和防坍缩正则化，联合优化先验与后验分支，其中 $w_{\text{align}} = 10^{-3}$ ， $w_{\text{norm}} = w_{\text{rank}} = 10^{-4}$ 。预训练采用 UniHand 2.0 的统一序列格式，在人类和机器人混合操作轨迹上进行。

下游后训练期间，我们只在任务专属示范上优化动作生成目标和潜在对齐损失，不应用防坍缩正则项。我们使用序列打包，使有效全局批大小维持在约 128 个轨迹块。

表 1：多个具身操作任务上的基准比较。 CALVIN 表示“ABCD→D”，CALVIN* 表示“ABC→D”，LIBERO-plus* 表示使用 LIBERO-plus 数据集微调。破折号表示原文未报告结果；RoboTwin 2.0 的两个数字依次对应 Easy/Hard 设置。

类别	模型	规模	LIBERO	LIBERO-plus	LIBERO-plus*	RoboCasa-50	GR1	CALVIN	CALVIN*	RoboTwin 2.0
VLA	π_0 [4]	3B	94.4	53.6	—	42.4	—	—	3.92	65.9/58.6
VLA	π_0 -FAST [111]	3B	85.5	61.6	—	—	—	—	—	—
VLA	X-VLA [112]	0.9B	—	—	—	—	—	4.43	—	72.9/72.9
VLA	UniVLA [87]	8B	95.5	—	—	—	—	4.63	4.41	—
VLA	GR00T-N1.6 [5]	3B	93.9	—	—	36.0	47.6	4.60	4.24	—
VLA	$\pi_{0.5}$ [40]	3B	96.9	77.4	—	41.4	—	4.06	4.13	82.7/76.6
VLA	starVLA [113]	4B	96.5	77.0	—	—	48.8	—	—	88.2/88.2
VLA	MINT-4B [114]	4B	98.7	80.1	84.1	—	—	4.57	—	—
VLA	ABot-M0 [115]	4B	98.6	80.5	—	—	58.3	—	—	86.1/85.1

类别	模型	规模	LIBERO	LIBERO-plus	LIBERO-plus*	RoboCasa-50	GR1	CALVIN	CALVIN*	RoboTwist2
VLA	LingBot-VLA [116]	4B	—	—	—	—	—	—	—	86.5/85.7
VLA	Being-H0.5 [7]	2B	98.9	78.5	83.1	53.5	—	4.63	4.48	—
世界模型	UWM [57]	—	79.0	—	—	48.2	—	—	—	—
世界模型	UVA [56]	—	—	—	—	50.0	—	—	—	—
世界模型	VPP [52]	1.5B	—	—	—	—	—	—	4.33	—
世界模型	DreamVLA [65]	—	92.6	—	—	—	—	—	4.44	—
世界模型	JEPA-VLA [117]	—	96.4	25.6	—	—	—	—	—	73.5/—
世界模型	VLA-JEPA [64]	—	96.1	79.5	—	—	—	—	—	—
世界模型	LingBot-VA [14]	5B	98.5	—	—	—	—	—	—	92.9/91.7
世界模型	Cosmos-Policy [13]	2B	98.5	—	—	67.1	—	—	—	—
世界模型	Fast-WAM [15]	6B	97.6	—	—	—	—	—	—	91.9/91.7
本文	Being-H0.7	3B	99.2	82.1	84.8	62.1	49.2	4.67	4.48	90.2/89.7

4.2 仿真

4.2.1 实验设置

我们在以下六个广泛使用的仿真基准上评估 Being-H0.7:

- **LIBERO [118]**。LIBERO 是一个综合基准，用于评估桌面操作中的知识迁移与终身学习能力。它包含四个不同任务集：Goal、Object、Spatial 和 Long。我们遵循 [118,119]，在全部四个任务集的数据上训练模型。评估时，每个任务集执行 500 次试验，并报告所有任务集的平均成功率。
- **RoboCasa [120]**。RoboCasa 提供一个专注于日常长时程家务任务的大规模仿真框架。我们在不同厨房环境中评估 24 项基础操作任务，并采用具有挑战性的少样本设置，每项任务使用 50 条人类示范。评估在保留场景上进行，每项任务执行 50 次试验，专门测试模型对未见物体实例和新厨房风格的鲁棒性。
- **GR1 [5]**。GR1 是一个双臂操作基准，使用配备傅利叶灵巧手的 GR-1 人形机器人。它包含 24 项复杂桌面操作任务，要求精细的灵巧性与协调能力。我们用每项任务 1000 条示范训练模型，并用每项任务 50 次试验进行评估。
- **LIBERO-plus [121]**。LIBERO-plus 专门用于在多种受控环境扰动下，系统评估策略鲁棒性和零样本泛化。按照标准做法 [121]，我们在两种不同训练配置下评估模型：只在标准 LIBERO 数据集上训练的基线，以及在增强的 LIBERO-plus 数据集上微调的版本。
- **RoboTwin 2.0 [122]**。RoboTwin 2.0 是一个用于评测稳健双臂机器人操作的综合框架。为系统评估和改善仿真到现实迁移，该基准沿五个轴执行结构化域随机化：桌面杂物、不同光照条件、多样背景纹理、桌面高度变化，以及不同语言指令。我们使用来自干净场景的 2500 条示范训练模型，即每项任务 50 条；还使用来自高度随机化场景的 25,000 条示范，即每项任务 500 条。策略在 Easy（干净场景）和 Hard（域随机化场景）两种设置下评估，每项任务执行 100 条轨迹。
- **CALVIN [123]**。CALVIN 专门针对四个不同环境 A、B、C、D 上的多任务学习和长时程操作能力。按照标准评估协议，我们在两个数据划分上评估模型：ABCD→D，在全部环境上训练，在见过的环境 D 上测试；ABC→D，在未见环境 D 上测试零样本泛化。评估严格使用 1000 个不同指令序列，每个序列要求智能体连续执行 5 条指令。我们报告每个序列平均完成的任务数。

【图 4 位置】三种真实机器人具身形态：(a) PND Adam-U；(b) Unitree G1；(c) Franka FR3。

图 4：本次评估所用真实机器人具身形态概览。

4.2.2 结果

在全部六个仿真基准上，Being-H0.7 的整体表现达到当前最佳，并且如表 1 所示，平均排名最高。在 LIBERO 上，Being-H0.7 的平均成功率达到 99.2%，在所有任务集中都表现强劲。

在 RoboCasa 上，模型取得出色的 62.1% 成功率，证明它可以熟练执行多样、未见厨房环境中的日常家务任务。在 GR1 上，它也表现出很强的灵巧人形机器人操作能力，平均成功率为 49.2%。

在 LIBERO-plus 上评估环境扰动鲁棒性时，Being-H0.7 的零样本成功率达到 82.1%；在 LIBERO-plus 上微调后进一步提高到 84.8%，体现出它对视角偏移、新纹理和传感器噪声的韧性。

在 RoboTwin 2.0 上，Being-H0.7 在复杂双臂操作中表现出显著鲁棒性：严重视觉域随机化下仍维持 89.6% 成功率，与干净设置下的 90.2% 相比只下降 0.6 个百分点。

最后，在 CALVIN 上，Being-H0.7 证明了多任务长时程执行和零样本环境泛化能力：在 ABCD→D 和 ABC→D 两个划分上，连续 5 项任务中平均分别完成 4.67 项和 4.48 项。

4.3 真实世界实验

我们在三种真实机器人平台上评估 Being-H0.7：PND Adam-U、Unitree G1 和 Franka FR3。三种平台都配备 Linkerbot O6（6 自由度）手。PND Adam-U 和 Unitree G1 使用双手配置；Franka FR3 则提供单臂桌面设置，配有一个外部相机和一个腕部相机。图 4 展示了三种部署具身形态。

表 2：Being-H0.7 的真实机器人具身形态。 所有受测平台均搭配 Linkerbot O6（6 自由度）手，并共享统一状态／动作接口。

平台	类型	身体自由度	手部	总自由度	相机	策略频率
PND Adam-U	半身人形机器人	19	Linkerbot O6（6 自由度）	31	2 个第一视角相机	20 Hz
Unitree G1	双臂人形机器人	14	Linkerbot O6（6 自由度）	26	1 个第一视角相机	10 Hz
Franka FR3	单臂桌面机器人	7	Linkerbot O6（6 自由度）	13	1 个外部相机+1 个腕部相机	20 Hz

表 3：Being-H0.7 真实机器人任务集。 每项任务都分配一个主要任务集和可选的重叠标签；提示词是评估期间交给策略的指令。

编号	平台	主要任务集	重叠标签	提示词
Task01	Franka FR3	动态场景	运动推理	“在快速滚动的球离开捕捉区域之前，在桌面上接住它。”
Task02	PND Adam-U	物理推理	长时程	“使用移液管，把液体从源容器准确转移到目标容器中。”
Task03	Unitree G1	运动推理	动态场景、物理推理	“用球拍击球，让球落入标记的目标区域。”
Task04	PND Adam-U	物理推理	长时程	“把烧杯中的液体通过漏斗倒入接收容器。”
Task05	Unitree G1	动态场景	运动推理、物理推理	“把杯子里的物体倒入移动的目标容器。”
Task06	Franka FR3	动态场景	运动推理、长时程、泛化	“从移动的传送带上拿取货物，并把它放到正确高度的货架上。”
Task07	PND Adam-U	物理推理	长时程、泛化	“把衣物整齐折叠成目标形状。”
Task08	Unitree G1	长时程	动态场景、运动推理、泛化	“扫描移动传送带上的包裹，并把它分拣到正确目的地。”
Task09	Unitree G1	长时程	物理推理、泛化	“把鞋撑塞进鞋里，再把准备好的鞋放上传送带。”
Task10	PND Adam-U	长时程	动态场景、泛化	“从传送带上拿起鞋，并把它装进鞋盒。”
Task11	Franka FR3	泛化	长时程、物理推理	“拿起桌面物体，把它放进正确层的抽屉。”

编号	平台	主要任务集	重叠标签	提示词
Task12	Franka FR3	物理推理	运动推理、长时程	“拿起锤子，把钉子敲进孔里。”

4.3.1 具身形态与任务集

表 2 汇总了三种部署具身形态。除非另有说明，所有具身形态共享相同的统一控制接口和在线推理基础设施。在 PND Adam-U 上，策略控制 19 个身体自由度和双侧 Linkerbot O6 手。在 Unitree G1 上，策略暴露一个 26 自由度的上半身动作接口，即 14 个手臂关节加 12 个 Linkerbot O6 手部关节。Franka FR3 提供 7 自由度机械臂，并搭配一只 Linkerbot O6 手。

对于 Unitree G1，策略仍然暴露与部署栈其余部分相同的 26 自由度动作接口。额外后端是预训练 AMO 控制器 [124]，它被用作具备平衡感知能力的低层全身模块，负责执行人形机器人动作。在我们的集成中，AMO 接管 50 Hz 的 Unitree 身体控制循环，以最新的上臂目标为条件预测下半身和腰部命令，并组合出最终身体命令加以执行；Linkerbot O6 双手则继续通过与其他具身形态相同的手部接口控制。这样既保持了上半身策略接口的一致性，也在 G1 上提供了稳定的全身执行。

我们为 Being-H0.7 设计了 12 项真实机器人任务，并把它们组织成五个能力导向任务集：动态场景、物理推理、运动推理、长时程执行和泛化。这些任务集被有意设计成组合式：一项任务可能同时考查多种能力，例如既要响应移动目标，也要推理物体轨迹、重力、容纳关系或多阶段子目标。

表 3 列出完整任务集和评估提示词，图 5 对本次评估的任务场景作统一视觉展示。报告结果时，每项任务会分配一个主要任务集和可选的重叠标签；某个任务集的平均值使用带有相应任务集标签的所有任务计算。

五个任务集针对不同的困难来源。**动态场景**任务要求策略在移动物体或变化场景离开可行交互窗口之前作出反应。**物理推理**任务要求预测重力、液体转移、可变形接触、容纳关系或工具介导交互所引起的后果。**运动推理**任务强调预判轨迹、相对速度和接触时机。**长时程**任务考查子目标记忆，以及多个阶段之间的顺序一致性。**泛化**关注在布局、货架高度、容器和物体实例变化时保持任务结构。

【图 5 位置】12 项真实机器人评估任务的场景总览，覆盖 PND Adam-U、Unitree G1 和 Franka FR3，以及动态场景、物理推理、运动推理、长时程和泛化五类能力。

图 5：12 项真实机器人评估任务的视觉概览。图中展示了本文在 PND Adam-U、Unitree G1 和 Franka FR3 上开展真实世界评估时使用的任务场景，覆盖五个能力导向任务集。

4.3.2 评估协议

我们通过统一黑盒推理服务器部署所有受比较策略。该协议保证各方法周围的执行栈完全相同。对于每项任务，我们预先定义一组场景布局和初始条件；评估期间，将被测试的策略端点和执行顺序都随机化。活动策略端点的身份始终对操作者隐藏；操作者依据为该任务定义的固定二元标准记录任务是否成功。除非另有说明，每种方法在每项任务上进行 20 次盲测试验。

这一协议在这里尤其有用，因为多个新任务集除了考查最终抓取精度，还显式考查反应质量。例如，涉及动态场景变化、柔性物体或类似液体的交互任务，可能对策略更新中很小的时间差异十分敏感。共享部署服务器和固定盲测流程使不同方法之间的比较保持一致。

4.3.3 结果概览

图 6 汇总了按照上述重叠标签聚合方式计算的任务集级成功率。由于五个任务集所含带标签任务的数量不同，柱状图结果保留一位小数。

Being-H0.7 在全部五个任务集中领先，覆盖三种具身形态上的反应、物理、顺序执行和泛化任务。这种广泛优势是本节真实机器人实验的主要结果：提升遍布整个基准，而不是集中在某个角落。

【图 6 位置】五个能力导向任务集上的真实机器人成功率柱状图，按 Being-H0.7、Being-H0.5、 $\pi_{0.5}$ 、Fast-WAM 的顺序分别为：动态场景 70.0、47.5、49.2、58.3；物理推理 66.9、59.4、55.0、46.9；运动推理 67.5、46.7、45.8、57.5；长时程 66.7、60.6、56.1、45.0；泛化 67.5、57.5、58.3、49.2。

图 6：任务集级真实机器人成功率（%）。比较 Being-H0.7、Being-H0.5、 $\pi_{0.5}$ 和 Fast-WAM 在五个能力导向任务集上的表现。每项任务进行 20 次盲测试验，每个任务集的得分对带有相应任务集标签的所有任务求平均。

预测优势在动态和运动导向任务中最明显。 最大优势出现在动态场景任务集，运动推理任务集大体也保持相同的模型排序。这些任务集包含基准中对时机最敏感的任务，例如接住快速滚动的球、用球拍改变球的方向、向移动容器中倾倒，以及与传送带交互。

这类任务会迅速惩罚过时的状态估计：物体一旦移出有效接触窗口，很小的位姿误差或延迟修正通常就会立刻导致失败。在所有基线中，Fast-WAM 仍然是这些反应式任务集上最强的一个，这与它强调低延迟动作生成一致。Being-H0.7 又进一步扩大了这一优势，说明反应成功率同时取决于运行时响应速度，以及能够追踪物体运动、相对时机和承诺一次接触所产生后续后果的未来感知潜在状态。

物理和长时程任务集凸显模型的第二项优势。 在物理推理和长时程任务上，最接近的基线是 Being-H0.5，反映出它具有更强的稳定操作先验和逐阶段执行一致性。代表性任务包括移液管转移、通过漏斗倾倒、衣物折叠、插入鞋撑、装鞋入盒，以及锤子与钉子交互。

成功完成这些任务，需要把灵巧性与关于容纳关系、重力、可变形接触、工具介导的力传递，以及早期子目标如何约束后续子目标的推理结合起来。Being-H0.7 在两个任务集上都保持领先，表明学到的世界—动作先验既支持快速反应，也能在更长、物理约束更强的操作链中维持因果一致性。

【图 7 位置】潜在推理可视化的六个执行示例：1. 击球，“用球拍把球打向目标”；2. 接下落的球，“用管子接住运动的球”；3. 传送带倾倒，“把物体倒进传送带上的移动容器”；4. 传送带打包，“从传送带拿起包裹，用条形码扫描器扫描，再放入箱子”；5. 装鞋，“把鞋放进盒子并合上盒子”；6. 分拣杂货，“把杂货分类摆上货架”。每项示例展示当前观察和由潜在隐藏状态合成的未来任务状态。

图 7：潜在推理可视化。

泛化提升在不同具身形态间持续存在。 泛化任务集混合来自三个平台的任务，考查布局、货架高度、容器、物体实例和相机几何变化。在这里， $\pi_{0.5}$ 和 Being-H0.5 仍然相当有竞争力，使该任务集保持均衡且具有现实意义。即便如此，Being-H0.7 整体上仍然最可靠，说明其潜在预测先验的收益可以延续到具身形态和场景结构的变化中。由于该基准被有意设计成组合式，在全部五个任务集柱状图中稳定领先，比只在一项精心挑选的任务上获胜更有说服力。

潜在推理可视化。 为了更直接地揭示潜在推理空间编码的内容，可以把当前观察和 Being-H0.7 先验分支的潜在隐藏状态共同作为视频生成模型的条件，合成未来任务状态。

Being-H0.7 在推理期间虽然不会显式重建未来帧，但图 7 中的可视化结果表明，其潜在表示已经捕捉了关于世界将如何演化的预测信息。这进一步证明 Being-H0.7 的确发挥着潜在世界—动作模型的作用：它没有在像素层面对未来建模，而是学习足以支持动作生成的内部预测表示。

推理基础设施增强真实世界可部署性。 图 8 报告了同一部署基础设施下的系统级推理成本。在客户端，我们进一步使用 Being-H0.5 [7] 中具备延迟感知能力的通用异步分块（UAC）机制，并将其实现为异步实时分块。

具体来说，客户端维护一个线程安全的动作缓冲区，同时持续估计下一个动作块就绪前会消耗多少个控制步。控制线程以机器人频率从已提交前缀中取出动作；并行推理线程则在缓冲区剩余量低于触发阈值时唤醒，获取最新观察，并向服务器请求下一个动作块。

关键规则是，UAC 绝不会改写已经提交的前缀；它只会在估算的推理延迟之后，把未来后缀拼回缓冲区。这种“锁定前缀／更新后缀”的设计吸收了模型、传输和调度抖动，而不改变策略接口本身；它也使同一个部署协议能够用于控制频率和具身形态专属动作维度各不相同的平台。

UAC 是把分块预测转化为连续控制的部署协议。它保持时间连续性、减少肉眼可见的控制卡顿，并让不同具身形态使用统一评估栈。最明显的效果是，启用 UAC 的 Being-H 变体进入每步 3–4 毫秒的范围，同时 GPU 内存占用与相应的不使用 UAC 版本相同。

【图 8 位置】真实世界部署栈中的推理成本。（a）平均推理延迟，单位为毫秒／步：Being-H0.5-UAC 3.45、Being-H0.7-UAC 3.61、 $\pi_{0.5}$ -RTC 12.45、Being-H0.5 17.12、Being-H0.7 28.81、Fast-WAM 41.26。
（b）GPU 内存占用，单位 GB：Being-H0.5-UAC 5.6、Being-H0.5 5.6、Being-H0.7-UAC 6.8、Being-H0.7 6.8、 $\pi_{0.5}$ -RTC 9.3、Fast-WAM 15.6。

图 8：真实世界部署栈中测得的推理成本。除了主要成功率比较外，我们还将其作为可部署性的系统级视图进行报告。

这为控制器执行动态任务提供了更多时间余量，使缓冲区占用在网络和调度器抖动下更加稳定，也让机器人接口上的在线执行显著更加平滑。结合上面的任务集级结果，成本图说明策略收益是在高效推理循环中实现的，而不是以笨重的部署设置为代价。

5 结论

我们提出 Being-H0.7，这是一种通过紧凑潜在推理空间，连接直接动作预测与世界建模的潜在世界—动作模型。通过把可部署的先验分支与感知未来的后验分支对齐，该方法把未来相关推理注入动作生成，而无需在推理时进行成本高昂的像素级展开。结合大规模人类视频预训练，Being-H0.7 为具身模型提供了一套有效且可扩展的框架。