

Being-H0：从大规模人类视频中预训练视觉—语言—动作模型

原文：Being-H0: Vision-Language-Action Pretraining from Large-Scale Human Videos

作者：Hao Luo、Yicheng Feng、Wanpeng Zhang、Sipeng Zheng 等

项目主页：<https://beingbeyond.github.io/Being-H0>

日期：2025 年 7 月 21 日

说明：译文按中文阅读习惯重组段落，保留技术定义、公式、主要实验数字和附录性质的实现信息；图片以文字标注位置与内容。

摘要

本文提出 **Being-H0**，一个在大规模人类视频上训练的灵巧视觉—语言—动作模型（VLA）。现有 VLA 依赖存在 sim-to-real 差距的合成数据，或者规模小、缺乏多样性的遥操作演示，因此难以处理需要高灵巧度的复杂操作，也不容易泛化到新任务和新场景。

作者把手视为一种“基础操纵器”：它足够灵巧，又能在网络视频中以极大规模出现。为此，论文提出 **物理指令微调（Physical Instruction Tuning）**，将三件事连成一体：从人类视频进行大规模 VLA 预训练、为三维推理做物理空间对齐、再通过后训练适配真实机器人。

模型还使用按手部结构分组的动作分词方法，以毫米级重建精度把连续手部轨迹变成离散 token。配套数据流水线把动作捕捉、VR 和普通 RGB 视频统一为数百万条动作指令样本，最终形成超过 1.5 亿训练样本的 UniHand。实验表明，Being-H0 能生成符合指令的手部动作，模型和数据规模扩大时性能稳定上升；经过物理指令微调后，它也能显著改善真实机器人操作。

【图 1：Being-H0 通过 UniHand 中的大规模人类视频学习人手动作，经物理空间对齐和机器人后训练，将人手运动先验迁移到灵巧机器人操作。】

1. 引言

大语言模型和大多模态模型依靠互联网规模数据获得了广泛推理能力，机器人领域却还没有类似的跃迁。RT-2、OpenVLA、 $\pi 0$ 等工作尝试把大模型改造成 VLA，但机器人遥操作数据比互联网文本和图像小几个数量级；尤其是灵巧手，设备昂贵、操作复杂，公开数据更少。多数 VLA 因而仍使用简单夹爪，无法完成精细手指协调和力度控制。仿真能廉价扩充数据，却仍受场景多样性和 sim-to-real 差距限制。

人类活动视频真实、丰富、容易扩展，看起来是理想替代来源。已有工作常用对比学习、掩码自编码或潜动作，从视频中隐式学习表示，但没有取得类似语言模型规模化预训练的巨大收益。作者认为，关键障碍在于数据结构：语言模型的预训练文本与下游文本任务同构，视觉—语言模型也能自然复用图文理解；而 VLA 的输入是文本和二维视觉，下游输出却是带本体状态的三维物理动作，二者并不同构。

论文提出的问题是：

能否像 GPT-3 从海量文本中学习语言一样，从大规模人类视频中预训练灵巧 VLA，让它显式模仿人类动作，再通过后续训练适配机器人手？

这需要解决四项困难：

1. **数据异构**：不同视频的相机、坐标系和拍摄条件各不相同。
2. **手部量化**：细微手指运动必须离散化成语言模型可处理的 token，又不能损失毫米级精度。
3. **跨模态推理**：视觉、指令与精细手指运动之间的关系比普通图文任务更复杂。
4. **机器人迁移**：人手与机器人在形态、自由度和物理约束上不同，动作不能直接照搬。

Being-H0 的回答是“物理指令微调”：先显式学习人手动作，再对齐不同数据的物理空间，最后把模型迁移到具体机器人。模型以统一自回归架构处理视觉、文本和动作；分部位动作 tokenizer 使用分组残差量化（GRQ）；UniHand 则汇集动作捕捉、VR 和 RGB-only 数据，覆盖 150 多种任务、1000 多小时视频和超过 1.5 亿条指令跟随样本。

2. 相关工作

2.1 大多模态模型

Flamingo、LLaVA 和 InternVL 等模型把视觉编码器接入语言模型，通过图文预训练和视觉指令微调获得少样本理解与指令跟随能力。常见数据构建方式是先用视觉模型描述图像，再让语言模型生成问答，或直接用强闭源多模态模型标注。Being-H0 借用了这条路线，但把“回答文本”扩展成“回答物理动作”。

2.2 人体与手部动作生成

人体动作研究已经形成 KIT-ML、AMASS、HumanML3D、MotionX 等数据集，并使用 SMPL/SMPL-X 统一人体参数。生成方法主要是扩散模型和自回归模型；后者通常用 VQ-VAE、残差量化或层级量化把动作转成 token。

手部动作更加关注手—物交互和细节精度。动作捕捉或多相机数据精确但局限于实验室桌面场景；第一视角视频环境丰富，却缺少可靠三维手标注。MANO、HaMeR、Dyn-HaMR 等方法使单目手部重建成为可能，但弱透视假设、遮挡和相机运动仍会带来偏差。

2.3 从人类视频学习 VLA

已有方法从人类视频提取视觉特征、三维感知先验、接触点、抓握和可供性；也有方法通过修补、渲染或遮罩对齐人机视觉，或把人体与机器人映射到统一状态—动作空间。多数方法只处理简单夹爪，没有对精细手指运动进行大规模显式建模。Being-H0 把手设成统一基础操纵器，先学习其完整运动分布，再向较简单或不同形态的执行器迁移。

3. Being-H0 总览

物理指令微调包含三个阶段。

3.1 人类视频预训练

训练样本写成：

$$D = \{(v_i, t_i, m_i)\},$$

其中 v 是视觉输入， t 是语言指令， $m = \{\theta, r_{rot}, \tau, \beta\}$ 是 MANO 表示的动作，分别包含关节角、腕部旋转、平移和手形参数。每个样本被整理成指令与回答 (X_Q, X_A) ，用统一自回归目标训练：

$$\Theta^* = \arg \min_{\Theta} - \sum_{i=1}^N \sum_{j=1}^L \log P_{\Theta}(y_j \mid X_Q, \hat{y}_{1:j-1}).$$

回答既可以是文字，也可以是动作 token，因此同一个模型能够完成视觉到动作、动作描述、带上下文动作续写等任务。

3.2 物理空间对齐

视频来自不同相机和动态世界坐标；模型骨干最初只在二维图文上训练，没有可靠三维先验；摩擦、力等物理量又无法从普通视频直接得到。作者把动作统一到规范化 MANO 和一致坐标系，并用弱透视投影与视角分布平衡，使模型不把某个数据源的相机方向误当成动作本身。

3.3 机器人后训练

预训练模型保留视觉、语言和人手运动先验。向下游机器人迁移时，加入固定数量的可学习动作查询，通过 MLP 投影到机器人的动作块。本文刻意使用较简单的适配器，以检验人类视频预训练本身是否有价值。

【图 2：预训练阶段以自回归方式生成文本或手部动作 token；后训练阶段加入动作查询和本体状态投影器，直接预测机器人动作块。视觉编码器、文本 tokenizer 和主体模型共享。】

4. 物理指令微调

4.1 模型架构

Being-H0 基于 InternVL3，视觉编码器为 InternViT-300M，后接两层 MLP 投影器。图像采用动态高分辨率切块，在尽量不扭曲宽高比的情况下保留手指与物体细节。模型词表加入动作码本中的 K 个离散代码，并用 $\langle \text{MOT} \rangle$ 、 $\langle / \text{MOT} \rangle$ 标记动作块边界。

4.2 手部动作分词

长度为 T 的连续动作 $M \in \mathbb{R}^{T \times D}$ 先经一维卷积编码器压缩到 $\lceil T/\alpha \rceil$ 个特征，再量化并解码：

$$M \xrightarrow{\text{Encoder}} z \xrightarrow{VQ} \{m_1, \dots, m_n\} \xrightarrow{\text{Decoder}} \hat{M}.$$

作者比较了多种 MANO 特征：轴角或 6D 旋转、是否加入三维关节点、是否显式预测手形。最终选择 **MANO-D162**：腕部和平移、手指 6D 旋转并加入辅助关节点；每段序列的手形固定为首帧值，让 tokenizer 专注于运动。

关键设计是 **部位级量化**。腕部全局运动与手指局部运动在统计尺度和语义上不同，如果用一个码本统一量化，大幅腕部位移会掩盖微小手指变化。作者分别编码腕部和手指，再使用 GRQ 逐层量化残差。训练损失包含重建、码本承诺和腕部加权项：

$$\mathcal{L} = \mathcal{L}_{recon} + \lambda_1 \mathcal{L}_{commit} + \lambda_2 \mathcal{L}_{wrist}.$$

默认总码本规模为 8192。部位级 tokenizer 在测试集上达到毫米级重建误差，例如 MANO-D162 的 MPJPE 为 0.573 cm、对齐后 PA-MPJPE 为 0.129 cm。

4.3 多模态统一与训练

视觉、文字和动作都拼接成同一 token 序列。视觉 token 替换图像占位符，动作 token 放在动作块标记之间；共享自注意力直接学习场景、指令、腕部轨迹和手指姿态的依赖关系。

由于不同任务长度不同，作者对样本损失做过滤和均衡，避免超长动作或大量容易文本样本主导训练。模型支持三种解码模式：

- **自由格式**：完全由模型决定是否以及何时生成动作块，用来检验它是否真正学会格式。
- **块格式**：强制输出动作块和固定数量 token，便于公平比较空间误差。
- **软格式**：长序列生成时提供部分格式或范围约束，降低误差累计和轨迹漂移。

4.4 弱透视投影对齐

不同来源的绝对焦距和尺度并不可靠。作者把三维动作按弱透视模型投影到图像坐标，通过尺度和平移标准化，使手部轨迹与视觉观测一致，同时保留相对深度和姿态。这样能把动作捕捉、VR 与普通单目视频统一起来。

4.5 视角无关的动作分布平衡

各数据集常偏向特定拍摄方向。作者对动作做视角增强，并按腕部方向和姿态覆盖度重新平衡数据，使同一技能在不同观察角度下都有样本。去掉这一步后，尾部分布的误差显著增大，说明模型原本容易记住占主导的相机视角。

4.6 机器人适配

机器人阶段在共享主干后添加本体状态投影器和动作查询。动作查询像一个固定长度的“待填写动作块”，从视觉、语言和当前关节状态中读取信息，再经 MLP 输出连续机器人动作。由于预训练已经学习了人手如何接近、抓取和操作物体，少量机器人数据主要负责解决形态和控制接口差异。

【图 3：左侧为部位级动作 tokenizer；中间为相机与 MANO 规范化的物理空间对齐；右侧为共享多模态模型及机器人动作查询。】

5. UniHand 数据集

5.1 数据来源与规模

UniHand 综合三类数据：

- 高精度动作捕捉数据，提供可靠三维姿态；
- VR 数据，提供自然的双手轨迹和操作过程；
- 普通 RGB 视频，提供大规模、多场景、多物体的真实活动。

数据共超过 1000 小时，覆盖 150 多类任务。整理成多种视觉、语言和动作指令后，样本总数超过 **1.5 亿**。数据既有常见“头部”技能，也保留少见物体、视角与长时程动作组成的“尾部”分布。

5.2 数据整理流水线

首先把各种手部估计结果转换为统一 MANO 参数，修复左右手标记、异常关节、丢帧和不连续轨迹。随后把长视频切为最长约 10 秒、语义较完整的阶段，并以 2 FPS 采样视觉帧。语言模型根据视频内容、轨迹和已有标签生成任务描述、动作说明和问答。

由此形成多种训练任务：

- 给定图像和指令生成未来手部动作；
- 给定起始手姿和视觉上下文续写动作；
- 把动作翻译成文字；
- 从文字生成动作；
- 理解左右手、时间顺序和长时程步骤。

【图 4：UniHand 的数据来源、清洗与标注流程，以及视觉到动作、动作到文本、长时程生成等训练样例。】

6. 实验

6.1 评测任务与指标

作者训练 1B、8B 和 14B 三种规模。手部动作评测区分常见动作的 head split 和稀有动作/新数据源的 tail split。

- **MPJPE**: 预测与真实关节在绝对三维空间中的平均距离。
- **MWTE**: 腕部平移轨迹平均误差。
- **PA-MPJPE**: 经刚性 Procrustes 对齐后的关节误差，侧重相对手形。
- **M2T R@3**: 用动作检索文本时，正确描述进入前三名的比例。
- **FID**: 生成动作与真实动作在动作表征空间中的分布距离。
- **Valid Rate**: 自由生成时是否形成可正确解析的 `<MOT>...</MOT>` 动作块。

6.2 动作生成与动作翻译

模型越大，越能稳定遵守动作格式。自由格式下，1B、8B、14B 的有效率分别为 **64.8%、99.8%、100%**。动作翻译的文本—动作 R@3 也随规模上升。

在视觉条件动作生成中，14B 模型在 head/tail 上的 MPJPE 为 **6.87/8.11 cm**，相比 GR00T N1.5 的 **9.82/15.35 cm** 明显更好；MWTE 为 **5.19/7.41 cm**，PA-MPJPE 为 **1.03/1.20 cm**。在带起始状态的上下文动作生成中，14B 的 MPJPE 为 **6.21/7.33 cm**，同样优于 GR00T N1.5 的 **7.14/8.55 cm**。

模型扩展带来的提升在 tail split 上更突出，说明容量增加主要改善了少见动作、物体和视角的泛化，而不只是拟合常见动作。

6.3 长时程生成

论文分别评估 2~5 秒和 6~10 秒动作。时间越长，MPJPE 和腕部轨迹误差自然上升，但大模型漂移更小。视觉条件任务的 6~10 秒 tail MPJPE 从 1B 的 **11.24 cm** 降到 8B 的 **9.98 cm**、14B 的 **9.72 cm**；上下文任务相应为 **10.98、9.67、9.45 cm**。

6.4 tokenizer 消融

把腕部和手指分开量化优于统一四组量化或 16 层残差量化。轴角表示在绝对重建上有时稍好，6D 旋转则在对齐后的手指姿态和最终自回归生成上更稳。加入辅助关节点有

效，直接建模手形 β 反而会分散容量。

最终的 MANO-D162 + 部位级配置虽然不是每项静态重建指标的绝对最优，却在真正的动作生成任务上最好，说明 tokenizer 不能只按重建误差选择，还要看其是否利于时间建模和自回归预测。

6.5 数据配方消融

去掉动作—文本翻译任务，语义指标明显下降；去掉上下文动作生成，空间误差和尾部泛化变差；去掉视角分布平衡的影响最大，tail MPJPE 从 9.02 cm 恶化到 **12.13 cm**，M2T R@3 从 18.7% 降到 **10.3%**。随着 UniHand 数据量从 50 万、100 万、150 万增加到 250 万核心动作片段，性能持续提升，说明尚未达到数据饱和。

6.6 真实机器人实验

硬件包括 7 自由度 Franka Research 3、6 自由度 Inspire 灵巧手和 RealSense L515 RGB 相机。每项任务改变物体初始位置，进行 20 次试验，以严格二元成功率评估。任务覆盖：

- 盖紧盖子等高精度几何对齐；
- 按语言选择指定颜色或类别的玩具；
- 展开衣物等可变形物体操作；
- 把液体从一个杯子倒入另一个杯子等平滑长轨迹控制。

比较对象为 GR00T N1.5 和未经人手动预训练的 InternVL3。三者用完全相同的机器人后训练数据，因此差异主要反映人类视频预训练与物理对齐的作用。Being-H0 在动作精度、语言理解和复杂任务鲁棒性上整体领先，尤其在需要细手指协调、连续轨迹和新物体理解的任务上优势明显。

【图 9~11：真实机器人完成关盖、按颜色抓取玩具、展开衣物和倒杯等任务的连续帧；对比模型常见失败包括抓取位置偏移、指令对象选错和长轨迹中途漂移。】

7. 结论与未来工作

Being-H0 把视觉指令微调扩展到物理世界：以人手为基础操纵器，在大规模视频上显式学习动作 token，再做三维空间对齐和机器人后训练。部位级 GRQ 能以毫米级精度表示连续手部运动，UniHand 则提供了足够规模和多样性，使动作生成、语言对齐和尾部泛化都随模型与数据规模改善。

当前版本仍有明显边界：它没有显式建模物体六自由度姿态、接触力、摩擦和可执行性；普通视频的三维伪标签仍有噪声；机器人适配也只是简单 **MLP** 投影。后续工作可以加入物体与接触建模、物理反馈或强化学习，并设计更强的跨形态动作映射。但实验已经说明，人类视频不只适合学习视觉特征，也可以成为灵巧机器人动作模型的直接预训练数据。