

Do as I Do: 来自日常人类视频的灵巧操作数据

原文: *Do as I Do: Dexterous Manipulation Data from Everyday Human Videos*。

作者: Bhawna Paliwal*, Haritheja Etukuru*, William Liang*, Pieter Abbeel、Nur Muhammad “Mahi” Shafiullah、Jitendra Malik (加州大学伯克利分校)。星号表示同等贡献。

项目主页: <https://do-as-i-do.com>

版本: arXiv:2606.19333v1, 2026 年 6 月 17 日。

阅读说明: 本文按照原文逐段、逐句翻译到第 5 节结论及其“局限性”结束, 合并 PDF 的跨页断句和排版换行, 以中文阅读顺畅为准; 公式、数值、表格、图注和引用编号均保留。文中的“我们”指论文作者。图像本身不嵌入译稿, 在对应位置标明原文图号并翻译图中关键信息。致谢、参考文献及附录按要求不翻译。

摘要

怎样才能以可扩展的方式为机器人操作生成数据, 尤其是为多指灵巧手等类人平台生成数据? 近期, 从人类视频中学习逐渐成为这个问题的一种可能答案。然而, 估计手—物体交互, 以及跨越人类到机器人的具身形态差距仍然十分困难, 这阻碍了将大量仅含单目 RGB 的人类视频用作机器人操作数据的主要来源。

本文提出 **DO AS I DO**, 一种把单目 RGB 人类视频重建并重定向到多指灵巧机器人手的算法。**DO AS I DO** 从各种第一视角和第三视角野外视频来源中重建手—物体交互。随后, 该算法把这些手—物体交互估计重定向为可以在真实世界中执行的动作序列, 从彼此差异很大的人类视频中生成机器人所需信息完备的操作数据。

总体而言, 我们在具有真值的数据集和一个在线收集的视频片段数据集上开展实验, 结果表明, 在估计手—物体交互和从 RGB 视频提取灵巧操作轨迹方面, **DO AS I DO** 超越了此前最佳方法。这些实验还使我们可以为采集机器人操作所需人类数据的实践者提出一套有效性操作手册。

【图 1 位置】上方为野外单目 RGB 手—物体交互视频, 包括挤酱、倾倒、搅拌、擦拭、使用工具等日常行为; 下方为经过重建和重定向后, 由多指机器人手执行的相应灵巧操作数据。

图 1: 我们提出 DO AS I DO, 一种以野外单目 RGB 手—物体交互视频为输入, 并生成灵巧手操作数据的算法。

1 引言

数据是包括机器人学习在内的任何学习算法的关键组成部分。然而, 对于儿童、学徒或机器人等初学智能体来说, 任何任务的可用数据大多是观察性的: 不是通过亲自执行获得经验, 而是通过观看专家操作来学习。儿童可以轻易跨越观看与行动之间的差距 [1,2], 但对今天的机器人来说, 这仍是一道无法逾越的障碍; 机器人主要依赖通过真实世界遥操作或仿真探索采集的经验数据。

以图 1 所示的灵巧行为为例, 生成经验数据面临诸多挑战。遥操作受限于操作者的专业水平、操作成本和遥操作设备的机械透明度。仿真探索同样受限于设计多样环境和奖励函数的复杂性。本文自然要问的问题是: 怎样把容易获取的人类观察数据转换成机器人经验数据, 从而弥合这道差距?

通过观察人类来推断机器人动作, 也称为“照我做”(Do as I do), 其研究历史几乎与人工智能领域本身一样悠久。代表性工作包括 1970 年 MIT 的“复制示范”(copy-demo) [3]、通过人类直接示范进行“机器人教学”[4], 以及结合动作合成和重定向的“照我做”[5]。

其中有两项主要算法挑战: 识别或重建人类行为, 以及把该行为重定向到一种可能与人类差异极大的机器人具身形态上。通过对行为作出假设, 例如只处理抓取放置, 或对物体作出假设, 例如只处理经过三维扫描的物体, 研究者已经能够在这个问题上取得进展 [6,7]。随着时间推移, 对数据模态作出更多假设, 例如使用专用硬件采集的数据中具有深度、三维信息或手部关键点, 又推动了“照我做”研究的发展 [8,9]。

然而, 今天绝大多数观察数据都以人类单目 RGB 视频的形式保存。因此, 能够处理这一一般情形的算法, 有望最大幅度增加机器人数据。

相邻领域近期的两项进展, 为这一问题提供了新解法。第一, 今天的三维计算机视觉模型可以接收二维 RGB 图像, 并仅根据单目 RGB 视频重建深度 [10]、物体 [11] 和三维手部 [12], 从而实现四维手—物体估计。与此同时, MuJoCo Warp [13] 和 Isaac [14] 等 GPU 并行物理仿真器支持快速的采样式优化算法 [15]; 借助这些算法, 我们可以在几分钟内根据四维手—物体状态推断机器人灵巧手动作。

需要注意, 这两种方法对问题结构, 例如被观察的行为或目标物体, 都只作出极少假设。受到这些进展启发, 本文提出 DO AS I DO, 旨在弥合灵巧操作的观察数据与经验数据之间的差距。

DO AS I DO 从日常单目 RGB 视频中识别并重定向人类灵巧动作, 生成让多指机器人手和机械臂对环境执行同一任务的动作。更关键的是, 我们无需对视频中展示的行为作出限制性

假设，例如不需要抓取先验；也不限制物体类别，可以支持任意刚体。

具体来说，本文贡献如下：

- 1. 我们提出 DO AS I DO，一种分两步把单目 RGB 视频中的行为重建并重定向到多指灵巧手的算法。
- 2. 我们的手—物体重建流程在相关指标上超越当前最佳方法，并且可以处理多种视频：既包括第一视角和第三视角视频，也包括野外互联网片段和生成式视频模型的输出。
- 3. 我们的重定向流程引入新组件，提高带噪声重建参考轨迹的鲁棒性，从而改进现有可扩展的动力学感知重定向技术。
- 4. 我们生成的机器人数据可以在灵巧机器人手和机械臂上回放。据我们所知，这完成了首个从互联网视频一路转换到真实灵巧手执行轨迹的完整流水线。

2 相关工作

从人类视频学习灵巧操作。 许多既有工作探索如何利用人类视频中的语义和运动。有些方法通过预训练提取先验，包括视觉表示 [26–28]、灵巧策略 [29–33] 或前向动力学模型 [34,35]。其他方法则计算结构化程度更高的先验，例如可供性 [36,37]、流 [38,39]，以及用于重定向的三维重建 [6,40–42,16,7,22,18]。本文属于最后一类，并如表 1 所示，把利用多样野外数据源的前沿进一步向前推进。

表 1：相关工作。 我们按照大致的困难程度，汇总此前工作使用的方法和数据来源。“自行采集”表示由论文作者采集的数据，“生成”表示生成式数据，“第一视角”表示第一视角数据。空白表示未使用相应数据来源。

方法	重建	重定向	自行采集	生成	第一视角	互联网
H2Sim2Robot [16]	LiDAR 扫描+ FoundationPose [17]	强化学习	✓			
VideoManip [18]	MeshyAI [19]+ FoundationPose	DRO [20]+DP3 [21]	✓		✓	
DexMan [22]	TRELLIS [23]+ FoundationPose+ SpaTrack [24]	强化学习	✓	✓		
DexImit [7]	SAM 3D [11]+ FoundationPose++ [25]	运动规划	✓	✓		

方法	重建	重定向	自行采集	生成	第一视角	互联网
本文	SAM 3D+引导扩散	采样式优化	✓	✓	✓	✓

手—物体重建。从单目 RGB 视频重建四维手—物体交互，可以沿三个互补方面拆解：手部姿态估计、物体形状与姿态估计，以及二者的联合建模。人手具有结构化的形状与运动 [43]，这使手部跟踪模型 [12,44,45] 能够抵抗运动模糊、遮挡和低分辨率。

由于日常物体非常多样，在同样带噪声的野外条件下重建并跟踪物体仍然困难得多。近期进展来自两方面。第一，以图像为条件的三维生成基础模型 [46,23,11] 对形状和姿态具有稳健先验，可以处理遮挡和较低分辨率。第二，基于模型的六自由度跟踪器 [17,47] 可以在已知或同步重建网格的情况下估计物体姿态。然而，这些方法主要在干净的实验室视频上验证；如下文所示，它们在带噪声的野外视频上表现不佳。

最后，联合手—物体重建方法会同时推理手部和物体信号，并已经在实验室数据 [48] 与野外视频 [49–51] 上取得进展。近期视频方法的适用范围仍然狭窄：一些方法只能处理第一视角视频 [52]，按类别提供条件的方法 [53,54] 则假设物体来自封闭分类体系。

与这些联合方法不同，DO AS I DO 采用模块化拆解：使用 HaWoR 跟踪手部，使用 SAM 3D 从单张图像生成物体网格，再使用本文基于 SAM 3D 的跟踪方法（第 3.1 节）估计物体姿态随时间的演化。

人类到机器人的重定向。灵巧重定向算法把手姿态映射到几何结构差异极大的机器人具身形态，例如手指连杆长度和关节结构不同。运动学重定向方法通过求解几何、任务空间或关节空间优化来完成映射 [55–58]，但只考虑机器人构型，不考虑手与物体之间的力，因而常常造成穿透、指尖滑动和抓取不稳定。

为解决这些问题，具备动力学感知能力的重定向框架会优化物理仿真中的手—物体轨迹；一般做法是通过强化学习跟踪基于参考的奖励 [59,60,16,61]，或者使用采样式优化 [62,63,15]。然而，此前大多数重定向方法都共享一个关键假设：可以获得带手—物体姿态真值的干净参考，例如动作捕捉数据。相比之下，我们处理的是难度更高的带噪声重建参考，其中可能存在时间不连续和严重的手—物体错位。

3 方法

DO AS I DO 由图 2 所示的两部分组成。首先，我们重建三维手部和物体，并在时间维度上跟踪它们（第 3.1 节）。随后，把重建结果重定向到机器人具身形态上，生成在动力学上可行、且能在真实世界中有效执行的轨迹（第 3.2 节）。

【图 2 位置】方法总览。输入视频依次经过视觉基础模型，重建并跟踪三维手部与物体；随后，在物理仿真中通过采样式优化，把人类手—物体轨迹重定向为机器人手和机械臂轨迹。

图 2：方法总览。本文方法利用视觉基础模型重建手部与物体，再通过仿真中的采样式优化把它们重定向到机器人上。

3.1 重建

从野外视频中识别并重建手—物体交互，可以拆解成两个部分：第一，跟踪人手；第二，确定物体形状并跟踪其姿态。关键在于，这些能力必须能够抵抗带噪声互联网视频中多样的视觉条件。

我们发现，HaWoR [45] 等现有模型满足这一要求，可以直接用于手部跟踪，并取得合理表现。然而，对于受到手部遮挡的开放类别刚性物体，一旦视觉证据退化，此前工作 [17,47] 往往会失去姿态锁定、发生漂移，或者无法重新捕捉物体，如图 5 所示。因此，我们基于使用遮挡数据训练的三维生成基础模型 SAM 3D [11]，开发了自己的跟踪方法。

跟踪完成后，三维手部、物体和相机会被组合到一致的近似度量空间中。我们执行三个处理步骤：(a) 使用 SAM 3 [64] 分割手部和物体；(b) 使用 MoGe [10] 估计深度与相机内参；(c) 使用 SAM 3D [11] 生成物体三维网格。

通过引导扩散跟踪物体。 我们把 SAM 3D [11] 这一能够抵抗遮挡和低分辨率的图像到三维生成模型，改造为视频物体跟踪器。给定单张二维图像和物体掩码，它学习形状和姿态的联合分布 $p_\theta(x^s, x^p \mid c)$ 。因此，如果把它独立应用到每一帧，就会逐帧生成不同网格，并得到没有时间连贯性的姿态序列。

我们的关键观察是，在学到的联合分布中，形状和姿态共享同一个潜在空间；因此，我们可以固定形状，并且完全在推理时为每一帧获得更新后的姿态。具体来说，我们在锚点帧固定形状 $\bar{x}^s$ ，然后根据前一帧的姿态 x_{k-1}^p ，预测第 k 帧的姿态 x_k^p 。这样，跟踪就归结为从 $p_\theta(x_k^p \mid x_k^s = \bar{x}^s, c_k)$ 中抽样，并使抽样偏向 x_{k-1}^p 。

SAM 3D 具有庞大的生成骨干，在六自由度连续姿态空间中对所有可能姿态边缘化并不可行。我们转而利用流匹配推理本身：从 $x_0 \sim \mathcal{N}(0, I)$ 开始，沿线性路径 $x_t = (1 - t)x_0 + tx_1$ 对常微分方程 $\dot{x} = v_\theta(x_t, t, c)$ 积分，从而生成样本。在流模型中，经过前向加噪的目标，就是该目标沿模型自身概率路径的插值 [65,66]。

在每一个欧拉步中，我们分别取形状块和姿态块的自由欧拉更新，再将其朝目标插值混合：形状块被推向规范形状 $\bar{x}^s$ ，姿态块被推向前一帧姿态 x_{k-1}^p ：

$$x_t^s = (1 - \alpha_s)(x_{t-\Delta}^s + \Delta v_\theta^s) + \alpha_s z_{\text{ref}}^s(t), \quad x_t^p = (1 - \alpha_p)(x_{t-\Delta}^p + \Delta v_\theta^p) + \alpha_p x_{k-1}^p(t).$$

其中, $\alpha_s, \alpha_p \in [0, 1]$ 是引导强度参数; $z_{\text{ref}}^s(t) = (1 - t)\epsilon^s + t\bar{x}^s$ 和 $z_{\text{ref}}^p(t) = (1 - t)\epsilon^p + tx_{k-1}^p$ 是目标插值; ϵ^s, ϵ^p 是两个块的初始噪声; v_θ^s, v_θ^p 是速度 $v_\theta(x_{t-\Delta}, t - \Delta, c)$ 的形状与姿态分量。式中每个分量的第一项对应去噪, 第二项对应混合。

自适应引导参数。 由于本文关注刚性物体, 任何位于 $[0.9, 1]$ 的固定形状引导强度 α_s 都有良好效果。固定姿态引导强度 α_p 可能造成过度僵化或错误翻转, 因此我们不使用固定值, 而是根据二维点轨迹 [67] 估计的物体旋转速度, 从数据中导出 α_p 。这会为每段视频增加一次离线跟踪过程, 但如附录所示, 可以显著改善姿态跟踪。

【图 3 位置】流水线生成的 20 种不同动作及其物体示例: 放置、拾取、刷洗、涂抹、挤压、熨烫、绘画、除尘、挖掘、擦除、倾倒、书写、搅打、搅拌、戳刺、压实、钻孔、锤击、切割和淋汁。

图 3: 动词与物体。我们可视化了流水线生成的 20 种不同动作: 放置、拾取、刷洗、涂抹、挤压、熨烫、绘画、除尘、挖掘、擦除、倾倒、书写、搅打、搅拌、戳刺、压实、钻孔、锤击、切割和淋汁。

逐帧姿态采样。 如上所述, 式 (1) 中的引导姿态采样是随机的。因此, 在每一帧 k , 算法抽取共享固定形状 $\bar{x}^s$ 的 N 个候选 $\{x_{k,i}^p\}_{i=1}^N$, 然后需要逐帧选择其中一个样本。

原则上, 应该根据模型自身在给定形状条件下的姿态条件对数密度对候选排序。然而, 这个过程所需计算量比生成本身高几个数量级, 在视频规模下难以承受。因此, 我们在加权 SE(3) 距离下对姿态采样并聚类。实验上, 置信度较高的样本会集中于同一个姿态模态, 估计器噪声则散布在 SE(3) 空间中; 所以, 共识过滤和掩码 IoU 无需再次调用扩散骨干, 就能恢复该模态中的最佳姿态。

手—物体对齐。 独立重建手部和物体后, 两者可能具有不同尺度, 因此需要对齐。我们把手部重建尺度视为真值, 并缩放物体平移量 s , 使其与手部对齐。

我们计算物体尺度下的手部与物体质心 $c_{\text{hand}}^M, c_{\text{obj}}^M$, 以及手部网格尺度下, 即近似度量尺度下, 可见手部网格的质心 c_{hand}^H 。根据质心 z 坐标得到缩放比例 $k = z_{\text{hand}}^H / z_{\text{hand}}^M$ 后, 我们优化目标物体位置 $\text{obj}_{\text{target}} = c_{\text{hand}}^H + k(c_{\text{obj}}^M - c_{\text{hand}}^M)$, 其中逐帧平移尺度通过最小二乘法求解。最后, 我们使用 GeoCalib [68] 将轨迹与重力方向对齐。

3.2 重定向

接下来, 我们要在机器人手上复现重建的手—物体轨迹。然而, 这种参考并不完整: 人与机器人的形态不同, 而且运动学信号中没有接触信息和力。此前工作使用运动学求解器 [22] 或机器人启发式方法 [18, 7] 解决这个问题, 但这些方法无法保证物理合理性, 或者会丧失通用表达能力。

DO AS I DO 改为执行具备动力学感知能力的重定向：它在跟踪参考的同时，确保物理仿真中的真实性。基于 Pan 等人 [15] 的框架，我们执行类似 MPPI 的采样式优化；其核函数会沿迭代次数和预测跨度两个维度退火，使优化从广泛探索逐步转向局部细化。为支持带噪声重建参考的重定向，我们进一步引入图 4 所示的几项新设计。

【图 4 位置】上方展示本文方法成功处理的常见失败模式，例如初始时未稳定抓住物体、物体在指尖上不稳定平衡、关键拾取过渡失败；下方展示它对带噪声参考的处理能力，例如深度估计错误造成手物对齐不良时，仍能得到稳定的物理轨迹。

图 4：重定向。本文方法可以解决常见失败模式，并且特别擅长处理带噪声参考；例如，即使错误的深度估计造成较差对齐，方法仍能成功。

预热步骤。 初始轨迹跨度 H 中存在两个问题。第一，带噪声的第一帧可能把手和物体初始化到无法恢复的状态，例如物体没有被抓住。第二，退火采样无法充分探索这 H 个步骤，因为它们只出现在滚动预测跨度的开始位置。

因此，我们在参考轨迹前增加 H 个额外预热步骤。在预热期间，物体被固定在原处，例如悬停在空中，而机器人手可以自由移动；预热结束后，焊接约束被移除，仿真正常进行。这样，机器人可以在开始跟踪参考之前调整姿态，例如避免图 4 中物体掉落，并自然引导优化器最大化跟踪目标。关键在于，这种预热设计不假设任何抓取采样或启发式方法，只使用已有的核心优化过程。

随机力扰动。 第二，滚动预测跨度可能让优化陷入局部最优，产生只能短暂跟踪却无法恢复的不稳定物体交互，例如图 4 中让物体在指尖上保持平衡。为解决这一问题，我们要求交互能够抵抗轻微扰动。受到仿真到现实研究 [69,70] 启发，我们对采样轨迹施加随机力，鼓励控制对这类扰动保持鲁棒。重要的是，这种解法具有通用性，不像接触引导 [15] 等替代方案那样假设存在高保真参考。

过渡奖励。 第三，物体在“静止”和“手中”状态之间的转换，是轨迹中的关键拐点；但面对带噪声参考，仅靠跟踪奖励不够精确，而且过于平滑，无法鼓励这类过渡引发的阶跃式交互，例如图 4 中未能成功拾取。

因此，我们为失败过渡加入固定惩罚项：第一，当参考时间步要求物体静止时，如果物体没有与地面接触，就施加惩罚；第二，当参考时间步要求物体位于手中时，如果手与物体没有接触，就施加惩罚。我们通过测量参考中的手—物体距离是否低于阈值 ϵ ，定义参考时间步所处的阶段。

4 实验

4.1 实验设置

我们在各步骤对应的标准任务基准上，分别评估框架的每一步。首先，对于手—物体重建，我们沿用此前工作 [51,53,54] 的设置：在 DexYCB [71] 和 HOI4D [72] 数据集上评估，二者分别包含 160 段和 12 段标注视频。为单独考查物体层面的表现，我们提供手部真值，并测量物体重建与跟踪质量。

我们与两组基线比较。第一组是联合手—物体重建方法，同时包括基于图像的方法 [48–50] 和基于视频的方法 [51,54]。第二组是物体跟踪器 [17,47]；在我们的流水线中，用这些基线替换本文物体跟踪方法，其余组件保持不变。

为了进一步评估方法在更接近日常视频的分布上的表现，我们收集了一个由 150 段视频构成的基准，视频来源包括野外互联网视频、第一视角数据集和生成视频。由于这些视频没有物体姿态真值，我们通过人类偏好进行评估：每段视频邀请 3 名志愿者，把本文基于 SAM 3D 的跟踪方法所得物体姿态，与当前最佳方法所得结果进行比较。各基线及人类评估设置的细节见附录。

最后，在重定向方面，我们使用由 655 条重建参考组成的野外重建数据集，以及大型动作捕捉数据集 OakInk2 [73] 进行评估；OakInk2 包含 1352 条干净的双手人类—物体任务轨迹。

我们与灵巧重定向当前最佳方法 SPIDER [15] 比较，它也是此前唯一面向这种规模设计的方法。SPIDER 作为“退火采样”基线，我们逐步加入本文三个组件，以评估各自贡献。沿用近期文献 [15,59,60]，平均位置误差 $E_{\text{pos}} < 0.1$ 米且平均旋转误差 $E_{\text{rot}} < 0.5$ 弧度的轨迹被判为成功。技术细节见附录。

所有任务均使用 22 自由度 Sharpa Wave 手。本文展示的真实世界部署结果来自双臂设置，其中使用 Sharpa Wave 双手和 UR3e 双臂，二者都以 50 Hz 接收控制命令。

【图 5 位置】左侧是在 150 段视频上进行的物体跟踪正面对比人类评估：相较 FoundationPose [17]，67% 的视频偏好本文方法，另有约 32% 偏好 FoundationPose，少量结果持平；每段视频显示三位评审的投票一致性。右侧给出定性样例：FoundationPose 在运动模糊和遮挡下丢失物体、发生漂移或姿态翻转，本文方法维持连贯的平移与旋转。

图 5：物体跟踪比较。我们在 150 段视频上通过正面对比人类评估，比较本文方法和 FoundationPose [17] 的物体跟踪结果（左），并展示定性样例（右）。

表 2：重建结果。在两个手—物体跟踪数据集上报告 F-5、F-10 和 Chamfer 距离（CD）。F-5 和 F-10 越高越好，CD 越低越好；破折号表示原文未报告。

方法	DexYCB	DexYCB	DexYCB	HOI4D	HOI4D	HOI4D
	F-5 ↑	F-10 ↑	CD ↓	F-5 ↑	F-10 ↑	CD ↓
HO [48]	0.24	0.48	4.76	0.28	0.51	3.86
IHOI [49]	—	—	—	0.42	0.70	2.70

方法	DexYCB	DexYCB	DexYCB	HOI4D	HOI4D	HOI4D
	F-5 ↑	F-10 ↑	CD ↓	F-5 ↑	F-10 ↑	CD ↓
HORSE [50]	0.23	0.42	6.97	0.26	0.45	6.69
MCC-HO [51]	0.36	0.60	3.74	0.52	0.78	1.36
G-HOP [54]	0.31	0.49	8.11	0.69	0.91	0.63
FoundationPose [17]	0.69	0.89	0.89	0.71	0.91	0.49
Any6D [47]	0.69	0.88	0.97	0.71	0.91	0.50
本文	0.71	0.93	0.66	0.72	0.91	0.49

4.2 重建结果

如图 5 左侧所示，在包含 150 段野外视频的基准上，人类评审在 67% 的视频中更偏好本文物体跟踪结果，而不是当前最佳的 FoundationPose；大多数视频都获得一致偏好。定性结果（图 5）显示，FoundationPose 在轻微运动模糊和遮挡下会丢失物体，而本文方法可以在整段视频中恢复时间连贯的平移和旋转。

这一优势也延续到表 2 所示的标准手—物体重建基准：我们在 DexYCB 和 HOI4D 上都创造了新的最佳结果，超过所有基线。

此外，我们还在附录中消融物体跟踪的设计选择。结果表明，借助点跟踪进行自适应姿态引导，可以持续改善重建质量；基于聚类的选择与基于姿态似然的选择表现相当，但速度最高可快 30 倍。

4.3 重定向结果

重定向结果见表 3。在我们的野外重建数据上，DO AS I DO 的成功率达到 71%，显著高于 25% 的基线。最主要的差异来自预热：它找到的初始状态比带噪声第一帧稳定、自然得多，从而能够在后续时间步成功跟踪。

我们还发现，扰动虽然只会小幅影响定量指标，却可以明显改善定性结果，例如产生更自然的抓取。过渡奖励则可以在关键过渡时间步鼓励成功的拾取和放置；如果没有这一奖励，轨迹可能会错过物体。

表 3：重定向结果。 在两个人类—物体参考数据集上报告成功率、平均位置误差和平均朝向误差。成功率越高越好，位置和旋转误差越低越好。

方法	重建数据成功率 ↑	位置误差 ↓	旋转误差 ↓	OakInk2 成功率 ↑	位置误差 ↓	旋转误差 ↓
退火采样	0.25	0.08	0.40	0.72	0.08	0.32
+ 预热	0.66	0.06	0.28	0.77	0.06	0.25
+ 扰动	0.67	0.06	0.30	0.79	0.03	0.14
+ 过渡奖励	0.71	0.05	0.28	0.81	0.03	0.15

在 OakInk2 上进一步验证本文方法时，加入每个组件同样会持续改善结果，使成功率从 72% 的基线提高到 81%。这说明，本文重定向方法虽然是针对不完美重建参考设计的，但即使用于干净的动作捕捉轨迹，也能带来有效提升，并且可以很好地扩展到该基准中超过 1000 项双手任务。

4.4 真实世界部署

我们的流水线总共生成了 500 条经过人工验证的高质量灵巧操作轨迹，其中互联网视频占 53%，第一视角视频占 31%，生成视频占 16%。为了展示轨迹质量，我们在真实世界中执行一组有代表性的轨迹。

我们选择了 10 种动作，覆盖不同物体几何形状和抓取类别 [74]，包括书写三指抓取、力量抓取、掌面抓取和平行伸展抓取。经过重力对齐后，重建结果仍然遵循视频的相机坐标。因此，在计算机机械臂逆运动学并部署到真实世界之前，我们先在仿真中手动把初始位姿 (x, y, z, yaw) 与机器人工作空间对齐。

结果见图 6；更多连续帧见附录，视频见项目网页。

【图 6 位置】双臂 Sharpa Wave 手与 UR3e 机械臂在真实世界执行 10 类轨迹：搅打、倾倒、除尘、挤压、压实、擦除、搅拌、锤击、涂抹和拾取。

图 6：真实世界部署。我们展示 10 项任务的执行轨迹：搅打、倾倒、除尘、挤压、压实、擦除、搅拌、锤击、涂抹和拾取。

4.5 人类数据过滤操作手册

鉴于近期研究对使用人类数据扩展机器人学习的兴趣 [30,33,75]，本节旨在强调在线人类数据源中常见的质量问题。我们在分析常用数据集时注意到这些模式，并在 100DOH [76] 上开展了分析。不过，这些经验应该具有更广泛的适用性。

我们首先从 100DOH 中采样 2000 个长度为 10 秒的视频片段；该数据集已经筛选过手—物体交互。结果发现，只有 187 个片段，即 9%，真正包含有意义的手—物体交互。

在这 187 个候选片段中，41 个片段的手或物体位于视频边界之外；29 个片段没有活动，或者活动跨越镜头切换边界。另有 14 个片段因相机运动而失败，10 个片段因 SAM 3D 而失败；未来更好的模型或许可以修复这两类问题。还有 10 个片段因为其他原因被排除。

最终，从 100DOH 采样的 2000 段视频中，只有 83 段，即 4%，通过质量检查，可以进入重建流程。即使在最佳情况下，我们预计也只有 107 个片段，即约 5% 的数据，能直接用于学习灵巧操作。这意味着，如果没有为机器人学习正确地预处理和过滤互联网视频，就会付出约 20 倍的数据代价。

5 结论

本文提出 DO AS I DO，一个把日常人类视频重建并重定向到灵巧机器人手的框架。我们的方法对第一视角、第三视角和在线视频来源都有效，展示了一条仅通过观察人类来扩展机器人数据的路径。我们希望 DO AS I DO 能推动人类视频在机器人学习的数据版图中成为一等公民。

局限性。 本文方法假设物体为刚体，并假设单目 RGB 可以给出相对准确的度量深度预测；任一假设不成立时，方法都可能失败。单目观察还存在真实手—物体距离的歧义，因此难以区分物理接触和纯粹的视觉遮挡。

此外，本文方法只重建手部和一个物体，而不是完整场景。因此，它无法推理障碍物或关节结构等环境约束。即使参考轨迹完全准确，这类场景级推理仍然很重要，因为人类意图不仅通过手—物体交互表达，也通过手—场景交互表达。

最后，当前物理仿真器只能近似模拟真实世界动力学，这为本文框架所能达到的真实世界表现设置了上限。