

Dream2Flow：用 3D 物体流连接视频生成与开放世界操作

原文：Dream2Flow: Bridging Video Generation and Open-World Manipulation with 3D Object Flow (Stanford, 2025)。

摘要

给定当前场景图像和任务指令，现成的视频生成模型可以零样本生成“任务完成时物体如何运动”的视频。Dream2Flow 不直接执行生成视频中的人类动作，而是从视频提取目标物体的 3D flow，把它作为机器人规划的中间表示。这样可以在开放世界中处理“打开烤箱、把面包放进碗、拉出椅子”等未见任务。

【图 1：指令 → 生成视频 → 3D 物体流 → 机器人交互。】

方法

首先用图像和文字提示视频生成模型，合成与真实机器人相同场景中的未来视频。随后用点跟踪/分割得到物体表面点在各帧的位移，并结合深度和相机几何重建 3D 运动。物体流表示为 $F(p, t) = p_t - p_0$ ，其中 p 是物体坐标中的点。

再将流拟合为物体刚体变换或局部形变，求解末端执行器轨迹和抓取时机。规划器以流作为目标，通过轨迹优化或模型预测控制在线执行；真实观测持续校正物体位姿。

结果与限制

方法在多种开放世界任务上优于仅依赖语言或单张图像的规划器，尤其适合训练数据中没有明确动作标签的任务。生成视频提供了有用的“结果想象”，但视频幻觉、物体形变和点跟踪丢失会直接影响规划。因此 Dream2Flow 是推理时的目标生成框架，不是像 DreamGen 那样离线制造训练集。

具体算法

生成视频可能改变相机或产生不可见区域，因此系统先估计相机运动，再在每个候选物体上建立点轨迹。静态背景点用于剔除相机运动，剩余点的平均运动用于估计物体刚体变换。对非刚体物体，方法只保留与任务相关的局部 flow，并把它转成抓取点和目标区域。

机器人规划采用两阶段优化：先让末端位姿到达从 flow 推出的关键帧，再优化速度、碰撞和夹爪约束。执行过程中根据真实相机重新估计物体姿态，并对计划做短时重规划。实验中的失败主要来自生成视频没有遵守物理（例如物体凭空出现）以及遮挡导致的 3D 深度不确定性。

3. 从像素视频到 3D flow

给定初始图像 I_0 、指令 g 和生成视频 $I_{1:H}$ ，系统先对视频帧进行点级跟踪。跟踪点被分成背景点和目标物体点；背景点用于估计相机运动，目标点用于估计物体流。结合 RGB-D 相机的深度和内参 K ，可将像素位移反投影到相机坐标，再拟合每一帧的刚体变换 T_t 。

若物体是刚体，目标是让 $K T_t P_0$ 与视频中跟踪到的二维点尽可能一致；若是布料、食物等非刚体，系统不强行拟合全局刚体，而只提取和任务相关的局部运动。这个表示比直接预测末端动作更具跨形态性，因为 T_t 描述的是物体应该怎样变化，而不是某一台机器人的关节怎样变化。

4. 任务覆盖与局限

论文展示了推、拉、打开、放置、扫动和回收等任务。生成模型能提供零样本的动作结果想象，因此不需要为每个新物体收集示范。另一方面，视频生成模型可能改变物体身份、产生不合理接触或忽略遮挡；系统需要多条候选视频、几何一致性筛选和真实观测闭环修正来降低风险。

5. 论文中的实际组件

输入是机器人现场的 RGB-D 初始图和文本任务。为避免通用视频生成模型画出形态错误的机械臂，作者先从条件图像中移除机器人，再让现成图生视频模型生成“任务如何发生”。Grounding DINO 定位目标物体，SAM2 给出时序 mask，CoTracker3 在物体表面跟踪二维点。SpatialTrackerV2 提供生成视频中的逐帧深度，并用真实首帧 RGB-D 对预测深度做尺度和偏移对齐。

对于抓取任务，AnyGrasp 生成真实场景中的抓取候选，生成视频中的 HaMeR 拇指位置帮助选择人类可能抓住的区域。选定抓取后，PyRoki 优化末端轨迹，使抓取后的物体点尽量跟随 3D flow，同时满足关节、平滑和碰撞约束。

对于推块、开门等不适合固定抓取的任务，3D flow 可以作为控制奖励。例如门操作实验使用 SAC 学习策略，奖励根据物体关键点是否沿目标 flow 移动计算。由此可见，Dream2Flow 的输出不是一种固定机器人动作格式，而是下游轨迹优化或强化学习共同使用的目标表示。

6. 3D flow 的价值

对刚性杯子，足够多点的 flow 可约化为一个 6D 刚体变换；对门、抽屉这类关节物体，不同点受几何约束沿弧线或直线运动；对布和颗粒物，单一刚体变换根本不足。点级 3D flow 因而比末端轨迹更通用，但也更依赖可靠的生成视频、分割、点跟踪和深度。

7. 实验结果

真实机器人在 Bread in Bowl、Open Oven 和 Cover Bowl 三项任务上分别成功 8/10、8/10 和 3/10；AVDC 分别为 7/10、0/10、2/10，RIGVID 为 6/10、6/10、1/10。刚体接口在可见点太少或运动非刚性时会产生噪声变换，而 3D flow 可以直接保留点级目标。

在仿真开门任务中，作者将 3D object flow 用作强化学习奖励，并与直接访问物体真值状态的奖励比较。Franka、Spot、GR1 三种形态上的成功次数分别为 100/100、100/100、94/100，而真值物体状态奖励为 99/100、99/100、96/100，说明 flow 奖励接近状态 oracle，同时允许不同机器人选择不同动作策略。

60 次真实执行中，主要失败为 12 次视频生成失败、4 次 flow 提取失败和 4 次机器人执行失败。生成失败包括物体变形或凭空生成新物体；flow 失败来自剧烈旋转和物体出画；执行失败主要出现在盖碗任务的抓取点或移动距离不正确。

8. 方法（原文第 III 节）

给定任务指令、初始 RGB-D 观测和已知相机投影，Dream2Flow 的目标是输出动作序列，使机器人跟随生成视频推断出的物体运动。动作空间不受限制，可以是运动基元、末端位姿或底层控制量。图像到视频模型生成帧，视频深度估计器提供逐帧深度；利用目标物体掩码，将像素结合深度提升到机器人坐标系，得到三维物体流 $P_{1:T} \in \mathbb{R}^{T \times n \times 3}$ 。

动作推断把状态写成物体点与机器人状态的组合，并最小化物体点与时间对齐目标流之间的距离，同时加入控制代价，满足动力学约束：

$$\min \sum_t \lambda_{task}(\hat{x}_t^{obj}, \tilde{P}_t) + \lambda_{control}(\hat{x}_t, u_t), \quad \hat{x}_{t+1} = f(\hat{x}_t, u_t).$$

视频提取流程先用 Grounding DINO 定位目标，再用 SAM 2 得到掩码，从首帧掩码采样点并用 CoTracker3 跨帧跟踪；结合校准深度和相机内外参，将可见点提升为三维轨迹。

【图 2：Dream2Flow 总览。视频模型生成未来帧，视觉基础模型提供掩码、深度和点跟踪，系统重建三维物体流，最后由轨迹优化或强化学习生成跟踪该流的动作。】

在仿真 Push-T 任务中，动作是推技能的起点、方向和距离。粒子动力学模型输入全场景中带有位置、颜色、法向量及推技能参数的粒子，预测下一时刻各点的位置增量；随机采样多组推技能并选择预测代价最低者。在真实机器人上，动作是绝对末端位姿，系统先用 AnyGrasp 产生候选抓取，再选择最接近视频中 HaMeR 拇指位置的抓取。PyRoki 优化末端轨迹，加入平滑、可达性和物体流跟随代价。开门任务使用 SAC，把物体流作为奖励训练不同形态的感知运动策略。

9. 实验

评测任务包括 Push-T、把面包放进碗、打开烤箱、盖住碗和开门。【图 3：各任务的初始与完成状态。】真实机器人上，Dream2Flow 在三项任务中分别成功 8/10、8/10、3/10，优于 AVDC 的 7/10、0/10、2/10 和 RIGVID 的 6/10、6/10、1/10。点级物体流在点数少、遮挡多或物体可变形时比刚体变换更稳定。

【表 1：真实机器人中间表示比较。】在 100 个随机门位置上，物体状态奖励与物体流奖励训练出的 Franka、Spot、GR1 策略成功率分别为 99/100、99/100、96/100 和 100/100、100/100、94/100，说明物体流奖励接近状态 oracle，同时允许不同机器人采取不同策略。【图 6：不同形态的开门策略。】

视频模型实验中，Push-T 的 Wan2.1 和 Kling 2.1 成功率为 52/100 和 31/100；打开烤箱时 Wan2.1、Kling 2.1、Veo 3 为 2/10、4/10、8/10。动力学模型消融中，粒子、姿态和启发式模型分别为 52/100、12/100、17/100，表明逐点预测对于处理旋转十分关键。

【表 4：动力学模型消融。】

10. 结论

Dream2Flow 将文本条件视频预测转化为可执行机器人动作，以三维物体流作为中接口，把环境中“需要发生什么”与具体机器人“如何实现”分离。仅凭 **RGB-D** 观测和语言、无需任务专属示范，它就能在仿真和真实机器人上处理刚体、关节体、可变形物体和颗粒物的开放世界操作。实验显示，相比稠密光流和刚体位姿轨迹，物体流更具泛化性；视频模型和动力学模型的选择都很重要，其中粒子动力学最可靠。主要瓶颈是视频变形与幻觉、遮挡导致的跟踪丢失，以及抓取点选择不匹配。总体而言，三维物体流为从开放式视频生成到非结构化环境机器人控制提供了可扩展的桥梁。