

DreamGen：通过视频世界模型释放机器人学习的泛化能力

原文： *DreamGen: Unlocking Generalization in Robot Learning through Video World Models*, Joel Jang 等, arXiv:2505.12705v2, 2025 年 6 月。译至第 6 节“结论”。文中的“我们”指论文作者。Neural trajectory 译作“神经轨迹”，即生成的视频加上预测的伪动作标签。

【原文图 1：DreamGen 的泛化能力。只在一个环境中采集一种行为（抓取放置）的遥控操作数据，借助视频世界模型生成合成数据，让二维视觉运动策略在新环境中执行新行为；图中还展示了接触丰富任务的数据增强。】

摘要

我们提出 DreamGen。这是一套简单而高效的四阶段流程：通过“神经轨迹”，即视频世界模型生成的合成机器人数据，训练能够跨行为、跨环境泛化的机器人策略。

DreamGen 利用先进的图像到视频生成模型，并使其适应目标机器人形态，从而在不同环境中生成机器人执行已知或新任务的逼真合成视频。这些模型只生成视频，所以我们使用潜动作模型或逆动力学模型（IDM），恢复伪动作序列。

尽管方法简单，DreamGen 却带来了很强的行为与环境泛化能力：一台人形机器人只需在一个环境中针对一项抓取放置任务采集遥控操作数据，就能在已见和未见环境中执行 22 种新行为。为系统评估整个流程，我们提出视频生成基准 DreamGen Bench，并发现其基准表现与下游策略成功率高度相关。我们的工作为机器人学习提供了一条超越人工采集数据、继续扩大规模的新路径。

作者注：前四位作者贡献相同；Scott Reed、Yuke Zhu、Linxi Fan 共同指导。

【原文图 2：DreamGen 四阶段总览。先用遥控操作轨迹微调视频世界模型；输入初始帧和语言指令生成行为视频；用潜动作模型或 IDM 为视频预测伪动作，形成“神经轨迹”；最后用这些轨迹训练视觉运动机器人策略。】

1. 引言

利用大规模人类遥操作数据训练的机器人基础模型，已展现出完成灵巧真实任务、构建通用机器人系统的巨大潜力 [1–6]。但这种范式高度依赖于为每个新任务和新环境手工采集遥操作数据，成本高、耗费人力。在仿真中生成合成数据是一个有吸引力的替代方案，但通常需要大量人工工程工作；将视觉运动策略部署到实体机器人时，还会受到仿真到现实差距的影响。针对这些问题，我们提出 **DreamGen**：利用视频世界模型，以尽可能少的人工劳动和工程工作，大规模制作逼真训练数据的合成数据流程。

DreamGen 采用简单的四步方法（图 2），将先进的视频生成模型 [7–12]，也就是视频世界模型，用于制作合成训练数据。这个流程面向不同机器人、环境和任务，具有通用性。（1）在目标机器人数据上微调视频世界模型，使其掌握该机器人形态的动力学和运动学。（2）用初始帧与语言指令组成提示，生成大量机器人视频，既包括微调阶段见过的行为，也包括未见场景中的新行为。（3）用潜动作模型 [13] 或逆动力学模型（IDM）[14] 提取伪动作。（4）用所得的视频—动作序列，即“神经轨迹”，训练下游视觉运动策略。已有工作侧重将视频世界模型用作实时规划器 [15–19]；**DreamGen** 则把它当作合成数据生成器，利用模型在物理推理、自然运动和语言语义对应方面积累的先验知识。

我们首先研究 **DreamGen** 能否为已有遥操作数据的任务补充训练数据，实验包括仿真与现实场景。在仿真中，我们把 **DreamGen** 用于 **RoboCasa** 基准 [20]，把合成数据扩展到原始人工示范的 333 倍。随着神经轨迹数量增长，策略性能呈对数线性提升（图 4）。在现实世界中，我们使用 **Fourier GR1**、**Franka Emika** 和 **SO-100** 三种机器人，验证九项不同任务，展示这一流程对不同机器人形态及复杂灵巧任务的适用性；这些任务包括叠毛巾、擦拭液体、使用锤子和舀取 **M&M** 巧克力豆，均难以在仿真中精确实现。

DreamGen 在所有机器人上都提高了成功率：**GR1** 人形机器人的四项任务平均从 37% 提升至 46.4%，**Franka** 的三项任务从 23% 提升至 37%，**SO-100** 的两项任务从 21% 提升至 45.5%；每项任务只使用 10–13 条真实轨迹。

接着，我们展示 **DreamGen** 带来的两种关键泛化能力：行为泛化与环境泛化。在行为泛化方面，我们让 **GR1** 人形机器人完成 22 种新行为，如倾倒、打开与关闭有关节的物体，以及操作多种工具。原始遥操作数据集只包含抓取放置，没有其他动作动词。在环境泛化方面，我们用十个新环境的初始帧提示仅在一个环境的数据上微调过的视频世界模型。这样，只在一个环境中为一项任务采集遥操作数据，就能训练出在新行为、新场景中泛化的视觉运动策略。这是从零到一的性能提升：仅用抓取放置数据训练的 **GR00T N1**，在多数新行为和新环境实验中的成功率为 0%；**DreamGen** 则使策略在已见环境中的新行为上达到 43.2%，在完全未见环境中达到 28.5%。这些实证结果指向一种不必依赖大量人工示范、仍可扩展机器人学习规模的新范式。

最后，我们提出 **DreamGen Bench**（第 4 节），用来评估不同视频世界模型适应新机器人形态的能力。我们考察八种模型（四种零样本模型、四种微调模型），看它们能否在遵守物理规律的同时，生成机器人操作未见物体、执行未见行为、置身未见环境的视频。实验证明，基准得分较高的模型，也能带来更强的下游机器人策略。**DreamGen Bench**

无须实体机器人参与，就能以较低成本诊断视频世界模型在机器人领域的适用性。我们希望，这能为视频模型研究者参与机器人学习提供一条容易进入的路径。

2. DreamGen

下面详细介绍 DreamGen 的四个阶段（见图 2）：如何制作和使用神经轨迹，训练视觉运动机器人策略。

2.1 微调视频世界模型

第一阶段，我们用人类遥操作得到的机器人轨迹微调视频世界模型。经过这种适配，模型便能学习该机器人的物理约束和运动能力。为减少模型遗忘在互联网视频中学到的知识，我们默认使用低秩适配（LoRA）[21] 微调不同的视频世界模型。微调时，我们考察“指令遵循”和“物理遵循”两个指标，以判断模型是否充分适应目标机器人领域；具体说明见第 4 节。多数下游机器人实验都以 WAN2.1 [9] 为基础视频世界模型。如果训练数据有多个视角（RoboCasa [20] 和 DROID [22]），我们把这些视角拼成 2×2 网格（其中一个格子为黑色像素），再微调视频世界模型。不同视频世界模型与微调数据组合所需的最佳微调量也不一样。

原文脚注 1：多视角示例见附录 C。脚注 2：所有实验设置的超参数（学习率、训练轮数等）见附录 D。

2.2 视频世界模型生成视频

在目标机器人形态上微调视频世界模型后，我们用不同的初始帧和语言指令生成合成机器人视频。对于仿真实验，我们从仿真器采集新的初始帧，并针对每项任务随机改变目标物体的位置或环境。对于现实实验，我们手动拍摄新初始帧，同时随机改变目标物体的位置。对于环境泛化实验，我们还拍摄新环境的初始帧，但训练视频世界模型的数据仍只来自一个环境（图片见附录 B）。最后，在行为泛化实验中，我们手工设计新行为的提示语，并把所有候选行为纳入第 4 节的视频基准。

原文脚注 3：虽然采集新初始帧仍需一些人工工作，但比采集新的遥操作数据省力得多。未来我们希望采用图像到图像扩散技术：从一张初始帧出发，通过图像修补改变物体位置、物体类型和环境，自动生成新的初始帧。

2.3 标注伪动作

图 3 展示了用来从生成视频中提取伪动作标签的两种模型结构：(a) 逆动力学模型 IDM；(b) 潜动作模型 LAPA。

【原文图 3：伪动作提取。左图为 IDM，以两帧图像和动作编码器为条件，通过扩散 Transformer 与动作解码器预测动作片段；右图为 LAPA，用 ViT 编码器、VQ 码本和 ViT 解码器学习两帧之间的潜动作。】

IDM 动作。 对于逆动力学模型，我们使用带 SigLIP-2 视觉编码器的扩散 Transformer，以流匹配目标训练。IDM 以两帧图像为条件，预测两帧之间的一段动作（图 3）。输入中不显式加入语言或本体感知信息，因为我们希望 IDM 只学习机器人的动力学。除非另有说明，各项实验中训练 IDM 的数据与训练视频世界模型的数据相同。训练完毕后，我们用滑动窗口标注伪动作：IDM 先预测 H 个动作，即 $\hat{a}_t$ 到 $\hat{a}_{t+H}$ ；再将窗口前移一步，预测下一组 H 个动作，即 $\hat{a}_{t+1}$ 到 $\hat{a}_{t+1+H}$ ，以此类推。更多细节见附录 A。

潜动作。 我们使用 LAPA 潜动作模型 [13]。它采用 Transformer 编码器—解码器结构，并在多种机器人和人类视频上训练。模型使用 VQ-VAE 目标，使潜动作捕捉视频中两帧之间的视觉变化。要从生成视频中提取潜动作，我们把轨迹中的当前帧和未来帧（相隔一秒）输入模型。遵循 GR00T N1 [5]，我们使用量化前的连续嵌入作为潜动作。潜动作模型所用训练数据的确切混合比例见原文表 3。潜动作的一项好处是：训练潜动作模型时，无须掌握目标机器人形态对应的真实动作标签。

2.4 用神经轨迹训练策略

最后，我们在 DreamGen 生成的神经轨迹上训练视觉运动机器人策略，以语言指令和图像观测为条件。由于神经轨迹不包含状态信息，我们把状态输入设为零。更具体地说，给定图像观测 o_t 和任务指令 i_t ，我们训练策略输出 $\hat{a}_{t:t+H}$ ；它可以是上一节所说的潜动作，也可以是 IDM 标注的动作。神经轨迹并不依赖特定的策略架构，因此我们在三种视觉运动策略模型上展示 DreamGen 的效果：Diffusion Policy [24]、 π_0 [2] 和 GR00T N1 [5]。

我们提出两种使用神经轨迹的训练场景：与真实轨迹联合训练，或只用 IDM 动作标注的神经轨迹训练。联合训练时，神经轨迹与真实轨迹按 1:1 的采样比例混合。对 GR00T N1，我们使用不同的动作编码器和解码器，把两种轨迹视作不同机器人形态的数据。行为与环境泛化实验中的策略则只用神经轨迹训练。

原文脚注 4：初步实验显示，零状态输入不会损害性能。让 IDM 预测状态信息留待未来研究。

【原文图 4：RoboCasa 中神经轨迹数量扩展实验。横轴改变神经轨迹数量；分别在少量、中等、大量真实轨迹条件下，用潜动作或 IDM 动作作伪标签，报告 24 项任务的平

均成功率。横轴为 0 时，是只用真实视频训练的基线。图中示例任务包括抓取放置、旋钮、门、拉杆和按钮操作。】

3. 实验

这一节展示 DreamGen 的三项主要用途：（1）为已有任务增加训练数据；（2）泛化到新行为；（3）泛化到新环境。

3.1 扩充训练数据

仿真实验使用 RoboCasa 基准 [20]，遵循原工作相同的训练和评估方案。现实实验则在三种机器人上进行九项任务评估：GR1 人形机器人、Franka 机械臂，以及低成本 SO-100 机械臂。

仿真实验。 图 4 展示了在 RoboCasa 的三种真实数据规模下，增加神经轨迹总量对下游策略的影响：低数据量（720 条）、中数据量（2,400 条）、高数据量（7,200 条）。这些设置也决定了 IDM 的能力，因为拥有越多某种机器人的真实数据，IDM 就越能学到有用的动力学知识。在这组实验中，视频世界模型使用 1,200 条原始人工示范训练，而 IDM 和策略按基准的不同数据规模设置训练。

首先，无论使用 IDM 动作还是 LAPA 潜动作，也无论真实数据规模如何，联合训练神经轨迹都能提升性能。两种方式带来的效果接近；在后续实验中，我们默认使用 IDM，因为 IDM 动作可以让我们只用神经轨迹训练并评估策略，而且所有实验设置都有相应机器人的遥操作数据，足以训练效果较好的 IDM。其次，神经轨迹总量与下游策略性能之间呈现稳定的对数线性关系。这提示了一种新的机器人学习范式：与模仿学习中传统的人工遥操作相比，通过神经轨迹制作合成数据更容易扩大规模。最后，仅使用 IDM 动作标注的神经轨迹训练，策略在 24 项任务上仍达到 20.6% 的平均成功率，进一步体现了神经轨迹的质量。详细结果见附录 E。

原文脚注 5：RoboCasa 基准为策略训练提供左、右、腕部三个视角；本实验以 GR00T N1 [5] 为基础策略。脚注 6：对完全没有真实动作数据的机器人形态，实现向新行为和新环境的零样本泛化仍是尚未解决的研究问题。

【原文图 5：真实机器人评估。红色矩形框表示训练与评估期间物体位置的随机化范围。“Low Data”表示只用可用训练数据的 10%（除 GR1 叠毛巾任务使用 25 条外，每项任务只用 10 条）；“Low Data + Neural Traj.”表示加入神经轨迹联合训练。】

真实世界实验。 对 GR1 的四项任务和 Franka 的三项任务，我们每项采集 100 条轨迹；对 SO-100 的草莓抓取放置与井字棋两项任务，分别采集 40 和 50 条。九项任务的

数据采集及评估标准见附录 I，逐任务的视频世界模型训练流程见附录 F。为检验数据效率，主实验默认只使用 GR1 和 Franka 采集轨迹的 10%（每项任务 10 条），以及 SO-100 采集轨迹的 25%（两项任务分别为 10 和 13 条）。我们为每项 GR1 任务生成 300 条神经轨迹，为每项 Franka 任务生成 100 条，为 SO-100 两项任务分别生成 40 和 50 条，再以 1:1 的采样比例与真实轨迹联合训练。

如图 5 所示，在各种机器人形态上，神经轨迹都稳定提升了不同视觉运动策略（Diffusion Policy、 π_0 和 GR00T N1）的性能。任务涵盖工具操作、可变形物体操作及抓取放置。这些任务涉及工具和可变形材料之间复杂的物理交互，给仿真带来很大挑战，因此现有文献的方法难以为其生成合成数据。实证上，GR00T N1 的性能增益高于 Diffusion Policy 和 π_0 ；我们推测，给 IDM 动作单独设置动作编码器和解码器参数，有助于处理神经轨迹状态输入全为零的问题。

原文脚注 7：附录 G 还给出了使用全部训练数据（“High Data”）训练的模型评估结果。

3.2 释放泛化能力

为了展示 DreamGen 如何让机器人学习具备泛化能力，我们使用 GR1 人形机器人执行多种抓取放置动作的 2,884 条轨迹，训练目标视频世界模型。然后，用（1）已见环境中的新行为，以及（2）新环境中的已见行为与新行为来提示模型，生成神经轨迹。评估设置的可视化示例（包括目标物体的位置随机化范围）见图 11。本节以 GR00T N1 为基础策略。

行为泛化。 我们考察：仅凭神经轨迹、完全不进行人类遥操作，机器人能否学会全新行为。我们把“新行为”定义为超出既有运动适配范围的新动作动词。令人意外的是，只给出初始帧和语言指令，视频世界模型就能生成完全未见行为的视频（示例见图 12；原文建议访问项目网站观看效果）。利用这种能力，我们为 14 项新行为任务各生成 50 条神经轨迹，并且只用这些轨迹训练下游视觉运动策略。

表 1 首先列出仅用 2,885 条抓取放置轨迹微调的 GR00T N1 结果。某些任务允许“只抓起物体”得到部分分数，例如在“倒水”任务中抓起瓶子计作 0.5 次成功，因此该基线也有一定非零表现。正文此处写的是 11.8%，但随后给出的提升幅度和表 1 中的平均值均为 11.2% → 43.2%。加入神经轨迹后取得的非零性能提升，表明这个流程能让策略学到全新的动作动词。

环境泛化。 令我们意外的是，给视频世界模型输入完全陌生环境的初始帧，它仍能生成十分逼真的机器人视频：既遵循微调时学到的运动学，又保留预训练时从互联网视频获得的知识。我们按同一流程，只用神经轨迹训练视觉运动策略。如表 1 所示，策略在已见行为（抓取放置的变体）和未见行为（浇花、关容器、用打蛋器搅拌等）上，都取得了非零的成功率。与通过扩大训练数据中环境总数来实现环境泛化的已有研究 [6] 不

同，我们的方法除了单个环境（即实验室布置）以外，不需要采集新的实体机器人数据；只需拍摄新环境的初始帧，便能实现零样本迁移。只在单一环境中用抓取放置数据训练的基线，在新环境上的成功率是 0%，因为它无法泛化出原训练环境。

原文表 1：新行为（14 项任务）与新环境（13 项任务）的成功率，单位为 %。“加入 DreamGen”对应原表的 w/ DreamGen。

已见环境中的新行为	GR00T N1	加入 DreamGen
打开微波炉	0	23
打开 MacBook	0	45
关上饭盒	0	10
敲击铃鼓	5	15
敲击键盘	0	90
按下按钮	45	75
倒水	40	55
给花浇水	50	95
点燃蜡烛	10	15
使用吸尘器	0	55
熨烫衬衫	0	20
取出勺子	7	17
展开垫子	0	55
移动鼠标	0	35
平均	11.2	43.2

新环境中的任务	GR00T N1	加入 DreamGen
拿起橘子	0	30
把三明治装盒	0	10
给橙子称重	0	20
把杯子放进垃圾桶	0	45
把梨放进篮子	0	35
把酱料放在托盘上	0	45

新环境中的任务	GR00T N1	加入 DreamGen
给花浇水	0	15
提起篮子	0	55
用勺子画圈搅动	0	15
使用打蛋器	0	25
关上汤罐	0	55
揭开锅盖	0	30
盖上锅盖	0	35
平均	0.0	28.5

译注：本节首段写训练视频世界模型用了 2,884 条轨迹，下文另写基线在 2,885 条轨迹上微调；11.8% 和 11.2% 也并存于原文。这里保留各处原始数字，不自行统一。

4. DreamGen Bench：面向机器人的视频生成基准

受近期评测视频生成模型世界建模能力的工作 [25–28] 启发，我们提出 DreamGen Bench。这是一个系统性的世界建模基准，目标是量化现有视频生成模型适应某一特定机器人形态的能力：模型既要掌握该机器人的刚体物理规律，也要泛化到新物体、新行为和新环境。我们衡量两个关键指标：指令遵循和物理遵循。

原文脚注 8：项目网站为 <https://research.nvidia.com/labs/gear/dreamgen>。

原文表 2：DreamGen Bench 的数据统计与结果。 IF 为指令遵循，PA 为物理一致性；GPT、Qwen、Hu 分别表示 GPT-4o、Qwen2.5-VL 和人工评估。**-zero** 是零样本推理，**-sft** 是微调版本；原表以粗体标最佳、下划线标第二名。RoboCasa 训练集为 1,200 条轨迹、评估集为 48 帧；GR1 训练集为 100 条轨迹，对物体、行为、环境分别有 50、47、30 帧评估数据。为方便阅读，下表每组数字按“IF: GPT / Qwen / 人工；PA”排列，— 表示没有人工评分。

模型	RoboCasa	GR1 新物体	GR1 新行为	GR1 新环境
Hunyuan-zero	1.0 / 0.0 / —； 0.0	0.0 / 0.0 / —； 0.0	0.0 / 2.1 / —； 2.1	0.0 / 0.0 / —； 0.0

模型	RoboCasa	GR1 新物体	GR1 新行为	GR1 新环境
CogVideoX-zero	0.0 / 0.0 / —; 0.0	0.0 / 0.0 / —; 0.0	0.0 / 0.0 / —; 0.0	0.0 / 0.0 / —; 0.0
WAN2.1-zero	0.0 / 0.0 / —; 0.0	0.0 / 2.0 / —; 2.0	0.0 / 2.1 / —; 2.1	0.0 / 6.7 / —; 6.7
Cosmos-zero	4.2 / 22.9 / —; 22.9	0.0 / 32.0 / —; 32.0	6.4 / 31.9 / —; 31.9	3.5 / 24.1 / —; 24.1
Hunyuan-sft	68.8 / 8.3 / 81.3; 44.8	38.0 / 26.0 / 52.0; 39.0	38.3 / 10.6 / 14.9; 12.8	27.6 / 27.6 / 43.2; 35.4
CogVideoX-sft	72.9 / 10.4 / 79.2; 44.8	72.0 / 38.0 / 72.0; 55.0	44.0 / 28.0 / 21.3; 24.7	55.2 / 41.4 / 61.1; 51.3
WAN2.1-sft	77.1 / 18.8 / 91.7; 55.3	72.0 / 58.0 / 80.0; 69.0	72.3 / 55.3 / 74.5; 64.9	48.3 / 65.5 / 67.4; 66.5
Cosmos-sft	79.2 / 29.2 / 93.8; 61.5	90.0 / 62.0 / 84.0; 73.0	59.6 / 61.7 / 68.1; 64.9	69.0 / 65.5 / 53.3; 59.4

首先，指令遵循指标评估生成视频是否严格依照给定指令，呈现机器人完成指定任务的过程。我们把生成视频连同特定提示语交给 Qwen-VL-2.5 [29]，让它输出二值分数（0 或 1），衡量视频内容与任务指令是否一致，从而检查视频里的动作和场景是否符合预定目标。评估时使用的完整提示语见附录 H.1。除模型评估外，我们还提供人工评估；附录 H.3 显示，模型评分与人工判断的平均皮尔逊相关系数超过 90%。

其次，我们量化“物理一致性”，判断生成视频在物理上是否合理，从而能否真正用于下游机器人学习。为此，我们先使用 VideoCon-Physics [26]：一个专门训练来评价生成视频是否遵循物理规律的视觉语言模型，其分数介于 0 到 1。实际使用中，我们发现它没有在多视角视频（如 RoboCasa）和多种机器人环境上训练，因此又让通用视觉语言模型 Qwen-VL-2.5 根据我们的提示为每个视频评分。对每个数据集中的每种视频生成模型，我们将两个分数取平均。VideoCon-Physics 的更多细节见附录 H.2。

我们用这两个指标比较四种视频世界模型：Hunyuan [10]、CogVideoX [8]、WAN 2.1 [9] 和 Cosmos [7]。训练与评估有两组设置：一组是使用 Franka Emika 的仿真实验，另一组是使用 Fourier GR1 人形机器人的真实实验。我们还衡量模型未针对特定机器人形态适配时的零样本能力。结果和数据统计见表 2。除了这两个指标，我们还在仿真中回放 IDM 动作，从实际效果检验其质量；为此我们使用 Fourier GR1 的数字孪生体。更多细节见附录 H.4。

DreamGen Bench 得分与下游策略性能呈正相关。 为检验 DreamGen Bench 能否用作下游机器人策略性能的替代评估，我们分别只用不同视频世界模型生成的神经轨迹训练策略，再测量 RoboCasa 基准成绩。如果 DreamGen Bench 与 RoboCasa 呈正相关，就说明构建更善于遵循语言指令、模拟世界物理规律的视频世界模型，有望提升下游机器人操作任务的表现。我们比较表 2 中所有模型，每个模型生成 7,000 条神经轨迹；DreamGen Bench 得分取表 2 的 IF（GPT 评分）和 PA 的平均值。结果见图 6。两种得分确实呈正相关，表明更强的视频世界模型可能带来更大的策略性能提升。

【原文图 6：DreamGen Bench 得分与 RoboCasa 成绩的相关性。每个点对应一个视频世界模型，虚线表示整体正相关趋势。】

5. 相关工作

机器人领域的合成数据生成。 通过人类遥操作采集真实机器人数据耗时且成本高。作为替代，在仿真中收集合成数据能够更高效地自动进行，减少人力投入 [20,30–39]。但使用这些轨迹仍有三类困难：（1）仿真到现实的差距；（2）液体、有活动关节的物体等难以仿真；（3）数据生成会受限于基于任务与运动规划（TAMP）的系统，或只能在已有的人类遥操作数据之间插值。另一条路线使用神经生成模型扩充现有机器人示范 [40–43]，方法包括图像修补、图像扩散，甚至视频到视频模型 [44]。然而，生成数据的多样性依旧有限，尤其是机器人运动方面；这些扩充数据也只是用于增强模型应对视觉分布变化的鲁棒性。

机器人领域的视频世界建模。 视频生成模型能够生成合成机器人轨迹，并在测试时通过逆动力学模型（IDM）[15,16]、作为稠密对应关系的光流 [17]，或作为高层规划的轨迹 [18,19]，从中提取可执行动作。还有工作在测试时生成附带三维跟踪的人类视频 [45]，或生成新场景、新运动下的人类视频 [46]，再以点跟踪目标训练策略。一项同期工作 [47] 探索将文本到视频模型适配到任务泛化：生成合成轨迹后用 IDM 提取可执行动作，或从中提取奖励来引导强化学习策略；但它的研究范围仅限仿真任务。近期另一些工作尝试以视频生成模型初始化机器人策略 [48,49]，或者联合训练策略、逆动力学和前向动力学，从而同时使用机器人数据与视频数据 [50–53]。我们有意将这些组件分开，以便充分利用目前最先进的视频生成模型；现阶段还无法让这类模型与机器人策略在实时控制中并行运行，同时保证最强的泛化能力。

从视频学习机器人策略。 视频为训练机器人提供丰富信息，但大多数视频没有动作标签 [54]。为改进视觉表示，已有工作利用人类活动的第一人称视频预训练视觉编码器 [55]，并证明它对下游任务有益 [56,57]。一些方法从以人为中心的视频中提取不同形式的信息，包括人与物体的交互 [58]、物体的可操作性 [59–62] 和视觉轨迹 [63,64]。另一些研究把人的运动转化为机器人行为，使用手部姿态估计器 [62,65–69] 或动作捕捉系统 [70]。还有一条研究路线从当前帧与未来帧之间的视觉变化提取潜动作，以训练下游机

器人策略 [4,13,71–76]。本文使用的来源是世界模型生成的合成视频，而非人类视频；我们探索通过把潜动作与真实动作联合训练来利用这些视频。

6. 结论

我们提出一套新的机器人学习流程，借助先进视频生成模型的能力。通过生成合成视频并提取伪动作，我们能够训练视觉运动策略，而不必完全依赖人工示范。这种方法既能扩充已有任务的数据，也能让机器人在未见环境中学会全新行为。**DreamGen** 为充分释放世界模型在机器人领域的潜力迈出了坚实的一步。