

Ego-Exo4D：围绕熟练人类活动的多模态多视角视频数据集

原文：[2311.18259v4.pdf](#)

范围：仅翻译到 Acknowledgements 之前，包括摘要、正文、结论和贡献声明；Acknowledgements 及其后的附录、参考文献不在本文件范围内。

项目主页：<https://ego-exo4d-data.org/>

摘要

本文提出 Ego-Exo4D：一个多样化、大规模、多模态、多视角视频数据集和 benchmark 挑战。Ego-Exo4D 围绕熟练人类活动中同步采集的第一人称 (egocentric, ego) 和第三人称 (exocentric, exo) 视频展开，例如运动、音乐、舞蹈、自行车维修等。来自全球 13 个城市的 740 名参与者，在 123 种自然场景上下文中完成这些活动，形成了每段 1 到 42 分钟不等的长视频，总计 1,286 小时。

该数据集的多模态性质前所未有：视频同时配有多通道音频、眼动注视、三维点云、相机位姿、IMU，以及多种成对语言描述。其中包括一种新的“专家评论”：由教练和教师完成，专门面向熟练活动领域。为了推动第一人称视频对熟练人类活动理解的前沿，作者还提出一套 benchmark 任务及其标注，包括细粒度活动理解、熟练度估计、跨视角翻译、三维手部/身体姿态等。所有资源均开源，以推动社区研究。

关键词：视频理解；第一人称视频；egocentric；视频-语言；三维；身体姿态。

1. 引言

舞者跃过舞台；Lionel Messi 送出精准传球；你的祖母包出她著名的饺子。我们在各种场景中观察并追求人类技能，从实用技能（修自行车）到令人向往的技能（优美地跳舞）。AI 理解人类技能意味着什么？要实现这一目标又需要什么？

AI 对人类技能的理解可以支撑许多应用。在增强现实中，佩戴智能眼镜的人可以通过虚拟 AI 教练快速学习新技能，并获得实时指导。在机器人学习中，机器人通过观看环境中的人类，可以用更少物理经验获得新的灵巧操作技能。在社交网络中，人们可以根据视频中展示的专业知识和互补技能形成新的社区。

作者认为，第一人称和第三人称视角对捕获人类技能都至关重要。首先，两种视角具有协同关系。第一人称视角捕获近距离手-物交互细节和佩戴者注意力；第三人称视角捕获全身姿态和周围环境上下文。教学视频经常在示范者的第三人称视图和接近第一人称的手部近景之间切换，正是这一点的自然体现。例如厨师可能先在第三人称视角中描述方法和设备，再切换到手部操作食材和工具的近景片段。

其次，在学习技能时，不仅 ego 和 exo 视角互补，还需要能在二者之间流畅转换。想象你观看专家修补自行车轮胎、颠足球或折纸天鹅，然后把他们的步骤映射到自己的身体上。认知科学告诉我们，即使年纪很小，人类也能观察他人的行为 (exo) 并映射到自己 (ego) 身上；这种行动者-观察者转换是视觉学习的基础。

但现有数据集和学习范式无法实现这一潜力。已有同时包含 ego 和 exo 视角的数据集数量少、规模小、缺少跨相机同步，或者过于舞台化和策划化，无法应对真实世界多样性。因此，当前活动理解文献通常只关注 ego 或 exo 其中一种视角，难以在第一人称和第三人称之间自然迁移。教学或 how-to 视频数据集虽然能观察熟练活动，但也多局限于单视角视频，或仅在某些时间点混有“类似 ego”的视角。

作者提出 Ego-Exo4D，作为支持 ego-exo 视频学习和多模态感知研究的基础数据集。该数据集由 15 个研究机构组成的联盟历时两年完成，是首个此类大规模多模态多视角数据集和 benchmark 套件。它是当前最大的公开时间同步第一/第三人称视频数据集：由 740 名多样化相机佩戴者，在全球 13 个城市、123 个不同场景中采集。每个序列都包含相机佩戴者的 ego 视频，以及围绕佩戴者放置的 4 到 5 个三脚架 exo 视频。所有视角时间同步，并在米制、重力对齐的参考系中精确定位。总数据为 1,286 小时视频、5,035 个实例，每个实例为 1 到 42 分钟连续采集。

Ego-Exo4D 聚焦单人熟练活动。740 名参与者以非脚本方式、在自然场景中执行熟练的身体活动或程序性活动，包括舞蹈、足球、篮球、抱石、音乐、烹饪、自行车维修、健康护理等；参与者技能水平从新手到专家不等。所有视频均在严格隐私与伦理政策下采集，并获得参与者正式同意。

Ego-Exo4D 不仅是多视角，也是多模态。借助开源 Project Aria 眼镜，所有 ego 视频都伴随 7 通道音频、IMU、眼动注视、RGB 相机、两个灰度 SLAM 相机，以及三维环境点云。此外，Ego-Exo4D 提供多种新的视频-语言资源，全部带时间索引：相机佩戴者以第一人称描述自己动作；第三人称逐步描述每个佩戴者动作；以及第三人称专家语音评论，对其表现进行评价。最后一种尤其新颖：它由特定领域的经验教练和教师完成，关注活动“如何执行”，而不只是“做了什么”，能够揭示非专业观察者难以察觉的熟练执行细节。三类语言语料全部与视频对齐。作者认为此前没有任何视频资源具备如此广泛且高质量的多模态数据。

伴随数据，作者提出面向 ego-exo 视频的基础任务 benchmark，并用标注和评估协议将其形式化。任务分为四大家族：

- 1. **ego-exo relation**：通过估计语义对应和进行视角翻译，将教师（exo）的动作与学习者（ego）关联起来。
- 2. **ego(-exo) recognition**：识别细粒度关键步骤和任务结构。
- 3. **ego(-exo) proficiency estimation**：推断一个人执行某项技能的好坏程度。
- 4. **ego pose**：从 ego 视频中恢复熟练三维身体和手部运动。

作者为每个任务提供标注，这些标注来自超过 200,000 小时的标注员劳动。为了推动这些新挑战，作者还开发 baseline 模型并报告结果，并在 2024 年举办第一批公开 benchmark 挑战。

虽然动机来自技能学习，Ego-Exo4D 的影响范围会更广。现有数据集缺少真实世界三维上下文中的活动建模，常限于动捕服或实验室场景；现有三维数据集则通常聚焦静态场景和物体。Ego-Exo4D 可用于一般三维视觉研究，例如环境重建、相机重定位、音视频映射等。它的新视频-语言资源也为动作和物体 grounding、多模态表征学习和语言生成提供机会。最后，尽管 benchmark 优先考虑“ego-only”视角感知，数据中的 exo 部分也可用于传统第三人称活动识别和身体姿态估计。

总之，Ego-Exo4D 是社区第一个多样化、大规模、多模态、多视角视频资源。作者开源了全部数据、标注、相机 rig 协议和 benchmark，目标是推动 ego-exo、多模态活动理解及更广泛研究。

图 1

Ego-Exo4D 为一系列熟练人类活动同时提供第一人称视频和多个时间同步第三人称视频流，总计 1,286 小时 ego 与 exo 视频。数据既是多视角也是多模态，并包含大量语言、三维身体和手部姿态、关键步骤、程序依赖和熟练度评分标注，用于支持作者提出的 benchmark 任务。

图 2

图 2 是全文路线图：第 3 节介绍数据集，包括 ego-exo 相机 rig、领域与环境、参与者、隐私和伦理；第 4 节介绍自然语言描述，包括专家评论、边做边讲、原子动作描述；第 5 节介绍 benchmark，包括 ego-exo 关系、ego-exo 关键步骤识别、ego-exo 熟练度估计、ego pose。

2. 相关工作

第一人称数据集

第一人称视频理解近年来快速发展，受益于 Ego4D、EPIC-Kitchens、UT Ego、ADL、KrishnaCam 等展示非脚本日常活动的数据集，以及 EGTea、AssistQ、Meccano、CMU-MMAC、EgoProcel、HoloAssist 等程序性活动数据集。不同于这些数据集，Ego-Exo4D 聚焦多模态 ego 和 exo 同步采集，并关注熟练活动领域。

Ego-Exo4D 团队中的许多成员也参与创建 Ego4D。两个数据集有共同点：都强调真实环境中的长时连续非脚本数据、参与者多样，并提供新 benchmark 和视频-语言标注。但 Ego4D 仅关注第一人称日常活动；Ego-Exo4D 聚焦特定领域的熟练活动，同时采集 ego 和 exo 视角，并显著更加多模态。Ego-Exo4D 的语言标注也更宽，不仅有逐步动作叙述，还包括第一人称 how-to 描述和第三人称专家评论。

多视角与 ego-exo 数据集

多数现有多视角数据集关注静态场景、物体，或仅第三人称的人类活动。CMU-MMAC 和 CharadesEgo 是早期同时采集 ego 和 exo 视频的尝试。CMU-MMAC 包含 43 名穿动捕服参与者在实验室厨房中烹饪 5 个食谱。CharadesEgo 中，71 名众包参与者按脚本顺序录制 ego 和 exo 视频，因此视频不同步且活动不完全匹配。

较新的 ego-exo 工作多聚焦一两个环境中的特定活动。Assembly101 和 H2O 在实验室桌面环境中提供同步 ego/exo 视频，用于玩具车组装或手持物体操作。LEMMA 包含多智能体、多任务日常活动。Homage 提供家庭活动如洗衣的 30 小时 ego-exo 视频。EgoExoLearn 提供 120 小时第一人称视频，用于模拟跟随第三人称人类示范的过程。

相比这些工作，Ego-Exo4D 在参与者数量、地点多样性和时长上都高一个数量级：740 名参与者、123 个独立场景、13 个城市、1,286 小时视频。更重要的是，它聚焦熟练任务，使参与者走出实验室或家庭，进入足球场、舞蹈室、攀岩墙、自行车维修店等场所。这些活动带来场景中的多样全身姿态和运动，不局限于桌面物体操作。因此，Ego-Exo4D 也扩展了已有三维人体姿态数据集。表 1 总结了 Ego-Exo4D 与已有数据集的比较。

表 1

表 1 比较 Ego-Exo4D 与相关数据集。相比已有同时采集第一人称和第三人称视角的数据集，Ego-Exo4D 具有更多模态、更多被试、更大场景多样性，以及更丰富标注，包括关键步骤片段、物体掩码、身体姿态、手部姿态，以及三类与视频精细同步的自然语言描述（narration、narrate-and-act、expert commentary）。作者认为 Ego-Exo4D 还提供了迄今最大规模的人工 ego 身体姿态真值标注，并总计有约 1,400 万帧三维姿态标注和伪标注。

人类技能与视频学习

技能和动作质量分析此前关注有限。教学或 how-to 视频研究主要由 HowTo100M 等第三人称为主的数据集推动，挑战包括关键步骤 grounding、程序规划、任务结构学习，以及利用噪声叙述。Ego-Exo4D 的一部分也是程序性活动，但它同时提供 ego-exo 采集；其规模和多样性，以及三种语言描述，拓宽了熟练活动理解研究的路径。

Ego-exo 跨视角建模

由于缺少高质量同步真实数据，ego-exo 跨视角建模研究有限。已有工作涉及跨视频匹配人物、学习视角不变特征或 ego 特征。更一般的跨视角方法也研究翻译、新视角合成、跨视角定位、相机重定位等。Ego-Exo4D 通过同步多视角、多模态数据，为跨视角关系、对应和翻译提供更扎实资源。

3. Ego-Exo4D 数据集

Ego-Exo4D 的目标是采集自然环境中的熟练活动，且同时获得第一人称和多个第三人称视角。数据集设计包含相机 rig、Project Aria 设备、预计算三维空间信号、录制流程、领域和环境、参与者，以及伦理合规。

3.1 Ego-exo 相机 rig

采集系统包含佩戴者的 Project Aria 眼镜和多个 GoPro 第三人称相机。每条记录中，相机佩戴者执行一个熟练活动，多个 exo 相机放置在周围，提供同步的外部观察。所有设备都通过统一流程同步和定位，形成米制、重力对齐的三维参考系。

图 3 展示用于第一人称记录的 Aria 设备。它包含 RGB 相机、两个灰度 SLAM 相机、眼动追踪、IMU、麦克风阵列等传感器。图 4 展示 Project Aria 记录的传感器流。图 5 展示 Aria MPS 为若干记录输出的结果，包括轨迹、点云和空间定位信号。

3.1.1 Aria 设备与传感器

Project Aria 眼镜提供多种传感器流：RGB 视频、双灰度相机、IMU、音频、眼动注视，以及可用于三维环境理解的定位与点云。相比普通第一人称相机，这使 Ego-Exo4D 能同时支持视频理解、空间理解、姿态估计和多模态学习。

3.1.2 预计算三维空间信号

数据集提供预计算空间信号，包括相机位姿、三维点云、重力方向对齐和跨视角几何关系。这些信号允许研究者将 ego 和 exo 视频放在同一三维坐标框架中分析，支持视角对应、视角翻译、姿态估计等任务。

3.1.3 录制流程

录制流程包括场景准备、相机布置、设备同步、参与者同意、活动执行和后处理。作者强调流程可复现，并在不同国家和机构复制，以获得一致数据。附录中给出了更详细的相机设置和站点采集流程。

3.2 领域与环境

Ego-Exo4D 覆盖 8 个领域、43 个具体活动和 689 个关键步骤。这些领域分为两类：程序性技能和身体技能。程序性技能强调使用工具操作环境，例如烹饪、自行车维修、健康护理；身体技能强调对身体的力量、柔韧性或训练要求，例如舞蹈、足球、篮球、抱石、音乐演奏。

图 6

图 6 展示 Ego-Exo4D 在 8 个领域中捕获熟练活动，覆盖 43 个任务和 689 个关键步骤，场景多样，包括厨房、维修空间、医疗训练空间、运动场、舞蹈室、音乐排练空间等。

表 2

表 2 列出三类程序性领域和五类身体领域采集的 43 个具体活动。程序性活动包括烹饪、自行车维修、健康护理中的多个任务；身体活动包括篮球、足球、舞蹈、音乐、抱石等。该表将具体活动按领域组织，作为后续关键步骤、语言描述和 benchmark 标注的基础。

3.3 参与者

Ego-Exo4D 包含 740 名参与者，来自 13 个城市和 123 个场景。参与者技能水平覆盖新手、早期专家、中级专家、后期专家等。图 7、图 8 展示不同领域中的自然场景样例。图 9 展示数据集在地理上的覆盖范围，图 10 展示相机佩戴者自报技能水平分布。

3.4 隐私与伦理

数据采集遵循严格隐私和伦理流程，包括正式同意、场景中其他人的隐私处理、采集前后检查、敏感信息处理等。作者强调，所有视频均在严谨政策下记录，且参与者正式同意被采集和用于研究。

4. 自然语言描述

Ego-Exo4D 提供三类成对视频-语言语料：专家评论、边做边讲、原子动作描述。图 11 展示三种语料及专家评论词云。图 14 给出三种标注风格示例。

4.1 专家评论

专家评论是 Ego-Exo4D 的新颖资源之一。它由 52 名领域专家完成，包括教练、教师或具备评估/教学经验的人。专家在观看视频时，对参与者表现进行时间同步评论，重点不是简单描述动作，而是评价动作如何执行：哪里做得好，哪里可以改进，应注意什么身体姿态、节奏、工具使用方式或策略。图 12 展示执行专家评论的专家群体，图 13 给出专家评论示例。

专家评论尤其适合研究熟练度理解和可操作反馈，因为它把观察者的专业判断与视频时间轴对齐，并包含对细节的空间关注和质量判断。

4.2 边做边讲

“Narrate and act” 指参与者在执行活动时用第一人称描述自己正在做什么、为什么这样做，以及与其技能相关的思考。它反映了行动者自身对技能执行过程的理解。与第三人称动作描述相比，这类语言更接近学习者或执行者的内在解释，包含经验性判断和策略说明。

4.3 原子动作描述

原子动作描述是第三人称的逐步动作标注，描述相机佩戴者每个动作，粒度较细，用于探索数据、训练动作识别、定位关键步骤和构建任务结构。该类描述可以提供关键词和短动作片段边界，为后续 benchmark 任务提供基础。

5. Ego-Exo4D Benchmark

作者提出五个主要 benchmark 方向，组织在四个任务家族中：ego-exo 关系、ego-exo 关键步骤识别、程序理解、ego-exo 熟练度估计、ego pose。表 3 汇总不同 benchmark 任务的标注统计，例如对象数、活动数、关键步骤数、熟练度评分等。

表 3

表 3 总结 Ego-Exo4D benchmark 任务的标注统计。标注覆盖 ego-exo 关系、关键步骤识别、程序理解、熟练度估计、身体姿态和手部姿态等任务，包含数千对象、数百关键步骤、数千熟练度评分，以及大量姿态标注。

5.1 Ego-exo 关系

该任务族关注第一人称和第三人称之间的关系，包含两类任务：ego-exo correspondence 和 ego-exo translation。图 15 展示对应任务与翻译任务：前者要在 exo 视频中找到与 ego 中给定查询区域对应的语义区域；后者要从 exo 输入合成或预测 ego 视角。

5.1.1 Ego-exo 对应

Ego-exo 对应任务要求模型在同步 exo 视频中定位与 ego 查询掩码语义对应的区域。评估指标包括 balanced accuracy、IoU、location score 和 contour accuracy。作者比较空间基线、时间/几何基线和学习型基线。图 16 展示不同 baseline 的定性结果；表 4 展示测试集定量结果。结果说明，跨视角精确对应仍然困难，单纯空间或几何线索不足以解决真实场景中的遮挡、视角差异和语义歧义。

5.1.2 Ego-exo 翻译

Ego-exo 翻译任务关注从 exo 输入生成 ego 视角，或在视角之间转化。作者评估若干生成式模型和变体，表 5 报告 exo 到 ego 翻译结果，图 17 展示定性结果。结果表明，从外部视角生成佩戴者视角具有挑战：模型必须理解相机位置、身体运动、手-物交互和遮挡关系。

表 4

表 4 给出 ego-exo correspondence benchmark 的 baseline 结果。指标包括 balanced accuracy、IoU、location score 和 contour accuracy。最佳结果以加粗标示。整体结果显示，该任务仍存在显著提升空间。

表 5

表 5 给出 exo-to-ego translation 任务结果。作者比较不同条件、输入和模型变体，用图像质量和结构相似相关指标评估。结果显示，利用同步 exo 信息可以帮助生成 ego 视角，但视角转换仍远未解决。

5.2 Ego-exo 关键步骤识别

该任务族关注细粒度关键步骤和任务结构理解。图 18 概览了 ego-exo key-step recognition 的任务，包括细粒度识别、能效多模态预测、程序理解等。

5.2.1 细粒度关键步骤识别

细粒度关键步骤识别要求模型从视频片段中识别活动中的关键步骤，例如烹饪、修车、健康护理中的具体动作。关键步骤持续时间分布差异很大：有些动作很短，有些持续很久。图 19 展示程序性场景中关键步骤分布；图 20 展示烹饪、修车和健康场景的关键步骤示例。

作者评估多个视频模型、预训练设置和输入视角组合。表 6 报告验证集和测试集 Top-1 准确率。结果显示，ego 视频对近场手-物交互关键步骤识别很有价值，exo 视频提供上下文补充；多视角和预训练可以改善性能，但细粒度识别仍具挑战。

表 6

表 6 报告关键步骤识别的 Top-1 accuracy，区分验证集和测试集，并标注预训练数据集。整体趋势是：更强视频预训练、多模态/多视角输入和任务相关数据能提高性能，但模型仍难以充分捕捉长尾关键步骤和细粒度差异。

5.2.2 能效多模态关键步骤预测

这一任务研究在能耗受限设备上进行关键步骤预测。由于可穿戴设备功耗敏感，模型不仅要准确，还要低功耗。作者比较不同模态与模型组合的 mcAP 和功耗。表 7 给出关键步骤预测结果，图 21 展示性能和总功耗之间的权衡。结果说明，加入低功耗模态可以在一定功耗范围内获得较好预测，但高性能视频模型通常功耗很高，能效仍是实际部署的关键问题。

表 7 与图 21

表 7 报告不同方法的关键步骤预测 mcAP 和功耗。图 21 将 mcAP 与总功耗画在一起，展示不同预测方法的准确率-能耗权衡；其中一些设置功耗约 20mW，而完整视频处理方案可达到数千 mW。

5.2.3 程序理解

程序理解任务要求模型理解活动中步骤之间的依赖关系和结构。例如在烹饪中，某些步骤必须先于另一些步骤发生。作者将任务结构表示为图，评估模型是否能从视频中恢复程序依赖。图 22 展示一个烹饪任务图示例，图 23 展示两种程序理解方法：基于图的方法和基于视频序列的方法。表 8 报告结果。结果显示，程序理解比单步识别更难，因为它要求模型捕获长期依赖和任务结构，而不仅是局部动作分类。

表 8

表 8 给出程序理解任务结果，最佳结果加粗，第二好结果标注。结果表明，结合视频证据和结构建模的方法较强，但任务仍有明显提升空间。

5.3 Ego-exo 熟练度估计

熟练度估计任务要求推断一个人执行技能的水平。图 24 展示示范者熟练度和示范熟练度的概念区别。示范者熟练度指人本身在某领域的水平；示范熟练度指某一次具体执行的质量。表 9 给出不同熟练度等级上的视频 take 分布。

作者分别评估 demonstrator proficiency estimation 和 demonstration proficiency estimation。前者希望从视频中判断参与者整体技能水平，后者判断特定片段或执行实例的质量。标注来自参与者自报、专家评价或任务相关评分。表 10 和表 11 分别报告相关 benchmark 结果。结果说明，ego 视频已足以取得较好表现，但 exo 信息和多模态信号可提供补充；熟练度估计仍然依赖对细节和领域知识的理解，远比普通动作识别更细。

表 9、表 10、表 11

表 9 展示熟练度 benchmark 中视频 take 的分布。表 10 报告示范者熟练度估计结果。表 11 报告示范熟练度估计结果，使用 mean average precision 等指标，在验证集和测试集上评估。整体结果表明，该任务具有可学习信号，但仍有较大改进空间。

5.4 Ego pose

Ego pose 任务关注从第一人称原始视频或 IMU 数据中估计三维人体身体姿态和手部姿态。为促进只依赖第一人称信号的方法发展，输入排除了会不公平简化任务的其他 ego 模态，例如音频和眼动，也排除了 exo 视频及其可提取信号。图 25 展示 ego-pose 估计中的手部和身体关键点。

相关工作

可穿戴相机三维身体姿态估计已有少量工作。有些方法假设身体完全不可见，另一些通过改造相机捕获部分身体。Ego-Exo4D 可支持两类范式。现有手部姿态数据集多来自受控环境，手部运动简单；Ego-Exo4D 包含真实世界中多样熟练手部运动，例如专家音乐家和自行车技师的动作。

标注

三维人体姿态标注分两阶段：自动真值生成，以及人工多视角关键点标注/修正。首先用现成模型在每个 exo 视角中预测二维人体框；由于场景中可能有多人，作者将 MPS 输出的三维头显位置投影到图像中，以选择对应相机佩戴者的框。随后对每个框运行二维人体关键点检测器，最后用带 RANSAC 的三维三角化最小化重投影误差，得到佩戴者三维关键点。人工标注阶段中，将去畸变帧和重投影二维关键点导入多视角标注界面。

三维手部姿态标注也包含自动真值生成和人工多视角关键点标注两个阶段。与身体姿态不同的是，手部姿态还从 ego 帧检测手部关键点，并利用全身姿态估计结果在多人场景中推断手部位置。人工标注时，除 exo 帧外也向标注员展示 ego 帧，使其能标注或修正手部关键点。对每个人工标注关节，数据记录用于三角化的可见视角数量，作为真值置信度指标。标注员在 ego 图像上对手部关节的修正，也可作为理解从给定 ego 视角重建手部难度的指标。

Ego-Exo4D 提供了目前最大规模可用人工身体姿态标注和手部姿态标注：身体姿态约 376K 三维/2M 二维，手部姿态约 68K 三维/340K 二维。此外还提供自动生成的身体姿态 9.2M 三维/47M 二维、手部姿态 4.3M 三维/21M 二维，总计约 1,400 万帧三维真值和伪真值。作者认为这是目前文献中最大的身体姿态标注集合，无论 ego 或 exo 视频。

自动真值质量如何？相对于人工标注，身体和手部 MPJPE 分别为 3.33 cm 和 1.87 cm，明显小于最佳 baseline 方法误差。需要注意，Ego-Exo4D 处理的是真实世界场景，相机数量不超过 5 个，而不是受控环境，因此存在身体和物体遮挡、远距离相机中手部视角和分辨率有限等挑战。尽管如此，自动生成流水线仍优于 baseline，显示出鲁棒性和有效性。后续实验还表明，使用自动真值训练可提升各 baseline 性能。

指标

身体姿态估计使用平均关节位置误差 MPJPE（厘米）和平均关节速度误差 MPJVE（米/秒）。Ego 手部姿态 baseline 使用 MPJPE 和 PA-MPJPE，单位为毫米。PA-MPJPE 在对手部姿态进行 Procrustes 对齐后计算平均三维关节误差。

Baseline

身体姿态估计评估三种先进 baseline，并加入一个静态姿态 baseline：该 baseline 将三维人体姿态固定为训练集平均姿态，并根据 IMU 传感器平移，使预测在每帧匹配相机位置。

- **Kinpoly**：使用模拟人形体跟踪头部位姿，并基于动作类型生成全身运动。它输出关节力矩并控制仿真人体进行姿态估计。
- **EgoEgo**：先从 ego 视频估计头部位姿，再用扩散模型基于头部位姿序列生成全身运动序列。头部位姿使用 DROID-SLAM 初始化，并用学习方法修正。
- **Location-based**：受基于 Transformer 的稀疏输入姿态估计方法启发，使用设备捕获的头部位姿序列作为输入，直接预测三维位置。

手部姿态估计实现或训练了四个 baseline。二维热图可以显式估计并提升到三维，或直接从二维特征估计三维关节；特征提取器可以是 CNN 或 Transformer。所有手部 baseline 都处理单帧图像，不使用时间信息；可用人工标注或人工+自动标注训练，并只在人工标注上评估。由于多数原方法输出手部 mesh，作者将其修改为只在二维/三维手部关节上训练和监督。

- **THOR-net**: 使用 Keypoint-RCNN 提取二维信息和手部关键点热图，再用 GraFormer 将二维估计提升到三维。
- **HandOccNet**: 使用 ResNet50-FPN 提取二维特征，再用 Feature Injecting Transformer 和 Self-Enhancing Transformer 处理遮挡区域并细化特征。
- **POTTER**: 使用 Pooling Attention Transformer 提取二维视觉特征，降低显存和计算成本，再用 HybriK mesh 回归头生成三维关节和 mesh。
- **METRO**: 提取 CNN 全局图像特征，并用 Transformer 编码器联合建模顶点-顶点和顶点-关节交互；由于该方法强依赖手部 mesh 监督，作者借用 FreiHand 训练 checkpoint，仅推理不在 benchmark 上训练。

结果

表 12 展示三维人体姿态 benchmark 的结果。静态姿态 baseline 的 MPJPE 显著高于其他方法，说明数据集中不同场景姿态极为多样，不能用同一静态姿态处理全部测试样例。其他 baseline 有明显提升，但作者认为仍需进一步改进，尤其是下半身姿态估计和预测时间一致性。

表 13 展示不同场景上的身体姿态测试结果。表 14 报告手部姿态 baseline 的 MPJPE 和 PA-MPJPE；表 15a 报告参数量和 MACs；表 15b 分析可见视角数量对 PA-MPJPE 的影响。图 26 展示各关节平均 PA-MPJPE。结果显示，拇指和指尖误差更大，可能因为它们更常被遮挡或不可见。每个关节标注还记录其可见视角数量；可见视角越少，通常表示它越容易与物体或手部其他部分纠缠，估计难度越大。表 15b 显示，可见视角越多，PA-MPJPE 越低。为保证真值准确，所有实验只使用至少在 3 个相机中可见的关节。

表 12

表 12 报告三维人体姿态 benchmark 的 MPJPE 和 MPJVE。测试集 MPJPE: 静态姿态 215.87 cm, EgoEgo 26.38 cm, Kinpoly 24.36 cm, Location-based 18.51 cm。Location-based 在该表中表现最好。

表 13

表 13 按场景报告身体姿态测试 MPJPE。场景包括篮球、足球、自行车维修、烹饪、健康、舞蹈和音乐。不同方法在不同场景上优势不同，说明技能活动和场景类型对姿态估计难度有明显影响。

表 14

表 14 报告 ego 手部姿态 baseline 的 MPJPE 和 PA-MPJPE。POTTER 在人工标注训练下 PA-MPJPE 为 11.14 mm，使用人工+自动标注后为 11.07 mm；HandOccNet 使用人工+自动标注后 PA-MPJPE 为 13.56 mm；THOR-net 在人工+自动标注后 PA-MPJPE 为 17.61 mm；METRO 未在该 benchmark 上训练，PA-MPJPE 为 20.61 mm。

表 15 与图 26

表 15a 比较手部姿态 baseline 参数量和计算量：THOR-net 参数 59.5M、MACs 123.6G；HandOccNet 参数 37.22M、MACs 15.5G；POTTER 参数 14.5M、MACs 5.2G。表 15b 显示关节可见视角数越多，PA-MPJPE 越低：3 个视角为 14.01 mm，4 个为 12.15 mm，5 个为 11.03 mm，6 个为 10.02 mm。图 26 给出每个关节的平均 PA-MPJPE。

6. 结论

Ego-Exo4D 提供了一条鲁棒的数据收集流水线、一个具有前所未有规模和真实性的数据集，以及一套面向 ego-exo 熟练活动理解和视频学习的 benchmark。作者提出可复制流程，在室内外多样场景中同步采集多个 exo 相机和 ego 数据。该设置跨国复制，用于收集同质数据。这首次使 ego-exo 数据采集走出运动捕捉和实验室设置，捕获参与者自然执行熟练活动的场所，例如厨师在厨房、舞者在舞蹈室、足球运动员在球场。

数据集选择了 8 个具有吸引力且多样的熟练活动领域。作者将这些领域分为身体技能和程序性技能。身体技能特别需要人类身体的力量、柔韧性或训练，例如舞蹈；程序性技能通过使用工具操作周围环境来掌握，例如烹饪。此前这两类熟练活动从未被联合探索。通过把二者放入一个共同数据集和 benchmark，Ego-Exo4D 有望推动辅助技术超越单一领域或应用。

数据集同时提供 benchmark、模型、评估脚本、网页可视化工具和 baseline，帮助研究社区探索并推进 Ego-Exo4D 提出的挑战。

Ego-Exo4D 的一个挑战，也是其局限之一，是在各种设置中优化 exo 相机位置很困难。由于 exo 相机位置标准且静态，动作经常在多数 exo 相机中被参与者自己遮挡。这有时影响标注，因此作者在标注过程中会手动选择合适 exo 相机。此外，数据因活动自然持续时间而呈长尾。例如，烹饪小时数约为足球的 9 倍，因为准备一餐比完成足球训练用时长得多。任务的技能挑战也不同：学习把篮球投进篮筐比完成 COVID 测试需要更多训练和专业性。这种多样性是日常活动的一部分，但也会给当前模型训练带来挑战。

除了数据集的三大基础：流水线、数据和 benchmark，作者还强调两个值得未来研究关注的亮点。

第一，视频配有三层语言描述：正在进行动作的细粒度叙述；参与者自己对活动的描述，反映其专业知识以及为什么以某种方式执行，作者称之为“act and narrate”；以及专家导师评论。这些专家接受过教授或评估他人技能的训练。评论与动作时间同步，并通过空间高亮提示关注某些技能执行方式，既展示优秀表现，也指出改进点，作者称之为“expert commentary”。因此，Ego-Exo4D 提供了首个此类资源，可比较行动者和观察者如何相似或不同地反思技能。

第二，Ego-Exo4D 首次让研究者能够在同一数据集中研究包含手-物交互的细致手部姿态和全身姿态。近期工作已经在合成或受控环境中展示了结合二者的潜力；Ego-Exo4D 可作为基础，把这些方向推进到真实世界记录中。

Ego-Exo4D 是迈向整体理解个体相机佩戴者的重要一步，尤其是理解他们为了工作或爱好提升技能水平的个人目标。理解个人技能的模型可以成为终极辅助伙伴：它能提供可操作的个性化反馈，并随着时间持续监控和量化反馈对佩戴者技能的影响，支持终身技能掌握。除视频中的技能理解外，Ego-Exo4D 也可作为资源推动一般三维视觉、视频-语言学习和传统第三人称活动理解研究。

贡献声明

本项目是过去两年中多个机构大规模合作的结果。初始作者代表项目领导团队。Kristen Grauman 发起项目，担任技术负责人，发起 recognition、proficiency benchmark 和 expert commentary，并协调相关工作组。Andrew Westbury 担任项目经理和运营负责人，负责项目各方面运营。Lorenzo Torresani 领导采集领域开发，发起 relation 和 ego-pose benchmark，并协调相关工作组。Kris Kitani 领导多相机 rig 开发，并在数据标注和组织的各个方面支持 Ego-Exo4D 工程团队。Jitendra Malik 担任科学顾问。带星号的作者是项目实现、采集和/或标注开

发的关键推动者。带 dagger 符号的作者是项目的 faculty 和 senior researcher PI。附录详细说明了各作者在不同 benchmark、数据采集和标注流水线中的贡献。