

Ego2Robot：从第一人称人类数据大规模合成机器人训练数据

原文：Ego2Robot: Scalable Robot Data Synthesis from Egocentric Human Data。对应所提供的 arXiv:2608.02580v1，2026 年 8 月 3 日。

作者：Ye Wang、Pei Lin、Xiong-Hui Chen、Haoqi Yuan、Zhixuan Liang、Yiyang Huang、Anzhe Chen、Zixing Lei、Jie Zhang、Tao Zhang、Haoyang Li、Tong Zhang、Chenxi Xiao、Ziyuan Jiao、Qin Jin。前三位为共同贡献，Qin Jin 为通讯作者。机构包括中国人民大学 AIM3 实验室、阿里巴巴 Qwen 团队、上海科技大学、北京通用人工智能研究院和北京航空航天大学。

阅读说明：按便于个人阅读的中文技术文章翻译，保留正文和全部技术附录，合并断行及重复叙述。VLA 是视觉-语言-动作模型，VLM 是视觉语言模型，EEF 是末端执行器，IK/FK 是逆/正运动学，TCP 是工具中心点。embodiment/morphology 按语境译为“机器人形态”或“平台”。文中的“我们”指论文作者。参考文献保留英文，便于查找。

摘要

要学习有泛化能力的机器人操作策略，需要规模大且多样的示范数据。第一人称人类操作视频具有丰富的场景和任务多样性。此前工作已经证明，把这些视频的动作重定向到机器人，再渲染成机器人格式的数据，可以在小规模、单任务上训练出有效策略。然而，这种方法能否在大规模 VLA 预训练中带来收益，还没有得到充分研究。

我们提出 Ego2Robot：一个可扩展流程，通过动作重定向、机器人手臂视觉合成，以及多层质量清洗，把第一人称人类操作视频转换成机器人训练数据。它既支持整理好的数据集，也支持自然环境中的视频，最终生成覆盖 15 种机器人形态、共 18,561 小时的数据，是作者所知截至本文最大的第一人称人类到机器人合成数据集。

为了评估泛化，我们扩展 RoboTwin 2.0，把视觉外观、场景布局、机器人形态和任务语义拆成独立扰动轴。实验表明，合成数据与机器人数据联合预训练，可以在多种扰动下持续改善 OOD 泛化，收益也在真实机器人部署中得到验证。

关键词：机器人数据合成、第一人称数据、泛化评估。

1. 引言

近年来，VLA 模型通过大规模机器人示范预训练，在操作任务上取得明显进展。但它们的泛化仍根本受制于可用机器人数据的规模和多样性。即使有 Open X-Embodiment、DROID、AgibotWorld 等大规模项目，采集示范仍昂贵且耗费人力，还受到硬件可用性、遥操作成本和交互多样性的限制。

第一人称人类视频提供了另一条路径。相比机器人遥操作，人手交互可以在大量不同物体、环境和任务变体中采集，包含单靠机器人很难获得的操作先验。但人类和机器人形态差异很大，不能直接把人类视频当机器人训练数据。

一种有希望的方法是把人手动作重定向到机器人运动学，再把画面中的人手替换成渲染机器人。这已在小规模单任务中有效，尚未充分探索它能否作为大规模预训练数据，尤其能否改善 OOD 泛化。

本文的假设是：即使形态不同，人类操作视频仍包含可迁移的交互规律，只要正确对齐，就能补充机器人数据。我们据此提出 Ego2Robot，用动作对齐、视觉对齐和多层清洗形成端到端数据合成流程。它支持带手部标注的数据集和纯视频，把约 1,940 小时、四个来源的第一人称视频转到 15 种机器人形态，最终得到 18,561 小时有效训练数据。

【图 1：Ego2Robot 总流程】路径 A 输入带手部姿态标注的数据集 ANT、EgoDex、ViTRA、EgoVerse；路径 B 输入无姿态标注的 Ego Play 视频，先估计手部姿态。随后共同执行重定向平滑、手臂分割、去手修复、基座搜索和 IK、深度合成，并进行流程内、统计和 VLM 语义一致性三层清洗。15 形态、四来源，数据量约扩展 9.6 倍。

我们还构建了 RoboTwin 2.0 上的独立扰动评估。此前把多种分布变化合成一个总分，很难知道预训练究竟改善了视觉稳健性、形态迁移还是语义理解。新的协议将四类因素分开，能细致归因。实验显示，合成数据具有与机器人数据互补的价值，视觉、形态、语义扰动下的提升最明显。这说明它主要改善了不变性和跨分布稳健性，而不只是增加轨迹覆盖。

本文贡献是：支持 15 形态的完整合成流程；18,561 小时合成数据集；拆分视觉、场景、形态、语义的泛化基准；以及合成与机器人数据联合训练改善 OOD 泛化的系统证据。

2. 相关工作

机器人数据扩展与人类数据学习。 大规模机器人数据集和便携采集系统增加了示范，但采集成本和硬件扩展仍限制多样性。人类视频提供更广来源，催生了视觉预训练、奖励

学习、运动先验和点追踪等方法，不过它们通常仍靠机器人数据跨越形态差异。

更直接的路线，一类在人类或第一人称视频和机器人数据上联合训练，另一类通过重定向与渲染、或形态遮罩，把人类示范转成机器人格式。重定向渲染此前主要用于有限规模或单任务。本文把它扩到 18,561 小时、15 形态，并系统研究 VLA 预训练与 OOD 泛化收益。

机器人数据增强。 仿真和数字孪生能合成示范；RoviAug、Mirage、OXE-AugE 通过视频修复和图像编辑缩小机器人到机器人的视觉差异。本文面向差异更大的第一人称人类到机器人领域，利用人手视频生成 15 形态数据，并沿多种独立扰动评测。

泛化基准。 RoboTwin、LIBERO、CALVIN、RLBench、SIMPLER 等通常同时改变多个因素，难以定位失败原因。ManiSkill2/3 和 RoboCasa 支持多个机器人配置，但缺乏标准化跨形态评测。Colosseum、LIBERO-Plus、LIBERO-PRO 将扰动分解，显示 VLA 在单一变化下也明显下降，但主要限于单臂。RoboTwin 2.0 和 EBench 支持双臂，但报告仍多为组合结果。本文同时支持独立扰动、双臂和跨形态评测。

3. Ego2Robot 数据合成流程

给定人手操作的第一人称视频，流程依次执行动作对齐、视觉对齐和质量清洗。动作对齐把手部姿态转换为末端轨迹并平滑；视觉对齐分割并去除人臂、搜索机器人基座、求解 IK，并做深度渲染；质量清洗在轨迹、帧和整段示范层面过滤样本。

路径 A 接受已有手部姿态标注的数据。路径 B 先用 WiLoR 逐帧重建，用 DynHaMR 做时序优化；长视频还通过 Qwen3.5 分割成带自然语言说明的独立子任务。得到手部姿态后，两路径进入相同流程，可以为 15 形态并行生成数据。

3.1 动作对齐

人手到平行夹爪。 每个检测到手的帧，根据 21 个关键点提取紧凑夹爪表示。虚拟指尖由食指尖和中指尖加权：

$$p_{vf} = 0.7p_{index} + 0.3p_{middle}. \quad (1)$$

TCP 是拇指尖与虚拟指尖中点，夹爪开口是二者距离：

$$p_{tcp} = \frac{p_{thumb} + p_{vf}}{2}, \quad w = \|p_{thumb} - p_{vf}\|. \quad (2)$$

方向由右手正交坐标系 $R = [x \ y \ z]$ 表示。抓取轴 z 沿拇指与虚拟指尖连线， $d = p_{vf} - p_{wrist}$ 为手腕到指尖方向。二者张成夹爪平面， y 为法向， x 为接近轴：

$$z = \frac{s(p_{thumb} - p_{vf})}{w}, \quad y = \frac{z \times d}{\|z \times d\|}, \quad x = y \times z. \quad (3)$$

右手 $s = +1$ 、左手 $s = -1$ ，使两只手具有一致抓取轴方向，映射到同一夹爪坐标定义。

时序平滑。 逐帧检测会产生高频噪声。位置和宽度使用 Savitzky-Golay 滤波，方向使用高斯加权 SLERP，在保留动作结构的同时平滑轨迹。

速度对齐。 人手通常比机器人遥操作快，训练按来源降低采样帧率：ANT、EgoDex 为原来的 60%（约慢 1.7 倍），EgoVerse 45%（约慢 2.2 倍），ViTRA 25%（约慢四倍）。这里保留作者给出的降速解释。

3.2 视觉对齐

目标是让同一场景的视频，从“人手操作”变成“机器人手臂操作”。

手臂分割。 SAM 3 为每帧生成具有时序一致性的手臂掩码。

去除人手。 ProPainter 根据掩码做时序一致的视频修复，重建人臂后的背景。

机器人基座搜索。 人手轨迹不带机器人基座，而机器人到机器人迁移有源基座可参考。我们必须寻找 $T_{base} = (t, R) \in SE(3)$ ，让目标形态能在运动学上实现重定向轨迹。

给定 N 个末端目标位姿，选代表性关键帧集合 $\mathcal{K}$ ，覆盖位置最大位移或姿态显著变化，优化 IK 可行比例：

$$T_{base}^* = \arg \max_{T_{base}} \frac{1}{|\mathcal{K}|} \sum_{k \in \mathcal{K}} \mathbf{1}[\text{IK}(T_{base}^{-1} T_k^{ee}) \text{ 可行}]. \quad (4)$$

候选基座在轨迹中心附近网格搜索，范围受机器人最大可达距离 r_{max} 约束。每个候选在所有关键帧求解 MuJoCo IK，选择可行率最高者。每种形态独立搜索，因为臂长关节配置不同。

IK 和渲染。 固定优化后的基座，逐帧求 IK，从原视频相机视角渲染机器人。

深度合成。 将机器人与修复背景按深度排序合成：

$$I_{final}(u, v) = \begin{cases} I_{robot}(u, v), & D_{robot}(u, v) < D_{scene}(u, v) \wedge M_{robot}(u, v) \neq 0, \\ I_{inpaint}(u, v), & \text{其他情况.} \end{cases} \quad (5)$$

场景深度来自深度传感器或单目估计。每个视频分别生成 Panda、UR5e、ARX-L5、xArm7、Sawyer、Kinova Gen3、IIWA、Jaco、FR3、UR10e、ViperX、WidowX、

3.3 三层质量清洗

L1：流程内部。 标记 IK 失败、自碰撞、异常动作、工作空间覆盖不足等帧。

L2：统计过滤。 移除极端动作、不连续突变，以及无效帧过多的轨迹。

L3：VLM 一致性。 审核合成视频中的机器人行为，是否与原始操作意图在语义上相容。

四组输入是 ANT（内部采集、带手部标注的抓取放置数据，7 小时）、EgoDex（732 小时）、ViTRA（249 小时）、EgoVerse（954 小时），合计约 1,940 小时。经过 15 形态生成和清洗，最终为 18,561 小时。

每个样本包含合成机器人视频帧、对应相机系末端动作、相机参数和文本指令。第一人称相机位置多样且未知，世界系动作需要逐视频标定，跨源动作空间容易不一致。相机系相对末端动作直接在观察者坐标系中表达位移，可以自然统一不同相机设置和机器人形态。

4. 如何评估泛化

既要知道合成数据改善哪些能力，也要知道哪些能力仍受域差异限制，就需要独立扰动。RoboTwin 2.0 的多因素同时随机化只给一个 OOD 总分，混合了视觉、空间、形态和语义变化。

我们扩展 11 个独立 RoboTwin 条件，支持相机系相对末端控制，并增加外部 EBench 的七个 Isaac Sim 精密桌面任务。EBench 头部相机更高，更接近人类第一人称视角。

【图 2：四维十二种评测设置】虚线框表示从原随机化中拆出的独立因素，实线框表示新增因素，灰框表示外部 EBench。

四维具体为：

- **视觉外观：** 背景纹理、光照、机器人颜色。前两者独立控制；颜色对所有机器人连杆随机改变色相，测试对未见外观的视觉不变性。
- **场景布局：** 桌高 ± 4 cm、干扰物、相机位置每轴最多偏移 5 cm。独立测量常见空间布置变化。
- **机器人形态：** 默认 Aloha-Agilex 换成 UR5-WSG、ARX-X5、Franka Panda，IK 对齐初始末端，零样本测试，不做目标形态专用微调。

- **任务语义：**50 项任务使用该任务训练未见的物体实例；另有 505 条口语化改写指令，测试新外观及语言表达变化。

5. 实验

5.1 实验设置

架构采用 Qwen3.5-4B 主干和 DiT 动作头，在相机系相对末端表示中预测 32 步动作块，使用八次扩散训练计算。附录进一步明确，推理采用四步欧拉积分。

所有预训练配置相同：八 GPU，每 GPU 批量 12，学习率从 10^{-5} 余弦衰减到 10^{-6} ，bf16，200K 步。每种配置处理相同约 19.2M 帧，数据集大小不同不会造成训练样本数量不公平。微调加载预训练权重，用 ColorJitter，训练 50K 步。

比较四方案：仅机器人数据，来自 DROID、AgibotWorld 和 InternData，约 6,565 小时；以及 Ego2Robot 合成（简称 Ego2R）与机器人按 1:3、3:1、1:1 混合。比例均为 **Ego2R : Robot**。

各模型在 RoboTwin Clean 的 50 任务、每任务 50 示范上微调，每个扰动条件下每任务评测 50 次。EBench 单独微调。真实实验用 ARX ACone，五项长时序任务。

5.2 主要结果

表 1：成功率 %。 Visual、Scene、Embodiment、Task 是 RoboTwin 对应维度平均，EBench 为外部基准平均。

预训练	Clean	随机化	视觉	场景	形态	任务	EBench
仅机器人	62.2	50.9	61.4	52.9	23.8	46.2	39.6
Ego2R+Robot 1:3	61.4	51.0	61.2	52.5	21.9	49.5	47.4
Ego2R+Robot 3:1	64.1	49.2	62.7	54.3	28.2	51.6	51.7
Ego2R+Robot 1:1	68.1	53.5	67.3	56.9	27.2	54.1	49.8

相对仅机器人，1:3 的变化依次为 -0.8、+0.1、-0.2、-0.4、-1.9、+3.3、+7.8 点；3:1 为 +1.9、-1.7、+1.3、+1.4、+4.4、+5.4、+12.1；1:1 为 +5.9、+2.6、+5.9、+4.0、+3.4、+7.9、+10.2。

表 2：独立扰动成功率 %。

预训练	背景	光照	机器人颜色	桌高	杂物	相机	ARX	UR5	Franka	新物体	改写语言
仅机器人	66.6	58.2	59.4	60.1	48.3	50.4	44.1	20.2	7.0	29.3	63.1
1:3	65.0	58.3	60.3	58.6	49.3	49.6	43.7	17.6	4.5	36.8	62.2
3:1	65.5	60.9	61.8	62.0	49.2	51.6	47.6	31.4	5.6	40.0	63.1
1:1	70.3	65.8	65.8	62.4	52.0	56.3	51.2	25.0	5.3	39.6	68.5

这些结果带来以下结论。

联合训练提高 OOD 泛化。 1:1 在七列中五列最好，Randomized 为 53.5，比仅机器人高 2.6 点，同时 Clean 达 68.1。1:3 总体收益较小，3:1、1:1 更明显，但不是所有测试都提高，例如 3:1 的组合随机化低于基线。

视觉外观收益最大。 1:1 的背景、光照、颜色分别约提高四、八、六点。第一人称场景多样性帮助背景光照，多形态渲染帮助机器人外观不变性。

场景布局有中等改善。 相机位置扰动约提高六点，与第一人称视频中自然变化的头部姿态和视角有关。

多形态数据帮助迁移。 ARX 从 44 到 51（1:1），UR5 在 3:1 达约 31，预训练见到 15 种形态直接有益。但 Franka 仍低于约 7%，反映它与微调形态的较大运动学差异。

任务语义持续改善。 新物体从 29 到 40，3:1 约提高 11 点，来自人类视频中的丰富物体交互；改写指令在 1:1 达约 69，受益于更广语言表达。

EBench 的较高视角进一步验证收益。 3:1 最好，为 51.7，比机器人基线高 12.1。当目标相机视角更接近第一人称来源时，联合训练收益可能更明显。

5.3 消融

为了隔离流程的作用，这组实验的预训练只用人类来源数据，不含机器人数据，随后仍在 RoboTwin Clean 微调。

【图 3：流程价值与形态数量】原始第一人称数据在 RoboTwin Randomized 仅 28.1%；经过合成、只用一种机器人形态为 31.7%，提高 3.6 点，证明动作和视觉对齐

有效。

机器人形态从一增加到十五，表现逐步由 31.7 到 33.5。再混入原始第一人称视频，达到 37.3%。原始人手可视作第十六种“形态”，具有稍不同的外观和动作分布，进一步丰富预训练。

5.4 真实机器人实验

在 ARX ACone 上测试水果放篮子、积木放抽屉、折毛巾、扫垃圾、插螺钉五项长任务。每任务采集 20 遥操作示范，另录约每场景七分钟的人手自由操作 Ego Play，再由流程转成 ACone 专属合成示范。

比较：Robot-only 用仅机器人预训练，在遥操作示范上微调；Mix 用 1:1 联合预训练，在相同示范上微调；Mix + Ego2R Play 再把遥操作和合成自由操作按 1:1 混合微调。图中还展示 Scratch 从头训练对照。

【图 4：真实平台结果】Mix + Ego2R Play 五项都最好，放积木相对 Robot-only 约提高 14 点，插螺钉约提高 13 点。仅混合预训练已经改善表现，Ego Play 再持续提高。图中精确柱高未全部印数字，不在译文中臆造数值。

【图 5：真实执行序列】展示五任务在 ACone 上的关键帧。

这些结果表明，随手记录的第一人称操作视频，通过合成流程也能变成有效训练信号。

计分说明：正文和图使用“成功率”表述；附录明确采用子步骤部分计分、每任务满分 100。读取图中数值时应结合这个协议，不能一概视为完整任务成功比例。

6. 局限

首先，人手姿态重定向到平行夹爪会丢失细粒度手指运动。扩展到多指灵巧手，可能迁移更多技能。

其次，视觉对齐依赖视频修复和深度合成，在严重遮挡或复杂光照下可能产生伪影。提高渲染保真度，例如使用生成模型，可能进一步缩小视觉域差异。

最后，评测主要局限于 RoboTwin 2.0 的任务范围，扩到更多任务和形态会增强结论的一般性。

7. 结论

Ego2Robot 把第一人称人手操作视频大规模转换为 15 种机器人形态的数据。独立扰动评测显示，合成与机器人数据互补，视觉、形态和语义变化下收益最明显。真实机器人上，合成数据加少量遥操作示范可以实现有效多任务部署。作者希望推动利用海量人类操作视频，扩展机器人学习。

附录 A：合成流程的具体实现

A.1 无标注视频的手部姿态估计（路径 B）

逐帧重建。 WiLoR 检测人手并回归 MANO 参数 (θ, β, t) ，每帧得到 21 关键点和手部网格。用 SAM 3 的手部掩码过滤：如果超过 80% 的投影关键点落在掩码外，该帧丢弃。

跨帧关联。 WiLoR 的 YOLO 检测器给出框及初始左右标签。选择左右手检测分数之和最高的帧作为种子，双向传播。每帧的新检测分配给上一帧图像空间手腕位置最近的手，使用欧氏距离；多个检测竞争同一只手时保留最高分。

关联后去除手腕三维速度超过 $\max(4 \times \text{median velocity}, 0.003 \text{ m/frame})$ 的跳变帧，认为其属于误检测。

时序优化。 DynHaMR 在完整序列上联合优化 MANO 姿态和形状：

$$\mathcal{L}_{dyn} = \mathcal{L}_{data} + \lambda_{smooth} \mathcal{L}_{smooth} + \lambda_{bio} \mathcal{L}_{bio}. \quad (6)$$

数据项约束与 WiLoR 一致，平滑项惩罚手腕位置与手指角度加速度，生物力学项约束关节范围。重建手部距离相机的深度限制在 0.05-0.4 m。

缺失处理。 连续缺失超过十帧时，用机器人初始关节配置填补，在边界平滑过渡。过渡长度：

$$n = \max(5, \min(90, \lceil 0.6n_{pos} + 0.4n_{rot} \rceil)), \quad n_{pos} = \frac{\Delta p}{3.25 \text{ mm}}, \quad n_{rot} = \frac{\Delta \theta}{1.08^\circ}.$$

这对应在固定过渡速度下完成位移/转角需要的帧数。缺失不超过十帧时，位置线性插值，方向 SLERP。

A.2 子任务分割（路径 B）

长连续视频先每 60 秒切段，将片段交给 Qwen3.5，提示内容为：

你正在观看第一人称操作视频（时长 {duration} 秒）。
任务：{task_desc}。
按完整任务目标分割视频，每个子任务应是独立且完整的目标。
为每个子任务写一条简短英文动作指令，长度 5-12 个词。
只输出 JSON 数组：
[{"description": ..., "start_time": ..., "end_time": ...}, ...]

返回的时间边界和描述作为训练指令。这里只翻译提示含义，JSON 字段保持代码形式。

A.3 动作对齐细节

左右手符号直接由身份确定。构造法向的手腕指尖向量直接取 MANO 关键点。

退化方向。 夹爪宽度小于 0.01 m，拇指与虚拟指尖几乎重合，姿态会退化，此时沿用最近有效姿态。 z 与 d 近乎平行、叉积约为零时，同样处理。

速度过滤。 位置逐帧位移 $v_t = \|p_t - p_{t-1}\|$ 的阈值为：

$$\tau_t = \max(5 \cdot \text{median}(\{v_s\}_s), 0.9/\text{fps}). \quad (7)$$

旋转使用类似阈值，下限为 10.0/fps rad/frame。超阈值帧通过相邻帧插值替换，重复两轮。

平滑参数。 位置和夹爪开口的 Savitzky-Golay 窗口是 $\min(21, n)$ ，多项式阶数是 $\min(3, \text{window} - 1)$ 。方向用高斯加权 SLERP， $\sigma = 10$ 帧，核大小 21。插值前做四元数半球修正：若 $q_t \cdot q_{t-1} < 0$ ，把 q_t 取负，避免等价四元数符号翻转带来的跳变。

A.4 视觉对齐细节

分割。 SAM 3 使用文本提示 **person**，以中间帧为时间传播锚点。长视频按 400 帧处理，相邻段重叠 50 帧，重叠掩码按位或合并。后处理包括：不超过三帧的缺失，用相邻掩码插值；面积低于局部中位数一半的帧，用最近有效掩码替换，局部窗口 11；用 5×5 椭圆核做形态学闭运算。

修复。 ProPainter 使用 fp16，参数 **neighbor_length=10**、**ref_stride=10**、**subvideo_length=80**、**mask_dilation=4**，RAFT 迭代 20 次。

基座候选。 以可达距离 r 缩放，在相机坐标系生成：

变量	候选
左右偏移	$r \times \{0.3, 0.4, 0.5, 0.6, 0.8, 1.0, 1.2\}$; 左右臂符号相反
前后偏移	$r \times \{-0.1, 0.0, 0.1, 0.3, 0.5, 0.7, 0.9\}$
上下偏移	$r \times \{0.4, 0.2, 0.0, -0.2, -0.4\}$
俯仰	30°、45°、60°
偏航	-45°、-20°、0°、20°、45°
滚转	-15°、0°、15°

离相机小于 0.20 m、轨迹点距基座超过 $0.9r$ 、或小于 0.08 m 的候选被排除。剩余候选评分：

$$S = FR(T_{base}) - 5.0|\bar{\rho} - 0.65|. \quad (8)$$

FR 是最多 20 个关键帧上的 IK 可行率，使用 `mink`、`quadprog` 后端、100 次迭代、 10^{-5} 阈值。 $\bar{\rho}$ 是末端到基座平均距离除以 r ：

$$\bar{\rho} = \frac{1}{|\mathcal{K}|} \sum_{k \in \mathcal{K}} \frac{\|T_{base}^{-1} p_k^{ee}\|}{r}.$$

惩罚最小时，机器人在最大可达距离的约 65% 处操作，以保留运动学余量。每臂独立保留前五候选，再联合检查全部 25 个左右组合，选择最终基座。

深度合成的实际规则。 正文给了统一深度排序，但实现分机械臂主体与夹爪。通过 `MuJoCo` 每几何体分割掩码区分：机械臂主体总是叠到修复场景，因为假设它在相机和工作空间之间，不会被场景物体遮挡；夹爪逐像素比较深度。若场景更近、且像素不在膨胀人手掩码中，则隐藏夹爪。

场景深度由 `Depth Anything V3` 估计，机器人由 `MuJoCo` 渲染。人手掩码用 5×5 核膨胀一次，防止显露原手臂轮廓处的修复边缘。

$$I_{out}(u, v) = \begin{cases} I_{sim}(u, v), & (u, v) \in M_{arm} \cup M_{gripper_vis}, \\ I_{inpaint}(u, v), & \text{其他情况}, \end{cases} \quad (9)$$

其中 $M_{gripper_vis}$ 是从夹爪掩码中，减去“场景深度小于机器人深度且不在人手掩码内”的像素。

A.5 清洗条件

L1 中一帧有效须同时满足：检测到人手；IK 跟踪误差小于 0.05 m；渲染机器人可见，像素数大于零；MuJoCo 接触检查没有自碰撞。若双臂交叉接触数大于一，或机器人掩码超过图像面积 70%，也标无效。

稳定性侵蚀。 两段无效帧之间，如果有效连续段短于 $\lfloor 0.3 \times \text{fps} \rfloor$ 帧，也整段标无效。

L2 做两项事后统计检查。第一，对每个数据集、每个动作维，排除此前无效帧后计算 $Q1/Q99$ ，区间 $[Q1 - 3(Q99 - Q1), Q99 + 3(Q99 - Q1)]$ 外标异常。第二，在状态动作轨迹计算残差、加速度和 jerk，根据该数据集逐维分布设阈值，超阈值标异常。两过滤后，无效帧比例超过 60% 的示范整段丢弃。

L3 用 Qwen3.5，以 4 fps 抽取合成视频，加子任务描述进行审核。提示含义为：

判断操作视频是否符合文字描述。
这是机器人操作数据集，“手”指机器人夹爪/末端执行器。
不少任务用假物体、玩具或仿真物体代替真实物体，这属于正常情况。
任务描述：{description}。
判断机器人动作是否符合任务。
标记重大不匹配：动作类型错误、物体类别错误、目标位置错误、执行失败。
容忍玩具、轻微外观变化、小的空间偏差和不同抓取方式。
用 JSON 回答：
{
 "is_consistent": true/false,
 "confidence": 0.0-1.0,
 "reasoning": "..."}
}

判断不一致的示范被丢弃。

A.6 颜色随机化

每个渲染机器人采用可复现的 HSV 随机颜色： $H \sim U(0, 1)$ ， $S \sim U(0.3, 1)$ ， $V \sim U(0.4, 1)$ ，同一机器人所有连杆统一使用该颜色。

A.7 支持的机器人

表 3：形态、自由度、夹爪开口和可达距离。 可达距离按论文定义保留。

机器人	自由度	夹爪 mm	可达距离 m
Panda	7	0-80	1.272
Kinova Gen3	7	0-85	1.337
IIWA	7	0-85	1.411
Sawyer	7	14-79	1.420

机器人	自由度	夹爪 mm	可达距离 m
FR3	7	0-80	1.272
xArm7	7	0-85	1.290
UR5e	6	0-85	1.236
UR10e	6	0-85	1.627
Jaco	6	0-125	1.200
ViperX	6	15-87	0.911
WidowX	6	11-55	0.787
ARX-L5	6	0-88	0.855
Piper	6	0-70	0.883
YAM	6	4-75	0.866
Aloha-Agilex	6	7-102	0.853

【图 6】15 种机器人的三维模型。

附录 B：评测实现细节

B.1 扰动参数

原始 Randomized 同时替换背景纹理、随机光照、桌高和杂物。我们拆开这些因素，再加入相机偏移、机器人颜色、改写指令和新物体。

背景从纹理库随机替换桌面和地面；光照随机位置和强度；所有机器人连杆统一施加 $[0^{\circ}, 360^{\circ})$ 色相变化。桌高 $\pm 4\text{ cm}$ ；杂物三至五个，随机姿态；头部相机每轴最多偏移 5 cm。

语义包括人工与大模型生成的 505 条口语指令。未见物体测试使用 50 个新任务，同类别但外观几何不同，分七组：

任务组	数量	具体组合
移到垫子	10	瓶/杯/碗到垫子；杯/瓶/马克杯/苹果/印章/药瓶/碗到锅

任务组	数量	具体组合
或锅		
放篮子	11	肥皂、马克杯、香水、茶盒、玩具车、苹果、瓶、杯、咖啡盒、酱料罐、汉堡
放支架	4	杯、马克杯、瓶、苹果
放秤上	3	瓶、杯、马克杯
放柜子	3	苹果、印章、碗
双臂 A 放到 B	12	cup-left-bottle、mug-right-apple、bottle-left-cup、seal-right-mug、mug-left-cup、apple-left-mug、bottle-right-apple、seal-left-cup、mug-left-bottle、apple-right-cup、cup-right-seal、bottle-left-apple
移开	7	杯、瓶、苹果、马克杯、印章、碗、药瓶

双臂组合保留英文代码中的 left/right，避免把任务名里的臂侧信息误解成额外空间关系。

默认 Aloha-Agilex 用一个双臂 URDF。替代形态用两个独立单臂 URDF，在工作空间中心两侧对称放置。臂基座间距 ARX-X5 为 0.6 m，UR5-WSG 为 0.59 m，Franka 为 0.65 m。IK 对齐初始末端，头部加两腕共三个相机外参跨形态对齐。

B.2 五十项训练评测任务

下面保留任务代码并给出中文名称，方便对照代码和逐任务表。

代码	中文
adjust_bottle	调整瓶子
beat_block_hammer	用锤敲积木
blocks_ranking_rgb	按 RGB 颜色排列积木
blocks_ranking_size	按大小排列积木
click_alarmclock	按闹钟
click_bell	按铃

代码	中文
dump_bin_bigbin	小桶内容倒入大桶
grab_roller	抓滚筒
handover_block	交接积木
handover_mic	交接麦克风
hanging_mug	挂马克杯
lift_pot	抬锅
move_can_pot	罐子移到锅
move_pillbottle_pad	药瓶移到垫子
move_playingcard_away	移开扑克牌
move_stapler_pad	订书机移到垫子
open_laptop	打开笔记本电脑
open_microwave	打开微波炉
pick_diverse_bottles	抓取多样瓶子
pick_dual_bottles	双臂抓瓶
place_a2b_left	左侧 A 到 B 放置
place_a2b_right	右侧 A 到 B 放置
place_bread_basket	面包放篮子
place_bread_skillet	面包放煎锅
place_burger_fries	汉堡与薯条放置
place_can_basket	罐子放篮子
place_cans_plasticbox	多个罐子放塑料盒
place_container_plate	容器放盘子
place_dual_shoes	双臂放鞋
place_empty_cup	放空杯
place_fan	放风扇
place_mouse_pad	鼠标放垫子
place_object_basket	物体放篮子

代码	中文
place_object_scale	物体放秤
place_object_stand	物体放支架
place_phone_stand	手机放支架
place_shoe	放鞋
press_stapler	按订书机
put_bottles_dustbin	瓶子放垃圾桶
put_object_cabinet	物体放柜子
rotate_qrcode	旋转二维码
scan_object	扫描物体
shake_bottle	摇瓶子
shake_bottle_horizontally	水平摇瓶子
stack_blocks_three	叠三积木
stack_blocks_two	叠两积木
stack_bowls_three	叠三碗
stack_bowls_two	叠两碗
stamp_seal	盖章
turn_switch	拨开关

任务步数上限从 400 到 1700，多数为 400；开微波炉 1500，排列积木与叠三积木 1200，叠碗 900-1200，挂杯 900，叠两积木、交接积木、罐子入塑料盒 800，瓶子入垃圾桶 1700。新任务默认 1000。

B.3 统计协议

每任务 50 次，二值成功。Visual 为背景、光照、机器人颜色平均；Scene 为桌高、杂物、相机平均；Embodiment 为 ARX、UR5、Franka 平均；Task 为新物体、改写语言平均。

B.4 EBench 桌面任务

七项是收集咖啡豆、翻杯并收集饼干、把框靠在笔筒上、安装齿轮、插销入孔、玻璃杯放玻璃盒、拧紧螺母。相机比 RoboTwin 高，接近第一人称视角。

附录 C：模型细节

Qwen3.5-4B 输入每个时间点两至三张 RGB 视图和结构文本，得到联合视觉语言隐藏序列 $H \in \mathbb{R}^{L \times d}$ 。相机内参 $K \in \mathbb{R}^{3 \times 3}$ 和外参 $T_{wc} \in SE(3)$ 通过 mRoPE 位置编码注入视觉特征，帮助理解相机与场景的三维关系。

上下文生成器使用八个可学习 query，把 H 压缩成条件特征 C ；DiT 通过交叉注意力关注 C ，用流匹配生成 32 步动作块。每次前向八次训练采样、推理四步。

C.1 结构化提示

```
embodiment: {type}_{model}
instruction: {task_description}
```

形态字段同时表示来源和机器人型号，例如 **robot_aloha** 为真实机器人，**h2r_arx** 为 ARX 合成，**human_ego** 为原始人类数据。训练以 15% 概率把形态字段改成 **None**，指令从不丢弃。

C.2 相机系相对末端动作

每步七维：三维位移 Δp 、三维旋转向量 $\Delta \omega$ 、一维夹爪。末端到相机变换为 $T_{ce} = T_{wc}^{-1} T_{we}$ ，旋转部分为 R_{ce} ，增量变换：

$$\Delta p^{cc} = R_{ce} \Delta p^{ee}, \quad \Delta R^{cc} = R_{ce} \Delta R^{ee} R_{ce}^\top. \quad (10)$$

作者表示，这自然统一不同相机和形态的数据，不需要额外显式外参标定。

原文表述提示：这一段文字称“基座系增量”，公式却用末端系 ee 上标；正文又强调相机参数作为样本内容，附录说“不需显式标定”。理解时可以区分“不额外逐视频标定世界坐标系”和“完全不需要任何相机几何信息”。译文保留原公式及原文主张，不擅自将坐标定义改成一致版本。

C.3 流匹配

令干净动作为 a_0 ，噪声为 $\epsilon \sim \mathcal{N}(0, I)$:

$$a_t = (1 - t)a_0 + t\epsilon, \quad t \in [0, 1]. \quad (11)$$

$$\mathcal{L} = \mathbb{E}_{t, a_0, \epsilon} \|v_\theta(a_t, t, c) - (\epsilon - a_0)\|^2. \quad (12)$$

c 为视觉语言条件。推理用四步欧拉，步长 1/4。

这里从干净动作到噪声定义路径，目标速度是“噪声减动作”；Qwen-RobotManip 从噪声到动作定义路径，目标速度相反。两篇采用相反时间方向，不能直接混用符号。

附录 D：训练细节

D.1 预训练

八张 A100，每 GPU 批量 12；主干学习率 $10^{-5} \rightarrow 10^{-6}$ 余弦衰减，预热 5K 步；动作头学习率十倍，为 $10^{-4} \rightarrow 10^{-5}$ 。AdamW, $\beta_1 = 0.9, \beta_2 = 0.95$ ；bf16、ZeRO-1；200K 步，约 19.2M 帧；每次前向八次扩散训练采样；不做图像增强。

D.2 数据与比例

机器人数据：DROID 约 511 小时，Franka 上丰富物体场景的真实遥操作；AgibotWorld 约 2,404 小时，180 项人形操作任务；InternData 约 3,650 小时，Franka、人形、ALOHA 仿真。合计约 6,565 小时。

第一人称数据：ANT 7、EgoDex 732、ViTRA 249、EgoVerse 954 小时，共约 1,940。15 形态合成清洗后为 18,561。

1:3、3:1、1:1 是通过每来源采样权重实现的训练混合比例。所有配置总训练帧数一样。

【图 7：数据组成饼图】机器人总量约 6,565 小时，Ego2R 总量约 18,561；扇区表示来源的训练采样权重，不是简单的原始时长占比。

D.3 微调

加载预训练权重，八 A100，每 GPU 批量 12，主干和动作头学习率、预热、优化器、bf16 同预训练；改为 ZeRO-2，加入 ColorJitter，每前向八次扩散训练采样。

目标	数据	步数	动作块与重规划
RoboTwin Clean	50 任务×50 示范, 2,500 段	50K	块长 20, 每 16 步重规划
EBench Table Top	7 任务×400 示范, 2,800 段	50K	块长 32
真实机器人	遥操作与 Ego2R 1:1	50K	块长 32

D.4 消融配置

图 3 全部只用人类来源预训练，不混机器人，然后在 RoboTwin Clean 微调：

配置	时长	形态
原始第一人称	约 1,940 小时	已按流程质量过滤，不渲染机器人
Ego2R 一形态	约 1,237	ARX-L5
Ego2R 五形态	约 6,187	Aloha-Agilex、ARX-L5、FR3、ViperX、xArm7
Ego2R 十形态	约 12,374	Aloha-Agilex、ARX-L5、FR3、IIWA、Jaco、Piper、UR5e、ViperX、YAM、xArm7
Ego2R 十五形态	约 18,561	全部十五
十五形态 + 原始第一人称	约 20,501	合成加原始人类数据

附录 E：真实机器人实验细节

E.1 平台与任务

ARX ACone 双臂，每臂六自由度、平行夹爪，头部加两腕 RGB 相机，15 Hz 控制，每 32 步重规划。

- 放水果：三步，依次把三个水果放篮子。
- 放积木：四步，开抽屉、放两块积木、关抽屉。
- 折毛巾：两次连续折叠。
- 扫垃圾：四步，拿扫帚、扫、倒垃圾、放回扫帚。
- 插螺钉：四步，对两颗螺钉分别进行双臂交接和插入。

E.2 数据

每任务 20 遥操作示范，共 100；五场景约 35 分钟 Ego Play。路径 B 的 WiLoR、DynHaMR、Qwen3.5 与 Ego2R 生成 675 段 ACone 合成示范。微调中遥操作与合成数据按 1:1 采样。

E.3 可视化

【图 8：自由操作视频到机器人合成】上排原始第一人称人手视频，下排 ACone 叠到修复背景后的对应帧。

E.4 计分

每任务 20 次，采用子步骤部分计分，任务满分 100。

表 4：每一步分值。

任务	第一步	第二步	第三步	第四步
放水果	33.3	33.3	33.3	—
放积木	25	25	25	25
折毛巾	50	50	—	—
扫垃圾	25	25	25	25
插螺钉	25	25	25	25

附录 F：补充实验

F.1 与 $\pi 0.5$ 比较

$\pi 0.5$ 在相同 RoboTwin 末端设置中评估，使用 OpenPI 和相机系相对末端动作。它的主干及预训练数据与本文不同。

【图 9】沿背景、光照、颜色、桌高、杂物、相机、ARX、UR5、Franka、新任务和改写语言，比较 $\pi 0.5$ 、仅机器人和 1:1 合成混合模型。合成混合在几乎所有设置优于仅机器人，但 Franka 不在此收益模式中。

F.2 逐任务结果

表 5：RoboTwin 各任务成功率 %。 每格为 **Clean / Randomized**。任务中文对照见 B.2，混合比例仍是 Ego2R : Robot。

任务	$\pi 0.5$	仅机器人	1:3	3:1	1:1
adjust_bottle	62 / 18	94 / 77	92 / 79	100 / 72	89 / 91
beat_block_hammer	48 / 16	63 / 27	64 / 56	57 / 18	65 / 71
blocks_ranking_rgb	74 / 16	56 / 60	64 / 63	49 / 43	78 / 60
blocks_ranking_size	32 / 0	30 / 22	46 / 21	43 / 7	52 / 16
click_alarmclock	44 / 56	96 / 93	100 / 87	100 / 85	100 / 100
click_bell	32 / 40	100 / 95	100 / 94	100 / 93	100 / 100
dump_bin_bigbin	72 / 70	54 / 73	72 / 69	81 / 76	86 / 72
grab_roller	94 / 46	98 / 71	68 / 48	91 / 64	89 / 63
handover_block	16 / 0	5 / 2	18 / 4	39 / 9	36 / 9
handover_mic	26 / 4	69 / 13	86 / 34	83 / 17	97 / 23
hanging_mug	10 / 4	14 / 16	14 / 9	12 / 9	10 / 10
lift_pot	8 / 2	93 / 28	84 / 14	95 / 44	93 / 44
move_can_pot	28 / 0	47 / 50	30 / 40	42 / 85	47 / 65
move_pillbottle_pad	60 / 44	63 / 60	68 / 69	41 / 67	74 / 82
move_playingcard_away	90 / 52	74 / 58	88 / 92	88 / 42	92 / 63
move_stapler_pad	22 / 6	23 / 19	34 / 21	30 / 13	43 / 31
open_laptop	68 / 20	77 / 61	74 / 56	64 / 46	75 / 58
open_microwave	26 / 8	77 / 59	42 / 29	37 / 32	50 / 25
pick_diverse_bottles	56 / 18	60 / 37	58 / 53	71 / 50	70 / 50
pick_dual_bottles	82 / 14	91 / 59	80 / 77	83 / 55	97 / 54
place_a2b_left	60 / 10	40 / 55	58 / 42	54 / 48	73 / 44
place_a2b_right	58 / 14	42 / 49	52 / 41	53 / 51	64 / 53

任务	π 0.5	仅机器人	1:3	3:1	1:1
place_bread_basket	68 / 44	75 / 55	72 / 64	76 / 59	79 / 62
place_bread_skillet	86 / 46	76 / 41	76 / 50	80 / 61	87 / 53
place_burger_fries	90 / 78	96 / 83	98 / 81	97 / 88	96 / 88
place_can_basket	40 / 0	49 / 25	38 / 9	34 / 15	34 / 16
place_cans_plasticbox	94 / 74	90 / 68	54 / 68	97 / 59	70 / 59
place_container_plate	96 / 58	86 / 76	92 / 79	93 / 73	93 / 81
place_dual_shoes	54 / 12	50 / 30	34 / 27	35 / 17	35 / 19
place_empty_cup	74 / 56	73 / 74	86 / 83	88 / 78	88 / 66
place_fan	36 / 30	48 / 54	48 / 24	41 / 50	39 / 46
place_mouse_pad	18 / 0	41 / 34	22 / 36	30 / 25	29 / 33
place_object_basket	24 / 4	65 / 50	76 / 28	77 / 51	69 / 48
place_object_scale	58 / 44	38 / 46	40 / 33	52 / 45	40 / 47
place_object_stand	94 / 40	70 / 75	80 / 77	87 / 71	82 / 82
place_phone_stand	40 / 4	65 / 49	48 / 63	70 / 61	75 / 45
place_shoe	64 / 24	84 / 84	78 / 84	63 / 58	75 / 76
press_stapler	42 / 32	86 / 71	82 / 62	76 / 70	83 / 62
put_bottles_dustbin	14 / 2	25 / 20	42 / 32	41 / 19	50 / 39
put_object_cabinet	22 / 0	41 / 20	30 / 19	39 / 36	43 / 29
rotate_qrcode	50 / 2	31 / 17	54 / 16	54 / 36	69 / 37
scan_object	62 / 38	62 / 37	66 / 46	66 / 46	56 / 33
shake_bottle	96 / 72	91 / 75	88 / 89	99 / 75	96 / 87
shake_bottle_horizontally	98 / 74	98 / 81	84 / 87	99 / 84	97 / 92
stack_blocks_three	68 / 16	14 / 23	14 / 28	10 / 13	28 / 23
stack_blocks_two	80 / 56	75 / 70	82 / 75	77 / 56	95 / 61
stack_bowls_three	38 / 36	50 / 41	40 / 43	48 / 50	47 / 45
stack_bowls_two	82 / 44	76 / 78	66 / 73	73 / 67	72 / 72
stamp_seal	32 / 2	35 / 42	46 / 30	34 / 30	44 / 42

任务	$\pi 0.5$	仅机器人	1:3	3:1	1:1
turn_switch	56 / 40	55 / 42	40 / 42	53 / 41	50 / 48
平均	54.9 / 27.7	62.2 / 50.9	61.4 / 51.0	64.1 / 49.2	68.1 / 53.5

参考文献（原文保留，便于检索）

[1] B. Zitkovich, T. Yu, S. Xu, P. Xu, T. Xiao, F. Xia, J. Wu, P. Wohlhart, S. Welker, A. Wahid, et al. Rt-2: Vision-language-action models transfer web knowledge to robotic control. In Conference on Robot Learning, pages 2165–2183. PMLR, 2023.

[2] M. J. Kim, K. Pertsch, S. Karamcheti, T. Xiao, A. Balakrishna, S. Nair, R. Rafailov, E. Foster, G. Lam, P. Sanketi, et al. Openvla: An open-source vision-language-action model. arXiv preprint arXiv:2406.09246, 2024.

[3] K. Black, N. Brown, D. Driess, A. Esmail, M. Equi, C. Finn, N. Fusai, L. Groom, K. Hausman, B. Ichter, et al. pi 0: A vision-language-action flow model for general robot control. arXiv preprint arXiv:2410.24164, 2024.

[4] P. Intelligence, K. Black, N. Brown, J. Darpinian, K. Dhabalia, D. Driess, A. Esmail, M. Equi, C. Finn, N. Fusai, et al. pi {0.5}: a vision-language-action model with open-world general-ization. arXiv preprint arXiv:2504.16054, 2025.

[5] J. Bjorck, F. Castañeda, N. Cherniadev, X. Da, R. Ding, L. Fan, Y. Fang, D. Fox, F. Hu, S. Huang, et al. Gr00t n1: An open foundation model for generalist humanoid robots. arXiv preprint arXiv:2503.14734, 2025.

[6] A. O’Neill, A. Rehman, A. Maddukuri, A. Gupta, A. Padalkar, A. Lee, A. Pooley, A. Gupta, A. Mandlekar, A. Jain, et al. Open x-embodiment: Robotic learning datasets and rt-x models: Open x-embodiment collaboration 0. In 2024 IEEE International Conference on Robotics and Automation (ICRA), pages 6892–6903. IEEE, 2024.

[7] A. Khazatsky, K. Pertsch, S. Nair, A. Balakrishna, S. Dasari, S. Karamcheti, S. Nasiriany, M. K. Srirama, L. Y. Chen, K. Ellis, et al. Droid: A large-scale in-the-wild robot manipulation dataset. arXiv preprint arXiv:2403.12945, 2024.

- [8] Q. Bu, J. Cai, L. Chen, X. Cui, Y. Ding, S. Feng, S. Gao, X. He, X. Hu, X. Huang, et al. Agibot world colosseum: A large-scale manipulation platform for scalable and intelligent embodied systems. arXiv preprint arXiv:2503.06669, 2025.
- [9] C. Chi, Z. Xu, C. Pan, E. Cousineau, B. Burchfiel, S. Feng, R. Tedrake, and S. Song. Universal manipulation interface: In-the-wild robot teaching without in-the-wild robots. arXiv preprint arXiv:2402.10329, 2024.
- [10] T. Z. Zhao, V. Kumar, S. Levine, and C. Finn. Learning fine-grained bimanual manipulation with low-cost hardware. arXiv preprint arXiv:2304.13705, 2023.
- [11] P. Wu, Y. Shentu, Z. Yi, X. Lin, and P. Abbeel. Gello: A general, low-cost, and intuitive teleoperation framework for robot manipulators. In 2024 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), pages 12156–12163. IEEE, 2024.
- [12] R. Hoque, P. Huang, D. J. Yoon, M. Sivapurapu, and J. Zhang. Egodex: Learning dexterous manipulation from large-scale egocentric video. arXiv preprint arXiv:2505.11709, 2025.
- [13] R. Punamiya, S. Kareer, Z. Liu, J. Citron, R.-Z. Qiu, X. Cai, A. Gavryushin, J. Chen, D. Li-conti, L. Y. Zhu, et al. Egoverse: An egocentric human dataset for robot learning from around the world. arXiv preprint arXiv:2604.07607, 2026.
- [14] M. Lepert, J. Fang, and J. Bohg. Phantom: Training robots without robots using only human videos. In Conference on Robot Learning, pages 4545–4565. PMLR, 2025.
- [15] S. Kareer, D. Patel, R. Punamiya, P. Mathur, S. Cheng, C. Wang, J. Hoffman, and D. Xu. Egomimic: Scaling imitation learning via egocentric video. In 2025 IEEE International Conference on Robotics and Automation (ICRA), pages 13226–13233. IEEE, 2025.
- [16] T. Chen, Z. Chen, B. Chen, Z. Cai, Y. Liu, Z. Li, Q. Liang, X. Lin, Y. Ge, Z. Gu, et al. Robotwin 2.0: A scalable data generator and benchmark with strong domain randomization for robust bimanual robotic manipulation. arXiv preprint arXiv:2506.18088, 2025.
- [17] N. M. M. Shafiullah, A. Rai, H. Etukuru, Y. Liu, I. Misra, S. Chintala, and L. Pinto. On bringing robots home. arXiv preprint arXiv:2311.16098, 2023.

[18] L. Pei, H. Yuzhe, L. Wanlin, X. Chenxi, and J. Ziyuan. Dexmove: Learning tactile-guided non-prehensile manipulation with dexterous hands. In The Fourteenth International Conference on Learning Representations, 2026. URL <https://openreview.net/forum?id=dT3ZciXvNX>.

[19] S. Nair, A. Rajeswaran, V. Kumar, C. Finn, and A. Gupta. R3m: A universal visual representation for robot manipulation. arXiv preprint arXiv:2203.12601, 2022.

[20] I. Radosavovic, T. Xiao, S. James, P. Abbeel, J. Malik, and T. Darrell. Real-world robot learning with masked visual pre-training. In Conference on Robot Learning, pages 416–426. PMLR, 2023.

[21] Y. J. Ma, S. Sodhani, D. Jayaraman, O. Bastani, V. Kumar, and A. Zhang. Vip: Towards universal visual reward and representation via value-implicit pre-training. arXiv preprint arXiv:2210.00030, 2022.

[22] A. S. Chen, S. Nair, and C. Finn. Learning generalizable robotic reward functions from “in-the-wild” human videos. arXiv preprint arXiv:2103.16817, 2021.

[23] C. Wang, L. Fan, J. Sun, R. Zhang, L. Fei-Fei, D. Xu, Y. Zhu, and A. Anandkumar. Mimicplay: Long-horizon imitation learning by watching human play. arXiv preprint arXiv:2302.12422, 2023.

[24] M. Xu, Z. Xu, Y. Xu, C. Chi, G. Wetzstein, M. Veloso, and S. Song. Flow as the cross-domain manipulation interface. arXiv preprint arXiv:2407.15208, 2024.

[25] J. Ren, P. Sundaresan, D. Sadigh, S. Choudhury, and J. Bohg. Motion tracks: A unified representation for human-robot transfer in few-shot imitation learning. In 2025 IEEE International Conference on Robotics and Automation (ICRA), pages 8802–8810. IEEE, 2025.

[26] R. Zheng, D. Niu, Y. Xie, J. Wang, M. Xu, Y. Jiang, F. Castañeda, F. Hu, Y. L. Tan, L. Fu, et al. Egoscale: Scaling dexterous manipulation with diverse egocentric human data. arXiv preprint arXiv:2602.16710, 2026.

[27] H. Luo, Y. Feng, W. Zhang, S. Zheng, Y. Wang, H. Yuan, J. Liu, C. Xu, Q. Jin, and Z. Lu. Being-h0: vision-language-action pretraining from large-scale human videos. arXiv preprint arXiv:2507.15597, 2025.

[28] H. Luo, Y. Wang, W. Zhang, S. Zheng, Z. Xi, C. Xu, H. Xu, H. Yuan, C. Zhang, Y. Wang,

et al. Being-h0. 5: Scaling human-centric robot learning for cross-embodiment generalization.

arXiv preprint arXiv:2601.12993, 2026.

[29] Q. Li, Y. Deng, Y. Liang, L. Luo, L. Zhou, C. Yao, L. Zeng, Z. Feng, H. Liang, S. Xu, et al.

Scalable vision-language-action model pretraining for robotic manipulation with real-life hu-

man activity videos. arXiv preprint arXiv:2510.21571, 2025.

[30] T. Zhang, S. Xia, Y. Wang, and Q. Jin. Easymimic: A low-cost framework for robot imitation

learning from human videos. arXiv preprint arXiv:2602.11464, 2026.

[31] A. Mandlekar, S. Nasiriany, B. Wen, I. Akinola, Y. Narang, L. Fan, Y. Zhu, and D. Fox.

Mimicgen: A data generation system for scalable robot learning using human demonstrations.

arXiv preprint arXiv:2310.17596, 2023.

[32] S. Nasiriany, A. Maddukuri, L. Zhang, A. Parikh, A. Lo, A. Joshi, A. Mandlekar, and Y. Zhu.

Robocasa: Large-scale simulation of everyday tasks for generalist robots. arXiv preprint

arXiv:2406.02523, 2024.

[33] L. Y. Chen, C. Xu, K. Dharmarajan, M. Z. Irshad, R. Cheng, K. Keutzer, M. Tomizuka,

Q. Vuong, and K. Goldberg. Rovi-aug: Robot and viewpoint augmentation for cross-

embodiment robot learning. arXiv preprint arXiv:2409.03403, 2024.

[34] L. Y. Chen, K. Hari, K. Dharmarajan, C. Xu, Q. Vuong, and K. Goldberg. Mirage: Cross-

embodiment zero-shot policy transfer with cross-painting. arXiv preprint arXiv:2402.19249, 2024.

[35] G. Ji, H. Polavaram, L. Y. Chen, S. Bajamahal, Z. Ma, S. Adebola, C. Xu, and K. Goldberg.

Oxe-aug: A large-scale robot augmentation of oxe for scaling cross-embodiment policy learn-

ing. arXiv preprint arXiv:2512.13100, 2025.

[36] Y. Mu, T. Chen, Z. Chen, S. Peng, Z. Lan, Z. Gao, Z. Liang, Q. Yu, Y. Zou, M. Xu, et al.

Robotwin: Dual-arm robot benchmark with generative digital twins. In Proceedings of the computer vision and pattern recognition conference, pages 27649–27660, 2025.

[37] B. Liu, Y. Zhu, C. Gao, Y. Feng, Q. Liu, Y. Zhu, and P. Stone. Libero: Benchmarking knowl-

edge transfer for lifelong robot learning. Advances in Neural Information Processing Systems, 36:44776–44791, 2023.

- [38] O. Mees, L. Hermann, E. Rosete-Beas, and W. Burgard. Calvin: A benchmark for language-conditioned policy learning for long-horizon robot manipulation tasks. *IEEE Robotics and Automation Letters*, 7(3):7327–7334, 2022.
- [39] S. James, Z. Ma, D. R. Arrojo, and A. J. Davison. Rlbench: The robot learning benchmark & learning environment. *IEEE Robotics and Automation Letters*, 5(2):3019–3026, 2020.
- [40] X. Li, K. Hsu, J. Gu, K. Pertsch, O. Mees, H. R. Walke, C. Fu, I. Lunawat, I. Sieh, S. Kirmani, et al. Evaluating real-world robot manipulation policies in simulation. *arXiv preprint arXiv:2405.05941*, 2024.
- [41] J. Gu, F. Xiang, X. Li, Z. Ling, X. Liu, T. Mu, Y. Tang, S. Tao, X. Wei, Y. Yao, et al. Maniskill2: A unified benchmark for generalizable manipulation skills. *arXiv preprint arXiv:2302.04659*, 2023.
- [42] S. Tao, F. Xiang, A. Shukla, Y. Qin, X. Hinrichsen, X. Yuan, C. Bao, X. Lin, Y. Liu, T.-k. Chan, et al. Maniskill3: Gpu parallelized robotics simulation and rendering for generalizable embodied ai. *arXiv preprint arXiv:2410.00425*, 2024.
- [43] W. Pumacay, I. Singh, J. Duan, R. Krishna, J. Thomason, and D. Fox. The colosseum: A benchmark for evaluating generalization for robotic manipulation. *arXiv preprint arXiv:2402.08191*, 2024.
- [44] S. Fei, S. Wang, J. Shi, Z. Dai, J. Cai, P. Qian, L. Ji, X. He, S. Zhang, Z. Fei, et al. Libero-plus: In-depth robustness analysis of vision-language-action models. *arXiv preprint arXiv:2510.13626*, 2025.
- [45] X. Zhou, Y. Xu, G. Tie, Y. Chen, G. Zhang, D. Chu, P. Zhou, and L. Sun. Libero-pro: Towards robust and fair evaluation of vision-language-action models beyond memorization. *arXiv preprint arXiv:2510.03827*, 2025.
- [46] S. A. Laboratory. EBench: Elemental mobile manipulation benchmark, 2026. URL <https://internrobotics.github.io/EBench-doc/>. Preprint coming soon.
- [47] R. A. Potamias, J. Zhang, J. Deng, and S. Zafeiriou. Wilor: End-to-end 3d hand localization and reconstruction in-the-wild. In *Proceedings of the Computer Vision and Pattern Recognition Conference*, pages 12242–12254, 2025.
- [48] C. Si, Y. Liu, B. Ai, J. Xie, R. A. Potamias, C. Zheng, and H. Su.

Anyhand: A large-scale

synthetic dataset for rgb (-d) hand pose estimation. arXiv preprint arXiv:2603.25726, 2026.

[49] Z. Yu, S. Zafeiriou, and T. Birdal. Dyn-hamr: Recovering 4d interacting hand motion from a dynamic camera. In Proceedings of the Computer Vision and Pattern Recognition Conference, pages 27716–27726, 2025.

[50] Q. Team. Qwen3. 5: Accelerating productivity with native multimodal agents, february 2026.
URL <https://qwen.ai/blog>.

[51] N. Carion, L. Gustafson, Y.-T. Hu, S. Debnath, R. Hu, D. Suris, C. Ryali, K. V. Alwala, H. Khedr, A. Huang, et al. Sam 3: Segment anything with concepts. arXiv preprint arXiv:2511.16719, 2025.

[52] S. Zhou, C. Li, K. C. Chan, and C. C. Loy. Propainter: Improving propagation and transformer for video inpainting. In Proceedings of the IEEE/CVF international conference on computer vision, pages 10477–10486, 2023.

[53] E. Todorov, T. Erez, and Y. Tassa. Mujoco: A physics engine for model-based control. In 2012 IEEE/RSJ international conference on intelligent robots and systems, pages 5026–5033. IEEE, 2012.

[54] K. Zakka. Mink: Python inverse kinematics based on MuJoCo, Feb. 2026.
URL <https://github.com/kevinzakka/mink>.

[55] Y. Tian, Y. Yang, Y. Xie, Z. Cai, X. Shi, N. Gao, H. Liu, X. Jiang, Z. Qiu, F. Yuan, et al. Interndata-a1: Pioneering high-fidelity synthetic data for pre-training generalist policy. arXiv preprint arXiv:2511.16651, 2025.