

JALA：联合对齐潜动作——迈向利用野外数据进行可扩展的 VLA 预训练

Hao Luo、Ye Wang、Wanpeng Zhang、Haoqi Yuan、Yicheng Feng、Haiweng Xu、Sipeng Zheng、Zongqing Lu

北京大学、中国人民大学、BeingBeyond

原文日期：2026 年 2 月 25 日

摘要

尽管视觉-语言-动作模型（VLA）已经取得进展，但大规模、多样化机器人数据的匮乏仍限制着它们的发展。人类操作视频提供了一种丰富的替代数据来源，然而现有方法不得不在两类数据之间作出选择：一类是规模较小、标签精确的数据集，另一类是数量庞大、但手部追踪标签并不可靠的野外视频。我们提出 JALA，这是一种学习联合对齐潜动作（Jointly-Aligned Latent Actions）的预训练框架。JALA 绕过完整的视觉动态重建，转而学习一种同时与逆动力学和真实动作对齐的预测动作嵌入。由此得到的是一个感知状态转移、以行为为中心的潜空间，可用于从异构人类数据中学习。我们进一步借助 UniHand-Mix 扩展这种方法；UniHand-Mix 是一个包含 750 万段视频、总时长超过 2,000 小时的语料库，融合了实验室视频和野外视频。实验表明，无论在受控还是非受控场景中，JALA 都能生成更加逼真的手部运动，并显著提升下游机器人在仿真和真实世界任务中的操作性能。这些结果说明，联合对齐潜动作作为利用人类数据开展可扩展的 VLA 预训练提供了一条可行路径。

1 引言

长期以来，研究人员一直致力于构建能让机器人执行多种任务的基础模型。近期的视觉-语言-动作模型（VLA）[1-3] 通过使用机器人数据集 [4, 5] 对大型多模态模型（LMM）进行适配，展现出很大潜力。然而，与推动视觉和语言领域取得突破的数据集 [6, 7] 相比，机器人数据的规模和多样性仍相差数个数量级。这种数据匮乏与跨机器人形态的异构性相叠加，构成了扩大 VLA 预训练规模的主要障碍 [8, 9]。

为了突破这一数据瓶颈，近期工作 [10, 11] 开始转向人类示范视频，把手部运动视为一种丰富且低成本的训练信号，使 VLA 能获得机器人数据集覆盖范围以外的技能。然而，数据质量与多样性之间仍存在权衡：实验室采集的数据集 [12-15] 能提供精确的三维手部追踪，却局限于受控桌面场景；野外视频 [16-18] 拥有巨大的多样性和自然行为，却缺少可靠的动作标签。这引出了我们的核心问题：如何有效结合这两种互补的人类数据来源，从而扩展 VLA 预训练？

野外视频虽然没有动作标签，但其中的运动动态反映了交互过程中发生的视觉变化。以往方法通过辅助视觉表征学习 [20, 21] 或世界模型 [22, 23] 间接捕捉这些信息，但它们与动作之间的联系较弱。为提取更直接的动作信息，近期工作 [19, 24, 25] 利用逆动力学，即把视觉状态转移映射为其背后的动作，从而生成潜动作并构成潜动作空间。通常，逆动力学模型（IDM）根据当前帧和未来帧推断潜动作，前向动力学模型（FDM）则根据潜动作和当前帧重建未来帧，以此约束潜动作，使其编码与动作有关的信息（图 1 左）。不过，对于细粒度人类操作而言，这种范式效率不高，因为潜动作的质量高度依赖 FDM 对未来帧建模的能力。手部运动细微且多变，准确学习 FDM 十分困难，往往会引入噪声、降低潜动作质量，而不是提供稳定的基础。

在本文中，我们从一个新的角度看待用于 VLA 预训练的人类动作。其灵感来自人类学习操作的方式：人类依靠可迁移的动作模式，而不是记住每一处视觉细节。我们的框架 JALA 不再采用重建驱动的流水线（图 1 左），而是让 VLA 上下文产生的预测嵌入 h 与 IDM 得到的潜动作 z 联合对齐。这样塑造出的潜动作空间既能从上下文中预测，又保留逆动力学信息，同时无需重建像素。当真实动作 a 可用时，模型还会根据 h 预测该动作，通过预测嵌入把共享空间明确锚定在控制语义上。无论动作标签是否存在，JALA 都能构建统一的潜动作空间，从实验室标注视频和野外视频中共同学习。

为实现这一设计，我们在基于 Transformer 的 VLA 上构建 JALA。如图 1 右侧所示，VLA 根据动作掩码 token 预测动作 token，同时让中间隐藏状态与 IDM 输出的潜动作对齐；这些隐藏状态就是连接真实动作与潜动作的预测嵌入。当我们把预训练后的 VLA 适配到机器人任务时，会把这些预测嵌入输入流匹配头 [26]，从而高效地将预训练潜动作空间迁移到机器人任务。

我们使用 UniHand-Mix 扩展预训练。它是一个包含 750 万个样本的混合语料库，由 500 万段带精确手部追踪的实验室视频和 250 万段不带手部追踪的野外操作视频组成。沿用文献 [10]，我们处理了 1,000 小时实验室视频，生成带显式运动标签的指令微调样本；随后又从 Ego4D [16] 的另外 1,123 小时视频中过滤片段，将数据扩展到非受控场景。我们在手部运动生成和机器人操作任务上评估 JALA。结果表明，JALA 在维持实验室场景性能的同时，尤其擅长在野外场景中生成逼真的手部运动。它在 LIBERO [27] 和 RoboCasa [28] 上超过规模相近的 VLA，也能与更大的模型竞争；在真实世界中，尤其是在分布外任务上，它同样表现更好。

我们的主要贡献如下：(1) 新的潜动作范式：我们引入联合对齐潜动作，使 VLA 能以前所未有的规模同时从有标签和无标签的人类视频中学习。(2) 大规模混合数据集：我们创建 UniHand-Mix，在 UniHand 基础上增加 250 万个野外人类操作样本，为 VLA 预训练提供更大的多样性。(3) 强有力的实验结果：我们证明，所构建的 VLA 显著改善手部运动生成的泛化能力，并在机器人任务上的同等规模模型中达到最先进水平。

【图 1：使用人类视频的 VLA 潜动作范式对比。左：LAPA [19] 等以往重建式方法依靠多阶段流水线，通过动态重建提取潜动作并将其用作伪标签。中：JALA 引入与潜动作对齐的预测嵌入。右：基于 Transformer 的 JALA 实现，中间隐藏状态作为预测嵌入与潜动作对齐，输出 token 则使用可用的动作标签监督。】

2 相关工作

视觉-语言-动作模型预训练。 通过改造预训练视觉语言架构来构建 VLA，已经受到越来越多关注。借助大规模机器人数据集 [5, 29, 30]，研究人员主要采取两条路线：一条把机器人动作转换成离散 token，像训练自回归大语言模型一样训练 [1, 4, 8, 31-33]；另一条使用扩散或流匹配方法生成连续动作 [2, 3, 9, 34-38]。本工作在预训练阶段使用 token 化来学习通用动作模式，在部署阶段则切换到流匹配，以实现精确机器人控制。

然而，仅靠机器人数据仍然受限，因此研究人员开始把人类视频当作更容易扩展的资源。一些工作从人类视频中间接学习，例如提取通用视觉表征、构建世界模型 [3, 20-23]，或创建潜动作空间 [19, 25, 39]。这些方向虽很有前景，却难以把抽象表征与实际物理动作连接起来。另一些方法使用带精确手部追踪的实验室人类数据 [13-15, 40]，显式建模人手运动 [10, 11, 41]。这种方法能提供更强的物理基础，但需要昂贵的数据采集，而且限制任务多样性。我们的工作连接了这两条路线。我们让预测嵌入与运动动态对齐，从而既能利用无标签视频学习的可扩展性，又能利用显式标注轨迹的精确性。该设计在维持物理基础的同时降低标注成本，使 VLA 预训练能更有效地扩展到异构人类数据集。

从视频中学习。 我们的工作也与从视频中学习 (LfV) [42, 43] 有关。这类研究使用多种技术从无标签视频中提取行为知识，包括：预测视频缺失部分的掩码自编码 [21, 44]；学习区分不同视频片段的时间对比学习 [20, 45]；预测未来帧的视频预测 [43, 46]；以及根据视觉变化推断动作的逆动力学建模 [47-49]。就机器人控制而言，一些工作利用精心匹配的人类—机器人数据对来训练模仿策略 [50-53]，但只能扩展到特定任务集合。将非受控人类视频与机器人动作结合使用时 [19, 39]，由于人类行为与机器人行为之间缺乏明确对齐，效果也受到限制。我们则利用人类手部追踪作为丰富的物理对齐来源，而人手正是现有数据中标注最广泛的操作器。我们在统一预训练框架内把这些精确标注与多样的野外视频结合，同时获得物理基础和任务多样性。

3 预备知识

沿用 Being-H0 [10], 我们使用 MANO 参数 [54] 对用于 VLA 预训练的人手运动建模。每个样本包含视频 $v = \{v_1, v_2, \dots, v_T\}$ 、文本指令 x 和手部姿态序列 $M = \{m_1, m_2, \dots, m_T\}$ 。其中, 每个姿态 m_t 由 MANO 参数 $(\theta_t, r_t, \tau_t, \beta_t)$ 定义, 分别表示相对关节角、全局手腕旋转、手腕平移和手形; 静态手形参数 β_t 不纳入训练。

预训练时, 我们把姿态序列切成固定长度的块, 通过 GRQ [55] 将每块 token 化为 K 个运动 token。输入序列为 $[x, v_1, A_1, A_2, \dots, A_N]$, 其中 v_1 是第一帧, A_i 表示第 i 个运动块, 长度为 T/N 。这种格式与 VLA 预训练范式一致, 使模型能根据视觉和文本输入生成手部运动。VLA f_Θ 的训练目标是最大化给定先前上下文时的运动 token 似然:

$$\max_{\Theta} \sum_{i=1}^N \log p(A_i \mid A_{<i}, v_1, x; \Theta). \quad (1)$$

我们还加入运动描述生成、运动续写等辅助任务, 帮助模型在适配机器人任务前学习更丰富的 token 语义, 同时保持逐块生成运动的形式。鉴于手部追踪数据有限, 我们同时使用有标注和野外视频。定义: (1) 有标注数据集 $D_A = \{(x^{(i)}, v^{(i)}, M^{(i)})\}_{i=1}^{N_A}$, 含指令、视频和手部姿态; (2) 无标注数据集 $D_U = \{(x^{(j)}, v^{(j)})\}_{j=1}^{N_U}$, 只有指令和视频。目标是在混合数据集 $D = D_A \cup D_U$ 上联合训练, 兼得有标注数据的精确性和野外视频的多样性。

【图 2: JALA 框架。预训练 (左): 被掩码运动块的隐藏状态作为预测嵌入, 与边界帧得到的潜动作对齐。潜动作感知器 (LAP) 把边界帧映射到潜动作空间, 无需动作标签也能提供监督。参数共享的潜状态感知器 (LSP) 注入初始帧上下文; LAP 与 LSP 通过解耦 EMA 更新相连, 以保证稳定性。后训练 (右): 预测嵌入送入流匹配头, 迁移到机器人任务。】

4 方法

如图 2 所示, JALA 建立在基于 Transformer 的视觉语言模型之上, 共同处理视觉、指令和运动 token。我们把中间隐藏状态作为预测嵌入, 与逆动力学推断的潜动作联合对齐。再配合可选动作监督, 联合对齐会导出一个统一潜动作空间: 它既可从 VLA 上下文预测, 又能在混合人类视频数据中编码视觉动态和动作语义。

4.1 与潜动作联合对齐

对运动块 A_i 中每个运动 token $a_{i,k}$ ，我们从预选注意力层提取其隐藏状态作为预测嵌入 $h_{i,k} \in \mathbb{R}^d$ 。它由两种互补信号塑造：(1) 运动标签监督；(2) 潜动作对齐。

掩码块预测 (MCP)。为依据手部追踪标签捕捉运动信息，我们引入类似 GR-1 [22] 的块级掩码 token 建模目标。预训练期间，把一个块内所有运动 token 替换为 [MASK]，并在块内使用双向注意力，使模型理解块内运动之间的关系。VLA 预测原始 token：

$$\mathcal{L}_{\text{MCP}} = - \sum_{i=1}^N \sum_{k=1}^K \log p_{\Theta}(a_{i,k} \mid A_{<i}, v, x). \quad (2)$$

虽然对各 token 分别求和，但双向注意力保证 A_i 中所有 $a_{i,k}$ 被联合建模。因此，对应隐藏状态 $h_{i,k}$ 会通过 VLA 上下文中的预测嵌入承载块级运动模式。

潜动作感知器 (LAP)。为让预测嵌入与视觉动态联合对齐，我们引入作为逆动力学模型的感知器模块 LAP [56, 57]。对每个运动块，LAP 接收起止帧 $(v_t, v_{t+\delta})$ ，用一组固定可学习查询向量生成 K 个潜动作 $\{z_{i,1}, \dots, z_{i,K}\}$ ，捕捉块级转移动态。我们不重建完整视频帧，而是对齐预测嵌入和潜动作：

$$\mathcal{L}_{\text{Align}} = \sum_{i=1}^N \sum_{k=1}^K \|h_{i,k} - z_{i,k}\|_1. \quad (3)$$

MCP 或 LAP 单独使用都不充分：LAP 本身无法保证表征以动作为中心，MCP 本身则遗漏视觉动态。联合对齐把隐藏状态中的运动模式与潜动作中的视觉动态融合，以双重约束把预测嵌入锚定到适用于混合数据的统一潜动作空间。

4.2 采用解耦更新的联合感知器

为更有效捕捉块级动态，我们使用预训练视觉编码器 (DINOv3 [58] 或 V-JEPA2 [59]) 的特征作为潜动作模块输入。不过，这些特征来自与预训练 VLM 不同的视觉骨干，可能处于未对齐的表征空间。简单连接到预测嵌入可能丢失重要信息，或产生与模型上下文不匹配的潜动作。为此，我们引入潜状态感知器 LSP，与 LAP 配对 (图 2)。LAP 处理边界帧特征生成潜动作，LSP 则把 VLM 的预测上下文连接到同一潜动作空间，以减轻预测负担。

LAP 与 LSP 采用相同的两层感知器架构并共享权重。每层包含一个交叉注意力块和一个自注意力块：前者以可学习潜查询为查询、视觉特征为键和值；后者在提取的潜 token 之间执行注意力。随后，两层 MLP 把潜变量投影到 VLM 嵌入空间。为处理双手视频且不牺牲共享性，我们使用共享主干，但把 MLP 通道加倍并拆成左、右手专用头，按当前活动运动流动态选择。为保证架构一致，二者都处理帧对：LAP 接收运动块边界帧 $(v_t, v_{t+\delta})$ ，LSP 使用重复初始帧 (v_0, v_0) ，使差异来自输入语义而非架构不一致。

一个核心困难是 LAP 和 LSP 处理异构信号（视觉边界帧与预测上下文）；直接用对齐损失耦合，可能因一侧占主导而不稳定或坍缩。我们因此解耦感知器骨干与可学习查询的优化，并采用非对称 EMA 更新。用来自 LSP 的梯度优化骨干，使视觉特征映射到由 MCP 和对齐塑造的预测嵌入空间；用来自 LAP 的梯度优化查询，以显式动作线索锚定潜动作。随后将 LSP 骨干权重传播给 LAP，将 LAP 查询权重传播给 LSP：

$$\theta_b^{\text{LAP}} \leftarrow \alpha \theta_b^{\text{LAP}} + (1 - \alpha) \theta_b^{\text{LSP}}, \quad (4)$$

$$\theta_q^{\text{LSP}} \leftarrow \alpha \theta_q^{\text{LSP}} + (1 - \alpha) \theta_q^{\text{LAP}}. \quad (5)$$

其中上下标分别表示 LAP/LSP 的骨干和查询参数， $\alpha \in [0, 1)$ 是 EMA 系数。这种非对称设计让 LAP 骨干与预测上下文一致，也让 LSP 查询逐渐继承动作基础能力，保证潜动作既可从上下文预测，又由动作线索锚定。

4.3 MCP 细节

混合掩码方案。 朴素策略会造成训练与推理不匹配：训练时块内 token 全被 [MASK] 替换，推理时运动块却依次生成。为减小差距，我们：（1）从含 N 个块的序列随机选择一个主要预测目标；（2）保留目标之前的块；（3）在目标块内，从 $\{0.05, 0.15, \dots, 1.0\}$ 均匀采样比例来掩码 token；（4）对目标之后各块的 token 以固定 5% 概率掩码，在不扭曲上下文时提供额外监督。这样，主要预测块在训练和推理时处理一致上下文。

无标签视频完全掩码。 对缺少运动 token 的野外纯视频样本，整个 A_i 都用 [MASK] 替换。MCP 不启用，只使用 $\mathcal{L}_{\text{Align}}$ 与 LAP 潜动作对齐。接口因而保持统一，模型也无需显式标签就能学习与动态对齐的预测嵌入。

使用 MCP 推理。 生成运动时，多次解码当前块，每次解码约 5% 的 token，最后集成输出以减小近似误差。这保留了相对因果解码的效率优势；下游迁移仍只需一次前向传播提取预测嵌入。

4.4 两阶段训练

混合数据预训练。 对无标签视频，跳过 MCP，只让预测嵌入与 LAP 的视觉动态对齐，使野外视频在无精确标注时仍提供学习信号。混合目标为：

$$\mathcal{L} = \mathbf{1}_{\text{labeled}} \mathcal{L}_{\text{MCP}} + \lambda \mathcal{L}_{\text{Align}}. \quad (6)$$

$\mathbf{1}_{\text{labeled}}$ 仅在手部追踪标签可用时激活 MCP。预测嵌入由两种来源学习：标签可用时学习运动标签，并始终学习动态，使预训练可扩展至异构数据。

流匹配后训练。 完成预训练后，JALA 建立了预测嵌入经过对齐的统一潜动作空间。对于机器人任务，使用流匹配头迁移到机器人特定动作（图 2 右）。预训练 VLA 的 $\{h_{i,k}\}$ 作为条件输入送入基于 DiT 的策略头，其自注意力处理本体感知状态与加噪动作，交叉注意力将其与预测嵌入融合，把通用动态知识注入动作生成。对真实动作块 A_t ，根据时间步 τ 和标准高斯噪声 ϵ 构造 $A_t^\tau = \tau A_t + (1 - \tau)\epsilon$ ，模型 V_θ 预测去噪向量场 $\epsilon - A_t$ ：

$$\mathcal{L}_{\text{FM}} = \mathbb{E}_{\tau, \epsilon, A_t} [\|V_\theta(\{h_{i,k}\}, A_t^\tau, q_t) - (\epsilon - A_t)\|_2^2], \quad (7)$$

其中 q_t 是机器人本体感知状态。推理时，用固定步数的前向欧拉积分反复去噪随机初始动作块，最终得到精确机器人动作命令。

5 混合人类操作数据集

为扩大 JALA 预训练，我们构建 UniHand-Mix，把实验室标注数据与野外第一人称视频统一起来。实验室数据提供准确手部运动监督和密集任务标注，野外数据提供更广泛的行为多样性和上下文先验。数据集包括：（1）配有指令、视频和 MANO 手部运动序列的实验室子集；（2）从 Ego4D [16] 整理、带自动验证的手部中心片段和生成指令的野外子集，其中部分样本有伪手姿态标注。总计超过 750 万个指令—视频样本，包括 500 多万个实验室指令—视频—运动样本和 250 万个野外指令—视频对，后者约 10% 有手姿态标注。

5.1 实验室标注子集

沿用 UniHand 流水线 [10]，我们整理带精确三维手部监督和密集任务描述的高质量实验室子集。每个样本含指令、视频片段和 MANO 手部运动序列，并支持运动生成、运动描述和运动续写三种指令微调任务。

数据整理分三步。**手姿态标准化：**所有标注统一成 MANO [54]。动作捕捉或 SLAM 标签直接转换；只有三维关节时，通过优化拟合；只有 RGB 时，用 HaWoR [60] 逐帧估计，再做时间平滑和左右手校正。**分层任务标注：**视频切成 10 秒片段；片段级提供祈使式指令和简洁摘要，秒级标注接触状态、物体属性和手—物交互，覆盖双手与单手动作。**指令数据生成：**根据标注为三类任务构造多模态样本，从任务专用基础模板出发，用 Gemini 增加语言多样性，同时保持视觉、语言、运动对齐。约 1,000 小时实验室视频最终产生 500 多万个样本。

【图 3：UniHand-Mix 统计。数据类型：运动生成 42.5%、无运动标签视频 29.1%、运动描述 12.9%、运动续写 15.5%；视频长度为 1 至 10 秒；来源为 Ego4D 32.9%、

EgoDex 14.7%、OakInk2 12.4%、HOI4D 10.0%、ARCTIC 9.7%、TACO 9.7%、H2O 6.5%、Dex-YCB 4.1%。】

5.2 野外子集

为用更多样、自然的人类行为补充实验室子集，我们从 Ego4D [16] 整理野外子集。第一人称视频噪声更大：手常因遮挡而时隐时现，许多片段包含静止或非操作性手部运动。我们设计分阶段过滤与标注流程：（1）用 WiLoR [61] 做帧级手部区域检测，移除看不到手的片段；（2）用 Gemini-2.5-Flash 识别以手部为中心的操作，丢弃手部缺失、静止或只是干扰因素的样本，并为有效片段自动生成指令；（3）可选地用 HaWoR [60] 估计手姿态，保留置信度超过 0.65 的片段，作为全标注实验室数据与纯视频野外数据之间的桥梁。该流程得到约 250 万个指令—视频对，约 10% 含伪手姿态标注，显著扩展任务多样性和上下文覆盖。

5.3 统计信息

图 3 从任务类型、片段长度和数据来源概括 UniHand-Mix。任务分布有意保持异构：运动生成占比最大，是学习视觉到运动映射的主要信号；大量纯视频样本把视觉和上下文多样性扩展到手部标注数据之外；运动描述和续写为语言对齐与时间建模提供互补监督。长度分布偏向短片段：短片段捕捉密集局部交互和细粒度运动基元，长片段保留多步骤行为和时间依赖，混合二者兼顾短时程运动学习与长时程续写。

八个来源横跨实验室数据和 Ego4D 野外视频。野外部分保证环境、物体和交互上下文的广泛覆盖；实验室部分则用可靠手部运动监督和干净操作片段提供锚点，而且分散在多个基准中，增加采集设置、任务和物体类别的多样性。总之，UniHand-Mix 具有：

（1）实验室数据的强运动监督；（2）野外及纯视频样本的广泛上下文多样性；（3）长短片段的多尺度时间覆盖，共同支持运动预测、语言基础和时间推理方面的可扩展预训练。

6 实验

实验研究三个核心问题：（1）**野外学习**：JALA 能否从野外人类视频中学习，并表现出随规模扩展而增长的能力？（2）**下游迁移**：预训练预测嵌入能否改善机器人任务性能？（3）**消融验证**：所提出的对齐设计是否有效？

6.1 实现细节

预训练。 JALA 沿用 Being-H0 的设计，以具有 28 个注意力层的 InternVL3-2B [62] 为视觉语言骨干，并使用 DINOv3 [58] 或 V-JEPA2 [59] 作为向潜感知器提供输入的视觉编码器。为加入运动模态，我们将 15 帧运动块 token 化。每块被拆为手腕运动和手指运动，两者分别量化为 64 个 token，合计 128 个。每部分码本大小为 4096，通过向量量化算法 GRVQ [55] 学习，以捕捉通用运动模式。运动 token 用两个特殊 token `<mot>` 和 `</mot>` 包裹，形成统一格式：

`<mot> {wrist_motion_tokens} {finger_motion_tokens} </mot>`

这些特殊 token 是明确的分隔符，帮助 VLM 区分运动块和视觉、指令 token 等其他模态。序列包含双手时，我们沿时间轴交错排列左右手运动块，既保持同步，也维持模态区分。野外数据在时间上按 0.5 倍速度放慢，以适应其与实验室数据的动作速度差异。用于联合对齐的预测嵌入取自 28 个注意力层中的第 19 层。训练目标结合 MCP 和潜动作对齐， $\lambda = 0.5$ ；野外视频只使用对齐损失。

优化器为 AdamW，基础学习率 3×10^{-5} ，权重衰减 0.05， $\beta = (0.9, 0.95)$ 。前 5% 步数进行学习率预热，随后按余弦调度衰减；全程使用最大范数 1.0 的梯度裁剪。感知器模块以 $\alpha = 0.999$ 的 EMA 系数更新。每张 GPU 的 batch size 为 16，8 张 GPU 配合梯度累积得到 128 条序列的有效 batch size；每条序列含一个 15 帧运动块、配对指令及边界帧。在完整的 750 万样本 UniHand-Mix 上训练一个 epoch，使用 8 张 NVIDIA A800 80GB GPU，共需 68 小时。

后训练。 预训练后，我们使用流匹配头在 LIBERO、RoboCasa 和真实世界任务上微调 JALA。DiT 策略头由交替的自注意力和交叉注意力层组成，共 16 层，每个注意力块 32 个头，隐藏状态维度 2048。训练 batch size 128，学习率 1×10^{-4} ，预热 5% 后余弦衰减。使用相同硬件，LIBERO 训练 3 万步（约 8 小时），RoboCasa 训练 6 万步（约 16 小时），真实任务训练 3 万步（约 8 小时）。只解冻语言模型参数，视觉编码器保持冻结。作为对比，我们用相同设置训练 GR00T-N1.5 基线。推理时使用 $N = 4$ 个去噪步骤。

6.2 手部运动生成

我们评估 JALA 的手部运动生成能力，即给定初始视觉输入和指令，预测一个运动块。这直接反映模型从预训练数据中内化人类操作先验的程度。更重要的是，它检验 JALA 的联合对齐潜动作是否形成了统一潜动作空间，既支持精确标注数据，也支持非受控、无标签的野外视频。

模型变体与基线。 两个 JALA 变体 JALA-dino 和 JALA-vjepa 的唯一区别，是 LAP/LSP 使用 DINOv3 还是 V-JEPA2 视觉骨干。另设四个基线：（1）Being-H0 [10]，使用相同 InternVL3-2B 骨干复现；（2）Being-H0+dino，在 Being-H0 上加入 DINO 特征，以匹

配 JALA 的 LSP 输入；(3) JALA w/o align, 完全移除 LAP, 以单独考察联合对齐的贡献；(4) JALA w/o latent, 先训练一个动作 token 预测器, 把边界帧映射到运动块 token, 再将其预测 token 作为纯视频数据的显式伪标签, 以此替代潜动作来支持混合数据。JALA-dino、JALA-vjepa 和 JALA w/o latent 在完整 UniHand-Mix 上训练, 其余基线只在动作标签可用的子集上训练。

评估指标。 使用两个评估划分：(1) Lab, 实验室标注数据的留出子集, 衡量精确监督下的保真度；(2) Wild, 从带 HaWoR 标注的 Ego4D 中整理, 衡量对未见过的野外操作行为的泛化。四项指标为：(1) MPJPE, 预测与真实三维关节的平均欧氏距离, 衡量空间精度；(2) PA-MPJPE, 刚性对齐后的 MPJPE, 衡量相对姿态保真度；(3) MWTE, 手腕轨迹平均偏移, 衡量全局轨迹保真度；(4) MDE, 从初始手腕位置计算的最终位移方向误差, 衡量运动趋势一致性。它们同时覆盖局部姿态精度和全局轨迹真实性。

表 1: Lab 与 Wild 划分上的手部运动生成与预测结果, 均为越低越好。

模型	MPJPE Lab	MPJPE Wild	PA- MPJPE Lab	PA- MPJPE Wild	MWTE Lab	MWTE Wild	MDE Lab	MDE Wild
Being-H0	7.61	16.91	1.34	3.81	6.03	14.54	7.16	18.33
Being-H0+dino	7.54	15.14	0.90	2.78	5.85	13.65	6.95	17.17
JALA w/o align	7.72	15.73	0.89	2.34	6.18	14.02	8.09	16.23
JALA w/o latent	8.26	20.34	1.83	3.94	8.02	17.13	10.17	26.74
JALA-dino	7.16	11.02	0.91	1.12	5.77	9.79	7.24	11.04
JALA-vjepa	7.05	11.54	0.94	1.32	5.85	10.04	6.73	11.87

数据集设置。 运动生成评估遵循与预训练相同的协议。Lab 衡量受控室内环境下精确监督的保真度；Wild 衡量对多样真实活动中非受控行为的泛化。

主要结果。 表 1 显示，两个 JALA 变体在几乎所有指标上都超过基线。Lab 上提升较小，Wild 上提升显著。所有模型都会因 Wild 更高的变异性和复杂度而退化，但 JALA 的降幅小得多。这说明联合对齐潜动作确实捕捉到可迁移到精选实验室环境之外的操作先验，使模型能稳健扩展到真实人类交互。

设计洞见。 消融揭示了四点：（1）Being-H0+dino 相对 Being-H0 只有轻微提升，说明加入更强视觉特征作用有限。（2）JALA w/o align 的相近表现说明，预测范式本身（下一 token 或掩码块）不是主要因素。（3）JALA w/o latent 虽使用更多数据，却明显差于 JALA w/o align，尤其是在 Wild 上，说明缺少适当结构监督时，单纯增加无标签视频甚至有害。（4）联合对齐潜动作提供稳定、可迁移的信息，使 JALA 从大规模野外视频中受益，而非受其拖累。JALA-dino 与 JALA-vjepa 表现相近，也表明 JALA 对自监督视觉骨干的选择稳健。总体而言，预测范式、视觉特征或数据量调整作用有限，联合对齐潜动作才是泛化增益的主要来源。

可视化。 为验证联合对齐产生一致潜空间，我们可视化 Lab/Wild 数据中预测嵌入 h 与潜动作 z 的对齐。图 4 中，两个空间聚集在紧密对齐的区域，Wild 样本大体扩展了 Lab 流形，而非形成彼此分离的域。这证实 JALA 在单一潜动作空间中弥合了精选实验室数据与非受控野外视频的差距。

【图 4：Lab 与 Wild 数据中预测嵌入 h 和潜动作 z 的 t-SNE 图。两个空间在相近区域成簇，Wild 样本大体扩展了 Lab 流形。】

图 5 给出野外与实验室场景的定性结果。野外一侧，模型能处理拨吉他弦、双手协调编织、用筷子搅拌锅中蔬菜等多样的非受控交互，显示对复杂场景和双手协调的稳健泛化。实验室一侧，模型为拨下耳机线、把碗中物品放到碗盖上、把碗放到自己面前生成精确且时间一致的运动，反映结构化场景下的细粒度控制。这些结果与表 1 的定量趋势一致。

【图 5：实验室场景（左列）和野外场景（右列）的定性手部运动生成结果。彩色叠加图表示生成的手部姿态。】

6.3 仿真结果

为评估下游迁移，我们在 LIBERO、RoboCasa 和 GR1 桌面任务三个仿真基准上微调 JALA。除上述基线外，再加入五项对比：（1）LAPA [19] 官方检查点，一种重建式潜动作方法；（2）LAPA[†]，用 JALA 骨干和我们的数据重新训练，以排除骨干与数据差异；（3）JALA^{*}，把有标注野外片段当作无标签，以检验少量野外运动标注是否必要；（4）JALA-act，只在动作可用子集训练，以区分方法和额外数据的贡献；（5）JALA w/o dec.，去掉解耦 EMA 更新的 JALA-act，以验证稳定机制的必要性。由此系统区分训练目标、数据构成和架构设计的作用。

6.3.1 LIBERO 实验

设置。我们分别在 LIBERO 的 Spatial、Object、Goal 和 Long 四个任务套件上微调。除原始双视角设置外，还评估更困难的单第三人称视角：移除辅助第一人称相机，因而要求模型从视觉观察中形成更强抽象。基线包括利用重建式潜动作进行纯视频预训练的 LAPA 与 UniVLA。单视角实验还加入 JALA w/o align 和 JALA w/o latent。所有模型每项任务使用不到 50 条示范微调。

表 2：双视角 LIBERO 成功率 (%)。

模型	Spatial	Object	Goal	Long	平均
LAPA	83.4	87.6	78.2	68.8	79.5
MolmoAct	87.0	95.4	87.6	77.2	86.6
π 0-FAST	96.4	96.8	88.6	60.2	85.5
GR00T N1.5	94.4	97.6	93.0	90.6	93.9
π 0	96.8	98.8	95.8	85.2	94.2
UniVLA	95.4	98.8	93.6	94.0	95.5
Being-H0	92.6	96.8	94.0	77.4	90.2
JALA-act	93.4	97.8	94.2	91.8	94.3
JALA w/o dec.	64.6	58.4	61.2	42.2	56.6
LAPA†	87.4	91.2	90.0	65.4	83.5
JALA★	95.2	96.4	97.2	94.0	95.7
JALA-vjepa	95.4	98.0	98.0	94.8	96.6
JALA-dino	96.0	98.2	97.4	96.0	96.9

双视角结果。标准设置中，近期 VLA（包括重建式 UniVLA）已经很强。JALA 虽更轻量，却与这些基线持平或更好。JALA-dino 在完全未用机器人数据预训练的情况下达到最高平均成功率 96.9%，表明联合对齐潜动作提供了能泛化到下游机器人任务的有效动作抽象。LAPA 官方模型为 79.5%，同数据同骨干重训的 LAPA† 为 83.5%，都明显落后；LAPA† 虽受益于我们的数据与骨干，仍平均落后 JALA 逾 13 个百分点，说明差距来自训练目标，而非数据或架构。

在同一动作可用子集上，JALA-act（94.3%）持续优于 Being-H0（90.2%），Long 上增益最大（91.8% 对 77.4%），说明即使没有野外数据，联合对齐也有助于学习可迁移的人类先验。把野外标注片段当作无标签的 JALA★ 接近完整模型（95.7% 对 96.9%），说

明少量野外运动标注有帮助但并非强性能所必需。JALA w/o dec. 骤降至 56.6%，凸显解耦 EMA 对稳定对齐至关重要；没有它，LAP 与 LSP 无法收敛到一致潜空间。

表 3：单视角 LIBERO 成功率 (%)。

模型	Spatial	Object	Goal	Long	平均
LAPA* (>3B)	73.8	74.6	58.8	55.4	65.7
OpenVLA (>3B)	84.7	88.4	79.2	53.7	76.5
TriVLA (>3B)	91.2	93.8	89.8	73.2	87.0
4D-VLA (>3B)	88.9	95.2	90.9	79.1	88.5
UniVLA-human† (>3B)	91.2	94.2	90.2	79.4	88.7
UniVLA-full†† (>3B)	96.5	96.8	95.6	92.0	95.2
Diffusion Policy (≤3B)	78.3	92.5	68.3	50.5	72.4
Octo (≤3B)	78.9	85.7	84.6	51.1	75.1
UniACT (≤3B)	77.0	87.0	77.0	70.0	77.8
SpatialVLA (≤3B)	88.2	89.9	78.6	55.5	78.1
DiT Policy (≤3B)	84.2	96.3	85.4	63.8	82.4
ThinkAct (≤3B)	88.3	91.4	87.1	70.9	84.4
Being-H0 (≤3B)	86.6	92.8	89.6	70.4	84.9
GR00T N1.5 (≤3B)	91.4	97.6	94.0	85.6	92.1
JALA w/o align (≤3B)	89.4	91.2	90.0	72.6	85.8
JALA w/o latent (≤3B)	80.4	83.6	75.2	68.6	77.0
JALA-vjepa (≤3B)	91.6	98.2	94.4	84.2	92.1
JALA-dino (≤3B)	90.4	96.4	95.2	87.2	92.3

注：LAPA* 的结果引自 UniVLA；UniVLA-human† 只使用人类预训练数据，UniVLA-full†† 还使用 Bridge-V2 [64]。

单视角结果。 在更难的设置中，两个 JALA 变体仍属第一梯队。JALA-dino 在同等骨干规模（小于 3B）模型中取得新的最先进平均成功率 92.3%，超过 GR00T N1.5 等强基线，尽管 JALA 只在人类数据上预训练。Long 上达到 87.2%，显示长时程任务泛化尤其突出。去掉联合对齐会明显下降，而只是叠加更多预训练视频会造成更大退化，证明联合对齐潜动作是 JALA 胜出的关键。UniVLA 等重建式模型需要显著更多计算、显存和训

练；JALA 不做重建且只用人类视频，仍超过仅用人类数据的 UniVLA，并接近额外使用大规模机器人数据的 UniVLA-full。这说明联合对齐是从野外视频提取可迁移操作先验的更高效路线。

6.3.2 RoboCasa 实验

设置。 RoboCasa 是厨房环境基准，同时提供合成示范和人类采集示范。我们在原子任务上做两项实验：每项任务分别使用 50 条人类示范或 50 条合成示范。只用 50 条是为了与每任务仅提供 50 条的人类划分一致，并突出少样本下游场景，因为这比大量示范微调更能反映先验泛化。

结果。 表 4 显示，JALA 在两个 RoboCasa 划分上都持续超过重建式基线和消融。合成数据上的优势尤其明显，因为预训练视频与下游示范的域差距更大。JALA-act 在相同动作可用子集上再次超过 Being-H0，去掉解耦 EMA 则急剧退化，证实该更新的必要性。在骨干和数据完全相同时，LAPA† 与 JALA 之间持续存在的差距进一步支持：少样本迁移中，联合对齐优于重建目标。

6.3.3 GR1 桌面实验

设置。 LIBERO 与 RoboCasa 使用平行夹爪，GR1 桌面任务则使用灵巧手末端执行器，其形态更接近预训练视频中的人手。因此，GR1 特别适合检验来自人类的操作先验能否迁移到形态相似但不同的机器人。我们使用单个第三人称相机，每任务 50 条示范。

结果。 表 4 中，JALA 在 GR1 上以 26.33% 达到最高成功率，明显超过 GR00T N1.5（20.41%）、LAPA（11.42%）和 Being-H0（12.91%）。相对 Being-H0 的增益尤其突出：在同一动作可用子集上，JALA-act 为 20.25%，几乎是 Being-H0 的两倍，说明下游机器人形态偏离预训练数据时，联合对齐尤其有益。LAPA† 虽使用相同骨干和数据，也仅为 13.50%，再次证明改进来自训练目标，而非数据或架构。

表 4：RoboCasa 与 GR1 成功率（%）。

模型	RoboCasa 合成	RoboCasa 人类	GR1 桌面
GR00T N1.5	20.83	35.17	20.41
LAPA	16.25	22.42	11.42
Being-H0	23.83	31.33	12.91
JALA-act	24.92	32.42	20.25
JALA w/o dec.	14.25	19.33	9.25

模型	RoboCasa 合成	RoboCasa 人类	GR1 桌面
LAPA†	20.25	27.33	13.50
JALA★	25.33	33.83	24.50
JALA	27.58	35.42	26.33

6.3.4 消融研究

我们用 JALA-dino 在 LIBERO 上做两项消融，验证：（1）扩展到非受控人类视频的能力；（2）预测嵌入相对其他隐藏状态的作用。

扩展到野外数据。 固定实验室标注数据，将预训练野外数据比例设为 0%、25%、50%、100%。图 6 左显示，野外数据增加时，下游成功率持续提升，证实框架具有很强的规模扩展潜力。

流匹配输入消融。 JALA-dino 预训练时始终用第 19 层进行对齐，只改变下游适配时向流匹配头提供输入的层，比较第 14、19、24、28 层。图 6 右显示，第 19 层迁移最好，第 14 层稍差，后面的层则急剧退化。这可能说明，对齐把可泛化线索集中在选定层，而更深层过拟合数据集特定细节，降低了对下游控制的效用。

【图 6：在 LIBERO 上对 JALA-dino 进行的消融。左：预训练使用不同比例野外数据时的性能。右：适配时把骨干不同层的隐藏状态输入流匹配头时的性能。】

6.3.5 重建与联合对齐

三个仿真基准都显示重建式基线与联合对齐之间存在一致的经验差距。JALA 在双视角 LIBERO（表 2）上超过 LAPA 和 LAPA†，在 RoboCasa 和 GR1（表 4）上的增益更大，包括形态变化与少样本设置。LAPA 等重建目标提供密集像素监督，可能对野外视频的外观、背景和相机伪影赋予更多权重；尤其当手很小或部分遮挡时，这些信息不总与动作相关。联合对齐则用边界帧动态约束预测嵌入，产生更以行为为中心的信号，在数据稀缺或域变化很大时迁移得更好。

LAPA† 与 JALA 使用相同骨干和数据，因此性能差距反映的是重建与对齐的差别，而非骨干或数据规模。两种范式的训练效率也不同：在相同骨干和数据下，LAPA† 需要两阶段预训练（29 小时加 57 小时），JALA 在 8 张 A800 80GB 上只需 68 小时，即不到前者 80% 的墙钟时间，同时性能更好。像素重建虽提供密集目标，却容易放大野外视频中的背景变化或噪声，大量计算被花在与动作无关的信号上；JALA 则通过联合对齐提供更以行为为中心、与动作相关的梯度，因而更加有效且高效。

6.4 真实机器人实验

机器人系统。 真实平台由 7 自由度 Franka Research 3 机械臂和 6 自由度 Inspire 灵巧手组成。Inspire 手能独立驱动拇指、食指、中指、无名指和小指，还能横向旋转拇指，支持丰富的强力抓取与精细抓取。固定位置安装的 Intel RealSense L515 深度相机采集第三人称 RGB 观察。策略接收 RGB 帧及机器人本体感知状态（关节位置和夹爪配置），输出待执行的动作块。

任务设计。 三个多步骤操作任务考查互补的灵巧控制能力（图 8）。（1）Put-Three-Obj：打开抽屉，把三个水果放进去，再关闭抽屉；共五个有序子任务，考查多物体定位、连续抓取放置和长时程协调。（2）Wipe-Board：抓起抹布，擦拭白板笔迹并移除可见墨水；共三个子任务，要求持续平面接触、遮挡下的区域感知和反复擦拭。（3）Water-Plant：抓住喷壶，重新朝向植物并扣动扳机；共三个子任务，考查细粒度多指协调和空间推理。Put-Three-Obj 与 Water-Plant 使用单固定视角，Wipe-Board 使用双视角，以减轻擦拭时机械臂造成的遮挡。

【图 7：三个真实操作任务的遥操作示范。上：Put-Three-Obj，打开抽屉，依次抓放三个水果，再关闭抽屉。中：Wipe-Board，抓起抹布，擦过标记区域，移除大部分可见墨水。下：Water-Plant，抓住喷壶，朝植物重新定位，再扣动扳机。】

【图 8：三个多步骤真实机器人任务的环境。Put-Three-Obj 和 Wipe-Board 包含未见变体，用于评估对视觉变化的稳健性。】

数据收集与评估协议。 每任务收集 50 条由人类操作员遥控机械臂—灵巧手系统完成的示范。每条示范配有第三人称 RGB 观察和文本任务指令，用于下游后训练（图 7）。每任务评估 10 次 rollout，以完成子任务的平均比例（完成率）为成功指标。为评估视觉分布变化下的泛化，两个任务另设未见变体：Put-Three-Obj 把桌布换成未见纹理，Wipe-Board 把记号笔换成训练分布外的颜色（图 8）。Water-Plant 背景本已相对简单稳定，故不设未见变体。

表 5：真实机器人多步骤任务的平均子任务完成率（%），每个策略每任务评估 10 次。

模型	Put-Three-Obj 已见	Put-Three-Obj 未见	Wipe-Board 已见	Wipe-Board 未见	Water-Plant 已见
Being-H0	38.0	16.0	40.0	33.3	36.7
GR00T N1.5	48.0	28.0	56.7	43.3	53.3
JALA w/o align	40.0	32.0	53.3	43.3	56.7
JALA-vjepa	38.0	34.0	66.7	60.0	66.7

模型	Put-Three-Obj 已见	Put-Three-Obj 未见	Wipe-Board 已见	Wipe-Board 未见	Water-Plant 已见
JALA-dino	60.0	58.0	83.3	80.0	73.3

定量结果。 三项任务中（表 5），JALA 都持续超过强基线和消融，JALA-dino 在每项任务上取得最高完成率。优势同时存在于已见和未见设置，并非来自某个有利场景。JALA 在多步骤物体放置和表面交互任务上提升明显，在 Water-Plant 上也保持强劲领先。这说明从人类视频学到的联合对齐潜动作空间能有效迁移到真实三维操作。

对视觉变化的稳健性。 在 Put-Three-Obj 与 Wipe-Board 的未见变体中，桌布或记号笔颜色变化会使基线性能大幅下降，JALA-dino 则稳定得多，例如 Put-Three-Obj 仅从 60.0% 降至 58.0%。这说明 JALA 较少依赖表面外观线索，更多依赖与动作相关的动态和交互结构。JALA w/o align 尤其在未见设置中持续不及完整模型，也支持这一解释：与潜动作对齐是学习能在域变化和物理变化下保持有效的表征的关键。真实机器人实验说明，JALA 不仅提高多步骤操作成功率，也增强环境变化下的稳健性和可迁移性。

成功 rollout 分析。 我们定性分析成功执行（图 9、10）。Put-Three-Obj 中，策略对不同形状物体表现出准确空间推理、精确的抓取前对齐和稳定抓取。未见设置中出现了值得注意的行为：抓香蕉时，由于弯曲几何形状和变化后的桌布纹理，初次接近略有偏差；策略没有贸然提起，而是回撤、重新调整手腕，第二次正确抓住。该自我纠正动作未受显式监督，而是从潜动作建模中产生，说明策略内化了由反馈驱动的恢复策略。Wipe-Board 中，墨迹很少一次擦净，策略会反复调整抹布方向并重新访问残余区域，体现闭环适应而非固定轨迹；未见颜色下仍保持这种迭代修正，显示对新视觉分布的强泛化。Water-Plant 中，策略稳定抓住喷壶并可靠地朝植物重新定向；需要精确多指协调的扣动扳机也执行干净，没有过早松手。

失败模式分析。 Put-Three-Obj 的失败源自感知—控制失配的累积：预测抓取前姿态的细微空间偏移使手指以错误角度接触水果；即使接触成功，手指闭合不足或手腕方向小误差也会使水果在搬运中滑落，细长香蕉的几何形状尤其会放大扭矩不稳定。Wipe-Board 有两个主要失败因素：抹布有时没有足够用力或平整地压在白板上，导致折叠或失去平面接触；模型偶尔不再擦拭痕迹较淡的区域，说明闭环感知有时低估浅色墨迹。Water-Plant 的多数失败来自错误的可供性推理：策略虽抓住喷壶，却相对植物或扳机以错误方向放置，无法让喷嘴朝向目标，或无法让食指驱动方向对准扳机。这些案例凸显了精确对齐、接触稳定性和细粒度可供性建模方面仍存在的挑战。

【图 9、图 10：JALA 在三个真实机器人任务中的成功执行示例。】

【图 11：三个真实机器人任务中的代表性失败案例。】

7 结论

本文提出 **JALA**，一种重新思考潜动作表示方式的预训练框架，面向利用人类视频开展可扩展 **VLA** 预训练。通过让 **VLA** 上下文中的预测嵌入与 **IDM** 得到的潜动作联合对齐，**JALA** 超越了重建负担沉重的范式，转而在不引入细节失真的情况下捕捉运动线索。这一设计形成统一潜动作空间，能在实验室标注数据和野外人类数据上保持一致作用。

为支持大规模预训练，我们构建了 **UniHand-Mix**：一个包含 750 万个样本的数据集，融合超过 2,000 小时的有标注与非受控人类视频。该混合资源既提供可靠的物理锚点，也提供广泛的任务多样性；实验表明，**JALA** 能有效利用这两种来源。结果显示，**JALA** 大幅改善手部运动生成，并提升下游机器人操作基准性能，超过模型规模相当或更大的现有 **VLA** 方法。

总体而言，我们的研究表明，预测嵌入是连接人类视频数据与机器人学习的一条实用且可扩展的路径。我们相信，这一视角将为从规模更大、更多样的人类语料中学习创造新的机会。