

从视频进行潜动作预训练

原文: *Latent Action Pretraining from Videos*, ICLR 2025. Seonghyeon Ye 等。

摘要

我们提出潜动作预训练 (Latent Action Pretraining), 这是第一种无需真实机器人动作标签即可预训练视觉-语言-动作 (VLA) 模型的无监督方法。现有 VLA 模型通常需要在预训练阶段由人工遥操作员采集动作标签, 这严重限制了可用数据来源和规模。本文提出一种从互联网规模视频中学习的方法, 而这些视频没有机器人动作标签。我们首先利用基于 VQ-VAE 的目标训练动作量化模型, 从图像帧之间学习离散潜动作; 随后预训练潜 VLA 模型, 根据观测和任务描述预测潜动作; 最后在小规模机器人操作数据上微调 VLA, 把潜动作映射为机器人动作。

实验表明, 我们的方法显著优于利用大规模视频训练机器人操作策略的现有技术。在需要语言条件、未见物体泛化以及对未见指令进行语义泛化的真实操作任务上, 它还优于使用机器人动作标签训练的先进 VLA 模型。仅使用人类操作视频训练也能产生正迁移, 说明机器人基础模型有可能利用互联网规模的数据。我们将公开模型检查点和代码: latentactionpretraining.github.io。

1 引言

机器人视觉-语言-动作模型通过将大语言模型与视觉编码器对齐, 再在多样化机器人数据集上微调来训练; 这使模型能够泛化到新指令、未见物体和分布变化。然而, 多样化的真实机器人数据集大多需要人工遥操作, 因此难以扩展。另一方面, 互联网视频以大规模方式提供了丰富的人类行为和物理交互示例, 为克服小型、专门化机器人数据集的限制提供了有希望的途径。

但从互联网视频学习存在两个主要挑战。第一, 网络上的大量原始数据没有明确的动作标签; 第二, 网络数据的分布与典型机器人系统的具身形态和环境存在根本差异。为此, 我们提出潜动作预训练: 一种无需真实机器人动作标签的机器人基础模型无监督预训练方法 (图 1)。

潜动作预训练依次学习两个模型, 之后再通过微调把潜动作映射为真实机器人动作。在第一阶段, 我们使用基于 VQ-VAE 的目标, 在原始图像帧之间学习量化的潜动作。类似

于语言建模中的字节对编码（BPE），这可以看作学习对原子动作进行分词，而不需要预先规定末端执行器位置、关节位置等动作先验。第二阶段进行行为克隆：预训练视觉语言模型，根据视频观测和任务描述预测第一阶段得到的潜动作。最后，在带有机器人动作的小规模操作数据集上微调模型，学习从潜动作到机器人动作的映射。本文将得到的 VLA 模型称为 LAPA。

【图 1：问题形式化】左侧比较大规模机器人数据集和互联网规模视频数据：前者采集昂贵、需要机器人硬件但含机器人动作，后者广泛可得却存在人-机差距且没有机器人动作。LAPA 旨在从无动作标签的人类运动视频构建通用机器人基础模型。

我们在多种操作视频上评估性能，包括现有机器人视频数据集（不使用真实动作）和人类操作数据集。结果显示，特别是在跨环境和跨具身形态场景中，所提方法显著优于不使用真实动作标签训练操作策略的基线。在真实操作任务上，我们的方法产生了新的单体式 VLA 模型，超过当前先进的 OpenVLA；后者是在包含真实动作标签的多数据集混合数据上训练的。这证明了在具有不同具身形态的机器人数据集之间学习统一量化潜动作表示的有效性（见第 5.2 节）。

我们还证明，即使只在人类操作视频上预训练，潜动作预训练仍然有效，并且优于在 Bridgev2（最大的开源机器人数据集之一）上预训练的模型。我们观察到，LAPA 能有效捕获以环境为中心的动作，包括物体和相机运动，这可能有利于导航或动态、非准静态任务。我们预计，该方法能够通过更大规模的网络视频上预训练，为机器人构建基础模型。

主要贡献和发现如下：

- 提出潜动作预训练，一种从互联网规模视频中编码机器人技能的机器人基础模型无监督预训练方法。
- 在仿真和真实机器人任务上的实验表明，该方法不仅显著优于不使用真实动作标签进行预训练的机器人操作策略基线，还得到一个超过当前真实动作监督 VLA 的模型（提升 6.22%），同时预训练效率高出 30 倍以上。
- 定性地证明，可以把 LAPA 用作动作预测模型，把潜动作量化模型的解码器用作世界模型：根据当前观测和 LAPA 预测的潜动作生成未来帧，从而完全通过神经推理构建能够闭环评估的神经模拟器。

2 相关工作

视觉-语言-动作模型

在大规模互联网文本、图像和视频数据上训练的视觉语言模型，已经表现出理解和生成文本及多模态数据的强大能力。近期的单体式 VLA 模型在此基础上用机器人动作数据进行微调，以增强物理落地能力。加入视觉轨迹、语言推理路径，或从机器人轨迹构造对话式指令数据等辅助目标，进一步提升了 VLA 性能。然而，这些方法仍依赖带标签的动作数据，限制了可扩展性。相比之下，我们的方法只在微调阶段需要带标签动作，减少了对人工遥操作数据的依赖。

从视频训练机器人策略

视频为机器人学习提供了丰富数据，但大多数视频没有动作标签。相关工作在第一人称人类视频上预训练视觉编码器以改善视觉表示，或训练视频生成模型来生成未来机器人轨迹；还有一些方法从人类视频中提取交互、可供性或视觉轨迹等特征。部分工作将人类运动重定向为机器人动作，使用手部姿态估计器或动作捕捉系统；这些策略通常针对特定任务，或需要同一环境中对齐的人类和机器人数据。另一些工作训练逆动力学模型、光流模型或强化学习模型，根据世界模型生成的未来状态轨迹预测动作，也有工作使用逆动力学模型进行主动学习。

潜动作

以往工作在不同场景使用潜动作。GENIE 将用户输入（真实动作）映射到潜空间，使生成模型能够创建交互式环境。我们采用类似的潜动作模型，但用它为无动作标签数据赋予标签，从而训练单体式 VLA 解决机器人任务。也有工作使用潜动作预训练和微调电子游戏策略。与这些工作不同，我们关注从现实世界的人类运动中学习潜动作，以处理更复杂、连续的机器人任务。另一些方法把真实动作转换到潜空间，以捕获更好的多模态性和任务语义；我们的方法则直接从观测而非真实动作中得到潜动作。

3 LAPA：通用动作模型的潜动作预训练

潜动作预训练依次学习两个模型：潜动作量化和潜预训练。整体流程见图 2。潜动作量化和潜预训练使用相同的预训练数据集。

3.1 潜动作量化

为以完全无监督的方式学习潜动作，我们按照 Bruce 等人的方法训练潜动作量化模型，并作出若干修改。模型是编码器-解码器结构：编码器接收视频当前帧 x_t 和固定窗口 H 后的未来帧 x_{t+H} ，输出潜动作 z_t ；解码器接收 z_t 和 x_t ，重建 x_{t+H} 。与原方法

不同，我们使用交叉注意力，在给定 x_t 的条件下关注 z_t ，而不是使用相加嵌入；实验上这能捕获语义更明确的潜动作。

量化模型是 C-ViViT 分词器的变体。编码器包含空间和时间 Transformer，解码器只包含空间 Transformer，因为模型输入只有两帧图像。训练目标基于 VQ-VAE：从连续嵌入对应的嵌入空间中检索最近的量化表示，每个嵌入对应 codebook 中的一个条目。VQ-VAE 目标使潜动作 z_t 成为离散 token，便于 VLM 预测。潜动作由 $|C|$ 个 codebook 词表中的 s 个 token 组成； s 由量化前 CNN 的核大小、步长和填充决定。

为避免 VQ-VAE 中常见的梯度坍塌，我们使用 NSVQ，将量化误差替换为原始误差与归一化噪声向量的乘积。解码时对当前帧 x_t 的 patch 嵌入停止梯度，以避免表示坍塌。训练早期采用 NSVQ 的 codebook 替换技术，提高 codebook 利用率。更多模型和训练细节见附录 A。

我们把潜动作量化模型的编码器用作潜预训练中的逆动力学模型，把解码器用于生成基于神经网络的闭环轨迹。不同于只训练世界模型或只训练策略的工作，我们同时训练一个由潜动作生成轨迹的世界模型，以及一个通过潜预训练产生潜动作的策略模型。

【图 2：潜动作预训练概览】（1）潜动作量化：用 VQ-VAE 目标以完全无监督的方式学习离散潜动作。（2）潜预训练：VLM 预测潜动作，本质上执行行为克隆。预训练后，在少量带动作标签的轨迹上微调 LAPA，将潜空间映射到末端执行器增量动作空间。

3.2 潜预训练

我们使用潜动作量化模型的编码器作为逆动力学模型：给定 x_{t+1} ，为所有当前帧 x_t 标注潜动作 z_t 。随后使用预训练 VLM，根据视频片段的语言指令和当前图像 x_t 预测 z_t ，进行动作预训练。我们不使用 VLM 原有的语言模型头，而是接入一个独立的潜动作头（单层 MLP），其词表大小为 $|C|$ 。默认情况下冻结视觉编码器，解冻语言模型。

由于潜预训练不依赖真实动作，它可以使用任何与语言指令配对的原始视频。与机器人中常用的末端执行器位置、关节位置、关节力矩等动作粒度不同，我们不需要关于动作层级或粒度的先验；动作以端到端方式学习，只需优化为最好地捕获给定视频数据集中连续观测之间的“增量”。凡经过潜预训练的模型，我们统称为 LAPA。

3.3 动作微调

预训练为预测潜动作的 VLA 不能直接在真实机器人上执行，因为潜动作不是实际的末端执行器增量或关节动作。为映射到实际机器人动作，我们在少量含真实增量末端执行器动作的标注轨迹上微调 LAPA。对于动作预测，按照已有 VLA 工作，将每个机器人动作

维度的连续空间离散化，使每个 bin 分配到的数据点数量相等。随后丢弃潜动作头，用动作头替换它，并在机器人数据上进行监督微调。

4 实验

4.1 基准与环境

我们在仿真和真实世界评估 LAPA。仿真使用 SIMPLER，包含从真实机器人数据重放的任务，并测试域内物体、未见物体、未见环境和未见指令。我们还使用 Language Table，它要求机器人根据语言指令在桌面上移动物体。真实世界实验在桌面操作平台上进行，包含敲倒物体、覆盖物体和抓取放置等任务。预训练数据分别来自 Bridgev2、Open-X Embodiment 和人类操作视频；微调使用少量带动作标签的机器人轨迹。

4.2 基线

我们比较从头训练 (Scratch)、仅视觉预训练、视频预训练以及使用真实机器人动作标签预训练的模型。主要基线包括 UniPi、VPT、ACTION VLA 和 OpenVLA。所有模型在相同的微调数据和评估任务上比较。LAPA 的预训练阶段不使用真实动作标签，因此能公平检验无标签视频预训练的效果。

4.3 Language Table 结果

在 Language Table 上，LAPA 在平均成功率上显著超过 Scratch 以及其他视频预训练基线。它在未见物体和未见指令设置下仍保持优势，说明潜动作预训练不仅记忆视觉外观，还学习了与语言条件相关的运动先验。使用更大、更丰富的 Open-X 数据预训练通常带来正迁移；这表明继续扩大预训练数据的规模和多样性仍有收益。

4.4 真实世界结果

真实桌面实验显示，LAPA (Open-X) 在多数任务和泛化设置上优于 OpenVLA (Open-X)，并在不同机器人形态和数据集之间利用共享的潜动作空间。OpenVLA 在抓取放置任务上有时更好，但 LAPA 的大多数失败来自过早抓取；在到达任务上 LAPA 的成功率为 83.33%，高于 OpenVLA 的 66.67%。这说明 LAPA 具有更强的语言条件和粗粒度规划能力，但抓取等精细技能仍需更多带标签轨迹。每条轨迹中抓取只发生一到两次，150 条标注轨迹可能不足以让 LAPA 根据不同物体的物理特征准确预测抓取动作。

Open-X 预训练模型优于 Bridgev2 预训练模型，表明扩大预训练数据能为下游任务带来正迁移。相比 OpenVLA，LAPA 在三项任务中的两项显著更好，并在所有泛化设置上超过 OpenVLA。我们认为，这是因为 LAPA 在多具身形态数据上学习了共享的潜动作空间；传统动作预训练受不同机器人和数据集动作表示差异影响，数据集之间的正迁移可能较弱。

4.5 从人类操作视频学习

【图 4：人类视频预训练结果】左图为 SIMPLER，右图为真实桌面机器人；比较 Scratch、OpenVLA（Bridge）、LAPA（Bridge）和 LAPA（Human Videos）的平均成功率及标准误。

本节把潜动作预训练扩展到人类操作视频。与机器人轨迹相比，人类视频同时面临没有动作标签以及人类分布与机器人具身形态不同两个挑战。我们在 Something-Something V2 数据集上预训练，该数据集包含 22 万段人类使用日常物体执行动作的视频。

在 SIMPLER 上，LAPA（Human Videos）超过 Scratch，说明即使预训练数据分布与部署环境不同，人类视频仍能通过潜动作预训练带来正迁移。它也超过使用同一人类视频训练的 UniPi 和 VPT，表明潜动作预训练对人到机器人的具身形态变化具有鲁棒性。由于人类视频没有机器人动作标签，ACTION VLA 无法训练。

真实机器人实验中，LAPA（Human Videos）的平均表现意外地超过 OpenVLA（Bridge）。尽管 LAPA 面临更大的具身差距（人到机器人，而非机器人到机器人），它仍学到了更好的机器人操作先验。它在未见物体上尤其具有良好泛化，这可能是因为 Something-Something V2 涉及的物体比 Bridgev2 更丰富。结果凸显了网络人类操作视频相对于昂贵机器人数据的潜力；后者需要耗时的遥操作采集。将方法应用到 YouTube 等大规模互联网视频，可能实现通用动作基础模型的大规模预训练。

4.6 预训练效率

LAPA 的优势还体现在预训练效率上。表现最佳的 LAPA（Open-X）使用 8 张 H100 GPU 训练 34 小时，批大小为 128，总计 272 个 H100 小时。相比之下，OpenVLA 使用批大小 2048，总计需要 21,500 个 A100 小时。尽管 LAPA 的预训练效率高约 30 至 40 倍，它仍超过 OpenVLA。

我们认为效率来自两个因素：第一，使用 Large World Model 作为骨干 VLM；第二，LAPA 的动作比传统动作预训练更粗粒度。LWM 预训练目标包括生成下一状态，即视频中的下一帧，这可能使模型隐式理解视频中的高层动作。ACTION VLA（Bridge）和 OpenVLA（Bridge）使用相同数据和目标，但前者使用 LWM 骨干，只需 3 个 epoch 就

达到最佳动作 token 准确率，OpenVLA 则需要 30 个 epoch。其次，LAPA 的动作空间远小于 OpenVLA (84 对 256)，使从感知和语言生成动作更容易学习。对于 Bridgev2、Open-X 和 Human Videos 的所有 LAPA 模型，一个 epoch 就足以达到最佳性能。

5 消融与分析

5.1 模型、数据和潜动作规模扩展

大语言模型显示出规模定律：增大模型、数据集和训练计算资源会提升性能。我们分析 LAPA 在三个维度上是否也受益：潜动作量化模型大小、数据规模和潜动作表示空间。控制实验在 Bridgev2 上进行，再在 SIMPLER 上微调（图 5c 的 Language Table 除外）。

【图 5：LAPA 规模扩展消融】分别扩大模型参数量（百万）、数据规模（相对于 Bridgev2 的比例）、潜动作序列长度和词表大小，并报告 SIMPLER 微调任务的平均成功率。

结果显示，三个维度的扩展都能使 LAPA 受益。有趣的是，潜动作空间的最佳规模取决于预训练数据中的动作复杂度。例如，在 Language Table 中，增加潜动作序列长度不如增加词表有效。除 Language Table 外，主要实验始终将 LAPA 的生成空间保持为 84。结果说明，当预训练扩展到超越操作视频的互联网规模视频时，同时扩展模型、数据集和潜动作空间，尤其有助于捕获全身控制等更高动作维度。

5.2 潜动作分析

我们定性分析量化潜动作与真实连续动作的对应关系。为便于解释，将当前图像观测 x_1 和每个潜动作输入潜动作量化模型的解码器，展示重建图像。

在 Language Table 中，每个潜动作对应机器人手臂的一种明确运动，潜动作在实际二维动作空间中形成良好聚类（附录 E 的图 12、13）。在人类操作视频中，相机视角变化也会对应潜动作，因为视频内视角发生了改变（附录 E 的图 14）。我们还分析包含多种具身形态、任务和环境的 Open-X。尽管具身形态和环境不同，在解码器中使用相同潜动作会在重建图像中产生相似动作。这支持了潜动作在不同具身形态和数据集之间学习共享表示空间的结论，并解释了多数据集之间更强的正迁移。

【图 6：潜动作分析】潜动作示例及其语义： $[1, 1, 3, 2]$ 表示向下、向左， $[3, 2, 0, 1]$ 表示向上， $[4, 2, 4, 1]$ 表示向右并旋转， $[5, 1, 2, 7]$ 表示向下，

[5, 3, 5, 2] 表示向左并旋转, [6, 7, 0, 2] 表示向上、向左。

我们还通过闭环轨迹定性分析 LAPA 的粗粒度规划能力。使用只经过预训练、没有动作微调的 LAPA。由于它生成的潜动作不能直接在真实世界执行, 我们把当前观测 x_1 和 LAPA 预测的潜动作输入潜动作量化模型解码器。如图 7 所示, 给定“把西兰花从锅里拿出来”的指令, LAPA 生成的轨迹成功接近西兰花、向下移动并抓取; 手臂离开锅时, 西兰花消失。

【图 7: LAPA 的闭环轨迹】LAPA 根据当前图像和指令生成潜动作, 量化模型解码器据此逐帧生成未来图像。

这表明 LAPA 不仅能预测动作, 也能预测动作结果, 具有作为通用机器人世界模型的潜力。例如, 可以把它扩展为任务与运动规划系统: 先根据自然语言任务指令生成多个计划, 再利用评估多个候选轨迹成功率的方法选择最优轨迹, 并执行开环或闭环推理。这可能形成通过扩展测试时计算量来提升性能的范式, 类似于大语言模型。

6 局限与结论

本文提出潜动作预训练, 一种无需真实动作标签、可扩展的 VLA 预训练方法。在涵盖仿真和真实机器人实验的三个基准上, 我们证明, 与现有方法相比, 该方法显著改善了向下游任务的迁移。我们还给出了一个先进 VLA 模型, 它超过了在 97 万条带动作标签轨迹上训练的当前模型。此外, 我们证明该方法可以完全在人类操作视频上应用: 这些视频没有显式动作信息, 且存在显著的具身形态差距。

LAPA 仍有一些局限。第一, 在抓取等需要精细运动生成的任务上, LAPA 不如动作预训练。扩大潜动作生成空间可能有助于解决这一问题。第二, 与此前 VLA 类似, LAPA 在实时推理中也面临延迟问题; 可以采用分层架构, 让更小的动作头以更高频率预测动作。最后, 虽然我们定性展示了潜动作空间能够捕获相机运动 (图 14), 但尚未探索 LAPA 在操作视频之外的应用, 例如自动驾驶、导航或自然景观视频。这些问题留待未来工作。