

通过世界建模进行潜动作预训练

原文：Latent Action Pretraining Through World Modeling。arXiv:2509.18428v2, 2026 年 6 月 13 日。

以下按原文顺序翻译，保留公式、图表和实验数字。

摘要

视觉—语言—动作（VLA）模型在学习遵循语言指令的机器人操作任务方面日益流行。OpenVLA 和 $\pi 0$ 等先进 VLA 使用通过遥操作采集的大规模人工标注动作数据集训练。较新的 LAPA 和 villa-X 引入潜动作表示，通过建模帧间抽象的视觉变化，支持在未标注数据集上进行无监督预训练。尽管这些方法表现良好，但较大的模型规模使真实场景部署变得困难。

本文提出 LAWM：一个与模型无关的框架，通过世界建模从未标注视频中学习潜动作表示，以自监督方式预训练模仿学习模型。视频可以来自机器人录像，也可以来自人类操作日常物体的视频。框架能够在任务、环境和具身形态之间迁移知识；在 LIBERO 和真实环境中，它超过使用真实机器人动作预训练的模型及其他类似方法，同时保持真实部署所需的效率和实用性。

1 引言

自监督学习推动了 ChatGPT 和 Gemini 等大语言模型的突破：模型从互联网的大量文本中学习。受此启发，机器人研究也可以从原始、非结构化视频中直接学习动作表示，而不再依赖整理好的动作标签。

当前机器人学习方法大多依赖监督学习。模仿学习和 OpenVLA、 $\pi 0$ 等 VLA 需要图像—动作配对数据，这些数据通常通过遥操作获得。动作标注采集昂贵、难以扩展且容易带有偏差，限制了系统在不同任务、环境和具身形态之间的泛化。

LAWM 将模仿学习模型和世界模型结合起来。第一阶段给定当前图像和语言指令，模仿学习模型预测动作块表示；世界模型利用潜动作逐步预测未来帧。第二阶段只使用带标签的下游机器人数据微调模仿学习模型，并丢弃世界模型。

【图 1：左侧为人类示范视频预训练，右侧为机器人动作下游微调。】

【图 2：潜动作预训练阶段由当前图像和指令预测潜动作，再通过世界模型预测下一帧；动作微调阶段把图像、语言和机器人状态映射为真实动作。】

本文贡献如下：

1. 提出与模型无关的 LAWMM，从无动作标签的机器人视频和人类视频中学习模仿学习动作块表示。
2. 证明不使用真实动作标签，也能从人类示范和机器人操作视频中学习有用的动作先验。
3. 证明结合小型 Diffusion Policy 或 DreamerV3 的 LAWMM 在 LIBERO 上优于 villa-X。

2 相关工作

2.1 模仿学习

模仿学习直接把观测映射为专家动作。OpenVLA 是 70 亿参数模型，使用 DINOv2 和 SigLIP 双视觉编码器，在 Open X-Embodiment 的 97 万条真实机器人示范上训练。 π_0 是 33 亿参数 VLA，使用预训练 VLM 继承互联网知识。轻量模型 BAKU 约 700 万参数，通过 FiLM 条件编码器和 MLP 融合视觉、本体感觉和任务指令。Diffusion Policy 将控制建模为条件去噪扩散过程；ACT 预测未来动作块，以减少长任务中的误差累积。

2.2 世界模型

世界模型学习环境动力学表示，为规划和控制提供支持。Dreamer 系列采用循环状态空间模型（RSSM），把状态编码为随机表示，并根据过去动作预测未来状态。DreamerV3 支持从 100 万到 2 亿参数的不同规模。

2.3 潜动作方法

先前工作包括在人类第一视角视频上预训练视觉编码器、将人类运动重定向到机器人，以及使用逆动力学模型预测动作。LAPA 使用三阶段流程学习潜动作，但存在框架复杂、推理延迟和计算成本高的问题。UniVLA 使用 DINOv2 特征和语言条件分离任务相关动力学。villa-X 在潜动作模型中加入本体感觉前向动力学模型，预测未来关节角和夹爪状态，但微调时仍需要潜动作模块。

3 方法

LAWM 包含潜动作预训练和动作微调两个阶段。

3.1 潜动作预训练

给定当前图像 x_t 和语言指令 c ，模仿学习模型 IL_{θ} 预测 n 个潜动作：

$$z_{t:t+n-1} = IL_{\theta}(x_t, c). \quad (1)$$

潜动作不接受真实机器人动作监督，而是作为世界模型输入。世界模型 WM_{ϕ} 从当前帧初始化，依次使用潜动作预测接下来的 n 帧：

$$\hat{x}_{t+1:t+n} = WM_{\phi}(x_{t:t+n-1}, z_{t:t+n-1}). \quad (2)$$

实现中，世界模型采用 DreamerV3 的 RSSM。在第 k 步，模型根据前一状态和潜动作更新确定性状态，并预测随机状态和下一帧：

$$h_{t+k} = f_{\phi}(\hat{s}_{t+k-1}, z_{t+k-1}),$$

$$u_{t+k} \sim q_{\phi}(u_{t+k} | h_{t+k}, x_{t+k}),$$

$$\hat{u}_{t+k} \sim p_{\phi}(\hat{u}_{t+k} | h_{t+k}),$$

$$\hat{x}_{t+k} \sim p_{\phi}(\hat{x}_{t+k} | \hat{s}_{t+k}).$$

其中 s_{hat} 等于 h 和 u_{hat} 的拼接。模仿学习模型和世界模型通过下一帧重建联合优化：

$$\mathcal{L}(\theta, \phi) = \frac{1}{n} \sum_{k=1}^n \|x_{t+k} - \hat{x}_{t+k}\|_2^2 + \beta \mathcal{L}_{KL}(\phi). \quad (7)$$

这个目标迫使模仿学习模型产生能够解释环境动力学的潜动作，无需真实动作监督。

3.2 动作微调

预训练后丢弃世界模型，只在带真实动作的下游数据上训练 BAKU 或 Diffusion Policy。可以增加动作解码头，也可以重新初始化最后的潜动作层，使其匹配真实动作维度；本文实现采用后者。

观测包含一个或两个图像视角、语言指令和本体状态。模型输出动作序列，监督目标为：

$$\mathcal{L}_{IL}(\theta) = \frac{1}{n} \sum_{k=1}^n \ell_{act}(\hat{a}_{t+k-1}, a_{t+k-1}). \quad (8)$$

其中动作损失可以是 BAKU 的似然损失或 Diffusion Policy 的去噪损失。

4 实验

我们重点回答以下研究问题：

- **Q1：** 与使用真实动作进行预训练相比，LAWM 能否学习到更好的先验？
- **Q2：** 与 villa-X 等近期类似方法相比，LAWM 的表现如何？
- **Q3：** 学到的潜动作是否与真实动作相关？

4.1 基准与环境

我们在多种数据集和环境上评估 LAWM，涵盖大规模预训练和下游微调，包括大型机器人操作数据集 BridgeData v2、包含人类与日常物体交互视频的 Something-Something v2、机器人操作仿真基准 LIBERO，以及定制的真实机器人操作环境。这些基准覆盖了广泛的操作任务和评估设置。数据集、任务套件和环境的更多细节见附录 C。

4.2 基线与实验设置

我们使用两个模仿学习基线评估 LAWM：BAKU 和 Diffusion Policy。为回答 Q1 至 Q3，我们设计了以下实验。

E1：潜动作先验与真实动作预训练的比较。 在 LIBERO-90 上建立两个性能边界。第一，基线模型直接在 LIBERO-90 上从头训练。第二，基线模型先在 BridgeData v2 的真实动作上预训练，再在 LIBERO-90 上微调。为了将我们的方法与这两个边界比较，我们分别在没有动作标签的 Something-Something v2 和 BridgeData v2 上预训练 LAWM，随后在 LIBERO-90 上微调。

E2：与类似方法比较。 我们在 Something-Something v2 人类视频上预训练 Diffusion Policy，再在 LIBERO 的 Spatial、Object、Goal 和 Long 任务套件上微调，与 villa-X 和 UniVLA 保持相同设置，以便直接比较。我们还与其他使用真实动作监督预训练的先进模型，以及从互联网规模数据训练的 VLM 初始化的 VLA 进行比较。

E3：潜动作与真实动作的相关性。 为量化学到的潜动作与真实动作之间的相关性，我们使用典型相关分析（CCA）。CCA 为两组变量寻找线性变换，使变换后的表示具有最大相关性。给定潜动作 $Z \in \mathbb{R}^{n \times p}$ 和真实动作 $Y \in \mathbb{R}^{n \times q}$ ，CCA 寻找权重向量 $a \in \mathbb{R}^p$ 和 $b \in \mathbb{R}^q$ ，最大化变换变量 u 和 v 之间的相关性：

$$u = Za, \quad v = Yb. \quad (9)$$

CCA 产生成对的典型分量 (u_i, v_i) ，按从强到弱的顺序捕获潜动作和真实动作之间的线性相关性。第一对 (u_1, v_1) 称为第一典型分量，相关性最强。相关因子就是变换变量 u 和 v 之间的 Pearson 相关系数：

$$\rho = \frac{\text{cov}(u, v)}{\sqrt{\text{var}(u) \text{var}(v)}}. \quad (10)$$

其中， $\text{cov}(u, v)$ 表示协方差， $\text{var}(u)$ 和 $\text{var}(v)$ 表示方差。

5 结果与讨论

我们在 LIBERO 基准及其任务套件、真实环境上报告定量和定性结果，并讨论所得发现。我们使用 5000 万参数配置的 DreamerV3 世界模型，潜动作空间维度设为 7，与真实动作维度一致。BAKU 实验的动作块大小设为未来 10 个动作，Diffusion Policy 实验设为 16。性能使用成功率（SR）衡量，即成功试验次数占总尝试次数的百分比。结果取三个随机种子的结果；LIBERO 每个任务评估 30 次，真实环境每个任务评估 10 次。更多训练细节见附录 B。

R1：潜动作先验与真实动作预训练

我们在 LIBERO-90 任务上使用 BAKU 和 Diffusion Policy 作为基线。一个有趣的发现是：与世界模型结合后，在没有真实动作的机器人或人类视频数据上预训练，能够超过在动作标签上进行监督预训练。我们的假设是，动作监督预训练迫使模型把观测映射到动作，可能导致模型过拟合 BridgeData v2 的动作分布（特定机器人、轨迹和任务设置）。而世界模型预训练鼓励模型学习状态转移和动力学；与特定具身形态相关的动作相比，动力学在不同任务之间更普遍，因此在下游任务微调时具有更好的泛化性。

【图 4：不同预训练策略下 BAKU 和 Diffusion Policy 在 LIBERO-90 上的成功率。WM 表示不使用动作标签的世界建模预训练。】

LIBERO-90 结果

如图 4 所示，从头训练的 BAKU 和 Diffusion Policy 基线分别为 91.4% 和 85.7%。在 BridgeData 上进行监督预训练后，性能分别提高到 92.7% 和 91.9%。世界建模预训练进一步带来提升：使用 BridgeData 的世界建模预训练时，BAKU 达到 93.7%；使用 Something-Something 时达到 92.6%。Diffusion Policy 在相同设置下分别达到 93.0% 和 91.9%。这些结果表明，世界建模不仅降低了对动作标签的依赖，而且在不同模型上都能匹配或超过监督预训练。

真实环境结果

仅在 Something-Something v2 人类视频上预训练 LAWM，就能显著改善真实任务表现，在五个定制下游任务上达到接近完美的成功率。只使用定制数据集训练、没有预训练时，平均成功率为 84%；使用我们的预训练框架后提高到 94%。表 1 表明，世界建模不仅在仿真中有效，也能改善真实任务性能。图 3 给出了真实测试中的定性结果，展示了方法处理复杂真实场景的能力。

表 1：真实机器人操作环境中五个任务的成功率（%）。

模型	抓取放置 1	抓取放置 2	抓取放置 3	移 动	堆叠	平 均
BAKU，无潜动作	80.0	100.0	90.0	70.0	80.0	84.0
BAKU，有潜动作（本文）	90.0	100.0	90.0	90.0	100.0	94.0

R2：与类似方法比较

我们使用 Diffusion Policy 比较 LAWM 与 LIBERO 的 Spatial、Object、Goal 和 Long 任务套件上的其他先进模型。表 2 包含三类模型：第一类是在真实机器人动作上预训练的模型，包括 Octo、OpenVLA 和 $\pi 0$ ；第二类是从互联网规模数据训练的 VLM 初始化的模型，包括从 PaliGemma 初始化的 $\pi 0$ 和从 smolVLM 初始化的 smolVLA；第三类与本文目标相似，依赖人类视频、机器人视频或两者混合，包括 LAPA、UniVLA 和 villa-X。

我们首先在没有任何预训练的情况下训练 Diffusion Policy，得到一个低于 UniVLA 和 villa-X 的基线。随后在 Something-Something v2 上使用本文的预训练框架，进一步提升 Diffusion Policy，在所有任务套件上取得最佳平均成功率。

表 2：不同 LIBERO 任务套件上的基线性能比较。

模型	预训练方法	Spatial	Object	Goal	Long	平均
Octo	机器人动作	78.90	85.70	84.60	51.10	75.10
OpenVLA	机器人动作	84.70	88.40	79.20	53.70	76.50
$\pi 0$	机器人动作	90.00	86.00	95.00	73.00	86.00
$\pi 0$ (PaliGemma-3B)	VLM 检查点	87.00	63.00	89.00	48.00	71.80
SmolVLA (SmolVLM-2.25B)	VLM 检查点	93.00	94.00	91.00	77.00	88.75
LAPA	混合视频	73.80	74.60	58.80	55.40	65.70
UniVLA	人类视频	91.20	94.20	90.20	79.40	88.70
villa-X	混合视频	97.50	97.00	91.50	74.50	90.10
Diffusion Policy, 无潜动作	无	88.10	81.40	87.50	70.50	81.87
Diffusion Policy, 有潜动作 (本文)	人类视频	92.70	96.30	94.20	88.00	92.80

R3：潜动作与真实动作的相关性

我们按任务类型对动作分组，以评估不同操作任务之间的相关性。如表 3 所示，第一典型分量在所有任务类别中都具有很强相关性：放置为 0.9154，移动为 0.9599，移除为 0.9098，拿取为 0.9541。我们的方法在大多数任务上的相关因子优于 villa-X。这是因为我们的潜动作由以任务指令为条件的模仿学习模型预测，与真实动作更一致；相比之下，villa-X 依赖逆动力学模型，其潜变量主要捕获场景转移，而不是动作本身。

表 3：各任务组的 CCA 第一相关系数。

方法	放置	移动	移除	拿取
villa-X	0.7863	0.9174	0.9955	0.9270
LAWM (本文)	0.9154	0.9599	0.9098	0.9541

6 局限

尽管取得了上述改进，本文仍存在局限。第一，联合训练模仿学习模型和世界模型的计算成本可能很高，尤其是在使用近期 **VLA** 和数十亿参数世界模型时。第二，使用均方误差进行图像重建的世界模型已知会更重视像素准确性，而不是与任务相关的动力学，因而可能产生模糊或利用背景捷径。加入感知损失、光流损失或掩码建模，可能有助于减少捷径学习。第三，世界模型只在单视角视觉观测上训练，忽略了多视角输入、本体感觉数据和夹爪状态。这可能限制模型对操作动力学和场景几何的理解。加入这些信息源，可能帮助模型学习物理落地程度更高的潜动作。相关探索留待未来工作。

7 结论

本文提出 **LAWM**，一种通过世界建模从无标签视频中学习高质量动作表示的模仿学习潜动作预训练框架。我们证明，在 **LIBERO** 基准和真实环境中，与监督预训练相比，该方法能够改善下游任务性能。我们还证明，该方法可以应用于人类示范视频；这类视频缺少显式动作信息，并且存在显著的具身形态差距。**LAWM** 提供了一种无需动作标签即可学习动作先验的可扩展方式。我们预计，利用规模更大的网络视频预训练大型模型，将为构建机器人基础模型打开新的可能。