

LDA-1B：通过通用具身数据摄取扩展潜动态动作模型

原文：LDA-1B: Scaling Latent Dynamics Action Model via Universal Embodied Data Ingestion (2026)。

摘要

LDA-1B 是一个 16 亿参数机器人基础模型，在超过 3 万小时异构人类和机器人轨迹上训练。它把策略、动力学和视觉预测放进结构化 DINO latent 空间，并让不同质量的数据承担不同角色：高质量示范用于策略，带噪和无动作视频用于动力学与视觉先验。模型在仿真和真实接触丰富任务上明显超过 $\pi 0.5$ 等基线。

【图 1：EI-30k 数据统一格式；动作、未来视觉和策略在 DINO latent 中共同学习。】

统一世界模型

行为克隆只看“专家怎么做”，会丢掉大量非专家数据中的物理变化。LDA-1B 同时训练：

- **策略头**：根据观测和指令预测动作；
- **动力学头**：根据当前 latent 和动作预测未来 latent；
- **视觉预测头**：补充未来视觉表示。

预测 DINO 特征而非 RGB 像素，避免把容量浪费在光照、纹理和背景上。多模态 diffusion Transformer 处理异步视觉流与动作流，适合 1B 规模稳定训练。

数据摄取

EI-30k 把人类视频、机器人演示、无动作视频和低质量轨迹转换为统一时序格式。数据质量不再只有“保留/丢弃”两种状态：有动作标签的片段强化策略学习；无标签片段强化世界动力学；噪声片段仍可提供视觉和接触先验。

结果

在多种模拟、真实和接触丰富任务上，LDA-1B 相比 $\pi 0.5$ 的提升最高约 21%、48% 和 23%（不同任务组）。消融证明，去掉无动作视频或视觉预测会削弱泛化；只扩大高质量 BC 数据不能得到同样的收益。

架构和训练配方

模型以 DINO 特征作为状态空间，动作 token 与视觉 token 通过多模态 diffusion Transformer 交互。策略、动力学和视觉预测共享编码器，但使用独立输出头；对异步传感器流使用时间戳和 attention mask，而不是强行同步。动作 chunk 预测后由低层控制器插值执行。

EI-30k 的数据经过统一坐标、帧率和语言字段处理。高质量专家轨迹使用行为克隆损失，普通机器人视频使用未来 latent 预测，无动作人类视频只使用视觉/动力学损失。按质量分配任务让模型不会把噪声动作当作专家标签，同时仍能从噪声中学习物体运动。

失败模式

在训练集中完全没有相似接触模式时，动力学先验不能替代真实示范；透明物体、快速碰撞和严重遮挡也会影响 DINO 未来预测。论文因此把 LDA-1B 定位为统一预训练模型，而不是零样本控制器。

4. 为什么要摄取无动作数据

行为克隆只能利用带专家动作的高质量样本，而真实世界中大量视频没有动作标签，或动作质量参差不齐。LDA-1B 把这些数据分配给动力学和未来视觉预测任务：即使不知道操作者的控制量，也能观察到“物体被推开、门被打开、接触后发生位移”等物理变化。高质量动作再把这些变化与可执行控制对齐。

5. 统一世界模型的损失

对有动作样本，模型同时优化动作预测和未来 latent 预测；对只有视频的样本，只计算未来预测；对带语言的片段，还加入指令条件建模。可以概括为：

$$L = \lambda_a L_{\text{action}} + \lambda_d L_{\text{dynamics}} + \lambda_v L_{\text{visual}} + \lambda_t L_{\text{text}}.$$

不同数据源使用不同的有效损失 **mask**，而不是为每种数据单独训练模型。这样同一个 **backbone** 可以从示范学习“怎么做”，从无标签视频学习“做了之后会发生什么”。

6. 规模化结果

EI-30k 超过 3 万小时，模型规模为约 16 亿参数。论文报告在仿真、真实和接触丰富任务上相较 $\pi 0.5$ 的最高提升约为 21%、48% 和 23%。结果支持一个核心判断：数据质量很重要，但只保留最高质量数据并不是扩展机器人基础模型的最佳策略。

7. 四种训练任务

LDA 把数据按可用字段分配给四种目标：Policy 用当前观测预测动作；Forward Dynamics 用当前观测和动作预测未来 DINO latent；Inverse Dynamics 用当前与未来状态恢复动作；Visual Forecasting 只凭当前观测预测未来视觉 latent。高质量有动作数据可用于前三项，低质量动作数据更多用于动力学，无动作视频用于 Visual Forecasting。

视觉以约 3 Hz 编码，动作约 10 Hz，模型保留时间戳并处理异步 token。相机外参也被保留，以区分头部/相机运动与手部运动。所有原始数据先转换为 LeRobot 2.1 格式，再统一坐标、指令、质量标签和人手/夹爪字段。

8. 模型实现与详细结果

语言视觉编码器使用 Qwen3-VL-4B-Instruct，观测编码器使用冻结的 DINOv3-ViT-s。MM-DiT 隐藏维度为 1536，共 16 层、32 个注意力头，图像输入为 224×224，DINO latent 为 14×14×384，动作块长度为 16。预训练时冻结 VLM 和 DINO，后训练时解冻 VLM 做端到端适配。

RoboCasa-GR1 的 24 个任务中，LDA 平均成功率为 55.4%，高于 GR00T 的 47.6% 和在 EI-10k 上预训练的 GR00T 51.3%。优势主要出现在接触丰富、关闭容器和新物体重排任务。例如 Bottle → Cabinet Close 为 76% 对 51.5%，Can → Drawer Close 为 71% 对 13%。

真实实验使用 Galbot G1 和 Unitree G1，包括平行夹爪、22-DoF SharpaWave 灵巧手和 10-DoF BrainCo 手。LDA 在 handover 上达到 90%，flip box 为 60%，pouring 为 80%；论文将这些收益归因于显式动力学训练，而不仅是更大的行为克隆模型。

9 定性分析与多任务学习

潜在前向动力学

除了定量预测误差，作者还通过 DINO 特征嵌入的 PCA 投影，定性检查 LDA 学到的前向动力学。模型生成的未来状态预测遵循物理约束，包括物体持续存在、接触连续性，以及施加动作后的运动一致性。预测的动力学聚焦于与任务相关的物体，同时对不影响控制回路的视觉干扰保持不变。这说明 LDA 学到的是具有动力学意识的潜在世界模型，能够捕获动作如何因果地传播到场景中，而不是简单外推视觉外观。

【图 9：LDA 在 DINO 潜空间中的未来状态预测。预测轨迹保持物体、接触和运动的连续性。】

动作条件注意力

为理解 LDA 如何推理动作引起的状态转移，作者可视化了不同动作原语条件下的注意力图，并将主动运动指令与静止的 No-Op 指令产生的注意力差异作为动作特定的视觉落点。在不同任务中，LDA 始终关注与所命令交互具有因果关系的区域。

在“向右推动”场景中，注意力差异突出杯子的前缘和预期运动方向，反映出模型对物体位移的感知。在“推近”场景中，注意力集中在抽屉表面，即预计发生接触和施力的位置。背景杂乱以及视觉上显眼但不参与交互的区域基本被抑制。结果表明，LDA 会根据动作的物理后果选择性地关注驱动状态转移的区域，而不是静态外观。

【图 11：注意力热图。“向右推动”突出杯子的前缘和运动轨迹；“推近”集中在接触表面。模型只关注可移动区域，忽略无关背景。】

梯度相似性

作者测量了训练早期和后期不同训练目标之间的梯度余弦相似度。目标相同的任务从训练初期就高度一致，并且随训练继续而更加一致：策略和逆动力学都预测动作，视频生成和前向动力学都预测 DINO 特征。预测目标不同的任务在训练早期呈现弱负相关，但到训练后期这种竞争消失并转为正向对齐。这说明 LDA 会逐渐把异构目标组织到相互兼容的特征子空间中。

【图 12：训练 10k 次和 400k 次迭代时各目标之间的梯度余弦相似度。】

10 统一数据摄取的作用

有效利用异构具身数据，需要同时扩展数据来源和训练目标。实验显示，只有同时优化策略学习、动力学建模和视觉预测时，LDA 才能取得最佳性能。当数据规模或训练目标减少时，性能会明显下降。若只使用带动作标签的轨迹并采用 **Policy Only** 目标，扩大数据集会产生不稳定行为：中等规模扩展最初带来收益，但继续扩展并不稳定。

与 UWM 相比，LDA 在 0.1B 到 1B 的不同模型规模上都持续获得收益，并且随着训练数据增加而保持改进。UWM 的潜在表示源自 VAE，低层特征把外观、几何和动力学纠缠在一起，限制了模型分解动作导致的状态转移，也阻碍了异构监督信号在扩展过程中的复用。LDA 则在大规模视觉预训练得到的语义结构潜空间中工作，该表示保留物体级语义和空间一致性，使动力学学习可以随模型容量、训练目标和数据集多样性平稳扩展。

这些结果支持一种联合扩展范式：模型容量、训练目标和异构具身数据需要协同设计，才能可靠地吸收更多数据并提高性能。低质量轨迹不必被完全丢弃；在不把它们当作专家动作模仿的前提下，它们仍可为动力学和未来视觉预测提供监督。无动作的人类视频也能通过未来状态预测贡献视觉和物理先验。

11 结论、局限与未来方向

本文提出 LDA-1B，一种通过通用具身数据摄取扩展潜动态学习的机器人基础模型。通过为异构数据分配不同角色，并利用 EI-30k 中超过 3 万小时的人类和机器人轨迹，LDA-1B 在结构化 DINO 潜空间中学习动力学，同时采用混合频率的多模态扩散 Transformer，使 10 亿参数规模的稳定训练成为可能。实验表明，LDA-1B 在多种操作任务和长时序任务上表现强劲，并且能够在不完美轨迹上实现高效微调。

本文仍有一些局限。模型依赖固定的 DINO 视觉特征，并且训练数据主要来自第一人称视角，这可能限制模型泛化到新的视觉视角和多模态信号。未来工作包括联合学习视觉表示与潜动力学，扩展到更丰富的传感模态，自动优化不同数据角色，以及推动社区采用可扩展、由异构数据驱动的机器人基础模型。