

<!-- 全文中文翻译；保留 LaTeX 公式、图表、模型名称与引用命令。-->

¹*Shanghai Jiao Tong University, China*

²*University of Cambridge, UK*

^{*}*Authors are with equal contributions*

通讯作者：Hesheng Wang, is with the Department of Automation, Shanghai Jiao Tong University, Shanghai 200240, China and the Key Laboratory of System Control and Information Processing, Ministry of Education of China.

wanghesheng@sjtu.edu.cn

摘要

具身智能与机器人技术进一步发展的关键瓶颈之一，是机器人数据规模化的挑战。近年来，受益于丰富的人类活动视频和计算机视觉进步，从人类视频数据中学习机器人操作技能受到广泛关注。这一方向有望让机器人被动地从海量且易获取的人类示范中学习技能，为通用机器人系统的规模化学习提供支持。本文综述人类视频驱动的机器人学习技术，重点讨论人机技能迁移与数据基础。我们首先回顾机器人策略学习基础，随后介绍引入人类视频的基本接口；接着提出将人类视频迁移为机器人技能的层次化分类，涵盖任务、观测和动作导向路径，并分析不同数据配置与学习范式之间的耦合关系。此外，我们调研常用人类视频数据集与视频生成方案，给出数据集发展和使用的大规模统计趋势。最后总结该领域的挑战与局限，并展望未来研究方向。论文列表见 <https://github.com/IRMVLab/awesome-robot-learning-from-human-videos>。

关键词：Human-Robot Skill Transfer, Video-Based Learning, Robot Manipulation, Imitation Learning, Reinforcement Learning

图片占位: figs/teaser.pdf

图 1: 本文综述的人类视频与机器人执行衔接示意图。相关工作被分为任务导向、观测导向和动作导向三类迁移路径; 家族内分析和家族间比较用于突出其设计原则与权衡, 并进一步给出选择合适 LfHV 路径的实践指南。

图片占位: figs/taxonomy.pdf

图 2: 从人类视频中学习机器人的分类体系。

从人类视频中学习机器人: 综述

Junyi Ma^{1,*}, Erhang Zhang^{1,*}, Haoran Yang¹, Ditao Li¹, Chenyang Xu¹, Guangming Wang², Hesheng V

2026 年 9 月 9 日

1 介绍

随着现代工业和社会对自动化需求的迅速增长, 具身智能与机器人技术在过去几年中取得了快速进展。模仿学习、强化学习等机器人学习技术的显著发展, 是推动这一进步的关键动力, 为机器人操作和全身控制提供了重要而广泛的解决方案。

然而, 制造、物流和日常服务中的任务场景日益复杂, 对机器人系统的通用性和泛化能力提出了更大挑战。传统模仿学习范式 [brohan2022rt,zhao2023learning,fu2024mobile,ze20243d,chi2025diffusion] 依赖耗时且重复的示教采集过程, 包括动作捕捉或遥操作示范, 这显著降低了机器人策略在真实世界中的部署效率。示范数据的多样性有限且数量不足, 也进一步限制了策略在新操作环境中的泛化。引入强化学习算法 [schulman2017proximal,fujimoto2018addressing,haarnoja2018soft,hafner2019dream,janner2019trust] 可以通过与环境交互提升策略适应性, 但通常依赖精心设计的奖励函数以及大量试错经验, 不仅使真实机器人系统的训练成本高昂, 还带来样本效率、训练稳定性和探索安全性方面的担忧。因此, 模仿学习和强化学习在将机器人技能扩展到多样化开放世界场景时仍面临根本挑战。近年来, 大语言模型和视觉语言模型的发展很大程度上得益于训练数据规模的急剧增长 [chen2024expanding,grattafiori2024llama,yang2025qwen3]。受此启发, 要提高机器人策略的泛化能力, 就需要寻找比传统机器人数据更易采集、也更易扩展的数据来源。

表 1: 定量证据表明, 人类视频比传统机器人遥操作具有更高的数据效率。

参考文献	设置	对比设置	定量效率结论
[?]	单臂	人类视频 vs. 机器人遥操作示范	人类视频的采集速度比机器人遥操作示范快 5–7 倍 。
[?]	双臂	一小时人类数据 vs. 一小时机器人数据	一小时人类数据约产生 1400 条示范 , 而一小时机器人数据仅产生 135 条示范 (数据产出约高 ~ 10.4 倍)。
[?]	单臂	人类视频 vs. 机器人遥操作示范	人类视频每个片段约需 20 秒 , 而机器人示范约需 60 秒 。
[?]	双臂	人类视频驱动自动 rollout 示范 vs. 遥操作	自动 rollout 的速度 远快于遥操作 , 8 小时约可采集 300 条示范 , 并支持将每项任务扩展 100 倍至 5K–24K 条轨迹 。
[?]	单臂	第一视角人类示范 vs. 遥操作	基于人类视频的流程所需数据采集时间减少 5–8 倍 , 即速度约为遥操作的 5–8 倍 。

在这一背景下, 人类活动视频成为机器人学习的有前景的监督来源。随着计算机视觉持续进步, 人类视频能够被更准确、高效地分析。这类数据天然包含密集的任务语义以及与多种物体交互的丰富模式, 与机器人策略学习的需求高度契合。与遥操作示范相比, 人类视频更易采集, 互联网上还存在海量现成视频, 使通用机器人开发所需的大规模数据获取成为可能。尽管已有综述 [mccarthy2025towards,eze2025learning,feng2026human,zheng2026video] 为基于视频的机器人学习提供了有价值的视角, 但 LfHV 仍需要更聚焦的梳理。尤其是, 当前领域缺少以“信息如何从人类视频流向机器人执行”为中心的分类体系; 围绕视角选择、对真实机器人数据的依赖以及学习范式, 对不同迁移路径进行系统交叉比较的工作也十分有限。人类视频来源的整理同样较为零散, 特别是在数据集使用频率、使用模式和视频生成方案的新兴作用方面。鉴于相关文献发展迅速, 近期出现的一些方法和数据集也有必要在后续讨论。

为此, 本文对人类视频驱动机器人学习的方法体系、数据基础和新兴研究趋势进行全面总结与细致分类, 旨在为具身智能和机器人领域的后续研究提供更清晰的基础。如图 1 所示, 我们将问题概念化为通过多个层次的迁移来衔接人类视频与机器人操作; 综述的总体结构见图 2。主要贡献如下:

- **技能迁移的层次化桥梁机制:** 我们提出连接人类视频与机器人执行路径的层次化分类, 说明人机技能迁移如何在任务、观测和动作层面建立, 并为每个层面识别作为迁移桥梁的关键视频中间表示, 给出选择合适 LfHV 路径的实践指南。
- **跨数据配置与学习范式的家族间分析:** 除了构建分类体系, 我们比较不同迁移家族与视角选择、真实机器人数据依赖和学习范式之间的关系, 揭示现有 LfHV 方法中特有的设计耦合与方法权衡。
- **人-物交互分析的系统总结:** 在分类技能迁移路径之外, 我们系统总结视频中解析人-物交互的常用方法, 重点回顾二维、三维和四维空间中的手与物体检测、跟踪、重建和姿态估计工具, 帮助研究者了解 LfHV 文献中当前实用且常见的现成交互分析技术。
- **人类视频数据的演变和偏好:** 我们在 LfHV 背景下提出了迄今为止 (迄今为止) 最大的人类视频源统计分析, 系统地总结了人类视频数据集的发展趋势和相关生成技术。基于综合情况, 我们进一步分析了不同类别的 LfHV 方法所表现出的数据偏好。
- **跨模型、数据和基准的未来方向:** 根据在桥梁机制和数据基础中观察到的趋势, 我们确定了未来研究的几个有希望的方向。我们特别强调新的建模范式、更丰富的数据模式、更标准化的基准和更具协作性的生态系统的机会。

图片占位: figs/bridging_overview_new.pdf

图 3: 在任务、观测和动作层面衔接人类视频与机器人执行的示意图。

为了保持更清晰、更有针对性的范围,本次调查关注的是利用人类视频数据来促进机器人操纵策略的 LfHV 作品,而不是那些无需复杂操纵的全身控制和运动的作品 [mao2024learning,allshire2025visual,li2025robomirror,yar 本文的其余部分组织如下: Sec. ?? (背景) 回顾了基础机器人学习范例及其用于合并人类视频的接口,并介绍了 LfHV 问题的统一表述。Sec. ?? (人类-机器人技能转移) 对人类视频和机器人执行之间的桥接机制进行了分类,并以分层方式研究了相关工作。Sec. ?? (数据基础) 介绍了现有人类视频的开源数据集,以及想象的对应物的生成技术。Sec. ?? (讨论) 深入研究了这一新兴领域的关键挑战,并概述了有希望的未来方向。最后, Sec. ?? (结论) 提供了本次调查的总结。

2 背景

机器人从人类视频中学习通常建立在机器人技术的两个基本范例之上: 模仿学习 (IL) 和 强化学习 (RL)。它们提供了学习视觉运动策略的核心框架,现有的 LfHV 方法可以被视为扩展或重新解释它们。因此,在回顾基于人类视频的机器人学习之前,我们简要回顾一下 IL 和 RL 的数学基础,并讨论将人类视频纳入这些框架的接口。本节进一步提供了将 LfHV 表征为最小化跨实施例差异的统一公式。

2.1 模仿学习

模仿学习旨在通过模仿专家演示来学习策略。在机器人技术中,轨迹通常表示为 $\tau = \{(o_t, s_t, a_t)\}_{t=1}^T$, 其中 o_t 表示视觉观察, s_t 表示本体感受状态, a_t 对应于动作。在现代的具体人工智能系统中,通常会合并任务指令 l 来指定任务目标。模仿学习的标准公式是对专家演示数据集 $\mathcal{D}_{expert}$ 的最大似然估计:

$$\max_{\theta} \sum_{\tau \in \mathcal{D}_{expert}} \sum_t \log \pi_{\theta}(a_t | o_{\leq t}, s_{\leq t}, l), \quad (1)$$

其中 π_{θ} 表示由 θ 参数化的 IL 策略。

将人类视频融入机器人模仿学习中,旨在降低通过远程操作收集 $\mathcal{D}_{expert}$ 的大量成本 (见表 1)。因此,它尝试使用从人类视频中提取的信息来重建等式 (??) 中的 l 、 o_t 和 a_t 。根据 o_t 和 a_t 的形式可以确定 s_t 。对于任务指令 l , 人类视频本质上提供了人类如何完成目标操纵任务的程序结构。因此,可以轻松地从文本或图像形式的人类视频中解析任务指令,以进行机器人任务规划。对于视觉观察 o_t , 最直观的策略是将人类视频观察转化为与实施例无关或以机器人为中心的观察。或者,从人类视频中学习视觉编码器以将 o_t 压缩为机器人策略可直接使用的视觉表示也是实用的。对于动作 a_t , 从人类视频中提取的手部物体姿势和潜在动作表示等显式可供性可以用作机器人动作生成的指导。

2.2 强化学习

强化学习侧重于通过与环境的交互来学习策略，旨在最大化累积奖励。形式上，RL 目标是：

$$\max_{\theta} E_{\tau \sim \pi_{\theta}} \left[\sum_{t=1}^T \gamma^{t-1} R_{\phi}(s_t, a_t) \right], \text{ with } \theta \leftarrow \theta_0, \quad (2)$$

其中 $R_{\phi}(s_t, a_t)$ 表示由 ϕ 参数化的奖励函数， γ 是折扣因子， θ 表示可学习的策略参数， θ_0 表示策略的初始化。与模仿学习相比，强化学习不一定需要专家的动作标签，而是通过奖励引导的试错探索来改进策略。然而，设计合理的奖励函数并实现有效的探索是现实世界机器人应用面临的主要挑战。

因此，人类视频可以通过两个重要的接口（ θ_0 的策略初始化和 R_{ϕ} 的奖励学习）相应地纳入 RL 框架中。对于策略初始化，人类视频可以提供明确的可供性（例如手部轨迹）作为 θ_0 之前的初始策略。这种初始化可以减轻下游机器人学习中的探索负担并提高样本效率。对于奖励塑造，可以从人类视频中推断出视觉嵌入和可供性等信息信号来构建奖励函数，而不是手动设计 R_{ϕ} 。通过这种方式，人类视频可以为策略优化提供更好的起点，或者提供信息更丰富且一致的学习目标来指导强化学习。

可以看出，人类视频在机器人学习中的作用可以通过模仿学习和强化学习的镜头来解释。从模仿学习的角度来看，人类视频通过提供任务说明、视觉观察和动作提示，可以作为专家演示的可扩展替代品。从强化学习的角度来看，它们为策略初始化和奖励构建提供了信息丰富的先验，从而降低了探索难度和手动奖励工程。这个观点还表明，大多数现有的 LfHV 方法可以被视为在 IL 和 RL 的特定接口上运行。可以从 IL 和 RL 范式的这些接口中进一步抽象出不同的桥接机制，从而促进以下方法分类。

2.3 从人类视频学习的统一形式化

尽管策略学习范式存在差异，但机器人通常会接收任务指令，感知其环境，然后生成动作来完成操纵任务。因此，从人类视频中学习的问题可以进一步抽象为最小化跨实施例差异的多个来源。具体来说，我们可以将学习目标描述为：

$$\Phi^* = \arg \min_{\Phi} \mathcal{L}_{obs}(\Phi) + \mathcal{L}_{act}(\Phi) + \mathcal{L}_{obj}(\Phi), \quad (3)$$

其中 Φ 表示将人类视频映射到共享表示空间的桥接函数。在这里， $\mathcal{L}_{obs}$ 测量人类和机器人感知之间的观察差距， $\mathcal{L}_{act}$ 捕获人类行为和机器人控制空间之间的动作差距， $\mathcal{L}_{obj}$ 表示由于人类视频中缺乏任务注释或明确奖励而导致的客观差距。值得注意的是，这种概念表述自然涵盖了更广泛的转移范式，包括那些不属于传统 IL 或 RL 的范式，例如从人类演示中直接重定向。

根据这个提法，我们自然可以将文献分为不同的类别。在下一节中，我们回顾每个类别下的代表性方法，并分析它们的设计选择，以缩小人类视频和机器人控制之间的差距。

3 人机技能迁移

根据 Sec. ?? 中的表述，从人类视频到机器人执行的桥接机制可以分为三类：面向任务的传输、面向观察的传输和面向动作的传输。如图 ?? 所示，这些类别对应于六种形式的信息流，包括任务结构、任务意图、转换视频、视觉嵌入、可供性和潜在动作。接下来，我们将回顾每个类别下的代表

图片占位: `figs/tasksstructuretransfer.pdf`

图 4: 作为桥梁
的任务结构的高级图。




图 5: 任务结构下的方法按时间顺序概述, 作为 *Sec. ??* 中的桥梁。

性方法, 并讨论它们如何实现从人类视频到机器人系统的技能转移。我们为与主导人机机器人技能转移的主要信息桥相对应的系列分配一种方法, 即使使用了其他系列的辅助组件。

3.1 任务导向迁移

面向任务的传输旨在在任务指令层面连接人类视频和机器人执行。尽管野外人类视频不能直接为机器人策略学习提供动作标签, 但任务的程序组织和目标可以作为指令跨实施例转移。因此, 该类别强调从人类视频中提取高级任务知识以指导下游机器人决策。这种桥接机制中的现有方法可以分为两组: (1) 任务结构作为桥梁, 它将人类视频中演示的任务显式分解为时间指令; (2) 任务意图作为桥梁, 它在不构建完整指令序列的情况下推断全局任务目标或任务阶段转换信号。也就是说, 任务结构是任务过程的显式的、按时间组织的表示, 而任务意图表示任务目标的紧凑的、隐式的表示。

3.1.1 任务结构

如图 ?? 所示, 任务结构作为桥梁, 旨在在机器人执行之前将人类视频转换为明确的、按时间组织的中间阶段 (例如, 细粒度形式: 手柄上方的位置 → 向下移动 → 关闭夹具 → 向上移动, 或粗粒度形式) 形式: 从柜台上拿起刀 (→), 用刀 (→) 切白菜 (将刀放在柜台上)。它引导机器人在不同阶段遵循有针对性的任务计划。为了清楚起见, 我们将相关方法分为传统判别方法和现代 VLM 增强方法, 并在图 ?? 所示的时间线中总结它们的发展。

(a) 传统判别方法: 早期代表性工作采用规模有限的判别模型或基于规则的机制, 将人类视频中的任务分解为步骤。例如, [?] 先从视频帧识别抓取类型和被操作物体, 再将这些感知线索整合为“视觉句子”; 随后依据概率操纵动作语法, 将视觉句子解析为层次化语法树, 最终转换为可执行的原子任务指令序列。受 [?] 启发, [?] 以端到端方式结合 CNN 和 RNN, 直接将人类视频翻译为动词-名词指令序列。沿着视频到指令的路线, [?], [?] 和 [?] 联合利用全局场景特征与抓取感知的局部

物体特征,进一步改进了用于机器人操纵的 LSTM 指令生成。[?] 引入更具扩展性的动作识别模型,直接预测人类示范视频中的技能分布,得到任务结构的离散高级语义标签。为理解周期性任务的结构,[?] 引入 RepNet,从单个人类视频估计动作循环次数,使复杂长时任务能够自动分解为标准化周期组件。为获得交互层面的细粒度分解,[?] 识别人-物和物-物关系,将人类视频分割为三种可泛化的接触事件原语。然而,受模型容量和预定义规则限制,这些方法在多样且复杂的任务分解中泛化能力有限。

(b) 现代 VLM 增强方法:得益于近年来生成式基础模型的快速发展,越来越多工作采用 VLM 进行时间任务分解,并在互联网规模的人类视频上取得更强的泛化能力。例如,[?] 率先使用 GPT-4V [achiam2023gpt] 识别视频中的人类动作,并将其转写为顺序文本指令。通过引入思想链技术,[?] 提高了 VLM 推理能力,自动注释人类视频并提供详细的任务计划描述。SeeDo [wang2024vlm] 和 Super-Mimic [ye2025watch] 进一步利用手部速度信息进行关键帧提取和视频分割,然后使用 VLM 为结果子任务生成语言描述。为了进一步丰富任务规划的层次结构,PhysBrain [lin2025physbrain] 采用了三种基于场景的视频分割策略,包括固定间隔分割、事件驱动分割和运动学感知分割。然后,它通过七维模板化 VQA 方案生成任务描述。可以注意到,现有的基于 VLM 的方法,如 SeeDo [wang2024vlm]、Super-Mimic [ye2025watch] 和 PhysBrain [lin2025physbrain] 基本上只能理解人类行为,并仅从单个分段剪辑或关键帧生成相应的任务描述。然而,长视野任务中的微步骤自然取决于整个视频的上下文。因此,剪辑级和关键帧级指令生成失去了远程依赖性,并导致任务理解不理想。为了解决这个问题,[?] 提出了一种长上下文 Q-Former,它进一步合并了当前视频片段之外的相邻剪辑的时间上下文。该架构提高了机器人确认生成和细粒度任务规划的准确性。为了减轻 VLM 推理的开环性质,[?] 引入了额外的人为纠错机制,当初始计划不正确时,可以交互式重新规划显式子任务序列。[?] 相反开发了一种端到端时间交互定位算法,无需人工干预即可实现闭环反馈。它集成了有效的 VLM 检查器,可自动验证手部对象交互事件的任务分解结果。

尽管上述基于 VLM 的方法在互联网规模的人类视频中实现了鲁棒的时间任务分解,但所得的任务结构仍然与机器人动作规划松散耦合。它们通常需要一个额外的阶段,使用分解的指令来指导单独的机器人策略。为了缩小这一差距,[?] 提出了一种基于知识的演示编程框架。它将人类视频分解为结构化的行动计划,并通过产品感知参数化将其语义映射到可执行的机器人任务。VLMimic [chen2024vlmimic] 和 FMimic [chen2025fmimic] 进一步使用 VLM 来总结人类视频中控制动作的高级语义约束和低级几何代码参数。这使得机器人能够更直接地重放所演示的行为。此外,CoM [wang2025chain] 集成了多模态线索,将人类视频表示为结构化操作程序。该方案将演示的任务分解为具有相关控制相关参数的有序子任务,然后将它们转换为可执行的机器人代码。它进一步加强了任务结构和机器人动作生成之间的联系。

(c) 任务结构小结:任务结构作为桥梁在动作生成前为机器人提供显式且按时间组织的程序知识。该方向已从基于规则和判别式的分解,发展到具有更强扩展性和更丰富语义的 VLM 任务解析。近期工作还通过提高任务结构的可执行性,进一步缩小任务分解与下游执行之间的差距。不过,这些方法主要仍处于规划层面,通常需要额外的落地模块将任务结构转换为特定实施例的机器人动作。

3.1.2 任务意图

与作为桥梁的显式任务结构相比,作为桥梁的

(a) 全局意图提取:该类早期工作将完整人类视频表示为用于策略适配的全局任务意图。[?] 利用域自适应元学习,从单个人类示范视频提取与任务相关的意图,并将其迁移到新任务的机器人策




图 6: 任务意图的高级图作为桥梁。




图 7: 按时间顺序概述 任务意图下的方法, 作为 Sec. ?? 中的桥梁。

略适配中。此时, 人类视频是待完成任务目标的紧凑表示。BC-Z [jang2022bc] 将这一思想扩展到更广泛的多任务场景, 以语言或人类视频产生的任务嵌入为条件训练共享机器人策略, 从而无需为每个新任务收集机器人示范即可实现零样本泛化。类似地, Vid2Robot [jain2024vid2robot] 将人类提示视频的视觉标记作为全局意图输入机器人策略; 与 BC-Z 的 FiLM 层相比, 它采用更强的交叉注意力 Transformer [vaswani2017attention] 融合全局意图。

(b) 阶段信号生成: 当机器人操纵任务变得复杂且时间跨度较长时, 仅有全局任务意图往往不够, 还需要反映任务进度的更丰富信号。[?] 从人类视频发现隐式中间阶段, 并将其转化为稠密感知奖励, 证明无需构建显式指令序列也能获得任务阶段信号。[?] 进一步使用阶段预测器从未剪辑视频推断任务进展, 使机器人自主决定下一步调用哪个人类动作原语。XSkill [xu2023xskill] 从无标注视频提取跨实施例技能原型, 并规定这些潜在技能在未知机器人任务中的组合方式。[?] 从第三人称人类视频逐步生成机器人第一人称视觉子目标, 使低层控制器能在机器人自身环境中完成这些子目标。近期, [?] 将任务意图扩展到非马尔可夫主动感知, 通过认知辅助头推断机器人何时应在信息寻求与任务执行阶段之间切换行为。

(c) 任务意图小结: 任务意图作为桥梁无需显式解析完整指令序列, 而是利用人类视频为机器人控制生成紧凑的高级指导。现有方法主要通过提取任务总体目标、建模任务进度随时间的演化来实现这一点。与任务结构相比, 任务意图避免固定的符号分解, 通常更灵活, 也更易跨实施例迁移; 但仍需完善的机器人学习策略将推断出的意图落地为具体动作规划。




图 8: 按时间顺序概述了 将视频转换为桥梁的方法。??。




图 9: 将视频转换为桥梁的插图。一些元素改编自 [?, ?]。

3.1.3 任务导向迁移小结

面向任务的传输为桥接人类视频和机器人执行提供了最与具体实施无关的途径。它不需要观察和行动之间的直接对应，而是在指令级别提取与任务相关的指导，在指令级别跨实施例迁移更自然可行。从这个角度来看，任务结构作为桥梁和任务意图作为桥梁可以被视为组织人类视频中的高级知识的两种互补方式。前者强调显式的程序分解，使转移的知识更易于下游规划的解释。后者放松了对完整符号解析的需求，而是提供了紧凑的指导信号，这些信号通常对于跨域和长期政策适应更加灵活。它们的差异本质上反映了显性和灵活性之间更广泛的权衡。

剩下的一个关键瓶颈在于如何将人类视频的任务指导转化为具有足够精度和鲁棒性的可执行机器人行为。未来的进展可能取决于面向任务的迁移与面向观察和面向行动的迁移更紧密地结合。因此，来自人类视频的高级任务语义可以与实施例感知感知和低级控制联系起来。这种集成可能最终决定面向任务的迁移是否仍然只是一种规划辅助，还是成为可扩展机器人从人类视频中学习的更核心的界面。

3.2 观测导向迁移

与面向任务的迁移相比，面向观察的迁移侧重于在视觉感知层面连接人类视频和机器人执行。它不是提取符号指令或高级意图，而是旨在将原始人类视频转换为与机器人的感知和控制管道直接兼容的观察表示。人类视频和机器人观察通常在视角、实体外观和环境条件方面存在显著差异。因此，这一类别强调生成可转移的视觉表示，以跨实施例对齐感知空间。具体来说，我们根据两个标准对现有的面向观察的转移工作进行分类：(1) 将视频转换为桥梁，它将人类视频直接转换为与实施例无关或类似机器人的视觉格式，以及(2) 视觉嵌入作为桥梁，其目标是学习实施例不变的潜在视觉表示，从而在共享特征中对齐人类和机器人观察。空间。

3.2.1 变换后的视频

连接人类视频和机器人感知的最直接方法是将人类视频转换为视觉观察，从而抑制人类体现线索（即观察到的身体外观）。可选地，可以用特定的机器人实施例进一步呈现变换后的观察结果。因此，我们将相关方法分为实施例抑制和实施例变换，并使用图 ??所示的时间线来呈现它们。

(a) 实施例抑制：由于机器人观测不包含人类外观，一些工作从视频中抑制与实施例相关的视觉线索，以缩小人类示范与机器人观测之间的形态差距（见图 ??(a)）。MIR [zhou2021manipulator] 通过构建不可见手臂环境，聚焦物体状态变化并学习与机械臂无关的表示。[?] 利用现成视频修复方法 [lee2019copy] 从人类和机器人视频中移除执行体，同时保持物体状态与场景动态，再以修复视频设计与实施例无关的对齐目标，通过真实交互改进策略。[?] 则基于单帧修复模型 [rombach2022high]，将第一视角人类视频显式分解为执行体与环境成分；相比直接丢弃手部信号，这种分解更结构化，并保留指示交互位置的末端执行器运动。

有趣的是，从 Ag2Manip [li2024ag2manip] 到 Ag2x2 [xiong2025ag2x2] 也可以观察到类似的进化模式。Ag2Manip [li2024ag2manip] 从视频中分割出人手，然后将 E²FGVI [li2022towards] 修复与时间对比学习相结合，以获得与代理无关的视觉表示。相比之下，Ag2x2 [xiong2025ag2x2] 认识到从视频中完全消除人为因素可能会丢失重要的物体进展和双手协调信息。因此，它保留了人类视频中手部物体交互点的坐标，并将它们与视觉观察结合起来用于策略学习。

(b) 实施例变换：在移除人类外观后进一步渲染机器人手臂，将人类视频转换为与机器人观测一致的视觉结果。AVID [smith2020avid] 使用 CycleGAN 完成视频翻译并为各阶段选择目标图像；后续方法结合关键点检测和扩散模型提升几何一致性与策略学习效果，但在野外场景中仍可能受到视点差异和生成伪影影响。

随着生成建模的发展，底层视频翻译范式已经从前面提到的基于 GAN 的风格化发展到基于扩散的具有修复技术的实施例转换。例如，Phantom [lepert2025phantom] 像 Ag2Manip [li2024ag2manip] 一样通过 E²FGVI [li2022towards] 移除人类手臂，并进一步在其位置覆盖渲染的机器人以产生与机器人一致的观察结果。尽管获得了高质量的渲染结果，但它需要固定的第三人称相机设置来合成策划的外心机器人视点。在处理互联网上存在的大量具有不同观点的以自我为中心的人类活动视频时，这种假设限制了鲁棒性。为了解决这个问题，Masquerade [lepert2025masquerade] 将虚拟双手机器人放置在具有已知内参和外参的机器人相机坐标系中，并驱动机器人末端执行器跟踪恢复的人手运动。然后，它从原始视点渲染机器人观察结果，减少野外以自我为中心的人类视频与机器人执行之间的视点差异。此外，考虑到野外人类视频通常没有相应的度量深度，[?] 进一步使用 2D 关键点位置作为视觉模型中辅助损失的监督标签。这规避了像 Phantom [lepert2025phantom] 这样使用深度观测来完善 HaMeR 的要求。他们还证明，与仅使用视点对齐视频进行视觉编码器预训练的并发工作 H2R [li2025h2r] 相比，他们的协同训练管道可以在复杂的长视野双手任务上实现稳健的机器人策略。MimicDreamer [li2025mimicdreamer] 提出了一种更系统的人机视频对齐框架，共同解决视点对齐、动作对齐和视觉对齐问题。转换后的视频和对齐的动作轨迹直接用于训练 π_0 VLA 模型 [black2024pi0] WARPED [freeman2026warped] H2R-Grounder [ci2025h2r]

与上述直接使用转换后的视频进行机器人策略学习的方法相比，Mitty [song2025mitty] 还利用它们来训练端到端的人机视频转换模型。这种范式可以更好地概括未知的任务和环境。与 Mitty [song2025mitty] 类似，[?] 也专注于端到端转换建模。此外，他们引入稀疏光流轨迹作为附加生成条件，从而获得合理的视觉质量和轨迹可控性。

(c) 变换视频小结：变换视频作为桥梁以最直接的方式减少人类视频与机器人观测的视觉差异。

ditionally requires video textual descriptions to align its representation, VIP [ma2022vip] is developed as a fully self-supervised learning paradigm. It further models temporal reachability between visual embeddings through a value-implicit objective. LIV [ma2023liv] extends the VIP paradigm [ma2022vip] to multimodal value function learning, simultaneously supporting both language goals and image goals. [?] further evolve the TCL paradigm of VIP [ma2022vip] into a temporal-difference learning (TDL) framework, yielding an intent-conditioned value function (ICVF). By modeling the reachability from the current state to a variety of future goal states, the learned value function captures scene dynamics as a transferable visual representation. To capture embodiment-agnostic visual embeddings during pretraining, [?] and [?] both utilize inpainted human videos to achieve temporal contrastive learning, encouraging the encoder to focus on interaction-relevant scene dynamics rather than embodiment-specific appearance cues.

可以注意到, 时间对比学习致力于限制时间维度中的视觉嵌入。相比之下, 掩模预训练 (MP) 范式侧重于空间维度上的图像重建任务 (见图 ?? (b)) 来预训练视觉编码器。该范式的相关工作实质上受到了屏蔽自动编码器优化原理的启发 [he2022masked]。例如, [?] 提出 MVP, 通过在大规模人类视频上使用掩模图像重建来预训练视觉编码器, 从而构建 MP 范式的基础。他们冻结这些编码器用于下游电机控制, 证明仅空间屏蔽预训练就可以为机器人学习产生可转移的视觉表示。[?] 通过缩放预训练人类视频数据和模型大小进一步扩展了 MVP [xiao2022masked], 并将其下游应用扩展到现实世界机器人操作的大规模模仿学习。通过仔细重现 MVP [xiao2022masked] 和 R3M [nair2022r3m], [?] 证明, 将 R3M 等语言监督引入 MVP 的屏蔽预训练范式可以弥补语义限制, 同时保留用于视觉嵌入生成的强大空间建模能力。与 [?] 使用语言模态辅助视觉模态相比, [?] 的 M2VTP 在重建机制中结合了触觉信号, 以实现互补的交互线索。它旨在解决视力被遮挡或难以视觉感知精细局部几何形状的情况。VTAO-BiManip [sun2025vtao] 在 M2VTP [liu2024masked] 的基础上进一步引入了手部动作和以对象为中心的理解。它将 M2VTP 的屏蔽预训练从视觉-触觉框架扩展到视觉-触觉-动作框架。最近, [?] 将重点从对象理解转移到捕获更深层次的类人操作模式。他们受到人脑顶下小叶 (IPL) 神经元的启发, 提出了一种 IPL 令牌, 用于在掩蔽预训练过程中通过 Transformer 编码器 [vaswani2017attention] 进行多感觉整合。考虑到集成的表示, 他们通过强化学习为不同任务的专家策略训练多任务动作策略, 并通过在线模仿学习将这些专家提炼成统一的策略。与上述通过图像重建来优化感知模型的 MP 范式相比, MimicDroid [shah2025mimicdroid] 直接使用掩模图像作为手部预测预训练的输入。它隐式地减少了对人类特定视觉线索的过度拟合, 并鼓励模型专注于环境和对象交互。

在 TCL 和 MP 范式的基础上, 一些研究人员进一步深入研究了哪些类型的现有模型架构和预训练数据可以为下游机器人操作产生更有效的视觉嵌入。例如, [?] 将注意力转向发现哪种视觉预训练范例最有效。他们系统地对 TCL 和 MP 方法进行了基准测试, 以表明没有单一模型能够在所有机器人任务中普遍占主导地位。他们进一步使用 MAE 训练多个不同尺度的 ViT 模型 [dosovitskiy2020image], 并最终获得 VC-1, 这是一种平均优于现有预训练方法的统一视觉编码器。[?] 进一步将问题从使用哪种视觉预训练转向使用哪种数据。他们展示了数据集的图像分布比下游视觉运动学习的规模更重要。他们还观察到, 即使是 ImageNet [deng2009imagenet]、Kinetics [smaira2020short] 和 100DOH [shan2020understanding] 等传统视觉数据集对于机器人视觉预训练也具有惊人的竞争力。与 [?] 和 [?] 相比, [?] 专门关注视觉泛化能力并推进预测泛化的指标。他们确定了强泛化的秘诀: 具有高紧急分割精度的 ViT 模型往往会在视觉分布变化下生成更泛化的视觉嵌入。此外, 与许多其他鲁棒性指标相比, 新兴分割精度是更强的泛化预测指标, 且无需额外的训练过程。

值得注意的是, TCL 范式通过在时间维度上强制执行相似关系来捕获视觉表示, 但它不一定

要求编码器对人与物体交互背后的更深层次的物理机制进行建模。MP 范式强调通过重建来理解空间,但大多数重建目标可以从单帧内的静态纹理和外观线索中恢复,而无需推理潜在的交互动态。这些限制激发了另一项工作,即通过人类视频预测(HVP)学习视觉嵌入,如图??(c)所示。通过从过去的交互中预测未来的观察结果,此类方法鼓励视觉编码器不仅捕获时空规律,而且捕获与下游机器人操作更直接相关的物理动力学的因果关系。HVP 范式与最近文献中的世界模型的概念密切相关,因为世界模型从根本上关注预测未来的观察如何从过去的相互作用和与动作相关的动态演化[liao2025genie,ye2026world]。值得注意的是,在这里我们只回顾那些明确使用人类视频进行视觉预训练的作品。[?]的早期工作通过预测未来的人类视频帧来预训练视觉编码器,并使用由此产生的视觉嵌入从情景记忆中检索最相似的人类演示片段。然后使用检索到的演示来提取低级机器人动作的对象运动。然而,预测的帧通常在视觉上是模糊的,这可能会限制学习的视觉表示的质量,从而损害视觉预训练的有效性。相比之下,[?]通过仅预测过渡帧和最终帧来避免长视野视频生成。通过强调关键的交互状态,他们的MPI框架鼓励视觉编码器学习操纵的核心因果结构和状态演化。他们凭经验验证MPI在视觉预训练方面优于几种流行的TCL和MP范例[nair2022r3m,xiao2022masked,karamcheti2023language]。受益于生成技术的发展和模型容量的扩展,最近的工作重新审视了连续视频剪辑的直接预测,作为视觉预训练的更丰富的监督信号。例如,GVF-TAPE[zhang2025generative]使用人类视频作为补充数据来预训练基于整流流[liu2022flow]的端到端视频预测模型。与仅执行特定于实施例的视频预测的GVF-TAPE[zhang2025generative]相比,[?]进一步引入了用于跨实施例预测的交叉预测视频生成。也就是说,它们致力于根据人类图像预测机器人视频以及根据机器人图像预测人类视频。因此,学习到的视觉嵌入成为用于跨实施例捕获任务语义和环境上下文的更统一的表示。最近,研究人员还发现,将人类视频预测范式集成到VLA模型中可以通过预测未来事件来促进生成更相关和更合适的动作。以[?]为例,GR-1将大规模视频生成预训练集成到GPT式VLA中,以端到端的方式预测未来图像和机器人动作,从而提高动作生成性能。与GR-1[wu2023unleashing](从80万到3800万)相比,GR-2[cheang2024gr]将人类视频生成预训练数据量进一步扩展了近50倍,从而在各种未见过的场景中具有更强的泛化能力。为了弥合纯人类视频预测和动作生成之间的差距,RynnVLA-001[jiang2025rynnvla]提出了一个中间阶段,其中结合了手腕轨迹预测,以学习视觉变化与其潜在人体运动之间的关联。imit-video[pai2025mimic]不是从头开始训练视频预测模型,而是直接使用Cosmos-Predict2[agarwal2025cosmos,ali2025world]作为视频生成骨干,并在其视觉表示上调节流匹配动作解码器。

尽管HVP范式通过使用人类视频预测目标预训练视觉编码器来关注物理维度,但最终的视觉嵌入仍然编码人类交互行为而不是机器人交互状态。这不可避免地会导致潜在的形态差距,因为在视觉预训练过程中只有人类数据可用[mower2026robot]。为了进一步缓解实施维度中的这个问题,一些工作将机器人数据集成到人类视频的视觉预训练过程中。如图??(d)所示,该范例实现了联合域适应(JDA),使语义相似的人类和机器人观察的视觉嵌入在共享表示空间中更紧密地结合在一起。因此,预训练的视觉编码器更适合在下游机器人任务中生成视觉嵌入。[?]提出对抗性域混淆来学习域不变编码器,将人类视频帧和机器人观察映射到共享特征空间。他们进一步表明,少量配对的人类机器人数据有助于锚定跨实施例的视觉嵌入对齐。随后的JDA工作通常侧重于直接减少人类视频的视觉嵌入和机器人观察之间的距离。例如,Vid2Robot[jain2024vid2robot]引入了基于时间周期一致性的视频对齐损失,鼓励视觉编码器生成对实施例和环境因素不变的视觉嵌入。[?]还根据配对的人类和机器人片段之间的最佳传输距离,通过将匹配的视觉嵌入拉得更近来学习共享视觉编码器。为了进一步减轻不同实施例的时间不一致和运动学变化的问题,[?]引入动态时间扭曲(DTW)[sakoe1978dynamic]以实现视觉表示对齐的最佳传输。与[?]类似,[?]也使用DTW来配对每个人类时间步根据视觉嵌

入的最佳匹配机器人时间步长。他们还应用 MixUp [zhang2017mixup] 为后续协同训练过程生成插值人体数据。[?] 进一步让任务描述功能与人类和机器人视频的视觉嵌入交互，并实现跨实施例的任务感知对比学习。

(b) 视觉引导: As shown in Fig. ??(e), another line of research shifts the focus from vision encoder pretraining to how visual embeddings derived from human videos can directly construct reward or cost functions that guide robot interaction with the environment. Encoders obtained through *visual pretraining* can often be directly reused within the *visual guidance* paradigm. [?] formulate the reinforcement learning objective by penalizing the squared Euclidean distance between the robot’s current visual embedding and the demonstration embedding translated from human videos. Similarly, XIRL [zakka2022xirl] defines the reinforcement learning reward as the negative distance to the goal state in the learned visual embedding space. A related one-shot setting is explored by [?], who extract a state alignment-based reward from a single observation-only demonstration video and combine it with sampling-based MPC for efficient policy optimization in contact-rich fabric manipulation. RoboTube [xiong2022robotube] complements the visual guidance paradigm by providing a curated human video dataset together with RT-sim, a suite of simulated twin environments that closely match the appearance and dynamics of the real scenes. It enables visual guidance learned from human videos to be benchmarked reproducibly in simulation and more reliably transferred to real robots. [?] further parse visual embeddings into interaction-aware temporal relations through IAAFormer. The alignment distance reflects the cross-embodiment task process at the sequence level. It provides more structured visual guidance for downstream robot adaptation. [?] further learn an affordance-grounded latent space from human videos, where distances between latent states can also serve as planning-oriented visual guidance. Rather than relying only on instantaneous visual embedding similarity for reward design, it models how these affordance-centric visual states evolve under actions through a world model, enabling more effective downstream control. [?] also follow the world model scheme and propose DexWM, a dexterous world model trained on large-scale human videos. At test time, DexWM performs goal-conditioned MPC using a planning cost defined by the visual state distance and hand-keypoint pixel differences.

与这些使用特征距离作为视觉引导的方法相比，[?] 进一步将视觉嵌入转换为二元分类器，用于确定输入图像是否与指定目标图像匹配，以利用输出对数概率构建奖励函数。与 [?] 类似，[?] 开发了 DVD，它在视觉嵌入之上学习二元分类器，以量化任务方面的功能相似性作为奖励。与仅考虑域内数据的 [?] 相比，他们明确专注于利用野外人类视频和适度的机器人演示来提高奖励函数的通用性。[?] 遵循 DVD 模型 [chen2021learning] 构建奖励函数，但在没有任何带注释的机器人视频的情况下学习功能相似性。

(c) 视觉嵌入小结: *Visual embeddings as a bridge* avoid the explicit inpainting and rendering errors of transformed videos by mapping human observations into latent representations that are more readily transferable to robot learning. Existing methods have mainly developed along two complementary directions. Visual pretraining learns reusable perception models from human videos through temporal contrastive learning, masked pretraining, human video prediction, and joint domain adaptation. Visual guidance further uses visual embeddings to define reward and cost for downstream robot interaction. Compared with transformed videos, this bridging mechanism is generally more compact and robust to appearance gaps across embodiments. However, whether the




图 12: HOI 分析技术和从人类视频中提取可供性的插图。部分图像取自 [?, ?, ?, ?, ?, ?, ?, ?, ?, ?, ?, ?, ?, ?, ?, ?, ?, ?, ?]。

learned representations preserve task-relevant interaction dynamics and cross-embodiment consistency sufficiently to support reliable downstream action planning remains largely implicit.

3.2.3 观测导向迁移小结

面向观察的迁移解决了 LfHV 中最基本的挑战之一，即如何减少人类视频和机器人观察之间的感知差距。与通过高级任务语义桥接实施例的面向任务的迁移相比，该类别的操作更接近视觉运动界面。因此，它在确定机器人是否能够以与下游控制兼容的方式解释人类演示方面发挥着更直接的作用。从这个角度来看，将视频转换为桥梁和视觉嵌入作为桥梁代表了同一问题的两种互补解决方案。前者明确地将人类观察结果修改为与实施例无关或与机器人一致的视觉格式，使传输的信息更加直观和直接可用。相反，后者将人类观察压缩到共享的潜在空间中，牺牲视觉的明确性来换取更大的紧凑性、鲁棒性和灵活性。它们的差异本质上反映了显式感知对齐和隐式表示对齐之间的权衡。转换后的视频提供了更具可解释性的桥梁，而视觉嵌入则提供了更具可扩展性和通用性的界面。

这一类别的一个明显趋势是从外观级别对齐转向更深入的交互动态和跨实体一致性建模。早期的工作主要集中在抑制特定于实施例的外观线索或从人类视频中学习通用视觉特征。最近的方法越来越多地结合时间预测、人机联合对齐和世界模型目标。这种演变表明，有效的观察转移需要匹配视觉外观，同时还捕获交互如何随着时间的推移在实施例中展开。有鉴于此，面向观察的迁移的核心挑战在于保留与动作相关的动态，同时消除特定于实施例的干扰因素。因此，未来的进展可能取决于转换后的视频和视觉嵌入之间更紧密的集成。它还可能与面向动作的传输更强的耦合，以便感知对齐可以更好地支持可执行且具有物理意义的机器人行为。

3.3 动作导向迁移

与面向任务的传输和面向观察的传输相比，面向动作的传输在动作规划层面更直接地连接人类视频和机器人执行。它致力于从人类视频中提取与动作相关的信息，例如交互可供性和潜在动作，然后将它们转移到机器人策略中作为可执行指导。因此，我们将这一类别组织成两种形式的信息流：作为桥梁的可供性，它从人类演示视频中暴露显式的几何动作线索，而潜在动作作为桥梁，它将观察到的人类行为压缩为可转移的动作抽象，以供下游机器人策略学习。

3.3.1 可供性

可供性作为桥梁 are more directly grounded in action compared with task instructions and visual embeddings. As introduced by [?], affordances from human videos explicitly specify *where* and *how* the hand-object interaction (HOI) should occur. That is, when manipulating an object,

affordances explicitly indicate where on the object to make contact, and how to make this contact [kannan2023deft]. Therefore, in this survey, we broadly instantiate *affordances* as all possible interaction-related geometric and functional signals that can be extracted from human videos, including 2D/3D hand&object positions (e.g., trajectories, motion flow, contact/separation regions), 6D hand&object poses (e.g., grasping poses, sequential rigid transformations), hand&object geometric representations (e.g., meshes, point clouds, hand parametric representations), and physical object functionality (e.g., 4D object parts, articulations, functional keypoints). We will detail how these affordances facilitate action-oriented transfer in the following sections.

(a) 人-物交互分析: Hand-object interactions in human videos fundamentally facilitate affordance extraction. Therefore, before delving into specific affordance-based bridging mechanisms, we first review how existing works analyze hand-object interactions to recover action-relevant cues from human videos.

首先, 我们介绍在 2D 空间中广泛使用的 HOI 检测方法, 如图 ??(a)-(b) 所示。[?] 通过从互联网人体视频中联合推断 2D 手部位置、手部侧面、接触状态以及接触物体的边界框, 建立检测范式。他们预先训练的 HOI 检测器随后成为在后续各种 LfHV 作品 [bahl2022human, bahl2023affordances, wang2023mimicplay, kumar2023gr] 中提取手部接触线索的实用基础。在这种 2D 手部接触分析的基础上, [?] 进一步将人手视为交互式对象理解的探针。通过利用以自我为中心的人类视频中的手部外观和动作, 他们以交互区域和提供的抓握的形式学习对象可供性。这将重点从接触检测转移到下游机器人策略学习的更丰富的 2D 可供性发现。其颜色抖动和裁剪等增强策略也启发了后续的 LfHV 作品, 例如 2HandedAfforder [heidinger20252handedafforder]。[?] 进一步将 HOI 分析扩展到更丰富的接触词汇, 区分触摸、握持和使用。它也被用作多个 LfHV 作品中的现成分段器 [heppert2024ditto, shan2025slot, wang2026paws]。GLIP [li2022grounded]、GroundingDINO [liu2024grounding]、YOLO 系列 [Ultralytics2023, khanam2024yolov5, sohan2024review, cheng2024yolo] 和 SAM 系列 [?, ?, ?, ?, ?] 等视觉基础模型也被 LfHV 作品广泛使用, 以可推广的方式从人类视频中提取手部物体边界框和分割掩模 [xu2024flow, wang2024vfm, ma2025madiff, yoshida2025developing, ma2025uni, ma2025egoloc, li2025h2r, ch]

除了上述 2D HOI 区域提取之外, 2D 点跟踪方法也成为基于可供性的桥接机制中的重要技术组成部分。它们主要用于生成物体运动流并进一步恢复刚性变换。例如, CoTracker 系列 [karaev2024cotracker, karaev2025cotr] 联合跟踪视频帧中的大量查询点, 即使在遮挡情况下, 也能在长视频范围内产生时间一致的密集轨迹。这使得它们对 LfHV 研究特别有吸引力 [bharadhwaj2024track2act, li2024okami, yuan2024general, werby2025articulated, chen2025v] 因为以自我为中心的人类视频本质上涉及手和被操纵物体之间频繁的相互遮挡。TAPIR [doersch2023tapir] 及其增强版本 [doersch2024bootstap] 通过通过时间细化的每帧匹配来跟踪任意查询点, 提供类似的通用替代方案。它们保持时间相干轨迹的能力也使它们非常适合在一些 LfHV 作品 [xu2024flow, papagiannis2025r, chen2025grap] 中估计人类演示中的手部物体运动流。LocoTrack [cho2024local] 也是一种有前途的 2D 点跟踪方法, 它结合了双向对应、匹配平滑性和紧凑的时间聚合。因此, 它对机器人从人类视频中学习的重复纹理和同质区域具有坚实的鲁棒性 [hu2025learning]。

由于人与物体的交互基本上发生在 3D 现实世界环境中, 因此仅 2D HOI 分析通常不足以充分表征潜在的交互。因此, 我们回顾了用于 3D 手部对象重建和姿势估计的流行 HOI 分析工作。我们从 LfHV 文献中广泛使用且有前途的 3D 人手检测和重建算法开始, 如图 ??(c)-(d) 所示。作为野外 3D 手部检测的开创性工作, MediaPipe [zhang2020mediapipe] 强调通过手掌检测和地标回归从单目 RGB 进行轻量级实时 3D 手部地标(关键点)估计。它的效率使其在 LfHV 中很受欢迎, 用于从不受约束的人类视频中提取可扩展的以手为中心的可供性 [arunachalam2022dexterous, qin2022one, gao2023k, gu2023rt, zhou2025human, lu2] 除了 MediaPipe 的手部标志提取之外, FrankMocap [rong2020frankmocap] 还根据单眼 RGB 估计 3D 手

部和身体运动,并将它们集成到统一的参数表示中以生成手部网格结构。它提供了一种实用工具,用于从人类视频中恢复 3D 手部运动线索,作为 LfHV 文献 [patel2022learning,mandikal2022dexvip,sivakumar2022robotic,kannan2022reconstructing] 中的可供性。HaMeR [pavlakos2024reconstructing] 通过完全基于 Transformer 的架构进一步致力于更高保真度的单目 3D 手部网格恢复。它通过扩大模型架构和数据消耗,显着提高了野外手部重建和姿势估计的鲁棒性和准确性。这使得它更适合需要更丰富的几何信息或高质量的手部姿势作为可见性的 LfHV 设置,而不是单独的稀疏地标 [li2024okami,shi2025zeromimic,papagiannis2025r,lum2025crossing,liu2025egozero,hsieh2025dexman]。为了解决 HaMeR 端到端回归固有的未对准和不正确姿势问题,WiLoR [potamias2025wilor] 引入了一个额外的细化层,该层使用网格对齐的多尺度特征来变形手部姿势。它支持高效的多手重建和平滑的单目视频跟踪,这对于从人类视频中进行大规模可供性提取很有用 [zhou2025you,yuan2025hermes,zhu2025learning,shah2025mimic]。HaMeR 和 WiLoR 主要恢复相机帧中的手部几何形状,而 HaWoR [zhang2025hawor] 进一步针对从自我中心视频中重建世界空间手部运动。它将相机空间手恢复与世界空间相机轨迹估计分离,并进一步引入了视野外帧的运动填充。因此,它产生了时间连贯的全局手部轨迹,更直接地适用于现代 LfHV [li2025scalable,luo2026being,luo2026joint,feng2025spatial,yang2026aoe] 中的动作导向迁移。最近,Ego-HandICL [xie2026egohandicl] 通过引入 VLM 引导的样本检索的上下文学习,成为一种有前途的手部重建方法,这提高了在具有挑战性的以自我为中心的 HOI 条件下的语义对齐和鲁棒性。此外,SAM 3D Body (3DB) [yang2026sam] 将这条路线从以手为中心的重建延伸到快速的全身网格恢复,联合估计身体、脚和手,具有很强的野外泛化能力。因此,它为未来的 LfHV 作品提供了更丰富的全身可供性线索。[?] 的扩展工作尝试将 3DB 集成到面向操作的传输范式中,该范式已在其存储库中开源。

接下来,我们介绍 LfHV 文献中代表性的物体重建和姿态估计方法,如图 ??(e)-(f) 所示。一般来说,获得可靠的物体重建是准确的物体姿态估计的先决条件。BundleSDF [wen2023bundlesdf] 是针对人类视频中出现的被操纵对象的最基本的对象重建方法之一。它将神经对象场与姿态图优化结合起来。当部署在使用质量高度可变的人类视频的 LfHV 作品 [chen2024vlmimic,patel2025robotic,hsu2025spot] 上时,这增强了其在姿势变化、遮挡、无纹理表面和镜面高光方面的稳定性。之后,更多的重建方法,如 InstantMesh [xu2024instantmesh]、MesyAI [meshyai] 和 TRELLIS [xiang2025structured],只需要单个图像即可直接为目标人体视频帧 [chen2025web2grasp,ye2025video2policy,hsieh2025dexman,soraki2026objectforesight,chen2026dexterous] 内的遮罩对象区域生成对象网格。它们消除了连续扫描的需要,显着提高了特定任务对象重建的效率。

可以基于重建的对象进一步执行对象姿态估计。给定 CAD 模型和感兴趣区域,MegaPose [labbe2022megapose] 可以直接应用于 LfHV 作品 [liang2024dreamitate,patel2025robotic],以从粗到细的方式估计新物体的姿态,而无需重新训练。在过去的两年里,FoundationPose [wen2024foundationpose] 已成为一种更流行的物体姿态估计方法,因为它将基于模型和无模型的新颖物体姿态估计和跟踪统一在一个框架内。与 MegaPose 相比,它进一步利用神经隐式表示进行新颖视图合成以及大规模合成训练,在具有挑战性的 LfHV 设置中实现更强的泛化和更鲁棒的姿势跟踪[chen2024vlmimic,yuan2025hermes,hsieh2025dexman,mao2025robot,lum2025]。最近,Any6D [lee2025any6d] 还放松了对重建 CAD 模型的依赖,并引入了全面到部分匹配策略。它通过改编自 FoundationPose [wen2024foundationpose] 的渲染和比较程序联合对齐 2D 外观、3D 几何和公制比例。这为物体尺度和姿态估计提供了一种有前途的替代方案 [hsieh2025dexman],特别是当难以获得高质量物体重建时。

为了实现更通用的无模型 6D 物体姿态估计,一些研究人员[?] [bharadhwaj2024track2act,zhu2024vision,haldar2025point,liu2025] 手动将上述 2D 点跟踪提升到具有深度信息或立体三角测量的 3D 空间,然后根据所得的 3D 物体流计算刚性变换。尽管如此,还是有现成的 3D 点跟踪方法可用于直接生成用于姿态估计的 3D 对象流。如图 ??(g) 所示,SpatialTracker [xiao2024spatialtracker] 和 SpatialTrackerV2 [xiao2025spatialtrackerv2] 将视