

Masquerade：利用数据编辑，从野外人类视频中学习

原文：Masquerade: Learning from In-the-wild Human Videos using Data-Editing

作者：Marion Lepert、Jiaying Fang、Jeannette Bohg（斯坦福大学）

项目主页：<https://masquerade-robot.github.io>

说明：本文按便于阅读的方式翻译，保留方法、公式、实验数字和主要图表含义；参考文献只保留论文中出现的引用编号，不逐条翻译书目信息。

摘要

机器人操作研究仍然严重缺数据。即便是最大的机器人数据集，其规模和多样性也远低于推动自然语言和计算机视觉突破的数据集。

本文提出 **Masquerade**：先编辑自然环境中的第一视角人类视频，缩小人与机器人之间的视觉具身差距，再利用这些视频学习机器人策略。处理流水线会把人类视频变成“机器人化”的演示：

1. 估计三维手部姿态；
2. 把人的手臂从图像中修补掉；
3. 渲染一台双臂机器人，使其末端执行器沿恢复出的轨迹运动，再把机器人叠加回画面。

作者用 67.5 万帧编辑后的视频预训练视觉编码器，让它预测未来的二维机器人关键点；随后只用每项任务 50 条真实机器人演示微调扩散策略头，同时继续保留这项辅助预测损失。这样得到的策略在新场景中的泛化能力显著优于已有方法。

实验包含三项长时程双臂厨房任务，每项任务都在三个未见场景中测试。**Masquerade** 的表现是基线的 5~6 倍。消融实验表明，**机器人叠加层**和**联合训练**缺一不可；性能还会随编辑后人类视频量近似对数增长。这说明，即使只是以不完美的方式显式缩小视觉具身差距，也能让机器人策略真正利用海量现成人类视频。

【图 1：Masquerade 总览。左：人类第一视角视频经过修补和机器人叠加，成为“机器人化”演示。中：在编辑后视频上预训练视觉表示，并与单一场景中的 50 条真实演示联合训练。右：策略零样本部署到未见环境。】

1. 引言

自然语言处理和计算机视觉的快速进步来自大规模、多样化数据。机器人领域则仍受数据匮乏限制：采集真实机器人数据既慢又贵，因此通用机器人策略远落后于语言和视觉模型。

人类视频覆盖海量真实操作场景，是机器人数据的重要补充。但它们通常没有精确动作标签，而且人与机器人在外观和运动方式上差异很大。已有研究往往用人类视频做代理任务，例如预训练视觉编码器、推断奖励函数、学习世界模型，或者从中提取轨迹和可供性；它们通常让模型靠混合训练自行学会人与机器人之间的对应关系，没有直接处理视觉具身差距。

本文追问：**如果显式缩小这项差距，即便处理得并不完美，是否能从人类视频中释放更多有效信号？**

Masquerade 把 Phantom [13] 的数据编辑思路扩展到真正的野外视频。Phantom 只在固定相机、精心录制的单手演示上验证；本文则面对第一视角相机运动、遮挡、复杂抓握和双手动作。作者先恢复手部姿态，去除人体，再渲染同姿态的模拟机器人并叠回原图，由此构造大规模“机器人化”数据。

训练采用“广泛预训练、针对性微调”的路线：先从编辑视频预测未来二维机器人姿态，再用单一场景中的少量真实演示训练策略。一个关键发现是：微调时必须继续优化人类视频上的预训练目标，否则编码器会很快忘掉学到的跨场景表示。

本文的核心贡献是证明：**用简单的二维修补和机器人覆盖显式处理人与机器人的外观差异，就足以显著提升野外视频对机器人策略的价值。**

2. 相关工作

2.1 野外人类视频

野外视频是未经专门布置的日常活动记录，规模大、场景丰富，但经常带有遮挡、相机运动和不适合机器人的动作标签。

一类工作用它们预训练视觉表示：R3M 在 Ego4D 上使用时间对比和视频—语言目标；Voltron 通过重建和生成对齐视频与文本；MVP、VC-1 使用掩码自编码；HRP 自动挖掘未来接触点、手部姿态和活动物体等可供性信号。另一类工作从视频学习奖励、世界模

型、动作先验或物体中心可供性。LAPA 则用 VQ-VAE 从视频学离散潜动作，再用少量机器人数据微调 VLA。

这些方法很少直接改变画面中的人体外观，因此视觉编码器仍要自行解决具身差距。

2.2 精心采集的人类演示

这类数据专门为机器人学习录制，动作清楚、遮挡较少，有时还有深度相机、VR 或动作捕捉设备提供精确姿态。它更容易与机器人动作对齐，但采集成本高、规模和场景多样性有限。Phantom 首先展示了“删除人手、叠加机器人”的编辑方式，但其条件较理想，不能直接用于野外第一视角视频。

Masquerade 的区别在于：接受姿态估计和叠加中的噪声，以换取真实互联网式视频的规模与多样性。

3. 方法

3.1 问题设定

作者有两个数据集：

- 人类视频集 D_{human} ：包含视频帧和自然语言活动描述，没有机器人动作标签；
- 小规模机器人演示集 D_{robot} ：包含图像、语言任务和机器人笛卡尔末端动作。

目标是通过编辑把 D_{human} 转为 D'_{human} ，预训练一个能理解机器人运动的视觉编码器，再用少量 D_{robot} 学会真正控制机器人，并在未见环境中泛化。

【图 2：数据编辑流水线。检测左右手，恢复 21 个三维关键点，将手部轨迹重定向到双臂机器人，修补掉人体区域，渲染机器人后叠加到原视频。】

3.2 处理野外第一视角视频

实验使用 EPIC-KITCHENS。作者依据数据标注找到每帧中的左右手，再用 HaMeR [45] 估计每只手的 21 个三维解剖关键点：

$$\hat{X}_t \in \mathbb{R}^{21 \times 3}.$$

随后沿用 Phantom 的重定向方法，把关键点映射为机器人末端姿态：

$$P_t = (p_t, R_t, g_t),$$

其中 $p_t \in \mathbb{R}^3$ 是笛卡尔位置， R_t 是方向， $g_t \in [0, 1]$ 是夹爪开合量。轨迹经过时间平滑，以减小姿态估计抖动。

接着，系统分割并修补掉人的手臂和身体，把按恢复轨迹运动的双 Kinova 机器人渲染出来，再覆盖到视频中。为了让训练画面更一致，真实机器人数据里的机器人也会先被修补，再叠加一份渲染机器人。

野外数据有两个主要问题。第一，快速相机运动与固定底座机器人的设定不相容；第二，姿态估计可能产生越界或运动学无效动作。因此作者过滤相机运动超过阈值、关键点错误或超出运动学限制的帧。

处理后的叠加并不完美。平行夹爪无法复现所有灵巧抓握；视频没有深度，系统也不知道机器人像素应当位于物体前面还是后面，因而可能出现错误遮挡。但后续实验说明，即便这种粗糙对齐，也比完全不做对齐强得多。

3.3 策略学习

模型包含语言条件视觉编码器 $f(x, z)$ 和扩散动作头 $g(\cdot)$ 。

视觉编码器预训练

对每个编辑后视频片段，作者用 DistilBERT 得到固定语言嵌入 z_x ，并通过 FiLM 注入视觉编码器。模型从当前图像预测未来 H 步的二维机器人关键点。目标为：

$$\mathcal{L}_{2D} = \|h(f(x, z_x)) - p_{t:t+H, 2D}\|^2, \quad x \sim D'_{human},$$

其中 h 是小型 MLP， $p_{t:t+H, 2D}$ 是未来二维关键点序列。这个目标迫使视觉表示同时理解任务语义、场景物体和机器人接下来应如何运动。

用联合训练学习机器人策略

作者随后用少量任务专用机器人演示训练模仿学习策略。真实机器人动作经过映射 $P(r)$ 后，策略损失为：

$$\mathcal{L}_{policy} = \|g(f(y)) - P(r)\|^2, \quad y \sim D_{robot}.$$

训练机器人策略时不停止人类视频任务，而是同时优化：

$$\mathcal{L} = \mathcal{L}_{2D} + \lambda \mathcal{L}_{policy}.$$

这就是文中的 **co-training**（联合训练）。它持续提醒编码器保留从多场景人类视频获得的表示，避免在只有一个场景、50 条演示的小数据上过拟合。

4. 实验

4.1 实验设置

机器人平台由两台 Kinova 机械臂和两个平行夹爪组成。模型使用来自 EPIC-KITCHENS 的 1 万个片段，共 67.5 万帧；每项机器人任务只有 50 条真实演示，全部来自同一个场景。

视觉编码器是以 ImageNet 权重初始化的 ViT-Base，动作头使用 Diffusion Policy。所有比较模型均使用相同规模的 ViT-Base，以免架构容量干扰结论。

三项长时程双臂任务为：

1. **叠锅 (Stack Pots)**：从大锅中拿出小锅；把中号锅放进大锅；再把小锅放进中号锅。
2. **刮土豆 (Scrape Potato)**：拿起装土豆的盘子；拿起刮铲；把土豆从盘中刮进锅里。
3. **扫辣椒 (Sweep Chilis)**：拿起碗并移到桌边；拿起海绵；把辣椒扫进碗里。

每个子步骤占总分的三分之一。每项任务在三个训练时未见的场景测试，每个场景 10 次，共 30 次。

【图 3：三项任务的训练场景，以及每项任务的三个分布外测试场景。】

4.2 基线

- **HRP**：在约 15 万个第一视角人类视频片段上预测未来手姿、活动物体框和接触点，再把编码器用于策略训练；它使用原始人类画面，也不在策略训练阶段继续联合训练。
- **ImageNet**：ImageNet-1K 预训练的 ViT，是机器人控制中非常可靠的通用初始化。
- **DINOv2**：在 1.42 亿张精选图像上自监督训练的强通用视觉模型。

4.3 未见场景性能

Masquerade 在所有任务和所有未见场景中都显著领先。三个任务的平均成功率从基线总体约 **12% 提高到 74%**，平均提升 62 个百分点，约为基线的 5~6 倍。

【图 4：ImageNet、DINOv2、HRP 与 Masquerade 在三个任务上的平均成功率。Masquerade 在每项任务都明显领先；误差条为均值标准误。】

4.4 机器人叠加是否必要

作者训练一个完全相同的变体，但预训练和联合训练都使用未经编辑的原始人类视频。这个“**No Overlay**”版本在三个任务上均大幅下降，说明关键并不只是看过更多厨房视频，而是画面中的机器人外观和可执行运动让人类视频信号变得更容易迁移。

4.5 联合训练是否必要

另一个变体先在人类视频上预训练，随后只优化机器人策略损失。移除联合训练后，表现同样严重下降。原因是仅靠 50 条单场景演示微调时，编码器会遗忘人类视频中学到的多样化视觉表示。

【图 5：无机器人叠加、无联合训练与完整方法的消融比较。两项设计都对分布外成功率至关重要。】

4.6 增加野外视频是否继续有效

作者把联合训练的人类视频量缩放为完整数据的 0%、10%、50% 和 100%，其余训练设置相同。在叠锅任务的一个未见场景中，成功率依次为：

使用的人类视频比例	成功率
0%	2%
10%	26%
50%	47%
100%	68%

性能随数据量单调增长，尚未显示饱和迹象。这直接支持论文的中心论点：增加经过编辑的野外视频，确实会提升机器人策略。

【图 6：数据规模实验，横轴为人类视频比例，纵轴为叠锅成功率；25 次测试，误差条为均值标准误。】

4.7 分布内与分布外

作者在“扫辣椒”任务上比较原训练场景与一个新场景。ImageNet、DINOv2 和 HRP 换场景后都有明显下降，而 Masquerade 的分布内、分布外表现接近，说明它学到的不是训练背景的表面特征。

【图 7：各方法在训练场景与新场景中的平均成功率。Masquerade 的跨场景跌幅最小。】

5. 局限与未来工作

1. 方法依赖手部姿态估计，姿态错了，机器人重定向也会错。
2. 缺少深度信息，无法正确判断渲染机器人与场景物体的前后遮挡关系，抓握画面因而不够真实。
3. 第一视角视频中的相机运动迫使系统过滤大量帧。更好的相机位姿估计，以及带可动相机的移动机器人，可以减少浪费。
4. 人类灵巧抓握被重定向到平行夹爪，本身就是不完美映射。灵巧手和更先进的重定向算法有望进一步缩小差距。

同一套数据编辑流水线还可能服务于奖励学习、运动先验提取和视频生成。将其与深度估计、姿态恢复、视频生成和更强重定向结合，是实现网络规模机器人学习的一条自然路线。

6. 结论

Masquerade 证明，显式缩小人与机器人的视觉具身差距，即便只用简单的二维修补和叠加，也能让机器人策略利用大规模野外人类视频。用 67.5 万帧机器人化视频预训练 ViT-Base，并在每项任务仅有 50 条真实演示时继续联合训练，策略就能零样本迁移到未见场景，在三项长时程双臂任务上超过基线 5 倍以上。

机器人叠加和联合训练都不可省略，且扩大视频数据能稳定提高性能。这一结果提示：与其期待模型自行忽略巨大的人机外观差异，先在数据层面把人“伪装”成机器人，是一条简单、可扩展而且有效的路线。

致谢

本项目获得美国国家科学基金会项目 [#2327974](#) 支持。作者感谢 Jingyun Yang、Carlota Parés-Morlans、Claire Chen、Zen Yaskawa 和 Stanford Robotics Center 提供的帮助。