

MimicPlay：通过观看人类玩耍进行长时程模仿学习

作者：Chen Wang, Linxi Fan, Jiankai Sun, Ruohan Zhang, Li Fei-Fei, Danfei Xu, Yuke Zhu, Anima Anandkumar

单位：Stanford, NVIDIA, Georgia Tech, UT Austin, Caltech

会议：第 7 届 Conference on Robot Learning, CoRL 2023, Atlanta, USA

代码和视频：mimic-play.github.io

摘要

从人类示范中进行模仿学习，是在真实世界中教授机器人操作技能的一种有前景范式。然而，学习复杂长时程任务通常需要数量难以达到的示范。为降低高数据需求，作者转向人类 play data：人们用手自由地与环境交互形成的视频序列。尽管人和机器人形态不同，作者假设人类 play data 包含丰富且显著的物理交互信息，可以直接促进机器人策略学习。

基于这一动机，作者提出名为 MIMICPLAY 的层次化学习框架：它从人类 play data 中学习潜在计划，用来引导由少量遥操作示范训练出的低层视觉运动控制。通过在真实世界 14 个长时程操作任务上的系统评估，作者表明 MIMICPLAY 在任务成功率、泛化能力和抗扰动鲁棒性上优于先进模仿学习方法。

关键词：模仿学习；从人类学习；长时程操作。

图 1

图 1 说明：人类完成长时程任务的速度远快于遥操作机器人。这个观察启发作者开发 MIMICPLAY：一种层次化模仿学习算法，用廉价人类 play data 学习高层规划器，用少量多任务遥操作机器人示范学习低层控制策略。结果显示，MIMICPLAY 显著提升了长时程任务中模仿学习算法的样本效率和鲁棒性。

1. 引言

高效教会机器人执行通用操作任务，是一个长期挑战。模仿学习近年在该方向取得了显著进展，尤其是使用人类遥操作示范或专家策略轨迹进行监督训练。尽管如此，模仿学习方法仍大多局限于短时程原语，例如开门或拿起特定物体。对于复杂真实任务，尤其是初始条件和目标条件分布都很宽的长时程任务，收集示范的时间成本和劳动强度仍然是模仿学习广泛采用的关键障碍。

近期有两个相关方向试图将模仿学习扩展到复杂长时程任务：层次化模仿学习，以及从 play data 学习。前者通过把端到端深度模仿学习拆分为高层规划器和低层视觉运动控制器来提升样本效率。后者利用另一类机器人训练数据，即 play data。通常，play data 由人类遥操作机器人在没有具体任务目标或引导的情况下与环境交互获得。已有工作表明，与典型任务导向示范相比，这类数据覆盖更多样的行为和情境。基于 play data 的方法常训练层次化策略：高层规划器捕获意图分布，低层策略学习面向目标的控制。然而，在真实世界中收集机器人 play data 依然昂贵。例如，C-BeT 需要 4.5 小时 play data 来学习特定场景中的操作技能，TACO-RL 在一个三维桌面环境中需要 6 小时 play data。

本文认为，用于学习高层计划和低层控制的数据可以来自不同形式，这将显著降低复杂长时程任务的模仿学习成本。基于此，作者提出新范式：机器人从人类 play data 中学习高层计划；在这些数据中，人类用手自由地与环境交互。人类 play data 比机器人遥操作数据更快、更容易收集，能够规模化覆盖多样情境和行为。作者展示，这种可扩展性对策略泛化很关键。随后，机器人再从少量人类遥操作机器人的示范数据中学习低层操作策略。与人类

play data 不同，机器人示范数据昂贵，但不存在人类和机器人具身不匹配带来的问题。

为了将模仿学习扩展到长时程操作任务，作者提出 MIMICPLAY。它利用两类数据源的互补优势：人类 play data 和机器人遥操作数据。MIMICPLAY 从人类 play data 中训练目标条件潜在规划器，在给定目标图像的条件下预测未来三维人手轨迹。这些潜在计划在每个时间步提供丰富三维引导，即“做什么”和“在哪里交互”，从而把困难的长时程操作问题转化为有引导的运动生成过程。在这些潜在计划条件下，低层控制器结合细粒度操作所需的状态信息，生成最终动作。

作者在 6 个环境的 14 个真实世界长时程操作任务上评估方法。结果显示，相比先进模仿学习方法，MIMICPLAY 在样本效率和泛化能力上有显著提升。此外，MIMICPLAY 将人类运动和机器人技能整合进联合潜在计划空间，由此形成一个接口：可以直接用人类视频作为“提示”，指定机器人操作任务目标。

主要贡献如下：

- 提出一种从廉价人类 play data 中学习三维感知潜在计划的新范式。
- 提出一个层次化框架，训练由计划引导的多任务机器人控制器，以样本高效的方式完成困难长时程操作任务。
- 在 14 个真实世界长时程评估任务中，MIMICPLAY 达到先进性能，能泛化到新任务并干扰动鲁棒，同时支持用人类视频提示机器人运动。

2. 相关工作

从示范中模仿学习。 模仿学习已使机器人成功执行多种操作任务。DMP、PrMP 等传统方法样本效率高，但难以处理高维观测和需要闭环控制的情形。相比之下，基于深度神经网络的近期方法能从原始示范数据中学习反应式策略，灵活性更强；但即使学习简单 pick-and-place 任务，也需要大量人类示范，仍然费工费资源。本文改为利用无需机器人硬件、可高效收集的人类 play data，大幅减少对机器人本体示范数据的需求。

层次化模仿学习。 本文从示范中学习层次化策略的想法与已有工作相关。但此前方法都使用单一数据类型，即昂贵的遥操作机器人示范，同时学习规划和控制。本文用廉价人类 play data 学习高层规划，用少量机器人示范学习低层控制，在保持低示范数据需求的同时显著增强模型规划能力。

从人类视频学习。 大量近期研究探索利用大规模人类视频数据改善机器人策略学习。与本文密切相关的是 R3M 和 MVP，它们使用互联网规模人类视频数据集 Ego4D 预训练视觉表征，再用于后续模仿学习。但由于数据源多样且域差距大，将预训练表征迁移到特定操作任务可能困难。另一些工作利用域内人类视频，即人类直接用手与机器人任务环境交互；这类数据在人类和机器人域之间差距更小，可以用于样本高效的奖励塑形和模仿学习。但这些工作主要从人类视频中学习任务奖励或特征，并不直接帮助低层机器人动作生成。本文从人类 play data 中抽取有意义的轨迹级任务计划，为低层控制器解决长时程操作任务提供高层引导。

从 play data 学习。 本文利用人类 play data 的想法受到 learning from play 的启发。该范式关注从没有具体目标的遥操作机器人 play data 中进行多任务学习。尽管 play data 行为多样，但它需要费力的遥操作过程。本文改为从人类 play data 学习，即人类用手自由与场景交互。这种数据收集方式非常省时，每个环境只需 10 分钟，同时为机器人运动生成提供丰富的轨迹级引导。因此，机器人只需要极少量遥操作数据，实验中少于 30 分钟，就能把引导转化为自身运动命令，成功完成复杂长时程操作任务。

3. MimicPlay

训练机器人完成长时程任务很困难，因为它既需要高层规划来决定不同阶段“在哪里交互”和“与什么交互”，也需要低层运动控制来决定“如何达到目标”。MIMICPLAY 的关键洞察是：高层规划可以从快速收集的人类 play data 中有效学习；低层控制技能则最适合从没有具身差异的遥操作示范中获得。由于人类和机器人具身不同，找到一种能弥合两类数据源差距的中间表征至关重要。MIMICPLAY 通过学习三维感知潜在规划空间，从低成本人类 play data 中抽取多样计划来解决该问题。图 2 给出了方法总览。

3.1 收集人类 play data

人类 play data。 作者利用人类 play data：人类操作者受好奇心驱动，用一只手自由地与场景交互。例如在厨房中，操作者可能先打开烤箱再拉出托盘，或拿起平底锅放到炉子上。这类数据包含丰富的状态转移，以及人类关于物体可供性和部件功能的隐式知识。更重要的是，人类 play data 比遥操作更便宜、更高效，因为它不需要任务标签，也不需要重置环境，只需要很短时间：一个人类操作者 5 秒就能完成机器人遥操作需要 90 秒的任务。本文为每个任务环境收集 10 分钟人类 play 视频作为训练数据，约等价于 3 小时机器人遥操作视频数据。

跟踪三维人手轨迹。 人类进行 play 时，会在心中构造一系列运动，然后用手与环境物理交互。这个过程形成手部轨迹，包含个体潜在意图的丰富信息。基于这些手部轨迹，机器人可以通过在目标条件下重建手部轨迹，学习模仿人类运动规划能力。常见人类视频数据集通常只有单视角观测，只提供二维手部轨迹，这会带来深度轴歧义和遮挡问题。因此，作者使用两个标定相机从人类 play data 中跟踪三维手部轨迹。具体做法是用现成手部检测器从两个视角识别手部位置，再基于标定相机参数重建三维手部轨迹。数据收集流程和系统细节见附录。

图 2

图 2 展示 MIMICPLAY 总览。训练阶段 1：用廉价人类 play data 训练目标条件轨迹生成模型，构建包含多样任务目标高层引导的潜在计划空间。训练阶段 2：用少量遥操作数据训练低层机器人控制器，控制器以预训练并冻结的规划器生成的潜在计划为条件。测试阶段：给定一个长时程任务视频提示，无论是人类运动视频还是机器人遥操作视频，MIMICPLAY 都生成潜在计划，并引导低层控制器完成任务。

3.2 从人类 play data 中学习三维感知潜在计划

给定一个由目标图像表示的长期任务，策略应在该目标条件下生成动作。作者将问题形式化为层次化策略学习任务：目标条件高层规划器 p 从目标观测 g_t 中提炼关键特征，并将其转换为低维潜在计划 p_t ；这些计划随后用于引导低层运动控制器朝目标运动。然而，学习这种基于视觉的运动规划器需要大数据集，因为它必须处理目标分布中的多模态性。作者用廉价且易收集的人类 play data 解决该问题。

学习多模态潜在计划。 给定收集的人类 play data 及对应三维手部轨迹 τ ，作者将潜在计划学习形式化为目标条件三维轨迹生成任务。卷积网络实现的观测编码器 e 处理人类视频中的视觉观测和目标图像，将它们编码为低维特征，再由基于 MLP 的编码器网络处理为潜在计划向量 p_t 。基于潜在计划 p_t 和手部位置 l_t ，基于 MLP 的解码器生成三维手部轨迹预测。

但是，简单回归轨迹无法覆盖人类运动中丰富的多模态分布。即使同一个人类操作者，一个任务目标也可以用不同策略完成。为解决这一点，作者使用基于 MLP 的高斯混合模型（GMM）从潜在计划 p_t 建模轨迹分布：

$$p(\tau \mid \theta) = \sum_z p(\tau \mid \theta, z) p(z \mid \theta) \quad (1)$$

其中 $\theta = \{\mu_k, \sigma_k, \eta_k\}_{k=1}^K$ 是 GMM 参数， $p(\tau \mid \theta, z_k)$ 是高斯分布， z 包含 K 个分量，权重 η_k 表示第 k 个分量的概率。GMM 比简单 MLP 表达力更强，因为它能捕获人类 play data 中固有的多模态性。最终学习目标是使检测到的三维人手轨迹的负对数似然：

$L_{\text{GMM}}(\theta) = -E_{\tau} \log \sum_{k=1}^K \eta_k N(\tau | \mu_k, \sigma_k)$, 其中 $0 \leq \eta_k \leq 1$ 且 $\sum_k \eta_k = 1$ 。(2)

处理人类域和机器人域之间的视觉差距。作者考虑人类和机器人在同一环境中交互的设置。但两者视觉外观不同，会给将学到的潜在规划器迁移到下游机器人控制带来挑战。作者引入新的学习目标，最小化两个域的视觉表征差距。给定人类视频帧和机器人本体视频帧，在每个训练 batch 中，计算视觉编码器输出特征嵌入的人类域分布和机器人域分布，并用 KL 散度损失最小化二者距离： $L_{\text{KL}} = D_{\text{KL}}(Q_r || Q_h)$ 。注意，该方法不要求成对的人类-机器人视频数据；两类视频可以包含不同行为、解决不同任务，只使用视频图像帧来缩小表征差距。潜在规划器最终训练损失为：

$$L = L_{\text{GMM}} + \lambda * L_{\text{KL}}$$

其中 λ 控制两个损失的权重。

3.3 计划引导的多任务模仿学习

MIMICPLAY 聚焦多任务模仿学习：训练单一策略，在不同目标条件下执行多个任务。已有工作通常从头端到端学习多任务视觉运动策略。但由于目标空间很大，这些方法需要大量遥操作数据。本文利用用 10 分钟人类 play data 预训练的潜在规划器 p ，将高维输入压缩为低维潜在计划向量 p_t 。由于这些计划能为低层机器人动作 a_t 生成提供丰富三维引导，低层策略 π 可以专注学习从低维计划到动作的转换；由于机器人示范不存在具身差异，这个转换可以高效学习。

训练时，机器人示范提供当前观测、目标图像、机器人末端位置/本体状态和动作。冻结的潜在规划器根据当前观测、目标图像和机器人末端位置生成潜在计划，低层策略再以腕部图像、本体感知和潜在计划为输入预测机器人动作。测试时，可以用一段人类视频或机器人视频作为提示，从视频中逐步取目标图像，引导潜在规划器和低层策略完成长时程任务。

图 3

图 3 展示六个 Franka Emika 机器人长时程评估环境及其初始状态和目标状态：厨房、书桌、插花、白板、三明治、布料。任务包括：厨房环境中的 3 个任务，例如用烤箱做食物；书桌环境中的 7 个任务，例如整理桌面；将花插入花瓶；擦除白板曲线；为芝士汉堡或三明治选择食材；将毛巾折叠两次。细节见附录。

4. 实验设置

作者在真实机器人上设计了 6 个环境、共 14 个长时程操作任务。环境覆盖多种挑战：接触丰富的工具操作、关节物体操作、高精度任务和可变形物体操作。主要比较对象包括目标条件行为克隆、从机器人 play data 学习的 C-BeT 和 LMP、使用互联网人类视频预训练视觉表征的 R3M-BC，以及若干 MIMICPLAY 消融版本。

基线包括：

- GC-BC (BC-RNN)：用 RNN 实现的目标条件行为克隆。
- GC-BC (BC-trans)：用 GPT 式 Transformer 实现的目标条件行为克隆。
- C-BeT：从遥操作机器人 play data 学习的目标条件方法，用 Behavior Transformer 实现。
- LMP：从遥操作机器人 play data 学习潜在计划的方法；LMP(single) 为每个任务单独训练模型。
- R3M-BC：使用 Ego4D 预训练视觉表征的目标条件模仿学习框架；R3M-BC(single) 为每个任务单独训练模型。

消融版本包括：

- Ours：完整 MIMICPLAY，使用 10 分钟人类 play data。
- Ours(single)：每个任务单独训练模型。
- Ours(0% human)：不使用人类 play data，只用遥操作机器人示范训练潜在计划空间。
- Ours(50% human)：用 50% 人类 play data，即 5 分钟训练潜在规划器。
- Ours(w/o GMM)：不用 GMM 从人类 play data 学习潜在计划空间。
- Ours(w/o KL)：预训练潜在规划器时不用 KL 损失处理人类和机器人数据的视觉差距。

5. 结果

作者的真实世界实验显示，MIMICPLAY 在长时程任务成功率、子目标完成率、样本效率和泛化能力上均优于基线。相比只使用机器人示范的行为克隆方法，MIMICPLAY 通过人类 play data 学到的潜在计划显著增强了高层规划能力。相比同样层次化但依赖机器人 play data 的方法，MIMICPLAY 降低了数据收集成本。相比使用 R3M 等大规模人类视频预训练视觉表征的方法，MIMICPLAY 不是只迁移视觉特征，而是抽取轨迹级计划，因此更直接服务于低层动作生成。

消融结果显示，人类 play data、GMM 多模态建模和 KL 域对齐都很重要。去掉人类数据会使潜在计划过拟合训练任务中的子目标转移，难以处理新组合；去掉 GMM 会削弱对多模态人类运动的建模；去掉 KL 损失会使人类数据和机器人数据的视觉嵌入分布重叠减少，进而影响迁移。

作者还展示了 MIMICPLAY 的实时重规划能力。完整系统，包括视觉潜在规划器、低层引导策略和机器人控制，以 17Hz 运行，因此可以面对扰动和操作误差进行实时重规划。

6. 结论与局限

MIMICPLAY 当前仍有若干局限。第一，目前的高层潜在计划从特定场景的人类 play data 中学习；如果能在互联网规模数据上训练，其可扩展性将显著受益。第二，目前任务局限在桌面设置，但人类是可移动的，其导航行为包含丰富高层规划信息；该工作可以扩展到更具挑战性的移动操作任务。第三，跨具身表征学习仍有很大提升空间，可能方向包括视频中的时间对比学习和循环一致性学习。

作者提出 MIMICPLAY：一种可扩展的模仿学习算法，利用两类数据源的互补优势，即低成本人类 play data 和小规模遥操作机器人示范。使用人类 play data，高层控制器通过在目标图像条件下预测未来三维人手轨迹来学习目标条件潜在计划；使用机器人示范数据，低层控制器再根据潜在计划生成机器人动作。通过这种层次化设计，MIMICPLAY 在 14 个困难长时程操作任务中比已有方法高出超过 50%，为未来以较低人力成本扩大机器人模仿学习规模开辟道路。

致谢

本工作部分由 ONR MURI N00014-21-1-2801 支持。Li Fei-Fei 部分由 Stanford HAI Hoffman-Yee Research Grant 支持。该工作在 Chen Wang 于 NVIDIA 实习期间完成。Stanford 为本项目提供计算资源和机器人硬件。作者特别感谢 Yifeng Zhu、Ajay Mandlekar 在开发机器人控制库 Deoxys 和 RoboTurk 中的努力，也感谢 Yucheng Jiang 协助进行仿真中的多随机种子评估。

参考文献

参考文献条目按原 PDF 保留，避免误改作者名、题名和出处。PDF 中列出了 64 条参考文献，涉及模仿学习、运动基元、层次化策略、机器人 play data、从人类视频学习、视觉表征预训练、机器人控制库、仿真平台与基准等。

附录 A：实现细节

这里给出数据收集、训练和测试流程细节。

收集人类 play data 与训练细节。 每个场景中，人类操作者用一只手直接与场景交互 10 分钟，收集人类 play data。完整轨迹以每秒 60 帧记录，不切分也不标注。三维手部轨迹用现成多视角人手跟踪器检测。10 分钟视频总帧数约 36k。作者为每个环境用收集到的人类 play data 训练一个潜在规划器。多环境设置中，将每个场景的人类 play data 合并训练单个潜在规划器。潜在规划器包含两个用于图像处理的 ResNet-18 网络、基于 MLP 的编码器-解码器网络，以及一个含 $K=5$ 个分布分量的 GMM。潜在规划器训练 100k 次迭代，在单 GPU 机器上约需 12 小时。

收集机器人示范与训练细节。 机器人遥操作数据通过基于 IMU 的手机遥操作系统 RoboTurk 收集。机械臂控制频率为 17-20Hz，夹爪以 2Hz 控制。每个任务收集 20 条示范；实验中也有 40 条示范数据集，用于测试不同方法的样本效率。机器人策略模型是 GPT 式 Transformer，包含 4 层多头注意力，每层 4 个头。策略训练 100k 次迭代，在单 GPU 机器上约需 12 小时。为了公平比较，不使用人类 play data 的基线在训练潜在规划器和低层策略时额外使用 5 条示范。

视频提示。 本文使用一次性视频 v 作为提示，可以是人类视频或机器人视频，让预训练潜在规划器生成对应计划。训练时，目标图像取自机器人示范中输入观测之后 H 步的帧， H 在 200 到 600 之间均匀采样，对应现实时间 10-30 秒。这里的 l_t 是机器人末端执行器三维位置。推理时，假设可访问一个任务视频作为目标图像来源。目标图像从任务视频第 200 帧开始，每一步向后移动 i 帧；所有实验使用 $i=1$ 。潜在规划器生成形状为 $R^{1 \times d}$ 的潜在计划特征嵌入，用于引导低层机器人策略。

数据可视化。 表 9 可视化了收集的人类 play data 和机器人示范数据。对于人类 play data，作者使用现成手部检测器在左右图像帧中定位手的二维位置，并用红色框显示。对于机器人示范，作者直接将机器人末端执行器三维位置投影到左右图像帧，并用蓝色框显示。

测试。 作者在 Franka Emika 机械臂上以 17Hz 控制频率进行实时推理，从原始图像输入直接输出 6 自由度机器人末端执行器和夹爪控制命令。机器人使用操作空间控制（OSC）。

附录 B：实验设置

环境。 六个环境共 14 个任务，环境如图 3 所示，均面向 Franka Emika 机械臂。挑战包括：接触丰富的工具操作（擦白板）、关节物体操作（打开烤箱和书桌上的盒子）、高精度任务（插花、按按钮开灯）、可变形物体操作（折布）。

任务。 厨房环境设计 3 个任务，书桌环境设计 4 个训练任务，目标各不相同。本文关注长时程任务，要求机器人完成多个子目标。为了分析方法性能，作者定义 Subgoal 类别，只统计第一个子目标是否完成；Long horizon 类别统计完整任务。书桌环境另设计 3 个组合泛化任务，测试模型对训练集未包含的新任务目标序列的泛化能力。Easy 是两个训练任务及其子目标的简单拼接；Medium 包含一对子目标之间未见过的组合转移；Hard 包含两个这样的未见转移。其余四个环境各有一个任务目标，分别体现新空间配置泛化、极长时程和可变形物体操作等挑战。

表 4

表 4 给出 LIBERO 仿真中的定量评估结果，成功率为 5 个随机种子的平均值。GC-BC(BC-RNN) 和 GC-BC(BC-trans) 在第一个子目标上能取得较高成功率，但在更复杂子目标和长时程任务中几乎失败。Ours(0% human) 即使不使用人类数据，也凭借层次化框架在多数任务上明显优于这些基线，例如长时程任务 Task-1 为 0.58、Task-3 为 0.62、Task-5 为 0.67。

附录 C：补充实验结果

仿真结果。 为了用更多测试试验和训练随机种子评估方法，作者在 LIBERO 仿真中实验。LIBERO 是基于 robosuite 和 MuJoCo 的多任务机器人操作基准，使用 BDDL 语言进行目标指定，便于评估从 play data 学习的多任务设置。主文中使用人类 play data，但仿真中无法获得这种数据，最终只能是机器人遥操作。因此该实验使用相同遥操作机器人 play 数据训练高层规划器和低层控制器，并报告 Ours(0% human) 与基线结果。每种方法用 5 个随机种子训练，并报告 100 次测试试验的平均成功率。结果显示 MIMICPLAY 层次化策略学习框架优于基线，与真实世界结果一致。实现代码可见 <https://github.com/j96w/MimicPlay>。

轨迹预测结果可视化。 图 6 将从潜在计划解码出的三维轨迹投影到二维图像上。最后两行展示未见子目标转移的结果。本文模型生成的轨迹最接近真实轨迹；Ours(0% human) 过拟合训练集中的子目标转移，并生成错误潜在计划。例如训练数据中机器人只学过关灯后打开盒子，而 Easy 泛化任务要求关灯后拿起笔；Ours(0% human) 仍输出打开盒子的潜在计划，因盒子已经打开而导致任务失败。

Transformer 架构有助于多任务学习。 表 1 中，在 40 条示范的 Subgoal 设置下，使用 GPT Transformer 的 GC-BC(BC-trans) 比 GC-BC(BC-RNN) 高 30% 以上。但在 20 条示范设置下，GC-BC(BC-trans) 性能很快降至与 GC-BC(BC-RNN) 相同水平。这说明端到端训练基于视觉的 Transformer 策略需要更多数据。

学到的潜在计划可视化。 作者用 t-SNE 可视化不同任务条件下生成的潜在计划。结果显示，同一任务的潜在计划倾向于在潜在空间中聚类，说明本文方法能有效区分不同任务。

分析人类和机器人数据的视觉差距。 为缩小人类 play data 和机器人示范数据之间的视觉差距，方法中对视觉编码器输出的特征嵌入使用 KL 散度损失。图 7 中，作者用 t-SNE 将 Ours 和 Ours(w/o KL) 学到的特征嵌入可视化为二维分布，并用斜线标出两种数据分布的重叠区域。使用 KL 损失的方法，相比不用 KL 的版本，人类数据和机器人数据之间的重叠面积大 23%。这说明 KL 散度损失有效，也支持表 2 中 Ours(w/o KL) 成功率低于 Ours 的结果。

图 6

图 6(a) 显示由不同方法学到的潜在计划解码出的轨迹预测结果。轨迹颜色从蓝到绿逐渐变淡，表示时间步从 1 到 10。图 6(b) 是潜在计划的 t-SNE 可视化，同一任务的潜在计划倾向于在潜在空间中聚类。

图 7

图 7 比较人类数据和机器人数据输入后生成的特征嵌入分布。斜线表示两个数据分布的重叠区域。图 7(a) 是不用 KL 散度损失的可视化，图 7(b) 是使用 KL 散度损失的可视化。本文方法比基线多覆盖 23% 的重叠区域。

附录 D：系统设置细节

图 8 展示数据收集系统设计。人类 play data 通过让人类操作者用一只手直接与环境交互来收集。左右相机以每秒 100 帧记录视频。收集时没有给定具体任务目标，操作者基于好奇心自由与场景互动。每个实验场景收集 10 分钟人类 play data。

机器人遥操作示范通过手机遥操作系统 RoboTurk 收集。左相机、右相机和末端腕部相机以每秒 20 帧记录视频，与机械臂控制速度 20Hz 对齐。每条机器人示范序列有预定义任务目标。收集过程中，人类示范者逐个完成指定子目标，最终完成整个任务。每个训练任务收集 20 条示范。在厨房环境中，每个任务收集 40 条示范，用于判断哪种方法样本效率更高。

图 8

图 8(a) 是人类 play data 收集：人类操作者用一只手直接与场景交互，根据好奇心执行有趣行为，没有具体任务目标。图 8(b) 是机器人示范数据收集：人类示范者使用手机遥操作系统控制 6 自由度机器人末端执行器；夹爪通过按下手机界面上的按钮控制。

附录 E：任务设计细节

每个长时程任务都有预定义初始状态和子目标。只有当所有子目标按正确顺序完成时，整个任务才算完成。

E.1 厨房

Task-1. 初始状态：抽屉位于桌子左侧，未完全打开，里面有南瓜和生菜；关闭的微波炉位于桌面右侧；碗和炉子位于桌面下边缘；碗里有胡萝卜；平底锅在炉子上。子目标：打开微波炉门；拉出微波炉托盘；拿起碗；把碗放到微波炉托盘上。

Task-2. 初始状态同 Task-1。子目标：打开抽屉；拿起胡萝卜；把胡萝卜放进抽屉。

Task-3. 初始状态同 Task-1。子目标：拿起平底锅；把平底锅放到桌上；拿起碗；把碗放到炉子上。

E.2 书桌

Task-1. 初始状态：书在架子上；灯亮着；盒子以随机状态打开或关闭；笔位于桌子中央或盒子里。子目标：关灯；拿起书；把书放到书架位置。

Task-2. 初始状态：书位于书架或架子上；灯关着；盒子关着；笔在桌子中央。子目标：开灯；打开盒子；拿起笔；把笔放进盒子。

Task-3. 初始状态：书在架子上；灯状态随机；盒子关着；笔在桌子中央。子目标：打开盒子；拿起笔；把笔放进盒子；拿起书；把书放到书架。

Task-4. 初始状态：书位于书架或架子上；灯亮着；盒子关着；笔位于桌子中央或盒子里。子目标：打开盒子；关灯。

Easy. 初始状态：书位于书架或架子上；灯关着；盒子关着；笔位于桌子中央或盒子里。子目标：开灯；打开盒子；关灯。

Medium. 初始状态：书位于书架或架子上；灯亮着；盒子关着；笔在桌子中央。子目标：打开盒子；关灯；拿起笔；把笔放进盒子。

Hard. 初始状态：书在书架上；灯亮着；盒子关着；笔位于桌子中央或盒子里。子目标：关灯；打开盒子；拿起书；把书放到书架。

E.3 插花

初始状态：两朵花和一个花瓶放在桌上；花瓶随机放在桌面左上角或右上角。子目标：拿起一朵花；把花插入花瓶；拿起另一朵花；把花插入花瓶。

E.4 白板

初始状态：白板和板擦放在桌上；板擦在白板左侧。子目标：拿起板擦；移动到曲线上方；擦除曲线；把板擦放回原位。

E.5 三明治

初始状态：圆形食材选择器位于桌面右上角；半圆中是三明治食材（面包、生菜、番茄片），另一半是芝士汉堡食材（面包、奶酪、汉堡肉饼）；白色盘子位于桌面左下角。三明治子目标：旋转食材选择器到正确位置，拿起一片面包放到盘子上；旋转到正确位置，拿起生菜放到面包上；旋转到正确位置，拿起番茄片放到生菜上；旋转到正确位置，拿起另一片面包放到番茄上。

E.6 布料

初始状态：一块未折叠的棕色布随机放在桌上。子目标：机器人将布对折一次，变成原大小的二分之一；机器人再折叠一次，变成原大小的四分之一。

附录 F：训练超参数

表 5 列出潜在规划器 $\mathcal{P}$ 的训练超参数：batch size 16，学习率 $1e-4$ ，epoch 1000，无学习率衰减，KL 权重 1000，MLP 维度 $[400, 400]$ ，左右视角图像编码器均为 ResNet-18，图像特征维度 64，GMM 模式数 5，最小标准差 0.0001，标准差激活函数 Softplus。

表 6 列出机器人策略 $\mathcal{P}_i$ 的超参数：batch size 16，学习率 $1e-4$ ，epoch 1000，训练序列长度 10，学习率衰减因子 0.1，衰减 epoch 为 $[300, 600]$ ，MLP 维度 $[400, 400]$ ，腕部图像编码器 ResNet-18，图像特征维度 64，GMM 模式数 5，最小标准差 0.01，标准差激活 Softplus，GPT block size 10，头数 4，层数 4，嵌入大小 656，dropout 0.1，GPT MLP 维度 $[656, 128]$ 。

表 7 列出 GC-BC(BC-trans) 的超参数，整体与机器人策略类似，但包含腕部、左视角、右视角三个 ResNet-18 图像编码器。

附录 G：网络架构

基于 Transformer 的策略网络。 T 个时间步的嵌入序列表示为 $[w_t, e_t, p_t, \dots, w_{t+T}, e_{t+T}, p_{t+T}]$ ，并送入 Transformer 架构。Transformer 模型通过 N 层自注意力和前馈网络处理输入嵌入。给定 $T-1$ 个时间步的嵌入序列，模型以自回归方式生成轨迹预测嵌入。多头自注意力机制使模型在每一步从完整历史轨迹中汇聚上下文和依赖。最终机器人控制命令由两层全连接网络处理动作特征得到。为了处理机器人动作的多模态分布，作者同样使用基于 MLP 的 GMM 进行动作生成。

图 9

图 9 是数据集可视化，展示厨房和书桌场景中人类 play data 与机器人多任务示范的左右视角时间序列。人类 play data 中手部位置以红色框标出；机器人示范中末端执行器位置投影以蓝色框标出。