

Qwen-RobotManip 技术报告：通过对齐，让机器人操作基础模型真正受益于规模扩展

原文：Qwen-RobotManip Technical Report: Alignment Unlocks Scale for Robotic Manipulation Foundation Models。Qwen 团队，2026 年 6 月，本文对应所提供的 arXiv:2606.17846v2 PDF。

阅读说明：按中文技术文章的习惯翻译，合并跨页和断行，适当合并重复表述，但保留方法、实验、公式、限制和图表说明。文中的“我们”指论文作者。VLA 指视觉-语言-动作模型，VLM 指视觉语言模型，EEF 指末端执行器，embodiment 译为“机器人形态”或“具身平台”，episode 译为“一段完整示范/一次任务执行”。原文参考文献在文末保留英文，方便检索。

摘要

语言和多模态基础模型之所以能够表现出很强的泛化能力，一方面是因为异构数据可以通过统一的建模方式对齐，另一方面是因为互联网上有大量低成本数据，让不同来源的训练信号能够在大规模训练中互相增强。这份报告研究的是：同样的规模扩展方法能否用于机器人操作，让模型获得真正的泛化能力？

这件事比处理文本困难得多。机器人操作数据天然存在异构性，采集成本高，多样性也有限，因此很难同时做到数据对齐和规模扩展。

我们提出 Qwen-RobotManip，这是一个基于 Qwen-VL 的、具有泛化能力的 VLA 基础模型。它从表示、运动和行为三个层面统一对齐操作数据，让大规模多源训练中的信号彼此一致，而不是互相冲突。这种对齐能力使模型能够吸收此前训练方案难以有效利用的大规模操作数据。

为了提供可扩展的数据来源，我们建立了一个人到机器人的合成流程，把第一人称人手示范转成 15 种机器人平台上的轨迹；同时，通过严格的数据整理流程统一真实机器人与合成数据。令人意外的是，仅使用开源机器人操作数据集和人类示范视频，不进行任何专有机器人数据采集，我们就构建了约 38,100 小时的预训练语料，并观察到涌现出的泛化能力，包括零样本指令遵循、抗扰动能力、根据反馈恢复错误，以及跨机器人形态的知识迁移。

实验还发现，多数标准基准无法系统地反映预训练质量。因此，我们把分布外（OOD）评测作为衡量真正泛化能力的主要依据，使用 RoboCasa365、LIBERO-Plus、EBench、RoboTwin-Clean2Rand，以及新提出的指令遵循基准 RoboTwin-IF 和跨形态迁移基准 RoboTwin-XE。Qwen-RobotManip 在所有 OOD 设置上显著优于包括 $\pi 0.5$ 在内的此前先进模型，在 RoboChallenge 中获得第一名，相对提升约 20%，并在 AgileX ALOHA、Franka、UR 和 ARX 等真实平台上得到验证。

【首页总览图】左侧是超过 38,100 小时的多源操作数据及 15 平台人到机器人合成；中间是表示、运动、行为三层对齐；右侧是分布内性能、真实机器人测试、任务与场景泛化、指令遵循和跨形态迁移，以及随数据增长出现的泛化能力。

1. 为什么要先对齐，再扩大规模

大语言模型和多模态模型的成功，依赖于统一建模下的异构数据对齐，以及大量廉价的互联网数据。机器人领域能否复用这条路径，是本文的核心问题。

当前 VLA 模型虽然不断在标准基准上刷新成绩，但展示出来的泛化往往比较表面。很多工作中的 OOD 测试只是轻微改变视觉输入，机器人形态、任务结构和工作空间布局仍与采集训练数据时相同。一旦超出这些狭窄条件，性能就会急剧下降。

预训练先验难以迁移，有两个原因。第一，现有机器人示范数据主要集中在少数遥操作设置中，机器人形态和任务多样性不足，无法支撑有效的规模扩展。第二，也是更根本的原因：只有多样性，没有对齐，仍然不够。不同机器人的观察和动作表示互不兼容时，更多数据带来的可能是干扰，而不是协同。

此前的跨形态方法使用共享架构、机器人形态 token 或统一动作 token 化，但如果没有让同一种物理运动在不同机器人上具有一致的数值表示，新增数据就很难转化为能力增长。对齐不是独立的工程选项，而是数据规模扩展的前提。

Qwen-RobotManip 遵循“先对齐，再扩大规模”的原则，采用三个互补机制：

- 用统一的状态-动作模板和逐维二值掩码，容纳不同机器人结构。
- 用相机坐标系中的位姿增量表示，让视觉上相似的运动，在不同坐标系下也具有接近的动作数值。
- 把同一次任务执行中的历史作为隐式的机器人形态标识，通过上下文策略适应，调整与运动学相关的行为。

训练采用双流联合训练：一条流学习操作数据，另一条流学习经过整理的视觉语言数据，避免动作预测训练损害 VLM 主干的感知和推理能力。

这种对齐能力进一步支持大规模数据吸收。第一人称人手视频通过人到机器人流程转成 15 平台的数据，真实机器人与合成数据则经过统一清洗，共形成约 38,100 小时的操作数据。整个操作语料来自开源数据和第一人称人类视频，没有额外的专有机人采集，但已出现零样本指令遵循、抗扰动、错误恢复和跨形态迁移能力。

评估方法也必须跟着模型发展。标准域内基准中，没有大规模机器人预训练的模型也能追平甚至超过预训练模型，说明这些测试难以区分真正的泛化和分布内模式记忆。我们因此引入多组 OOD 设置，并设计 RoboTwin-IF 来检验语言是否真正参与控制，而非模型依赖视觉捷径；设计 RoboTwin-XE 来评估对形态明显不同的机器人的零样本迁移。

本文的贡献包括：统一跨形态对齐框架；约 38,100 小时的多源操作数据及用于保留感知推理能力的视觉语言数据；以 OOD 泛化为核心的评估方法；以及在四种真实平台、域内域外、少样本适应和跨形态迁移条件下的验证。模型还在 RoboChallenge Table30-v1 通用策略赛道上取得第一名。

2. 训练数据从哪里来

为了让模型能够泛化到不同机器人、任务和环境，我们整理了三种互补数据：不同硬件上的机器人操作示范、第一人称人类操作视频，以及人到机器人流程生成的合成数据。所有来源都经过统一整理和预处理，使状态、动作、视频和语言标注具有一致性和较高质量。

表 1：操作训练语料组成。

数据类型	形态	任务环境	时长
机器人	单臂	桌面	3,808 小时
机器人	双臂	桌面	6,744 小时
机器人	移动平台与人形机器人	桌面及室内	868 小时
人类	人手；EgoDex、VITRA、EgoVerse	桌面及自然环境	1,933 小时
人到机器人合成	15 种双臂平台，由人类数据合成	桌面及自然环境	24,808 小时

2.1 机器人数据

机器人示范是预训练语料的核心，包括单臂和双臂桌面操作、灵巧操作、移动操作，以及人形机器人的移动与操作，覆盖仿真和真实世界。我们使用九组开源数据，总计超过 11,000 小时。

Open X-Embodiment (OXE) 汇总不同研究机构的真实机器人数据。我们保留 Fractal、Bridge 和 BC-Z 三个高质量单臂桌面子集，涉及 Google Robot 与 WidowX，约 600 小时。

AgiBotWorld-Beta 在 AgiBot G1 双臂平台上采集真实人形机器人操作数据。本文使用配备夹爪的数据，涵盖约 200 类任务、2,400 小时。

RoboMIND 与 RoboMIND 2.0 包含单臂、双臂、ALOHA 和人形机器人的多种真实桌面任务。前者涉及 Franka Emika Panda、UR5e、AgileX Cobot Magic V2.0 和天工；后者扩展到 Franka、UR5、AgileX、ARX、天工和天铁六个平台。两者合计约 1,400 小时。

Galaxea Open-World 在 Galaxea 双臂机器人上采集多样化家务移动操作，约 500 小时。

RoboCOIN 覆盖多种双臂和人形平台。我们保留 AgiBot G1、Airbot MMK2、Alpha Bot 2、AgileX Cobot Magic、Unitree G1edu、Leju、Realman R1 Lite、Realman RMC-AIDA-L、ALOHA 和 Tianqin A2 共十种形态，约 430 小时。

DROID 使用 Franka Panda，在 86 个真实环境中采集单臂自然环境示范，约 95,000 条轨迹、500 小时。

RH20T 是接触丰富的真实数据，涉及 Flexiv、UR5、Franka 和 Kuka 四种机器人，传感模态包括视觉、力与力矩、音频和本体感知，覆盖 42 类技能中的 140 多项任务，约 1,100 小时。

RDT-1B 提供 ALOHA 上 29 小时的双臂操作示范。

InternData-A1 在高保真仿真中生成单臂、双臂操作数据，涉及抓取放置、关节物体操作和长时序任务，总计超过 3,600 小时。

2.2 第一人称人类数据

第一人称人手视频与机器人机载相机的视角天然比较接近，是高效扩展操作数据的来源。我们使用三组带手部姿态标注的数据。

EgoDex 使用 Apple Vision Pro 采集，包含 338K 段示范、194 个桌面任务，共 829 小时、30 Hz 的第一人称视频。每帧提供双手各 25 个关节的 SE(3) 标注，通过多个标定相机和视觉惯性 SLAM 在设备端追踪。我们使用其中 732 小时。

VITRA 对非结构化第一人称视频自动执行三维手部重建、相机轨迹估计和原子动作分割。其约一百万条轨迹来自 Ego4D 的烹饪清洁与一般活动子集、EPIC-KITCHENS、EgoExo4D 和 Something-Something v2。本文使用 Ego4D 与 EPIC-KITCHENS 子集，约 247 小时。

EgoVerse 是协作构建的大规模第一人称操作数据，覆盖 1,362 小时、1,965 项任务、240 个场景和 2,087 名示范者。通过视觉惯性 SLAM 和模型式姿态估计等视觉方法，恢复每只手的 21 个关键点及六自由度头部姿态。我们使用产业贡献部分，约 954 小时。

三者合计约 1,933 小时。所有手部姿态都转为统一的 MANO 参数和 21 关键点表示；没有原生 MANO 标注的来源，通过优化拟合恢复参数。

2.3 人到机器人的数据合成

人手数据和机器人数据之间，既有形态差异，也有视觉域差异。我们把人手轨迹映射到机器人动作空间，并把视频中的人手替换为机器人模型。受到 Phantom、Masquerade 等工作的启发，整个流程明确分成动作对齐和视觉对齐。

【图 1：人到机器人合成流程】输入第一人称视频，依次执行动作重定向与平滑、SAM3 手臂分割、ProPainter 去手修复、机器人基座搜索与 MuJoCo 逆运动学求解、深度引导合成。约 1,933 小时、三种来源的人类视频，在 15 种机器人形态上渲染，最终形成约 24,808 小时合成示范。

动作对齐。 每帧机器人动作为 $a_t = (p_t, R_t, w_t)$ ，其中 p_t 是末端三维位置， R_t 是夹爪方向， w_t 是开口宽度。根据 MANO 三维关键点，先把食指尖和中指尖加权，形成“虚拟指尖”：

$$k_{vf} = 0.7k_{index} + 0.3k_{middle}, \quad p = \frac{1}{2}(k_{thumb} + k_{vf}), \quad w = \|k_{thumb} - k_{vf}\|_2.$$

即夹爪中心取拇指与虚拟指尖的中点，开口宽度取两点的距离。

夹爪姿态用右手正交坐标系 $R = [x \ y \ z]$ 表示。 z 沿夹爪开合方向，即拇指尖与虚拟指尖的连线； $d = k_{vf} - k_{wrist}$ 是手腕到指尖的方向。两者张成夹爪平面， y 是平面法向， x 补全右手系：

$$z = \frac{s(k_{thumb} - k_{vf})}{w}, \quad y = \frac{z \times d}{\|z \times d\|}, \quad x = y \times z. \quad (2)$$

右手 $s = +1$ ，左手 $s = -1$ ，保证左右手映射到一致的夹爪坐标定义。三个轴分别对应接近方向、夹爪平面法向和抓取开合轴。

逐帧检测会产生高频噪声。位置和宽度采用 Savitzky-Golay 滤波，姿态采用高斯加权球面线性插值 (SLERP)，在保留运动结构的同时平滑轨迹。

视觉对齐。 SAM3 根据文本提示生成手臂二值掩码；ProPainter 使用光流引导的视频修复，得到去除人手的干净背景序列 $\hat{I}_t$ 。

一个关键难题是放置机器人的基座。机器人到机器人的迁移有源基座可参考，但人手轨迹没有机器人基座。我们因此优化基座位姿：给定目标末端位姿 T_i^{ee} ，选取覆盖轨迹空间极值的代表性关键帧集合 $\mathcal{K}$ ，最大化可行逆运动学的比例：

$$T_{base}^* = \arg \max_{T_{base}} \frac{1}{|\mathcal{K}|} \sum_{k \in \mathcal{K}} \mathbf{1}[\text{IK}(T_{base}^{-1} T_k^{ee}) \text{ 可行}]. \quad (3)$$

候选基座通过围绕轨迹中心的网格搜索生成，并受机器人最大可达距离约束。15 种形态分别搜索，因为不同臂长、关节配置需要不同基座。

确定基座后，在 MuJoCo 中求解 IK，追踪平滑后的轨迹，渲染机器人图像 I_t^{robot} 和深度 D_t^{robot} 。Depth Anything v3 估计场景的米制深度 D_t ，用深度比较形成遮挡掩码 $M_t^{occ} = \mathbf{1}[D_t^{robot} \leq D_t]$ ，再合成：

$$I_t^{syn} = M_t^{occ} \odot I_t^{robot} + (1 - M_t^{occ}) \odot \hat{I}_t. \quad (4)$$

每个人类示范会转换成 15 种双臂配置，每种配置由两个相同的机械臂组成：Panda、UR5e、ARX-L5、xArm7、Sawyer、Kinova Gen3、IIWA、Jaco、FR3、UR10e、ViperX、WidowX、Piper、YAM 和 AgileX ALOHA。

动作速度对齐。 人手操作通常比机器人遥操作快。训练按来源进行帧采样调整，EgoDex 降到原帧率的 60%（约慢 1.7 倍），EgoVerse 为 45%（约慢 2.2 倍），ViTRA 为 25%（约慢 4 倍）。这里沿用作者对降速的表述。

2.4 数据清洗与预处理

不同机器人、仿真器和采集系统混合后，状态动作信号会存在碰撞造成的离群点、时钟不同步或丢包造成的时间错位、影响优化的极端值，以及同一种机器人在不同数据集中的末端定义不一致。我们对所有来源使用五阶段过滤。

【图 2：多阶段数据清洗】 上方是突变检测、状态动作趋势对齐、极值检测、正运动学一致性、坐标及姿态对齐；下方是语言指令一致性、视频与状态一致性、视频质量过滤。

第一阶段：突变检测。 每维信号先经过中值滤波和 Savitzky-Golay 平滑，提取平滑趋势，再计算原始与平滑轨迹的绝对残差、二阶差分（加速度）和三阶差分（加加速度），

jerk)。残差超过缩放阈值，并且加速度或 jerk 同时超阈值时，标记该帧，避免把缓慢漂移误判为突变。阈值按数据集、机器人、旋转表示、真实或仿真来源，以及基座是否可移动设置。处理从删帧到丢弃整段示范不等。例如 InternData-A1 的突变仅由物理碰撞产生，因此整段丢弃。

第二阶段：状态动作趋势对齐。 正确记录中，动作指令应当先于或同时发生于由它引起的状态变化。时间不同步或丢包会破坏这种因果关系。对共有的关节维度，先平滑状态和动作，用互相关寻找最佳时间偏移，再对时间对齐后的一阶差分计算方向一致性 DA。低于数据集阈值（通常 0.6-0.7）的维度会导致整段示范被排除。若数据是增量动作，先积分恢复绝对值。此步骤发现 RoboMIND 的 UR 类型数据中 81% 的示范存在问题，被排除。

第三阶段：极值过滤。 训练使用分位数归一化，把 $[q_{01}, q_{99}]$ 映射到 $[-1, 1]$ 。按机器人类型计算各维的 1% 和 99% 分位数，排除落在区间 $[q_{01} - \alpha(q_{99} - q_{01}), q_{99} + \alpha(q_{99} - q_{01})]$ 之外的帧，避免极端值扭曲归一化。夹爪维度通常是双峰分布，因此不参与此过滤。

第四阶段：关节与末端的正运动学一致性。 根据 URDF，用 Pinocchio 从关节值计算 FK，并与记录的末端位姿比较。偏差可能来自关节角符号、末端坐标定义、旋转表示、基座假设或记录错误。此阶段主要纠错而不是大量删除数据：固定位置偏移通过调整工具中心点 TCP 解决，双臂相对肩部的位姿转到世界坐标系。检查还发现，相同机器人在不同数据集里也可能使用不同关节角约定，进一步说明统一表示的必要性。

第五阶段：基座坐标和末端方向对齐。 对每个数据集修正旋转，使世界坐标系正 x 始终指向机器人前方，保证跨形态状态动作表示在几何上相容。

此外还进行三项跨模态检查。

指令一致性。 首先把长示范分成子任务片段，让视觉证据集中在局部动作单元上。然后用结构化推理提示，引导 VLM 分析被操作物体、动作语义、时间顺序和主体与环境交互，再给出一致性结论，避免直接二分类产生表面判断。最后，对不一致或模糊片段，由多个独立 VLM 投票裁决，降低单模型偏差。语义不一致的样本不参与训练。

视频状态一致性。 用 URDF 和记录的关节状态渲染机器人在图像平面的投影，再用微调的 SAM3 分割视频中的实际机器人，测量重叠程度。低重叠样本被过滤。图中还说明，若偏差由相机参数造成，可先优化相机参数，否则排除该段示范。

视频质量。 联合图像处理及状态动作信号，移除黑帧、损坏帧、模糊帧和长时间静止片段，尤其是示范边界的冗余静止时间。夹爪闭合等任务关键帧明确保留，避免删掉视觉变化微小但语义重要的转折。

2.5 视觉语言联合训练数据

此前工作表明，VLA 与视觉语言数据联合训练能改善泛化。这样可以保留互联网多模态预训练得到的视觉语义知识，再通过动作专家把知识传给动作生成，使机器人能够理解新指令、面对陌生背景、操作未见物体。

我们从专有数据、RoboPoint、RefSpatial、PixMo、CapsFusion 等开源数据，以及专门合成的具身数据中整理出约 2,800 万条视觉语言样本。

原文口径说明：“没有专有数据采集”针对前述操作语料；本节明确指出视觉语言混合数据包含专有数据。两种说法对应不同的数据流。

这些数据包括六类：

- 1. **通用视觉理解：** 视觉问答、多图推理、从单句到详细段落的图像描述，保留广泛感知和常识推理。
- 2. **空间感知与推理：** 二维/三维定位、点定位、计数、深度比较、距离估计、相机视角推断和操作可行性推理，直接服务机器人空间理解。
- 3. **OCR 与文档理解：** 保留文字、数字和符号识别能力，例如寻找带指定数字的积木。
- 4. **多模态专业知识：** STEM 解题、图表理解、视觉谜题，防止一般推理能力在 VLA 微调中遗忘。
- 5. **指令遵循、多语言和纯文本：** 增强对不同自然语言表达的遵循，支持多语言控制并保留文本生成质量。
- 6. **具身视觉语言数据：** 具身思维链 ECoT、第一人称视频理解、二维轨迹预测，连接网页视觉语言知识与机器人动作。

前五类兼顾保留通用能力和提供空间、定位、OCR 等直接收益。第六类则专门帮助动作生成：ECoT 学习场景感知、进度判断和下一步动作；人类第一人称视频帮助理解手与物体接触、变形、滑动、倾倒，以及抓取、放置和工具使用时的状态变化；二维轨迹把视觉观察和图像坐标下的运动推理连接起来。三者共同构成适合向低层动作预测迁移的表示基础。

表 2：原子动作分类及示例。

类别	动作	中文示例
运动	接近并抓取	伸向桌子左侧的红杯子并抓住它。
运动	移动并松开	把手中的杯子放到木托盘上并松开。
操作	翻转	把锅里的金黄色煎饼翻转 180 度。

类别	动作	中文示例
操作	旋转	顺时针旋转烤箱门上的黑色旋钮。
操作	拨动	把红色电源开关拨到开启位置。
操作	打开	打开柜子左侧的木抽屉。
操作	关闭	合上黑色笔记本电脑。
操作	推	沿桌面向前推黄色积木。
操作	拉	把银色抽屉把手向远离柜子的方向拉。
操作	插入	把红色插销插进板上的圆孔。
操作	施压	把海绵压在桌面上。
操作	点击/按按钮	按下控制面板上的红按钮。
操作	敲击	用木锤敲银色钉子。
特殊	交接	把手中的线缆递向右臂并松开。
特殊	回到初始位置	让机械臂回到初始位置。
特殊	其他	把红杯子里的水倒进玻璃杯。

ECoT 的构建。 对带任务指令的操作轨迹，在采样时间点 t 提取同步的前方、腕部、侧面等多视角图像。标注时另外构建三种辅助上下文：从示范开始到 t 均匀采帧，让强 VLM 总结已完成动作和状态变化，作为记忆摘要；从 t 起以一秒间隔抽取六帧，总结短期未来行为，作为下一原子动作的标注依据；根据 t 在整段中的相对位置，提供粗略进度提示。

强 VLM 输出三部分：当前场景描述，包括物体、空间关系、机械臂位置和夹爪状态；任务进度判断，包括已完成子目标，并明确以“任务已完成”或“任务尚未完成”结束；从表 2 选一个下一步原子操作。

虽然标注模型可以看到额外轨迹信息，提示仍要求文本仅以当前观察和任务指令中的证据表述。训练时，模型只输入当前多视角图像和指令，预测完整三段 ECoT；记忆、未来和粗略进度这些特权信号仅用于提高标注质量，不进入训练输入。实际合成使用开启思考模式的 Qwen3.6-Plus。

第一人称视频理解。 把主相机视频切成不重叠的随机 1.5-3 秒片段，每段在 0%、33%、67%、100% 处抽取四帧，要求强 VLM 描述手臂移动方向、带空间关系的手物交互和物体状态变化。视觉变化很小的片段由 VLM 排除，以免训练静态无信息样本。这补充了基于机器人观察的 ECoT。

二维轨迹预测。 根据估计的相机参数，把机器人末端或人手轨迹投影到图像，帮助 VLM 从两种来源学习运动规划，并减轻深度理解歧义。用包围框判据移除几乎没有运动的样本。

3. 模型怎么设计

3.1 主架构

Qwen-RobotManip 采用解耦架构：视觉语言主干负责多模态感知和语义推理，流匹配动作专家负责连续动作生成。二者端到端联合训练，让专家专注高频精细控制，同时保留并扩展主干的感知推理能力。

视觉语言主干采用 **Qwen3.5-4B**，这是一种早期视觉语言融合的原生多模态模型。ViT 通过动态分辨率的空间合并产生视觉 token，直接插入文本流，与图像和语言统一经过同一个 Transformer。一个或多个相机视图及自然语言指令被联合编码，最后一层隐藏状态维度为 2,560，同时包含细粒度视觉特征和任务语义，作为动作专家交叉注意力的输入。

动作专家是一个用于流匹配的 **Diffusion Transformer (DiT)**，有 10 个 Transformer 块，隐藏维度 768、12 个注意力头。每块先对拼接的状态和动作 token 做自注意力，再对 VLM 隐藏状态做交叉注意力，最后经过 SwiGLU 前馈网络。偶数编号块关注视觉 token，奇数编号块关注语言 token，让不同阶段分别依据空间观察与语言指令生成动作。

本体状态通过两层 MLP 编码，放在带噪动作序列前面。专家还接受去噪时间嵌入及相机相关嵌入。

训练中，真实动作块为 a ，从 $\text{Beta}(1, 1.5)$ 采样 t ，从标准高斯分布采样噪声 ϵ ，构造 $x_t = (1 - t)\epsilon + ta$ ，用均方误差学习速度场 $a - \epsilon$ 。推理使用四步欧拉积分生成动作序列，以降低延迟、支持实时控制。

【图 3：模型总览】Qwen-VL 联合编码多视角图像、结构化形态提示和历史上下文；最后层特征通过交替交叉注意力进入 DiT。状态动作共享 80 维模板，末端动作使用相机坐标系增量。相机与末端类型嵌入参与去噪。VLM 与 VLA 使用独立批次，每个批次只包含视觉问答或视觉-语言-上下文-动作数据中的一种。

3.2 跨形态的状态动作表示

不同机器人的本体状态和动作空间不同。我们用一个 **80 维标准向量** 统一表示，包含两组每臂 29 维的字段，后面再预留 22 维。每臂字段如下：

语义字段	维数	含义
机械臂关节位置	7	机械臂各关节位置
末端位姿	9	三维位置 + 六维连续旋转表示
夹爪状态	1	平行夹爪关节位置
灵巧手关节	12	多指灵巧手的主动关节位置

末尾 22 维可供移动基座速度等额外自由度使用。状态全部采用绝对值；动作中的关节位置也是绝对值，末端位姿则表示相对当前状态的增量。末端旋转动作使用三维旋转向量，状态使用六维旋转表示。

表示说明：原文给出 9 维末端模板，同时说明旋转动作只使用三维旋转向量；这里保留两项原始描述，不把动作误写成六维旋转增量。

不同机器人只填实际存在的字段。单臂七自由度夹爪机器人，例如 Panda，只填一臂的关节、末端和夹爪，其他为零；双臂机器人填两组；有灵巧手的再填手关节。填零的结构缺失维度通过逐维二值掩码排除损失，使梯度只来自有实际语义的维度。

3.3 统一末端运动预测

80 维模板解决的是结构布局差异，还没有解决坐标系差异。同一种运动，在不同数据集里可能相对不同基座或相机表示；模型不得不花容量协调几何不一致，而不是学习技能。

我们把末端动作统一到相机坐标系中的位姿增量，并用位置编码把相机几何注入专家，结合形态相关条件，使视觉相似动作具有接近的数值。

具体地，从 80 维向量提取一或两个独立的 **40 维末端 token**。每臂 29 个有效字段放入 40 维槽，11 维预留；DiT 通过自注意力联合处理。

相机系位姿增量。 不使用基座系绝对位姿、末端局部相对位姿或世界系增量，而使用相机系增量。其核心性质是：图像中看起来相似的动作，在动作空间中也接近，从而对齐视觉与动作、帮助跨形态迁移。训练和推理都需要标定好的相机内外参。

为便于阅读，令 R_{ce} 表示从当前末端坐标系 e 到参考相机系 c 的旋转， R_{ee^*}, t_{ee^*} 表示未来目标末端 e^* 相对当前末端的运动。原文式 (5) 可写为：

$$a_p = \begin{bmatrix} R_{ce}R_{ee^*}R_{ec} & R_{ce}t_{ee^*} \\ 0 & 1 \end{bmatrix}. \quad (5)$$

旋转块通过共轭把相对旋转到相机坐标系；平移块把末端位移旋转到相机坐标系。另一种更紧凑的写法是：

$$a_p = T_{ce^*}T_{ec}. \quad (6)$$

后一式能完全消除末端定义的不一致，但其平移会与末端相对旋转及相机末端偏移耦合，更容易产生长尾分布，对标定误差更敏感，因此实现采用式（5）。

相机感知位置编码。 在 DiT 交叉注意力中加入 CaPE。每个 64 维注意力头中，32 维表示相机位姿，另 32 维使用 RoPE 表示时间。图像 token 采用其来源相机外参，状态动作 token 采用选定参考相机外参。CaPE 为旋转位置编码，在点积注意力中，世界坐标系原点的影响会抵消，只保留视觉 token 与查询状态动作 token 的相对位姿。

参考 GTA 和 PRoPE，CaPE 不仅作用于 key 和 query，还作用于 value 和注意力输出，以加强几何一致性。相机内参则通过将各图像 patch 的归一化图像平面坐标送入可学习线性层，并加到对应 token 上，为各 token 提供视场信息。

末端相关条件。 除去噪时间，还通过自适应层归一化加入两个加性嵌入：末端类型，包括单臂、双臂左、双臂右、第一人称头部和移动基座；相机参数是否可用的二值标志，用于在相机系增量模式与机器人基座相对模式之间切换。

多视角参考相机选择。 单臂训练随机选择外部或腕部相机；双臂随机选择两种策略：两臂共享头部或第三人称相机；或者左臂用左腕相机、右臂用右腕相机。交叉注意力中的每个图像 token 使用自己的相机位姿，状态动作 token 使用所选参考位姿，视图间关系通过旋转编码隐式表示。

3.4 结构化机器人形态提示

提示不仅表示做什么任务，还表示谁执行、如何执行，包含机器人平台、任务指令、按 500 步分箱的示范长度 speed、输入采样帧率 fps，以及相机在机械臂同侧还是对侧。

```
embodiment: robot_aloha
instruction: 把桌上的玩具拿起来，放到垫子上。
speed: 1000
fps: 30
camera view direction: arm side
```

这些字段降低形态、控制、时间结构带来的歧义，提高跨平台适应以及对速度和帧率变化的稳健性。训练以 15% 概率随机丢弃 **embodiment**、**speed** 和 **fps**，让测试时信息不完整也能泛化。

3.5 上下文策略适应

新机器人或新环境的部署，往往需要不更新参数就快速调整行为。受大语言模型上下文学习启发，我们让当前动作预测依赖同一次执行的近期观察动作历史，不做任务专用微调，也不更新参数。

每个决策时刻，模型观察视觉和本体状态，预测 K 步动作块。因此，一个历史上下文块定义为 (o_h, s_h, a_h) ，记录机器人当时“看到什么、处于什么状态、做了什么”。 H 个块构成近期行为窗口。

历史图像放在当前图像前，通过同一次 VLM 视觉编码器前向计算；指令后附图像数量说明，帮助模型识别时间位置。本体状态和动作块通过独立轻量 MLP 投影到 VLM 隐藏空间，并加入块级时间嵌入和块内槽位嵌入：

$$t_h^s = \text{MLP}_s(s_h) + e_h^{\text{temp}}, \quad (7)$$

$$[t_h^{a,0}, \dots, t_h^{a,K'-1}] = \text{reshape}(\text{MLP}_a(\text{flatten}(a_h))) + e_h^{\text{temp}} + e_{0:K'}^{\text{slot}}. \quad (8)$$

这些状态和动作 token 按历史块顺序组成上下文序列：

$$C = [t_0^s, t_0^{a,0:K'}, t_1^s, t_1^{a,0:K'}, \dots, t_{H-1}^s, t_{H-1}^{a,0:K'}] \in \mathbb{R}^{H(1+K') \times D_{\text{vlm}}}. \quad (9)$$

当前状态 s_t 不放进历史编码，仍使用动作头专用状态编码器处理，与基础模型保持兼容。

历史有两种注入方式。“统一模式”把 C 加到 VLM 输入末尾，与视觉语言在因果自注意力中联合处理，再将融合历史的最后层特征传给 DiT；“双路模式”直接把状态动作历史送入 DiT，VLM 上下文长度不变，但融合较浅。默认使用统一模式，让 VLM 完整地联合推理行为、任务和观察。

随机上下文采样很关键。 如果训练总是提供紧邻当前的 H 个动作块，模型可以简单复制最近动作，得到很低训练损失，却没有理解行为动力学。近期历史模糊或不典型时，这个捷径就会失效。我们希望模型学习整段执行的速度模式、抓取策略和交互特征，而非依赖时间接近。

因此训练时从同一示范中的随机位置采样上下文窗口，采样块可能离当前时刻很远，迫使模型提取整段行为风格。部署时再使用最近 H 个块的滚动窗口。这种随机化提高对

缺失、部分或时间错位历史的稳健性。不随机采样时，模型虽训练损失低但任务成功率差；随机采样后才表现出根据整段行为动态调整策略的能力。

4. 训练方案

4.1 预训练

VLA 流包含真实机器人、人手第一人称视频和人到机器人合成轨迹；VLM 流包含上述视觉语言监督。两流联合训练，防止动作优化损害感知语言能力，进而削弱新指令和陌生场景泛化。实际操作数据与视觉语言数据的比例是 **9:1**。

流匹配采用：

$$x_t = (1 - t)\epsilon + ta, \quad \epsilon \sim \mathcal{N}(0, I), \quad t \sim \text{Beta}(1, 1.5),$$

$$\mathcal{L}_{FM} = \mathbb{E}_{a, \epsilon, t} \|f_\theta(x_t, t, s, o) - (a - \epsilon)\|_2^2. \quad (10)$$

梯度同时更新 VLM 主干和动作专家。

为了适配 80 维空间中的不同有效字段，损失使用时间与维度的复合二值掩码：机器人槽位掩码排除不存在的自由度；时间有效性掩码排除清洗标记异常或超出示范边界的步，并在某步无效后屏蔽后续步骤以保持因果一致性；人手有效性掩码在某只手离开相机视野后屏蔽整臂字段，避免监督不可见手轨迹。

三个掩码逻辑与合并。对每个样本，只在有效项上计算平均损失，再对批次平均：

$$\mathcal{L}_{FM} = \frac{1}{B} \sum_{i=1}^B \frac{\sum_{u,j} m_{i,u,j} (f_\theta(x_i, t_i, s_i, o_i)_{u,j} - v_{i,u,j})^2}{\sum_{u,j} m_{i,u,j}}. \quad (11)$$

这里用 u 表示动作步，以免与流匹配时间 t 混淆。每个样本权重相等，不让自由度较多的机器人主导优化。

VLM 流使用标准自回归下一 token 损失：

$$\mathcal{L}_{VLM} = -\mathbb{E} \sum_i \log p_\phi(y_i | y_{<i}, c), \quad (12)$$

$$\mathcal{L} = \mathcal{L}_{FM} + \lambda \mathcal{L}_{VLM}, \quad \lambda = 0.1. \quad (13)$$

视觉语言监督提供稳定正则而不压过动作学习。主干和专家使用不同学习率。为摊薄 VLM 前向开销，同一动作块重复采样八组独立噪声与时间，让专家进行 $K_{repeat} = 8$ 次

训练计算，提高效率而不增加数据消耗。

4.2 后训练

预训练后，通过监督微调 SFT 适应部署域。不是每个任务训练一个专用策略，而是把目标基准或真实部署中的所有示范合并，训练一个覆盖该域全部任务的通用模型。

SFT 只优化掩码流匹配损失，不使用 VLM 下一 token 损失；关闭前述多阶段数据清洗，在完整未过滤数据上训练，保留所有有效示范；图像使用颜色抖动增强。相比预训练，GPU 数和训练步数更少。

但大量基准专用 SFT 可能让模型逐渐忽略语言，依靠重复场景和任务模式获得高分，退化成视觉动作匹配器。我们称其为 **VLA-to-VA degradation**，即 **VLA 向 VA 退化**。

原因包括：目标数据多样性有限，视觉布局和指令集中，容易学到场景动作捷径；训练测试视觉模式相近，模式记忆也能高分，基准高估语言遵循；缺少组合式语言定位能力的模型，把语言当弱上下文，动作越来越受视觉捷径支配。

作为可选增强，后训练可混入与目标域分布接近的预训练子集，提供更广适应信号，同时保留执行能力，避免无关数据稀释目标学习。主实验仍采用标准域内 SFT，以公平比较；混合方案在 6.5.1 验证。RoboTwin-IF 则直接检查相同或相似场景下，改变指令是否真的改变动作。

5. 部署

推理运行在远程服务器，机器人通过 WiFi 传输观察和动作。为缓解云端推理及网络延迟，使用实时动作分块 Real-Time Chunking (RTC)：机器人执行当前块时，异步生成下一块，隐藏往返延迟，使控制更平滑。

6. 实验

6.1 标准基准够不够

我们先使用广泛采用的 LIBERO 和 RoboTwin。LIBERO 有四组单臂桌面任务套件、130 种任务场景组合；RoboTwin 有 50 项双臂任务，提供简单和困难模式，涉及背景、物体和布局变化。

【图 4：分布内与分布外的对比】在 LIBERO、RoboTwin 等域内测试中，StarVLA 和本文从头训练版本能追平甚至超过 $\pi 0.5$ 、Abot-M0 等预训练模型；转到 LIBERO-Plus 和 RoboTwin-Clean2Rand 后，预训练模型明显领先。

这种现象不是偶然。训练和评测来自相同环境任务分布时，只靠记住重复视觉和行为模式就能高成功率，基准无法区分记忆和真正能力。此前工作也发现，基准数据上的预训练模型微调与从头训练差不多。

OOD 测试则揭示可迁移结构。例如 StarVLA 从 RoboTwin Easy 的 85.7% 跌到 Clean2Rand 的 10.6%，而 $\pi 0.5$ 明显更稳。扰动越强，预训练与从头训练差距越大。

实际用户往往只有自己硬件、工作空间和任务上的少量示范，面对的是与基准不同的分布。决定基础模型价值的，应是它内部学到了多少通用结构，以及这些结构能否在陌生数据上通过少量微调有效迁移，而非域内排行榜名次。

6.2 泛化评测设置

我们沿三条轴评估：扰动下的任务场景泛化、新语言与新任务的指令遵循、以及零样本跨形态迁移。

【图 5：评测环境】仿真覆盖 LIBERO、LIBERO-Plus、EBench、RoboTwin、RoboTwin-IF、RoboTwin-XE 和 RoboCasa365，共 500 多项任务；真实测试覆盖 UR、Franka、AgileX ALOHA、ARX 四种平台和 80 多项任务。

任务场景泛化。 LIBERO-Plus 在原 LIBERO 上独立改变背景纹理、相机视角、语言指令、光照、物体布局、机器人初始状态和传感噪声。模型只在标准 LIBERO 训练集微调。

RoboTwin-Clean2Rand 只在固定白背景、默认光照、无干扰物、固定桌高的 Clean 数据上微调，分别测试背景、光照、杂物和桌高变化，再在 Hard 中同时改变全部因素。

RoboCasa365 是大规模厨房基准：Atomic 包含 18 类基本技能及物体布局变化；Composite-Seen 是训练见过的多步长时序任务；Composite-Unseen 是训练未见的长时序任务。

EBench 基于 Isaac Sim，包含 26 类室内移动操作任务、794 个评测实例，改变背景、指令、物体及其组合，同时报告成功率和过程得分。

指令遵循。 RoboTwin-IF 在同一场景中设置多个合理动作，让语言决定正确目标和行为，包含五个套件：

- **Pick-Diverse-Object**: 从 12 种日常物体随机选四种，按颜色和名称指出其中一种，机器人须从三个干扰物中识别并举起目标。
- **Place-Relative**: 两个指定物体与一至三个干扰物，要求把 A 放到 B 旁边或上面，测试空间关系。
- **Operate-Mic-Drawer**: 一臂开抽屉，另一臂拿麦克风放进去；部分指令还规定哪只手做哪步，测试顺序和双臂协作。
- **Operate-Stapler**: 订书机、彩色垫子和干扰物始终同时出现，指令要求按订书机或移到垫子上。垫子在按压任务中是干扰项，在移动任务中是目标。
- **Operate-Tabletop**: 铃、订书机和可抓物体同时存在，指令要求按铃、按订书机或拿指定物体，只允许一种正确行为，测试动词和目标的联合区分。

模型均只在 RoboTwin Clean 微调。各套件区分采集时使用的 seen 指令模板和评测保留的 unseen 模板，并提供物体描述变体；评测每段只用未见模板。

【图 6: RoboTwin-IF 示例】左边同一桌面分别要求按铃、按订书机、拿咖啡盒；右边同一订书机与垫子场景分别要求移动和按压。正确动作必须由指令决定。

跨形态泛化。 RoboTwin-XE 只在默认 AgileX 的 Clean 数据上微调，测试时使用 Hard 场景，把机器人换成 ARX-X5、UR5-WSG 或 Franka Panda。IK 对齐初始末端位姿，头部腕部相机外参保持一致，任务、物体布局、扰动种子共享。模型需要同时适应机器人视觉外观和自由度、关节排列、臂长、工作空间等运动学差异；没有使用目标形态的微调数据。

6.2.2 总体结果

表 3：标准域内成功率，单位 %。

模型	LIBERO	RoboTwin Easy	RoboTwin Hard
$\pi 0$	94.4	65.9	58.4
$\pi 0.5$	97.6	82.7	76.8
StarVLA	98.0	85.7	87.3
Abot-M0	98.6	86.1	85.1
Being-H0.7	99.2	90.2	89.6
Qwen-RobotManip, 从头训练	98.2	88.7	88.4
Qwen-RobotManip	99.1	93.4	92.5
Qwen-RobotManip-Context	99.2	93.7	94.0

模型在域内达到先进水平，但主要结论依赖 OOD。相对 $\pi 0.5$ ，带上下文版本在 LIBERO-Plus 为 91.4 对 84.4，领先 7.0 个百分点；RoboTwin-C2R Hard 为 69.4 对 47.9，领先 21.5 点。基础版本在 EBench 为 45.6 对 27.1，RoboCasa365 为 35.9 对 16.9。

RoboTwin-IF 为 72.2% 对 49.6%，领先 22.6 点，表明双流训练与多样操作数据共同帮助保留语言条件控制，而非退化成忽略指令的默认行为。

跨形态测试最有解释力：只用 AgileX 示范微调、零样本控制其他机器人时，相机系末端动作的平均成功率为 23.9%， $\pi 0.5$ 为 7.5%，约 3.2 倍。视觉域中的动作对齐，使形态不同但物理相似的运动具有一致表示。

从头训练对比提供另一条证据。在 LIBERO-Plus，上下文预训练版 91.4，基础预训练版 89.0，从头训练版 78.3；在 Clean2Rand，从头训练版从 Easy 的 71.6 跌到 Hard 的 22.6，只保留约三成；预训练版从 73.2 到 62.6，保留约 86%， $\pi 0.5$ 保留约 66%。VLM 已提供一些背景、光照和语言稳健性，但新视角的空间推理、陌生机器人状态与杂物中任务目标注意，需要大规模跨形态操作预训练。

【图 7：三类 OOD 结果总览】展示任务场景、指令遵循与跨形态迁移。对比对象是各设置此前的最好模型，因此图中 LIBERO-Plus 的此前最好值为 Being-H0.7 的 84.8，而摘要式文字与 $\pi 0.5$ 比较时为 84.4。

6.2.3 各基准详细结果

表 4：LIBERO-Plus 七类扰动成功率，单位 %。

模型	相机	机器人初态	语言	光照	背景	噪声	布局	总计
$\pi 0$	13.8	6.0	58.8	85.0	81.4	79.0	68.9	53.6
$\pi 0.5$	78.4	73.6	80.8	96.2	94.1	89.0	84.5	84.4
StarVLA	52.5	49.8	88.5	95.7	95.7	73.0	76.9	74.1
Abot-M0	60.4	67.9	86.4	96.2	91.6	86.4	82.6	80.5
Cosmos-Policy	75.8	63.3	81.7	96.5	88.9	92.7	82.2	82.2
Being-H0.7	82.0	59.0	82.8	97.8	90.0	93.5	88.5	84.8
Qwen, 从头训练	70.4	44.9	88.1	95.8	95.5	84.4	79.1	78.3
Qwen	87.2	75.5	85.6	96.6	97.7	97.7	87.3	89.0
Qwen-Context	89.9	83.9	86.5	98.6	99.9	97.9	87.5	91.4

无机器人预训练模型在语言、光照、背景上已较强，说明 VLM 的表示天然具有这些稳健性。但在机器人初态扰动下，StarVLA 和从头训练版本只有 49.8%、44.9%，预训练版本为 75.5%。上下文进一步提高到 83.9%，增加 8.4 点，说明历史提供了隐式运动学先验。新相机视角也有类似规律，需要机器人多视角预训练带来的空间定位，而不仅是 VLM 的外观稳健性。

表 5：RoboTwin-Clean2Rand 成功率，单位 %。

模型	Easy	背景	光照	杂物	桌高	Hard
StarVLA	58.1	27.1	50.9	24.2	48.4	10.6
GR00T-N1.7	43.6	40.4	41.9	27.1	39.0	20.7
π 0.5	73.1	67.0	69.2	57.9	67.6	47.9
Abot-M0	70.7	56.5	68.8	46.0	56.3	36.0
Qwen，从头训练	71.6	60.6	70.7	24.6	63.6	22.6
Qwen，关节控制	73.2	74.6	68.4	61.3	71.0	62.6
Qwen，末端控制	74.0	75.8	70.1	59.8	69.4	60.8
Qwen-Context，关节控制	84.7	82.4	84.2	75.4	79.5	69.4
Qwen-Context，末端控制	85.0	82.4	84.7	66.8	82.9	64.0

基础模型关节与末端控制效果相近，Easy 到 Hard 下降最小。杂物条件下，从头训练版从 71.6 跌到 24.6，说明从复杂背景中关注任务目标需要大规模机器人预训练。背景随机化 74.6 甚至高于 Easy 的 73.2，作者推测，多样真实场景预训练让随机背景反而比纯白背景更接近模型训练分布。

上下文把关节控制 Easy、Hard 提升到 84.7、69.4，分别增加 11.5、6.8 点，说明执行历史能够补充当前视觉，让策略依据实际结果动态校准动作。

表 6：RoboCasa365 成功率，单位 %。

模型	原子任务	已见组合	未见组合	总计
π 0	36.3	5.2	0.7	15.0
π 0.5	39.6	7.1	1.2	16.9
GR00T-N1.5	50.7	14.8	2.7	23.9
GR00T-N1.6	51.1	9.4	1.7	21.9
RLDX-1	63.0	27.5	5.4	33.2

模型	原子任务	已见组合	未见组合	总计
Qwen	68.6	20.1	14.9	35.9
Qwen-Context	63.9	22.6	11.2	33.8

Qwen 总体超过此前最好的 RLDX-1，原子技能为最高的 68.6%。未见组合要求在 OOD 场景中完成成长任务，Qwen 的 14.9 接近 RLDX-1 的 5.4 的三倍，显示较强组合泛化。

表 7：EBench 成功率 / 综合得分。

模型	桌面灵巧任务	移动抓取放置	长时序	总体
π 0	15.7 / 30	35.0 / 39	17.0 / 41	23.6 / 37
π 0.5	12.9 / 32	45.0 / 50	18.1 / 39	27.1 / 41
X-VLA	8.6 / 24	50.0 / 54	6.2 / 25	23.7 / 36
InternVLA-A1	4.3 / 11	43.0 / 47	17.9 / 46	23.9 / 36
Qwen	50.0 / 70	56.5 / 60	29.9 / 55	45.6 / 60
Qwen-Context	49.3 / 56	55.0 / 66	26.6 / 55	43.6 / 59

EBench 使用 Lift2 + R5a 双臂移动平台。最大提升出现在桌面灵巧任务，Qwen 成功率约为 π 0.5 的四倍，综合得分超过两倍。移动抓取放置为 56.5，下一最好 X-VLA 为 50.0。长时序相对 π 0.5 增加 11.8 个成功率百分点和 16 分过程得分。

【图 8】按移动/灵巧操作、长/短时序、低/中/高精度要求细分，Qwen 在七类条件都保持优势。

【图 9】按背景、指令、物体、混合扰动细分 EBench。Qwen 成功率约保持在 44.5-46.8，组合扰动几乎没有进一步下降； π 0.5 从背景下的 34.6 跌到混合下的 23.3，约降 33%。混合扰动中 Qwen 46.8，领先 23.5 点。原文不同段落对背景值和相应差值略有不一致，这里保留其报告口径。

表 8：RoboTwin-IF 成功率，单位 %。

模型	多样目标抓取	相对放置	麦克风抽屈	订书机操作	桌面操作	平均
StarVLA	11	13	0	49	74	29.4
GR00T-N1.7	20	17	0	14	32	16.6
π 0.5	44	20	15	92	66	49.6

模型	多样目标抓取	相对放置	麦克风抽屉	订书机操作	桌面操作	平均
Qwen	79	57	42	90	93	72.2
Qwen-Context	77	71	33	89	90	72.0

Qwen 在五类中的四类领先 $\pi 0.5$ ，目标抓取、相对放置、麦克风抽屉和桌面操作分别增加 35、37、27、27 点。这些任务都要求在共享视觉场景中解析指令、从多个合理行为中选正确动作，因此能检验真正的语言控制。

【图 10：跨形态环境】分别展示 ARX-X5、UR5-WSG 和 Franka Panda。

表 9：RoboTwin-XE 零样本迁移成功率，单位 %。

模型与动作空间	ARX-X5	UR5-WSG	Franka Panda	平均
$\pi 0.5$ ，关节	24.6	2.2	0.9	9.2
$\pi 0.5$ ，末端	11.5	10.0	1.1	7.5
Qwen，关节	37.6	4.1	1.8	14.5
Qwen，末端	42.9	22.8	5.9	23.9

关节配置强依赖机器人，迁移到其他形态接近随机行为。改成相机系末端控制后，Qwen 在 UR5 上提高到 22.8，是关节模式的约 5.6 倍。ARX 最好，UR5 次之，Franka 最差，与相对 AgileX 的视觉及运动学差异相关：ARX 的六自由度外形与可达范围较相似；UR5 外观关节不同但工作空间接近；Franka 七自由度结构和更大可达范围产生最大差异。

6.3 真实机器人实验

6.3.1 ALOHA 平台

在 CobotMagic ALOHA 上，用 22.9 小时遥操作示范微调，然后测试同平台域内和域外任务。

【图 11：CobotMagic 域内域外设置】域内展示清桌、三碗堆叠、瓜入碗、折毛巾、积木放抽屉、圆盘插入、三积木堆叠的初始与结束状态。域外展示杂乱背景、新物体、左右关系、工具干扰和迪斯科灯光变化。

表 10：域内成功次数，每项五次。

任务	$\pi 0.5$	StarVLA	Qwen
清理桌面	4/5	0/5	5/5
按指定顺序叠三个碗	5/5	4/5	5/5
把小球状瓜玩具放进碗	2/5	0/5	5/5
折毛巾	4/5	3/5	4/5
开抽屉、放积木到小隔间、关抽屉	0/5	0/5	5/5
抓圆盘、双臂交接、插入对应槽	0/5	0/5	2/5
顺序叠三个积木	0/5	0/5	5/5
平均成功率	42.9%	20.0%	88.6%

前三项主要考察基本语言定位和顺序抓取放置；毛巾是可变形物体；抽屉要求准确抓小把手并精确推拉；插盘要求接触丰富的位姿对齐；积木堆叠要求关系理解、多步执行，以及滑落或倒塌后的恢复。

Qwen 五项任务五次全成功，毛巾为四次；插盘仍仅两次，说明真实精密插入有提升空间。 $\pi 0.5$ 在简单任务上尚可，但长时序、接触精度和失败恢复任务明显下降；StarVLA 几乎所有任务表现较弱。

表 11：域外成功次数，每项十次。

任务及扰动	$\pi 0.5$	StarVLA	Qwen
按颜色名称把目标放篮子；杂乱背景、新物体、随机目标	8/10	0/10	10/10
按左右关系叠碗；杂乱背景、新碗、左右指代	1/10	0/10	10/10
把指定勺或刀放毛巾；新小物体及干扰物	0/10	0/10	6/10
把香蕉放毛巾；迪斯科灯动态照明	6/10	0/10	9/10
平均	37.5%	0.0%	87.5%

Qwen 在杂乱场景、属性目标识别和左右关系上满分；新小工具抓取及强光变化仍有较好成功率。 $\pi 0.5$ 保留部分简单 OOD 稳健性，但需要组合和关系理解时大幅下降；StarVLA 全失败。这说明 Qwen 保留了更强的视觉语言表示。

ARX ALOHA 少样本适应。 三模型共享本体状态中的关节位置和末端位姿，预测末端动作，并共同使用 130 段遥操作示范：拧瓶盖 50 段，其余各 20 段。五任务覆盖多物体放置、长时序抽屉操作、可变形物体、双臂精密装配及旋转控制。

【图 12】上方展示 ARX 的放水果、放积木、折毛巾、插螺钉、拧瓶盖；下方展示跨平台技能迁移的叠盘、叠积木、水果放盘、纸团入桶。

表 12：少样本适应的子步骤成功次数，每步十次。

任务	子步骤	StarVLA	$\pi 0.5$	Qwen
放水果	第一个 / 第二个 / 第三个	3 / 1 / 0	9 / 5 / 2	9 / 5 / 3
放水果	平均	13.3%	53.3%	56.7%
放积木	开抽屉 / 第一块 / 第二块 / 关抽屉	1 / 1 / 0 / 0	4 / 2 / 2 / 2	5 / 4 / 3 / 3
放积木	平均	5.0%	25.0%	37.5%
折毛巾	第一折 / 第二折	0 / 0	3 / 1	3 / 3
折毛巾	平均	0.0%	20.0%	30.0%
插螺钉	交接 / 插入	0 / 0	2 / 0	2 / 0
插螺钉	平均	0.0%	10.0%	10.0%
拧瓶盖	抓瓶 / 拧开盖 / 放下	4 / 0 / 0	9 / 2 / 1	9 / 4 / 3
拧瓶盖	平均	13.3%	40.0%	53.3%

Qwen 四项优于基线。放积木四阶段合计 15/40， $\pi 0.5$ 为 10/40；拧盖成功翻倍，完整任务三次对一次；毛巾第二折三次对一次。插螺钉所有模型均没有完成插入，只在交接阶段成功两次。无预训练 StarVLA 接近零，说明大规模预训练对真实少样本操作重要。上述平均是子步骤平均，不能直接当完整任务成功率。

跨形态技能迁移。 一个策略联合用 6K 段 CobotMagic 和 130 段 ARX 示范微调，再在 ARX 测试四项新任务。ARX 上没有这些目标任务示范，必须从 CobotMagic 中相关但不完全相同的堆叠、精确放置和收集行为迁移。

表 13：每项十次的跨形态技能迁移。

模型	叠盘	叠积木	水果入盘	纸团入桶	平均
去掉 UnifiedSpace	0/10	0/10	3/10	0/10	7.5%
去掉 UnifiedEEF	0/10	0/10	5/10	0/10	12.5%
完整 Qwen	3/10	5/10	7/10	7/10	55.0%

去掉 UnifiedSpace 时只是拼接各机器人字段并填零，没有语义对齐；去掉 UnifiedEEF 时保留基础槽布局、统一旋转和夹爪归一化，但没有完整末端表示。两种都几乎失败，

说明表面维度统一或部分统一不足以跨越形态与任务的组合差异。完整模型超过最佳消融四倍，能将一个平台学到的技能迁移到另一平台新任务。

6.3.2 RoboChallenge Table30-v1

Table30-v1 包括四形态、30 任务。专用赛道每任务单独策略，共 30 模型；通用赛道每种形态一个策略，覆盖该机器人所有任务。我们选择更符合真实通用部署、也更难的通用赛道。

用官方示范进行关节控制后训练，以匿名身份 Lira_generalist 提交。模型成功率 45%、过程分 59.83，DM0_generalist 为 37%、48.43，分别领先八个成功率百分点和约 11.4 分。

表 14：各任务成功率 % / 过程分。 列顺序为 Qwen、DM0、 π 0.5、GR00T-MULTI、 π 0；均为通用策略。

平台	任务	Qwen	DM0	π 0.5	GR00T	π 0
全部	平均	45 / 59.83	37 / 48.43	17.67 / 31.27	15.33 / 32.29	9 / 20.22
ARX5	插花	30 / 64	20 / 49	0 / 30.5	20 / 57	0 / 13.5
ARX5	整理纸杯	70 / 83	10 / 54	0 / 31	0 / 19	0 / 15
ARX5	折洗碗布	30 / 48	10 / 10.5	0 / 0	0 / 17	0 / 0
ARX5	开抽屉	0 / 47	90 / 95	50 / 80	0 / 50	0 / 20
ARX5	鞋放鞋架	70 / 85	100 / 98.5	0 / 20	40 / 54.5	0 / 16.5
ARX5	杯放杯垫	100 / 99	100 / 100	70 / 63	80 / 92	0 / 0
ARX5	寻找绿盒	90 / 92	100 / 95.5	0 / 3	30 / 37.5	0 / 0
ARX5	电子产品分类	50 / 60.4	0 / 18.4	0 / 22.5	10 / 34.8	0 / 22.5
ARX5	开灯开关	70 / 69.5	70 / 70.5	10 / 25	0 / 5	20 / 29
ARX5	浇盆栽	0 / 9	0 / 33.5	0 / 0	0 / 6	0 / 0
ARX5	擦桌	0 / 72.5	0 / 47.5	10 / 28	0 / 66	0 / 29

平台	任务	Qwen	DMO	$\pi 0.5$	GR00T	$\pi 0$
ARX5	平台平均	46.4 / 66.3	45.5 / 61.1	12.7 / 27.5	16.4 / 39.9	1.8 / 13.2
ALOHA	清理餐桌	20 / 57.5	0 / 12	30 / 62	10 / 11.5	0 / 25.5
ALOHA	做素三明治	10 / 46.5	0 / 15	0 / 0	0 / 7	0 / 0
ALOHA	插网线	30 / 51	10 / 26	0 / 0	0 / 3	0 / 0
ALOHA	薯条倒盘	30 / 56	0 / 6	0 / 0	0 / 36	0 / 0
ALOHA	开瓶器放抽屉	0 / 0	10 / 10	20 / 38	0 / 0	0 / 0
ALOHA	笔放笔袋	90 / 95	20 / 40	50 / 63.5	20 / 58	0 / 14.5
ALOHA	扫二维码	10 / 13	0 / 0	0 / 7	30 / 26.5	0 / 3
ALOHA	叠碗	100 / 98.5	70 / 71	80 / 83	40 / 55.5	40 / 53.5
ALOHA	箱子贴胶带	0 / 22.5	0 / 14	0 / 16	0 / 2	0 / 0
ALOHA	扫垃圾	70 / 84.5	30 / 40	10 / 46	10 / 10	0 / 17
ALOHA	开水龙头	100 / 100	70 / 84.5	60 / 56	20 / 44	60 / 67.5
ALOHA	平台平均	41.8 / 56.8	19.1 / 29.0	22.7 / 33.8	11.8 / 23.0	9.1 / 16.5
UR5	水果整理入篮	80 / 89.5	70 / 87	0 / 9	30 / 54.5	0 / 11.5
UR5	挂牙刷杯	60 / 80	90 / 95	50 / 71	70 / 85	20 / 62
UR5	摆盘	100 / 87.5	60 / 62	40 / 49.5	0 / 24	50 / 69.5
UR5	碎废纸	0 / 15	30 / 45	20 / 36	0 / 0	20 / 27
UR5	整理书	0 / 9	0 / 8.5	0 / 24	0 / 6.5	10 / 26.5
UR5	叠彩色积木	70 / 84.5	100 / 100	10 / 30	0 / 44.5	30 / 39

平台	任务	Qwen	DM0	$\pi 0.5$	GR00T	$\pi 0$
UR5	平台平均	51.7 / 60.9	58.3 / 66.2	20.0 / 36.6	16.7 / 35.8	21.7 / 39.2
Franka	物体放箱	70 / 75.5	50 / 64.5	20 / 40	50 / 62	20 / 44.5
Franka	按三个按钮	0 / 0	0 / 0	0 / 4	0 / 0	0 / 0
Franka	平台平均	35.0 / 37.8	25.0 / 32.2	10.0 / 22.0	25.0 / 31.0	10.0 / 22.2

双臂协调。 八项 ALOHA 紧密协作任务中，Qwen 平均 40%， $\pi 0.5$ 21.2%、DM0 16.2%、GR00T 和 $\pi 0$ 均 7.5%。八项包括清餐桌、做素三明治、倒薯条、开瓶器放抽屉、笔入笔袋、贴胶带、扫垃圾和开龙头。

【图 13：薯条倒盘案例】Qwen 左臂稳住盒子，右臂打开盒角，再拿起倾倒，成功率 30%；所有基线零。DM0 右臂在初始协作阶段未到可抓位置。作者把优势归因于大量双臂真实预训练及人类视频合成带来的更多协作策略。

跨平台抓取放置。 四平台十二项任务平均 63.3%，DM0 为 48.3%，领先 15 点。任务包括插花、水果入篮、纸杯整理、清餐桌、物体入箱、摆盘、整理书、电子产品分类、叠碗、鞋入架、杯入杯垫和叠彩积木。大规模预训练提供丰富模式，统一动作空间让基础空间技能跨形态共享。

【图 14】分别比较八项双臂与十二项抓取放置任务。

【图 15：纸杯整理】Qwen 顺序拿杯、精准堆叠并收集，70% 成功； $\pi 0.5$ 为零，堆叠中杯子卡住后没有恢复，后续出现连锁错误。

涌现的重试行为。 抓取滑落、放置失败后，Qwen 往往自行重新尝试，而非直接下一步或停住。抓取、放置、倾倒、折叠、擦拭、扫地中都有观察。这很难用单一指标量化，但能改善中途失败恢复。

【图 16：电子产品分类】Qwen 抓起后两次掉落，第三次重新抓取并放入目标箱；DM0 也尝试三次，但始终没有抓牢。Qwen 任务成功率 50%，DM0 为零。作者推测，预训练示范自然包含不完美尝试及修正，让恢复策略作为普通策略的一部分被学到。

困难任务突破。 双臂协调、空间精度和自我纠错共同支持高难长任务。插网线、倒薯条各 30%，做素三明治 10%；纸杯整理 70%、电子产品分类 50%、折洗碗布 30%。

【图 17】六个困难任务中，此前先进通用方法平均成功率 5%，Qwen 36.7%。

原文一致性提示：本节文字说“电子产品分类比下一最好方法高 40 点”，与表 14 的 GR00T 10%、Qwen 50% 一致；图 17 却标成 50% 对 0%。这里同时保留，不把图中文字当作无差异的统一结果。

6.4 消融实验

消融涉及表示对齐、上下文适应、架构，以及人到机器人合成和视觉语言联合训练。各组内部训练条件相同，但使用缩小预训练规模，配置可能不同于主实验。

动作对齐与数据扩展。 从完整跨形态数据按每种形态的任务采样，建立 1%、5%、10%、25%、50%、100% 的嵌套子集。固定 OOD 验证集含 15 种形态、154 个从未进入任何训练集的任务。每点报告所有训练 checkpoint 中最佳验证 MSE，并统一到相同动作表示衡量。

三种设计分别是：无 UnifiedSpace，把原始动作直接拼接填零到 80 维；无 UnifiedEEF，按语义字段固定槽位，末端动作用相对初始末端的轴角增量；完整模型，进一步把末端运动转成相机系增量。

【图 18：规模曲线】语义槽位统一的两版本，最佳 OOD MSE 随数据量增加近似按对数线性下降。无结构对齐版本的末端曲线不稳定，误差明显较大。完整相机系版本平均末端误差最低。

【图 19：下游规模曲线】各版本再在 Clean 微调 80K 步，测试关节/末端及 Easy/Hard 四种组合。完整模型在 Hard 中随着数据量增加持续改善，满规模为关节 50.2%、末端 56.6%；两种消融趋势更嘈杂。Easy 中三种都没有明确增长，再次说明域内测试难以看到预训练收益。完整模型末端控制可追平或超过关节，两消融相反，验证相机对齐对末端策略的作用。

表 15：形态提示与上下文消融；RoboTwin-C2R 关节控制，speed=500。

配置	形态提示	FPS	历史	去噪步	Easy	Hard	平均
无 UnifiedEEF 基线	无	无	无	4	71.2	54.2	62.7
加软提示	soft	无	无	4	70.2	52.1	61.2
加自然语言提示	language	15	无	4	71.7	55.1	63.4
加结构提示	有	15	无	4	73.4	58.3	65.9
Context	有	15	有	4	72.1	54.4	63.3
Context	有	15	有	10	80.1	61.6	70.9

配置	形态提示	FPS	历史	去噪步	Easy	Hard	平均
Context	有	15	有	20	79.8	62.1	71.0

软提示略差；自然语言形态标签小幅改善，但粗类别不足以充分调整行为；结构提示增加时间属性，提高约 2.2-3.2 点，部署字段应真实反映执行条件。

单个历史块提供动态运动学特征，但也增加动作分布复杂度。无历史时四步去噪足够；有历史仍只用四步会抖动，抵消收益。十步解决不稳定，平均 70.9，比结构提示高五点；二十步没有额外改善。历史更像反映运动学执行特征的隐式形态标识，而不只是记忆，需要动作头有足够解码能力。

真实部署有一个限制：任务起始历史全填零时，模型可能迟疑再启动。因此同时发布有历史和无历史版本，供快速响应或丰富上下文适应的不同需求选择。

人到机器人合成数据。 固定机器人与辅助数据比例 7:3，对比仅机器人、加入原始第一人称数据、以同来源合成机器人数据替换原始视频。训练步、超参数和微调数据相同。

表 16: RoboTwin-C2R 末端控制。

配置	Easy	背景	光照	杂物	桌高	Hard
仅机器人	72.9	70.4	70.3	57.2	67.8	54.7
加原始人类视频	73.4	70.6	71.7	59.2	70.2	55.0
加 H2R 合成	74.2	71.4	73.3	58.1	71.0	58.7

表 17: LIBERO-Plus。

配置	相机	机器人	语言	光照	背景	噪声	布局	总计
仅机器人	72.8	78.2	88.7	97.5	97.6	95.4	85.4	87.1
加原始人类视频	77.7	79.0	88.5	98.8	98.7	97.3	84.9	88.4
加 H2R 合成	80.0	80.2	89.3	98.5	98.2	96.6	85.2	89.0

Hard 合成比仅机器人高四点，比原始视频高 3.7 点，光照和桌高收益较明显。LIBERO-Plus 平均 87.1 到 89.0，相机提高 7.2 点，机器人初态提高两点。原始视频主要贡献视觉多样性，动作与视觉对齐的合成则进一步释放收益。总体平均呈递增，但不是每个单项都单调提高。

视觉语言联合训练。

表 18: 预训练和后训练中的 VL 消融。

配置	LIBERO	LIBERO-Plus	C2R Easy	C2R Hard	RT-IF
默认：预训练含 VL，后训练不含	99.1	90.1	73.2	62.6	71.6
预训练去掉 VL	98.2	88.9	66.5	54.4	64.6
后训练加入 VL	98.6	91.4	74.0	62.5	73.1

预训练去掉 VL 后，LIBERO 与 Plus 小幅降低 0.9、1.2 点，但 C2R Easy/Hard 降 6.7、8.2，IF 降七点。任务、场景与分布变化越复杂，VL 越重要：通用 VL 保留感知语言，空间数据增强定位关系理解，具身数据对齐任务语义。

架构设计。 三种变体：第一种复制 VLM 视觉语言隐藏状态进入纯自注意力 DiT，并逐层与对应 VLM 特征加权残差融合；第二种只输入 VLM 最后层，仍用纯自注意力，没有中间层融合；第三种使用少量可学习查询 token 作为视觉语言代理，与状态动作 token 拼接，联合交叉关注 VLM 最后层，再彼此自注意力，最后丢弃查询输出。

所有变体只用机器人预训练，再在 LIBERO 微调；不使用结构提示、ECoT 和历史，仅保留相机系增量设计，以隔离架构作用。

【图 20：三种架构】逐层自注意力、最后层自注意力、最后层交叉注意力。

表 19：架构的 LIBERO-Plus 成功率。

架构	相机	机器人	语言	光照	背景	噪声	布局	总计
逐层自注意力	74.5	74.3	86.8	98.6	96.0	94.9	86.1	86.4
最后层自注意力	75.5	71.4	87.2	98.3	98.9	96.1	88.1	87.0
最后层交叉注意力	76.9	73.4	86.9	98.9	97.7	97.3	87.3	87.5

第三种平均最好且计算最省，不需逐层融合，也不需在 DiT 存完整视觉语言 token；因此采用第三种。纯自注意力并没有明显的特征交互优势。

6.5 对齐之后可以做什么

6.5.1 混合后训练

主实验后训练不含 VL，以符合标准比较协议。加入 VL 后，表 18 中 Plus、C2R Easy 和 IF 改善，而 Hard 基本不变。语言相关收益最明显：Plus 语言扰动由 86.9 到 93.9；

IF 多样物体抓取由 76 到 81。Hard 主要改变视觉，指令固定，VL 收益不明显。不同消融配置的数字与主结果不必相同。

只训练动作可能造成 VLM 语言理解和视觉定位遗忘，混入 VL 帮助保留这些基础能力，解析未见指令并将指代落到物体上。

进一步，我们在目标域数据中加入通用 VL 与辅助 VLA。VL 包括物体检测、空间指点和轨迹预测；VLA 包括其他仿真器轨迹以及形态相近机器人的大规模真实示范，全部在可迁移的末端动作空间对齐。

【图 21：训练过程】只在 RoboTwin-Clean 微调时，Qwen 初期明显超过 $\pi 0.5$ ，但随步数增长 IF 逐渐下降，出现过拟合。混合 10% VL 后，峰值不稳定和后续衰退缓解；再令辅助 VLA 占全部 VLA 数据的 75%，过拟合现象消失，IF 随训练持续提高，在保持相近峰值的同时稳住 OOD 泛化。图在 10K、30K、50K、70K、90K 步评测，图注提到“比例”，正文实际重点是这些训练步数下的不同混合方案。

【图 22：UnifiedEEF 与混合后训练】默认 71.6%；无 UnifiedEEF 为 35.0%；无 UnifiedEEF 又混合预训练数据为零；完整对齐加混合达到 75.8%。作者据此强调，UnifiedEEF 是释放混合后训练收益的必要条件，模型不能自行消化不相容的混合表示。

6.5.2 末端控制与跨形态迁移

相机系增量把动作放在视觉观察坐标系，不依赖具体关节运动学，因此可依次改善控制质量、跨形态技能组合和零样本部署。

表 20：三个层面的收益。

维度	评测	基线	Qwen	增益
末端控制质量	C2R Easy / Hard，末端模式	无 UnifiedEEF：49.0 / 33.0	72.5 / 56.6	+23.5 / +23.6 点
技能组合	CobotMagic 到 ARX，四新任务	无 UnifiedEEF：12.5%	55.0%	4.4 倍
零样本迁移	AgileX 到 ARX、UR5、Franka 平均	关节：14.5%	末端：23.9%	1.65 倍

在规模消融配置中，末端控制 72.5 / 56.6 还超过自身关节控制 68.1 / 50.2，而其他表示从关节切末端会下降。统一末端表示的 OOD 误差规模曲线更稳定，说明它是较强策略接口，不只是另一种输出形式。

联合 6K CobotMagic 和 130 ARX 后，目标任务没有 ARX 示范仍能 55% 成功，说明同一技能在不同机器人上的一致数值模式支持新的机器人任务组合。最难的零样本设置中，UR5 末端 22.8 对关节 4.1，显示共享笛卡尔动作空间能够产生有意义的形态迁移。

7. 结论与限制

本文研究的是，语言和多模态基础模型中“统一对齐异构数据，再扩大训练规模”的方法，能否带来机器人操作的真正泛化。Qwen-RobotManip 给出肯定结果：对齐与规模紧密关联，没有统一表示，更多数据可能产生冲突；没有足够数据多样性，对齐良好的模型也无法超出训练分布。

三个结果尤其值得关注。第一，标准状态动作模板、相机系位姿增量和上下文策略适应，不只是为了兼容不同机器人，更是有效规模扩展的条件，消融显示未经对齐的表示难以获得稳定规模收益。第二，仅依靠开源操作数据及人类第一人称视频，就能构建约 38,100 小时语料并出现泛化，说明如果合成和清洗基础设施合适，机器人操作基础模型的数据门槛可能没有想象中高。第三，域内基准反复无法区分通用预训练结构和模式匹配，OOD 评估更能反映实际基础能力。

限制仍然存在。人到机器人重定向近似及视频修复伪影带来分布差异，限制合成数据有效质量；OOD 测试仍主要在仿真中，更广真实部署条件需要进一步验证；固定动作块长度及推理延迟限制需要亚秒级反应的任务。

未来可扩展更多机器人与任务，提高重定向精度和符合物理的渲染质量，并引入智能体系统处理更长时序推理与操作。作者希望评估重点从域内名次，转向真正决定实际部署价值的分布外泛化。

8. 作者

核心贡献者：Haoqi Yuan、Zhixuan Liang、Anzhe Chen、Ye Wang、Haoyang Li、Pei Lin、Yiyang Huang、Zixing Lei、Tong Zhang，以及 Jiazhao Zhang、Jie Zhang、Jingyang Fan、Gengze Zhou、Qihang Peng、Chenxu Lv、Xiaoyue Chen、An Yang、Fei Huang、Junyang Lin、Dayiheng Liu、Jingren Zhou、Chenfei Wu、Xiong-Hui Chen。前九位为共同贡献；Chenfei Wu 与 Xiong-Hui Chen 为通讯作者，Xiong-Hui Chen 同时为项目负责人。

其他贡献者：Jinhui Ye、Sicheng Xie、Hale Yin、Xudong Guo、Shuai Bai、Lulu Hu、Minying Zhang、Shurui Li、Wenhu Xiao、Yue Wang、Kun Yan、Xiao Xu、Jiahao Li、Xuancheng Ren。

致谢：感谢国家具身智能应用中试基地提供真实机器人实验环境和设备，感谢 AgileX Robotics 的硬件支持，以及 Hao Dong 教授和 Yao Mu 教授的支持。

参考文献（原文保留，便于检索）

AgiBot-World-Contributors. AgiBot World Colosseo: A large-scale manipulation platform for scalable and intelligent embodied systems. arXiv preprint arXiv:2503.06669, 2025.

Shuai Bai, Yuxuan Cai, Ruizhe Chen, Keqin Chen, Xionghui Chen, Zesen Cheng, Lianghao Deng, Wei Ding, Chang Gao, Chunjiang Ge, et al. Qwen3-vl technical report. arXiv preprint arXiv:2511.21631, 2025.

Johan Bjorck, Fernando Castaneda, Linxi Fan, Dieter Fox, et al. GR00T N1: An open foundation model for generalist humanoid robots. arXiv preprint arXiv:2503.14734, 2025.

Kevin Black, Noah Brown, Danny Driess, Adnan Esmail, Michael Equi, Chelsea Finn, Niccolo Fusai, Lachy Groom, Karol Hausman, Brian Ichter, et al. π^0 : A vision-language-action flow model for general robot control. arXiv preprint arXiv:2410.24164, 2024.

Kevin Black, Noah Brown, James Darpinian, Karan Dhabalia, Danny Driess, Adnan Esmail, Michael Robert Equi, Chelsea Finn, Niccolo Fusai, Manuel Y Galliker, et al. $\pi^0.5$: a vision-language-action model with open-world generalization. In 9th Annual Conference on Robot Learning, 2025.

Kevin Black, Manuel Galliker, and Sergey Levine. Real-time execution of action chunking flow policies. Advances in Neural Information Processing Systems, 38:33383–33407, 2026.

Tom Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared D Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, et al. Language models are few-shot learners. In NeurIPS, 2020.

Junhao Cai, Zetao Cai, Jiafei Cao, Yilun Chen, Zeyu He, Lei Jiang, Hang Li, Hengjie Li, Yang Li, Yufei Liu, et al. Internvla-a1: Unifying understanding, generation and action for robotic manipulation. arXiv preprint arXiv:2601.02456, 2026.

Nicolas Carion, Laura Gustafson, Yuan-Ting Hu, Shoubhik Debnath, Ronghang Hu, Didac Suris, Chaitanya Ryali, Kalyan Vasudev Alwala, Haitham Khedr, Andrew Huang, Jie Lei, Tengyu Ma, Baishan Guo, Arpit Kalla, Markus Marks, Joseph Greer, Meng Wang, Peize Sun, Roman Rädle, Triantafyllos Afouras, Effrosyni Mavroudi, Katherine Xu, Tsung-Han Wu, Yu Zhou, Liliane Momeni, Rishi Hazra, Shuangrui Ding, Sagar Vaze, Francois Porcher, Feng Li, Siyuan Li, Aishwarya Kamath, Ho Kei Cheng, Piotr Dollár, Nikhila Ravi, Kate Saenko, Pengchuan Zhang, and Christoph Feichtenhofer. Sam 3: Segment anything with concepts, 2025. URL <https://arxiv.org/abs/2511.16719>.

Justin Carpentier, Guilhem Saurel, Gabriele Buondonno, Joseph Mirabel, Florent Lamiroux, Olivier Stasse,

and Nicolas Mansard. The Pinocchio C++ library: A fast and flexible implementation of rigid body

dynamics algorithms and their analytical derivatives. In IEEE/SICE International Symposium on System

Integration (SII), pp. 614–619. IEEE, 2019.

Anzhe Chen, Yifei Yang, Zhenjie Zhu, Kechun Xu, Zhongxiang Zhou, Rong Xiong, and Yue Wang. Toward

embodiment equivariant vision-language-action policy. arXiv preprint arXiv:2509.14630, 2025a.

Tianxing Chen, Zanxin Chen, Baijun Chen, Zijian Cai, Yibin Liu, Zixuan Li, Qiwei Liang, Xianliang Lin,

Yiheng Ge, Zhenyu Gu, et al. Robotwin 2.0: A scalable data generator and benchmark with strong

domain randomization for robust bimanual robotic manipulation. arXiv preprint arXiv:2506.18088,

2025b.

William Chen, Suneel Belkhale, Suvir Mirchandani, Oier Mees, Danny Driess, Karl Pertsch, and Sergey

Levine. Training strategies for efficient embodied reasoning. ArXiv, abs/2505.08243, 2025c.

Cheng Chi, Siyuan Feng, Yilun Du, Zhenjia Xu, Eric Cousineau, Benjamin Burchfiel, and Shuran Song.

Diffusion policy: Visuomotor policy learning via action diffusion. In Robotics: Science and Systems (RSS),

2023.

StarVLA Community. Starvla: A lego-like codebase for vision-language-action model developing. arXiv

preprint arXiv:2604.05014, 2026.

Dima Damen, Hazel Doughty, Giovanni Maria Farinella, Sanja Fidler, Antonino Furnari, Evangelos

Kazakos, Davide Moltisanti, Jonathan Munro, Toby Perrett, Will Price, and Michael Wray. Scaling

egocentric vision: The EPIC-KITCHENS dataset. In European Conference on Computer Vision (ECCV),

2018.

Timothée Darcet, Maxime Oquab, Julien Mairal, and Piotr Bojanowski. Vision transformers need registers.

In B. Kim, Y. Yue, S. Chaudhuri, K. Fragkiadaki, M. Khan, and Y. Sun (eds.), International Conference

on Learning Representations, volume 2024, pp. 2632–2652, 2024. URL <https://proceedings.iclr.cc/>

paper_files/paper/2024/file/0b408293619f725fd30162af057e531a-Paper-Conference.pdf.

Matt Deitke, Christopher Clark, Sangho Lee, Rohun Tripathi, Yue Yang, Jae Sung Park, Mohammadreza

Salehi, Niklas Muennighoff, Kyle Lo, Luca Soldaini, Jiasen Lu, Taira Anderson, Erin Bransom, Kiana

Ehsani, Huong Ngo, Yen-Sung Chen, Ajay Patel, Mark Yatskar, Chris Callison-Burch, Andrew Head,

Rose Hendrix, Favien Bastani, Eli VanderBilt, Nathan Lambert, Yvonne Chou, Arnavi Chheda, Jenna

Sparks, Sam Skjonsberg, Michael Schmitz, Aaron Sarnat, Byron Bischoff, Pete

Walsh, Chris Newell,
Piper Wolters, Tanmay Gupta, Kuo-Hao Zeng, Jon Borchardt, Dirk Groeneveld,
Crystal Nam, Sophie
Lebrecht, Caitlin Wittlif, Carissa Schoenick, Oscar Michel, Ranjay Krishna,
Luca Weihs, Noah A. Smith,
Hannaneh Hajishirzi, Ross B. Girshick, Ali Farhadi, and Aniruddha Kembhavi.
Molmo and pixmo:
Open weights and open data for state-of-the-art vision-language models. In
IEEE/CVF Conference on
Computer Vision and Pattern Recognition, CVPR 2025, Nashville, TN, USA,
June 11-15, 2025, 2025.
Danny Driess, Jost Tobias Springenberg, Brian Ichter, Lili Yu, Adrian Li-
Bell, Karl Pertsch, Allen Z Ren,
Homer Walke, Quan Vuong, Lucy Xiaoyang Shi, et al. Knowledge insulating
vision-language-action
models: Train fast, run fast, generalize better. arXiv preprint
arXiv:2505.23705, 2025.
Abhimanyu Dubey, Abhinav Jauhri, Abhinav Pandey, Abhishek Kadian, Ahmad Al-
Dahle, Aiesha
Letman, Akhil Mathur, Alan Schelten, Amy Yang, Angela Fan, et al. The llama
3 herd of models.
arXiv:2407.21783, 2024.
Patrick Esser, Sumith Kulal, Andreas Blattmann, Rahim Entezari, Jonas
Müller, Harry Saini, Yam Levi,
Dominik Lorenz, Axel Sauer, Frederic Boesel, et al. Scaling rectified flow
transformers for high-
resolution image synthesis. In ICML, 2024.
Hao-Shu Fang, Hongjie Fang, Zhenyu Tang, Jirong Liu, Chenxi Wang, Junbo
Wang, Haoyi Zhu, and
Cewu Lu. RH20T: A comprehensive robotic dataset for learning diverse skills
in one-shot. In IEEE
International Conference on Robotics and Automation (ICRA), 2024.
Haoquan Fang, Jiafei Duan, Donovan Clay, Sam Wang, Shuo Liu, Weikai Huang,
Xiang Fan, Wei-Chuan
Tsai, Shirui Chen, Yi Ru Wang, et al. Molmoact2: Action reasoning models
for real-world deployment.
arXiv preprint arXiv:2605.02881, 2026.
Senyu Fei, Siyin Wang, Junhao Shi, Zihao Dai, Jikun Cai, Pengfang Qian, Li
Ji, Xinzhe He, Shiduo Zhang,
Zhaoye Fei, et al. Libero-plus: In-depth robustness analysis of vision-
language-action models. arXiv
preprint arXiv:2510.13626, 2025.
Youhe Feng, Hansen Shi, Haoyang Li, Xinlei Guo, Yang Wang, Chengyang Zhang,
Jinkai Zhang, Xiaohan
Zhang, Jie Tang, and Jing Zhang. Procvlm: Learning procedure-grounded
progress rewards for robotic
manipulation. CoRR, abs/2605.08774, 2026.
Galaxea AI. Galaxea open-world dataset and G0 dual-system VLA model. arXiv
preprint arXiv:2509.00576,
2025.
Raghav Goyal, Samira Ebrahimi Kahou, Vincent Michalski, Joanna Materzynska,
Susanne Westphal,
Heuna Kim, Valentin Haenel, Ingo Fruend, Peter Yianilos, Moritz Mueller-
Freitag, et al. The " something
something" video database for learning and evaluating visual common sense.
In Proceedings of the IEEE
international conference on computer vision, pp. 5842–5850, 2017.
Kristen Grauman, Andrew Westbury, Eugene Byrne, et al. Ego4D: Around the
world in 3,000 hours of

egocentric video. In IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2022.

Kristen Grauman, Andrew Westbury, Lorenzo Torresani, Kris Kitani, Jitendra Malik, Triantafyllos Afouras, Kumar Ashutosh, Vijay Baiyya, Siddhant Bansal, Bikram Boote, et al. Ego-exo4d: Understanding skilled human activity from first-and third-person perspectives. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pp. 19383–19400, 2024.

Byeongho Heo, Song Park, Dongyoon Han, and Sangdoo Yun. Rotary position embedding for vision transformer. In European Conference on Computer Vision, pp. 289–305. Springer, 2024.

Ryan Hoque, Peide Huang, David J Yoon, Mouli Sivapurapu, and Jian Zhang. Egodex: Learning dexterous manipulation from large-scale egocentric video. arXiv preprint arXiv:2505.11709, 2025.

Yiyang Huang, Yuhui Hao, Bo Yu, Feng Yan, Yuxin Yang, Feng Min, Yinhe Han, Lin Ma, Shaoshan Liu, Qiang Liu, et al. Dadu-corki: Algorithm-architecture co-design for embodied ai-powered robotic manipulation. In Proceedings of the 52nd Annual International Symposium on Computer Architecture, pp. 327–343, 2025.

Simar Kareer, Dhruv Patel, Ryan Punamiya, Pranay Mathur, Shuo Cheng, Chen Wang, Judy Hoffman, and Danfei Xu. Egomimic: Scaling imitation learning via egocentric video. In 2025 IEEE International Conference on Robotics and Automation (ICRA), pp. 13226–13233. IEEE, 2025.

Alexander Khazatsky, Karl Pertsch, Suraj Nair, et al. DROID: A large-scale in-the-wild robot manipulation dataset. In Robotics: Science and Systems (RSS), 2024.

Dongyoung Kim, Huiwon Jang, Myungkyu Koo, Suhyeok Jang, Taeyoung Kim, Beomjun Kim, Byungjun Yoon, Changsung Jang, Daewon Choi, Dongsu Han, et al. Rldx-1 technical report. arXiv preprint arXiv:2605.03269, 2026a.

Moo Jin Kim, Karl Pertsch, Siddharth Karamcheti, Ted Xiao, Ashwin Balakrishna, Suraj Nair, Rafael Rafailov, Ethan Foster, Grace Lam, Pannag Sanketi, et al. Openvla: An open-source vision-language-action model. arXiv preprint arXiv:2406.09246, 2024.

Moo Jin Kim, Chelsea Finn, and Percy Liang. Fine-tuning vision-language-action models: Optimizing speed and success. arXiv preprint arXiv:2502.19645, 2025.

Moo Jin Kim, Yihuai Gao, Tsung-Yi Lin, Yen-Chen Lin, Yunhao Ge, Grace Lam, Percy Liang, Shuran Song, Ming-Yu Liu, Chelsea Finn, et al. Cosmos policy: Fine-tuning video models for visuomotor control and planning. arXiv preprint arXiv:2601.16163, 2026b.

Xin Kong, Shikun Liu, Xiaoyang Lyu, Marwan Taher, Xiaojuan Qi, and Andrew J. Davison. EscherNet: A generative model for scalable view synthesis. In Proceedings of the IEEE/CVF Conference on Computer

Vision and Pattern Recognition (CVPR), pp. 9503–9513, 2024.

Shanghai AI Laboratory. EBench: Elemental mobile manipulation benchmark, 2026. URL <https://internrobotics.github.io/EBench-doc/>.

Zixing Lei, Changxing Liu, Yichen Xiong, Minhao Xiong, Yuanzhuo Ding, Zhipeng Zhang, Weixin Li, and Siheng Chen. Towards long-horizon embodied agents with tool-aligned vision-language-action models. arXiv preprint arXiv:2605.13119, 2026.

Marion Lepert, Jiaying Fang, and Jeannette Bohg. Masquerade: Learning from in-the-wild human videos using data-editing. arXiv preprint arXiv:2508.09976, 2025a.

Marion Lepert, Jiaying Fang, and Jeannette Bohg. Phantom: Training robots without robots using only human videos. arXiv preprint arXiv:2503.00779, 2025b.

Hao Li, Ziqin Wang, Zi-Han Ding, Shuai Yang, Yilun Chen, Yang Tian, Xiaolin Hu, Tai Wang, Dahua Lin, Feng Zhao, Si Liu, and Jiangmiao Pang. Robointer: A holistic intermediate representation suite towards robotic manipulation. CoRR, abs/2602.09973, 2026.

Qixiu Li, Yu Deng, Yaobo Liang, Lin Luo, Lei Zhou, Chengtang Yao, Lingqi Zeng, Zhiyuan Feng, Huizhi Liang, Sicheng Xu, et al. Scalable vision-language-action model pretraining for robotic manipulation with real-life human activity videos. arXiv preprint arXiv:2510.21571, 2025a.

Ruiling Li, Brent Yi, Junchen Liu, Hang Gao, Yi Ma, and Angjoo Kanazawa. Cameras as relative positional encoding. Advances in Neural Information Processing Systems, 2025b.

Zhixuan Liang, Yao Mu, Mingyu Ding, Fei Ni, Masayoshi Tomizuka, and Ping Luo. Adaptdiffuser: diffusion models as adaptive self-evolving planners. In Proceedings of the 40th International Conference on Machine Learning, pp. 20725–20745, 2023.

Zhixuan Liang, Yizhuo Li, Tianshuo Yang, Chengyue Wu, Sitong Mao, Liyao Pei, Tian Nian, Shunbo Zhou, Xiaokang Yang, Jiangmiao Pang, et al. Discrete diffusion vla: Bringing discrete diffusion to action decoding in vision-language-action policies. In Proceedings of the 43rd International Conference on Machine Learning, 2026.

Haotong Lin, Sili Chen, Junhao Liew, Donny Y Chen, Zhenyu Li, Guang Shi, Jiashi Feng, and Bingyi Kang. Depth anything 3: Recovering the visual space from any views. arXiv preprint arXiv:2511.10647, 2025.

Yaron Lipman, Ricky T. Q. Chen, Heli Ben-Hamu, Maximilian Nickel, and Matt Le. Flow matching for generative modeling. In International Conference on Learning Representations (ICLR), 2023.

Bo Liu, Yifeng Zhu, Chongkai Gao, Yihao Feng, Qiang Liu, Yuke Zhu, and Peter Stone. Libero: Benchmarking knowledge transfer for lifelong robot learning. arXiv preprint arXiv:2306.03310, 2023.

Songming Liu, Lingxuan Wu, Bangguo Li, Hengkai Tan, Huayu Chen, Zhengyi

Wang, Ke Xu, Hang

Su, and Jun Zhu. RDT-1B: a diffusion foundation model for bimanual manipulation. In International

Conference on Learning Representations (ICLR), 2025.

Hao Luo, Yicheng Feng, Wanpeng Zhang, Sipeng Zheng, Ye Wang, Haoqi Yuan, Jiazheng Liu, Chaoyi

Xu, Qin Jin, and Zongqing Lu. Being-h0: vision-language-action pretraining from large-scale human

videos. arXiv preprint arXiv:2507.15597, 2025.

Hao Luo, Ye Wang, Wanpeng Zhang, Haoqi Yuan, Yicheng Feng, Haiweng Xu, Sipeng Zheng, and

Zongqing Lu. Joint-aligned latent action: Towards scalable vla pretraining in the wild. In Proceedings of

the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pp. 35047–35058, 2026a.

Hao Luo, Ye Wang, Wanpeng Zhang, Sipeng Zheng, Ziheng Xi, Chaoyi Xu, Haiweng Xu, Haoqi Yuan, Chi

Zhang, Yiqing Wang, et al. Being-h0. 5: Scaling human-centric robot learning for cross-embodiment

generalization. arXiv preprint arXiv:2601.12993, 2026b.

Hao Luo, Wanpeng Zhang, Yicheng Feng, Sipeng Zheng, Haiweng Xu, Chaoyi Xu, Ziheng Xi, Yuhui Fu,

and Zongqing Lu. Being-h0. 7: A latent world-action model from egocentric videos. arXiv preprint

arXiv:2605.00078, 2026c.

Jiangran Lyu, Kai Liu, Xuheng Zhang, Haoran Liao, Yusen Feng, Wenxuan Zhu, Tingrui Shen, Jiayi Chen,

Jiazhao Zhang, Yifei Dong, et al. Lda-1b: Scaling latent dynamics action model via universal embodied

data ingestion. arXiv preprint arXiv:2602.12215, 2026.

Takeru Miyato, Bernhard Jaeger, Max Welling, and Andreas Geiger. GTA: A geometry-aware attention

mechanism for multi-view transformers. In International Conference on Learning Representations (ICLR),

2024.

Yao Mu, Tianxing Chen, Zan Ding, et al. Robotwin: Dual-arm robot benchmark with generative digital

twins. arXiv preprint arXiv:2501.00062, 2025.

Soroush Nasiriany, Abhiram Maddukuri, Lance Zhang, Adeet Parikh, Aaron Lo, Abhishek Joshi, Ajay

Mandlekar, and Yuke Zhu. Robocasa: Large-scale simulation of everyday tasks for generalist robots.

In Robotics: Science and Systems (RSS), 2024.

Soroush Nasiriany, Sepehr Nasiriany, Abhiram Maddukuri, and Yuke Zhu. Robocasa365: A large-scale

simulation framework for training and benchmarking generalist robots. In International Conference on

Learning Representations (ICLR), 2026.

OpenAI. Gpt-4 technical report. arXiv:2303.08774, 2023.

Abhishek Padalkar, Acorn Pooley, Ajinkya Jain, Alex Bewley, Alex Herzog, Alex Irpan, Alexander

Khazatsky, Anant Rai, Anikait Singh, Anthony Brohan, et al. Open X-Embodiment: Robotic learning

datasets and RT-X models. In IEEE International Conference on Robotics and Automation (ICRA), 2024.

William Peebles and Saining Xie. Scalable diffusion models with transformers. In Proceedings of the

IEEE/CVF International Conference on Computer Vision (ICCV), pp. 4195–4205, 2023.

Ryan Punamiya, Simar Kareer, Zeyi Liu, Josh Citron, Ri-Zhao Qiu, Xiongyi Cai, Alexey Gavryushin,
 Jiaqi Chen, Davide Liconti, Lawrence Y Zhu, et al. Egoverse: An egocentric human dataset for robot
 learning from around the world. arXiv preprint arXiv:2604.07607, 2026.
 Ri-Zhao Qiu, Shiqi Yang, Xuxin Cheng, Chaitanya Chawla, Jialong Li, Tairan He, Ge Yan, David J Yoon,
 Ryan Hoque, Lars Paulsen, et al. Humanoid policy~ human policy. arXiv preprint arXiv:2503.13441,
 2025.
 Javier Romero, Dimitrios Tzionas, and Michael J Black. Embodied hands: Modeling and capturing hands
 and bodies together. arXiv preprint arXiv:2201.02610, 2022.
 Abraham Savitzky and Marcel JE Golay. Smoothing and differentiation of data by simplified least squares
 procedures. Analytical chemistry, 36(8):1627–1639, 1964.

Gemini Team, Rohan Anil, Sebastian Borgeaud, Yonghui Wu, Jean-Baptiste Alayrac, Jiahui Yu, Radu
 Soricut, Johan Schalkwyk, Andrew M Dai, Anja Hauth, et al. Gemini: A family of highly capable
 of highly capable
 multimodal models. arXiv:2312.11805, 2023.
 Qwen Team. Qwen3.5: Accelerating productivity with native multimodal agents, February 2026. URL
<https://qwen.ai/blog?id=qwen3.5>.
 Yang Tian, Yuyin Yang, Yiman Xie, Zetao Cai, Xu Shi, Ning Gao, Hangxu Liu, Xuekun Jiang, Zherui Qiu,
 Feng Yuan, Yaping Li, Ping Wang, Junhao Cai, Jia Zeng, Hao Dong, and Jiangmiao Pang. InternData-A1:
 Pioneering high-fidelity synthetic data for pre-training generalist policy. arXiv preprint arXiv:2511.16651,
 2025.
 Emanuel Todorov, Tom Erez, and Yuval Tassa. Mujoco: A physics engine for model-based control. In
 2012 IEEE/RSJ international conference on intelligent robots and systems, pp. 5026–5033. IEEE, 2012.
 Ye Wang, Sipeng Zheng, Hao Luo, Wanpeng Zhang, Haoqi Yuan, Chaoyi Xu, Haiweng Xu, Yicheng
 Feng, Mingyang Yu, Zhiyu Kang, et al. Rethinking visual-language-action model scaling: Alignment,
 mixture, and regularization. arXiv preprint arXiv:2602.09722, 2026.
 Kun Wu, Chengkai Hou, Jiaming Liu, Zhengping Che, et al. RoboMIND: Benchmark on multi-
 embodiment intelligence normative data for robot manipulation. In Robotics: Science and Systems
 (RSS), 2025a.
 Kun Wu et al. RoboMIND 2.0: A multimodal, bimanual mobile manipulation dataset for generalizable
 embodied intelligence. arXiv preprint arXiv:2512.24653, 2025b.
 Shihan Wu et al. RoboCOIN: An open-sourced bimanual robotic data collection for integrated manipula-
 tion. arXiv preprint arXiv:2511.17441, 2025c.
 Feng Yan, Fanfan Liu, Yiyang Huang, Zechao Guan, Liming Zheng, Yufeng Zhong, Chengjian Feng, and
 Lin Ma. Robotron-mani: All-in-one multimodal large model for robotic

manipulation. In Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV), pp. 13707–13718, October 2025.

An Yang, Anfeng Li, Baosong Yang, Beichen Zhang, Binyuan Hui, Bo Zheng, Bowen Yu, Chang Gao, Chengen Huang, Chenxu Lv, et al. Qwen3 technical report. arXiv preprint arXiv:2505.09388, 2025.

Yandan Yang, Shuang Zeng, Tong Lin, Xinyuan Chang, Dekang Qi, Junjin Xiao, Haoyun Liu, Ronghan Chen, Yuzhi Chen, Dongjie Huo, et al. Abot-m0: Vla foundation model for robotic manipulation with action manifold learning. arXiv preprint arXiv:2602.11236, 2026.

Qiyang Yu, Quan Sun, Xiaosong Zhang, Yufeng Cui, Fan Zhang, Yue Cao, Xinlong Wang, and Jingjing Liu. Capsfusion: Rethinking image-text data at scale. In IEEE/CVF Conference on Computer Vision and Pattern Recognition, CVPR 2024, Seattle, WA, USA, June 16-22, 2024, 2024.

Wentao Yuan, Jiafei Duan, Valts Blukis, Wilbert Pumacay, Ranjay Krishna, Adithyavairavan Murali, Arsalan Mousavian, and Dieter Fox. Robopoint: A vision-language model for spatial affordance prediction in robotics. In Conference on Robot Learning, 6-9 November 2024, Munich, Germany, 2024.

Kevin Zakka. Mink: Python inverse kinematics based on MuJoCo, February 2026. URL <https://github.com/kevinzakka/mink>.

Michał Zawalski, William Chen, Karl Pertsch, Oier Mees, Chelsea Finn, and Sergey Levine. Robotic control via embodied chain-of-thought reasoning. arXiv preprint arXiv:2407.08693, 2024.

Tao Zhang, Song Xia, Ye Wang, and Qin Jin. Easymimic: A low-cost framework for robot imitation learning from human videos. arXiv preprint arXiv:2602.11464, 2026a.

Tianyi Zhang, Haonan Duan, Haoran Hao, Yu Qiao, Jifeng Dai, and Zhi Hou. Grounding actions in camera space: Observation-centric vision-language-action policy. In Proceedings of the AAAI Conference on Artificial Intelligence, volume 40, pp. 18782–18790, 2026b.

Zhanguang Zhang, Zhiyuan Li, Behnam Rahmati, Rui Heng Yang, Yintao Ma, Amir Rasouli, Sajjad Pakdamansavoji, Yangzheng Wu, Lingfeng Zhang, Tongtong Cao, et al. Do world action models generalize better than vlas? a robustness study. arXiv preprint arXiv:2603.22078, 2026c.

Tony Z. Zhao, Vikash Kumar, Sergey Levine, and Chelsea Finn. Learning fine-grained bimanual manipulation with low-cost hardware. In Robotics: Science and Systems (RSS), 2023.

Jinliang Zheng, Jianxiong Li, Zhihao Wang, Dongxiu Liu, Xirui Kang, Yuchun Feng, Yanan Zheng, Jiayin

Zou, Yilun Chen, Jia Zeng, et al. X-vla: Soft-prompted transformer as scalable cross-embodiment

vision-language-action model. arXiv preprint arXiv:2510.10274, 2025.

Ruijie Zheng, Dantong Niu, Yuqi Xie, Jing Wang, Mengda Xu, Yunfan Jiang,

Fernando Castañeda,

Fengyuan Hu, You Liang Tan, Letian Fu, et al. Egoscale: Scaling dexterous manipulation with diverse

egocentric human data. arXiv preprint arXiv:2602.16710, 2026.

Enshen Zhou, Jingkun An, Cheng Chi, Yi Han, Shanyu Rong, Chi Zhang, Pengwei Wang, Zhongyuan

Wang, Tie-Jun Huang, Lu Sheng, and Shanghang Zhang. Roborefer: Towards spatial referring with

reasoning in vision-language models for robotics. CoRR, abs/2506.04308, 2025.

Shangchen Zhou, Chongyi Li, Kelvin CK Chan, and Chen Change Loy. Propainter: Improving propa-

gation and transformer for video inpainting. In Proceedings of the IEEE/CVF international conference on

computer vision, pp. 10477–10486, 2023.

Yi Zhou, Connelly Barnes, Jingwan Lu, Jimei Yang, and Hao Li. On the continuity of rotation represen-

tations in neural networks. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern

Recognition (CVPR), 2019.