

Track2Act：通过预测互联网视频中的点轨迹实现可泛化的机器人操作

原文：Track2Act: Predicting Point Tracks from Internet Videos enables Generalizable Robot Manipulation。Homanga Bharadhwaj、Roosbeh Mottaghi、Abhinav Gupta、Shubham Tulsiani；卡内基梅隆大学与 Meta FAIR，2024 年。原文注明带星号作者贡献相同，通讯作者为 Homanga Bharadhwaj。

摘要

我们希望学习一种可泛化的目标条件策略，使机器人无需在测试时适应，就能在新场景中从未见过的物体交互，完成各种操作任务。典型方法通常依赖大量示范数据才能获得这种泛化能力；我们提出的方法则利用网络视频预测合理的交互计划，再学习一种不依赖具体任务的转换，将这些计划变成真实世界中的机器人动作。

我们的框架 Track2Act 根据目标，预测图像中的点在未来各时刻如何运动，得到点轨迹。它可以用网上各种各样的视频训练，其中既包括人类，也包括机器人操作日常物体的视频。我们利用预测的二维点轨迹推断待操作物体的一系列刚体变换，并得到可开环执行的机器人末端执行器位姿。随后，我们用少量针对目标机器人形态的示范训练闭环策略，让它预测残差动作，修正开环计划。

我们表明，把可大规模学习的轨迹预测与只需极少目标机器人数据的残差策略结合，能够实现多种可泛化的机器人操作。我们展示了大量真实机器人结果，涵盖未见任务、物体和场景。项目地址：<https://homangab.github.io/track2act/>。

关键词：多样化、可泛化的操作；网络视频。

1. 引言

能够在新环境中开箱即用、可靠执行任务的机器人，有潜力帮助人们完成日常工作。要实现这种可泛化的机器人操作，关键是让机器人具备直接执行能力：面对指定任务时，无需先通过示范或自行练习进行测试时训练，就能立即执行。这一点让系统可以反复使用而不必停机学习，也让它无需探索性动作就能安全地在人类身边工作。我们的目标就

是开发这样的机器人操作系统，使其能够完成范围广泛的日常任务。除了直接部署，我们还希望机器人能在真实世界中多样化的办公室和厨房里泛化，从而更容易普及。

已有工作尝试通过在机器人交互数据集上进行行为克隆来获得这种能力 [5,8,28,73]。原则上，这种路线可以随数据量扩展，但受实际操作条件限制，采集多样化的真实机器人交互数据十分困难。事实上，近期尝试扩大机器人数据集规模的工作，包括跨机器人和跨领域的数据集 [5,15,46]，仍存在任务多样性不足的问题，而且大多局限于类似实验室的结构化场景。另一些面向真实环境部署的近期工作没有学习可直接部署的单一策略，而是采用测试时训练 [2,40]。它们或者需要先提供人类完成任务的视频，再进行在线探索 [2]；或者需要人手持机器人末端执行器提供示范 [40]。要在多种场合部署，这类方法并不方便，因为它们要求人先完成任务，然后机器人还要花几个小时学习如何在完全相同的场景中完成完全相同的任务。因此，面对新场景中的新任务，它们并不能直接部署。

我们的核心认识是：要兼顾真实环境中的操作与直接部署，可以把操作策略分成两部分。一部分是交互计划，利用网上大规模、多样化的人类与机器人日常物体操作视频学习；另一部分是残差策略，只需要少量针对机器人形态的交互数据。这样的分解结构受到已有工作（如 [4]）的启发，但与 [4] 使用手和物体掩码不同，我们通过预测初始场景图像中的点在未来帧中如何移动，以不依赖机器人形态的方式表示交互计划。

这种交互计划比 Bharadhwaj 等人 [4] 的手和物体掩码更有表现力，因为它直接捕捉跨时间的点对应关系，同时又比完整 RGB 视频 [14] 更容易计算。给定场景初始图像、定义任务的目标图像，以及初始图像中的一组随机点，我们把交互计划定义为这些点在未来帧中的二维位置轨迹；沿着这些轨迹运动应能完成目标。重要的是，我们可以完全用网上丰富的人类与机器人视频训练这个模型，无需部署所用机器人形态的专门数据：使用现成的点跟踪方法 [29] 即可生成作为真值的点轨迹。在机器人环境中部署时，只需额外输入初始场景的深度图，并通过优化求得待操作物体的刚体变换，就可以把二维交互计划转成一系列三维末端执行器位姿。最后，利用少量涵盖不同任务、针对目标机器人形态的交互数据（总计约 400 条轨迹），我们学习一个目标条件残差策略，在每个时间步修正预测计划中的误差，实现闭环部署。

总之，Track2Act 的贡献如下：

- 我们提出一种框架，从多样化的网络视频中预测点轨迹，以此学习不依赖机器人形态的交互计划。
- 我们展示了如何利用交互计划预测模型，在机器人环境中获得三维刚体变换；无需机器人数据或在线探索，即可直接操作。
- 利用少量（约 400 条）针对目标机器人形态的任务示范，我们展示了如何学习目标条件残差策略，在每个时间步修正预测计划中的误差。交互计划预测与残差策略修正相结合，便可在新场景中闭环执行新任务。

Spot 机器人在真实世界中的操作结果（见图 1）表明，系统能够在未见过的场景中，面对多种未见物体和任务实现广泛泛化。这也说明，容易获取的网络被动视频有潜力用于学习不依赖机器人形态的交互计划。其意义在于：无需收集大规模目标领域操作数据，就可以使用一个通用的目标条件策略完成对未见任务的机器人操作。

【原文图 1】展示本文框架在真实办公室和厨房中的多种机器人操作能力。系统从网络视频学习预测点轨迹，形成可用于推断新场景中机器人动作的交互计划。一个共同的目标条件策略因此可以执行关微波炉、拉开抽屉、翻开烤面包机、从罐中倾倒物品等日常任务。每组图的两列分别是策略执行过程的第一帧和最后一帧。

2. 相关工作

从视频理解交互。 多种计算机视觉方法通过整理大规模视频数据集 [10,11,21,22,35,55,59]、估计手部姿态 [1,6,18,24,27,34,37,53,58,72]、估计物体姿态 [25,26,31,52,64]，以及预测交互热点或抓取位置 [7,20,38,43,44]，研究如何理解各种日常活动中的手与物体交互。有些方法研究如何根据任务描述生成视频，通常也以场景为条件 [14,23,68,69]。另一些工作尝试通过识别帧间视觉对应关系来理解一般视频 [19,36]。近期的通用视频跟踪系统在这一问题上取得显著进展：它们可以在视频各帧中跟踪某一帧指定的点 [13,29]。我们的轨迹预测模型受到这些进展启发，利用视频跟踪方法从网络视频生成真实轨迹，再训练一个模型，使其根据初始图像和目标预测未来点轨迹。

学习用于操作的视觉表征。 视觉模仿是实现机器人操作泛化的一种有前景的方法 [16,42,70]。近期将其扩展为大规模操作模型的工作需要极大量专家机器人轨迹，采集往往要花费数年 [5,8,73]，但面对新物体的新场景时，泛化能力仍有限。除了图像观测，已有工作也研究用点云 [9,47,54]、关键点 [51] 等结构化表征进行操作，但只适用于结构化的桌面任务。其中一些方法以流形式的表征预测动作 [19,54]，需要机器人交互的三维数据集（通常来自仿真），限制了它们在真实世界中泛化部署。近期，Vecerik 等人 [60] 将点跟踪用于视觉伺服，但其设置要求预先以结构化方式定义多阶段任务，而且测试时相对训练数据只允许很小的变化。与其同期的工作 [63] 通过预测当前图像中点的未来轨迹改进 [60]，结合目标领域的人类和机器人视频学习策略。然而，其框架的轨迹预测依赖每一步的图像观测，因此不便直接利用网络视频。相比之下，我们独立开发的方法只需要初始图像和目标，就能从网络视频学习预测任意点的轨迹；我们展示了如何由预测轨迹推断物体刚体变换并开环执行，再通过预测动作残差改善开环计划，实现闭环部署。这样，一个模型便能在真实环境中面对新物体和新场景，表现出多样化的操作行为。

利用非机器人数据进行操作。 在机器人交互数据以外实现高效学习的一种常见做法，是用人类被动视频 [22,30] 和图像数据 [12] 预训练策略模型的视觉骨干表征

[39,41,45,48,65]。不过，这些方法仍严重依赖大量目标领域机器人数据或部署时训练，并且只能学习特定任务的策略。一些不需要部署时训练的工作进一步利用经过整理的人类视频中的手部运动信息 [50,56]，但学习的仍是任务专用策略，而不是跨一般任务的单一模型。还有一些跨任务训练单一策略的方法需要大量目标领域中严格对齐的人机数据 [57,62,66]，无法利用网络数据。为了直接从网络视频学习更贴近操作的结构信息，一些工作预测视觉可供性，包括图像中的交互位置与局部交互方式 [3,20,38,43]。这些预测可作为机器人策略的良好初始化，但本身不足以完成任务，因而通常还需结合在线学习，需要数小时部署时训练和机器人数据 [2,3]。另一些方法预测场景中的手与物体掩码 [4]，供条件行为克隆使用；但掩码通常无法明确表达物体状态的准确变化。与这些方法不同，我们通过整段轨迹的点轨迹预测，估计场景中物体未来的大致运动，而且无需部署时训练即可直接执行。

【原文图 2】方法流程：从网络视频数据集学习轨迹预测，在机器人环境中根据预测轨迹推断物体刚体变换，再用少量机器人数据学习残差策略进行修正。这让单一目标条件策略能够处理多样化的（包括未见过的）任务。

3. 方法

我们的目标是开发可泛化的机器人操作系统，使其能够以可扩展的方式利用多样化视频数据，在真实世界中完成不同操作。我们的关键思路（图 2）是把策略分解成两步：第一步，学习不依赖机器人形态的交互计划，描述场景图像中的点在后续时间步应如何移动以实现给定目标；第二步，通过残差策略，根据交互计划推断机器人动作。我们展示了这种方法如何泛化到涉及未见任务和物体的多样化场景：预测模型受益于网络数据训练，能够泛化到新场景，而残差策略只需完成较简单的任务，即修正由交互计划导出的机器人动作。

3.1 概述与问题设置

给定描述场景的 RGB 图像 I_0 和表示任务目标的图像 G ，我们希望机器人在场景中执行动作 $a_{1:H}$ ，达到预期目标。为在未见场景中做到这一点，我们利用网络视频训练模型 $\tau = V_\theta(I_0, G, P_0)$ ，预测初始图像中 p 个随机点 P_0 的未来位置（即轨迹）。如果还知道初始帧的深度图，就可以利用预测轨迹中对应于运动点的子集 τ_{obj} ，推断待操作物体的刚体变换序列 $[T_t]_{t=1}^H$ ，进而得到机器人末端执行器位姿形式的开环计划 $[\bar{a}_t]_{t=1}^H$ 。最后，我们训练闭环残差策略 $\pi_{res}(I_t, G, \tau, [\bar{a}_t]_{t=1}^H)$ ，使其在每一步预测残差动作 Δa_t 、修正开环动作序列；实际执行的动作序列因此是 $[a_t = \bar{a}_t + \Delta a_t]_{t=1}^H$ 。下文分别解释这三个阶段的架构和算法。

【原文图 3】扩散 Transformer V_θ 的架构。模型根据初始图像 I_0 、目标图像 G 和包含 p 个点的初始集合 P_0 ，对点轨迹预测进行去噪。

【原文算法 1：由点轨迹预测刚体变换】输入轨迹 τ 、初始图像 I_0 、目标 G 、初始三维点 P_0^{3D} 、相机内参 K 和预测时长 H 。先从 τ 中筛选运动点的轨迹 $\tau_{obj} = \{(x_t^i, y_t^i)\}$ ；未知量为每个时间步的 3×4 刚体变换 T_t 。可选地用 RANSAC 去除轨迹异常值。对每个 $t = 1, \dots, H$ ，选择令投影误差最小的 T_t ：

$$T_t = \arg \min_{T_t} \sum_i (\|x_t^i - u_t^i\| + \|y_t^i - v_t^i\|), \quad (u_t^i, v_t^i, 1) \simeq K T_t P_0^i.$$

其中 $(u_t^i, v_t^i, 1)$ 是齐次坐标表示的投影点。算法返回各时间步的刚体变换 $T_t = (R_t, t_t)$ 。（原文算法中的点下标排版有歧义；结合正文，此处使用的是初始三维点 P_0^i 。）

3.2 从网络视频预测点轨迹

我们用基于 DiT 的扩散模型 [49]，把轨迹预测实现为去噪过程。令 I_0 表示视频首帧， G 表示目标，在这里取视频末帧。对于较长的视频，我们切出多个时长 4 至 5 秒的片段用于训练。假设需要跟踪首帧中的 p 个点，用 P_0 表示这些点的集合； H 是预测时长， $[P_t]_{t=1}^H$ 是我们希望预测的这些点在后续各时刻的位置。在正向扩散过程中，我们逐步向所有点 P_t 添加噪声 ϵ_k (k 表示扩散时间步)，得到 $\tilde{P}_t$ ，直至其分布收敛到单位高斯分布 $\mathcal{N}(0, I)$ 。要生成新样本，就逆转正向扩散过程，从高斯噪声逐步回到点的位置空间。因此，需要训练噪声预测器 $V_\theta(I_0, G, P_0, k)$ ，来求解逆向扩散过程。我们为它设计的 DiT Transformer 架构见图 3。与原始 DiT 不同，除了扩散步的嵌入 z_k ，我们还用初始图像嵌入 z_0 和目标图像嵌入 z_g 进行条件化。每个批次输入 Transformer 的序列包含 p 个 token，对应指定的 p 个跟踪点。按照时间序列条件扩散模型的惯例，初始点 P_0 不添加噪声。

我们用网络视频训练预测模型时，初始需要跟踪的点数 p 可以变化。为了让模型使用灵活，这 p 个点的位置也是随机选取的，因此测试时可以指定初始图像中的任意一组点。我们不对视频中的跟踪物体或相机运动作任何假设；除了保证片段时长为 4 至 5 秒，也不以其他方式筛选训练视频。如果目标图像相对初始场景有多个物体发生运动，或者相机发生运动，轨迹预测模型就会为不同物体预测不同的运动群组，同时预测背景点的运动以反映相机运动。不过，机器人实验每次只操作一个物体，而现实中不少不同类型的任务都符合这一条件。

【原文图 4】残差策略的架构。它在每个时间步对预测的开环计划给出修正，使机器人可以闭环执行。

3.3 根据交互计划推断粗略的机械臂轨迹

给定机器人环境中的场景图像 I_0 、目标 G ，以及初始图像中的随机点集 P_0 ，训练好的轨迹预测模型可以给出这些点未来的二维位置 $\hat{P}_t$ 。由于我们考虑固定相机、每次仅操作一个物体的场景，只有一部分点的预测运动幅度较大。我们识别出这 p 个点，把它们的预测轨迹记为 $\tau_{obj} = [\{(x_t^i, y_t^i)\}_{i=1}^p]_{t=1}^H$ 。假设机器人装有 RGB-D 相机，因此首帧中的点 P_0 也有深度。把这些三维点记为 $P_0^{3D} = \{(x_0^i, y_0^i, z_0^i)\}_{i=1}^p$ 。

有了首帧中的三维点 P_0^{3D} 、物体点的预测二维轨迹 τ_{obj} 和相机内参矩阵 K ，我们希望推断待操作物体相对首帧在每个时刻的刚体变换 T_t ，并使其形成平滑轨迹。如算法 1 所示，做法是让变换后三维点的投影，也就是 $KT_t P_0$ ，在每一步尽可能贴近预测的二维轨迹 $\{(x_t^i, y_t^i)\}_{i=1}^p$ 。设 $KT_t P_0 \simeq \{(u_t^i, v_t^i, 1)\}_{i=1}^p$ ，则第 i 个点在时刻 t 的二维投影是 (u_t^i, v_t^i) ；预测轨迹中同一点的坐标则是 (x_t^i, y_t^i) 。为求得 T_t ，可以求解算法 1 第 6 行的优化问题，例如使用 PnP 求解器。这个优化问题不是欠约束的，因为同一个三维刚体变换必须同时解释初始场景中多个点的二维运动。所得刚体变换不依赖机器人形态，描述的是物体在场景中应如何运动。

要真正操作场景中的物体，还得先把机器人末端执行器（即机器人与物体交互的部件）移到物体附近，必要时抓住物体，然后按照预测的 $[T_t]_{t=1}^H$ 移动末端执行器。第一步采用启发式方法：给定初始末端位姿 e_0 ，定义首个变换 T_0 ，让末端执行器以与 e_0 相同的朝向移动到物体三维点的中心。末端执行器到达位姿 e_1 后，执行抓取以握住物体。之后把刚体变换应用到 e_1 ，得到后续末端位姿，也就是开环动作轨迹 $\bar{a}_t = T_t e_1$ 。

3.4 用残差策略修正实现闭环操作

上一节所述的预测三维末端变换开环执行序列 $[\bar{a}_t]_{t=1}^H$ ，可能因预测中的小误差而失败。另外，由于这种方法完全不用针对目标机器人形态的数据，它对物体接触缺乏准确判断：即使余下轨迹都执行正确，也可能一开始就没能抓住物体。为解决这些问题，我们提出学习图 4 所示的残差策略 $\pi_{res}(I_t, G, \tau, [\bar{a}_t]_{t=1}^H)$ ，在每一步修正预测的末端位姿。时刻 t 的末端位姿为：

$$\hat{a}_t = \bar{a}_t + \Delta a_t, \quad \Delta a_t = \pi_{res}(I_t, G, \tau, [\bar{a}_t]_{t=1}^H). \quad (1)$$

我们不只预测单步残差动作 Δa_t ，还预测未来 h 步的残差 $\Delta a_{t:t+h}$ ；部署时只执行预测序列的第一个动作。已有研究表明，这种多步预测可以减轻行为克隆训练中误差逐步累积的问题 [5,71]。我们可以用少量代表性任务的机器人示范，通过行为克隆训练残差策略，总计约 400 条轨迹。每条轨迹包含一系列观测与动作对 $[(I_t, a_t)]_{t=1}^H$ ，其中 I_t 是机器人相机观察到的图像， a_t 是末端位姿形式的动作。

关键是，策略只需学习对预测路径点 $[\bar{a}_t]_{t=1}^H$ 的小幅修正，所以不必收集与实际部署场景完全相同的数据来训练它；预测模型则有望凭借多样化训练泛化到未见场景。我们的考虑是：只需在少数场景下获取针对目标机器人形态的示范，便可修正仅由网络数据得到的开环预测。评估时，我们设置了多个泛化等级，涵盖未见过的物体实例，以及未见场景中的全新物体。

4. 实验设置

实验聚焦于真实、自然的操作场景：移动机械臂需要根据指定目标，在不同的客厅、办公室和厨房里操作物体。所有机器人实验均使用 Boston Dynamics 的 Spot 机器人，它配有机械臂（手）和朝前的 Intel RealSense 相机 [32]。我们根据策略输出，通过末端执行器控制机械臂。

4.1 评估细节

轨迹预测。 为定量评估轨迹预测模型，我们使用已有工作 [13,29] 的 δ_x^t 指标的一个修改版本。对于评估视频，我们将 Co-Tracker [29] 的输出当作真值，再按照 δ_x^t 比较预测结果。 δ_x^t 定义为：在时间步 t ，预测位置与真值相距不超过 x 像素的点所占比例。我们让 x 从 1 变化到 $N = 10$ ，对 δ_x^t 在预测时长 H 上取平均，以曲线下面积 Δ 报告结果。换言之， Δ 综合衡量不同像素阈值和时间步上的命中比例，范围是 0 到 1，越高越好。

（原文公式写作 $\Delta = (\sum_{t=1}^H \sum_{x=1}^N \delta_x^t) / H$ ；结合作者所说的取平均以及 0 到 1 的范围，阈值维度还应有归一化。）

机器人操作。 按目标条件机器人学习的惯例，我们用成功率评估：如果执行结束后待操作物体在场景中的最终姿态与目标图像里的姿态一致，该次轨迹就算成功。参照已有工作 [4,5,8,73]，我们按以下泛化等级汇报结果：

- **轻微泛化 (MG)**：在已见场景里，以新的配置摆放已见过的物体实例；也包括光照、背景等自然场景变化。
- **标准泛化 (G)**：在已见或未见场景中操作未见过的物体实例。
- **组合泛化 (CG)**：在已见或未见场景中，面对未见过的活动与物体类型组合。
- **类型泛化 (TG)**：在未见场景中，面对全新的物体类型，或全新的活动类型。

4.2 基线与比较方法

在定量评估中，我们先将轨迹预测方法与相关基线比较，然后在机器人操作实验中与其他基线比较。

轨迹预测。 两个基线的输入与我们的模型相同，均为初始图像、目标图像和初始图像中指定的点；输出也相同，均为两幅图像之间的点轨迹。第一个是基于光流的基线：直接预测初始图与目标图之间的光流，再对各时间步的光流向量插值 [67]。第二个基线在初始图像和目标图像之间补全视频 [17]，然后用 Co-Tracker [29] 从生成的视频中获取轨迹。

机器人实验。 我们为目标条件机器人操作安排了多个基线与消融实验。所有基线均使用与我们的完整方法相同的目标机器人形态示范数据。我们的完整方法则在每一步对开环动作预测残差。具体比较对象如下：

- **目标条件行为克隆 (Goal-Conditioned BC)：** 与已有工作 [5,8,73] 类似的多任务策略学习基线。
- **可供性条件行为克隆 (Affordance-Conditioned BC)：** 来自 [3]，以初始图像中预测的可供性作为策略条件。
- **视频条件行为克隆 (Video-Conditioned BC)：** 基于 [14,17,33]，先预测 RGB 视频，再跟踪其中的点。
- **手与物体掩码条件行为克隆 (Hand-Object Mask Conditioned BC)：** 来自 [4]，以手和物体掩码构成的预测交互计划为条件。

我们的方法（开环） 先预测轨迹，再按算法 1 开环执行；训练时不使用任何针对目标机器人形态的数据。为了弄清预测动作残差是否优于直接预测完整动作，我们还比较消融版本 **我们的方法（直接预测动作，不预测残差）**：它直接预测 $\hat{a}_t$ ，不预测 Δa_t ，也不以开环计划作为输入。

4.3 训练数据

为了训练轨迹预测模型，我们使用由其他人采集、在网上提供的多样化被动视频。具体来说，包括 EpicKitchens [10] 的人类视频片段（切成 4 至 5 秒），以及 RT-1 [8] 和 BridgeData [61] 发布的大规模机器人视频。我们在由此得到的 40 万个视频片段上运行 Co-Tracker [29]，获得训练预测模型所需的真实轨迹。请注意，机器人数据集 RT-1 和 BridgeData 中的机器人与场景，和我们用于实验的 Spot 完全不同。训练残差策略所用的目标机器人形态数据，则是我们通过遥操作 Spot、执行关门、拉抽屉、操作瓶子和水壶等日常物体的 10 项任务所收集的约 400 条轨迹。这一数据量比相关策略学习工作 [5,8,73] 的需求少三到四个数量级。

5. 结果

我们先展示预测轨迹和机器人评估的定性结果，再用第 4.1 节的指标做定量比较。更详细的定性结果和机器人评估视频见补充材料压缩包。

5.1 点轨迹预测结果

【原文图 5】展示多个数据集里未见初始图像与目标图像的轨迹预测定性结果。给定初始图像中指定的点，模型预测它们朝目标图像变化时的未来轨迹。预测轨迹看起来合理，对应场景中物体的操作运动。

【原文表 1】在网上不同数据集的留出视频上评估轨迹预测。EpicKitchens [10] 和 SmthSmthv2 [21] 是人类视频数据集；BridgeData [61] 和 RT-1 [8] 是机器人视频数据集。这里是同一个模型在不同数据集上的评估。指标 Δ 见第 4.1 节，范围为 0 到 1，越高越好。

方法	EpicKitchens	SmthSmthv2	BridgeData	RT-1
光流 [67]	0.21	0.27	0.42	0.38
视频生成 [17]	0.30	0.17	-	-
我们的方法	0.67	0.70	0.77	0.75

先看预测模型在不同未见场景中的一些定性结果。图 5 显示了它对多个数据集中未见初始图像和目标图像的轨迹预测。我们在初始帧选取网格上的点，如图中第三行所示。预测模型以初始图像、目标图像和初始图像中待预测未来轨迹的点集为条件。第四行显示的预测是合理的，并且对应于各目标图像所描述的场景物体操作。当初始图像与目标图像之间有多个实体（例如人与物体、机器人与物体）或相机发生移动时，也能看到不同的点轨迹群分别预测各自的运动。

表 1 将我们的轨迹预测与光流基线 [67]、视频基线 [17] 比较。两个基线的准确率都明显低于直接预测点轨迹的方法。原因是，光流过于粗略，无法捕捉初始图像与目标图像之间幅度较大、非线性的状态变化；先预测 RGB 视频再跟踪，则容易生成不合理内容，因为视频生成远比点轨迹预测复杂，还必须处理外观、纹理等细节，而点轨迹预测把这些细节抽象掉了。作为参考，如果所有时间步都预测所有点完全不移动，四个数据集上的分数分别为 0.03、0.05、0.36、0.28。这说明，如果目标是捕捉场景中物体在初始图像和目标图像之间的运动，直接预测未来点轨迹更有优势。

5.2 机器人操作结果

我们还展示了训练好的预测模型在机器人环境中给出的点轨迹，以及残差策略根据这些预测执行的结果。图 6 在初始图像上叠加预测轨迹，图像上方给出相应的目标图像；下方依次给出一次执行过程的首帧（1）、两个中间帧（2、3）和末帧（4）。可以看到，预测轨迹使物体上的点朝满足目标的方向运动，策略也能够把物体操作到所需的目标配置。由于初始图像与目标图像之间相机没有移动，预测中背景（非物体）像素保持静止，这有助于准确预测物体的刚体变换。

【原文图 6】不同任务的点轨迹预测，以及随后由残差策略进行的闭环执行。预测轨迹合理，机器人执行也实现了预测的变化，完成目标图像指定的任务。底行给出第 4.1 节定义的各任务泛化等级。

【原文图 7】从第三人称视角展示残差策略在不同任务上的机器人执行定性结果，按第 4.1 节的泛化等级排列。每项任务展示一次执行过程的第一帧和最后一帧；补充材料压缩包中的视频更适合查看完整执行过程。

表 2 按泛化等级比较机器人操作实验结果。我们在五个不同的真实厨房、办公室和客厅场所，针对总计 25 项任务，在每个泛化等级上对每种方法评估 20 次执行。首先，残差策略的表现优于直接执行预测刚体变换所构成的开环计划。这说明，凭借少量针对目标机器人形态的数据，残差策略能够修正开环计划的不准确之处，帮助机器人准确抓住物体，并在轨迹执行中可能出错时恢复。

我们观察到，在轻微泛化（MG）等级，目标条件行为克隆基线的成功率只略低于我们的残差策略；但在标准（G）、组合（CG）和类型（TG）泛化等级，其成功率大幅下降，甚至为零。这体现了用网络视频学习交互计划的益处，它帮助我们方法有效泛化。最后，与同样使用网络数据的可供性条件、视频条件和手与物体掩码条件行为克隆基线相比，我们的方法在较高的泛化等级（CG 和 TG）上有显著优势。这说明，仅预测静态可供性而不推理运动轨迹、生成容易出错并在场景中产生不合理伪影的 RGB 视频，或者只预测手和物体的二维掩码而不推理点对应关系，都不足以有效利用网络视频。相比之下，我们通过轨迹预测学到的交互计划能用于推断三维刚体变换，为解决未见操作任务提供足够信息；残差策略再修正预测中的误差。

【原文表 2】按第 4.1 节的协议评估目标条件机器人操作。数字是各泛化等级下 20 次执行的平均成功率，越高越好。任务详细列表见补充 PDF，部分执行过程见图 7。

方法	MG	G	CG	TG
行为克隆（BC）	60%	20%	0%	0%
可供性条件	65%	30%	10%	5%
视频条件	60%	25%	0%	0%
手与物体掩码条件	70%	40%	25%	20%

方法	MG	G	CG	TG
我们的方法（开环）	35%	25%	30%	25%
我们的方法（消融：直接预测动作）	70%	45%	30%	30%
我们的方法（完整）	70%	60%	55%	40%

5.3 失败分析

这里讨论框架表现出的失败情况。对于基于刚体变换的开环计划，我们观察到的主要失败模式是无法在正确位置抓住物体，以及过程中出错后无法恢复。残差策略利用少量针对目标机器人形态的数据修正了这些行为，因此成功率更高。我们也注意到，在更高的组合泛化（CG）和类型泛化（TG）等级，成功率仍不算很高，因为这些设置非常困难。残差策略有时会抓错物体位置、尝试执行不可行的运动而卡住，或者执行出与目标图像不符的轨迹。

6. 讨论与结论

本文提出一个可泛化的机器人操作框架：利用大规模网络视频数据，学习不依赖机器人形态的计划，描述如何操作场景中的物体以实现目标。我们再结合少量针对目标机器人形态的数据，通过闭环策略学习对预测计划的残差修正。面对多样化任务与不同泛化等级，真实世界中的操作结果表明，可大规模利用网络数据来预测物体操作计划具有潜力。虽然该框架能够在真实环境中的未见任务上表现出较强的泛化能力，但目前的任务仍是短时程的，而且每次只涉及操作场景中的一个物体。未来一个有意义的方向，是将框架扩展到需要依次操作场景中多个物体的长时程任务。