

VidBot：从野外二维人类视频中学习可泛化的三维动作，用于零样本机器人操作

作者：Hanzhi Chen, Boyang Sun, Anran Zhang, Marc Pollefeys, Stefan Leutenegger

单位：慕尼黑工业大学；苏黎世联邦理工学院；Microsoft

项目主页：<https://hanzhic.github.io/vidbot-project/>

图 1

图 1 展示了 VidBot：一个从野外采集的、仅含 RGB 的人类视频中学习交互的框架。其可供性模型可以跨机器人部署，用于日常操作任务。图中示例包括：从日常人类视频中抽取三维可供性；学习语言条件下的三维可供性；在机器人之间零样本部署以完成家庭操作任务，例如“打开柜子”“放置杯子”“拿纸巾”“打开微波炉”“扔下盒子”“拉抽屉”“关冰箱”“打开碗柜”“拿牛奶”“推抽屉”“关柜子”“拿起洒水壶”等。

摘要

未来的机器人被设想为能够执行多种家庭任务的通用系统。核心问题仍然是：如何在尽量减少实体机器人学习的同时弥合具身差异，因为大规模实体机器人学习本质上很难扩展。我们认为，从野外人类视频中学习为机器人操作任务提供了一条有前景的路径，因为互联网上已经存在海量相关数据。本文提出 VidBot，这是一个利用从野外单目 RGB 人类视频中学到的三维可供性来实现零样本机器人操作的框架。

VidBot 使用一条流水线从视频中抽取显式表征，即三维手部轨迹。该流水线结合深度基础模型和运动恢复结构（SfM）技术，重建时间一致、米制尺度、且与具身形式无关的三维可供性表征。我们提出一种由粗到细的可供性学习模型：先从像素空间识别粗粒度动作，再在粗粒度动作条件下，用扩散模型生成细粒度交互轨迹；同时在测试时引入约束作为引导，实现具有场景上下文感知的交互规划，从而在新场景和新具身上获得较强泛化能力。大量实验表明 VidBot 有效：在零样本设置下，它在 13 个操作任务上显著优于对比方法，并能在真实环境中的不同机器人系统间无缝部署。VidBot 为利用日常人类视频扩大机器人学习规模铺平了道路。

1. 引言

人工智能的发展正在加速个性化设备的出现，例如能向用户提供虚拟指导的智能眼镜。未来，机器人也会成为类似智能手机或智能眼镜的个性化系统，为人类提供物理层面的辅助。然而，多样且新颖的机器人具身形式，为将 AI 部署到开放任务和开放环境中带来了重大挑战。

当前学习机器人操作技能的先进方法，仍然高度依赖人类专家的遥操作示范，并在模仿学习范式下用这些示范训练机器人策略。这个过程昂贵、耗时且劳动密集。虽然近期已有工作收集了面向日常操作的大规模机器人示范，例如 Open X-Embodiment 和 DROID，但由于具身、任务和环境的组合爆炸，继续扩大数据收集仍然困难。我们认为，人类视频提供了一个有前景且可扩展的替代方案：网络上已经有大量视频记录了人类在不同环境中执行多样任务。已有若干工作探索人到机器人的技能迁移，但它们通常受到限制，例如需要静态相机或静态场景、深度传感器、动作捕捉系统等。

这些约束通常导致数据来自实验室环境，缺乏场景、光照和视角的多样性。一类研究利用包含丰富场景上下文的互联网人类视频来增强机器人学习，重点学习视觉运动策略的视觉表征。但其主要限制在于：面对每个新环境和每种新具身，仍需要人类收集特定任务的遥操作数据来微调预训练模型。近期一些工作开始显式抽取与智能体无关的交互轨迹，但这些运动往往被简化为像素空间中的二维向量，限制了它们直接部署到机器人上的能力。我们认为，除

了视觉表征或受限于二维图像平面的像素级动作线索之外，三维可供性才是统一不同具身、从感知解释动作的关键；这里尤其指具有空间感知的接触点和交互轨迹。然而，从日常人类视频中抽取通用三维可供性数据仍然是重大挑战，也阻碍了机器人通过观看人类来学习操作技能。

本文目标是让机器人能够从大量未标注的日常人类视频中实现零样本学习，解决两个关键问题：第一，如何从原始的仅 RGB 人类视频中抽取三维可执行知识？第二，如何将这些抽取出的知识可靠地零样本迁移到新环境和新机器人具身中？对于第一个问题，我们采用原则化方法，将 SfM 用于机器人学习，开发了一条基于梯度优化的流水线，从野外视频中抽取三维手部轨迹。该流水线结合学习得到的单目深度和几何约束，保证重建具有时间一致性和米制尺度，从而恢复三维接触点和平滑手部轨迹，形成与智能体无关的三维可供性表征。对于第二个问题，我们提出由粗到细的可供性学习框架，从多样化抽取训练数据中学习丰富动作。粗预测阶段中，可供性模型基于 RGB-D 观测和任务指令，从像素中识别高层动作，也就是接触点和目标点；细预测阶段中，扩散模型在粗阶段输出和任务观测条件下生成细粒度交互轨迹。

不同于只依赖从人类数据中学到的动作先验，我们还加入若干可微代价函数，作为测试时采样引导。这些代价函数通过扰动输出，引导扩散去噪过程满足部署时约束。多目标到达、碰撞避免等可微目标，可以捕获粗输出的分布，并利用场景上下文中的几何线索。引导项在考虑场景上下文差异和机器人形态差异的同时，提高交互轨迹的合理性，并为选择最优计划提供直观启发。

我们在仿真和真实世界中进行了大量实验评估。仅使用野外二维人类视频，我们的三维可供性模型优于多个用仿真探索训练或用遥操作示范预训练的基线。此外，我们还展示了该模型在视觉目标到达和探索等下游机器人学习任务中的通用性，表现为更快收敛和更高性能。

2. 相关工作

2.1 视觉可供性学习

可供性的核心是判断智能体应当在给定场景中的哪里、以何种方式进行交互。一类工作使用人工标注数据集回归可供性，但收集可供性标签成本很高。因此，较新的研究通过在仿真环境中部署智能体探索有效交互来缓解该问题。尽管这提供了无需人工干预的数据收集替代方案，这些方法仍常受限于获取多样虚拟资产的成本。

相比之下，人类视频逐渐受到关注，被视为更通用的可供性先验来源。若干方法利用人类视频中的手-物接触标签预测逐像素可供性分数。然而，这些流水线通常只识别接触区域，或只在图像平面内建模交互动作，缺乏空间感知能力。近期一些工作尝试使用 flow 作为具有空间感知的可供性表征来解决这一限制。但这些方法在测试时需要给定目标图像或初始接触区域。相比之下，我们的可供性模型去除了这些要求，直接从野外 RGB-only 人类视频中学习并推断三维接触点和交互轨迹。

2.2 从人类学习机器人技能

已有工作探索利用人类视频辅助机器人学习。一类方法从人类视频中学习视觉表征，并用预训练视觉编码器训练策略网络。另一类研究从人类视频中学习奖励函数。此外，还有一些工作使用从视频中抽取的运动属性，例如估计三维手部姿态或跟踪手腕轨迹。然而，这些方法通常局限于实验室设置，或者仍需要人类专家额外提供遥操作示范。与本文最接近的是 VRB，它使用日常人类视频抽取与具身无关的动作；但它推断的二维像素级运动过度简化且有歧义，限制了直接部署到机器人。相比之下，我们的框架使用与 VRB 相同的人类视频数据进行监督，但可以在三维空间中预测可供性，从而实现机器人零样本技能迁移。

2.3 机器人中的扩散模型

扩散模型是一种强大的学习范式，通过迭代去噪过程近似复杂数据分布。近期它们已在多种生成式建模任务中取得成功。在机器人领域，扩散模型也被证明是强有力的策略学习框架。Diffusion Policy 提出了一种通过条件去噪扩散过程生成多模态机器人轨迹的通用框架。Diffuser 通过引入奖励函数增强了有引导的轨迹采样。后续工作提出了更分解式的策略学习框架，使扩散模型能够在关键步骤之间生成平滑动作。

不过，这些方法主要回归高度受限的域内遥操作数据，测试时不存在模态或具身差异。相比之下，我们的方法从人类视频抽取的大规模训练数据中学习策略。我们提出结合代价引导的由粗到细可供性学习框架，以增强在新场景和新具身中的泛化能力与测试时灵活性。

3. 方法

3.1 问题定义

我们希望从日常人类视频中学习一个分解式可供性模型：

$$\mathbf{a} = \text{pi}(\{\mathbf{I}^{\sim}, \mathbf{D}^{\sim}\}, \mathbf{l})$$

其中 $\{\mathbf{I}^{\sim}, \mathbf{D}^{\sim}\}$ 是 RGB-D 帧， $\mathbf{I}^{\sim}$ 为图像， $\mathbf{D}^{\sim}$ 为深度， $\mathbf{l}$ 为语言指令。深度帧可以来自深度传感器，也可以来自米制深度基础模型。由于可供性表征应当与具身无关，我们沿用已有工作，将最终输出可供性表征 $\mathbf{a}$ 表示为接触点 $\mathbf{c}$ 和交互轨迹 τ ，并将其扩展到三维空间：

$\mathbf{a} = \{\mathbf{c}, \tau\}$ ，其中 $\mathbf{c} \in \mathbb{R}^{N_c \times 3}$ ， $\tau \in \mathbb{R}^{H \times 3}$ 。 N_c 为接触点数量， H 为轨迹时域长度。 $\mathbf{a}$ 表示在观测相机坐标系中。

3.2 从人类视频中获取三维可供性

我们首先设计一条流水线，从移动单目相机记录的日常人类视频中抽取三维手部轨迹，其中每帧位姿未知。流水线主要包括以下组成部分。

数据准备。 给定包含彩色图像 $\{\mathbf{I}^{\sim}_0, \dots, \mathbf{I}^{\sim}_T\}$ 和语言描述 $\mathbf{l}$ 的视频，先使用 SfM 系统估计相机内参 $\mathbf{K}$ 、每帧无尺度位姿 $\{\mathbf{T}_{WC0}, \dots, \mathbf{T}_{WCT}\}$ ，以及世界坐标系下的稀疏路标点 $\{\mathbf{w}_1_0, \dots, \mathbf{w}_1_{N_1}\}$ 。随后使用米制深度基础模型预测每帧稠密深度 $\{\mathbf{D}^{\sim}_0, \dots, \mathbf{D}^{\sim}_T\}$ 。进一步使用手-物检测模型和分割模型，得到每帧手部和接触物体的掩码，即 $\{\mathbf{M}^h_0, \dots, \mathbf{M}^h_T\}$ 和 $\{\mathbf{M}^o_0, \dots, \mathbf{M}^o_T\}$ 。在手部掩码已知的情况下，再收集 $\mathbf{I}^{\sim}_0$ 之前的帧及其手部掩码，并用视频修复模型获得去手后的帧 $\{\mathbf{I}^{\sim}_0, \dots, \mathbf{I}^{\sim}_T\}$ 。

一致位姿优化。 第一目标是将相机位姿校正到米制空间尺度。为此，通过相机内参和位姿将稀疏路标点投影到每个图像平面，并优化所有帧共享的全局尺度 s_g ：

$$\min_{\{s_g\}} \sum_{\{i,j\}} M_{\sim i}[u_{ij}] ||\mathbf{D}^{\sim}_i[u_{ij}] - s_g \mathbf{d}(\mathbf{T}^{\sim}_{-1}\{\mathbf{WC}_i\} \mathbf{w}_1_j)||_2^2 \quad (1)$$

其中 $M_{\sim i} = \text{not}(\mathbf{M}^h_i \cup \mathbf{M}^o_i)$ 表示静态区域， u_{ij} 是第 j 个路标点在第 i 个相机中的像素坐标， $\mathbf{d}(\cdot)$ 表示该点深度。随后，进一步细化所有帧的位姿 $\mathbf{T}_{WCi} \in \mathbf{T}$ 和尺度 $s_i \in \mathbf{S}$ ，补偿由动态手-物运动导致的 SfM 重建误差，并同时让预测深度在不同视角间更一致：

$$\min_{\{\mathbf{T}/\{\mathbf{T}_{WCk}\}, \mathbf{S}/\{s_k\}\}} \sum_{\{i \neq k\}} \sum_{\{u_i\}} M_{\sim i}[u_i] M_{\sim k}[u_k] E[u_i] \quad (2)$$

其中 k 是与其他帧共视程度最高的参考帧索引。 $\mathbf{c}_i \times n_i$ 是由相机内参 $\mathbf{K}$ 和深度 $\mathbf{D}^{\sim}_i$ 反投影得到的点； $E[u_i]$ 衡量第 i 帧点变换到参考帧后与参考帧对应点之间的三维距离； u_k 是由 $s_i, s_k, \mathbf{K}, \mathbf{D}^{\sim}_i$ 和相对位姿计算出的投影像素对应。 s_k 固定为 s_g 。

可供性抽取。得到细化位姿和尺度后，先获取每帧手部中心点，并将其变换到第一帧中，计算交互轨迹 τ^* 。在第一帧中对手部点均匀下采样得到接触点 c^* ，在最后一帧中下采样得到目标点 g^* ，用于监督可供性模型的中间预测。语言描述 l 、修复后的彩色图像 $I_{\sim 0}$ 及其深度 $D_{\sim 0}$ ，以及用物体掩码裁剪出的修复物体图像，作为模型输入。作者使用 EpicKitchens-100 Videos 数据集及 EpicFields 提供的 SfM 结果展示该流水线效果。图 2 给出了抽取结果示例。

图 2

图 2 展示了从原始人类视频中抽取的轨迹示例，例如“打开碗柜”“擦拭台面”。

3.3 由粗到细的可供性学习

图 3 展示了可供性模型总览。模型设计有两个关键考虑。第一，它应能从大量野外人类可供性数据中，在观测和指令条件下捕获动作分布。第二，它应能在测试时利用上下文信息，缓解具身差异以及由训练数据不完美带来的潜在噪声，从而提高生成可供性的质量。

为满足第一点，作者将可供性模型 π 分解为粗模型 π_c 和细模型 π_f 。粗阶段中， π_c 执行高层场景理解，基于 RGB-D 帧和指令推断目标点 g 与接触点 c ，即 $\{g, c\} = \pi_c(\{I_{\sim}, D_{\sim}\}, l)$ 。给定粗阶段输出和任务输入， π_f 进一步规划低层细粒度交互轨迹 $\tau = \pi_f(\{I_{\sim}, D_{\sim}\}, l, a_c)$ 。

为满足第二点，作者将多个解析代价函数集成到 π_f 中，在测试时纳入场景上下文和智能体具身。这些约束引导轨迹生成过程，使交互轨迹更合理、更具上下文感知。最终的可供性输出是接触点 c 和交互轨迹 τ 。

3.3.1 粗可供性预测

粗可供性模型用于从高维图像空间中抽取宏观可执行信息。作者在像素空间中表示粗动作点，学习粗可供性的概率及其对应深度。首先，使用现成的开放集目标检测器获得目标物体的裁剪 RGB-D 图像。粗模型 π_c 包含两个网络：目标点预测网络 π_c^{goal} 和接触点预测网络 π_c^{cont} 。

对目标点预测，输入上下文彩色图像和一个用目标物体中位深度填充的深度图，输出同分辨率的目标热图激活和目标点深度。这样设计是因为交互轨迹的终点往往分布在自由空间中。模型用视觉编码器得到全局上下文特征，再通过 RoI Pooling 提取以物体为中心的嵌入，通过 MLP 得到边界框位置特征，并用冻结 CLIP 模型得到语言指令特征。随后，Perceiver 模块通过自注意力和交叉注意力，使全局上下文特征关注条件特征。融合后的全局上下文特征一方面经过 Transformer 编码器和 MLP 预测目标深度，另一方面送入视觉解码器预测逐像素目标概率。

接触点预测器使用与目标点预测类似的 hourglass 网络结构。但由于接触点通常位于物体表面、具有有效深度，作者省略接触点深度预测，只融合语言特征和视觉编码器抽取的物体接触特征。最后，结合相机内参、从预测热图采样的像素坐标及查询到的深度，将这些点提升到三维空间，得到粗可供性输出：目标点 g 和接触点 c 。

3.3.2 细可供性预测

细可供性模型在接触点和目标点引导下推断细粒度交互轨迹。该阶段受到扩散模型启发，被建模为条件扩散去噪过程。

扩散模型预备知识。给定来自真实分布 $q(\tau)$ 的样本 τ_0 ，前向过程在 K 步中以马尔可夫过程迭代加入高斯噪声：

$$\begin{aligned} q(\tau_k | \tau_{k-1}) &= N(\tau_k; \sqrt{1-\beta_k} \tau_{k-1}, \beta_k I) \\ q(\tau_{1:K} | \tau_0) &= \prod_{k=1}^K q(\tau_k | \tau_{k-1}) \end{aligned} \quad (3)$$

其中 β_k 来自预定义调度器。反向过程中，去噪神经网络学习分布 $p_\phi(\tau_{k-1} | \tau_k)$ ，逐步移除噪声以恢复 τ_0 ：

$$\begin{aligned} p_\phi(\tau_{k-1} | \tau_k) &= N(\tau_{k-1}; \mu_\phi(\tau_k, k), \Sigma_k) \\ p_\phi(\tau_{1:K}) &= p(\tau_K) \prod_{k=1}^K p_\phi(\tau_{k-1} | \tau_k) \end{aligned} \quad (4)$$

在本文设置中，扩散状态 τ 是交互轨迹。去噪网络学习在任务观测 o 条件下的条件分布 $p_\phi(\tau_{k-1} | \tau_k, o)$ 。

轨迹生成。 细可供性模型 π_f 由类似 1D U-Net 的结构参数化。首先，从预测概率最高的目标点集合和接触点集合中获得 $\bar{g}$ 与 $\bar{c}$ 。同时，通过视觉 Transformer 抽取物体特征嵌入，并结合粗阶段得到的语言指令嵌入，构建条件嵌入。为了把空间感知纳入推断轨迹，作者从 RGB-D 帧构建体素化 TSDF 地图，用 3D U-Net 编码得到潜在特征，并通过三线性插值为每个轨迹路点计算空间特征。空间特征和当前带噪轨迹拼接后作为去噪输入。不同于预测噪声， π_f 在每个扩散步直接推断无噪轨迹 $\bar{\tau}_0$ ，并用它计算反向均值。

3.3.3 代价引导的轨迹生成

如果条件目标点 $\bar{g}$ 存在偏移，推断轨迹可能出错。这是预期中的，因为 π_f 本质上是在接触点和目标点之间补全轨迹。仅根据预测分数选择单个最优目标点并不总是可靠；从目标集合中使用多个目标点可以产生更多样、鲁棒的预测。但通过采样不同目标配置多次查询模型效率很低。因此，作者将多目标条件建模为测试时引导轨迹生成的代价函数：

$$J_{\text{goal}} = \min_{g_n \in \mathcal{G}} \|g_n - \tau_{\text{bar}}^0\|_2^2 \quad (5)$$

其中 τ_{bar}^0 是轨迹终点， g_n 是第 n 个目标点。作者还定义场景碰撞避免引导 J_{collide} 和接触法向引导 J_{normal} 。其中， h 表示轨迹时域索引，碰撞项从智能体手部模型和物体表面采样点，在预计算 TSDF 地图中可微查询；法向项使用由接触点计算出的法向量约束运动方向。最终测试时引导代价为：

$$J = \lambda_g J_{\text{goal}} + \lambda_c J_{\text{collide}} + \lambda_n J_{\text{normal}} \quad (7)$$

每个引导项的强度由对应 λ 控制。作者采用重建引导：在每个去噪步，用 J 对当前扩散状态的梯度调整无噪预测：

$$\tau_0 = \bar{\tau}_0 - \Sigma_k \text{grad}_{\{\tau_k\}} J \quad (8)$$

随后用调整后的 τ_0 计算反向均值。把测试时引导加入轨迹生成有三个好处：一是无需大量前向传播即可更好捕获目标分布；二是可以考虑新具身形态和未见物体几何，生成无碰撞手部轨迹，便于下游全身规划；三是每条轨迹的最终代价值 J 可作为智能体选择最优交互计划的信息性标准。

3.3.4 可供性模型训练

训练粗可供性模型时，作者将抽取到的目标点和接触点投影到图像平面，并通过拟合高斯混合模型得到目标点和接触点的真实概率热图。目标深度也由目标点预测器回归，为目标点深度的中位数。训练中还包含辅助向量场回归损失。目标预测损失为：

$$L_g = \text{BCE}(\hat{G}, H_g) + \lambda_d \|D^{\hat{g}} - D_g\|_2^2 + \lambda_v L_v \quad (9)$$

接触预测损失为：

$$L_c = \text{BCE}(\hat{C}, H_c) + \lambda_v L_v \quad (10)$$

细可供性模型通过监督其输出的无噪轨迹来训练：

$$L_f = E_{\{\epsilon, k\}}[||\tau^k - \tau_{\text{bar}_0}||_2^2] \quad (11)$$

其中 k 为扩散步索引， ϵ 为用于污染真实轨迹并得到输入 τ_k 的高斯噪声。

图 3

图 3 给出可供性学习模型总览。模型分为粗阶段和细阶段。粗阶段从任务输入中解析高层接触和目标配置；补充材料提供了条件特征抽取过程的更详细图示。细阶段利用粗阶段输出，通过条件输入和代价函数引导细粒度交互轨迹生成。图中颜色表示最终代价值，颜色越深表示代价越低。

4. 实验

作者希望展示该可供性模型的四个方面：第一，它在零样本机器人操作任务中显著优于多个强基线；第二，粗可供性预测和测试时代价引导对最佳性能都很关键；第三，它能增强若干下游机器人学习应用；第四，它可以无缝部署到真实机器人系统。

4.1 实验设置

仿真环境。 作者使用 IsaacGym 作为仿真平台，环境基于已有工作开发。从三个常用基准 FrankaKitchen、PartManip 和 ManiSkill 中选取 13 个日常家庭任务。这些任务覆盖打开、推动、滑动等动作原语，以及柜子、抽屉、水壶等多种物体。每个任务从三个不同视角评估；每个模型为每个视角生成五条轨迹，因此每个任务每个模型共 15 次试验。评估指标为已有工作常用的成功率：成功交互定义为使任务物体的自由度超过预设阈值，且不与场景中其他物体碰撞。

基线模型。 作者比较了多个公开可用的代表性基线。GAPartNet 和 Where2Act 使用仿真器中收集并交互过的虚拟关节资产训练。Octo 在大规模遥操作数据集上预训练，并用作者收集的数据微调。VRB、GFlow 和本文模型使用人类视频训练；其中 GFlow 可以访问真实深度、相机参数和物体位姿，因此 VRB 和本文方法处在更野外的设置中。作者按照已有策略，将 VRB 的像素级轨迹借助物体法向聚类提升到三维。由于 VRB 和 GFlow 等基线无法准确推断接触区域，为公平比较，作者统一使用本文模型推断接触配置；因此基准主要聚焦于预测更具挑战性的准确交互轨迹。

4.2 结果与讨论

表 1 显示，本文模型在全部任务上获得最佳总体性能，平均成功率 88.2%，比第二名高近 20%。在基线中，VRB、GAPartNet 和 Where2Act 表现较弱。作者认为这是因为它们将交互策略抽象为方向向量；这种方式在直线拉出或推动抽屉等简单任务上尚可，但在打开柜门这类需要曲线交互的任务中表现困难，过度简化的运动容易导致夹爪打滑并失败。Octo 比这些模型提高约 10%，达到第二高成功率 69.2%。这符合预期，因为 Octo 在大规模遥操作数据集上预训练，并在本文抽取数据上微调后具有较好泛化能力。但从场景上下文直接推断复杂动作仍有挑战，导致其性能低于本文方法。GFlow 受轨迹尺度预测错误影响，性能下降。

这些结果表明：只要能够捕获三维交互伪标签，野外人类视频可以成为向机器人迁移操作技能的强大数据源。然而，场景上下文的差异要求可供性模型同时具备高层上下文理解能力和适应测试时约束的低层动作规划能力。值得注意的是，VRB 与本文方法使用同一视频数据源进行监督，但本文充分利用三维先验并采用提出的可供性学习策略，将任务成功率提升约 30%。图 5 在作者自采真实数据上展示了这种提升。

表 1

表 1 给出仿真中 13 个评估任务的成功率结果。任务包括：T01 关闭铰链柜，T02 关闭滑动柜，T03 关闭微波炉，T04 打开铰链柜，T05 打开微波炉，T06 拉抽屉，T07 推抽屉，T08 关闭洗碗机，T09 打开洗碗机，T10 拿起水壶，T11 从杂物中拿起易拉罐，T12 从杂物中拿起盒子，T13 抬起盖子。平均成功率：GAPartNet 51.1，Where2Act 58.5，Octo 69.2，VRB 59.0，GFlow 61.0，本文方法 88.2。Octo 使用本文抽取的可供性数据微调；VRB 使用已有策略将可供性提升到三维。

4.3 消融研究

表 2 给出了在一组操作任务上的消融实验，用于评估若干重要设计选择的必要性。V1 去掉粗目标预测，因此也没有目标条件和多目标引导 `J_goal`。V2 到 V4 分别去掉多目标引导、接触法向引导和碰撞避免引导。V5 不使用最终引导代价值作为启发式，而是随机选择生成轨迹。

粗可供性预测的影响。在 V1 中，性能从 85.6% 显著下降到 57.8%。这说明直接从信息密集的任务观测中生成细粒度动作很困难。先从高维观测空间推断粗目标配置作为可供性线索，可以简化准确交互轨迹的生成。

代价引导的影响。多目标引导是最关键因素，使总体性能提升 12.3%。单目标条件可能误导生成过程，而通过引导进行多目标条件化，有助于纠正粗阶段累积误差。接触法向引导为动作生成提供直观提示，进一步提高性能。碰撞避免引导也有效，尤其是在可携带物体的抓取任务中，成功率提升 26.7%。这些来自测试时观测的引导项，使轨迹生成在显式约束下更可控，增强了模型在新环境和新具身中的泛化。

代价值启发式的影响。V5 性能下降 11.1%，说明使用最终引导代价值作为选择最优交互计划的直观标准非常重要。

表 2

表 2 给出 6 个选定任务上的消融成功率。完整模型平均 85.6；去掉粗目标预测后为 57.8；去掉多目标引导后为 73.3；去掉接触法向引导后为 76.7；去掉碰撞避免引导后为 77.8；不使用代价值启发式后为 74.5。

图 4

图 4(a) 展示视觉目标到达任务的平均成功率；图 4(b) 展示探索任务中的平均偶然成功率。

4.4 机器人学习应用

沿用已有工作提出的机器人学习范式，作者在消融任务上进行了若干下游应用研究，以展示本文可供性模型作为强先验的通用性。

视觉目标到达。智能体还可以访问目标物体期望配置的图像，以增强策略搜索监督。由于本文可供性模型支持测试时引导，作者在后续 episode 中，当收集到足够有效交互后，会以一定概率用成功轨迹缓冲区中采样的目标点替换 `J_goal` 中使用的预测目标点。图 4(a) 显示，本文方法显著优于其他使用人类视频训练的基线，收敛更快且总体性能更好。

探索。智能体与场景交互时，希望最大化环境变化。作者使用与 VRB 相同的偶然成功指标，即在无法访问期望配置的情况下，将环境带到目标配置的轨迹数量。类似目标到达任务，作者也用先前成功轨迹引导可供性模型采样。图 4(b) 显示，本文方法相比其他基线持续显著提升。

图 5

图 5 比较了在给定 RGB-D 图像和指令时，VRB 与本文方法预测的可供性。虽然两者都使用相同的 RGB-only 人类视频训练，本文框架能直接在三维空间中预测更准确的接触点和交互轨迹，优于 VRB 在像素空间中的歧义预测。图中展示了本文模型推断出的前五个可供性样本，颜色表示最终代价值；颜色越深，代价越低，因而越适合智能体执行。示例指令包括“打开柜子”“拿杯子”“用布擦台面”“关闭洗碗机”“拿纸巾”。

4.5 真实机器人实验

作者在两个真实移动机器人平台上验证框架有效性：Hello Robot Stretch 3 和 Boston Dynamics Spot。两个机器人都配备机载 RGB-D 相机用于感知，并接收语言指令执行操作任务。作者在三个适合人类生活的环境中测试了若干处于机器人物理能力范围内的家庭任务，例如推抽屉、打开柜子、拿纸巾。总体而言，机器人在 55 次试验中达到 80.0% 成功率，说明该框架具有与具身无关的性质和零样本迁移能力。补充材料中提供了额外定量结果。

图 6

图 6 展示真实世界机器人操作任务，上方面板显示推断出的可供性。示例包括“打开柜子”“扔下纸球”“推抽屉”“拿起玩具”。

5. 结论

本文提出 VidBot：一个可扩展且有效的框架，使机器人能够直接从野外 RGB-only 人类视频中学习操作技能。VidBot 展现出显著泛化能力，在仿真零样本设置下，13 个操作任务的成功率比已有方法高 20%。此外，其与具身无关的设计允许跨机器人平台部署，使机器人能够在多个真实环境中成功执行多样家庭任务。它在下游机器人学习应用中的优越表现进一步说明了其通用性。

该框架的一个限制是：尽管作者使用最终优化损失过滤低质量标签，数据质量仍受深度基础模型和 SfM 流水线准确性的约束。由于本文数据抽取流水线与具体方法无关，未来探索近期基于学习的 SfM 框架可能进一步提高标签质量。未来工作中，作者计划使用可穿戴设备抽取多模态可供性数据，使机器人能够学习目前框架仍难处理的高精度任务，例如拧开瓶盖。

致谢

本工作由慕尼黑工业大学 Georg Nemetschek Institute 通过 SPAICR 项目资助，并得到 Google LLC 的礼赠资助。作者感谢 Simon Schaefer、Simon Boche、Yannick Burkhardt、Leonard Freissmuth、Daoyi Gao、Yao Zhong 的校对和富有成效的讨论。

参考文献

参考文献条目按原 PDF 保留，避免误改作者名、题名和出处。PDF 中列出了 97 条参考文献，覆盖条件生成决策、从人类视频模仿、可供性学习、深度估计、SfM、扩散模型、机器人操作基准和大规模机器人数据集等相关工作。