

VITRA：利用真实人类活动视频，可扩展地预训练机器人操作视觉—语言—动作模型

原文：Scalable Vision-Language-Action Model Pretraining for Robotic Manipulation with Real-Life Human Activity Videos

作者：Qixiu Li、Yu Deng、Yaobo Liang、Lin Luo 等（清华大学、Microsoft Research Asia）

项目主页：<https://microsoft.github.io/VITRA/>

说明：项目名为 VITRA。译文以顺畅阅读为主，完整保留方法、公式、主要实验与附录中的关键实现信息；图片以文字标注。

摘要

本文提出一种从大量、无脚本的真实人类手部活动视频中预训练机器人操作 VLA 的方法。作者把人手看作灵巧机器人的末端执行器，并证明：**完全没有人工动作标注的野外第一视角视频，也可以自动转换成与现有机器人 VLA 数据在任务粒度和标签形式上对齐的数据。**

为此，论文设计了一套完整的人类活动分析流水线。它能从任意手部视频中生成原子级动作片段及语言描述，并为每一帧恢复三维手部运动和相机运动。作者处理多个第一视角视频数据集，得到 **100 万条 episode、2600 万帧** 的手部 VLA 数据，覆盖的物体、概念、灵巧技能和真实环境变化远多于现有机器人数据。

随后，作者设计灵巧手 VLA，在这批数据上预训练。模型对从未见过的真实图像表现出很强的零样本手部动作预测能力；再用少量真实机器人数据微调，任务成功率和对新物体的泛化都会显著提高。性能还会随预训练数据规模稳定增长。

【图 1：从无结构人类视频自动构造一百万条原子 VLA episode；预训练模型在完全未见环境中零样本预测人手动作，再以少量机器人数据微调，执行抓取、放置、功能性抓握、倾倒和扫拢等任务。】

1. 引言

大模型获得常识与跨领域泛化的关键，是在大规模通用数据上预训练。语言模型和视觉—语言模型已经验证了这条路线，但灵巧机器人 VLA 的预训练仍不成熟。

机器人 VLA 数据通常通过实验室遥操作采集，成本很高，技能、物体和场景都有限。灵巧手数据尤其稀缺，目前几乎没有适合大规模预训练的真实灵巧手动作集。与之相反，互联网上的人类活动视频数量巨大，手部操作天然灵巧，内容也覆盖真实世界的长尾变化。

难点在于，普通视频既没有机器人式动作标签，也不是短小清楚的原子任务；第一视角相机还会运动，焦距、畸变和尺度各不相同。以往方法多把人类视频用于视觉表示、奖励、可供性或潜动作学习，没有把它完整转换成机器人 VLA 常用的“图像 + 指令 + 逐帧三维动作块”格式。

本文的路线是先自动重建三维手和相机，再依据手腕速度把长视频切成原子动作，最后让 GPT-4.1 结合图像和叠加轨迹生成精确命令。得到的数据与机器人数据在结构上同构，因而显著减小预训练和机器人微调之间的差距。

2. 相关工作

2.1 机器人 VLA 与预训练数据

RT 系列、OpenVLA、 $\pi 0$ 、Octo 等模型主要依赖 Open X-Embodiment、DROID、AgiBot 等机器人演示。这些数据价值很高，但规模、视觉多样性和灵巧度仍有限，不同机器人子数据集之间还容易产生“走捷径”：模型识别出某个实验室或机器人外观后，只调用对应动作分布。

2.2 从人类视频学习机器人能力

已有研究会学习通用视觉表示、手—物接触、可供性、奖励、世界模型、轨迹先验或潜动作。隐式表征不要求精确三维恢复，但也可能把背景变化混入动作表示；当下游环境改变时，这种纠缠会伤害泛化。本文选择更直接的显式三维动作监督。

2.3 三维手部与相机恢复

MANO 用参数化网格表示手形和关节；HaWoR、HaMeR 等方法可从单目图像恢复手部；DROID-SLAM、MegaSAM、MoGe 等方法估计相机运动与尺度。VITRA 把这些组件组合成可扩展流水线，并重点解决相机内参、动态相机、原子分段和语言对齐。

3. 把人类手部视频转成 VLA 数据

典型机器人 VLA episode 包含一条短指令、一段视频，以及与每帧对齐的未来三维动作块。VITRA 把两只人手当成两个末端执行器，依次完成三维运动标注、原子动作分段和指令标注。

【图 2：完整数据构建流程。左：估计视场角、相机位姿和三维手；中：在世界坐标中按手腕速度极小值切分原子动作；右：采样帧并叠加未来手轨迹，让 GPT 输出祈使句指令。】

3.1 三维运动标注

系统先根据背景光流判断相机是静止还是运动。运动相机使用 DroidCalib 估计内参；静态相机结合 MoGe-2 和 DeepCalib。畸变较大的视频先校正到针孔相机模型。

随后用 HaWoR 逐帧恢复相机坐标中的三维双手。每只手包含手腕六自由度位姿，以及 MANO 表示的关节角。运动相机的轨迹由修改版 MegaSAM 估计，作者以 MoGe-2 提供尺度更可靠的深度先验。把相机坐标手姿和米制相机位姿结合后，就得到世界坐标中的手部轨迹；再用样条平滑并去除异常点。

世界坐标轨迹可以重新投到任意一帧相机坐标，相当于把移动第一视角相机转换成机器人数据中常见的静态观察相机。为提高效率，长视频先切成相互重叠的 20 秒片段，分别处理后再拼回。

3.2 原子动作分段

固定时长切片经常把多个动作塞在一起，也会把一个动作从中间切断。作者利用人动作的自然“节拍”：从一个动作切换到另一个动作时，手通常会减速，速度极小值往往就是边界。

系统平滑世界坐标手腕轨迹，在固定时间窗中检测局部速度极小值，并把它们当作切点。左右手独立分段，不受另一只手影响，因此每段至少包含一只手的单一原子动作。来回擦拭可能被过度切分，但在得到语言标签后可以合并。

这个算法不需要额外神经网络推理或预先文本标注，适合大规模处理。

3.3 指令标注

每个片段均匀采样 8 帧。系统把当前帧到片段结束时的掌心三维轨迹投影到每张图上，让 GPT-4.1 同时看到场景内容和清楚的运动方向。提示词要求模型只描述指定手的动作，使用祈使句，并在没有明确语义动作时输出 N/A。

原子片段能降低 GPT 的推理难度；叠加轨迹则能消除静态帧中“正在拿起”还是“正在放下”等歧义。后续消融证明，这两项都明显改善最终 VLA。

3.4 数据集

原始视频来自 Ego4D、EPIC-KITCHENS、EgoExo4D 和 Something-Something-V2。作者没有使用这些数据集原有动作标注，因为其粒度和起止时间往往不符合 VLA 要求。

最终数据包含 100 万条 episode、2600 万帧：

来源	比例
Ego4D	77%
EPIC-KITCHENS	12%
EgoExo4D	6%
Something-Something-V2	5%

内容覆盖烹饪、清洁、施工、维修、手工和绘画等活动。

4. 灵巧手 VLA

模型策略写成：

$$\pi : (l, o_t, s_t) \rightarrow (a_t, a_{t+1}, \dots, a_{t+N}),$$

其中 l 为语言指令， o_t 为当前图像， s_t 为手或机器人的本体状态，输出未来动作块。

4.1 架构

VLM 骨干是 PaliGemma-2 3B：SigLIP 视觉编码器、线性视觉投影和 Gemma-2 语言模型，默认输入分辨率为 224²。相机视场角作为额外 token 输入，帮助模型解释宽高比和内参。末尾再加一个可学习的“认知 token”，其输出特征 f^c 用作动作专家条件。

动作专家是 DiT-Base。输入包含认知特征、当前手状态和带噪未来动作块；认知特征还通过 AdaLN 注入各层。动作专家预测扩散噪声：

$$\mathcal{L}_{MSE} = \mathbb{E}_{\epsilon \sim \mathcal{N}(0,1), i} \|\hat{\epsilon}_i - \epsilon\|^2.$$

动作专家、VLM 和认知 token 端到端训练，视觉编码器保持冻结。

【图 3：图像、左右手指令和 FoV 输入 VLM；认知 token 汇总多模态信息；DiT 同时读取手状态、带噪动作和有效掩码，迭代去噪未来动作块。】

4.2 手部动作空间

每一步动作在当前图像的相机坐标系中表示：

$$a_t = [\Delta t^l, \Delta r^l, \theta_h^l, \Delta t^r, \Delta r^r, \theta_h^r] \in \mathbb{R}^{102}.$$

$\Delta t \in \mathbb{R}^3$ 和 $\Delta r \in \mathbb{R}^3$ 是相邻帧手腕的相对平移与欧拉角旋转， $\theta_h \in \mathbb{R}^{15 \times 3}$ 是 MANO 的 15 个局部关节角。相对动作减少了不同相机和场景的绝对坐标差异。

4.3 统一单双手预测

语言输入始终写成：

Left hand: <左手动作或 None>.
Right hand: <右手动作或 None>.

动作专家始终接收双手动作。某只手没有标签时，相应动作置零、掩码设为 0，并排除出损失。这样单手片段、重叠双手片段和真正双手任务能用同一模型训练。

4.4 因果动作去噪

许多人类原子动作只有约 1 秒、30 帧，而预测块长度为 $N = 16$ 时很容易越过 episode 末尾。如果直接补零，双向注意力会让未来补零位置影响前面的有效动作，使模型误以为动作应提前停下。

作者因此在 DiT 中使用因果注意力：每个动作步只能关注之前的动作；补零位置同时由掩码排除。擦拭等动作即使片段在中途结束，早期预测也不会受到“结尾静止”的错误暗示。

4.5 人手数据预训练

训练使用轨迹感知增强。图像随机裁剪、改变宽高比和 FoV、做透视变换，同时按新相机参数同步变换三维动作；裁剪时确保从当前帧到 episode 末尾的手轨迹仍留在图中，因此交互物体通常也不会被裁掉。还会随机翻转，并同步交换左右手动作与语言；只有指令不含明确颜色时才做颜色抖动。

4.6 微调到机器人灵巧手

作者把人手动作空间看作机器人手动作空间的超集。机器人末端六自由度位姿用来计算 Δt 和 Δr ；每个机器人手指关节映射到拓扑上最近的人手关节，无法对应的 MANO 维度由动作掩码置零。

关节监督采用未来真正要执行的命令，而不是由记录状态差分出的标签，这会在手—物接触时产生更合理的动作。语言格式与人手预训练完全一致。这里不是把人姿态直接重定向给机器人，而是让微调学习形态差异。

5. 实验

5.1 训练设置

预训练先用 5000 步热身动作专家、认知 token 映射层和 FoV 投影 MLP；随后联合微调 VLM 与动作专家 8 万步。动作专家和 VLM 学习率分别为 10^{-4} 、 10^{-5} ，batch size 512。在 8 张 NVIDIA H100 上约需 2 天。

机器人微调 2 万步，batch size 256，学习率 10^{-5} ，8 张 H100 上约 8 小时。

5.2 数据多样性

视觉多样性以 OpenImages 为参照：从 OpenImages 随机取 8000 张查询图，用 DINOv2 提取特征，再计算每个查询与目标 VLA 数据最近图像的余弦相似度。VITRA 数据对自然场景的覆盖高于 EgoDex、Open X-Embodiment、DROID 和 AgiBot；只取 1 万条 episode 时，视觉多样性也已超过这些数据集。

语言多样性由 GPT-4.1 分别提取指令中的名词、动词和形容词，再统计词汇频次、h-index 与 i100-index。VITRA 在三类词汇上都包含更多高频而不同的词，说明多样性不是只靠大量低频噪声堆出来的。

【图 4：各 VLA 数据集与 OpenImages 的视觉相似度曲线及 t-SNE。图 5：名词、动词、形容词的频率—词汇量曲线。】

5.3 零样本人手动作预测

抓取基准

作者用 Azure Kinect 在 47 个未见环境中采集 RGB-D，标注 396 个物体及其三维点云，并在适合单个动作块抓取的位置渲染虚拟人手。指标是预测手指轨迹到目标物体点云的最小距离 $d_{hand-obj}$ 。

完整模型的平均/中位距离为 **8.8/6.2 cm**；初始手到物体为 20/20 cm。Being-H0-8B 为 19.1/18.4 cm，实验室 EgoDex 预训练为 17.6/18.3 cm。去掉增强后为 11.6/10.7 cm，改为双向去噪注意力后为 9.3/7.2 cm。

一般动作基准

作者在 117 个手机拍摄的新环境中渲染预测动作，请 23 名参与者为随机 30 个场景选前三名动作，依次给 3、2、1 分。完整模型平均 **1.91 分**；原始人工视频标注训练为 0.96，无增强为 1.43，双向注意力为 1.69，Being-H0-8B 为 0.15。

episode 构造消融

在同样的 35 万条 Ego4D 子集上：固定 1 秒切片得到 10.5/8.8 cm；不给 GPT 叠加轨迹得到 11.7/10.7 cm；完整原子分段与轨迹提示为 **9.9/8.1 cm**。这说明三维轨迹不仅是动作标签，也能帮助构造更准确的语言监督。

数据从 1%、10%、20%、50% 增到 100% 时，手—物距离在对数数据尺度上近似线性下降。EgoDex 即使 episode 和帧数更多，也落后于 VITRA 的小子集，说明多样性比单一实验室内的重复规模更关键。

5.4 真实机器人灵巧操作

平台为 Realman 机械臂、12 自由度 XHand 灵巧手和 RealSense 头部相机。遥操作设备由与机械臂拓扑匹配的主臂和 MANUS 手套组成。

作者采集 1200 条轨迹，覆盖四类任务：

1. 通用抓放：在 3~4 个干扰物中选择目标并放进盒子；
2. 功能性抓握：抓住把手等适合使用的位置；

- 3. 倾倒：拿起瓶子、倒入另一容器，再放回桌面；
- 4. 扫拢：从篮中拿扫帚，把垃圾扫进簸箕，再放回扫帚。

测试分为已见物体与背景、新物体与新背景，以及训练时从未出现过的物体类别。

已见条件成功率

方法	抓放	功能抓握	倾倒	扫拢	平均
VPP	57.5	29.2	12.5	0.0	24.8
$\pi 0$	37.5	25.0	75.0	50.0	46.9
无 VLA 预训练	32.5	33.3	12.5	50.0	32.1
潜动作预训练	42.5	41.7	37.5	62.5	46.0
OXE 预训练	40.0	37.5	62.5	25.0	41.3
VITRA	80.0	66.7	75.0	62.5	71.0

未见条件成功率

方法	新物体抓放	新物体功能抓握	新物体倾倒	新类别抓放	平均
VPP	12.5	0.0	0.0	8.3	5.2
$\pi 0$	0.0	6.2	25.0	33.3	16.1
无 VLA 预训练	31.2	0.0	0.0	12.5	10.9
潜动作预训练	0.0	0.0	0.0	0.0	0.0
OXE 预训练	12.5	6.3	0.0	12.5	7.8
VITRA	68.8	68.8	50.0	70.8	64.6

VPP 的视频生成监督较隐式，难以迁移为精确动作； $\pi 0$ 虽在大量机器人数据上训练，但知识主要来自夹爪，迁移到灵巧手并不充分。OXE 的场景和机器人子集差异容易诱发捷径。潜动作在已见任务尚可，却在未见环境完全失败，说明它把背景与真正动作混在了一起。显式三维动作监督在预训练和微调之间建立了更直接的接口。

EgoDex 有约 1.3 亿帧，远多于 VITRA 10% 子集的 260 万帧，却表现更差并在新场景完全失败，再次表明真实环境覆盖的重要性。随着 VITRA 数据从 10%、20%、50% 增到 100%，机器人已见和未见任务成功率都持续提高。

人手预测基准的手—物距离与机器人微调后的抓放成功率呈清楚相关性。因此这个零样人手基准可以作为机器人性能的廉价代理，用于快速筛选数据配方和预训练模型。

【图 8: Realman、XHand、MANO 关节映射与遥操作系统。图 9: 训练物体/背景和新物体/新背景。图 10: 机器人成功率的数据缩放曲线，以及人手预测精度与机器人性能的相关性。】

6. 讨论与未来工作

当前数据主要来自现成第一视角数据集，但自动流水线可以继续扩展到 HowTo100M 等更大视频源。三维重建和 VLM 标注仍有误差，未来可用更强恢复模型和过滤器清除噪声。

目前数据和模型集中于短时原子技能；若把原子片段进一步组织成层级任务，就能学习长时程规划和推理。机器人实验也主要是单手，但数据格式和模型原生支持双手，论文用简单的双手递交实验验证了可行性。多视角视觉和触觉反馈也是自然扩展方向。

7. 结论

VITRA 展示了一条可扩展路线：从无脚本、无动作标注的人类视频恢复三维手和相机，以运动节拍切出原子技能，再借助轨迹可视化生成准确语言标签，使最终数据与机器人 VLA 格式直接对齐。

一百万条 episode 带来的价值不只在“数量大”，更在于真实场景、物体、语言和技能的覆盖。模型能在新环境中零样本预测合理手部动作，经过少量机器人数据微调后，在未见物体、背景乃至类别上都大幅领先基线。实验说明，人类活动视频可以从一种松散的视觉资源，转化为带显式三维动作监督的机器人预训练数据。

致谢

作者感谢 Mozheng Liao、Guanghao Wang 和 Bo Liang 协助搭建硬件，感谢 Lidong Zhou 对分析实验的建议，以及 Yunze Liu、Ruicheng Wang、Fangyun Wei、Yichao Shen、Jianmin Bao 对改进工作的讨论。