# RMA：足式机器人的快速运动适应

原文：**RMA: Rapid Motor Adaptation for Legged Robots**
作者：Ashish Kumar（加州大学伯克利分校）、Zipeng Fu（卡内基梅隆大学）、Deepak Pathak（卡内基梅隆大学）、Jitendra Malik（加州大学伯克利分校、Facebook）。
版本：arXiv:2107.04034v1，2021 年 7 月 8 日。
项目与视频：https://ashish-kmr.github.io/rma-legged-robots/

> 本译文覆盖摘要、正文 I–VI 及致谢。按要求不翻译文后的补充材料；参考文献条目参见原 PDF，正文引用编号保留。图片以位置标注和中文说明代替。文中 extrinsics 指影响运动的环境因素潜在编码，下文称“环境潜变量”，并非相机外参。原文若有数值或表述不一致，另加译注。

**【图 1，论文首页：复杂自然环境中的 RMA】** 展示机器人在沙地、泥地、徒步小径、高草和土堆中行走，所有测试均无失败。沿徒步小径下台阶的成功率为 70%，穿越水泥堆和卵石堆为 80%。训练中没有见过不稳定或会下陷的地面、阻挡腿部的植被、楼梯等情况。所有部署都使用同一策略，没有针对真实环境标定仿真器，也没有真实世界微调。

## 摘要

要让足式机器人成功部署到真实世界，它必须实时适应从未见过的情况，例如地形变化、负载变化以及机械磨损。本文提出快速运动适应算法 RMA，解决四足机器人实时在线适应的问题。

RMA 包含基础策略和适应模块，两者结合使机器人能在不到一秒的时间尺度内适应新情况。RMA 完全在仿真中训练，不使用参考轨迹或预定义足部轨迹生成器等领域知识，部署到 A1 机器人时无需微调。

我们在多样地形生成器中，以生物能量学启发的奖励训练 RMA，再部署到多种困难地形，包括岩石、湿滑及可变形表面，以及草地、高植被、水泥、卵石、台阶、沙地等。RMA 在多样真实实验与仿真实验中表现达到当时先进水平。演示视频见项目网站。

## I 引言

过去四十年，足式机器人通过物理动力学建模和控制理论工具取得重大进展 [36,43,46,16,56,63,50,26,28,2,24]。这些方法要求设计者具备大量专业知识。近年来，研究者希望用强化学习和模仿学习复现这些成果 [23,18,41,55,32]，以减轻人工负担，甚至提高性能。

标准做法是在物理仿真中训练强化学习控制器，再通过仿真到现实迁移技术部署到真实世界 [52,40,23]。迁移很困难，因为差距来自多个方面：真实机器人与仿真模型明显不同；真实地形与仿真地形差异很大；仿真器无法准确刻画接触力、可变形表面等物理过程，这比模拟刚体在自由空间运动困难得多。

本文以相对便宜的宇树 A1 四足机器人为实验平台，研究如何解决这一挑战。人类行走时，会迅速适应不同土质、上坡下坡、携带负载、肌肉疲劳，甚至脚踝扭伤。我们把这种能力视为足式机器人的核心问题，称为快速运动适应 RMA。

我们要求适应在线发生，时间尺度小于一秒。这意味着没有时间在真实世界反复试验、执行多条轨迹，再通过优化估计系统参数。问题甚至更严重：若机器人毫无经验地进入岩石地面，策略可能频繁失败，造成硬件损伤。因此，即使为了适应而采集 3–5 分钟行走数据，也可能不可行。我们的方案要求基础行走策略和适应能力都在仿真中学习，然后直接部署。

如图 2，RMA 有两个子系统：基础策略 $\pi$ 与适应模块 $\phi$，协同实现对多样环境配置的在线实时适应。首先，基础策略在仿真中通过强化学习训练，可以访问摩擦、负载等特权环境配置 $e_t$。知道这些信息，就能根据环境调整行为。环境因素编码器 $\mu$ 将 $e_t$ 映射为潜在特征 $z_t$，即环境潜变量；基础策略接收 $z_t$、当前状态 $x_t$ 和上一动作 $a_{t-1}$，输出目标关节位置 $a_t$。策略与环境编码器在仿真中联合强化学习。

这一策略无法直接部署，因为真实世界没有 $e_t$ 的真值。适应模块 $\phi$ 因而负责运行时估计 $z_t$。关键观察是：给关节发出某个运动指令后，实际运动与期望的差异取决于环境因素。因此，可依据近期状态历史估计环境潜变量，类似卡尔曼滤波依据历史观测估计状态。具体而言，$\phi$ 仅从近期状态和动作推断 $z_t$，不假设能访问 $e_t$。

虽然运行时没有特权信息，但训练时仿真同时提供状态历史和目标 $z_t$，所以可以监督训练适应模块。部署时二者协同实现稳健、自适应的行走。由于机载算力有限，基础策略以 100 Hz 运行，适应模块以 10 Hz 运行；二者异步并行，没有中央时钟对齐。基础策略直接读取适应模块最新预测的潜变量来输出动作。

这与一些先在每个新环境采集小数据集，再推断关键物理参数 [7] 或潜在编码 [41] 来适应策略的方法不同。尚不具备良好行走能力时采集数据，可能导致摔倒与损坏。RMA 则通过快速估计潜变量，使策略及时适应并避免跌倒。RMA 用时不到 1 秒，而 Peng 等 [41] 需要约 4–8 分钟数据，即 50 个各 5–10 秒的回合。

把环境参数作为额外输入训练强化学习策略，也见于 [57,41]。我们的不同之处包括多样地形生成器，以及生物能量学启发的“自然”奖励，使行走策略无需参考示范 [41]。不过，本文最主要的新贡献是在仿真中训练、使 RMA 成为可能的适应模块。部署时，它类似系统辨识，但仅依据过去不足一秒内的一条轨迹在线完成。

为什么这可能奏效？我们提出几种解释：

- 系统辨识通常被视为优化问题。但若已有优化问题输入与解的样本，可以训练神经网络近似从问题到解的映射 [1,17]；$\phi$ 实质上就在学习这种映射。

- 不需要完美辨识系统。$z_t$ 是环境参数的低维非线性投影，能缓解多个参数共同变化却产生相同观测效果的可辨识性问题。它也不必在某种真值意义上完全正确，只要导向正确动作即可，端到端训练正是在优化这一点。
- 训练情境应覆盖真实部署情况。分形地形生成器结合质量、摩擦等参数随机化，创造大量机器人必须应对的物理情境。

真实足式运动强化学习中，性能最接近的是 Lee 等 [32]，但该方法依赖人工设定的轨迹生成器 [25] 和电机模型 [23]。我们在大量真实地形评估 RMA，它能在湿滑地面、不平地面、泡沫和床垫等可变形表面，以及草丛、高植被、水泥、卵石、岩石和沙地等自然环境行走。

**【图 2，第 2 页：训练与异步部署】** 第一阶段，环境编码器把质量、质心、摩擦、地形高度、电机强度等特权信息编码为 $z_t$，基础策略结合当前状态及上一动作输出关节位置，并通过无模型强化学习联合训练。第二阶段冻结基础策略，用当前策略执行数据监督训练适应模块，让它从状态—动作历史预测 $\hat{z}_t$。部署时不再使用环境真值：适应模块以 10 Hz 更新潜变量，基础策略以 100 Hz 使用最新潜变量输出目标关节位置，再交给 A1 的 PD 控制器转换为力矩。异步设计是低算力 A1 平稳部署的关键。

# II 相关工作

**传统控制方法**。 足式运动通常采用控制方法 [36,43,16,56,50,26,28,2,24,4]。MIT Cheetah 3 [5] 利用正则化模型预测控制和简化动力学实现高速运动与越障 [12]；ANYmal [20] 优化参数化控制器，并依据倒立摆模型规划 [15]。这些方法需要准确动力学、深入机器人知识，以及人工调节步态和行为。控制器优化结合 MPC 能缓解部分问题 [30,8,9]，但仍需大量任务专属特征工程 [11,15,3]。

**足式运动学习**。 较早的工作可追溯至 DARPA Learning Locomotion Program [63,64,44,62,27]。深度强化学习降低了对人工经验的依赖，在仿真中表现良好 [48,33,37,14]，但迁移到现实仍困难 [31,39,6]。直接在真实世界训练是一条路径 [18,55]，不过目前多限于简单设置，扩展到复杂任务需要不安全探索及大量样本。

**仿真到现实强化学习**。 域随机化在广泛环境参数和传感器噪声下训练策略，希望它对该范围鲁棒 [51,52,40,54,38]。但这种方法以最优性换鲁棒性，可能得到过度保守策略 [34]。

另一条路径是提高仿真准确度 [23,51,19]。Tan 等 [51] 用真实电机数据拟合分段线性模型；Hwangbo 等 [23] 用神经网络参数化执行器模型 [23,32]。这些方法需要事先采集机器人数据拟合电机模型，每个新配置都可能要重复。

**系统辨识与适应**。 策略可以通过在线系统辨识，以物理参数为条件，而非忽略它们。真实部署时，可用仿真训练的模块推断参数 [57]，或用进化算法直接优化高回报参数 [58]。精确参数预测往往既困难又不必要，实际性能可能较差，因此可改用低维潜在嵌入 [41,61]。测试时再用真实轨迹，通过策略梯度 [41]、贝叶斯优化 [59] 或随机搜索 [60] 优化潜变量。元学习也能

学习适于快速在线调整的策略初始化 [13]；虽然已在真实机器人展示 [49,10]，仍需多次真实执行才能适应。

# III 快速运动适应

本节依次介绍基础策略、适应模块，以及真实机器人部署，记号与引言一致。

## A 基础策略

基础策略 $\pi$ 输入当前状态 $x_t \in \mathbb{R}^{30}$、上一动作 $a_{t-1} \in \mathbb{R}^{12}$ 与环境潜变量 $z_t \in \mathbb{R}^{8}$，预测下一动作 $a_t$。动作是 12 个关节的目标位置，经过 PD 控制器转为力矩。环境潜变量由编码器 $\mu$ 将环境向量 $e_t \in \mathbb{R}^{17}$ 压缩得到：

$$z_t = \mu(e_t). \tag{1}$$

$$a_t = \pi(x_t, a_{t-1}, z_t). \tag{2}$$

$\mu$ 和 $\pi$ 都是多层感知机，结构见 IV-B。二者通过无模型强化学习端到端联合训练，以最大化期望回报：

$$J(\pi) = \mathbb{E}_{\tau \sim p(\tau|\pi)} \left[ \sum_{t=0}^{T-1} \gamma^t r_t \right].$$

其中 $\tau = \{(x_0, a_0, r_0), (x_1, a_1, r_1), \ldots\}$ 为策略轨迹，$p(\tau \mid \pi)$ 为策略下的轨迹概率。

**通过自然约束形成稳定步态。** 我们不依赖额外人为仿真噪声，而使用以下自然约束。第一，奖励从生物能量约束出发，鼓励减少做功和落地冲击 [42]；这些奖励对形成真实步态至关重要。第二，在不平地形上训练，替代 [23] 中额外的抬脚高度和抗外推奖励。

在这些约束下学习的行走策略，不作任何修改就能迁移到水泥地、木地板等简单真实环境。此前方法往往要先标定仿真 [51,23]，或在真实世界微调 [41]；适应模块则进一步使它应对图 1 的复杂地形。

**强化学习奖励。** 奖励鼓励机器人以最大目标速度 0.35 m/s 前进，并惩罚突兀和低效运动。设 $v$ 为线速度、$\theta$ 为姿态、$\omega$ 为角速度，均在机体基座坐标系表示；$q, \dot{q}, \tau$ 为关节角、关节速度、关节力矩，$f$ 为足端地面反作用力，$v_f$ 为足端速度，$g$ 为二值足端接触向量。每步奖励为下列项目加权之和：

| 项目 | 表达式 | 权重 |
|---|---|---|
| 1. 向前运动 | $\min(v_x^t, 0.35)$ | 20 |
| 2. 侧向移动与旋转 | $-\lVert \mathrm{Vertv}_y^t \rVert^2 - \lVert \omega_{\mathrm{yaw}}^t \rVert^2$ | 21 |

| 项目 | 表达式 | 权重 |
|---|---|---|
| 3. 做功 | $-\left\lvert(\tau^t)^\top(q^t-q^{t-1})\right\rvert$ | 0.002 |
| 4. 地面冲击 | $-\Vert\mathrm{Vertf}^t-f^{t-1}\Vert^2$ | 0.02 |
| 5. 平滑性 | $-\Vert\tau^t-\tau^{t-1}\Vert^2$ | 0.001 |
| 6. 动作幅度 | $-\Vert\mathrm{Verta}^t\Vert^2$ | 0.07 |
| 7. 关节速度 | $-\Vert\dot{q}^t\Vert^2$ | 0.002 |
| 8. 机体姿态 | $-\Vert\theta^t_{\text{roll,pitch}}\Vert^2$ | 1.5 |
| 9. Z 方向加速度（原文名称） | $-\Vert\mathrm{Vertv}^t_z\Vert^2$ | 2.0 |
| 10. 足端滑动 | $-\Vert\operatorname{diag}(g^t)v^t_f\Vert^2$ | 0.8 |

> 译注：第 9 项原文标题为“Z Acceleration”，公式却使用竖直速度 $v_z$，这里分别保留。表内绝对值用数学定界命令表示，含义为做功标量的绝对值。

**训练课程**。 如果直接用上述奖励训练，关节运动惩罚会使机器人学会原地不动。为防止退化，遵循 [23] 的策略：从很小惩罚系数开始，按固定课程逐渐增强。质量、摩擦和电机强度等扰动难度也随训练线性增加。但地形没有难度课程，从一开始就在固定难度的地形分布中随机采样。

# B 适应模块

真实部署无法访问特权环境配置 $e_t$ 及其编码 $z_t$。因此用适应模块 $\phi$，从最近的状态历史 $x_{t-k:t-1}$ 和动作历史 $a_{t-k:t-1}$ 在线估计：

$$\hat{z}_t=\phi(x_{t-k:t-1},a_{t-k:t-1}).$$

实验中 $k=50$，对应 0.5 秒。与典型系统辨识直接预测 $e_t$ 不同，我们预测 $z_t$，只编码针对环境应如何调整行为。

训练只需状态—动作历史和编码器给出的目标 $z_t=\mu(e_t)$，二者在仿真中都可获得，因此监督优化：

$$\mathrm{MSE}(\hat{z}_t,z_t)=\Vert\hat{z}_t-z_t\Vert^2.$$

适应模块采用一维 CNN，捕捉时间相关性，见 IV-B。

一种采集历史的方法，是用真值 $z_t$ 执行已训练基础策略。但这只得到行走顺畅的良好轨迹；用它训练的适应模块，难以应对部署中常见的偏离专家轨迹情况。

我们改用当前策略产生的数据训练 $\phi$，类似 Ross 等 [45]。从随机初始化的适应模块出发，用它预测的 $\hat{z}_t$ 执行基础策略，将所获状态—动作历史与真值 $z_t$ 配对训练，再反复迭代直到收

敛。随机初始化与不完美潜变量预测都会产生探索轨迹，使 RMA 见到足够多的偏离情况，增强真实部署鲁棒性。

## C 异步部署

RMA 完全在仿真训练，直接部署，无需修改或微调。两个子系统以明显不同频率异步运行，所需机载算力较少。适应模块处理 50 步历史，约每 0.1 秒更新一次，即 10 Hz；基础策略以 100 Hz 使用最新 $\hat{z}_t$、当前状态和上一动作生成动作。由于真实环境潜变量变化相对不频繁，异步执行实际不损害表现。

也可以训练直接输入全部状态—动作历史的单体策略，而不拆分模块，但我们发现：它在仿真中产生不自然步态、性能差；在机载计算机只能达到 10 Hz；也缺少使真实部署平稳的异步设计。将变化较慢的环境潜变量与变化较快的机器人状态解耦，正是无需同步或校准两子系统即可部署的基础。

# IV 实验设置

## A 环境细节

**硬件**。 所有真实实验使用宇树 A1，一种相对低成本、中型四足机器人，约重 12 kg。它有 18 个自由度，其中 12 个驱动自由度，每腿 3 个电机。状态来自电机编码器的关节位置与速度、IMU 的横滚和俯仰，以及足端传感器的二值接触信号。部署使用关节位置控制，PD 增益固定为 $K_p = 55, K_d = 0.8$。

**仿真**。 使用 RaiSim [22] 模拟刚体和接触动力学，导入宇树 A1 的 URDF [53]。内置分形地形参数为 octaves=2、lacunarity=2.0、gain=0.25、z-scale=0.27。每回合最多 1000 步；机体高度低于 0.28 m、横滚绝对值超过 0.4 rad，或俯仰超过 0.2 rad 时提前终止。原文报告策略控制频率为 100 Hz，仿真时间步为 0.025 s。

> 译注：100 Hz 对应控制周期 0.01 s，与原文此处的仿真时间步 0.025 s 不相同；正文未解释其调度关系，均按原文保留。

**状态与动作空间**。 30 维状态包括 12 个关节位置、12 个关节速度、机体横滚和俯仰、4 个二值足端接触信号。12 维动作为目标关节角 $a = \hat{q}$，PD 控制器计算：

$$\tau = K_p(\hat{q} - q) + K_d(\hat{\dot{q}} - \dot{q}), \qquad \hat{\dot{q}} = 0.$$

$K_p, K_d$ 为人工指定增益。

**环境变化**。 变化范围见表 I。17 维环境向量包括负载及其在机器人上的位置（合计 3 维，按原文计数）、12 维电机强度、1 维摩擦、1 维局部地形高度。地形整体难度固定，但机器人行

进时局部高度变化。各足下方高度保留到小数点后一位，再取四足最大值作为一个标量，降低对快速、精确地形感知的依赖，使部署时基础策略可异步使用低频更新的估计。

**表 I：环境参数范围**。

| 参数 | 训练范围 | 测试范围 |
|---|---|---|
| 摩擦系数 | [0.05, 4.5] | [0.04, 6.0] |
| $K_p$ | [50, 60] | [45, 65] |
| $K_d$ | [0.4, 0.8] | [0.3, 0.9] |
| 负载（kg） | [0, 6] | [0, 7] |
| 质心（cm，原表单位） | [−0.15, 0.15] | [−0.18, 0.18] |
| 电机强度 | [0.90, 1.10] | [0.88, 1.22] |
| 每步重新采样概率 | 0.004 | 0.01 |

# B 训练细节

**基础策略和环境编码器**。 基础策略是三层 MLP，输入 30 维状态、12 维上一动作和 8 维潜变量，输出 12 维目标关节角，隐藏层维度为 128。环境编码器为三层 MLP，隐藏层为 256、128，将 17 维环境向量编码为 8 维潜变量。

**适应模块**。 首先用两层 MLP 将近期各步状态与动作嵌入为 32 维表示，再用三层一维 CNN 沿时间卷积。各层的“输入通道、输出通道、卷积核、步长”分别为 $(32, 32, 8, 4)$、$(32, 32, 5, 1)$、$(32, 32, 5, 1)$。展平 CNN 输出后，线性投影得到 $\hat{z}_t$。

**基础策略与编码器训练**。 使用 PPO [48] 联合训练 15,000 次迭代，每次批量 80,000，分为 4 个小批次，学习率 $5 \times 10^{-4}$。奖励系数见 III-A。普通桌面计算机加一张 GPU 约需 24 小时，期间模拟约 12 亿步。

**适应模块训练**。 使用当前策略数据监督学习，以 Adam [29] 最小化 MSE。共 1000 次迭代，每次批量 80,000，分 4 个小批次，学习率 $5 \times 10^{-4}$。普通桌面计算机加一张 GPU 约需 3 小时，模拟约 8000 万步。

# V 结果与分析

我们在仿真中与多种基线比较（表 II），在真实室内设置与 A1 出厂控制器比较（图 3），并在大量自然地形中测试（图 1）。演示视频见项目网站。

**基线**。

1. **A1 Controller：** 厂商默认控制器，采用基于力的控制与 MPC。
2. **Robust：** 通过域随机化获得鲁棒性，不输入 $z_t$，在训练范围环境变化下学习稳健基础策略 [52,40]。
3. **Expert：** 仿真中使用真实 $z_t$ 的专家适应策略，可作为 RMA 性能上界。
4. **RMA w/o Adaptation：** 去掉适应模块的基础策略，用于消融。
5. **SysID：** 系统辨识 [57]，直接预测系统参数 $\hat{e}_t$，而不是潜变量 $\hat{z}_t$。
6. **AWR：** 用测试环境真实执行得到的轨迹，通过优势加权回归，离线优化 $\hat{z}_t$ [41]。

学习基线使用相同架构、奖励和其他超参数。

**评价指标**。 包括：摔倒前持续时间除以最长回合时长，归一化到 0–1，记为 TTF；平均向前运动奖励；成功率；行进距离；适应所需探索样本数；施加力矩；作为力矩变化率的平滑性指标；以及地面冲击，细节见原文补充材料。原文列项时两个项目都标为第 7 项，此处按实际内容列出。

# A 室内实验

真实环境只与 A1 默认控制器、无适应模块 RMA 比较，以避免其他方法损坏硬件。每方法通常测试 5 次，报告成功率、TTF 和行进距离；若某方法严重失败，仅运行 2 次即记失败，以减少硬件损伤。

室内设置包括：

- **n kg 负载：** 背负 n kg，行走 300 cm。
- **StepUp-n：** 登上 n cm 台阶。
- **Uneven Foam：** 在中部隆起泡沫上行走 180 cm。
- **Mattress：** 在记忆泡沫床垫上行走 60 cm。
- **StepDown-n：** 走下 n cm 台阶。
- **Incline：** 爬上 6° 斜坡。
- **Oily Surface：** 穿过有油的地面。

上下台阶试验在成功或失败时立即终止，所以只报告成功率，其他指标无实际意义。

RMA 在各设置中成功率较高，某些情况下明显胜过 A1 默认控制器。关闭适应模块使性能显著下降，说明适应是解决这些任务的关键。A1 在不平泡沫、大幅下台阶和较高上台阶时困难，常因不稳定落脚点而失稳。

负载实验中，A1 能承受超过厂商标称 5 kg 的负载，但继续增加时机体逐渐下沉，最终摔倒。RMA 保持机体高度，能以较高成功率携带 12 kg，即自身重量的 100%。无适应 RMA 通常不摔倒，但也不前进。

我们还让足部包裹塑料的机器人穿越油面这一更困难设置，RMA 能成功通过。值得注意的是，去掉适应模块的 RMA 仍能在木地板上行走，不需微调或标定仿真；此前一些方法即使面

对平坦静态环境，也需要仿真标定 [51,23] 或测试时微调 [41]。

**【图 3，第 6 页：真实世界分布外测试及负载分析】** 上方展示不平泡沫、上坡、记忆泡沫床垫、下 15 cm 台阶、上 6 cm 台阶、上 8 cm 台阶。下面按原图内嵌表格完整转写；TTF 和 Distance 是图中报告的归一化值。

| 场景 | 方法 | 成功率（%） | TTF | Distance |
|---|---|---|---|---|
| 不平泡沫 | RMA | 80 | 0.9 | 0.9 |
| 不平泡沫 | 无适应 RMA | 0 | 0.1 | 0.1 |
| 不平泡沫 | A1 | 20 | 0.36 | 0.36 |
| 上坡 | RMA | 100 | 1 | 1 |
| 上坡 | 无适应 RMA | 20 | 1 | 0.6 |
| 上坡 | A1 | 100 | 1 | 1 |
| 床垫 | RMA | 100 | 1 | 1 |
| 床垫 | 无适应 RMA | 0 | 1 | 0.25 |
| 床垫 | A1 | 100 | 1 | 1 |

| 场景 | RMA 成功率（%） | 无适应 RMA（%） | A1（%） |
|---|---|---|---|
| 下 15 cm 台阶 | 100 | 0 | 60 |
| 上 6 cm 台阶 | 100 | 40 | 80 |
| 上 8 cm 台阶 | 60 | 0 | 20 |

图下方为 0、5、8、12 kg 负载下的成功率、TTF、行进距离曲线。RMA 在高负载仍保持较好表现；A1 约从 8 kg 开始下降，12 kg 时明显失败；无适应 RMA 随负载增加难以前进，但较少摔倒。原图没有为曲线各点标注精确数值，因此这里只说明趋势，不猜读数据。

> 译注：图 3 图注称“下 15 cm 台阶成功率 80%，不平泡沫与床垫均 100%”，但内嵌表格分别为下台阶 100%、不平泡沫 80%、床垫 100%。两处不一致，以上表格忠实保留原图数字。图注还写无适应版本在负载超过 8 kg 时不能移动，而下方曲线显示其行进距离在 8 kg 已为零；均不擅自统一。

# B 室外实验

图 1 展示多种复杂室外地形。机器人在沙地、泥地和土面行走时全部试验均成功。这类地形使足部下陷、粘滞，需要动态调整落脚才能稳定。

在高植被或灌木中也达到 100% 成功。这些地形会阻挡足部，使行走周期性失稳；机器人必须抵抗腿足缠绕带来的扰动，有时还要较强劲地穿过障碍。

在徒步小径的楼梯下行中，成功率为 70%。考虑到训练从未见过楼梯，这仍相当可观。建筑废料测试中，沿土堆下坡全部成功，穿越水泥堆与卵石堆为 80%。水泥堆、卵石堆所在地面本身有较大侧向坡度，使横穿更困难。

# C 仿真结果

训练与测试参数范围见表 I。每回合中也会重新采样环境参数，训练概率为每步 0.004，测试为每步 0.01。每种方法以 3 个随机初始化策略、每个 1000 回合取平均。

**表 II：仿真测试结果。** Success 为成功率，TTF 越大越好；Reward 为平均向前奖励，Samples 为适应所需探索样本。力矩、平滑性及冲击指标按原文报告。

| 方法 | Success（%） | TTF | Reward | Distance（m） | Samples | Torque | Smoothness | Ground Impact |
|---|---|---|---|---|---|---|---|---|
| Robust [52,40] | 62.4 | 0.80 | 4.62 | 1.13 | 0 | 527.59 | 122.50 | 4.20 |
| SysID [57] | 56.5 | 0.74 | 4.82 | 1.17 | 0 | 565.85 | 149.75 | 4.03 |
| AWR [41] | 41.7 | 0.65 | 4.17 | 0.95 | 40k | 599.71 | 162.60 | 4.02 |
| 无适应 RMA | 52.1 | 0.75 | 4.72 | 1.15 | 0 | 524.18 | 106.25 | 4.55 |
| RMA | 73.5 | 0.85 | 5.22 | 1.34 | 0 | 500.00 | 92.85 | 4.27 |
| Expert | 76.2 | 0.86 | 5.23 | 1.35 | 0 | 485.07 | 85.56 | 3.90 |

RMA 胜过全部普通基线，仅略低于使用真值环境潜变量的 Expert。环境不断变化，使适应很慢的 AWR 表现较差。Robust 忽略环境潜变量，因而学到保守策略，牺牲性能。SysID 较弱，说明显式估计真实环境参数既困难，也并非取得高性能的必要条件。关闭适应模块也显著降低表现。

# D 适应过程分析

我们分析穿越湿滑表面时的步态、力矩曲线及估计潜变量，见图 4。在地面塑料片上倒油，并给机器人足部包塑料，机器人尝试通过；RMA 成功率为 90%。

取其中一次试验，绘制膝关节力矩、四足接触步态，以及经中值滤波的 $\hat{z}_t$ 第 1、5 维。约在第 2 秒开始打滑，规则运动受到扰动，随后进入适应阶段；潜变量两维发生相应变化，表明模块检测到打滑。

这一检测使机器人恢复并继续走过湿滑区域。适应后，力矩稳定在稍高水平，步态周期大致恢复，但环境潜变量没有回到初值，而是继续表示地面仍然湿滑。更多分析见原文补充材料。

**【图 4，第 7 页：湿滑地面上的在线适应】** 上图以四足接触条带表示步态：F/R 表示前／后，R/L 表示右／左；中图为膝关节力矩，单位 N·m；下图为适应模块预测环境潜变量的第 1、5 维，中值滤波后展示。时间过程分为原始步态、适应和恢复步态。进入油面后潜变量迅速改变；恢复稳定步态后，力矩稍高，潜变量持续反映湿滑条件，而不是回到进入前数值。

# VI 结论

本文提出 RMA，使足式机器人在多种地形中实时适应行走。训练不需要示范，也不需要预定义运动模板。尽管只使用本体感知，机器人仍能下楼梯、穿越岩石。

不过，没有视觉的机器人存在局限。较大扰动，例如下楼梯突然跌落，或多条腿同时被岩石阻挡，有时仍会导致失败。要构建真正可靠的行走机器人，不能只依赖本体感知，还需要机载视觉等外部感知。视觉对远距离、快速运动的引导作用已有充分研究，例如 [35]，这是未来重要方向。

# 致谢

感谢 Jemin Hwangbo 协助搭建仿真平台，Koushil Sreenath 和 Stuart Anderson 在项目中提供有益反馈；也感谢 Claire Tomlin、Shankar Sastry、Chris Atkeson、Aravind Sivakumar、Ilija Radosavovic、Russell Mendonca 对论文提出高质量意见。本研究属于 BAIR–FAIR 合作项目，近期也获得 DARPA Machine Common Sense 项目支持。

# 参考文献与补充材料

正文引用编号对应原 PDF References。英文书目信息参见原文；按要求，不翻译后面的 Supplementary 补充材料。