RoboTwin-Phys：WAM 和 VLA 理解物理世界吗?

原文题目：**RoboTwin-Phys: Do WAMs and VLAs Understand the Physical World?**
作者：Jiaqi Zhang、Feng Ye、Mingjia Yang、Zhihong Chen、Mingkang Xiang、Xinglin Yao、Yanbin Li、Siwei Ma、Chuanmin Jia。
机构：北京大学；北京大学信息技术高等研究院；Memo。
Feng Ye 为项目负责人，Chuanmin Jia 为通讯作者。
版本：arXiv:2609.26292v1，2026 年 9 月 22 日；正文首页日期为 2026 年 9 月 23 日。本文为 Memo 技术报告。

> 阅读说明：本译文覆盖摘要及正文第 1–5 节，保留正文全部表格和图片说明。按要求不翻译附录。正文没有编号公式。文中的 episode 译为“一次任务回合”，rollout 译为“策略执行过程”；WAM 指世界—动作模型，VLA 指视觉—语言—动作模型。正文对附录的引用予以保留，便于对照原 PDF。

摘要

当前机器人操作基准普遍缺少物理条件的多样性。虽然大型仿真基准越来越多地引入物体外观、场景布局和视觉观测变化，但底层物理参数通常保持固定。因此，质量、摩擦和关节动力学变化等真实世界中的重要差异，仍然很少得到测试。

我们提出 RoboTwin-Phys，一个具有多样物理条件的基准，将物理条件多样性作为机器人操作评估的一个显式维度。该基准在物理上合理的范围内，对 13 项物理属性进行连续变化，为评估策略在不同物理运行条件下的表现提供统一设置。

我们还发布超过 5,000 条带有物理参数真值的专家示范，支持物理属性估计、物理条件感知建模，以及以物理条件为输入的策略训练。对代表性 WAM 和 VLA 的评估揭示了明显的鲁棒性差距：在现有视觉与布局随机化设置下仍然有效的模型，面对物理条件变化时，性能可能显著下降。

RoboTwin-Phys 提供基准、数据和评估协议，使研究者能够系统衡量并改善机器人操作面对不同物理条件时的鲁棒性。

【图 1，原文第 2 页：RoboTwin-Phys 总览】 在 RoboTwin 双臂操作平台之上加入 13 项物理变化因素，将评估从视觉多样性扩展到物理多样性。上方展示基准构建思路，以

及改变质量、摩擦和刚度等条件的示意；下方左侧展示单因素扰动，如摩擦、质心、恢复系数和关节阻尼变化；中间展示多个因素共同变化时的成功与失败案例；右侧汇总物体属性、接触属性、阻尼、任务环境和相机配置五组因素。图中强调四个方面：真实物理条件、可组合的单因素与多因素扰动、开放的基准和数据，以及对物理变化的泛化能力。

1 引言

视觉—语言—动作模型（VLA）和世界—动作模型（WAM）正推动机器人学习从独立技能走向通用操作。顺应这一趋势，RoboTwin-2.0 [2] 等大型双臂仿真基准提供标准化任务集合、专家示范和评估协议，使模型训练能够复现，并支持系统性的模型比较。

然而，一种重要的环境差异来源仍然很少被衡量：**物理条件**。现有操作基准通过改变物体外观、场景布局、物体位姿、光照和相机视角，不断增加机器人“看到的内容”的多样性，但底层物理参数往往固定在标称值。

真实世界中，即使其他运行条件看起来相似，这些参数也会自然变化。物体质量随装载情况改变；摩擦取决于材料和表面磨损；制造公差或物体内部装填内容，可能使实际质心（CoM）偏离标称模型；关节阻尼也会随机械磨损而变化。这些因素直接影响接触动力学和操作结果，却很少被明确视为基准多样性的一部分。因此，模型在视觉与布局变化下的表现，并不能单独说明它对支配动作执行的物理属性变化有多鲁棒。

这一缺口带来三个直接后果。

第一，**缺少标准化评估**：现有基准没有系统协议，用于衡量操作性能如何随物理条件变化而改变。

第二，**训练资源有限**：缺少有意覆盖大量操作任务与多样物理条件的大规模数据集，限制了物理条件感知模型和策略的发展。

第三，**缺少物理真值**：如果不知道每个样本对应的实际物理参数，就难以训练、分析或审查那些旨在推断或利用物理条件的模块。

现有关于物理因素的研究，大多基于单独因素和小规模消融。因此，很难刻画多个因素的联合变化，也难以把这些观察转化为可复用的基准和数据资源。

我们提出 RoboTwin-Phys：在 RoboTwin-2.0 的 50 项双臂任务平台上，系统评估物理条件多样性。RoboTwin-Phys 不引入新操作任务，而是在现有任务集合中增加专门的物理变化维度。具体而言，每次任务回合在物理上合理的范围内，对 13 项物理属性进行连续采样，使每个回合对应不同的物理运行条件。

除评估之外，我们还构建超过 5,000 条专家示范的训练集，覆盖由此形成的物理条件分布。数据与官方 RoboTwin 格式完全兼容，同时每个样本都额外标注该回合实际使用的 13 维物理参数真值。

评估时，在环境初始化阶段采样物理属性，为回合设置特定运行条件。之后预先运行专家规划器，验证该采样配置下任务是否可行，确保基准评估的是物理上可实现的条件，而非任意参数扰动。这些设计使 RoboTwin-Phys 不仅适用于鲁棒性评估，也适用于物理属性估计、物理条件感知建模和以物理条件为输入的策略学习。

我们使用该基准，在多样物理条件下评估代表性 WAM 和 VLA。实验发现一致的鲁棒性差距：在原有视觉与布局随机化下仍然有效的模型，一旦物理条件发生变化，性能可能显著下降。这表明物理条件多样性暴露出一种独立的失败维度，而当前基准协议基本无法看到这一维度。因此，机器人学习需要显式建模并评估物理变化。

主要贡献如下：

1. **RoboTwin-Phys 基准**。 在 RoboTwin 2.0 上建立系统性物理条件多样性基准，引入 13 项连续采样的物理属性，并按任务校准其范围。
2. **带物理标注的训练集**。 发布超过 5,000 条专家示范，覆盖多样物理条件，并标注 13 维物理参数真值。数据直接支持物理条件估计、物理条件感知表示学习，以及以物理属性为条件的策略训练。
3. **物理鲁棒性评估**。 提出多样物理条件下评估 WAM 和 VLA 的系统协议，并通过对比实验刻画代表性模型的鲁棒性差距。

2 RoboTwin-Phys 基准

2.1 基准设计

RoboTwin-Phys 将物理条件多样性作为机器人操作评估的新维度。现有基准在视觉外观、场景布局和物体配置多样化方面已取得明显进展，但物理属性通常固定在标称值。RoboTwin-Phys 明确改变这些物理条件，并评估操作策略在由此产生的不同运行环境中是否仍然有效。

基准遵循三条设计原则：

- **物理有效性：** 每个采样条件都应对应物理上可实现的运行环境，而不是对仿真器进行任意扰动。
- **连续多样性：** 在有实际意义的范围内连续改变物理因素，而不是仅设置少数人工挑选的案例。

- **可组合性：** 把物理条件变化作为独立评估维度，既可单独研究，也可与现有视觉、布局变化共同研究。

依照这一设计，每个回合开始执行前，先设置完整的物理条件；随后整个回合保持这些条件不变，为策略提供一致的物理环境。基准允许多个物理因素同时变化，使模型面对更接近真实运行环境的条件组合。

如图 2 所示，RoboTwin-Phys 用 13 项物理属性实现这一设计。大多数任务共享通用物理条件配置；对物理变化敏感的任务则使用专门的可行参数范围，以避免物理上不合理的组合。完整属性范围见原文附录 A。

【图 2，原文第 4 页：13 项物理属性及其分组】 右侧将属性分成五组：物体属性 3 项——质量、质心、几何缩放；接触属性 2 项——摩擦系数、恢复系数；阻尼属性 3 项——物体关节阻尼、机械臂关节阻尼、夹爪阻尼；任务环境 3 项——桌面倾斜、桌面高度、外力；相机配置 2 项——相机距离、相机角度。它们涵盖场景几何、感知配置、质量、材料属性、质量分布及关节特性。左侧雷达图示意不同配置在五组因素上的变化，没有给出可用于数值比较的刻度或具体测量值。

2.2 物理条件采样

13 项物理属性在每个回合内，分别从各自指定的连续范围独立采样。采样在环境初始化时完成，对应策略执行过程中保持数值不变。回合随机种子决定采样过程，使具体物理条件能够复现。

这些属性覆盖相互补充的物理变化来源，包括物体属性、接触属性、阻尼属性、任务环境及相机配置。其范围旨在表示不同物体、材料、机械状态或部署环境中可能出现的合理差异。

物理采样独立于原有视觉与布局随机化。因此，RoboTwin-Phys 支持三种互补的评估方式：只启用物理变化来研究物理鲁棒性；保留原基准的视觉变化；或同时启用两个维度。这种分离使研究者能够区分物理条件鲁棒性，以及传统视觉与场景变化鲁棒性。

2.3 考虑任务约束的物理有效性

同一套全局物理范围不一定适用于所有操作任务。某个物理因素的允许范围，可能取决于任务的几何和操作约束。不考虑这些约束而直接使用全局范围，可能得到数值上能被仿真器接受、却已不再是该任务合理实例的配置。

我们为九项任务设置专用配置，通过实验校准其中敏感物理因素的范围。构建环境时，系统会根据任务自动选择全局配置或其专用配置。

这种考虑任务约束的设计非常重要：它确保基准衡量的是面对物理多样性的鲁棒性，而非面对人为制造的失败案例的鲁棒性。详细任务配置见原文附录 B。

2.4 可行性与基准实例

只有当采样物理条件下的任务仍然可执行时，该条件才会保留为一个基准实例。为验证这一点，我们预先在已设置好条件的环境中运行专家规划器。专家无法成功完成任务的回合，会从评估池中排除。

这一可行性检查确保，模型失败反映的是它应对物理变化的能力，而不是该环境本来就没有有效解。因此，RoboTwin-Phys 在一组物理上有意义、任务上可行的运行条件中评估模型。

发布的专家示范也采用同一原则生成，使基准评估空间与配套训练资源保持一致。

3 数据集

与基准一同发布的 RoboTwin-Phys Training Set v1，是从第 2.2 节定义的物理条件空间中采样得到的大规模专家示范集合。其目的在于，让物理条件直接成为可观测的学习目标，而不是隐藏在仿真器内部的状态。

3.1 数据集构建

训练集包含超过 5,000 个专家回合，覆盖物理条件分布。示范通过既有专家流程生成，每个保留回合在所设物理条件下均能成功完成任务。因此，数据来自有效的物理运行环境，而不是任意仿真器配置。

物理采样与基准定义一致：大多数任务使用全局物理配置，对物理敏感的任务自动使用专用配置。采集时仍可启用原有视觉与布局变化，物理采样则独立于这些因素进行。

3.2 物理真值

每条示范都配有执行时实际使用的物理条件。具体来说，我们提供 13 项物理属性的真值，使环境物理状态能够作为显式监督信号。详细数据格式和组织方式见原文附录 C。

观测、动作与物理条件之间的明确对应关系，支持物理属性估计、物理条件感知表示学习，以及以物理属性为条件的策略训练等下游应用。

总体而言，数据集把物理条件多样性转化为显式、可复用的学习资源，与基准的评估协议作用互为补充。

4 实验

我们在 RoboTwin-Phys 上评估代表性世界—动作模型（WAM）和视觉—语言—动作模型（VLA），研究其对物理条件多样性的鲁棒性。实验回答三个问题：物理条件变化时，当前模型表现如何；这种影响是否跨模型一致；由此产生的失败是否呈现有结构的任务级模式。

4.1 评估设置

我们采用三种环境协议：

- **Clean（无随机化）：** 关闭基准全部随机化，使用标称环境配置。
- **Official Random（官方随机化）：** 启用原有视觉与布局随机化，物理参数仍保持标称值。
- **Physical Random（加入物理随机化）：** 保留原有随机化，再按照 RoboTwin-Phys 协议额外采样 13 项物理属性。

评估五个代表性模型：Fast-WAM [6]、Motus [1]、FACT [5]、π0.5 [3] 和 Galaxea-VLA（G0.5）[4]。

表 1：代表性 WAM 与 VLA 在 RoboTwin-2.0 设置及 RoboTwin-Phys 上的成功率（%）。 Clean 和 Official Random 来自对应公开基准评估报告；Physical Random 由本文作者评估。

模型	Clean	Official Random	Physical Random
Fast-WAM [6]	91.88	91.78	44.24
Motus [1]	88.66	87.02	39.60
FACT [5]	88.40	86.60	39.14
π0.5 [3]	82.74	76.76	31.60
Galaxea-VLA [4]	93.70	92.80	37.82

4.2 总体结果

表 1 汇总三种设置下的表现。

物理条件变化后出现显著性能差距。在 Physical Random 下，Fast-WAM、Motus、FACT、π0.5、Galaxea-VLA 的成功率分别为 44.24%、39.60%、39.14%、31.60%、37.82%。从原有随机环境转向 RoboTwin-Phys 定义的物理多样环境时，全部五个模型都大幅退化。

相比之下，三个 WAM 在 Clean 和 Official Random 之间的差异较小：Fast-WAM 下降 0.10 个百分点，Motus 下降 1.64，FACT 下降 1.80。π0.5 下降更多，为 5.98 个百分点；Galaxea-VLA 下降 0.90 个百分点。

这一结果揭示了不同于传统视觉与布局随机化的鲁棒性维度。模型即使能应对外观和场景配置变化，也可能对支配交互过程的物理条件变化高度敏感。

这一影响同时出现在 WAM 与 VLA 中。尽管模型架构、训练范式存在显著差异，五个模型在 Physical Random 下均明显退化。跨模型类别的一致性表明，RoboTwin-Phys 揭示的挑战并非某一种模型设计特有的问题。

4.3 任务级分析

总体结果掩盖了不同操作任务之间的显著差异。因此，我们分析 Physical Random 下全部 50 项任务的结果，完整逐任务数据见原文附录 D。

不同模型的任务级结果呈现明确结构。一些任务在多样物理条件下始终困难，另一些则在多种架构上保持相对较高成功率。例如，`beat_block_hammer`（用锤子敲击方块）、`move_stapler_pad`（将订书机移到垫子上）、`pick_diverse_bottles`（抓取不同瓶子）、`put_bottles_dustbin`（将瓶子放入垃圾桶），以及部分堆叠、放置任务，在多个模型上成功率显著较低。相比之下，`grab_roller`（抓取滚筒）、`shake_bottle`（摇晃瓶子）、`shake_bottle_horizontally`（水平摇晃瓶子）、`place_container_plate`（将容器放到盘子上）相对鲁棒。

有些任务在各模型上始终具有挑战。比如，三个 WAM 在 `beat_block_hammer`、`pick_diverse_bottles`、`move_stapler_pad`、`place_can_basket`（将罐子放入篮子）、`put_bottles_dustbin` 上成功率均较低，而抓取滚筒、摇晃瓶子、水平摇晃瓶子和将容器放到盘子上等任务相对稳定。

> 译注：原文以上两段内容较为重复，分别描述跨模型总体趋势和三个 WAM 的共同趋势，此处保留。

这种共享的任务级结构表明，基准并非简单制造随机失败。相反，物理条件多样性会系统性地考验特定操作行为，尤其是依赖接触动力学、物体稳定性、质量分布或关节运动

的行为。

4.4 讨论

实验得到两点主要观察。第一，物理条件多样性对当前 WAM 和 VLA 在广泛操作任务中的表现构成明显挑战。第二，不同 WAM 的任务级性能高度一致，说明这一挑战具有结构性且可复现，并非孤立的模型专属失败。

这些观察也凸显配套物理标注的价值。基准确定模型在哪些地方失败后，物理条件真值为研究失败原因提供依据，例如判断失败是否来自质量、摩擦、质量分布、感知配置或关节动力学的变化。

总体而言，结果支持把物理条件多样性作为机器人操作中独立且必要的评估维度，并确立 RoboTwin-Phys 作为研究物理条件感知、条件感知建模及自适应机器人控制的实验平台。

5 结论

我们提出 RoboTwin-Phys，将物理条件多样性作为机器人操作评估的显式维度。通过在物理合理、考虑任务约束的范围内连续改变 13 项物理属性，RoboTwin-Phys 为评估策略在不同物理运行条件下的表现提供系统设置。

配套训练集包含超过 5,000 条专家示范，每个回合均附有物理参数真值，为物理条件估计和条件感知策略学习提供可复用资源。

对代表性 WAM 与 VLA 的评估显示，面对传统视觉和布局随机化的鲁棒性，并不必然延伸到多样物理条件。物理变化导致的显著性能退化，暴露出一种现有基准基本没有测量的独立鲁棒性维度。

我们希望 RoboTwin-Phys 能成为更全面评估具身模型的基础，并推动未来模型显式感知、推理和适应不断变化的物理条件。

按要求，本译文到正文结束，不包含原 PDF 第 8 页开始的附录 A–D。正文引用编号沿用原文，英文参考文献条目请参见原 PDF。