V-JEPA 2：自监督视频模型实现理解、预测与规划

原文：**V-JEPA 2: Self-Supervised Video Models Enable Understanding, Prediction and Planning**
作者：Mahmoud Assran、Adrien Bardes、David Fan、Quentin Garrido、Russell Howes、Mojtaba Komeili、Matthew Muckley、Ammar Rizvi、Claire Roberts、Koustuv Sinha、Artem Zholus、Sergio Arnaud、Abha Gejji、Ada Martin、Francois Robert Hogan、Daniel Dugas、Piotr Bojanowski、Vasil Khalidov、Patrick Labatut、Francisco Massa、Marc Szafraniec、Kapil Krishnakumar、Yong Li、Xiaodong Ma、Sarath Chandar、Franziska Meier、Yann LeCun、Michael Rabbat、Nicolas Ballas。
机构：Meta FAIR；Mila—魁北克人工智能研究所、蒙特利尔理工学院。
版本：arXiv:2506.09985v1，arXiv 标注日期为 2025 年 6 月 11 日，正文首页日期为 2025 年 6 月 13 日。
通讯作者：Nicolas Ballas、Michael Rabbat。
代码：https://github.com/facebookresearch/vjepa2

> 阅读说明：本文件翻译摘要、正文第 1–9 节及致谢，不翻译附录；参考文献书目信息请参见原 PDF。图片以位置标注和中文解释代替。文中“无标签机器人视频”指不使用任务、奖励或成功与否等标签，仍使用与视频同步的机器人末端状态，并据此构造动作；不应理解为完全没有动作相关信息。实验中的“零样本”指不使用部署实验室的数据进行额外训练。

摘要

现代人工智能面临的一项重大挑战，是主要通过观察来学习理解世界，并学会在世界中行动（LeCun，2022）。本文探索一种自监督方法，把互联网规模的视频数据与少量交互数据，也就是机器人轨迹，结合起来，构建能够理解、预测并在物理世界中进行规划的模型。

首先，我们在一个包含超过 100 万小时互联网视频的视频与图像数据集上，预训练不以动作为条件的联合嵌入预测架构 V-JEPA 2。V-JEPA 2 在运动理解方面表现很强，在 Something-Something v2 上取得 77.3% 的 top-1 准确率；在人类动作预判方面达到当时最先进水平，在 Epic-Kitchens-100 上取得 39.7 的 recall@5，超过此前专门针对该任务设计的模型。此外，把 V-JEPA 2 与大语言模型对齐后，它在 80 亿参数规模的多个视频问答任务上达到最先进水平，例如 PerceptionTest 为 84.0，TempCompass 为 76.9。

最后，我们展示自监督学习如何用于机器人规划：仅使用 Droid 数据集中不足 62 小时的无标签机器人视频，对潜空间动作条件世界模型 V-JEPA 2-AC 进行后训练。我们将 V-JEPA 2-AC 零样本部署到两个不同实验室的 Franka 机械臂上，以图像目标为依据进行规划，实现物体抓取与放置。尤其值得关注的是，我们没有从这些部署环境的机器人采集任何训练数据，也没有进行任务专属训练或使用任务奖励。这项工作表明，利用网络规模数据和少量机器人交互数据开展自监督学习，可以得到能够在物理世界中规划的世界模型。

1 引言

人类在面对新任务、进入陌生环境时，具有适应和泛化能力。一些认知学习理论认为，人类通过整合低层感官输入，学习世界的内部模型，用它表示和预测未来状态（Craik，1967；Rao 和 Ballard，1999）。这些理论进一步认为，世界模型会塑造我们每一时刻的感知，并在我们理解现实的过程中发挥关键作用（Friston，2010；Clark，2013；Nortmann 等，2015）。预测自身行为会怎样影响世界未来状态的能力，也是面向目标进行规划的基础（Sutton 和 Barto，1981、1998；Ha 和 Schmidhuber，2018；Wolpert 和 Ghahramani，2000）。如果人工智能体能够从视频等感官数据中学习世界模型，就可能理解物理世界、预测未来状态，并像人类一样在新情境中有效规划，进而处理从未遇到过的任务。

以往研究尝试从状态—动作序列构成的交互数据中学习预测性世界模型，往往还依赖环境显式提供的奖励反馈来确定目标。但真实交互数据数量有限，限制了这些方法的规模扩展。较新的工作把互联网规模视频与交互数据结合起来，训练用于机器人控制的动作条件视频生成模型。不过，它们通过基于模型的控制实现机器人执行的结果仍然有限。这一研究方向通常更重视预测是否可信、生成视频的视觉质量如何，而非规划能力；原因可能在于，通过生成视频来规划的计算成本较高。

本文沿着自监督学习假设构建世界模型，希望主要从观察中获取关于世界的背景知识。具体而言，我们采用联合嵌入预测架构 JEPA（LeCun，2022），在学习到的表示空间中进行预测。与完全依靠交互数据的方法相比，自监督学习让我们可以利用互联网规模的视频。这些视频呈现状态序列，却没有直接记录动作；我们可以据此同时学习视频观测的表示，以及该表示空间中的世界动力学预测模型。

与视频生成方法相比，JEPA 着重学习场景中可预测部分的表示，例如运动物体的轨迹，同时忽略不可预测的细节。生成式目标需要进行像素级预测，因此不得不关注这些细节，例如田野中每一根草、树上每一片叶子的精确位置。我们通过扩大 JEPA 预训练规模，证明它可以得到在理解和预测方面达到先进水平的视频表示；这些表示还能作为动作条件预测模型的基础，支持零样本规划。

V-JEPA 2 采用分阶段训练：先在互联网规模视频上进行不以动作为条件的预训练，再利用少量交互数据进行后训练，见图 1。第一阶段采用掩码去噪式特征预测目标（Assran 等，2023；Bardes 等，2024），在学习到的表示空间中预测视频被遮蔽的片段。我们使用超过 100 万小时的视频，训练最大约 10 亿参数的编码器。通过探测器评估，以及将编码器与语言模型对齐后进行视频问答，我们确认扩大自监督视频预训练能够提高视觉理解能力，包括广泛的运动与外观识别能力。

完成互联网视频预训练后，我们利用第一阶段学到的表示，在少量交互数据上训练动作条件世界模型 V-JEPA 2-AC。它是一个约 3 亿参数的 Transformer，使用分块因果注意力，根据动作与历史状态自回归预测下一视频帧的表示。仅利用 Droid 数据集中约 62 小时的无标签交互数据，我们就能训练出潜空间世界模型。给定子目标后，模型可规划 Franka 机械臂的动作，仅凭单目 RGB 相机，在新环境中零样本完成抓取类操作。

本文说明，从视频学习的联合嵌入预测架构，能够利用互联网规模视频与少量交互数据构建世界模型，实现物理世界理解、未来状态预测及新情境中的有效规划。具体成果如下。

- **理解——基于探测器的分类：** 扩大自监督视频预训练规模，可以获得适用于许多任务的表示。V-JEPA 2 擅长编码细粒度运动，在需要运动理解的 Something-Something v2 上，通过注意力探测器取得 77.3% 的 top-1 准确率。
- **理解——视频问答：** V-JEPA 2 可作为多模态大语言模型的编码器。在需要物理理解和时间推理的多个基准上，模型在 8B 语言模型级别达到先进水平：MVP 成对准确率 44.5，PerceptionTest 测试准确率 84.0，TempCompass 多选准确率 76.9，TemporalBench 短问答的多重二元准确率 36.7，TOMATO 准确率 40.3。没有语言监督的视频编码器，也能在语言对齐后达到先进水平，这与一些既有看法不同。
- **预测：** 大规模自监督视频预训练增强了预测能力。V-JEPA 2 通过注意力探测器，在 Epic-Kitchens-100 人类动作预判任务上取得 39.7 的 recall@5，相对此前最佳模型提高 44%。
- **规划：** 仅用 Droid 中约 62 小时无标签机器人操作数据后训练的 V-JEPA 2-AC，可在新环境中利用给定子目标规划抓取操作。不使用本实验室机器人采集的额外训练数据，也不进行任务专属训练或使用任务奖励，即可操作新物体，完成抓取和抓取放置。

本文后续安排如下：第 2 节介绍 V-JEPA 2 预训练，以及相较原始 V-JEPA 实现规模扩展的关键因素；第 3 节介绍任务无关动作条件世界模型 V-JEPA 2-AC；第 4 节展示基于模型的规划控制。由于表示空间世界模型的能力取决于表示中包含的信息，第 5、6 节进一步评估视频理解与预测能力。第 7 节介绍语言对齐和视频问答，第 8 节讨论相关工作，第 9 节总结。

【图 1，原文第 2 页：V-JEPA 2 总体框架】 先用约 100 万小时互联网视频和 100 万张图像，通过视觉掩码去噪目标预训练视频模型。预训练模型有三条使用路径：与大语言模型对齐后进行视频问答；训练注意力探测器，进行动作分类、物体识别和动作预判；冻结视频编码器后，用约 62 小时机器人状态与动作数据训练动作条件预测器 V-JEPA 2-AC，再在模型预测控制循环中进行机器人操作规划。

2 V-JEPA 2：扩大自监督视频预训练

我们在包含超过 100 万小时视频的视觉数据集上预训练 V-JEPA 2。训练任务是在表示空间中进行掩码去噪，以 V-JEPA 框架（Bardes 等，2024）为基础。本文探索更大的模型、更多的预训练数据，并引入空间与时间渐进分辨率训练策略，使模型能够高效地从短至 16 帧的视频片段扩展到更长输入。

2.1 方法

表示空间中的掩码去噪。 给定视频 y，随机移除部分图像块，得到遮蔽后的视图 x。V-JEPA 的目标是根据 x 预测视频 y 的已学习表示，见图 2 左侧。整体由编码器 $E_\theta(\cdot)$ 和预测器 $P_\phi(\cdot)$ 构成：前者提取视频表示，后者预测被遮蔽部分的表示。二者联合优化：

$$\underset{\theta,\phi,\Delta_y}{\text{minimize}} \left\| P_\phi\big(\Delta_y, E_\theta(x)\big) - \text{sg}\big(E_{\bar{\theta}}(y)\big) \right\|_1 . \tag{1}$$

其中，Δ_y 为可学习的掩码 token，表示被移除图像块的位置。损失使用停止梯度操作 $\text{sg}(\cdot)$，目标编码器权重 $\bar{\theta}$ 是在线编码器权重 θ 的指数移动平均（EMA），以避免表示坍塌。损失仅在被遮蔽图像块的预测上计算。

架构。 编码器与预测器都采用视觉 Transformer（ViT）。相较 Bardes 等（2024）使用的绝对正余弦位置嵌入，我们采用旋转位置编码 RoPE 来表示相对位置。具体做法是将一维 RoPE 扩展到三维：将特征维度近似等分成三段，分别对应时间、高度和宽度，并对各段独立施加一维旋转。对于最大模型，3D-RoPE 比绝对正余弦位置嵌入更能稳定训练。输入视频先被划分为 $2 \times 16 \times 16$（时间×高度×宽度）的小视频块，再采用与 Bardes 等（2024）相同的多块遮蔽策略。

规模扩展的四个关键因素。

1. **扩大数据：** 整理更多数据源，将视频数量从 200 万扩展到 2200 万。
2. **扩大模型：** 从约 3 亿参数的 ViT-L 扩展到超过 10 亿参数的 ViT-g。
3. **延长训练：** 使用“预热—恒定—衰减”学习率调度，简化调参，并把训练从 9 万步延长到 25.2 万步，充分利用新增数据。
4. **提高分辨率：** 在预热和恒定学习率阶段使用较短、较低分辨率的视频，在最后的学习率衰减阶段提高空间分辨率和／或片段长度。

后文会分别说明这些因素，并用以下评估协议量化其作用。

评估协议。 预训练的目标是让编码器具备通用视觉理解能力。我们在六个运动或外观分类任务上评价表示质量：Something-Something v2、Diving-48、Jester、Kinetics、COIN 和 ImageNet。评估时冻结编码器，在输出表示上训练任务专属的四层注意力探测器，预测类别。本节主要讨论六项任务的平均准确率；各任务、协议与结果的详细信息见第 5 节。

【图 2，原文第 4 页：多阶段训练】 左侧为无动作条件的预训练：将视频切成 token，移除部分 token；在线编码器只处理可见部分，预测器结合可学习掩码 token，回归 EMA 目标编码器从完整视频得到的表示，使用 L1 损失并阻断目标分支梯度。右侧为动作条件后训练：冻结编码器，用历史帧、动作和末端状态预测下一帧表示。分块因果注意力允许当前图像块关注当前及过去时刻的动作、末端状态与其他图像块。

2.2 扩大自监督视频学习

我们首先总结四个因素对下游平均表现的影响。基线是在 200 万视频上、以 V-JEPA 目标预训练的 ViT-L/16。将视频增至 2200 万，即 VM22M，平均准确率提高 1.0 个百分点；将模型从 3 亿参数扩至 10 亿参数 ViT-g/16，再提高 1.5 个百分点；训练从 90K 步延长至 252K 步，再提高 0.8 个百分点；最后，在预训练和评估中，将空间分辨率由 256 提至 384，时长由 16 帧增至 64 帧，平均准确率达到 88.2%。相较基线累计提升 4.0 个百分点。每项调整都带来正向收益，说明视频自监督学习具有规模扩展潜力。

【图 3，原文第 5 页：规模扩展因素】 柱状图依次展示：V-JEPA 1 基线 84.2%；增加数据后 85.2%；扩大模型后 86.7%；延长训练后 87.5%；提高分辨率后 88.2%。数值是 SSv2、Diving-48、Jester、Kinetics、COIN、ImageNet 六项任务的平均准确率。

2.3 预训练数据集

扩大数据集。 我们将多个公开数据源组合为大型视频数据集，以便其他研究者复现。包括 Something-Something v2 的第一人称视频；Kinetics-400、600、700 的第三人称动作视频；HowTo100M 的 YouTube 教学视频；以及 YT-Temporal-1B 的通用 YouTube 视频，后者简称 YT1B。我们还加入 ImageNet 图像，以扩大视觉覆盖范围。

为了联合预训练图像和视频，将单张图像沿时间重复，构成所有帧相同的 16 帧视频。训练时，各数据源按人工调参确定的权重采样。最终数据集 VideoMix22M，简称 VM22M，包含约 2200 万样本。表 1 列出组成与权重。

表 1：VideoMix22M（VM22M）预训练数据集。 四个视频源和一个图像源；YT1B 经过基于检索的数据筛选，以减少卡通、剪贴画风格等噪声内容。

数据源	样本数	类型	总时长（小时）	是否筛选	采样权重
SSv2	168K	第一人称视频	168	否	0.056
Kinetics	733K	第三人称视频	614	否	0.188
HowTo100M	1.1M	第三人称视频	134K	否	0.318
YT-Temporal-1B	19M	第三人称视频	1.6M	是	0.188
ImageNet	1M	图像	不适用	否	0.250

图 4 左侧比较 VM22M 与原 V-JEPA 的 200 万视频 VM2M 数据集。在相同 ViT-L/16 上，VM22M 带来约 1 个百分点的平均提升；Kinetics-400、COIN 和 ImageNet 等偏重外观的任务改善更明显，说明扩大视觉覆盖对这些任务尤其重要。

数据筛选。 与 Kinetics、SSv2 等较小数据集相比，YT1B 仅经过极少过滤，没有专门整理，包含约 140 万小时视频。未经筛选且不均衡的数据可能损害性能，因此我们把已有的基于检索的数据整理流程扩展到视频：先从 YT1B 提取场景片段，为每段计算嵌入，再用基于聚类的检索流程，按照目标分布选取场景。目标分布由 Kinetics、SSv2、COIN 和 EpicKitchen 的训练数据构成。数据构建细节位于原文附录 A.2。与 Oquab 等（2023）类似，我们确保初始未筛选数据池中不含目标验证集的视频。

图 4 右侧比较 ViT-L 在未筛选 YT1B 与 Curated-YT1B 上的表现。筛选带来 1.4 个百分点的平均提升。在 ViT-L 规模下，筛选后的 YT1B 与完整 VM22M 的表现已经接近；但更大模型从 VM22M 获益更多，说明把筛选后的 YT1B 与其他来源结合，有助于进一步扩大规模。

> 译注：原文表 1 将 YT-Temporal-1B 时长列为 1.6M 小时，而本段写约 1.4M 小时；此处分别保留原文口径。

【图 4，原文第 7 页：数据规模与数据筛选】 两组柱状图均使用训练 90K 步、采用余弦学习率调度的 ViT-L/16。左侧比较 VM2M 和 VM22M：平均提高约 1 个百分点，外观类任务收益更明显。右侧比较未经筛选与基于聚类检索筛选后的 YT1B：平均提高约 1.4 个百分点，说明数据质量本身也很重要。

2.4 预训练方案

扩大模型。 我们训练从约 3 亿参数 ViT-L 到 10 亿参数 ViT-g 的一组编码器。编码器架构见原文附录表 12。所有编码器都使用相同的、类似 ViT-small 的预测器。图 5 左侧给出六项视觉理解任务的平均表现。正文报告，从 ViT-L 扩到 ViT-g，平均提高 1.5 个百分点；运动与外观任务都受益，SSv2 提高 1.6，Kinetics 提高 1.5 个百分点，见表 4。这说明视频自监督预训练能够有效利用更大的模型容量，至少可扩至 1B 参数。

训练调度。 训练先进行学习率预热，再以恒定学习率训练，最后冷却衰减。与 Hägele 等（2024）类似，我们发现它与半余弦调度的表现相近，但探索长训练更省成本：可以从恒定阶段不同检查点分出多个冷却实验。相较原始 V-JEPA，我们不再逐步提升教师 EMA 和权重衰减系数，而是固定它们，因为这些变化对下游理解任务影响很小。图 3 显示，ViT-g 从 90K 延长至 252K 步训练，平均提升 0.8 个百分点。这一调度还方便在冷却阶段逐步提高视频分辨率。

高效的渐进分辨率训练。 以往编码器大多处理约数秒长的 16 帧短片段，我们则探索最长 64 帧、约 16 秒的高分辨率输入。不过，训练成本会随时长和分辨率显著上升：直接用 $64 \times 384 \times 384$ 输入训练 ViT-g，预计需要约 60 GPU 年。

我们采用渐进分辨率策略，在维持下游表现的同时提高效率。首先，在 16 帧、256×256 输入上进行 12K 步线性学习率预热，再以恒定学习率训练 228K 步；最后 12K 步线性衰减学习率，同时提高视频时长与分辨

率。高分辨率、长视频的额外计算成本仅发生在最后冷却阶段。对于可处理 64 帧、384×384 输入的模型，与始终全分辨率训练相比，这一策略减少约 8.4 倍 GPU 时间，并保留更长、更高分辨率输入的收益。

扩大时间与空间分辨率。 即使评估仍固定使用 16 帧，将预训练片段从 16 帧延长至 64 帧，也能使平均表现提高 0.7 个百分点。评估时进一步提高时长与分辨率，又会显著提升各任务表现，见表 4。因此，训练和评估阶段增加时间分辨率都能带来收益。我们也尝试过 128、256 帧输入，但在这些理解任务上没有发现超过 64 帧的额外改善。

【图 5，原文第 8 页：模型规模、训练效率与视频时长】 左图展示模型参数量与六任务平均准确率：模型先以恒定学习率训练至下游表现趋稳，再使用 64 帧、256×256 输入冷却；该图注报告从 300M 扩至 1B 后提高 1.7 个百分点。中图比较 A100 上高分辨率训练的 GPU 天数，渐进训练比直接全分辨率训练快约 8 倍。右图展示冷却阶段从 16 帧扩至 64 帧的收益：即使评估只输入 16 帧，平均准确率仍可提高约 0.7 个百分点。

> 译注：正文与图 5 对模型扩展收益分别写 1.5 和 1.7 个百分点，其对应训练／评估设置不同，此处各自保留。正文总训练为 12K+228K+12K=252K 步；图 5 中图图注则写先以低分辨率训练 252K 步、再高分辨率冷却 12K 步，两处步数描述也分别保留。

3 V-JEPA 2-AC：学习动作条件世界模型

预训练后的 V-JEPA 2 可以预测视频缺失部分，但这些预测没有直接考虑智能体动作对世界的因果影响。为使模型可用于规划，我们在冻结的视频编码器之上，利用少量交互数据训练帧级因果动作条件预测器，见图 2 右侧。

训练数据来自 Droid：通过遥操作桌面 Franka Panda 机械臂采集。我们将后训练模型称为 V-JEPA 2-AC。第 4 节将展示如何在模型预测控制循环中，用它在新环境规划动作。

3.1 动作条件世界模型训练

目标是在 V-JEPA 2 预训练基础上，得到能够通过闭环模型预测控制来控制具身系统的潜空间世界模型。V-JEPA 2-AC 是自回归模型，根据控制动作与本体感知观测，预测未来视频观测的表示。

本节具体讨论固定第三人称相机观察桌面机械臂的设置，控制动作为末端执行器指令。我们使用 Droid 原始数据中约 62 小时视频：视频通常长 3–4 秒，机器人为带双指夹爪的 7 自由度 Franka Emika Panda。“无标签”指不使用奖励、示范任务类别、示范是否成功等元数据，只使用原始视频及每帧同步的末端状态信号：三维位置、三维姿态和一维夹爪状态。

模型输入。 每次迭代随机采样一批 4 秒片段。为简化处理，丢弃不足 4 秒的视频，因此实际子集少于 62 小时。片段分辨率为 256×256，采样率为 4 fps，得到 16 帧 $(x_k)_{k\in[16]}$。

末端状态序列为 $(s_k)_{k\in[16]}$，每个 s_k 是相对机器人基座定义的七维实数向量：前三维为笛卡尔位置，接下三维为外禀欧拉角，最后一维为夹爪状态。通过相邻帧状态差构造 15 个动作 $(a_k)_{k\in[15]}$，每个七维动作表示第 k 帧到第 $k+1$ 帧的末端状态变化。视频使用随机缩放裁剪，宽高比在 $(0.75, 1.35)$ 内采样。

损失函数。 将 V-JEPA 2 编码器 $E(\cdot)$ 作为图像编码器，逐帧独立编码，得到特征图 $z_k = E(x_k) \in \mathbb{R}^{H\times W\times D}$。其中 $H \times W$ 为空间尺寸，D 为嵌入维度。实际使用 ViT-g，特征图形状为 $16 \times 16 \times 1408$。后训练过程中编码器始终冻结。

将动作、末端状态与特征图按时间交错排列为 $(a_k, s_k, z_k)_{k\in[15]}$，输入 Transformer 预测器 P_ϕ，得到下一状态表示预测 $(\hat{z}_{k+1})_{k\in[15]}$。教师强制损失为：

$$
\begin{aligned}
\mathcal{L}_{\text{teacher-forcing}}(\phi) &= \frac{1}{T}\sum_{k=1}^{T} \|\hat{z}_{k+1} - z_{k+1}\|_1 \\
&= \frac{1}{T}\sum_{k=1}^{T} \left\|P_\phi\big((a_t, s_t, E(x_t))_{t\le k}\big) - E(x_{k+1})\right\|_1 ,
\end{aligned}
\tag{2}
$$

这里 $T = 15$。我们还计算两步滚动预测损失，以改善推理时的自回归多步预测。为便于表达，略微复用记号：令 $P_\phi(\hat{a}_{1:T}; s_k, z_k)$ 表示从 (s_k, z_k) 出发，依次输入动作序列 $\hat{a}_{1:T}$，自回归运行后得到的最终状态表示，则：

$$\mathcal{L}_{\text{rollout}}(\phi) = \left\| P_\phi(a_{1:T}; s_1, z_1) - z_{T+1} \right\|_1 . \tag{3}$$

实际计算滚动损失时使用 $T = 2$，即只通过一次递归反馈步骤对预测器反向传播。总目标为：

$$\mathcal{L}(\phi) = \mathcal{L}_{\text{teacher-forcing}}(\phi) + \mathcal{L}_{\text{rollout}}(\phi), \tag{4}$$

只优化预测器参数 ϕ。图 6 为方便示意，将两种损失都画成 $T = 4$。

架构。 预测器约 300M 参数，包含 24 层、16 个注意力头、1024 维隐藏状态，使用 GELU。动作、末端状态与展平后的特征图分别通过可学习仿射变换，映射到预测器隐藏维度；最后一个注意力块的输出再通过仿射变换映射回编码器嵌入维度。

图像块的时空位置用 3D-RoPE 表示，动作与位姿 token 则只使用时间维度的 RoPE。分块因果注意力保证，每个时刻的图像块可关注本时刻的动作、末端状态与其他图像块，以及所有历史时刻的信息。

【图 6，原文第 10 页：V-JEPA 2-AC 的训练损失】 左侧教师强制：每次输入真实当前帧编码，预测下一时刻的编码。右侧滚动预测：把模型预测结果重新作为输入，连续预测多个未来时刻。二者相加训练，可以减少滚动过程中的误差累积。图中为示意画成四步，实际滚动损失只用两步。

3.2 通过规划推断动作

能量最小化。 给定目标状态图像，每个控制时刻都在固定规划时域内寻找动作序列，使目标条件能量函数最小；然后只执行第一个动作，观察新状态，再规划。

设当前末端状态为 s_k，当前图像与目标图像分别为 x_k, x_g，独立编码得到特征图 z_k, z_g。对规划时域 T，定义：

$$\mathcal{E}(\hat{a}_{1:T}; z_k, s_k, z_g) = \left\| P(\hat{a}_{1:T}; s_k, z_k) - z_g \right\|_1 . \tag{5}$$

最优动作序列为：

$$a^\star_{1:T} = \underset{\hat{a}_{1:T}}{\operatorname{argmin}} \mathcal{E}(\hat{a}_{1:T}; z_k, s_k, z_g).$$

模型选择的轨迹，会使其想象的 T 步后状态表示与目标表示之间的 L1 距离最小。实际使用交叉熵方法 CEM 优化式（5），每次只执行第一个动作，再重新规划，即滚动时域控制。

【图 7，原文第 11 页：模型预测控制中的规划】 编码当前观测和目标图像；预测器沿候选动作序列滚动，计算想象的终态与目标表示的 L1 距离。CEM 初始为规划时域中每个动作坐标设置零均值、单位方差的高斯分布，采样候选轨迹，按能量选出最好的 top-k，再以其统计量更新均值与方差。重复若干次，最终返回各高斯均值组成的动作轨迹。

4 规划：零样本机器人控制

本节展示如何利用 V-JEPA 2-AC 和模型预测控制，实现到达、抓取、抓取放置等基础技能。我们使用视觉目标指定任务，并考察模型对新环境的零样本泛化。

4.1 实验设置

基线。 比较两个基线：一个通过行为克隆训练的视觉—语言—动作模型，以及一个基于视频生成的世界模型。

第一个基线是支持目标图像条件的 Octo。我们从开源 octo-base-1.5 权重出发，该模型在包含超过 100 万轨迹的 Open-X Embodiment 上预训练。之后使用完整 Droid 数据集，通过行为克隆微调；目标图像和末端状

态采用事后重标记。训练时随机截取 Droid 轨迹，并从当前时刻之后最多 20 步内均匀采样目标图像。微调使用官方代码及标准 Droid 优化超参数：输入单侧视角的 256×256 图像，包含两个历史帧，预测未来 4 个动作。相比之下，V-JEPA 2-AC 使用 Droid 的约 23K 条轨迹，包含成功与失败交互。

第二个基线是 Cosmos 视频生成模型。我们从不以动作为条件的开源权重出发，采用连续 tokenizer 的 latent diffusion-7B；它预训练于 2000 万小时视频。随后用官方动作条件微调代码，在 Droid 上训练。为改善训练效果，我们做三项调整：降低学习率，使其与 Cosmos 的视频条件训练方案一致；移除视频条件分支的 dropout，改善训练动态；将噪声水平提高 e^2 倍，因为较低噪声设置下，模型难以利用条件帧信息。Cosmos 技术报告把规划和模型预测控制列为未来应用；据作者了解，本文是首次报告使用 Cosmos 控制机器人的尝试。

机器人部署。 所有模型均零样本部署到两个不同实验室的 Franka Emika Panda 机械臂，配备 RobotiQ 夹爪；两个实验室均未出现在 Droid 数据中。视觉输入来自未经标定、低分辨率的单目 RGB 相机。两个机器人使用完全相同的模型权重与推理代码，以及类似的操作空间低层控制器。

V-JEPA 2-AC 与 Cosmos 使用阻塞控制，即等待上一个指令执行完成后，再发送新指令。Octo 同时测试阻塞和非阻塞方式，报告较好结果。规划时，由于过大的动作相对偏离训练分布，我们将每个采样动作约束在以原点为中心、半径 0.075 的“L1-Ball”中；原文称这对应单个动作约 13 cm 的最大末端位移。

> 译注：原文把约束称为 L1 球，但约 13 cm 的欧氏位移上限对应三个位置坐标各约 7.5 cm 的情形，与严格 L1 球半径的通常定义不一致。此处保留原文名称和数值，不自行更改。

4.2 结果

单目标到达。 任务要求根据一张目标图像，把末端移动到指定空间位置。这既考察基本动作理解，也考察从单目 RGB 图像理解三维空间与深度的能力。

图 8 展示三个到达任务执行过程中，末端与目标的欧氏距离。所有任务中，模型都能使末端进入目标位置 4 cm 以内，并选择使误差单调减小的动作。这可视为一种视觉伺服：利用相机反馈控制运动。但与经典视觉伺服不同，V-JEPA 2-AC 是从无标签真实视频中学习这种能力的。

图 9 对应沿 Δy 方向到达的任务。固定 $\Delta z = 0$，扫描单次笛卡尔控制动作的 $\Delta x, \Delta y$，可视化式（5）的能量景观。最低能量出现在真实目标动作附近，说明无需精密感知，模型也能较合理地推断动作影响。能量面相对平滑、局部近似凸，也有利于规划。

【图 8，原文第 12 页：单目标到达】 三列分别展示沿 $+\Delta x, +\Delta y, +\Delta z$ 方向移动时的起始图像、目标图像及位置误差随步数的变化。每一步先规划，再只执行第一个动作，之后重新规划。模型能逐步接近目标。图注同样给出原文的半径 0.075 动作约束和约 13 cm 最大单步位移。

【图 9，原文第 13 页：V-JEPA 2-AC 能量景观】 真值动作约为 $(\Delta x, \Delta y) = (0, -0.1)$，固定 $\Delta z = 0$；图示最低点约在 $(0, -0.05)$ 附近。最低点并非完全等于真值，但方向与目标动作相近，说明表示空间能量能提供有用的控制信号。

抓取类操作。 我们进一步评估抓取、持物到达及抓取放置，表 2、3 报告成功率。表 2 的每种设置测试 10 次，改变物体位置、起始姿态等条件。抓取和持物到达各给一张目标图像；抓取放置则除最终目标外再给两张子目标：第一张显示已抓住物体，第二张显示物体到达目标附近，第三张显示物体已放到目标位置。

模型先针对第一子目标优化 4 步，自动切换到第二子目标执行 10 步，最后针对第三目标执行 4 步。抓取需要根据视觉反馈精确闭合夹爪；持物到达需要在移动中不掉落物体，涉及基础直觉物理；抓取放置则要求组合这些原子技能。

所有模型在到达任务上都表现较好，涉及物体交互时差异更明显。成功率也与物体有关。例如杯子通常适合一根夹指伸入杯内、夹住杯沿；动作不够准确就会错过杯沿。盒子有更多可行抓取姿态，但必须更精确控制夹爪张开幅度。各模型都受到次优动作及不同物体特有难点的共同影响。总体上，V-JEPA 2-AC 在所有任务上达到最高或并列最高成功率，证明潜空间规划用于机器人操作是可行的。

【图 10，原文第 14 页：抓取放置】 展示两个实验室中机械臂的闭环执行，物体配置多样，部分环境杂乱。高亮帧标记子目标达到及切换时刻。三个目标依次为抓住物体、持物移动到目标附近、放到目标位置，分别

使用 4、10、4 个控制步。动作全部由目标条件规划得到。

表 2：零样本机器人操作成功率。 两个实验室均为 Franka 加 RobotiQ 夹爪；每项条件测试 10 次。

方法	实验室	到达	抓杯子	抓盒子	持杯到达	持盒到达	杯子抓取放置	盒子抓取放置
Octo	Lab 1	100%	20%	0%	20%	70%	20%	10%
Octo	Lab 2	100%	10%	0%	10%	70%	10%	10%
Octo	平均	100%	15%	0%	15%	70%	15%	10%
V-JEPA 2-AC	Lab 1	100%	70%	30%	90%	80%	80%	80%
V-JEPA 2-AC	Lab 2	100%	60%	20%	60%	70%	80%	50%
V-JEPA 2-AC	平均	100%	65%	25%	75%	75%	80%	65%

表 3 比较 V-JEPA 2-AC 与基于潜扩散的动作条件视频生成模型 Cosmos。二者都在单张 NVIDIA RTX 4090 上，以 CEM 优化动作序列，并把目标帧编码到各自潜空间，按式（5）构造能量函数。

Cosmos 每轮使用 80 个样本、10 次优化迭代、规划时域 1，生成一个控制动作需要 4 分钟。它在到达任务上达到 80%，但物体交互较弱。每动作 4 分钟意味着一次完整抓取放置需要超过一小时。相比之下，V-JEPA 2-AC 每次迭代采样量多 10 倍，却只需每动作 16 秒，而且各项技能表现更好。

表 3：Lab 2 中的规划表现。 每项技能在 10 个任务上评估并平均。

方法	样本数	迭代数	规划时域	每动作耗时	到达	抓杯子	抓盒子	杯子抓取放置	盒子抓取放置
Cosmos	80	10	1	4 分钟	80%	0%	20%	0%	0%
V-JEPA 2-AC	800	10	1	16 秒	100%	60%	20%	80%	50%

未来可用更多计算资源、减少样本与迭代次数，或在世界模型想象中训练前馈策略以初始化规划，降低两种模型的规划耗时。V-JEPA 2-AC 还可能采用基于梯度的规划。

4.3 局限

对相机位置敏感。 模型没有显式相机标定，却需要根据单目输入预测末端笛卡尔动作对应的下一帧表示，因此必须隐式判断动作坐标轴。但画面中常常看不到机器人基座，坐标轴推断可能并无唯一明确解，造成世界模型错误。实际实验中，我们人工尝试多种相机位置，最终选取在所有实验中效果较好的位置。量化分析见原文附录 B.4。

长时域规划。 首先，自回归预测会累积误差，滚动越长，表示预测越不准确，可靠规划越困难。其次，时域线性增长会使可能的动作轨迹数量指数增长，搜索计算负担增大。但不借助图像子目标完成抓取放置等非贪心任务，又需要长时域规划。解决这一问题能拓展到更复杂任务。

图像目标。 与大量目标条件操作研究类似，本方法假定可获得视觉目标。在自然部署环境中，语言可能是更方便的目标表达方式。未来将潜空间动作条件世界模型与语言模型对齐，有望支持自然语言任务指定。

5 理解：基于探测器的分类

V-JEPA 2-AC 这样的表示空间世界模型，其能力受到表示所编码状态信息的根本限制。本节及之后两节探查 V-JEPA 2 学到的表示，并在视觉任务上与其他编码器比较。

视觉分类可偏重外观，也可偏重运动。外观任务往往只凭一帧信息就能完成，即使标签描述的是动作；运动任务则需要多个帧才能正确判断。为平衡两者，我们选取 SSv2、Diving-48、Jester 作为运动理解任务，考察人类手势与运动；外观理解采用 Kinetics-400、COIN 和 ImageNet，涵盖动作、场景和物体识别。实验表明，V-JEPA 2 在运动理解上优于其他先进视觉编码器，在外观任务上也具有竞争力。

注意力探测器。 冻结编码器，在每项任务训练集上训练四层探测器。前几个块为 Transformer，最后一个块用带可学习查询 token 的交叉注意力替代标准自注意力。推理时按常规从每段视频采样多个固定帧数片段，对分类 logits 求平均。输入分辨率与预训练相近。探测器深度消融和片段数、超参数见原文附录 C。

表 4：动作与物体分类。 数值为准确率（%）；“—”为未报告。文献结果使用其原始评估，后两组采用本文统一冻结编码器评估。

方法	参数量	平均	SSv2	Diving-48	Jester	K400	COIN	IN1K
文献报告结果								
VideoMAEv2	1B	—	56.1	—	—	82.8	—	71.4
InternVideo2-1B	1B	—	67.3	—	—	87.9	—	—
InternVideo2-6B	6B	—	67.7	—	—	88.8	—	—
VideoPrism	1B	—	68.5	71.3	—	87.6	—	—
统一协议的图像编码器								
DINOv2	1.1B	81.1	50.7	82.5	93.4	83.6	90.7	86.1
PEcore G	1.9B	82.3	55.4	76.9	90.0	88.5	95.3	87.6*
SigLIP2	1.2B	81.1	49.9	75.3	91.0	87.3	95.1	88.0
统一协议的视频编码器								
V-JEPA ViT-H	600M	85.2	74.3	87.9	97.7	84.5	87.1	80.0
InternVideo2s2-1B	1B	87.0	69.7	86.4	97.0	89.4	93.8	85.8
V-JEPA 2 ViT-L	300M	86.0	73.7	89.0	97.6	85.1	86.8	83.5
V-JEPA 2 ViT-H	600M	86.4	74.0	89.8	97.7	85.3	87.9	83.8
V-JEPA 2 ViT-g	1B	87.5	75.3	90.1	97.7	86.6	90.7	84.6
V-JEPA 2 ViT-g384	1B	88.2	77.3	90.2	97.8	87.3	91.1	85.1

表中 V-JEPA 2 均在 64 帧上预训练，通常分辨率 256×256，ViT-g384 为 384×384。除 ViT-g384 外统一使用 256 分辨率：SSv2 输入为 $16 \times 2 \times 3$，即 16 帧、2 个时间裁剪、3 个空间裁剪；K400 为 $16 \times 8 \times 3$；COIN 为 $32 \times 8 \times 3$；Diving-48 和 Jester 为 $32 \times 4 \times 3$。ViT-g384 六项任务均使用 384 分辨率，SSv2 额外采用 $64 \times 2 \times 3$，COIN 为 $32 \times 8 \times 3$。* PEcore G 原论文在 448 分辨率和其注意力探测器下，ImageNet 为 89.8%；此处使用 256 分辨率和不同探测器，得到 87.6%。

评估协议。 对比包括带 registers 的自监督图像模型 DINOv2，图文对比预训练模型 SigLIP2、Perception Encoder PEcore G，自监督视频模型 V-JEPA，以及主要依赖视觉—文本对比预训练的 InternVideo2s2-1B。

所有重新评估的模型均冻结编码器，训练注意力探测器。图像编码器通过拼接逐帧特征适配视频。InternVideo2s2 在 ImageNet 上用图像位置嵌入，在视频任务中将位置嵌入从 4 帧插值到 8 帧，使 token 数接近 V-JEPA 2。

虽然评估统一，各模型预训练数据仍不同，例如 DINOv2 使用 LVD-142M，PEcore G 使用 MetaCLIP，因此无法做完全受控的训练方法比较，只能进行系统层面比较。表中也列出文献使用类似冻结协议报告的 VideoMAEv2、InternVideo2、VideoPrism 结果，但其注意力头架构可能不同。

结果。 256 分辨率的 V-JEPA 2 ViT-g 在运动任务上显著领先：SSv2 为 75.3，而 InternVideo 为 69.7，PEcore G 为 55.4。外观任务也有竞争力，ImageNet 为 84.6，比 V-JEPA 高 4.6 个百分点。其六任务平均值 87.5，在这些图像与视频编码器中最高。更高分辨率、更长时长的 ViT-g384 在各项任务上继续改善，平均达到 88.2。

6 预测：基于探测器的动作预判

动作预判要求根据动作发生前一段时间的上下文视频，预测未来动作。在 Epic-Kitchens-100（EK100）上，我们发现 V-JEPA 2 的预判能力随模型规模稳定提升。即使只在表示上训练注意力探测器，也显著优于此前专门针对该任务设计的方法。

任务。 EK100 包含 45 个厨房中以第一人称录制的 100 小时烹饪活动。每个动作片段带有开始时间、结束时间和动作标签。共 3568 个不同动作标签，每个由一个动词与一个名词组成，覆盖 97 个动词类别、300 个名词类别。

任务输入是动作开始之前的一段上下文视频，输出动词、名词及二者联合形成的动作类别。上下文结束到动作开始的间隔称为预判时间，默认 1 秒。同一上下文可能对应多种合理未来，因此使用类别平均 recall@5 评估。

预判探测器。 冻结 V-JEPA 2 编码器和预测器，训练注意力探测器。采样在动作开始前 1 秒结束的视频，由编码器提取上下文表示。预测器同时接收编码表示，以及对应未来 1 秒后帧位置的掩码 token，预测未来帧表示。将编码器与预测器输出沿 token 维拼接，再输入类似第 5 节的探测器。

区别在于最后的交叉注意力使用三个可学习查询，各自接线性分类器，分别预测动作、动词和名词。三个分类器独立计算 focal loss，再相加，并通过共享注意力块反向传播。细节见原文附录 D.1。

基线。 InAViT 显式建模手—物交互，以监督方式训练；Video-LLaMA 和 PlausiVL 使用大语言模型。原文此处说后两者最大约 7B 参数，但表 5 将 PlausiVL 列为 8B，此处按表格保留。

表 5：EK100 人类动作预判。 验证集上的类别平均 recall@5。

方法	参数量	动词	名词	动作
InAViT	160M	51.9	52.0	25.8
Video-LLaMA	7B	52.9	52.0	26.0
PlausiVL	8B	55.6	54.2	27.6
V-JEPA 2 ViT-L（冻结骨干）	300M	57.8	53.8	32.7
V-JEPA 2 ViT-H（冻结骨干）	600M	59.2	54.6	36.5
V-JEPA 2 ViT-g（冻结骨干）	1B	61.2	55.7	38.0
V-JEPA 2 ViT-g384（冻结骨干）	1B	63.6	57.1	39.7

结果。 ViT-L、H、g 都以 8 fps 采样 32 帧、256 分辨率上下文；ViT-g384 使用 384 分辨率。动作 recall@5 随规模近似线性增长：300M 的 ViT-L 为 32.7，1B 的 ViT-g 为 38.0，提高 5.3 个百分点；提高分辨率又增加 1.7，达到 39.7。

即使 300M 模型也超过 8B 的 PlausiVL。ViT-g384 相比 PlausiVL 的动作 recall@5 高 12.1 个百分点，即相对提高约 44%。

【图 11，原文第 18 页：EK100 预测示例】 左侧为四张上下文帧，中间为按概率排序的五个候选动作，右侧是 1 秒后的真实帧。第一组成功示例依次预测“清洗水槽、清洗侧边表面、打开水龙头、冲洗海绵、清洁墙面”；第二组依次为“放盘子、把盘子放进沥水架、拿起盘子、开门、擦干盘子”。失败示例依次为“放玻璃杯、关门、放瓶子、放下调料包、把杯子挂到杯架”。

两个成功案例不仅 top-1 正确，后续候选也与场景一致。例如存在水龙头和墙面时，“开水”或“清洁墙面”都是合理未来；“冲洗海绵”也是当前正在进行、可能在 1 秒后继续的动作。失败例中的“关门”“放下调料包”仍合乎场景，但没有认对物体实际是茶包。

局限。 首先，模型仍会预测错动词、名词或两者，不能完全解决 EK100。其次，本节主要评估提前 1 秒的预判，时间更长时准确率下降。第三，EK100 只涵盖厨房和封闭词汇，模型能否泛化到其他环境尚不清楚，限制了实用性。最后，动作只能从固定类别中选择，无法泛化到训练集中不存在的动作类别。

7 理解：视频问答

本节研究 V-JEPA 2 的开放语言视频问答能力。为引入语言能力，我们采用 LLaVA 系列普及的、非离散视觉 token 的早期融合设置，以 V-JEPA 2 为视觉编码器训练多模态大语言模型（MLLM）：通过投影模块把编码器输出的图像块嵌入映射到 LLM 输入嵌入空间，之后冻结视觉编码器训练，或进行端到端训练。

已有视频问答 MLLM 多数使用图像编码器，逐帧独立处理视频，例如 CLIP、SigLIP、Perception Encoder。它们通过图像—描述预训练获得与语言的语义对齐，因此经常被选用。据作者了解，本文首次使用完全没有语言监督预训练的视频编码器来训练视频问答 MLLM。

下游表现也高度依赖对齐数据。我们使用与 PerceptionLM 类似的 8850 万图像／视频—文本样本。先取 1800 万样本，在受控设置下比较编码器；再研究编码器规模和分辨率；最后使用完整数据检验语言对齐潜力。结果表明，在受控设置下 V-JEPA 2 已具有竞争力，扩大数据后则在多个基准上达到先进水平。

7.1 实验设置

视频问答任务。 PerceptionTest 评价记忆、抽象、物理和语义等能力。MVP 通过最小差异视频对的评估框架，降低文本与外观偏置，重点考察物理世界理解。TempCompass、TemporalBench、TOMATO 用于考察时间理解和记忆。通用理解方面采用 MVBench，但它较偏重单帧外观；同时采用 TVBench，后者旨在缓解这些偏置，兼顾通用和时间理解。

视觉指令微调。 按照 LLaVA 流程，将视觉 token 经可学习投影器，通常是 MLP，转换成 LLM 输入。采用三阶段渐进训练：第一阶段只用图像描述数据训练投影器；第二阶段用大规模图像问答训练整个模型；第三阶段继续用大规模视频描述与问答训练。LLM 因而逐步学会理解视觉 token。

视觉编码器可以冻结，也可以随整个模型微调。冻结能更清晰反映视觉特征质量，微调通常取得更高整体表现。我们研究两种设置，细节见原文附录 E。

7.2 与图像编码器比较

为了隔离视觉编码器的贡献，所有模型使用相同的 Qwen2-7B-Instruct、相同数据与训练设置，并冻结视觉编码器，使用 1800 万图像／视频—文本对齐样本。对比 512 分辨率的 V-JEPA 2，与 DINOv2、SigLIP2 和 Perception Encoder。

表 6：冻结视觉编码器的受控比较。 参数量列为“编码器／LLM”；PerceptionTest 为 SFT 后验证集准确率。其余列分别为 MVP 成对准确率、TempCompass 多选准确率、TemporalBench 短问答多重二元准确率，以及各基准准确率。

编码器	参数量	平均	PerceptionTest	MVP	TempCompass	TemporalBench	TVBench	TOMATO	MVBe
DINOv2 ViT-g，518 分辨率	1.1B/7B	45.7	67.1	22.4	62.3	26.8	47.6	32.0	6
SigLIP2 ViT-g，384 分辨率	1.1B/7B	48.1	72.4	26.2	66.8	25.7	48.7	33.2	6
PE ViT-G/14，448 分辨率	1.9B/7B	49.1	72.3	26.7	67.0	27.5	51.6	34.0	6
V-JEPA 2 ViT-g，512 分辨率	1B/7B	52.3	72.0	31.1	69.2	33.3	55.9	37.0	6

除 PerceptionTest 略低于 SigLIP2 和 PE 外，V-JEPA 2 在全部测试基准上优于其他编码器。MVP、TemporalBench、TVBench 等侧重时间理解的基准提升尤其明显。

由于只替换视觉编码器，结果说明，没有语言监督的视频预训练也能胜过带语言监督的编码器，这与一些既有看法相反。视频编码器相较图像编码器还能改善视频问答的时空理解，表明发展更强视频编码器具有重要价值。

7.3 扩大视觉编码器与输入分辨率

已有研究表明，扩大自监督图像编码器和输入分辨率可显著改善 VQA。我们将 V-JEPA 2 从 300M 扩至 1B，分辨率从 256 提至 512，见表 7。

表 7：视觉编码器规模与分辨率扩展。 全部使用 Qwen2-7B-Instruct、相同数据及端到端训练，即视觉编码器不冻结。PerceptionTest 为 SFT 后验证集结果。列顺序与表 6 相同。

编码器	参数量	平均	PerceptionTest	MVP	TempCompass	TemporalBench	TVBench	TOMATO	MVBen
V-JEPA 2 ViT-L256	300M/7B	51.7	74.6	32.3	70.1	30.2	50.9	36.5	67
V-JEPA 2 ViT-H256	600M/7B	52.0	74.7	30.6	70.9	29.8	54.6	35.1	68
V-JEPA 2 ViT-g256	1B/7B	52.3	75.5	31.9	70.7	28.3	54.2	37.3	68
V-JEPA 2 ViT-g384	1B/7B	54.0	76.5	33.0	71.7	33.1	56.5	39.0	68
V-JEPA 2 ViT-g512	1B/7B	54.4	77.7	33.7	71.6	32.3	57.5	38.5	69

固定 256 分辨率，从 300M 增至 1B，PerceptionTest、TVBench、MVBench 分别提高 0.9、3.3、1.2 个百分点。提高到 512 分辨率后，相较 ViT-g256，PerceptionTest、TemporalBench、TVBench 分别再提高 2.2、4.0、3.3 个百分点。结果支持继续扩大编码器及分辨率以改善视频问答。

7.4 通过扩大数据推进最先进水平

在受控设置中了解模型能力后，我们将对齐训练从 1800 万样本扩至完整 8850 万，原文称约 4.7 倍。虽然更高分辨率有益，但也会产生更多视觉 token，加重 LLM 输入负担，因此选择 ViT-g384，每帧产生 288 个视觉 token。

我们沿用 PerceptionLM 的训练方案，以 Llama 3.1 为语言骨干。为简化过程，使用不带池化的 MLP 投影器。训练细节见原文附录 E。

表 8：与先进视频语言模型比较。 前四行为文献报告的至多 8B 语言模型级别结果。V-JEPA 2 使用完整 88.5M 对齐数据和 Llama 3.1 8B。PerceptionTest 为测试集准确率，V-JEPA 2 在该项使用 SFT，其余结果为零样本。注意本表 TVBench 和 TOMATO 的顺序已与表 6、7 统一，数字仍各自对应原指标。

模型	编码器／LLM 参数	平均	PerceptionTest	MVP	TempCompass	TemporalBench	TVBench	TOMATO	M
InternVL-2.5	300M/7B	52.1	68.9	39.9	68.3	24.3	61.6	29.4	
Qwen2VL	675M/7B	47.0	66.9	29.2	67.9	20.4	46.0	31.5	
Qwen2.5VL	1B/7B	49.7	70.5	36.7	71.7	24.5	50.5	24.6	
PLM 8B	1B/8B	56.7	82.7	39.7	72.7	28.3	63.5	33.2	
V-JEPA 2 ViT-g384 + Llama 3.1 8B	1B/8B	59.5	84.0	44.5	76.9	36.7	60.6	40.3	

增加对齐数据改善了各项下游表现，并在 PerceptionTest、MVP、TempCompass、TemporalBench、TOMATO 上达到该规模级别最先进结果。相较 PerceptionLM 8B，分别提高 1.3、4.8、4.2、8.4、7.1 个百分点。

V-JEPA 2 在 TVBench 与 MVBench 上仍不及 PerceptionLM，但显著优于 InternVL 2.5、Qwen2VL、Qwen2.5VL 等其他基线。结果强调视觉语言对齐数据规模的重要性，并表明完全没有语言监督预训练的编码器，也能通过充分规模的对齐达到先进水平。

8 相关工作

世界模型与规划。 早在 Sutton 和 Barto（1981）、Chatila 和 Laumond（1985）的工作中，研究者就尝试让智能体使用世界内部模型，既描述动力学，也表示静态环境，以支持高效规划与控制。后续研究涵盖模拟任务及真实运动控制、操作任务。预测可以直接发生在像素空间，也可以发生在已学习表示空间，或关键点等结构化表示空间。

此前在真实机器人上有效的世界模型，多针对特定任务训练，并依赖机器人部署环境中的交互数据；评估侧重已经探索过的任务空间，而非新环境和未见物体。本文训练任务无关世界模型，展示对新环境、新物体的泛化。

近期部分工作结合互联网视频与交互数据，训练通用、任务无关的动作条件视频生成模型。但截至本文，它们主要展示给定机器人动作后生成视觉上合理的计划，尚未展示通过这些模型实际控制机器人。

另一些工作把生成式建模融入策略学习。与之不同，我们通过模型预测控制使用世界模型，以避免需要专家轨迹的模仿学习阶段。两类方法并不冲突，未来可以结合。最接近本文的 Zhou 等（2024）、Sobal 等（2025）表明，可以分阶段或端到端学习世界模型，用于零样本规划；这些工作主要研究小规模规划，而本文将类似原则扩展到真实机器人任务。

机器人控制的视觉—语言—动作模型。 近期真实机器人模仿学习在策略泛化方面取得明显进展。常见做法是用互联网规模视频和文本预训练视觉语言模型，再通过专家示范行为克隆，微调或适配为动作预测模型。

尽管泛化结果有潜力，但这些模型缺少显式世界预测模型，其能否生成训练中未示范的行为仍不明确，也没有像本文一样通过推理时规划来利用计算。它们依赖大规模、高质量遥操作数据，主要利用成功轨迹；本文则希望使用任何交互数据，包括成功与失败。

> 译注：原文相关句写作“do leverage inference-time computation for planning”，与该段的对比语义不一致，疑似漏写“not”。本段按其讨论意图译出，并在此保留这一原文疑点。

视觉基础模型。 大型图像和视频观测数据，可通过图像自监督、视频自监督、弱语言监督或其组合，训练能迁移到多种任务的通用视觉编码器。以往评价多数集中于探测器理解任务，或与 LLM 对齐后的视觉问答。这些任务虽然推动了研究，但视觉系统的重要目标仍是让智能体与物理世界交互（Gibson，1979）。本文除视觉理解外，还研究大规模视频自监督如何支持在新环境中零样本完成规划。

9 结论

本文说明，联合嵌入预测架构能够以自监督方式，从网络规模数据和少量机器人交互中学习世界模型，实现物理世界理解、预测和规划。V-JEPA 2 在需要运动理解的动作分类，以及人类动作预判上达到先进表现；与大语言模型对齐后，它也在视频问答任务中超过先前视觉编码器。

进一步地，利用其表示后训练动作条件世界模型 V-JEPA 2-AC，可以在真实机器人上零样本完成抓取放置等操作。这表明 V-JEPA 2 朝着能够有效感知环境并在其中行动的高级人工智能迈出一步。

未来工作。 首先，本文主要研究预测约 16 秒以内未来的任务，凭单张目标图像可支持抓取、持物到达等较简单操作。若要不依赖子目标完成抓取放置乃至更复杂的长时域任务，仍需模型创新。能够跨多个时空尺度、多个抽象层次进行预测的层级模型，是有潜力的方向。

其次，V-JEPA 2-AC 当前依赖图像目标。部分任务这样表达很自然，另一些任务则更适合语言。未来可把语言目标嵌入 V-JEPA 2-AC 表示空间，使其支持语言条件任务；第 7 节的语言对齐结果可作为起点。

最后，本文模型最大为相对适中的 1B 参数，第 2 节表明扩大到这一规模时，性能仍持续改善。以往视觉编码器已探索到 20B。未来需继续开发可扩展预训练方案，使性能随模型规模持续提高。

致谢

感谢 Rob Fergus、Joelle Pineau、Stephane Kasriel、Naila Murray、Mrinal Kalakrishnan、Jitendra Malik、Randall Balestriero、Julen Urain、Gabriel Synnaeve、Michel Meyer、Pascale Fung、Justine Kao、Florian Bordes、Aaron Foss、Nikhil Gupta、Cody Ohlsen、Kalyan Saladi、Ananya Saxena、Mack Ward、Parth Malani、Shubho Sengupta、Leo Huang、Kamila Benzina、Rachel Kim、Ana Paula Kirschner Mofarrej、Alyssa Newcomb、Nisha Deo、Yael Yungster、Kenny Lehmann、Karla Martucci，以及 PerceptionLM 团队的 Christoph Feichtenhofer、Andrea Madotto、Tushar Nagarajan、Piotr Dollar，为本项目提供反馈与支持。

参考文献

完整英文书目信息请参见原 PDF 的 References。本译文不包含附录。