EgoInfinity：面向任意视角机器人重定向与视频到动作学习的网络规模四维手—物交互数据引擎

译自论文正文第 1 ~ 6 节，止于结论。为方便阅读，合并了双栏排版造成的断句；图表在对应位置标出原文编号。术语中的“度量”指具有实际物理尺度。

摘要

互联网视频是人类具身操作知识最大的来源，但要把任意 RGB 视频变成可用于机器人训练的数据，仍存在重大瓶颈。现有在实验室或工厂采集的数据集规模和多样性有限，难以支持开放世界的机器人学习。本文提出的不是一个固定数据集，而是 **EgoInfinity**：一个通用的四维手—物交互数据引擎，可在网络规模上生成用于机器人重定向和学习的数据。

EgoInfinity 是模块化的，整合了感知、分割、重建、交互感知优化和动作重定向，在没有人工逐条标注的情况下自动完成原本难以扩展的“视频到动作”转换。模块设计也使它能持续受益于各个组件的进步。它把自然环境中的人类操作视频提升为与操作者形态无关、具有物理尺度的四维手—物交互表示，其中包括手部轨迹、物体六自由度位姿以及与接触有关的状态。

它没有简单串接独立模型，而是利用跨模块尺度校准和交互感知优化提高物理可靠性，减少纯视觉重建常见的漂移与接触不一致。作者还提出新的动作重定向器，把恢复出的三维手部运动编译成适用于不同机器人形态的可执行关节轨迹。因此，哪怕视频视角和画幅任意、人体只露出一部分，也能将视频动作迁移到机器人。论文从感知精度、运动学可行性、接触一致性、跨形态泛化和真实机器人技能获取等方面验证该系统，展示了从互联网视频到可执行机器人行为的可扩展桥梁。项目页面：https://huggingface.co/spaces/Rice-RobotPI-Lab/EgoInfinity

【原文图 1：完整数据引擎。先筛选 Action100M 片段，再估计手、物体、深度和重力；根据静止、抓握、移动状态优化物体轨迹，最后输出四维交互表示，并将其用于直接回放或策略学习。】

1. 引言

训练通用机器人需要既能扩展、又足够多样的操作数据。实验室或工厂数据能提供适配机器人的监督；第一视角演示尤其有价值，因为它能从接近动作执行者的角度同时记录手、物体和接触模式。但此类数据很难扩展，现有可穿戴设备或实验室数据受任务种类、采集环境或参与者行为限制。互联网视频自然覆盖多种环境、视角和任务；仅 Action100M 就有 1.47 亿个动作片段、相当于 14.6 年的视频。然而，它们缺少有实际尺度的三维几何、

物体六自由度状态、接触信息和可执行机器人动作，因此还不能直接用于机器人。把任意视角的野外视频自动整理为机器人操作数据，是扩展机器人学习的重要一步。

EgoInfinity 无需人工标注，便能把普通 RGB 视频转换成与具体执行者无关的度量手—物表示。流水线包括手部位姿与网格估计、目标物体发现、物体分割、单目度量深度、相机与重力估计、物体跟踪与重建，以及根据交互状态修正轨迹。各模块共用坐标系与尺度，并结合物体几何先验，因此输出更一致、更符合物理规律。

系统还提供功能性动作重定向：它估计目标机器人的根坐标变换，在机器人约束内保留与任务相关的手部动作，而不要求准确复制人体和手臂的全部运动学。这对只看得到手或部分手臂的网络视频尤其重要。论文贡献有三点：全自动模块化四维数据引擎；跨模块校准与交互感知优化；经过运动学和真实机器人验证的跨形态重定向器。

2. 相关工作

机器人可用的操作数据。现有数据在规模、形态对齐和动作可执行性之间各有取舍。Ego4D、EgoDex、HOT3D 和 OakInk2 提供人类操作观察，但往往需要头戴设备、动作捕捉、Vision Pro、人工解说或受控采集。DROID 和 Open X-Embodiment 提供真正的机器人动作，却受硬件、任务设计和采集成本制约。UniHand-Mix 通过汇聚数据扩大覆盖面，但继承了异构标注和部分可穿戴设备依赖。EgoInfinity 面向野外互联网视频，无需可穿戴设备、深度传感器、CAD 模型或人工指定目标物体，仍能输出具有度量手部运动、物体状态和交互线索的四维数据。

【原文表 1：数据来源、标注形式、硬件需求、自动化程度、是否需要人工指定物体和规模的比较。EgoInfinity 的上限暂由 Action100M 的约 12.7 万小时决定，数据引擎本身不绑定该语料。】

从人类视频到四维操作数据。现有方法可按任务、观察和动作划分：用 VLM 推断意图；用视频转换或视觉嵌入缩小外观差距；或提取可供性与潜动作。EgoInfinity 接近动作级、以交互为中心的方法，但恢复的是真实尺度下的手和物体，而非二维伪动作。这得益于 RGB 手重建、单目几何、开放词汇分割与跟踪、物体重建、光流/PnP 跟踪及重力校准等组件的成熟。同期 EgoGrasp 也从动态第一视角视频恢复世界坐标中的手—物交互，并用抓握状态决定何时让手运动驱动物体；它依赖类似 SLAM 的相机估计、全身 SMPL-X 先验和扩散轨迹先验。EgoInfinity 则针对相机近似静止的野外视频，不需要在线 SLAM 或人体模型，以确定性的交互状态分类和手—物刚性绑定处理抓握，并把组件组织为语料规模的数据引擎。

跨形态功能重定向。过去方法常针对特定灵巧手、平行夹爪或人形上身。任意互联网视频常只有手、局部手臂或不断变化的视角，完整人体恢复与精确运动学模仿并不可靠。EgoInfinity 估计机器人专属的可行根坐标变换，在其约束内保留任务相关的手部运动。

3. EgoInfinity 数据引擎

引擎输入为普通网络 RGB 视频及其语义描述，输出度量手部状态、物体点云和网格、六自由度物体位姿轨迹、接触相关状态，以及可供下游重定向的坐标转换结果。

3.1 模块化流水线

系统把手部网格估计、度量几何恢复、相机与重力校准、目标物体发现、物体重建与跟踪、交互感知优化放在统一的中间表示中。每个模块可以单独升级。为了扩展到海量视频，系统分两遍处理：第一遍用轻量时间扫描检测有手的片段，根据手部运动统计和相机运动筛掉不太可能包含有效操作的内容；第二遍只对活跃片段运行完整重建。目前主要处理相机近似静止的视频，这在教程和操作示范中很常见。

3.2 经度量校准的手—物跟踪

统一的度量几何。不同模型的原始输出既不天然同尺度，也不处于同一三维坐标系。系统先把它们校准到共享的相机坐标和物理尺度。MoGe-2 估计焦距与全局尺度，Flow3R 预测稠密深度，GeoCalib 估计相机坐标中的重力方向。由此，图像里的手与物体都被提升到同一个三维空间，后续才能可靠判断关联、接触和机器人目标位姿。

三维手部跟踪。WiLoR 从 RGB 帧估计 MANO 手部姿态参数与形状参数，生成逐帧手部网格 M_t^h、三维关键点 K_t^h 和全局手部位姿 ${}^cp_t^h = ({}^cR_t^h, {}^ct_t^h) \in SE(3)$。填补模块补齐缺失或不稳定的估计，再将轨迹锚定到上述统一度量几何中。

物体发现、重建和跟踪。系统根据视频文字描述和视觉证据自动找出被操作物体，不要求人工框选。文字提示交给 SAM-3 检测，SAM-2 将掩码传播到整个片段；掩码结合深度得到逐帧物体点云 P_t^o。视觉证据足够时，SAM-3D 重建物体网格 M_o；FoundationPose++ 根据网格、掩码和点云跟踪六自由度位姿 ${}^cp_t^o$，并稳定静止或观测较弱的帧。初始状态可写为：

$$H_t = \{M_t^h, K_t^h, {}^cp_t^h, P_t^o, M_o, {}^cp_t^o\}.$$

3.3 交互感知优化

纯视觉物体跟踪在静止时会漂移，被手遮挡时会失败，图像对应点弱时也会跳动。系统先从物体掩码和深度构建每帧位姿候选：保留 SAM-3D 的规范朝向，以反投影掩码点的中心作为平移。随后结合 MEMFOF 光流和手部关键点，将每帧分成 **静止**、**被抓握**、**移动**三种状态。被抓握时把物体刚性绑定到手坐标系，${}^c\hat{p}_t^o = {}^cp_t^h T_{cano}$；静止时锁定到稳健的

点云质心；移动时采用视觉位姿候选。最后通过简单合理性检查剔除异常尺度和误检背景物体。实现中还有更细的状态分类。

3.4 输出清洗与坐标转换

若下游需要更干净的物体点云，可以选用掩码腐蚀、深度梯度过滤和统计离群点剔除。由于相机近似静止，系统可在恢复出的三维空间中以刚性坐标变换完成外视角到自视角的转换，而不依赖二维生成式视频翻译，从而避免图像修补或 GAN 造成的像素幻觉，并保持几何一致。

4. 跨形态机器人动作重定向

重定向将与执行者形态无关的三维手部运动变为具体机器人的运动。目标是保留任务功能，而非精确模仿人的身体或手臂姿态。

4.1 等变的运动学根坐标估计

输入为恢复出的手部位姿轨迹及可选的重力方向。网络 Φ 预测相机坐标中的共享根坐标系，例如人形机器人的躯干坐标系。网络被设计为 $SE(3)$ 等变：如果相机坐标或输入轨迹发生刚性变换，预测的根坐标也应以同样方式变化：

$$G \cdot \Phi(x) = \Phi(G \cdot x), \qquad G \in SE(3).$$

它用 Vector Neuron 层处理三维向量特征，天然保持旋转等变；把手位置相对质心中心化以处理平移。每帧编码双手的中心化位置、朝向轴及可选重力，经 VN 线性层融合、VN-Transformer 处理并做时间池化。旋转头输出两个向量，以 Gram–Schmidt 正交化生成旋转矩阵；平移头预测相对于根坐标的偏移，再映射回相机坐标，避免直接回归相机绝对平移。

同一双手轨迹可能对应多种合理躯干姿态，尤其人体只露出一部分时。作者因此用 **flow matching** 生成根坐标假设，而不是只回归一个结果。推理时从随机旋转和质心附近的随机平移出发，用 20 步欧拉积分求解学到的常微分方程，生成多个候选。

【原文图 2：双手轨迹和重力输入等变网络，经流匹配生成多个机器人根坐标候选；聚类并以逆运动学评分选出最佳候选，最后平滑关节轨迹。】

4.2 机器人专属模型训练

网络完全在 MuJoCo 仿真中训练，不需要真实世界监督。针对每台机器人，程序化生成成对的手轨迹和真实根位姿：从加噪参考关节配置取得手部锚点；以偏向锚点的 Ornstein–Uhlenbeck 随机游走生成平滑控制点；用以上一解初始化的仅位置逆运动学转换为关节节点，再以三次样条插值。每段轨迹随机采样相机位姿，把手轨迹和根坐标一并转换到相机系。

训练中加入跟踪噪声、突跳、手遮挡与重力噪声，模拟野外恢复错误、暂时跟踪失败、单手或局部观察，以及重力估计缺失。30% 的样本会直接去掉重力，使模型在没有该信息时仍能工作。

4.3 轨迹处理与机器人重定向

推理时把视频切成重叠时间窗，为每窗采样多个根坐标假设，再做 k-means 聚类、保留代表候选。相机或人体都可能运动，窗级估计因此作为关键帧，通过平移线性插值与旋转 SLERP 形成逐帧平滑根轨迹。对每个候选，系统把手位姿转换到移动根坐标系，用热启动及零空间正则化逐帧求逆运动学。依据 IK 收敛情况、残差、可操作度、关节限位余量和轨迹平滑度评分，选出最佳候选。失败的 IK 帧通过插值补齐，并反复均值滤波去除高频抖动。灵巧手手指关节另由 MANO 关键点经机器人专属几何映射得到；机械臂关节则跟随腕部 IK 目标。

5. 实验与验证

5.1 浏览器数据服务

作者开发在线服务，可用自然语言搜索视频语料、查看片段、启动在线处理，并浏览或下载四维结果。可视化内容包括 MANO 手网格轨迹、六自由度物体轨迹、重建物体几何、点云、三维包围盒、深度、光流和抓握事件。这让失败案例可以直接检查，也让 EgoInfinity 成为交互式数据整理工具。

5.2 整理后的 Action100M 子集

数据服务目前展示 106 段已处理操作视频，含 277 个物体、12107 帧，片段时长中位数 5.8 秒。论文统计了片段时长、物体类别、常见动作动词和逐帧交互状态。88% 的片段和 47% 的物体被判定存在操作，左手、右手和双手抓握均有覆盖。

【原文图 3a：网页三维查看器、片段列表、文字描述与中间结果。原文图 4：上述 106 段视频的时长、物体类别、动作动词和交互状态统计。】

5.3 跨形态动作重定向

实验对象是 Unitree G1、NASA Robonaut2 和双 Franka FR3。每种机器人都有自身的根坐标估计和 IK。表 2 的逐帧结果如下：

机器人	IK 成功率	位置误差	方向误差	关节限位余量	可操作度	平滑度
Unitree G1	0.821	2.86 cm	6.73°	0.619 rad	0.012	0.00693
Robonaut2	0.774	6.67 cm	8.25°	0.134 rad	0.058	0.00343
双 Franka	0.706	10.27 cm	12.17°	0.572 rad	0.080	0.00582

这里位置和方向误差是目标手姿与实际 IK 姿态间的平均误差；余量是到关节限制的平均最小距离；平滑度以平均关节速度平方衡量。图 3b 展示同一恢复动作在仿真和真实机器人的不同形态上的重定向。

5.4 真实机器人重定向与技能学习

作者首先把提取的手部运动作为先验，训练真实 LEAP 灵巧手的抓握策略，使其能抓取苹果、香蕉、罐头等不同物体（原文图 3c）。随后把提取动作直接重定向到真实双臂 Franka FR3，演示切割、倾倒和擦拭（原文图 3d）。这些结果覆盖从野外 RGB 视频、四维交互恢复、机器人专属重定向到策略训练和真实执行的完整链条。

6. 结论

EgoInfinity 是一个通用四维操作数据引擎：无需动作捕捉、深度传感器、CAD 模型、可穿戴设备或人工指定物体，就能把纯 RGB 互联网视频转换成与具体执行者无关、可供机器人使用的手—物表示。与二维伪动作相比，它强调有实际尺度的三维几何、物体六自由度状态和交互感知优化，使从人类视频提取的数据具有更可靠的物理依据。无脚本、无专门设备的视频还包含实验室数据难以复现的多样操作行为、教学演示和自然多模态语境。加上功能性跨形态重定向，EgoInfinity 为将网络规模人类视频转成可执行机器人行为提供了可扩展基础设施，可支撑后续机器人学习、多模态落地和人机交互研究。