HuRo：将人类视频机器人化，以可扩展方式预训练 VLA

译自论文正文第 1 ~ 5 节，止于结论。图表保留原文编号，段落按中文阅读习惯整理。

摘要

人类视频数据丰富且多样，可以补充昂贵的真实机器人数据。为了弥合人和机器人之间的形态差距，已有方法要么在与下游任务匹配的场景中将视频机器人化，要么分别处理观察和动作的对齐。本文系统研究：机器人化的人类视频能否成为有效、可扩展且与机器人对齐的监督数据。

作者开发一套流水线，将来源各异的人类视频转换成与机器人对齐的观察图像和动作轨迹，并根据不同数据源已有的标注程度补出缺失的中间信号。由此得到 **HuRo**：来自五个人类视频源、约 63 万条机器人化 episode、1.42 亿处理帧。四项真实机器人任务中，随着这类预训练数据增加，整体任务完成度从 51.5% 提升到 80.3%；在空间和视觉变化下，分布外完成度从 34.9% 提升到 72.2%。消融实验还表明，视觉机器人化提高了分布外鲁棒性，而使用重定向动作进行端到端预训练，优于只迁移视觉表示。

1. 引言

视觉—语言—动作（VLA）策略已成为机器人操作的常见框架，研究表明更多预训练数据有助于其性能。但大规模、多样的真实机器人交互数据采集成本很高。相比之下，人类视频更易获取，覆盖更多物体、场景、视角和操作行为，因此越来越多研究用它提供视觉和运动先验。

真正用视频训练机器人策略时，需要解决人机之间的具身差距。它同时存在于画面和动作：必须使人类观察图像与目标机器人外观对齐，也必须把人的运动映射为机器人的动作。已有流水线通过运动重定向，以及渲染或图像编辑，处理这两种差距；最近也有工作探索视频生成。不过，联合处理画面与动作的方法大多只在与下游机器人任务匹配的数据中展示，尚未证明能成为大规模通用预训练数据源。另一些工作恢复动作作为监督，却保留人类视角画面；还有一些把机器人化画面主要用于视觉或辅助任务。

本文因此构造同时对齐观察与动作的机器人化 episode，并用 VLA 预训练验证。流水线移除画面中的人手，叠加渲染机器人，再将人手运动重定向为机器人动作；它能利用现有标注并估计缺失输入，让标注层次不同的数据源进入统一格式。HuRo 包含五个来源的 63 万余条 episode 和 1.42 亿帧，比先前机器人化视频预训练的数据规模大一个数量级以上。

实验有三个主要发现。第一，数据增加会同时改善分布内和分布外性能，后者包含空间位置和视觉外观变化。第二，机器人画面叠加能提高分布外鲁棒性：只用 10% 数据的叠加版本，甚至超过使用全部数据但不叠加的版本。第三，保留重定向动作、端到端预训练 VLA，明显好于只迁移视觉编码器。

【原文图 1：大量人类活动视频经人手移除、机器人叠加和动作重定向，变成包含语言、机器人状态和动作的 HuRo episode；使用更多 HuRo 预训练后，真实机器人任务表现提高。】

2. 相关工作

视觉机器人化。 H2R 用渲染机器人替换人手，再以 MAE 和 R3M 预训练视觉编码器。Masquerade 恢复三维手轨迹，以机器人化片段预训练未来二维末端位置预测。其动作原则上也可重定向为机器人动作，论文在附录 B 评估这种扩展。生成式方法则从人类视频合成机器人外观的操作视频。

人类视频动作监督。 VITRA 把人手看作灵巧末端执行器，将机器人动作映射到统一的人手动作空间。EgoScale 将人手运动重定向为目标机器人动作，用于大规模第一视角预训练。其他工作也会恢复并重定向手或手—物运动，但可能保留人类画面。

观察与动作联合机器人化。 Phantom 将人手运动恢复出的机器人动作与渲染机器人图像配对；DexUMI、WARPED、RwoR 使用不同的采集或渲染流水线完成类似对齐；MimicDreamer 进一步对齐视角与动作，并生成机器人域视频用于 VLA 训练。这些工作主要研究任务匹配场景。HuRo 则研究来源异构的人类视频能否组成大规模、观察和动作同时对齐的预训练数据。

3. 方法

3.1 HuRo 数据集构建流水线

如原文图 2，流水线有三个阶段。**人类视频标注**补出不同来源缺失的相机几何、手部运动与语言指令；**动作转换**把手部运动重定向为目标机器人关节轨迹；**视觉转换**删除可见的人体部分，再把重定向后的机器人叠加到干净画面中。最终的观察、状态、动作和语言组成 HuRo episode。

【原文图 2：输入视频先得到相机参数、三维手轨迹和指令；动作转换使用目标机器人 URDF 与重定向，视觉转换进行手臂分割、视频修补和机器人渲染，最后形成配对的机器人视频与动作。】

3.1.1 人类视频标注

给定长度为 T 的第一视角视频 $V = \{I_t\}_{t=0}^{T-1}$，系统估计相机和手标注，找出操作片段，并为每个保留的有界长度片段生成一条语言指令。

相机内参与手跟踪。每段视频先用 droidcalib 估计内参 K；相机几乎不动时改用 AnyCalib。内参用于校正原帧，得到透视针孔图像。100DoH 逐帧检测左右手及边界框，BOT-SORT 在时间上稳定左右手归属，并提供一致的裁剪图像给三维手姿模型。

手姿估计。 HAWOR 对每一侧手 $h \in \{L, R\}$、每一帧 t 估计基于 MANO 的姿态 P_t^h，位于校正后的源相机坐标系。系统从中取得手腕轨迹，给 VLM 提供运动线索；还取得指尖位置和局部手形线索，供动作重定向使用。

相机轨迹。使用遮蔽手部区域的 DROID-SLAM 估计第一视角相机运动。单目 SLAM 不知道绝对尺度，因此再用 MoGe-2 恢复度量尺度，得到世界系下的相机位姿 $T_t^{W \leftarrow C_{src}}$。GeoCalib 将 SLAM 世界系与重力方向对齐，为重定向和机器人叠加建立一致参考。

分段与文字标注。连续有有效手标注的帧组成操作段，再切成长度有限的小片段。系统在采样 RGB 帧上绘出近期手腕轨迹，让 Qwen3.5 为每段生成单条指令 l_i；之后进行图文一致性核验，并过滤没有手—物操作的片段。将时间重新编号为片段内的 $0, \ldots, T_i - 1$，标注结果包含图像、内参、相机位姿、左右手姿态和指令：

$$H_i = \left(\{I_t\}_{t=0}^{T_i-1}, K, \{T_t^{W \leftarrow C_{src}}\}_{t=0}^{T_i-1}, \{P_t^h\}_{t=0, h \in \{L,R\}}^{T_i-1}, l_i \right).$$

3.1.2 动作转换

对于每个 P_t^h，系统提取指尖位置和局部手形线索，再利用相机位姿转到世界坐标。这个世界系与机器人底座系并不对齐，因此需为整段估计变换 $T_{\xi_i}^{B \leftarrow W}$，参数是三维平移和偏航角。

重定向通过 PyRoKi 分两步求解。第一步在稀疏帧上联合优化坐标对齐和机器人关节配置 q_t，目标包含手部运动、第一视角观测和运动学正则。第二步固定对齐变换，对全部帧优化关节轨迹，并加入时间平滑。优化得到的关节状态按目标机器人接口转成策略状态 s_t，手腕位姿由正向运动学计算。由于原视频没有机器人动作，作者把下一时刻重定向状态作为动作标注：$a_t = s_{t+1}$。

3.1.3 视觉转换

首先用 SAM2 分割人的手臂，并由 Detectron2 提供辅助人物区域提示；ProPainter 修补这些区域，得到去掉人体的干净画面 $\bar{I}_t$。随后 Isaac Sim 按相机内参 K、重定向关节配置 q_t 和对齐后的第一视角相机轨迹渲染机器人，再叠加到画面中。

这里视觉转换与动作转换共用同一个坐标变换，因此观察相机为：

$$T_t^{B\leftarrow C_{obs}} = T_{\xi_i}^{B\leftarrow W} T_t^{W\leftarrow C_{src}}.$$

机器人化图像 $\tilde{I}_t$、状态、动作目标与语言指令合成最终数据：

$$E_i = \{(\tilde{I}_t, s_t, a_t, l_i)\}_{t=0}^{T_i-1}.$$

3.1.4 HuRo 数据集

流水线可以适配不同机器人，但主数据集采用 **ALLEX**：双臂灵巧机器人，有两个 7 自由度机械臂、两只 15 自由度灵巧手、2 自由度颈部和 2 自由度腰部。视频来自 Ego4D、EPIC-KITCHENS、EgoDex、EgoVerse、Ego10K。最终超过 **63 万 episode**、**1.42 亿处理帧**，按 30 FPS 约为 **1317 小时**。按帧计，约 56% 来自 EgoDex、27% 来自 EgoVerse、10% 来自 Ego4D、6% 来自 Ego10K、2% 来自 EPIC-KITCHENS；百分比因四舍五入略超 100%。

3.2 VLA 策略训练

架构。模型基于 GR00T-N1.6-3B，使用末端执行器动作接口。VLM 骨干把当前机器人化 RGB 图像 $\tilde{I}_t$ 和片段指令 l_i 编成视觉—语言嵌入 ϕ_t。动作头同时读取 ϕ_t 与当前机器人状态 s_t，预测 $H = 40$ 步动作块。

动作表示。输出包含左右手腕位姿与左右手关节目标。每侧未来手腕目标相对于当前手腕位姿表示，两者都处于当前观察相机坐标中；相对手腕目标由三维平移和连续 6D 旋转构成，手指则使用绝对关节目标。

训练。 VLM 骨干从官方 GR00T-N1.6-3B 权重初始化，动作头从零初始化；视觉编码器也参与训练。优化目标是 flow matching。预训练用 AdamW、全局 batch 2048、学习率 10^{-4}、权重衰减 10^{-5}，线性热身后维持恒定学习率，训练 8 万步。下游微调 3 万步，batch 128，初始学习率 10^{-4} 并按余弦曲线衰减。

4. 实验

4.1 设置

在 ALLEX 上评估四项真实操作任务：苹果抓放（43 条演示）；叠杯（40 条演示，双手逐次加入杯子后放回桌面）；杯面递交（16 条演示，一手抓取、双手交接、放到目标架）；微波炉装载（20 条演示，开门、放入物品、关门）。苹果抓放按二元成功评估，其他任务

按阶段部分完成度评分。分布内测试使用微调分布中的保留条件；分布外测试改变空间位置和视觉外观。

数据规模对照使用 HuRo 的 0%、10%、50%、100%。0% 跳过 HuRo 预训练，直接微调。为检验画面机器人化，还设置“无叠加”版本：保留原始人类视频观察，但动作监督仍使用同一重定向结果。受控版本都从 GR00T-N1.6-3B 初始化 VLM，动作头从零开始；另外报告直接从发布权重微调、保留原有动作模块的 π0.5 和 GR00T N1.6 作为参考。

【原文图 3：四项任务的现场画面；数据规模、机器人叠加效果及与参考模型的完成度比较。】

4.2 机器人化视频的数据规模

各版本的预训练步数和全局 batch 相同，下游微调也相同。HuRo 数据从无到全部，四项任务平均完成度从 **51.5% 升到 80.3%**；分布内从 **68.1% 升到 88.4%**，分布外从 **34.9% 升到 72.2%**。完整 HuRo 预训练模型在两种测试下也超过 π0.5 和 GR00T N1.6 参考模型。

叠杯是代表案例：它要求反复抓取和双手协同，分布外测试还改变杯子位置与桌布花纹。用 10% 数据时分布外完成度为 **60.4%**，用全部数据达到 **79.2%**。小数据模型更容易抓取不稳、接近目标不准；位置和外观变化后会出现偏心接触、滑脱或叠杯失败。数据更多时，接近、抓取、提起与叠放更稳定。

【原文图 4：叠杯任务随预训练数据增长的分布内、分布外完成度，以及杯子位置和桌布外观的分布外变化。】

4.3 视觉机器人化的收益

完整 HuRo 与“无叠加”版本使用相同视频和重定向动作，只在画面中是否把人替换成机器人上不同。两者分布内完成度接近：**88.4% 与 89.4%**；但分布外完整模型为 **72.2%**，“无叠加”只有 **55.7%**。即使后者用满数据，仍低于只用 10% 数据的叠加版本的 **59.5%**。可见画面机器人化带来的好处，超出了动作监督本身。

4.4 重定向动作监督的收益

作者比较三种设置：不做 HuRo 预训练；只保留预训练视觉通路、在下游微调前重新初始化动作头；以及视觉和动作共同端到端预训练的完整模型。

专门设计的“多样物体抓放”任务要求机器人依次抓起两种抓取要求不同的物体并放入篮中。四种物体包含相机盒、无把手杯、清洁刷、有把手杯。分布内对每对物体测试各自三个初始位置的全部组合，共 36 次；分布外使用清洁刷与有把手杯组合，把杯子换成两个未见实例，并把两个物体放在新位置，共 18 次。每个物体只有以恰当方式抓取且放入篮中才得一分，一次执行最多两分。

仅迁移视觉表示相较无预训练只有小幅改善，完整预训练则显著提高两种条件下的完成度，达到分布内 **61.1%**、分布外 **50.0%**。这一优势在各物体组合中都存在。定性观察中，前两个模型经常从上方抓清洁刷，而不是抓手柄；对未见杯子，视觉迁移版本能靠近杯子，却不能把手指插入杯柄。完整模型能按照演示完成相应抓握。

【原文图 5：多样物体抓放的设置、三种预训练方式的分布内与分布外完成度、物体实例和抓握行为对比。】

4.5 与生成视频数据比较

作者还建立 **I2V + IDM** 基线：依照 DreamGen 和 RoboCurate 的 ALLEX 设置，用适配目标机器人的图像到视频模型生成操作视频，再让逆动力学模型从生成画面预测伪动作。两类数据分别在 70 万、350 万、700 万帧的相同预算下预训练，训练设置不变。下游任务和评分沿用上一节，但演示采集和评估均在另一个实体环境中完成。

每个规模上，HuRo 都优于 I2V + IDM。只用 **70 万帧**的 HuRo，已在分布内外超过 **700 万帧**的 I2V + IDM。数据越多，差距越明显，尤其在分布外：生成视频基线从 350 万增至 700 万帧后不再有进一步的分布外收益，HuRo 却继续改善。因此，在本实验比较的设置中，机器人化真实人类视频具有更有利的数据扩展趋势。

【原文图 6：在 70 万、350 万、700 万预训练帧预算下，HuRo 与 I2V + IDM 的分布内和分布外完成度曲线。】

5. 结论

本文研究机器人化的人类视频能否成为可扩展的、与机器人对齐的监督来源。作者构建了一条流水线，将异构第一视角视频转成彼此对齐的机器人观察与动作，并由此得到大规模 HuRo 数据集。实验表明，增加机器人化人类视频会改善下游真实机器人操作和泛化；视觉机器人化与重定向动作监督都十分关键。这些结果说明，机器人化人类视频有潜力成为真实机器人策略学习有效且可扩展的数据来源。