SuperMimic：用一个可微世界模型扩展人形机器人全身控制

原文：SuperMimic: Scaling Humanoid Whole-Body Control with One Differentiable World Model

作者：Qiayuan Liao、Yiyang Shao、Junfeng Long、Kevin Zakka、Roberto Horowitz、Pieter Abbeel、Koushil Sreenath，加州大学伯克利分校。Yiyang Shao 与 Junfeng Long 同等贡献；Pieter Abbeel 与 Koushil Sreenath 共同指导。

项目主页：https://supermimic.github.io

本文译至第 5 节结论。保留正文公式、引用编号与图表含义；图片以原文编号标记。论文发表于第十届机器人学习会议 CoRL 2026，美国得克萨斯州奥斯汀。

摘要

跟踪大规模人类动作数据集，已经成为实现通用且富有表现力的人形机器人全身控制的主要途径，但同时覆盖许多动作的训练成本很高。目前的流水线采用无模型强化学习：要么通过有信息损失的蒸馏，合并为单个动作训练的专家；要么动用集群规模的算力，直接训练一个统一策略。

SuperMimic 通过一个可微世界模型刻画所有动作共享的动力学，从而在不同动作间分摊学习成本。模型利用标准刚体仿真器记录的状态转移拟合。世界模型与跟踪策略在同一个循环中共同训练；对短时想象轨迹做时间反向传播，为策略提供解析梯度。快速想象轨迹和解析梯度使策略学习更加高效。

在一张 GPU 上训练 3 小时，SuperMimic 的回报就超过了一个在 128 张 GPU 上训练 7 天的最先进动作跟踪基线。其 GPU 小时消耗减少超过 1000 倍；在 129514 条基准动作中只失败 25 条，而基线失败 179 条。使用两张 GPU 训练 9.8 小时后，SuperMimic 实现零失败。动作数据从 1 小时增加到 264 小时时，世界模型预测误差保持稳定，达到目标回报所需的 GPU 小时仅缓慢增加。策略可以迁移到真实 Unitree G1，执行多种动作，包括杂技动作。SuperMimic 消除了扩大人形全身控制规模时的算力瓶颈，使研究动作跟踪的缩放规律变得切实可行。

关键词：人形机器人、全身控制、基于模型的强化学习。

【原文图 1】学习到的可微世界模型用于训练全身控制器。左侧展示策略通过想象轨迹不断改善；右侧比较 SONIC 的 128 张 L40、168 小时与本文的一张 H100、3 小时，GPU 小时相差超过 1000 倍。

1. 引言

人形机器人有望在人类设计的环境中工作，但这需要覆盖多种人类运动的全身控制器，从行走、舞蹈到蹲下和平衡恢复。基于物理的动作模仿通过训练强化学习策略跟踪大规模动作捕捉数据集中的参考片段来解决这一问题 [2,1]。现有系统通过将许多片段专属专家蒸馏为单个控制器 [3]，或者在大型动作库上直接训练通用策略 [1] 扩大规模。两条路线都表明，更丰富的动作库带来更强的控制器，但动作覆盖增加也使计算成本上升。最先进的跟踪器 SONIC [1] 例如需要在 128 张 GPU 上训练约 168 小时，总计约 21000 GPU 小时。

参考动作虽有差别，却共享同一个人形机器人混合刚体动力学。无模型强化学习没有显式利用这一共同结构，而是反复从有噪声的仿真轨迹估计动作的后果。因此，扩大动作规模实际上变成扩大算力。

SuperMimic 用仿真器记录的状态转移训练单个可微世界模型，解决这种低效。对短想象轨迹做时间反向传播（BPTT），可以通过学习到的模型获得解析策略梯度，使一个动力学模型能够服务整个动作捕捉库。这些梯度来自学习到的模型，而不是对仿真器求导，因此方法仍适用于普通刚体仿真器，包括接触不光滑、实现不可微的仿真器。

一张 GPU 训练不到 3 小时，SuperMimic 就超过 SONIC 发布权重的归一化回报，GPU 小时减少超过 1000 倍。在 129514 条动作上，一张 GPU 训练 3 小时后失败 25 条，两张 GPU 训练 9.8 小时后全部成功；SONIC 发布权重则失败 179 条。数据时长扩大 264 倍时，世界模型误差保持稳定，达到固定回报所需算力仅缓慢增长。策略可迁移到真实 G1。在下游接口的初步研究中，以强化学习训练的速度编码器也优于蒸馏基线。

本文的贡献如下。

- 面向可部署人形控制的基于模型强化学习。证明了通过学习到的可微世界模型做 BPTT，可以在长期由无模型 PPO [4] 主导的全身跟踪任务中训练策略，并迁移到真实 G1。

- 算力不再是扩展的瓶颈。单张 GPU 超过集群规模 PPO 系统 SONIC 的回报，GPU 小时减少超过 1000 倍；动作库增长时训练成本缓慢上升，无需庞大的 GPU 基础设施。

- 分析收益来源。三项关键性质是：数据时长增加 264 倍时预测误差稳定；模型轨迹生成比仿真器快 10 倍以上；使用解析梯度后，只需约六十四分之一的想象步数，就能达到世界模型上 PPO 的最佳回报。

- 超越蒸馏的下游控制。同一世界模型可以用接口自身的任务奖励训练目标编码器。在速度指令上，该编码器比蒸馏基线跟踪得更准。

2. 相关工作

大规模基于物理的动作跟踪。物理动作模仿学习在接触丰富的刚体动力学下复现参考动作。DeepMimic [2] 用无模型强化学习展示了富有表现力的角色技能；PHC [11] 将其扩展到大型动作集，并具备稳健恢复能力。SONIC [1] 进一步说明，同时扩大动作数据、策略容量和算力，可以得到迁移到人形硬件的通用控制器。这些工作确立了动作跟踪作为广泛全身行为覆盖的实用路线，但需要大量仿真轨迹和计算。SuperMimic 学习所有动作共享的可微动力学，使策略可以利用解析梯度，而非无模型的轨迹估计。

【原文表 1：不同阶段训练方式的比较】Mimic、Latent、Downstream 分别表示动作模仿、潜表示和下游控制阶段。Task signal 指下游接口使用自身任务奖励（RL），还是参考动作跟踪信号（Distill）。合并单元格代表联合训练；相邻但分开的单元格代表先冻结前一阶段再训练下一阶段。

方法 / 模仿阶段 / 潜表示阶段 / 下游阶段 / 下游训练信号 / 真实机器人

NPMP [5] / SVG(0) / BC / SVG(0) / RL / 否

ControlVAE [6] / 模仿与潜表示联合 MBRL / 联合 / MBRL / RL / 否

PhysicsVAE [7] / PPO / BC[1] / PPO / RL / 否

PULSE [8] / PPO / DAgger / PPO / RL / 否

MaskedMimic [9] / A2C / 潜表示与下游联合 DAgger / 联合 / 蒸馏 / 否

BeyondMimic [3] / PPO / DAgger / CGD / 蒸馏 / 是

SONIC [1] / 各阶段联合 PPO / 联合 / 联合 / 蒸馏 [2] / 是

LATENT [10] / PPO / DAgger / PPO / RL / 是

SuperMimic / 各阶段联合 MBRL / 联合 / 联合 / 蒸馏或 RL / 是

SVG(0) 是随机价值梯度；BC 是在固定专家轨迹上的离线行为克隆，区别于 DAgger 使用学生策略轨迹；CGD 是分类器引导扩散；A2C 是优势 actor–critic；DAgger 是数据集聚合。[1] 此处行为克隆还通过冻结的学习动力学模型加入单步下一状态一致性项。[2] SONIC 的目标编码器与跟踪器以跟踪奖励和潜变量对齐损失联合训练，没有任务专属奖励。

用于动作控制的可微学习动力学。SuperTrack [12] 通过可微仿真替代模型优化策略。ControlVAE [6] 联合学习动力学、潜技能表示和生成式控制器；MoConVQ [13] 把模型训练扩展到数十小时数据的离散动作表示；SuperDyno [14] 将可微神经动力学扩展至数万动作片段。这些研究证明了学习动力学与解析策略梯度在仿真角色控制中的作用。SuperMimic 将其推进到单 GPU 大规模人形跟踪及 sim-to-real 部署：世界模型以仿真上下文为条件，而实际部署的 actor 使用带噪本体感知和目标输入。本文评估精度、吞吐率、可微更新对效率的贡献，以及动作覆盖增加时的预测误差，并展示真实部署。

基于模型的策略优化与部署。Dreamer [15]、DreamerV3 [16] 学习潜动力学，进行想象式 actor–critic 学习；TD-MPC [17] 结合短期规划和终端价值预测；DayDreamer [18] 直接在真实机器人上学习世界模型。SHAC [19] 使用可微仿真做短时域 actor–critic 更新，启发了本文用 critic 自举的目标。解析梯度控制也可结合简化可微替代模型与高保真前向仿真器，四足行走已有这类示范 [20]。SuperMimic 从仿真转移学习替代模型，并通过短想象轨迹反向传播，保持对普通刚体仿真器的兼容性。

RWM [21] 和 RWM-U [22] 表明，在学习到的神经仿真器中训练策略能够迁移到实体机器人。两者都在想象轨迹上用 PPO；RWM-U 还采用不确定性惩罚的离线优化。SuperMimic 则对通过学习动力学得到的回报求导。RWM 与 RWM-U 用其他策略的轨迹预训练模型，SuperMimic 在训练中用自身策略采集的数据拟合模型。

可复用动作表示与下游控制。可复用控制器连接动作跟踪与下游目标接口。NPMP [5] 和 PhysicsVAE [7] 从专家行为学习潜在运动表示；PULSE [8] 和 LATENT [10] 用它支持下游强化学习。MaskedMimic [9] 通过动作补全支持局部身体和多模态目标，BeyondMimic [3] 用引导扩散跟随目标。SONIC [1] 通过跟踪奖励和潜变量对齐损失联合训练目标编码器与跟踪器。ControlVAE [6] 冻结技能控制器，通过模型优化下游策略。SuperMimic 用同一动力学模型联合训练不同目标编码器和共享解码器。接口可以优化参考跟踪奖励，也可优化自身任务奖励。初步研究让速度接口与动作跟踪同时训练，分别比较两种奖励。

3. 方法

3.1 训练循环

SuperMimic 在多技能动作库上训练一个以目标为条件的全身控制器，并支持多种目标接口。它用可微世界模型捕捉共享动力学，通过短想象轨迹改善策略。训练在一个循环中交替进行三个阶段：当前策略把仿真转移存进回放缓冲区；用回放中的短窗口拟合世界模型；冻结模型，通过想象回报反向传播改善策略。每条想象轨迹像 Dyna [23,24] 一样从缓冲区状态启动。缓冲区、模型和策略持续更新，使动力学学习与控制共同进步。早期策略收集的数据仍可拟合模型，因为动力学不依赖采集它的策略。

【原文图 2】当前策略在仿真中采集数据；固定大小缓冲区的新数据替换最老数据；世界模型拟合 k 步窗口；冻结模型，对 H 步想象轨迹做 BPTT 更新策略，同阶段训练 critic 为时域之后的回报自举。虚线表示梯度。仿真上下文 ξ 是域随机化参数。

记目标条件 POMDP 为 M，状态、目标、动作为 s_t、g_t、a_t。状态给出本体观测 o_t 和终止标记 d_t，终止时 $d_t=1$。在状态 s_t 执行动作 a_t 得到奖励 r_{t+1} 和下一状态。确定性策略为 $a_t=\pi\theta(o_t,g_t)$，动作参数化归一化关节设定点；跟踪目标来自参考动作。

采集时，仿真器执行带噪动作 $a_t+\varepsilon_t$，$\varepsilon_t\sim\rho\varepsilon$，缓冲区记录的也是实际执行动作。动作噪声拓宽模型拟合所覆盖的动作范围，只服务于模型拟合，是可选项。回报使用软生存权重：

$$c_0 = 1, \qquad c_{t+1} = c_t(1 - d_{t+1}), \qquad J(\theta) = \mathbb{E}\left[\sum_{t\geq 0} \gamma^t c_t r_{t+1}\right], \quad \gamma \in [0, 1).$$

仿真器记录硬终止，而模型预测终止概率 $\hat{d}_t\in[0,1]$，使想象中的生存权重可微。帽号表示仿真量的世界模型对应量。观测分解为 $o_t=\bar{o}_t+\eta_t$，其中 $\bar{o}_t$ 为无噪观测，已知传感器噪声 $\eta_t\sim\rho\eta$ 在模型之外采样。默认接口为完整参考动作跟踪；速度等接口共享相同动力学，并与其联合训练。

3.2 学习可微世界模型

仿真器的多刚体动力学已知，但不一定提供梯度。SuperMimic 因此学习可微替代模型，为 BPTT 提供预测和雅可比矩阵。得到的解析策略梯度，是仿真期望回报替代目标的梯度。仿真随机性的来源已知，所以模型保持确定性：以每 episode 的上下文 ξ（摩擦、校准偏移和躯干质心）为条件，预测无噪观测。

模型包括动力学，以及奖励、观测和终止头；各头可由网络学习，也可解析计算：

$$\hat{s}_{t+1} = f_\omega(\hat{s}_t, a_t, \xi), \quad \hat{r}_{t+1} = r_\omega(\hat{s}_t, a_t, g_t), \quad \hat{\bar{o}}_t = g_\omega(\hat{s}_t, \xi), \quad \hat{d}_t = d_\omega(\hat{s}_t, g_t).$$

训练使用 $k=8$ 步自回归回放窗口，以记录状态 $\hat{s}_0=s_0$ 初始化，按记录动作向前展开，并最小化：

$$\mathcal{L}_{WM}(\omega) = \mathbb{E}_{\mathcal{B}} \sum_{j=1}^{k} \left[\|\hat{s}_j - s_j\|^2 + (\hat{r}_j - r_j)^2 + \|\hat{\bar{o}}_j - \bar{o}_j\|^2 + \mathrm{BCE}(\hat{d}_j, d_j) \right]. \tag{1}$$

解析计算的头不包含相应损失。r_j 是仿真奖励，$d_j \in 0,1$ 是仿真终止标签，BCE 是二元交叉熵。

3.3 通过世界模型学习策略

每次策略更新都固定模型权重 ω，在 $H=32$ 步想象轨迹上优化 $\pi\theta$ 和 $V\psi$。critic 估计 H 步之后的回报，因此模型只需在这 H 步内准确。想象时域超过拟合模型的 k 步窗口；实际中模型在任意长展开中仍稳定，因为 k 步自回归拟合会训练它修正自身预测误差。

每条想象轨迹从缓冲区采样状态 $s_0 \sim \rho_0$，并带上记录的 ξ。每步模型产生无噪观测，再加回传感器噪声，策略据此行动。目标为：

$$\hat{J}(\theta) = \mathbb{E}_{s_0 \sim \rho_0, \pi_\theta} \left[\sum_{t=0}^{H-1} \gamma^t \hat{c}_t \hat{r}_{t+1} + \gamma^H \hat{c}_H V_\psi(\hat{s}_H, g_H, \xi) \right]. \tag{2}$$

动作跟踪使用 BeyondMimic [3] 的跟踪奖励，但去掉自碰撞惩罚。模型可微，因此 BPTT 经模型对状态和动作的雅可比，计算穿过 H 步轨迹的一阶梯度 $\nabla\theta\hat{J}$。PPO 则把动力学当黑箱，用动作优势对随机策略的得分函数 $\nabla\theta \log \pi\theta$ 加权，构成似然比估计。BPTT 直接求回报对各动作的导数，因此短时域内梯度方差小得多。

critic 仅拟合想象转移中的广义优势估计 [25] 回报，沿时间反向计算：

$$\mathcal{L}_V(\psi) = \mathbb{E} \sum_{t=0}^{H-1} (V_t - \hat{R}_t)^2, \quad \hat{R}_t = \hat{r}_{t+1} + \gamma(1 - \hat{d}_{t+1})[(1-\lambda)V_{t+1} + \lambda \hat{R}_{t+1}]. \tag{3}$$

其中 $V_t = V\psi(\hat{s}_t, g_t, \xi)$，递推从 $\hat{R}H = VH$ 开始。目标每条轨迹计算一次，拟合 ψ 时固定不变。

策略与 critic 共同组成类似 SHAC [19] 的短时域 actor–critic。SuperMimic 用生存权重替代硬终止，也没有指数移动平均的 critic 目标网络。过去解析梯度动作跟踪常省略 critic，只优化 H 步奖励和 [12,6]。无 critic 也可能达到相近名义跟踪回报，但更短视：扰动后的恢复和平衡奖励可能落在想象窗口之外，此时 critic 就很重要。

4. 实验结果

本文比较与 PPO 流水线的扩展效率，分析世界模型性质，展示真实 G1 迁移，并初步研究下游目标接口。仿真器为 MuJoCo 的 GPU 实现 MuJoCo Warp [26]；成本在 Lambda 按需实例的 NVIDIA H100（80 GB SXM5）上测量。作者运行多个随机种子，发现训练很稳定，认为原因是动作跟踪每步都有稠密奖励，因此图中没有报告种子变化。归一化回报是整个 episode 的逐步奖励不折扣求和，再除以其理论最大值；提前终止的策略因此得分低。

4.1 用更少 GPU 小时达到 SONIC 水平

SONIC 是已发表、在 128 GPU 集群上训练的 PPO 流水线。两者都建立在 BeyondMimic 跟踪形式上，因此它是最接近的已发表比较对象。单 GPU 3 小时内，SuperMimic 超过其发布权重的回报。在共享的 129514 条动作上，前者单卡 3 小时失败 25 条、双卡 9.8 小时零失败，后者

失败 179 条。3 小时这个说法较保守：从那时起，所有后续权重在回报和失败数上都领先 SONIC，且至少达到 SONIC 与 SuperMimic 最佳结果差距的一半。由此，实际训练时间减少超过 50 倍、GPU 小时减少超过 1000 倍。

计算成本口径。SONIC 报告 128 张 L40 训练 7 天，约 21000 GPU 小时；SuperMimic 是单张 H100 的 3 小时。实际时间比约 56 倍，GPU 小时比约 7200 倍。3 小时包含整个训练循环，但训练后的权重评估不计入。SuperMimic 用 BONES-SEED [27] 的 264.56 小时数据，即 SONIC 数据的公开子集，比其 611 小时少约 2.3 倍。硬件也不同：H100 的 FP32 峰值吞吐是 L40 的 0.74 倍，tensor core 峰值则为 5.5 倍；双方实际利用率未知。不过，2.3 倍数据差和最多 5.5 倍峰值算力差，仍不足以解释超过 1000 倍的 GPU 小时差。

受控比较使用 LAFAN1 [28]。PPO-Sim 与 SuperMimic 共享动作、观测、奖励、终止条件、域随机化、actor/critic 网络规模和评估流程，使用 BeyondMimic 的 PPO 超参数，每 GPU 8192 并行环境，是 SuperMimic 的两倍。PPO-Sim 从仿真采样估计梯度；SuperMimic 对模型想象回报反向传播。后者单 GPU 1.2 小时评估回报达到 0.82；PPO-Sim 在 18 小时预算内都未达到，一卡、四卡和八卡最终分别为 0.60、0.70、0.72，四卡翻到八卡几乎无益。数据时长增加时，SuperMimic 达到目标所需 GPU 小时缓慢增加，同一实验中模型误差保持稳定。

【原文图 3】a：三种策略在同一个 129514 动作、约 264 小时基准上的回报与算力；b：数据时长与达到目标所需算力；c：1 ~ 264 小时数据下，在线测得的八步状态预测误差稳定在 0.007 ~ 0.011，按预先规定的名义误差归一化。

【原文图 4】全部使用 LAFAN1 的 40 段、2.45 小时动作。a：单卡 SuperMimic 与 1、4、8 卡 PPO-Sim；每点是全部 40 段上的评估。b、c：不同想象时域、有无 critic 时的最终训练回报和达到 0.82 的时间。训练回报的初始状态随基于回报的重置采样变化，因此不等于 a 的固定评估分数。H=8 的两个版本以及 H=16 的无 critic 版本均未达到目标；默认 H=32。

4.2 世界模型的三项性质

一个模型分摊整个动作库。从 1 小时到 264 小时，八步误差保持 0.007 ~ 0.011。所有动作都由同一机器人执行，因此新增片段补充的是同一身体和接触动力学的证据，不必为每类动作增加新容量。这与达到目标回报所需算力缓慢增加一致。

想象加速轨迹生成。策略优化时，轨迹生成速度决定更新成本。在实际 batch 范围内，世界模型比 MuJoCo Warp 快 10 倍以上；64000 并行环境时快达 62 倍。

一阶梯度需要更少想象步数。为隔离策略更新方式的收益，作者让 PPO 也在世界模型上训练。SuperMimic 只需约六十四分之一的想象步数即可达到 PPO-WM 的最佳训练回报，因此收益不只是模型展开快。

【原文图 5】a：H100 上每秒控制步数；实用范围为 2000 ~ 16000 并行环境，64000 时仿真吞吐已趋平而模型仍可扩展。一个控制步为 50 Hz，MuJoCo Warp 用四个 5 ms 子步计算；模型使用训练时的 TF32。b：LAFAN1 走、跑、冲刺动作上的回报与想象步数；PPO-WM 比较四种 “并行环境数 × 每条步数”，16000×32 最好。曲线按想象步数的对数尺度、前后 0.05 个数量级做中心移动平均。

4.3 critic 支持更短时域和推扰恢复

不加 critic 时，H≤16 训练失败；加入后 H=16 可达到无 critic 的 H=32 水平，而 H=32 最快达到 0.82。H 从 64 增到 128，会使到达该回报的时间接近三倍，并降低最终回报；128 已是 H100 能容纳的最长时域。即便名义回报相同，行为也不同：仿真静态 T 姿势下施加 0.5 ~ 4 m/s 速度扰动，有 critic 的策略在 0.5 ~ 2.4 秒内恢复稳定；无 critic 的策略始终不稳定，即便 0.5 m/s 也持续踉跄，4 m/s 时跌倒。

4.4 真实机器人迁移

一个通用跟踪器无需为单个动作调参，即可部署到真实 Unitree G1。四种动作覆盖移动、躯干与四肢接触地面的全身运动及杂技。

【原文图 6】a：跳步跃起；b：侧滚；c：90° 翻转；d：原地 360° 翻转。连续帧时间间隔分别为 0.2、0.3、0.2、0.2 秒。

4.5 下游任务：RL 编码器与蒸馏基线

下游目标编码器与跟踪接口联合训练，共享解码器和世界模型。这部分研究是初步的。速度编码器通过模型优化速度跟踪奖励；蒸馏基线也使用速度编码器，但优化动作跟踪奖励，指令从参考动作读取。二者在覆盖速度空间的 672 个阶跃响应上评估：RL 编码器在 650 个响应上稳态误差更低，蒸馏编码器在 15 个上更低。只有蒸馏编码器跌倒，共七次，均为动作库几乎没有数据的快速转向。

【原文图 7】三个子图展示指令空间的不同平面，另一个分量固定为零；每个圆环代表一条指令。外圆面积对应两策略中较大的相对稳态误差，内孔对应较小误差，颜色标出更优策略。背景显示每格参考动作数据量。

5. 结论

SuperMimic 消除了扩展人形机器人全身控制时的算力瓶颈。单个学习得到的可微世界模型捕捉所有动作共享的动力学，通过时间反向传播，将整个数据集的学习分摊到一个策略中。策略可在一张 GPU 上训练，超过使用 128 GPU 集群训练策略的回报，并迁移到真实 Unitree G1。在受控数据时长实验中，训练成本仅缓慢增加。同一个模型还可以直接利用下游接口自身的任务奖励训练速度接口。现在，每次实验只需一张 GPU，便能以可承受的成本测量动作跟踪的缩放规律。