

策略学习的任意点轨迹建模

文^{*1,2,5} 兴林^{*1} 约翰·索^{*3}
凯陈⁶ 道⁶ 高^{2,4,5} 皮埃特·阿贝尔¹
¹ 伯克利大学 ² 华大学 IIIS ³ 斯坦福大学
⁴ 上海人工智能实验室 ⁵ 上海智研研究所 ⁶ 子




Fig. 1: 鉴于任务指令和图像框架中的任何点的初始位置, 我们的任意点轨迹模型 (ATM) 可以预测这些点的未来轨迹, 根据任务. 经过在无动作视频数据集上训练模型后, 预测的轨迹作为学习视觉运动策略的有效指导, 用于一组语言条件的操作任务.

Abstract—从示范中学习是一种强大的方法来教导机器人新技能, 并且拥有更多的示范数据往往改善了策略学习. 然而, 收集示范数据的高成本是显著的瓶. 视频作为丰富的数据来源, 包含了对行为, 物理和语义的知识, 但由于缺乏动作标签而从它们中提取特定控制信息是个挑战. 在这项工作中, 我们引入了一个新框架, 即 Any-point Trajectory Modeling (ATM), 通过预训练轨迹模型来利用视频示范来预测视频框架内的任意点的未来轨迹. 一旦训练, 这些轨迹提供了详细的控制指导, 使得学习具有最小的视觉动态标签数据的强大策略成为可能. 我们在模拟和现实世界中评估的超过 130 个语言条件任务中, ATM 超过了强大的视频预训基线的 80% 此外, 我们还显示了从人类视频和来自不同机器人形态的视频中有效转移操纵技能. 视觉化和代码可在: <https://xingyu-lin.github.io/atm>.

I. 介绍

近年来, 计算机视觉和自然语言理解取得了显著进展 [?] 在机器人领域, 扩大人类示范数据是学习新技能的关键.

* 前三位作者同样做出了贡献: 文领导了实施和实验. 兴林提出了这个想法, 监督了技术开发, 并为模型调试做了贡献. 约翰·索实施了机器人到机器人转移实验和 UniPi 基线.

随着更大的数据集的提高, [?] 然而, 通过远程操作设备收集的人类示范, 通常是以动作标签的轨迹 [?] 采集需要时间和劳动力. 130K 在 [?] 收集数据成为机器人学习的一个重大瓶.

视频包含有关行为, 物理和语义知识的信息, 呈现出另一个数据来源. 然而, 缺乏动作标签使得在策略学习中利用视频数据变得困难. 之前的作品通过使用视频预训的自我监督目标来解决这一问题. [?] 然而, 一个特征表示只描述当前的时间阶段的状态, 大大忽略了预测未来状态的过渡动态. [?] 然而, 学习控制视频预测模型带来了两个挑战. 首先, 视频预测任务通过对每个像素进行模型变化来避免任何抽象化, 将物理运动与纹理和照明等视觉外观相结合. 这种结合使得模型难以进行, 往往导致幻觉和不现实的未来预测 [?] 其次, 这些模型在训练和推理方面都具有计算要求. 由于计算资源有限, 性能显著下降. [?] 这种策略往往会导致不那么强.

在这篇论文中, 我们提出了一个新型和结构化的表现来

桥梁视频预训和策略学习. 我们首先将每个状态表现为视频框架中的一组点. (ATM) 将当前框架中的点的位置作为输入, 并输出它们的未来轨迹. 我们在摄像头坐标框架中预测这些轨迹, 以最大限度地降低校准摄像头的假设. 这些 2D 点轨迹与 3D 空间中的粒子轨迹相符, 它们是可以转移到不同的领域和任务的运动的普遍表示. 与视频预测方法相比, 基于粒子的轨迹建模提供了对物理动态的忠实抽象, 自然包含像对象永久性和连续运动这样的诱导偏见. 我们首先在无动作视频数据集上预训了轨迹模型. 预测的轨迹可以作为指导控制策略的子目标. 然后, 我们使用最小的动作标签示范数据训练轨迹指导的策略. [?] 我们在模拟和现实世界中评估的 130 多项语言定制任务中, ATM 在视频预训方面明显超过了各种强的基线, 实现了平均成功率 63% 与最高成功率相比, 37% 通过以前的方法, 标志着改善 80% 另外, 我们还证明了我们的方法能够从人类视频和不同形态的机器人视频中有效地转移学习.

- 1) 我们提出了任意点轨迹模型, 简单而创新的框架, 将视频预训与策略学习进行桥梁, 利用粒子轨迹的结构化表示.
- 2) 通过对模拟基准和现实世界进行广泛的实验, 我们证明了我们的方法可以有效地利用预训练中的视频数据, 并在模拟学习环境中显著优于各种视频预训基线.
- 3) 我们通过人体和机器人视频进行有效学习.

II. 相关工作

在学习端到端的视觉动力策略中, 该策略通常被定义为一个神经网络, 将图像观测作为输入表示 [???] 由于缺乏诱导偏见, 这些方法需要在大量的示范轨迹上进行培训, 而收集成本昂贵. [??] 网格 [??], 或神经 3D 表示 [??] 然而, 以前的结构往往将策略限制在特定任务上. 相反, 我们建议利用图像中的任意点的未来轨迹作为策略的额外输入, 对任务和环境做出最小的假设. 我们展示了其广泛应用于超过 130 个语言条件的操作任务. 在导航和运输中, 通常构建由机器人的未来轨迹指导的策略 [??] 在操纵中, 一些作品探讨了基于流量的指导 [???] 然而, 之前的研究只追踪了特定任务的点, 例如机器人的最终效应或人类的手. [?] 这种方法不是从数据中学习轨迹模型, 而是主要使用跟踪器进行测试时间的视觉服务. 这种设计选择需要更多的仪器, 例如将任务分为多个阶段, 预测每个阶段的目标位置, 并在推断时间运行跟踪器. 相反, 我们提出了一个更简单的框架, 使其在更多种设置中应用.

视频预训为控制. 视频包含有关行为和动态的丰富信息, 这可以帮助学习策略. 然而, 视频预训仍然是由于缺乏动作标签而具有挑战性. 一行作品首先学习了反动动态模型, 该模型从两个邻近的框架预测到行动, 然后将视频标记为伪行动 [????] 然而, 反动力学模型通常是在一个有限的动作标签数据集上训练的, 并没有很好地概括, 特别是对于连续行动. [???] 最近, 视频预测学习作为预训已经显示出了有前途的结果. [????] 在策略学习过程中, 使用视频预测模型生成未来的子目标, 然后可以学习目标条件的策略, 以达到子目标. 然而, 视频预测模型往往导致幻觉和不现实的物理运动. 此外, 视频模型需要广泛的计算, 这是一个问题, 特别是在推断时间. 相反, 我们的方法模型点的轨迹, 自然包含像对象持久性这样的诱导偏见, 同时需要

更少的计算. 这使我们的轨迹模型在策略执行过程中可以运行闭环. 此外, 轨迹为策略提供密集的指导.

特别有趣的是, 许多先前的著作提出了从人类视频的丰富来源中学习的建议. [?????] 然而, 这些作品往往明确地从人类视频中提取手姿势或接触区域, 从而损失了其余物体动态的信息. 相比之下, 我们的方法模拟了任意点的轨迹, 可以从人类视频和不同机器人的视频中学习.

III. 初步

在本论文中, 我们旨在从一个小组以动作标签的示范轨迹中学习强有力的控制策略. 我们的核心目标是利用更可扩展的, 未标签的视频作为预训的数据来源.

首先, 我们将无动作视频数据集表示为 $\mathcal{T}_o = \{(\tau_o^{(i)}, \ell^{(i)})\}_{i=1}^{N_o}$, 在哪里 $\ell^{(i)}$ 是语言教学. i^{th} 事件和 $\tau_o^{(i)} = \{o_t^{(i)}\}_{t=1}^T$ 同样, 我们也将示范数据集表示为 $\mathcal{T}_a = \{(\tau_a^{(i)}, \ell^{(i)})\}_{i=1}^{N_a}$, 在哪里 $\tau_a^{(i)} = \{o_t^{(i)}, a_t^{(i)}\}_{t=1}^T$ 在模仿学习过程中, 我们的目标是学习一种策略 π_θ 参数为 θ 通过以下行为克隆目标模仿专家行为:

$$\pi_\theta^* = \arg \min_{\theta} E_{(o_t, a_t, \ell) \sim \mathcal{T}_a} [\mathcal{L}(\pi_\theta(o_t, \ell), a_t)], \quad (1)$$

在哪里 $\mathcal{L}$ 是损失函数, 这可能是平均平方错误 (MSE) 或交叉熵损失.

视频跟踪的最新进展 [????] 在本文中, 我们使用了在视频框架中提议的现货跟踪器. [?] 根据视频的图像序列, $o_1, \dots, o_T$ 任何一个时间步骤 $t \in [1, T]$ 在这个框架中的一组点 $\{p_{t,k}\}_{k=1}^K$ 在哪里 $p_{t,k} = (x, y)$ 在相机框架中的点坐标, 跟踪任务是预测相应点的 2D 相机框架坐标. $p_{t,k}$ 在哪里 $t = 1 \dots T$ 在本文中, 我们用轨迹和跟踪术语交互地指向任何点的二维坐标序列, $(p_1, \dots, p_T)$ 我们只在摄像头框架中模拟 2D 轨迹, 这样我们就多视图摄像头或深度可用性不需要做额外的假设, 从而允许未来扩展到更多样的视频数据集. $v_{t,k}$ 表示点是否在步骤中被封闭 t .

IV. 方法

视频包含了大量关于世界的先前信息, 捕捉了物理动态, 人类行为和语义, [???] 通过视频, 我们将学习一个模型, 以预测未来的状态, 以指导控制策略. 通过这种方式, 我们可以基本上分解视觉运动策略学习挑战成两个部分. 第一部分是学习如何通过生成未来的状态作为具体的子目标, 仅仅是从视频中学习. 第二部分是学习预测控制行动, 以遵循子目标, 而这些行动需要训练的数据要少得多. 与学习策略结尾到结尾相比. 通过足够的视频预训练, 我们将能够从有限的动作标签轨迹中学习通用策略. [???] 虽然视频预测在训练和推断阶段都需要资源, 但其重点重建像素级细节, 这些细节往往与策略学习异常, 可对后续策略学习的效率产生负面影响.

我们提出任意点轨迹建模 (ATM) 如图所示 ??, ATM 是一个两个阶段的框架: 首先学习在视频框架中预测未来的点轨迹, 作为预训, 使用大规模的无动作视频, 然后使用预测的轨迹来指导策略学习, 使用少数拍摄的动作标签演示. ??我们首先描述如何从无动作视频数据集中学习一个点轨迹预测模型 $\mathcal{T}_o$. 然后在 Sec. ??我们将概述如何利用预训轨道预测模型来从有限的动作标签轨道数据集中学习轨迹引导的策略 $\mathcal{T}_a$.




Fig. 2: 我们的框架概述. (a) 在第一阶段, 由于无动作视频数据集, 我们首先在一个视频框架上采样 2D 点, 然后使用预训练的跟踪器跟踪整个视频的轨迹. 然后我们训练一个轨迹 Transformer 以预测当前的图像观测, 语言指令和点的初始位置. 对于变压器输入, 我们用隐藏值来取代未来的点位置. (2) 在第二阶段, 我们学习了轨迹引导的策略来预测控制行动. 预测的轨道的指导使我们能够从仅几项动作标签的示范中学习强大的策略.

A. 从视频数据集进行轨迹建模

我们的目标是从视频中预测未来点轨迹的模型. o_t 在时间的步伐上 t 图像框架上的任何 2D 查询点 $\mathbf{p}_t = \{p_{t,k}\}_{k=1}^K$, 以及语言教学. ℓ 我们学习一个模型. $\mathbf{p}_{t:t+H} = \tau_\theta(o_t, \mathbf{p}_t, \ell)$ 预测未来查询点的坐标 H 在相机框架中的步骤, $\mathbf{p}_{t:t+H} \in \mathbb{R}^{H \times K \times 2}$ 为了模拟轨道, 我们提出了轨迹 Transformer, ?? (a).

a) 自主监督轨道注释.: 我们从无动作视频中生成点轨迹, ??我们使用视觉跟踪器来预处理视频并生成跟踪数据集. $\bar{t}$ 随机取样点在这个框架上, 并通过运行跟踪器来生成它们的轨迹. 然而, 对于静态相机, 大多数随机取样点将在后台中, 因此在训练我们的轨迹 Transformer 时提供很少的信息. $n \times n$ 在框架上 $\bar{t}$ 在整个视频中追踪点的网格, 以获得最初的轨道集. $\tau \in \mathbb{R}^{n^2 \times T \times 2}$ 随后, 我们通过对时间的变化进行过, 过了视频期间没有移动的点, 在最后一步中, 我们重新样本了过的位置周围的点, 最后使用跟踪器生成了它们的位置.

b) 多动轨道建模.: 我们将未来预测问题正式化为一个多模式的掩盖预测问题: 我们的目标是预测每个点的未来位置, 根据其当前位置, 当前的图像观测和任务的语言指示. 我们首先将不同的模式编码到共享嵌入空间中, 每个模式由几个代币表示. 对于轨道, 我们在编码之前掩盖所有点的未来位置, 然后单独编码每个点成一个代币. [?] 我们将图像分为图像补丁, 50% 然后通过一个大型变压器模型传递所有代币. 最后, 我们将跟踪代币解码成相应点的未来轨迹. [?] 通过这个预训练过程, 我们的轨迹 Transformer 学习了视频框架内的粒子的前进运动.

B. 随轨指导的策略学习

在训练轨迹 Transformer 以根据观测预测未来轨道后, 我们可以学习这些预测轨道所引导的策略.

a) 随意追踪点.: 在轨迹 Transformer 预训练中, 我们可以在没有大动作的情况下过轨道. 然而, 使用这种论学需要知道每个点的未来位置, 这在策略推理过程中计算可能昂贵. 相反, 我们认为仅仅使用一个固定的 32 个点在网格上进行策略. 这种样本采集方法避免了学习关键点或找到跟踪点的潜在复杂性 [?] ATM 是对输入点数的变量不变的, 我们也发现 ATM 是对分数分布的强大,




Fig. 3: 鉴于目前的观察和预测的轨迹 Transformer 的预测, 我们从有限的示范数据集中训练了轨迹引导的策略.

b) 随轨指导的策略学习.: 一项以轨道为导向的策略 $\pi(a_t|o_t, p_{t:t+H})$ 接收了当前的观察 o_t 和预测的轨迹 $p_{t:t+H}$ 我们的策略架构的简单说明是如图所示. ??我们的变革策略架构跟随了以前的架构 [?] 虽然预测的轨道本身已经提供了丰富的信息来预测行动, 但我们仍然将文本图像观测纳入我们的策略, [?] 我们将轨道代币与图像代币 (早期融合和后期融合) 结合起来, 以确保轨道的指导信息可以有效地集成. 令人惊的是, 由于轨道已经提供了精细的子目标, 因此我们发现该策略不再需要语言指导作为任务规范. 基本上, 提供的轨道将困难的策略学习问题降低到更容易的子目标后的问题, 将该策略降低到反动态模型. 我们的轨迹引导策略是通过 MSE 损失训练的. 请注意, 我们的策略模型的重量是随机初始化而不是像其他视频训练方法一样从预训练的轨迹 Transformer 中复制. [?] 预测轨迹的任务指导能力的单独研究. 详细的架构图和超参数可在附件中找到.

V. 实验

我们进行了实验, 以回答以下问题:

- 如何与无动作视频学习的先进视频预训和行为克隆基线相比较?
- 可以使用 ATM 来从视频数据中学习, 而这些数据没有被分配到示范数据中吗?

我们的实验分为三个部分. ??通过电子游戏, 我们将 ATM 与视频预训的基线进行比较, ??最后, 我们将在第 2 条第 3 条中介绍了除结果. ??.

A. 视频预训练模仿学习

在 LIBERO 基准指标中, 我们对 100 多项语言操控操作任务进行了基线比较. [?] 基准分为五个套件, 即 LIBERO-Spatial, LIBERO-Object, LIBERO-Goal, LIBERO-Long 和 LIBERO-90. 每套件都有 10 个任务, 除了 LIBERO-90 包含 90 个任务. 每个任务都包含了专家人类示范. LIBERO-Spatial 包含具有相同的对象, 但不同布局的任务; LIBERO-Object 具有相同的布局, 但不同的对象的任务; LIBERO-Goal 具有相同的对象类别和空间布局, 但不同的目标; LIBERO-Long 具有多种对象类别和布局, 以及长视野任务的任务; LIBERO-90 具有极其多种的对象类别, 布局 and 任务.

我们将每个套件的基线单独进行比较. 10 动作标签示范轨迹 50 无动作视频演示轨迹, 为每项任务. 500 每个 10 任务套件的视频. 示范数据集包含来自第三方摄像头和手腕摄像头的 RGB 图像, 以及抓住器和关节状态作为观察. 由于每个任务是由语言指令指定的, 我们使用预训练的 BERT 网络来获得任务嵌入 [?] 图像分辨率是 128×128 而动作空间是 7 维, 代表终端效应器的转换, 旋转和开口.

我们将其与以下基线进行比较:

- 1) BC 表示尼拉行为克隆, 它仅使用有限的动作标签专家演示, 而不使用视频数据集训练一个策略. 它使用与 ATM 相同的策略架构, 除了粒子轨迹被掩盖为零, 而它取代语言嵌入为任务规范. BC 基线也可以被视为没有行动视频的策略学习的排放. 培训 BC 策略的具体架构和损失可能会有所不同. 我们使用 BC 来表示默认使用 MSE 损失训练的变压器策略, 并对比该部分末端与扩散策略分别.

- 2) R3M-细节 [?] 使用对比性学习目标, 使视频和语言与对比性时间损失结合起来, L_1 我们采用公开发布的 Ego4D 预训练权重, 并调整了我们在域内视频数据集中的权重. τ_0 . 在策略培训期间, 我们还进一步调整了 R3M 脊柱与行为克隆损失. 虽然这种方法通过演示学习捕获了无动作视频的先驱, 但视觉演示缺乏对决策至关重要的过渡动态的知识.
- 3) 其他类型 [?] 首先从动作标记轨迹中训练一个反动态模型 τ_a 通过这些伪标签, 一个策略然后训练行为克隆. 这种方法需要反动态模型是强大的输入观测分布, 这可能很难从有限的示范中学习.
- 4) 统一 [?] 在学习策略期间, UniPi 训练一个反动态模型, 使用动作标签数据. 我们基于 UniPi 的实现 [?] 虽然 UniPi 和 ATM 都利用以未来的子目标为条件的策略, 但轨迹表示将运动与其他基于像素的信息分离开来, 使策略学习更加容易. 请参阅附件, 我们将对 UniPi 的不同变化进行进一步全面的比较.

结果. 我们在图中介绍了主要的结果 ??我们看到, 通过将视频数据和策略学习与点轨迹的结构化表示联系起来, (我们的方法) 在视频预训方面明显超过了各种强的基线, 63% 与最高成功率相比, 37% 通过以前的方法, 标志着改善 80% 比较 BC 与 ATM 显示, 从额外的视频中学习为策略学习提供了有用的信息. VPT 表现不佳, 因为我们经验观察到, VPT 预测的伪动作标签通常显示出视频数据集的大错误. UniPi 失败于更复杂的, 因为视频预测模型没有物理的基础, 并且经常生成未来的框架, 不实质上可行, 例如机器人从图像中消失的情况. ATM 在长视线任务和需要理解目标的任务上表现出了惊人的优异性. 我们将这种表现归因于 ATM 的公式, 该公式利用明确的粒子轨迹作为子目标. 每次步骤, ATM 根据当前的观察预测未来的轨迹. 与其他方法所使用的静态自然语言指令相比, 这些方法在整个剧集中不会改变, ATM 的闭环未来轨迹提供了明确的指导, 说明该策略需要接下来做什么.

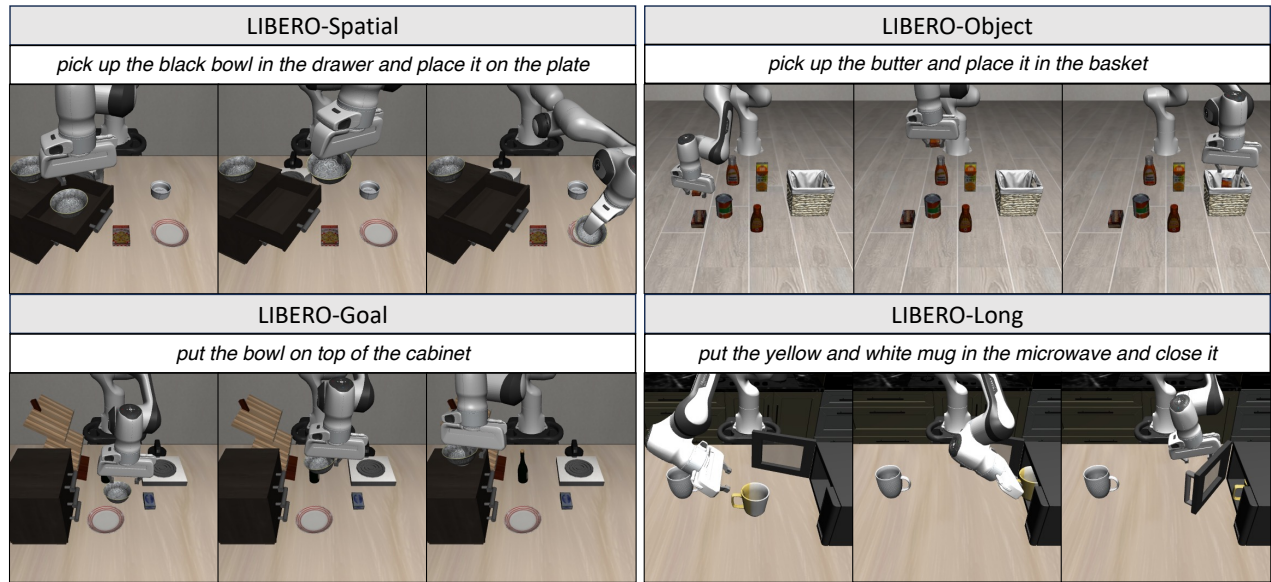
在不同的策略类别上, ATM 的普遍性. 预测轨迹的好处也可以用于流传策略等最先进的策略类别. [?], 如图所示 ??在这里, ATM 扩散策略将预测的未来轨道添加为策略类的额外条件, 同时保持其他一切相同. 我们看到 ATM 在所有套件中持续改善了扩散策略的性能, 在 LIBERO 基准上取得了最高分数. 更多详细信息可以在附件中找到.

我们在现实世界中进行了语言调节的操纵实验, 以进一步加强我们的声称. ??通过采用 GELLO 远程操作系统收集的人类专家示范, 我们学习了 6DOF UR5 机器人臂的策略 [?] 操作空间是联合位置控制和抓住状态. 观测包括两个 RealSense 摄像头的两个 RGB 图像. 为了弥补部分观测, 我们将最近的两个框架堆成代理的输入. 我们不会将自觉状态输入到代理中, 因为据报道, 仿真策略往往会过度适应它们并忽视视觉输入, 导致在线推广性能更糟. [?] 我们收集了总数 50 动作标签的轨迹 250 通过简单地从收集到的动作标签示范中删除行动 (无动作示范视频). ??我们看到, ATM 在 BC 和其他视频预训基线上表现得更好.

B. 人与机器人, 机器人与机器人转移

通过模拟低级任意点轨迹, ATM 可以从人类或执行任务的不同机器人的跨体视频中学习. 这使得更容易使用更可扩展的数据来源. 为了验证这一点, 我们在图中介绍了从人类视频中学习的结果. ??根据表表中的定量结果, ??在

(a) Visualization of the tasks in the LIBERO benchmark



(b) Comparison on the performance




Fig. 4: 在 LIBERO 基准指标中, 我们与最先进的视频预训练方法进行语言调控任务的比较 [?]。 (a) 可视化 LIBERO 任务分为四个套件, 重点关注空间推理, 对象推理, 任务理解和执行长视界任务中的操纵策略的不同方面。 (b) 进行不同套件的数量比较。 我们还将基线与包含 90 项任务的任务套件 (即 LIBERO-90) 的快速计算进行比较。ATM 在所有任务中优于基线, 并在 LIBERO-Goal 和 LIBERO-Long 中卓越。

TABLE I: 人与机器人实验的平均成功率。使用人类视频训练的 ATM 显著超过 BC 和仅使用 10 个机器人视频训练的 ATM, 这证明了 ATM 的跨具身能力。

方法	远程操作 演示	人类 视频	折叠布	放茄	扫除玩具
公元前	✓	✗	0%	10%	30%
银行票	✓	✗	0%	0%	13%
银行票	✓	✓	63%	63%	60%

Fig. ??我们将以下方法进行比较: (1) 仅使用动作标签的数据进行学习行为克隆策略 (2) ATM, 使用仅使用有限的动作标签的机器人数据训练的轨迹 Transformer, 以及 (3) ATM, 使用无动作的人类和无动作标签的机器人数据训练的轨迹 Transformer。实验表明, 在额外的跨体视频上训练轨道模型使轨道预测变得更加强和准确, 显著提高了策

略学习。另一方面, 由于动作标签的轨道数量很小, 只使用动作标签的轨道的 BC 基线失败。请参阅我们的网站上的视频以获得更好的可视化。

C. 废除分析

我们在模拟中进行了一系列的缩实验, 以证明我们的设计选择的影响。这些包括策略学习所需的动作标签轨迹数量, 轨迹预测视界的效果, 图像掩盖和后期轨迹融合。此外, 我们还研究了 ATM 的普遍性, 用于不同的策略模型。

我们研究了轨道长度对我们的策略输入的影响, 通过使用不同长度的预测轨道进行培训: 4, 8, 16, 32 和 64 步骤。如图所示 ??长度为 16 个轨道平均带来最佳性能。较小的轨道长度显著降低了性能, 而长度为 0 的轨道长度将 ATM 降低到行为克隆基线, 而没有预训练的任何好处。另一方面, 较大的轨道长度也可能对性能产生负面影响, 特别是在比利罗-长度和利比罗-目标等更具挑战性的任务上, 因为长轨预测对于实现短视野子目标来说是比较有噪音和不太

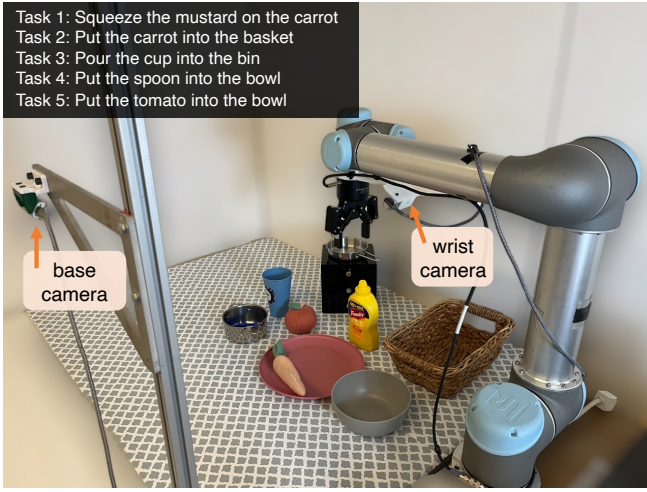


Fig. 5: 现实机器人实验在一个餐桌设置由五项任务组成. 左图显示了我们的现实世界设置和任务. 右上图显示了预测粒子轨迹和策略执行的一个例子, 紧随预测轨迹. 从量化结果, 我们可以看到 ATM 显示了显著的改善与最先进的视频预训练基线平均.




Fig. 6: 我们通过增加预测未来轨迹作为额外的条件来实施 ATM 扩散策略, 并在基准套件中显示了基本扩散策略的持续改善.

相关的. 确定子目标的最佳时间视野可能是未来研究的一个有趣的途径.

轨道长度效果. 我们的预训练轨迹 Transformer 的轨道长度为 16 个, 我们默认地使用每个轨道的 16 个点作为我们的策略输入. 在这个实验中, 我们通过训练我们的策略, 将预测轨道缩小成 4, 8 和 16 步骤来调查我们的策略输入的轨道长度效果. ?? 证明较长的轨道通常导致更高的成功率, 除了轨道长度的 LIBERO-Object = 8 减少轨道长度导致 LIBERO-Goal 和 LIBERO-Long 的性能下降更大. 这些任务需要全面了解任务目标. 较长的轨道为每个任务提供了更详细和具体的子目标, 这对于指导代理人的运动和行动在后期阶段至关重要. 相反, 对于 LIBERO-Object, 该项目强调了精确操作, 而不是理解任务目标, 一个长度 16 的策略与长度 8 的模型相比略低的性能. 我们假设, 较长的轨道可能会干扰由于噪音的反动态学习. 这也支持我们使用自然轨道作为反动态条件和利用反动态的方法.

TABLE III: Average success rates of real robot experiments over three random seeds.

Task instruction	BC	R3M-Finetune	VPT	ATM (Ours)
Squeeze the mustard on the carrot	0.83 ± 0.12	0.00 ± 0.00	0.00 ± 0.00	0.97 ± 0.06
Put the carrot into the basket	0.43 ± 0.38	0.00 ± 0.00	0.00 ± 0.00	0.90 ± 0.10
Pour the cup into the bin	0.93 ± 0.06	0.00 ± 0.00	0.00 ± 0.00	1.00 ± 0.00
Put the spoon into the bowl	0.23 ± 0.21	0.07 ± 0.12	0.00 ± 0.00	0.80 ± 0.10
Put the tomato into the bowl	0.47 ± 0.12	0.07 ± 0.06	0.03 ± 0.06	1.00 ± 0.00
Average	0.58 ± 0.18	0.03 ± 0.04	0.01 ± 0.01	0.93 ± 0.05

在轨迹 Transformer 中掩盖图像的效果. 训练轨迹 Transformer 时, 我们随机掩盖图像中的补丁, 并学习重建它们作为辅助任务. 我们通过删除图像掩盖损失并将其与我们的标准配置进行比较, 我们随机掩盖. 50% 图像面具. ?? 图像掩盖被遗漏时, 图像掩盖的性能略有下降, 这表明图像掩盖可能是一个有用的辅助任务, 除了 LIBERO-Space. 我们假设辅助损失鼓励模型共同推理图像观测的不同区域. 这种偏见可能对 LIBERO-Space 任务不至关重要, 因为对图像掩盖的特定空间位置已经完全指定在语言说明中 (例如, 所有任务都以“在 [某些空间位置] 上拿起黑碗”格式). 图像掩盖的功能在 LIBERO-SPACIAL 中可以被定义为:

早期和后期融合在策略架构的影响. ?? 预测的轨道在策略内变压器架构之前和之后都被输入到策略中, 我们分别称之为早期融合和后期融合. ?? 我们可以看到, 取消迟结导致性能下降; 在 LIBERO-目标上, 只有早期结的表现与其他基线相似, 而只有迟结的表现略低于我们的完整方法. 这表明, 预测的轨道的迟结作为有用的子目标, 帮助策略更好地理解多任务学习环境中的任务. 由于它在更大的视频数据集上训练, 因此子目标预测更强大.

VI. 限制

我们的方法仍然依赖于的一组被标记为行动的示范轨迹, 这限制了学习的策略的通用化. 未来的工作可以考虑使用增强学习学习学习轨迹后的策略, 以便不需要额外的示范数据. 我们的方法的另一个限制是, 我们在本文中使用的视频数据集仅含有小域空白. 从野生视频数据集中学习带来了多模式分布, 多种摄像头运动和低优势运动等额外的挑战. 我们将这些扩展留给未来的工作.

VII. 结论

在这项工作中, 我们将视频预训的任意点轨迹建模框架作为视频预训, 有效地从无动作视频数据集中学习行为和动态. 经过预训, 通过学习轨迹指导的策略, 我们证明了与以前的最先进方法相比的显著改进, 并展示了从未分发的人类视频中有效的学习. 我们表明, 基于粒子的表示可解



Fig. 7: 通过人类视频学习机器人技能. 我们收集了人类直接执行任务的 100 个视频和 10 个远程操作示范轨迹. 从上到下面的每一行都显示了人类视频的三个快照, 无人视频训练的 ATM 和人类视频训练的 ATM. 比较来说, 我们可以看到人类视频对于学习准确的轨迹预测至关重要, 并使策略能够成功执行任务.




Fig. 8: 在这里, 我们收集了 160 个无动作视频的 Franka 手臂和 10 个无动作标签的示范从一个 UR 手臂, 最终目标是学习一个 UR 策略. 我们比较一个尼拉 BC 基线与 ATM 训练使用数据类型: 仅使用 10 个 UR 视频, 仅使用 160 个 Franka 视频, 并使用 Franka 和 UR 视频 (Franka 视频) $\Rightarrow$ 在正确的图表中, 我们观察到, 额外的交叉具身数据导致了显著更好的结果. 令人惊的是, 即使轨迹模型仅使用 Franka 视频进行训练, 它表现出比 BC 没有 Franka 视频更好的性能.

释, 结构化, 并自然包含物体永久性等物理诱导偏见. 我们希望我们的作品将打开更多令人兴奋的方向从结构化表示的视频中学习.

VIII. 认可

这项工作部分由 BAIR 工业联盟, 以及香港特别行政区政府的 InnoHK 通过香港物流机器人中心支持. 这项工作也得到了中华人民共和国科学技术部的支持, 即 2030 年创新大项目. “新一代人工智能计划” (补贴号 2021AAA0150000), 以及国家关键 R&D 文在伯克利大学访问时完成这项工作.

TABLE II: 轨迹 Transformer 的图像掩饰的除研究, “在轨迹 Transformer 训练中, 我们不会掩盖图像补丁. “w/图像掩盖” 意味着我们随机掩盖 50% 我们可以看到, 轨迹 Transformer 中的面具图像建模提高了策略性能.

图像面具比例	空间	目标	目标	长时间
w/o 图像掩盖	69.17 ± 6.38	65.00 ± 3.89	74.33 ± 3.66	30.83 ± 11.43
w/图像掩盖 (默认)	68.50 ± 1.78	68.00 ± 6.18	77.83 ± 0.82	39.33 ± 15.80

TABLE III: 我们在两个位置探讨了被输入到策略中的轨道的影响: 变压器输入 (早期融合) 和 MLP 头 (后期融合), 如图所示 ??.

早期融合	后期融合	空间	目标	目标	长时间
✓	✗	44.67 ± 1.84	56.67 ± 3.09	5.33 ± 0.24	22.33 ± 4.94
✗	✓	65.50 ± 3.89	60.00 ± 1.47	72.83 ± 4.73	42.76 ± 14.62
✓	✓	68.50 ± 1.78	68.00 ± 6.18	77.83 ± 0.82	39.33 ± 15.80




Fig. 9: 我们的策略成功率%, 10% 和 20% 我们的策略训练只有 4 个% 与 BC 基线相比的表现% 在 Libero-Spatial, Object 和 Goal 上进行了演示, 甚至更好的是在 Libero-Spatial 上.% 我们的表现接近 BC, 所有的训练数据.




Fig. 10: 总体而言, 更长的轨迹长度提高了性能, 但在 16 后的效益往往会平稳.

A. 模拟实验

我们报告了 LIBERO 基准指数成功率数值在表中 ?? 所有方法都使用 20% 除了预言器外, ?? 关于 UniPi 和 UniPi-Replan 的详细的比较信息.

为了展示轨道如何引导该策略, 我们可视化 BC 的空间变压器和我们的方法中的空间 CLS 代币和 RGB 代币之间的注意力图. ?? 具体来说, 它在各自的示例任务中照顾奶油奶酪, 碗和葡萄酒瓶, 而 BC 通常被无关区域分散注意力, 突出了轨道的优越能力作为更好的任务提示.

B. 关于 UniPi 基线的讨论

统一 [?] 建议培训一个以语言为条件的视频传播模式 f_θ 在视频预训练期间. 在策略学习期间, o_0 和语言 l 首先, UniPi 生成了所有未来的框架. $\tilde{o}_1, \dots, \tilde{o}_{T-1} = f_\theta(o_0, l)$ 然后学习一个反向动态模型, $a_t = \pi(o_t, \tilde{o}_{t+1})$ 但是, 训练一个扩散模型预测完整的视频可能是计算密集的, [?] 我们预测的 $N = 7$ 未来的框架作为策略的子目标, 标志着 $\tilde{o}_1, \dots, \tilde{o}_N$ 在训练中, 我们均地抽样 N 在策略学习期间, 我们培训一个目标条件的策略 $\pi(a_t, \text{done}|o_t, \tilde{o}_i)$ 在哪里 $i \in 1, \dots, N$ 是图像的子目标和 t 该策略还预测完成的标志, 以确定该标志应该何时从当前的子目标中转移. $\tilde{o}_i$ 到下一个子目标 $\tilde{o}_{i+1}$ 机器人对 UniPi 的优势可以归因于两种原因. 第一, 机器人使用一个更结构化的点轨迹的子目标表示. 第二, 机器人执行闭环推理, 每一步都提出一个新的子目标, 而 UniPi 的视频传播过程太慢, 不能在每一步都引用.

TABLE IV: 计算成本和推断时间在 V100GPU 上的不同方法. ATM 执行轨迹生成, 而不是预测高维框架, 使其成为闭环控制的计算效率和可行性最高. UniPi 在开始时采用视频扩散模型来开放循环未来目标生成, 需要更高的计算资源. UniPi-Replan 使用较小的模型生成比 UniPi 少的框架, 从而产生了稍快的生成. 然而, 其在闭环控制中使用仍然是计算上的禁令.

计算	密切环节		开放循环 统一
	银行票	单一计划	
每一代的 TFLOPS	1.56	13.09	39.29
每一代的时间	0.015	4.51	8.14

为了训练 UniPi 策略, 我们采用样本. o_i 从未来的框架 o_t 在哪里 $t \in [t, t + t_{max}]$ 我们选择. t_{max} 对于每个任务组 ($t_{max} = 16$ 对于 LIBERO-Object 和 LIBERO-Spatial, $t_{max} = 50$ 为了减轻学习完成的标志时的数据集失衡, 我们采集了样本. o_i 作为下一个框架 10% 我们对这两项行动都进行了 MSE 回归. a_t 我们已经完成了.

为了分离 ATM 与 UniPi 的两个优势, 我们还将视频预测模型训练来预测未来的固定时间步骤. $\tilde{o}_{t+H} = f_\theta(o_t)$ 每个人的 H 策略执行的步骤 $H = 8$ 由于这种变化更频繁地重新规划子目标, 因此我们将这种方法称为 UniPi-Replan, 类似于 [?] 结果显示在表中. ?? 令人惊的是, 我们发现这种变化比 UniPi 更糟糕. 因此, 我们得出结论, 一个结构化的子目标表示可以比图像子目标更有效. 原因是, 在固定的未来时间步骤上预测一个图像目标可能是视频预测模型的困难目标, 导致不一致的子目标. 请参阅我们的网站

上各种基线的故障视频. 此外, 这种方法需要大量的计算. 需要的计算的比较在表中显示 ?? 由于计算成本, 我们只在 LIBERO-Object 和 LIBERO-Goal 上评估 UniPi-Replan,

C. 将 ATM 应用到传播策略中

除了从原本 LIBERO 论文中采用的变压器策略外, [?] 我们的 ATM 也可以与最先进的传播策略集成 [?] 具体来说, 我们通过使用预测轨道作为输入条件实施了 ATM 传播策略. % 在图中的实验的相同情况下, ??.

如表所示 ?? 尽管培训数据有限, 但标准的 LIBERO 基准策略取得了令人印象深刻的结果, 证明了其作为最先进的模仿策略的地位.

D. 人与机器人传输细节

为了展示 ATM 利用外域视频的潜力, 我们在三个不同的设置中设计了人到机器人传输任务: 1) 可变形的对象: 折叠布料并将其拉到右边, 2) 长视野: 将番茄放入子里, 关闭柜门, 3) 使用工具: 使用扫扫玩具进入子里, 将其放在子前. 我们收集了 10 个机器人传输轨迹 (动作标签) 和 100 个人类操纵视频比较 (无动作). 我们使用了三种方法: 1) 只有 10 个动作标签的机器人演示, 2) ATM, 训练轨迹 Transformer, 只有 10 个机器人演示, 3) ATM, 训练一个轨迹 Transformer, 使用无动作人类和无动作标签的机器人数据. ??.

人到机器人视觉化. 人到机器人技能转移的详细视频视觉化如图 ?? 由于训练样本有限, 只有 10 个机器人视频训练的轨迹 Transformer 无法预测未来的点轨迹, 导致成功率低. 相反, 使用人类视频训练的轨道模型在每个框架中产生高质量的轨迹, 引导代理完成任务, 只有 10 个动作标签的轨迹. 这表明我们的任何点轨道建模可以将前进的运动从跨体视频转移到机器人技能, 这显著改善了策略学习.

我们还可以在图中看到训练有素的人类视频或没有的人类视频的轨道变换器的注意力地图 ?? 轨迹 Transformer 使用人视频训练 (下行) 显示了精确的注意力热图, 主要集中在对象和机器人臂上. 相反, 没有人视频训练的模型的注意力地图 (中行) 更加分散, 通常不准确地集中在背景区域. 这种比较突出了我们的 ATM 在利用人类视频的先进知识的有效性, 从而促进了成功的跨体模仿学习.

APPENDIX B 实施细节

A. 策略架构

我们包括了 ViT-T 的更详细的视图. [?] 在我们的实验中使用的策略 ?? 我们的策略中输入是多个视图中的暂时堆叠图像. $o_t \in \mathbb{R}^{V \times T \times C \times H \times W}$, 和自覚 $p_t \in \mathbb{R}^{D_p}$ 为了处理这些输入, ViT-T 由三个阶段组成:

空间编码: 我们在每个时间步骤中编码所有模式. 我们首先利用结的轨迹 Transformer 为所有人提出一套轨道 V 中的 o_t 然后我们将每个模式进行投影, 使用特定模式的编码器, $\mathbb{R}^D$. 每个模式的代币使用共享的学习模式代币和特定模式的位置嵌入嵌入. 然后我们将代币连接到所有模式和视图中使用学习的空间 CLS 代币, 并对序列进行自我注意. 我们将空间 CLS 代币作为表示.




Fig. 11: 空间变压器中的 BC 和我们的注意力地图. 我们提取了空间 CLS 代币和 RGB 代币之间的注意力权重, 突出了策略的关注特定空间区域的决策过程中. 热地图显示了我们的策略的针对性关注任务相关领域, 而 BC 倾向于关注不相关的背景. 这突出了空间变压器中的输入轨道作为好任务提示的有效性, 引导 CLS 代币进入适当领域.

TABLE V: 在 LIBERO 基准上平均成功率. 我们的方法在所有套件中比所有基线都保持更好的表现. 由于计算成本, UniPi-Replan 仅被评估为单个种子.

方法	自由空间	自由对象	自由目标	自由长期	利贝罗-90
预测时间:	71.83 $\pm$ 3.70	71.00 $\pm$ 7.97	76.33 $\pm$ 1.31	24.17 $\pm$ 2.59	-
公元前	39.00 $\pm$ 8.20	51.83 $\pm$ 13.54	42.50 $\pm$ 4.95	16.67 $\pm$ 3.66	29.78 $\pm$ 1.14
R3M-细节 [?]	49.17 $\pm$ 3.79	52.83 $\pm$ 2.25	5.33 $\pm$ 1.43	9.17 $\pm$ 2.66	9.59 $\pm$ 0.27
其他类型 [?]	37.83 $\pm$ 4.29	19.50 $\pm$ 0.82	3.33 $\pm$ 2.36	3.83 $\pm$ 1.65	-
统一 [??]	69.17 $\pm$ 3.75	59.83 $\pm$ 3.01	11.83 $\pm$ 2.02	5.83 $\pm$ 2.08	-
单皮备案 [?]	-	31.00	3.00	-	-
银行卡 (我们的)	68.50 $\pm$ 1.78	68.00 $\pm$ 6.18	77.83 $\pm$ 0.82	39.33 $\pm$ 15.80	48.41 $\pm$ 2.09

TABLE VI: 我们的方法可以进一步改进这种策略, 这表明我们的任意点轨迹建模框架是适用于任何策略模型的重要基石.

方法	自由空间	自由对象	自由目标	自由长期	利贝罗-90
传播策略	67.67 $\pm$ 1.25	78.00 $\pm$ 2.45	35.00 $\pm$ 3.74	37.33 $\pm$ 2.05	33.85 $\pm$ 1.71
银行票流通策略	79.00 $\pm$ 3.74	81.00 $\pm$ 2.45	58.67 $\pm$ 4.64	44.00 $\pm$ 6.38	62.89 $\pm$ 1.10

时间解码: 我们将编码的模式跨时间步骤进行处理, 首先将每个时间步骤的自觉感应投射到同一共享嵌入空间中. $\mathbb{R}^D$ 然后我们将编码的自觉感知, 空间 CLS 标记和学习的行动 CLS 标记交叉时间步骤, 然后在序列之间进行因果化伪装的自我注意.

行动头: 我们独立处理每个时间步骤的输出, 并使用 MLP 对操作进行参数化.

B. 用点过进行有效训练

我们采用一个论法来过背景中的静态点, 然后使用现行跟踪模型来生成大运动点的相应轨迹. ??.

C. 培训细节

我们列出了轨迹 Transformer 的训练超参数和轨迹引导策略 ?? 其他 ?? 我们训练所有模型使用 4 个 A100GPU, 我们训练了轨迹 Transformer 使用 CoTracker 生成的地面真相轨道 [?] 我们不包括轨迹 Transformer 的框架堆, 以避免因果混乱 [?].

我们利用 LIBERO 提供的专家示范培训策略, [?] 由于行为克隆的验证损失并不总是可靠的,




Fig. 12: 为了总结空间信息, 我们执行自我注意力, 包括所有视图的轨迹和图像补丁和 CLS 标记. 为了整合信息, 我们执行随机自我注意力, 在空间 CLS 标记, 自觉感知和每个时间步骤的行动 CLS 标记之间. 为了退回行动, 我们将每个时间步骤的行动 CLS 标记和建议的轨迹连接.

TABLE VII: 轨迹 Transformer 训练的超参数.

超参数	轨迹 Transformer
时代	100
批量量	1024
优化器	亚当 W
学习率	1e-4
体重衰减	1e-4
时间表	科西斯
让你变暖.	5
片类	10
点采样	变量过
积分数量	32
轨道长度	16
轨道补丁尺寸	4
图像面具比例	0.5
增长	颜色发射器, 随机转换

TABLE VIII: 策略培训的超级参数.

超参数	策略
时代	100
批量量	512
优化器	亚当 W
学习率	5e-4
体重衰减	1e-4
时间表	科西斯
让你变暖.	0
片类	100
点采样	电网
积分数量	32
轨道长度	16
框架堆	10
增长	颜色发射器, 随机转换




Fig. 13: 视频 (左) 显示时, 我们采用现有 TAP 模型 (中部) 查询 1000 个随机抽样点, 每个颜色点都代表了轨道的起始位置. 然后我们通过视频中位置移动的选, 重新抽样这些点 (右). 我们可以看到提取的轨道集中在信息对象, 如机器人的抓住器和操纵目标.






Fig. 14: 随着人类视频的训练和没有人类视频的轨道变换器的注意力地图。包括大规模的人类视频导致了更清晰的注意力地图，专注于对象和机器人手臂，而没有人类视频的训练将关注错误的区域，如背景墙壁。

fold the cloth and pull it to the right



put the tomato into the pan and close the cabinet door



use the broom to sweep the toys into the dustpan and put it in front of the dustpan




Fig. 15: 我们可以看到 ATM 能够利用域外视频, 即人类视频, 产生更精确的轨道, 从而提高策略性能.